

Auto Encoder によるデータ多様体抽出仮説の 理論的・実験的検証に関する研究計画

1 研究背景

深層学習が高次元データに対して高い性能を示す背景の一つとして、多様体仮説が広く受け入れられている。すなわち、画像や音声のような高次元観測データは、実際には周囲空間全体に一様に分布しているのではなく、より低次元の滑らかな非線形多様体の近傍に集中している、という考え方である。現在の研究では、この考えに基づき、PCA や Auto Encoder を用いた次元削減を通して、入力データの本質的な構造を低次元空間に写像できるかどうかを検討している。特に、これまでの検討では、PCA によって得られた次元数や累積寄与率に対応する次元数を基準とし、Auto Encoder で低次元表現を学習し、その表現の妥当性を分類精度や再構成性能により評価してきた。

一方で、この枠組みには明確な限界がある。分類精度が高いことは「下流タスクに有効な特徴が得られた」ことを示すにとどまり、それだけでは「Auto Encoder が本当にデータ多様体そのものを抽出した」とは言えない。このため近年の検討では、TwoNN や MLE などの内在次元推定法を用いてデータの内在次元を見積もり、さらに VAE において AU や CKA を用いて実用上の最適潜在次元を求め、両者の関係を調べる方向へ発展している。そこでは概ね

$$\hat{d}_z^* \approx \hat{d}_{ID} \quad \text{あるいは} \quad \hat{d}_z^* \lesssim \hat{d}_{ID}$$

という経験的關係が観測されている。

さらに、VAE の潜在空間における内在次元は入力空間の内在次元より小さく収束しやすく、ボトルネックを過大に設定すると再構成誤差がむしろ悪化する場合があることも示唆されている。これは、生成モデルが単に入力を圧縮しているのではなく、冗長性やノイズを捨てながら、より本質的な自由度へ情報を集約している可能性を示している。

したがって、今後の論文化においては、「分類性能が良い次元数を探した」という段階から進み、「Auto Encoder はデータ多様体のどの性質を、どの程度保存・抽出しているのか」を理論的・実験的に検証する段階へ移る必要がある。

2 研究目的

本研究の目的は、高次元データに潜在する低次元多様体構造に対して、Auto Encoder が学習する潜在表現がどのような意味でその多様体を反映しているのかを、理論と実験の両面から明らかにすることである。

より具体的には、第一に、データの内在次元と Auto Encoder の潜在次元との関係を整理し、潜在次元の適切な設定に関する理論的指針を与えることを目的とする。第二に、再構成誤差や分類精度だけでなく、近傍構造、接空間構造、距離歪み、潜在空間の有効自由度などを用いて、Auto Encoder が学習した表現が元のデー

タ多様体の幾何学的・位相的性質をどの程度保存しているかを定量的に検証する．第三に，これらの結果を通じて，深層学習モデルにおけるボトルネック次元設計を経験則ではなく，内在次元や多様体構造に基づいて説明可能なものへと発展させることを目指す．

3 理論仮説

本研究では，以下の理論仮説を置く．

3.1 仮説 1：内在次元整合性仮説

入力データが d 次元多様体 $M \subset \mathbb{R}^N$ の近傍に分布しているとき，十分に学習された Auto Encoder の潜在表現は，その多様体の本質的自由度に対応する次元数を用いて情報を表現する．したがって，実用上有効な潜在次元 d_z^* は，入力データの内在次元 d_{ID} に近い値，またはそれよりわずかに小さい値になると予想される．

3.2 仮説 2：局所構造保存仮説

Auto Encoder が単に再構成誤差を小さくしているのではなく，多様体を適切に学習しているならば，入力空間における近傍関係は潜在空間でも大きく壊れないはずである．すなわち，元空間で近いサンプル同士は潜在空間でも近く，元空間で離れたサンプル同士は潜在空間でも相対的に離れていることが期待される．これは，近傍保存率や測地距離歪みの小ささとして検証できる．

3.3 仮説 3：接空間保存仮説

多様体の本質は点集合そのものだけでなく，各点の近傍でどの方向に変化しうるかという局所線形構造，すなわち接空間にある．したがって，Auto Encoder が真に多様体を抽出しているならば，エンコーダとデコーダのヤコビアン合成

$$J_D(E(x))J_E(x)$$

は，多様体上の接空間に沿った方向を保ち，法線方向やノイズ方向を抑制するはずである．

3.4 仮説 4：過大ボトルネック冗長性仮説

潜在次元を内在次元より過大に設定しても，有効に使用される自由度は飽和し，それ以上の次元は不活性化するか，あるいはノイズの記憶に使われる．このため，AU や CKA は飽和し，場合によっては再構成誤差や汎化性能が悪化する．

4 定理候補

以下は，論文中で直ちに「証明済みの定理」として主張するのではなく，まずは理論的に示すべき命題・定理候補として位置付ける．

4.1 定理候補 1：完全再構成に必要な潜在次元の下界

$\mathcal{M}$ を d 次元滑らかな多様体とし，エンコーダ $E: \mathbb{R}^N \rightarrow \mathbb{R}^m$ ，デコーダ $D: \mathbb{R}^m \rightarrow \mathbb{R}^N$ が多様体上で

$$D(E(x)) = x \quad (\forall x \in \mathcal{M})$$

を満たし，かつ $E|_{\mathcal{M}}$ が連続かつ単射であるとする．このとき，潜在次元 m は少なくとも多様体次元 d 以上でなければならない．

この定理候補の意味は，Auto Encoder が多様体上の情報を損失なく埋め込むためには，潜在空間の次元が多様体の自由度より小さくならない，という必要条件を与える点にある．これにより，内在次元推定値はボトルネック次元の下界として解釈できる．

4.2 定理候補 2：小再構成誤差と小ヤコビアン誤差からの局所構造保存

多様体 $\mathcal{M}$ 上で

$$\|D(E(x)) - x\|$$

が十分小さく，さらに

$$J_D(E(x))J_E(x)$$

が接空間上で恒等写像に近いならば，エンコーダ E は多様体上の局所近傍構造を近似的に保存する．したがって，潜在空間における局所距離と元空間における局所距離の比は 1 に近くなる．

これは，「再構成できる」だけではなく，「局所幾何も壊していない」ことを示すための理論的土台になる．

4.3 定理候補 3：最適潜在次元と内在次元の一致・近接

データが低ノイズの d 次元多様体近傍に分布し，Auto Encoder または VAE が十分に学習され，かつモデル容量が適切であるとき，再構成性能と有効潜在次元の両面から定まる実用上の最適潜在次元 d_z^* は，内在次元 d_{ID} と同程度，あるいはそれよりやや小さい範囲に入る．

この主張は現段階では実験的仮説に近いが，現在の知見からみて理論的に最も重要な候補命題の一つである．

4.4 定理候補 4：過大容量時の不活性次元出現

潜在次元 m を真の多様体次元より十分大きく設定した場合，適切な正則化の下では，追加された次元の多くは不活性となるか，再構成に本質的でない冗長自由度として振る舞う．このため，有効自由度の数は飽和し，AU の増加は頭打ちになる．

これは，AU の飽和や CKA のプラトーを理論的に説明する候補命題である．

5 実験計画

5.1 1. 人工多様体データによる基礎検証

まず，真の多様体次元が既知である人工データを用いて，Auto Encoder が多様体をどの程度保存するかを検証する．具体的には，Swiss roll, S-curve, two moons, sphere, torus, 線形部分空間，多様体に法線方向

ノイズを加えたデータなどを用いる。

この実験では、PCA, TwoNN, MLE, DANCo, ESS などの推定器の精度・安定性・計算コストを比較し、真の次元に対して信頼できる推定器を選定する。また、評価指標としては、再構成誤差だけでなく、近傍保存率、測地距離歪み、接空間の主角、ヤコビアン特異値分布、推定内在次元、必要に応じて persistent homology による Betti 数の保存などを用いる。これにより、「うまく再構成した」と「多様体構造を保持した」ことを分離して評価する。

5.2 2. MNIST に対する実データ検証

次に、これまで最も実験蓄積のある MNIST を用いて、実データ上で理論仮説を検証する。ここでは、ボトルネック次元を

$$d_z < d_{ID}, \quad d_z \approx d_{ID}, \quad d_z > d_{ID}$$

の 3 群に分け、各条件で再構成誤差, AU, CKA, 潜在空間の内在次元, 近傍保存率, 線形分類精度を比較する。これにより、「分類精度が高いから良い表現」という従来の見方を超えて、「多様体構造をどの程度保ったか」で各条件を比較できるようにする。

5.3 3. モデル構造差の検証

次に、FC-AE, Conv-AE, VAE, β -VAE, 必要であれば Denoising AE や Contractive AE を比較し、構造や正則化の違いが多様体保存に与える影響を調べる。特に、KL 項や収縮項を導入したモデルでは、局所構造保存やノイズ方向抑制がより明確に現れる可能性がある。

5.4 4. 複雑データへの一般化検証

MNIST のみでは一般性が不十分であるため、Fashion-MNIST, CIFAR-10, 可能であれば CelebA へと実験を拡張する。特に CIFAR-10 については、現時点のモデルでは表現力不足やチャネル間構造の扱いが課題となる可能性があるため、より表現力の高いモデルやチャネルごとの解析も視野に入れる。

5.5 5. 学習過程の動的解析

最後に、学習後の一点評価だけではなく、学習途中の各 epoch で潜在空間の内在次元, AU, CKA, 再構成誤差, ヤコビアン特性を追跡する。これにより、Auto Encoder が学習初期に大域構造を合わせ、後半で局所構造を整えていくのか、あるいは逆なのかを明らかにする。

6 まとめとしての主張案

以上を踏まえると、本研究の中心的主張は次のように整理できる。

本研究では、Auto Encoder が高次元データを単に圧縮しているのではなく、データに潜在する低次元多様体の自由度を反映した潜在表現を学習している、という仮説を検証する。そのために、内在次元推定, 近傍構造保存, 接空間保存, 有効潜在次元, 再構成性能を統合的に評価する枠組みを構築する。これにより、潜在次元設計を経験的探索から脱却させ、データ多様体の性質に基づく理論的指針へと発展させることを目指す。