

オートエンコーダによるデータ多様体抽出の理論的検証および実験的評価に関する包括的研究

序論

深層学習における表現学習の成功は、高次元空間に存在する実世界のデータが、実際にははるかに低次元の非線形多様体（データ多様体）上またはその近傍に分布しているという「多様体仮説（Manifold Hypothesis）」に大きく依存している¹。この仮説に基づき、オートエンコーダ（Autoencoder: AE）や変分オートエンコーダ（VAE）などの深層生成モデルは、高次元の入力空間から低次元の潜在空間への非線形写像を獲得し、データの本質的な特徴量を抽出することが期待されている¹。

これまでの研究において、主成分分析（PCA）のような線形手法とオートエンコーダを比較し、MNISTやCIFAR-10といった画像データセットを用いた次元削減の有効性が実験的に示されてきた¹。また、自閉スペクトラム症（ASD）の機能的MRI（fMRI）データに対して3次元量み込みオートエンコーダを適用し、脳機能の表現構造の連続的な違いを潜在空間上で可視化する試みも行われている¹。しかしながら、これらの既存研究は分類精度や平均二乗誤差（MSE）に基づく再構成誤差の評価を中心とした経験的・実験的なアプローチに留まっており、抽出された潜在空間が元のデータ多様体の幾何学的（Geometric）および位相的（Topological）性質を真に保持していることの理論的根拠としては不十分である¹。

十分な表現力を持つニューラルネットワークは、潜在空間が幾何学的に大きく歪んでいても再構成誤差を最小化することが可能であり、これは「多様体の過学習（Manifold Overfitting）」と呼ばれる現象を引き起こす¹。したがって、オートエンコーダがデータに含まれる多様体の特徴量として正確に抽出しているという仮説を論文として強固に主張するためには、経験的な分類精度への依存から脱却し、微分幾何学、位相的データ解析（TDA）、および情報理論に基づく厳密な理論的検証と、それらを裏付ける精緻な実験設計が不可欠である。本報告書では、この仮説を理論的に検証するための多角的なアプローチと、論文の説得力を飛躍的に高めるための具体的な実験計画を包括的に提示する。

多様体抽出の理論的根拠：微分幾何学的アプローチ

オートエンコーダが多様体を学習するプロセスを数学的に定式化するためには、データの局所的な曲率や計量（Metric）を扱う微分幾何学の枠組みを導入することが最も有効なアプローチの一つである。

ヤコビアンと接空間の推定

オートエンコーダは、エンコーダ $f_{\theta} : \mathbb{R}^D \rightarrow \mathbb{R}^d$ とデコーダ $g_{\phi} : \mathbb{R}^d \rightarrow \mathbb{R}^D$ （ここで $d \ll D$ ）

の合成関数として定義される。微分幾何学的な視点において、デコーダ g_ϕ の像は高次元のアンビエント空間 $\mathbb{R}^D$ 内に埋め込まれた d 次元の再構成多様体 $\mathcal{M}$ を形成する³。この多様体の局所的な構造は、デコーダのヤコビアン行列 (Jacobian Matrix) $J_g \in \mathbb{R}^{D \times d}$ によって記述される。具体的には、潜在空間の点 z におけるヤコビアン $J_g(z)$ の列ベクトルは、再構成多様体上の接空間 (Tangent Space) $T_{g(z)}\mathcal{M}$ を張る基底を形成する³。

オートエンコーダがデータの多様体を正確に抽出していることを証明するためには、このデコーダが生成する接空間が、真のデータ多様体の接空間と一致することを示す必要がある。理論的には、定数階数定理 (Constant Rank Theorem) を応用することで、オートエンコーダのヤコビアンが学習

データ領域の至る所で常に階数 d を持つよう制約された場合、その写像の像が厳密に d 次元の多様体構造を持つことが数学的に保証される⁵。この定理は、ネットワークの構造と正則化によって次元削減が達成されることの強力な理論的裏付けとなる。

プルバック計量と等長埋め込み

潜在空間における距離や角度が、元の高次元空間においてどのように解釈されるかを測るために、プルバック計量 (Pullback Metric) $g^* = J_g^T J_g \in \mathbb{R}^{d \times d}$ が導入される³。この計量テンソルは、低次元空間における微小な変位が、高次元の再構成多様体上でどれほどの距離に相当するかを規定する。理論上、プルバック計量が単位行列に比例する場合、その写像は等長埋め込み (Isometric Embedding) に近い性質を持ち、潜在空間でのユークリッド距離がデータ多様体上の測地線距離 (Geodesic Distance) を忠実に近似していることの証明となる³。

逆に、再構成誤差が十分に低くても、ヤコビアン行列の特異値に極端な偏りがある場合、潜在空間は特定の方向に不自然に引き伸ばされたり圧縮されたりしていることを意味する。これを防ぐための理論的アプローチとして、収縮オートエンコーダ (Contractive Autoencoder: CAE) のようにエンコーダのヤコビアンのフロベニウスノルムを罰則化する手法や、デコーダのヤコビアンの分散を最小化する幾何学的正則化 (Geometric Regularization) が提案されている³。論文においては、単なる再構成誤差の最小化だけでなく、これらの幾何学的な正則化項がデータ多様体の局所的な平坦性 (Flatness) を保持するメカニズムを数式を用いて説明することが求められる。

スコアマッチングとノイズ除去の理論的關係

オートエンコーダが多様体上の座標系を学習していることのもう一つの理論的根拠は、AlainとBengioによるスコアマッチングの理論に基づく¹⁰。デノイジングオートエンコーダ (Denoising Autoencoder) のように、データに微小なノイズを加えた上で元のデータを再構成するように学習させた場合、再構成関数はデータ生成分布の対数尤度の勾配 (スコア関数) に比例するベクトル場を形成することが証明されている¹¹。これは、オートエンコーダがデータを多様体の表面 (高密度領域) に引き戻す直交射影の力学系を学習していることを意味し、多様体仮説を支持する極めて重要な理論

的証拠である。

多様体抽出の理論的根拠: 位相的データ解析とホモロジー

微分幾何学が多様体の局所的な滑らかさや接空間を保証する一方で、データが持つクラスターの数やループ構造といった「大域的な構造」が潜在空間において保持されているかを理論的に検証するためには、位相的データ解析 (Topological Data Analysis: TDA) の枠組みが必要となる¹²。

パーシステントホモロジーによる位相的特徴の抽出

データ空間における点群と、オートエンコーダによって写像された潜在空間における点群のそれぞれに対して、位相的特徴を計算する。具体的には、各データ点を中心とする半径 ϵ の球を考え、その半径を徐々に拡大していく過程で形成されるヴィエトリス・リップス複体 (Vietoris-Rips Complex) を構成する¹⁴。このフィルトレーションの過程で、連結成分 (0次のベッチ数) やループ (1次のベッチ数)、空洞 (2次のベッチ数) といったトポロジックな特徴が誕生し消滅する様子を追跡する手法がパーシステントホモロジー (Persistent Homology) である¹³。

これらの特徴の誕生と消滅のタイミングは、パーシステンス図 (Persistence Diagram) として二次元平面上にプロットされる。オートエンコーダがデータ多様体の位相構造を破壊せずに抽出しているという仮説は、入力データ空間のパーシステンス図と、潜在空間のパーシステンス図が位相的に等価であることを示すことで理論的に定式化される。

ワッサースタイン距離と表現位相発散 (RTD)

二つのパーシステンス図の間の類似性を定量的に評価するための数学的尺度として、ワッサースタイン距離 (Wasserstein Distance) が用いられる¹²。理論的検証においては、高次元データと潜在表現の間の位相的差異を最小化するための指標である表現位相発散 (Representation Topology Divergence: RTD) を導入するアプローチが極めて有効である¹²。

オートエンコーダが単にデータの分散を保持する (PCA的なアプローチ) だけでなく、RTDを最小化するような連続写像を学習していることを示すことで、モデルが入力空間のトポロジーを潜在空間へ正確に転写していることの厳密な理論的裏付けとなる。これにより、例えばfMRIデータにおいてASD患者特有の脳機能ネットワークの連結性やクラスター構造が、次元削減後もアーティファクト (偽の特徴) として歪められることなく保持されていることを数学的に証明できる¹。

多様体抽出の理論的根拠: 情報理論とレート歪み理論

多様体の次元数とオートエンコーダのボトルネック次元の最適な関係性を理論的に説明するためには、情報ボトルネック (Information Bottleneck: IB) 理論およびレート歪み理論 (Rate-Distortion Theory) が強力な枠組みを提供する¹⁹。

情報ボトルネック理論に基づく多様体の圧縮

IB理論によれば、深層学習モデルは入力 X に対する圧縮表現 Z を獲得する際、入力との相互情報量 $I(X; Z)$ を最小化(圧縮)しつつ、目的変数との相互情報量 $I(Z; Y)$ を最大化するように最適化される¹⁹。これを自己教師あり学習であるオートエンコーダの枠組みに適用すると、モデルは再構成に必要な情報(Distortionの最小化)を維持しながら、潜在表現の複雑さ(Rateの最小化)を抑えるレート歪み最適化問題として定式化される²²。

多様体仮説に従えば、高次元データは低次元の多様体上に集中しているため、データの本質的な情報量はその内在次元(Intrinsic Dimension: ID)に依存する。情報理論的観点からは、ボトルネック次元 d_z を多様体の内在次元 d_{ID} と一致させた場合に、最も効率的な圧縮(不要な直交方向のノイズ分散の排除)と無損失に近い再構成が両立することが示唆される¹。この理論は、過剰な潜在次元がノイズの記憶(多様体の過学習)を招き、過小な潜在次元が情報の欠落(アンダーフィッティング)を招くという経験的観察¹を数学的に説明するものである。

論文構築のための具体的な理論検証アプローチの提案

これまでに述べた微分幾何学、位相的データ解析、および情報理論を統合し、現在の「実験中心で理論的根拠が弱い」という論文の課題を解決するためには、論文の理論構成を以下のアプローチで再構築すべきである。

1. 多様体埋め込みの数学的定義の明記:

論文の冒頭で、オートエンコーダのデコーダを $\mathbb{R}^D$ への滑らかな埋め込み(Immersion)として定義し、そのヤコビアン J_g によって接空間が定義されることを明記する。これにより、モデルが暗黙的に多様体を構築しているという幾何学的前提を読者に提示する。

2. スコアマッチングに基づく特徴抽出の理論的関連付け: 再構成誤差の最小化(特にノイズを伴う場合)が、データ生成分布の対数尤度の勾配を学習することと等価であるというAlainとBengioの定理¹¹を引用する。これにより、AEが抽出する特徴量が単なるピクセルの圧縮ではなく、データ多様体への直交射影ベクトルであることを理論的に主張する。
3. ボトルネック次元と内在次元の理論的境界の提示: 情報ボトルネック理論を引き合いに出し、

ロスレスな表現獲得のためには潜在次元 d_z がデータの内在次元 d_{ID} 以上である必要があるが、KLダイバージェンスなどの正則化やデコーダの非線形性により、実際には $d_z^* \leq d_{ID}$ の範囲で最適な圧縮が行われるという理論的仮説を展開する¹。

理論を裏付けるための実験的検討アプローチの提案

上述の理論的仮説が実際にモデル内で機能していることを証明するためには、分類精度による間接的な評価だけでなく、潜在空間の幾何学的・位相的性質を直接的に測定する実験プロトコルが必要である。以下に、論文の説得力を飛躍的に高めるための4つの高度な実験設計を提案する。

実験1: 合成多様体を用いた接空間と測地線の可視化検証

実データ(画像やfMRI)では真の多様体構造(Ground Truth)が未知であるため、理論の正確な検証が困難である。そのため、まずは構造が完全に既知の合成低次元多様体(Synthetic Manifolds)を用いた評価実験を行うべきである¹。

実験設計としては、3次元空間に埋め込まれたスイスロール(Swiss Roll)、Sカーブ、連結トーラス(Linked Tori)、あるいは高次元に埋め込まれた球面(Nested Spheres)をデータセットとして生成する²⁷。これらのデータに対してオートエンコーダを学習させ、潜在空間の分布を分析する。

ここで重要なのは、多様体上の2点間を結ぶ「測地線(Geodesic)」を計算し、潜在空間においてその測地線が直線の補間(Linear Interpolation)として表現されているかを確認することである²⁹。理論的にオートエンコーダが多様体を「平坦化(Flattening)」して抽出することに成功していれば、高次元空間における曲線的な移動が、潜在空間では直線的な移動と等価になる。この幾何学的な対応関係を視覚的かつ定量的に示すことで、AEが多様体座標系を獲得しているという理論の直接的な証明となる。

実験2: 非線形な内在次元(ID)推定と潜在次元の比較評価

提供された資料¹では、PCAを用いた累積寄与率によって次元を推定しているが、PCAは線形空間への射影に基づくため、高度に非線形な多様体の次元を極端に過大評価する傾向がある¹。多様体仮説を厳密に検証するためには、局所的な非線形構造を捉える高度な内在次元(ID)推定アルゴリズムを導入する必要がある。

以下の表に、実験に導入すべき主要な内在次元推定手法と、それぞれの特性を整理する。

推定手法 (ID Estimator)	理論的背景と計算手法	論文における適用目的と利点
TwoNN ¹	第1近傍点と第2近傍点の距離比の分布に基づき、局所的な次元を推定する。	ノイズに対して極めて頑健であり、非線形多様体の真の次元を正確に捉えるための主要な評価基準として用いる。
MLE (Maximum Likelihood) ¹	近傍距離の極値理論に基づくポアソン過程近似を用いて最尤推定を行う。	サンプルサイズが十分であれば理論的な収束が保証されるため、TwoNNと併用して推定の信頼区間を形成する。
PCA (Baseline) ¹	共分散行列の固有値分解により、線形な分散の寄与率を	従来手法(線形ベース)との比較ベースラインとして用

	計算する。	い、非線形手法の優位性を際立たせるために使用する。
--	-------	---------------------------

実験プロトコルとしては、MNISTやCIFAR-10、あるいはfMRIデータに対してTwoNNおよびMLEを用いて真の内在次元 d_{ID} を推定する。並行して、AEのボトルネック次元 d_z をスweepしながら学習させ、Active Units(閾値以上の分散を持つ活性化ユニット数)と、入力と再構成画像間のCentered Kernel Alignment(CKA)などの類似度指標を測定する¹。これにより、実質的に機能している最適な潜在次元 $\hat{d}_z^*$ を特定する。理論の予測通り、 $\hat{d}_z^* \approx \hat{d}_{ID}$ または $\hat{d}_z^* \leq \hat{d}_{ID}$ という関係性が成立することを実験的に示せば、AEがデータに内在する自由度を正確に学習・圧縮していることの極めて強力な証拠となる¹。

実験3: 局所的・大域的な幾何学・位相構造の保存性評価(定量メトリクス)

オートエンコーダによる次元削減が、データの局所的小および大域的な構造をどれだけ忠実に保存しているかを定量化するため、多様体学習の分野で標準的に用いられるトポロジーおよび幾何学的な評価指標(Metrics)を導入する実験を行う²⁸。元の高次元空間の距離行列と、潜在空間の距離行列を比較することで、以下の指標を算出する。

評価指標 (Metric)	測定する構造的特性	実験的評価の観点
Trustworthiness (信頼性) ³²	潜在空間での k -近傍が、元の高次元空間でも近傍であった割合。偽の近傍(Intrusions)を罰する。	潜在空間において、本来関係のないデータポイントが誤ってクラスタリングされていないかを評価する。
Continuity (連続性) ³²	高次元空間での k -近傍が、潜在空間でも近傍に保たれている割合。近傍の引き離し(Extrusions)を罰する。	多様体の局所的なつながりが、次元削減の過程で不自然に分断・破壊されていないかを評価する。
Tangent Space Approximation (TSA) ²⁸	高次元空間の局所PCA接空間と、デコーダのヤコビアンが張る接空間との角度のズレ(主角度)。	デコーダの生成する多様体が、真のデータの接空間にどれほど滑らかにフィットしているかを幾何学的に評価する。
Representation Topology Divergence (RTD) ¹²	高次元空間と潜在空間のパーシステンス図間のワッサースタイン距離に基づく	大域的な穴やクラスター構造が破壊されずに潜在空間にマッピングされているかを位

	ポロジの差異。	相幾何学的に評価する。
--	---------	-------------

これらの指標を用いることで、分類精度に依存することなく、Vanilla AE、位相的正則化を施したTopoAE¹³、あるいは幾何学的正則化を施したGeometric AE³の性能差を厳密に比較することが可能となる。

実験4: MFTMAプロトコルによる幾何学的容量の動的測定

ニューラルネットワークが層を経るごとに、多様体がどのように分離・平坦化されていくかを定量化するため、レプリカ平均場理論 (Replica Mean Field Theory) に基づく多様体解析であるMFTMA (Manifold Fit-based Tangent Manifold Analysis) プロトコルを用いた実験を行う³⁴。

この実験では、データセットの各クラス (例えばASDと健常者、あるいはCIFAR-10の各カテゴリ) を1つの「オブジェクト多様体」と見なし、AEのエンコーダを通した潜在空間上での幾何学的特性を測定する。

- 1. 多様体の分類容量 (Classification Capacity): 潜在空間上において、ランダムな線形分類器によって分離可能な多様体の限界数を測定する。
- 2. 多様体の半径 (Radius) と次元 (Dimension): 各クラスの多様体が潜在空間内でどれほどコンパクトに圧縮されているか (Radiusの縮小) と、本質的な特徴のばらつき (Dimension) を測定する³⁴。

AEが効果的に多様体を抽出・平坦化していれば、潜在空間に近づくにつれて各クラスの多様体半径が劇的に縮小し、内在次元が低下し、結果として線形分類容量が向上することが実験的に示される。これは「なぜ分類精度が向上するのか」というブラックボックスな問いに対し、多様体の幾何学的変化という明確な根拠を与える画期的な実験となる。

実データ (画像および脳機能データ) への応用と考察の展開

提案した理論および実験アプローチを、提供された研究内容の文脈に組み込むことで、論文の考察をさらに深めることができる。

例えば、CIFAR-10データセットを用いた実験において、低次元では一部のクラスの精度が高く、次元を増やすと逆に精度が低下したり境界が曖昧になる現象が観察されている¹。これは、情報ボトルネック理論における「Rate (圧縮) と Distortion (歪み)」のトレードオフ、および内在次元の観点から説明が可能である。CIFAR-10のように背景や色などの変動要因 (不要な分散) が多いデータにおいて、適切な内在次元を超えてボトルネックを広げると、ネットワークが多様体とは無関係なノイズまで再構成しようと試み、結果として潜在空間上でクラス多様体間の低密度領域 (マージン) が埋まってしまい、線形分離性が低下するためであると理論的に考察できる。

また、ASDのfMRIデータを3D畳み込みAEで解析した研究¹においては、ASD群が定型発達 (TD) 群の一部と重なりつつ、その周辺に広く分布するという結果が得られている。この現象に対してRTD (位相的発散) やMFTMA (多様体半径の測定) を適用すれば、ASDというスペクトラム障害が持つ「機能的表現の多様性」を、単なる点のばらつきとしてではなく、「データ多様体上での幾何学的な広

がり(Radiusの増大)」や「固有の位相的特徴の分岐(ホモロジー群の違い)」として定量的に裏付けることができる。これにより、病態の解釈に強力な数学的基盤を与えることが可能となる。

結論

オートエンコーダがデータに含まれる多様体を特徴量として抽出しているという仮説は、深層学習の驚異的な汎化性能を説明する中核的な理論であるが、その証明には単なる再構成誤差の最小化や下流タスクにおける分類精度の評価だけでは不十分である。

本報告書で提示したように、論文の理論的根拠を確固たるものにするためには、微分幾何学におけるヤコビアン の階数評価やプルバック計量による等長性の確認、情報ボトルネック理論に基づく圧縮の最適性、さらには位相的データ解析(TDA)を用いたパーシステントホモロジーによる大域的構造の証明を統合して論理を展開すべきである。

さらに、これらの理論を実証するための実験的アプローチとして、真の構造が既知の合成多様体を用いた測地線補間の検証、TwoNNやMLEによる高度な内在次元推定アルゴリズムの適用、TrustworthinessやRTDといった幾何学・位相構造保存メトリクスの導入、およびMFTMAを用いた多様体容量の定量測定を実施することが極めて有効である。

現状の実験中心のアプローチに対して、これらの強固な理論的背景と最先端の幾何学的評価手法を統合することで、モデルのブラックボックス性を解消し、オートエンコーダにおける多様体学習のメカニズムを数学的かつ実証的に解明する、極めて学術的価値と説得力の高い論文を構築することが可能となる。

引用文献

1. H-031 (1).pdf
2. Deep Generative Models through the Lens of the Manifold Hypothesis: A Survey and New Connections - OpenReview, 3月 23, 2026にアクセス、
<https://openreview.net/pdf/3fdc5de1d1498acacc9806f656039cddef2f26e8.pdf>
3. Geometric Autoencoders – What You See is What You Decode, 3月 23, 2026にアクセス、
<https://proceedings.mlr.press/v202/nazari23a/nazari23a.pdf>
4. Learning Manifolds with Autoencoders - CEDAR, 3月 23, 2026にアクセス、
<https://cedar.buffalo.edu/~srihari/CSE676/14.3%20Learning%20Manifolds.pdf>
5. Autoencoders for a manifold learning problem with a jacobian rank constraint - Nazarbayev University, 3月 23, 2026にアクセス、
<https://research.nu.edu.kz/en/publications/autoencoders-for-a-manifold-learning-problem-with-a-jacobian-rank/>
6. Differential Geometric Approaches to Machine Learning, 3月 23, 2026にアクセス、
https://backend.orbit.dtu.dk/ws/files/350384757/Thesis_Alison_Pouplin-2.pdf
7. [2208.10193] Learning Low Bending and Low Distortion Manifold Embeddings: Theory and Applications - arXiv, 3月 23, 2026にアクセス、
<https://arxiv.org/abs/2208.10193>
8. Contractive Auto-Encoders: Explicit Invariance During Feature Extraction, 3月 23, 2026にアクセス、
https://icml.cc/2011/papers/455_icmlpaper.pdf

9. Higher Order Contractive Auto-Encoder - ResearchGate, 3月 23, 2026にアクセス、
https://www.researchgate.net/profile/Xavier-Glorot/publication/215616971_Higher_Order_Contractive_Auto-Encoder/links/02e7e53832ea136bac000000/Higher-Order-Contractive-Auto-Encoder.pdf
10. A Connection Between Score Matching and Denoising Autoencoders - Semantic Scholar, 3月 23, 2026にアクセス、
<https://www.semanticscholar.org/paper/A-Connection-Between-Score-Matching-and-Denoising-Vincent/872bae24c109f7c30e052ac218b17a8b028d08a0>
11. What Regularized Auto-Encoders Learn from the Data-Generating Distribution, 3月 23, 2026にアクセス、
<https://www.jmlr.org/papers/volume15/alain14a/alain14a.pdf>
12. Learning topology-preserving data representations - OpenReview, 3月 23, 2026にアクセス、
<https://openreview.net/forum?id=llu-ixf-Tzf>
13. Topological Autoencoders - Proceedings of Machine Learning Research, 3月 23, 2026にアクセス、
<http://proceedings.mlr.press/v119/moor20a/moor20a.pdf>
14. Topological Autoencoders | topoae – Weights & Biases - Wandb, 3月 23, 2026にアクセス、
<https://wandb.ai/captain-pool/topoae/reports/Topological-Autoencoders--Vmlldzo1Mjk2MTI>
15. Artificial intelligence-aided protein engineering: from topological data analysis to deep protein language models | Briefings in Bioinformatics | Oxford Academic, 3月 23, 2026にアクセス、
<https://academic.oup.com/bib/article/24/5/bbad289/7241306>
16. Exploring the use of topological data analysis to automatically detect data quality faults, 3月 23, 2026にアクセス、
<https://par.nsf.gov/biblio/10422762>
17. Unveiling Topological Structures from Language: A Survey of Topological Data Analysis Applications in NLP - arXiv, 3月 23, 2026にアクセス、
<https://arxiv.org/html/2411.10298v4>
18. Ensuring Topological Data-Structure Preservation under Autoencoder Compression Due to Latent Space Regularization in Gauss–Legendre Nodes - MDPI, 3月 23, 2026にアクセス、
<https://www.mdpi.com/2075-1680/13/8/535>
19. Theory and Application of the Information Bottleneck Method - PMC - NIH, 3月 23, 2026にアクセス、
<https://pmc.ncbi.nlm.nih.gov/articles/PMC10968930/>
20. Information bottleneck method - Wikipedia, 3月 23, 2026にアクセス、
https://en.wikipedia.org/wiki/Information_bottleneck_method
21. Deep Learning and the Information Bottleneck Principle - ResearchGate, 3月 23, 2026にアクセス、
https://www.researchgate.net/publication/273388040_Deep_Learning_and_the_Information_Bottleneck_Principle
22. Rate-Distortion Optimization Guided Autoencoder for Isometric Embedding in Euclidean Latent Space - Proceedings of Machine Learning Research, 3月 23, 2026にアクセス、
<http://proceedings.mlr.press/v119/kato20a/kato20a.pdf>
23. On the Information Bottleneck Problems: Models, Connections, Applications and Information Theoretic Views - MDPI, 3月 23, 2026にアクセス、
<https://www.mdpi.com/1099-4300/22/2/151>
24. Distributional Autoencoders Know the Score - OpenReview, 3月 23, 2026にアクセス

- ス、<https://openreview.net/forum?id=5Rlop1E1ga>
25. Learning Manifold Dimensions with Conditional Variational Autoencoders - Amazon Science, 3月 23, 2026にアクセス、
<https://assets.amazon.science/b2/56/84ab19fd403c88af42e4a76a4de2/learning-manifold-dimensions-with-conditional-variational-autoencoders.pdf>
 26. Multi-Scale Geometric Autoencoder - arXiv, 3月 23, 2026にアクセス、
<https://arxiv.org/html/2509.24168v1>
 27. Manifold-Matching Autoencoders - arXiv, 3月 23, 2026にアクセス、
<https://arxiv.org/pdf/2603.16568>
 28. Measure Before You Look: Grounding Embeddings Through Manifold Metrics - OpenReview, 3月 23, 2026にアクセス、
<https://openreview.net/pdf?id=47vaoXzQsB>
 29. Exploring the Latent Space of Autoencoders with Interventional Assays - NIPS, 3月 23, 2026にアクセス、
https://proceedings.neurips.cc/paper_files/paper/2022/file/87213955efbe48b46586e37bf2f1fe5b-Paper-Conference.pdf
 30. A Geometric Perspective on Variational Autoencoders - BOTdesign, 3月 23, 2026にアクセス、
<https://botdesign.net/wp-content/uploads/2025/04/Geometric-Perspective-on-VAE.pdf>
 31. Maximum Likelihood Estimation of Intrinsic Dimension - stat.berkeley.edu, 3月 23, 2026にアクセス、
<https://www.stat.berkeley.edu/~bickel/mldim.pdf>
 32. pyDRMetrics - A Python toolkit for dimensionality reduction quality assessment - PMC, 3月 23, 2026にアクセス、
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7887408/>
 33. Manifold-Matching Autoencoders - Emergent Mind, 3月 23, 2026にアクセス、
<https://www.emergentmind.com/papers/2603.16568>
 34. chung039/contextual-repr-manifolds - GitHub, 3月 23, 2026にアクセス、
<https://github.com/schung039/contextual-repr-manifolds>
 35. Efficient Coding of Natural Images using Maximum Manifold Capacity Representations, 3月 23, 2026にアクセス、
<https://www.cns.nyu.edu/pub/lcv/yerxa23c.pdf>