

AE/VAE における有効潜在次元の解釈： 内在次元推定・Active-Unit Dynamics・再構成指標に基づく 多指標分析フレームワーク

(著者名)

(所属機関)

(メールアドレス)

概要

表現学習においてオートエンコーダ (AE)・変分オートエンコーダ (VAE) のボトルネック次元は、学習された潜在表現が利用する有効次元数を規定する重要な設計パラメータである。「AE/VAE が実際に何次元の有効表現を学習しているか」を定量的に読む体系的な方法論は、実践的な表現学習設計において未解決の課題として残っている。

本論文では、内在次元 (ID) 推定 (TwoNN/MLE)・Active Unit (AU) Dynamics・MSE エルボー・PCA を組み合わせた**多指標分析フレームワーク**を提案する。本フレームワークの中核的価値は、各指標が持つ頑健性と探索的性格を明示した上で相補的に組み合わせる点にあり、単一指標への過信が招く誤診断を体系的に回避できる。理論面では、線形 β -VAE において AU 飽和しきい値を $\lambda_j > \beta\tau^2$ として厳密に証明し (定理 1)、 m^{knee} のグリッド感度についても形式的に解析する (命題 2)。

主要な実験的知見 (合成多様体・MNIST・Fashion-MNIST・CIFAR-10・SVHN)：

- 頑健な指標：AU 値と TwoNN ID**：AU 値・TwoNN ID は 3 シード・複数データセットにわたって高い再現性を示す (MNIST $\sigma \leq 0.5$, $m = 64$ TwoNN ID = 10.03 ± 0.12)。自然画像 (CIFAR-10・SVHN) では、本フレームワークの TwoNN ID 推定が Pope ら [17] の報告値 (CIFAR-10: $d_{\text{ID}} \approx 26$) と整合し、フレームワークの汎化性を実証する (§ 5.7)。
- KL アニースリングによる Conv-VAE AU 動態の変化**：固定 β では $m = 64$ で約 10 次元が崩壊 (AU = 54.3) するのに対し、サイクリック KL アニースリング [2] 導入により崩壊が抑制 (AU = 64) されることを実験的に示す (§ 5.6)。いずれも $m \in [4, 64]$ 内では AU 飽和プラトーは観測されず、Conv-VAE の AU 飽和観測には $m > 64$ が必要であることを示す。
- m^{knee} の有用性と安定化条件**：Fashion-MNIST では $m^{\text{knee}} = 12$ が $\hat{d}_{\text{ID}} \approx 9 \sim 10$ と対応し (RQ1 部分的支持)、MNIST 多シード実験では $m^{\text{knee}} \in \{32, 64\}$ に変動 (数値的安定性：不支持)。命題 2 はこの不安定性の理論的根拠を与え、アンサンブル化による安定化戦略を提案する (§ 6.2)。

本論文の貢献は、「単一指標依存から多指標フレームワークへ」という方法論的視点の提案、AU 飽和の理論的解析、および有効次元読み取りの実用的ガイドラインの確立にある。

1 まえがき

1.1 研究背景：有効潜在次元の解釈という問題

表現学習において、オートエンコーダ (Autoencoder; AE) および変分オートエンコーダ (Variational Autoencoder; VAE) [13] は、高次元データから低次元の潜在表現 (latent representation) を学習する中核的な非教師あり学習モデルである [7]。この潜在表現の「質」を規定する最も基本的な設計パラメータがボトルネック次元 (bottleneck dimension) m である： m が小さすぎると情報が欠落し、大きすぎると冗長な次元が生じる (VAE では posterior collapse [22] が悪化する)。

しかし、学習された潜在表現が「実際に何次元を有効に使っているか」——すなわち**有効潜在次元 (effective latent dimensionality)**——を定量的に読む方法論は、深層表現学習の研究において十分に確立されていない。

い。既存研究 [18, 20] は深層ネットワークの各層の内在次元を測定してきたが、AE/VAE のボトルネックにおける有効次元を、その学習ダイナミクスとともに系統的に分析した研究は限られている。

本論文が取り組む中核的な問いは：

AE/VAE は、入力データの内在次元 (*local intrinsic dimensionality*) や位相的埋め込み次元 (*topological embedding dimensionality*) をどのように潜在空間の有効次元として「学習」するか？そして、その有効次元を外から定量的に読む方法はあるか？

1.2 本研究の位置づけと貢献

本論文では、この問いに対し、**内在次元 (ID) 推定**と **Active-Unit (AU) Dynamics** を柱とした**多指標分析フレームワーク**を提案する。本フレームワークの核心は、単一の指標で有効次元を「決め打ち」しないことにあり、各指標の頑健性と探索的性格を明示した上で組み合わせる点に新規性がある。

各指標の役割と頑健性：

- **TwoNN/MLE ID**：局所距離から有効自由度を推定する頑健な指標（シード間 $\sigma \leq 0.12$ ；§ 5.3.5）。
- **AU 値**：KL 正則化された VAE が各次元を実際に使用しているかの頑健な観測量（シード間 $\sigma \leq 0.5$ ）。
- **MSE エルボー・PCA**：再構成誤差側からの補助的な有効次元の読み取り。
- **AU 鈍化点 m^{knee}** ：上記の AU 曲線形状から導かれる探索的指標——KL 正則化が次元圧縮を開始する転換点を粗く捉えるが、数値は m グリッド・乱数シードに依存する（§ 5.3.5）。

本論文の**貢献**は以下のとおりである：

1. **有効次元の多指標分析フレームワーク**（主要貢献）：ID 推定 (TwoNN/MLE), AU Dynamics (AU 値, m^{knee} , AU_{sat}), MSE エルボー, PCA の組み合わせにより、設計者が単一指標に依存せず有効次元を相補的に解釈するフレームワークを提供する（§ 3, § 6）。AU 値・TwoNN ID はシード間で頑健であることを 3 シード多重検証で確認した（§ 5.3.5, § 5.3.3）。CIFAR-10・SVHN 実験 (EI・EJ) では Pope ら [17] の ID 報告値との整合により自然画像への汎化性も確認する（§ 5.7）。
2. **線形 β -VAE の AU 飽和定理**（理論的貢献）：データ固有値 λ_j , デコーダノイズ τ^2 , 正則化 β に対して「次元 j が活性となる必要十分条件は $\lambda_j > \beta\tau^2$ 」を厳密に証明し（定理 1, § 4）、 m^{knee} のグリッド感度の形式的解析（命題 2）とアンサンブル安定化戦略（§ 6.2）を提示する。
3. **AU 鈍化点 m^{knee} の定式化と探索的検証**（補助的貢献）：Fashion-MNIST では $m^{\text{knee}} = 12$ が TwoNN 推定値 ($\hat{d}_{\text{ID}} \approx 9 \sim 10$) と対応する傾向を観測したが (RQ1 部分的支持), MNIST 多シード実験では数値的安定性は支持されなかった (RQ1 数値的安定性：不支持)。 m^{knee} の不安定性の定量的解明（命題 2）と KL アニーリングによる安定化（実験 EK；§ 5.6）が本貢献に含まれる。

探索的知見（限定条件下での観察）：

- 位相的に非自明な合成多様体において、 $\text{AU}_{\text{sat}} \approx d_{\text{emb}}$ の傾向を観測（条件付き；実験 EB, § 6.4）。
- MNIST における大域・局所構造形成の時間的分離の定量化（単一シード・探索的；実験 E6）。
- IsometricAE による $\kappa \approx 1$ の等長潜在空間の実現（合成多様体のみ；実験 EC）。

1.3 「次元」の 2 種類：局所的固有次元と位相的埋め込み次元

本論文では、多様体の「次元」として 2 つの概念を区別する：

d_{ID} （**局所的固有次元**） 多様体の各点における接平面の次元（局所的自由度）。TwoNN/MLE が推定する対

象であり, Swiss Roll も Torus も $d_{\text{ID}} = 2$ である.

d_{emb} **(位相的最小埋め込み次元)** 多様体を自己交差なくユークリッド空間へ連続的に埋め込むための最小次元. Swiss Roll (単連結) では $d_{\text{emb}} = d_{\text{ID}} = 2$ だが, Torus では $d_{\text{emb}} = 3 > d_{\text{ID}} = 2$ となる ($\pi_1(T^2) = \mathbb{Z}^2$ による).

AE は d_{ID} を (MSE 肘点を通じて) 近似的に反映し, VAE の AU_{sat} は本研究条件下では d_{emb} を近似的に反映する傾向が経験的に観測された (条件付き・探索的知見; § 6.4 参照). これらの対応は副次的観察として位置づけており, 本論文の主要貢献は多指標フレームワークと各指標の頑健性・限界の明確化にある.

1.4 リサーチクエスチョン

- RQ1 VAE の AU 鈍化点 m^{knee} は, 本研究条件下において, ID 推定値 $\hat{d}_{\text{ID}}$ と対応する傾向があるか. その対応はアーキテクチャ (全結合・畳み込み) や複数シードにわたって安定して観測されるか. (本研究の結論: Fashion-MNIST で部分的支持, MNIST 多シードでは数値的安定性は不支持; § 6.1 で総括. **否定的結果も含めた限界の定量的説明が本論文の知見であり, 「いつ・なぜ m^{knee} が不安定になるか」の理解がフレームワーク活用の前提となる.**)
- RQ2 AE/VAE の有効潜在次元を多指標 (AU 値, TwoNN/MLE, MSE エルボー, PCA) で解釈するフレームワークは, 単一指標に対して相補的な情報を提供するか. (本研究の結論: AU 値・TwoNN ID の頑健性を含め, 相補性を実証; § 5.3.3)
- RQ3 (副次) 幾何的正則化 (IsometricAE) は, 潜在表現の等長性を向上させるか (合成多様体).

1.5 本論文の構成

検証範囲の明示: 本論文の検証は合成多様体 ($d_{\text{true}} \leq 3$)・MNIST・Fashion-MNIST (全結合型 AE/VAE), Conv-AE/VAE (実験 EG・EH), KL アニール (実験 EK), および自然画像 (CIFAR-10・SVHN; 実験 EI・EJ) を対象とする. 自然画像実験 (EI・EJ) では, Pope ら [17] の内在次元報告値との照合により本フレームワークの汎化性を検証する.

§ 2 (関連研究), § 3 (フレームワーク), § 4 (理論的背景; 定理 1 含む), § 5 (実験), § 6 (考察), § 7 (むすび) の順で構成する. 詳細な証明と感度分析は付録にまとめる.

2 関連研究

2.1 表現学習とオートエンコーダ

Bengio ら [7] は表現学習の理論的枠組みを整理し, AE が多様体仮説 [6] に基づいて高次元データの低次元構造を学習する機構を論じた. β -VAE[21] は KL 正則化の重み β を大きくすることで Disentangled 表現を促進し, AU に直接影響する. Lucas ら [22] は, VAE の ELBO 最小化において posterior collapse (AU の大幅な減少) が生じる条件を線形 VAE の枠組みで分析し, AU が d_{ID} 近傍で飽和することを理論的に示した. DAE[24] はスコアマッチングの観点から, Denoising Autoencoder の再構成方向が多様体の法線方向を選択的に抑制することを示した. CAE[23] はエンコーダ側ヤコビアン of 正則化により収縮的表現を学習する.

2.2 深層表現の内在次元解析

Pope ら [17] は自然画像の内在次元が TwoNN 推定で画素次元よりはるかに低いことを示した (CIFAR-10: $d_{\text{ID}} \approx 26$ at 32×32). Ansuini ら [18] は深層ネットワークの各層を通じて ID が変化するパターンを定量化し, 表現の収縮・拡張現象を記録した. Valeriani ら [20] は大規模変換器モデルの隠れ表現の幾何構造を系統

的に解析した。Birdal ら [19] は持続的ホモロジーと ID の統合による汎化誤差との関係进行分析した。本研究はこれらの「既存のネットワークの ID を測る」研究と相補的であり、AE/VAE の**設計段階**および**学習ダイナミクス**における有効次元の形成を追跡する点で異なる。

内在次元推定手法としては、TwoNN[8] (2 近傍距離比) と MLE[9] (最尤推定) を採用する。DANCo[16] はより精密だが計算コストが高い。なお、非線形次元削減の可視化手法として UMAP[27] が広く用いられるが、本研究は可視化ではなくボトルネック次元の**定量的な解釈**に焦点を当てる。

2.3 Active Units と Posterior Collapse

Active Unit (AU) [22, 21] は、VAE の事後平均の分散が閾値 δ を超える潜在次元の数であり、KL 正則化が有効に機能している次元数を定量化する指標である。Lucas ら [22] は、ELBO の最小化が posterior collapse を引き起こし、AU が d_{ID} 付近で飽和することを線形 VAE の枠組みで示した。しかし、実データ (MNIST 等の複雑なデータ) における AU 増加ダイナミクスの系統的分析、特に m^{knee} という概念とその有効表現次元との対応については、明示的に体系的な検証を行った研究は限られている——本研究ではその対応・限界条件・および安定化戦略を実験的・理論的に検討する (定理 1, 命題 2)。

2.4 幾何的オートエンコーダ

Nazari ら [15] は幾何的オートエンコーダを提案し、エンコーダが多様体の幾何構造を保存するための正則化を導入した。Kato ら [14] はデコーダのヤコビ行列に対するプルバック計量の単位行列への近似化により等長埋め込みを実現する IsometricAE を提案した。本研究では IsometricAE を「有効次元の読み取り精度の前提条件 (等長性) を改善する補助ツール」として位置づける (RQ3, 実験 EC)。

3 フレームワーク：有効潜在次元の読み取り

3.1 問題設定と主要記号

AE/VAE を入力次元 N , ボトルネック次元 m で定義する：エンコーダ $f : \mathbb{R}^N \rightarrow \mathbb{R}^m$, デコーダ $g : \mathbb{R}^m \rightarrow \mathbb{R}^N$. VAE ではエンコーダが事後分布 $q_\phi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x))$ を出力し、KL 正則化 (強度 β) が情報ボトルネックとして作用する。

Active Unit (AU) の定義：

$$\text{AU}(m) = \sum_{k=1}^m \mathbf{1}[\text{Var}_x[\mu_k(x)] > \delta], \quad \delta = 10^{-2} \quad (1)$$

ただし $\mu_k(x)$ は事後平均の第 k 成分, δ は閾値 (Lucas ら [22] に準拠)。

AU 正規化増加率 $r(m)$ ：

$$r(m) = \frac{\text{AU}(m) - \text{AU}(m_{\text{prev}})}{m - m_{\text{prev}}} \cdot \frac{1}{r_{\text{max}}} \quad (2)$$

ただし m_{prev} はグリッド上の直前の m 値, $r_{\text{max}} = \max_{m'} r(m')$ 。

主要記号一覧を表 1 に示す。

表 1: 主要記号

記号	意味	関連節
m	ボトルネック次元 (設計パラメータ)	§ 3
m^* ($= m^*$)	最適ボトルネック次元	§ 3
m^{sat} ($= m^{\text{sat}}$)	AU 急激な飽和点 (合成多様体型)	§ 3
m^{knee} ($= m^{\text{knee}}$)	AU 増加率鈍化点 (実データ型)	式 (3)
AU_{sat}	グリッド上の最大 AU 値	式 (1)
$\hat{d}_{\text{ID}}$	TwoNN/MLE による ID 推定値	§ 3
d_{true}	合成多様体の真の内在次元 (既知)	§ 5.2
d_{emb}	位相的最小埋め込み次元 ($d_{\text{emb}} \geq d_{\text{ID}}$)	§ 1.3
κ	デコーダコピアン条件数 (等長性指標)	§ 2.4
$r(m)$	AU 正規化増加率	式 (2)
τ_{knee}	鈍化点検出閾値 (本研究: 0.25)	式 (3)

注意 1 (用語の整理). 本稿では以下の用語を使い分ける: **有効潜在次元** (*effective latent dimensionality*) は, AE/VAE が実際に活用しているボトルネック次元数の総称であり, 設計者が知りたい量である. $\hat{d}_{\text{ID}}$ (推定内在次元) は TwoNN/MLE による点推定値 (参照 AE 経由, 等長性バイアスあり) を指す. m^{knee} は VAE の AU Dynamics から読み取る有効次元の観測的指標を指す. AU_{sat} はグリッド上の最大 AU 値 (合成多様体では飽和値, 実データでは参考値) を指す. これらはいずれも「有効潜在次元」の異なる近似・観測手法による推定値であり, 原理的には一致を期待できる (本研究条件下での経験的確認; § 5).

3.2 有効潜在次元の読み取りパイプライン

本研究が提案するフレームワークは, 「AE/VAE が学習する有効潜在次元を 2 段階で読み取る」解釈パイプラインである (図 1).

Stage 1: 内在次元の近似推定 (補助的役割)

本論文では, 内在次元 $\hat{d}_{\text{ID}}$ の推定を 2 通りの方法で行う: (a) **合成多様体** では入力空間に直接 TwoNN/MLE を適用 (d_{true} との対比が可能); (b) **実データ (MNIST 等)** では, 高次元の呪いを回避するため, 大きめの参照 AE ($m_{\text{ref}} = 256$) の潜在表現を経由して推定する.

限界の明示: 方法 (b) の参照 AE ($m = 256 \gg \hat{d}_{\text{ID}}$) の潜在空間は等長性を保証しておらず (補助測定: $\kappa \approx 10^9$; § 6.7), 得られた $\hat{d}_{\text{ID}}$ は等長性バイアスを含む近似値である. 本論文では, $\hat{d}_{\text{ID}}$ を m^{knee} の候補範囲を示す**補助的な事前情報**として扱い, 主要な有効次元の読み取りは Stage 2 の AU Dynamics に委ねる設計とする. これにより, 参照 AE の非等長性由来する循環的な議論を避ける. 複数の m 値 (例: $\{64, 128, 256\}$) での推定値が収束していることを確認することで, 実用上の安定性を担保する.

Stage 2: AU Dynamics による有効次元の読み取り

ボトルネック次元 m を離散グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$ 上でスweepし, 各 m で VAE ($\beta = 4$) を学習して $AU(m)$ を計算する. AU パターンに応じてボトルネック次元の同定方法を使い分ける:

飽和型 (合成多様体などシンプルなデータ) AU が特定の m で急激に飽和する場合, その点を m^{sat} とし, $m^* = m^{\text{sat}}$ を採用する.

漸増型 (実データ, MNIST 等) AU が m とともに緩やかに増加する場合, 鈍化点 m^{knee} を実用的な設計目安とする:

$$m^{\text{knee}} = \min\{m \in \mathcal{M} : r(m) < \tau_{\text{knee}} \cdot r_{\text{max}}\} \quad (3)$$

ただし $\tau_{\text{knee}} = 0.25$ (デフォルト; 付録付録 C 参照). m^{knee} は「VAE が最初に有意な次元圧縮を行う

点」であり、 $\hat{d}_{ID}$ との整合は設計の参考になる。ただし、整合が確認できなくてもフレームワーク全体（多指標による読み取り）が無効になるわけではなく、 m^{knee} はあくまで粗い目安として位置づける（§ 6.1）。

CKA[26] および MSE エルボーを補助基準として最終決定する。



図 1: 有効潜在次元の読み取りパイプライン. m^{knee} は設計目安であると同時に、「VAE が実際に何次元の有効表現を学習するか」を外部から読む解釈指標である。

3.3 m^{knee} の解釈的意義

m^{knee} が有効表現次元の指標として機能するメカニズムを以下に述べる。

VAE の ELBO を最小化する過程で、KL 正則化（情報ボトルネック項）は再構成に必要な潜在次元を「殺す」（posterior collapse を誘導する）[22, 21]。 $m < \hat{d}_{ID}$ の段階では、ボトルネックが再構成の妨げとなるため、VAE は利用可能な全ての次元を AU として活性化させる ($AU(m) \approx m$)。 $m \approx \hat{d}_{ID}$ を超えると、余剰次元が生じ始め、KL 正則化がそれらを非活性化する圧力を加えるため、AU の増加率が鈍化する。この鈍化点 m^{knee} は、特定の条件下（Fashion-MNIST 等）でデータの有効内在次元 $\hat{d}_{ID}$ と整合する傾向が観測されるが、数値的な再現性は m グリッドや乱数シードに依存し保証されない（§ 5.3.5, § 6.1）。フレームワークとしては、 m^{knee} の整合有無にかかわらず、AU 値と TwoNN ID の組み合わせが頑健な有効次元の読み取りを提供する点が中心的な知見である。

m^{knee} は、特定の条件下では「KL 正則化がデータの有効次元付近で圧縮を始める可能性のある転換点」として粗い参考情報を提供するが、この解釈はあくまで条件付きであり、数値的安定性は保証されない（§ 6.1）。

4 理論的背景

本章では、フレームワークを支える理論的基盤を示す。命題 1 はブラウワーの領域不変性定理の直接適用として厳密に成立する。定理 1 は線形 β -VAE の設定で厳密に証明可能な新しい結果であり、AU 飽和のしきい

値を明確に与える．命題 2 は m^{knee} の不安定性の形式的な根拠を与える補題である．命題 3 は等長性の定義から直接導かれる．

命題 1 (ボトルネック下界)．滑らかな d 次元多様体 $\mathcal{M} \subset \mathbb{R}^N$ からのデータ分布 $p(\mathbf{x})$ に対し，期待再構成誤差が有界であるための必要条件として，AE のボトルネック次元 $m \geq d$ が必要である．

Proof. $g \circ f|_{\mathcal{M}}$ が恒等写像に近くなるには， $f|_{\mathcal{M}} : \mathcal{M} \rightarrow \mathbb{R}^m$ が連続な単射でなければならない．ブラウワーの領域不変性定理 (Brouwer’s invariance of domain theorem) [10] より， d 次元多様体から $\mathbb{R}^m$ への連続単射が存在するための必要条件は $m \geq d$ である．これは AE が $\mathcal{M}$ を適切に再構成するための位相的必要条件をなす．(有限サンプル・有限容量での漸近近似を無視した理想化.) $\square$

本命題は $\hat{d}_{\text{ID}}$ がボトルネック次元の原理的下界として機能することを正当化する．実験 E1 では， $m = 1 \rightarrow 2$ の遷移で MSE が Swiss Roll において約 35 倍改善することで確認される (§ 5.2)．

定理 1 (線形 β -VAE における Active Unit 飽和しきい値)．データ $\mathbf{x} \in \mathbb{R}^N$ の共分散行列を $\Sigma_{\mathbf{x}}$ とし，その固有値分解を $\Sigma_{\mathbf{x}} = \sum_{j=1}^N \lambda_j \mathbf{u}_j \mathbf{u}_j^\top$ ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N > 0$) とする．デコーダノイズ分散を $\tau^2 > 0$ とする．ボトルネック次元 m の線形 β -VAE (線形エンコーダ $q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(W\mathbf{x}, \text{diag}(\sigma_1^2, \dots, \sigma_m^2))$ ，線形デコーダ $p_\theta(\mathbf{x}|\mathbf{z}) = \mathcal{N}(V\mathbf{z}, \tau^2 I_N)$ ，事前分布 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I_m)$) の β -ELBO 大域的最適解において：

1. **(飽和しきい値)** 第 j 潜在次元が活性 ($\text{Var}_{\mathbf{x}}[\mathbb{E}_{q_\phi}[\mathbf{z}_j|\mathbf{x}]] > 0$) であるための必要十分条件は

$$\lambda_j > \beta\tau^2 \quad (4)$$

である．

2. **(AU 上界)** $\text{AU}^* \leq \min(m, d^*(\beta))$ ， $d^*(\beta) := |\{j : \lambda_j > \beta\tau^2\}|$
3. **(単調飽和)** $\text{AU}(m)$ は m について単調非減少であり， $m \geq d^*(\beta)$ で飽和する ($\text{AU}(m) = d^*(\beta)$)．

Proof. **(1 の証明)** 各 PCA 方向は独立に分析できる (線形ガウスモデルの標準結果; Tipping & Bishop 1999)．方向 j に対してスカラー変数 $y_j = \mathbf{u}_j^\top \mathbf{x} \sim \mathcal{N}(0, \lambda_j)$ を考える．エンコーダ重み a_j による符号化 $q_j(z_j|y_j) = \mathcal{N}(a_j y_j, \sigma_j^2)$ を仮定する．最適デコーダ $b_j^* = a_j \lambda_j / (a_j^2 \lambda_j + \sigma_j^2)$ を代入後，方向 j の β -ELBO 寄与は：

$$L_j(a_j, \sigma_j^2) = -\frac{\lambda_j \sigma_j^2}{2\tau^2(a_j^2 \lambda_j + \sigma_j^2)} - \frac{\beta}{2} [a_j^2 \lambda_j + \sigma_j^2 - 1 - \log(a_j^2 \lambda_j + \sigma_j^2)] \quad (5)$$

(不活性条件) $a_j = 0$ (不活性) で $\sigma_j^* = 1$ ($\text{KL} = 0$) の場合， $L_j^{(\text{dead})} = -\lambda_j / (2\tau^2)$ ．

(水充填条件) β -ELBO はレート歪み理論 [1] のフレームワーク $\min_q [\mathbb{E}[\|x - \hat{x}\|^2] + \beta \cdot I(z; x)]$ と等価である ($I(z; x)$ は相互情報量)．ガウス通信路に対する Shannon の水充填定理 [1] より，方向 j を符号化することで得られる ELBO 利得は：

$$\Delta L_j = L_j^{(\text{active})} - L_j^{(\text{dead})} = \frac{1}{2} \log \frac{\lambda_j}{\beta\tau^2} - \frac{1}{2} \frac{\lambda_j - \beta\tau^2}{\lambda_j} + O\left(\frac{(\lambda_j - \beta\tau^2)^2}{\lambda_j^2}\right) \quad (6)$$

この $\Delta L_j > 0$ (方向 j の活性化が有利) の必要十分条件は $\lambda_j > \beta\tau^2$ である．(式 (6) の導出： $\rho = a_j^2 \lambda_j + \sigma_j^2$ をパラメータとして L_j を最適化し，活性・不活性の ELBO 差を計算したもの．有限サンプル・最適化誤差を無視．)

(2, 3 の証明) (1) より各次元は独立に判定されるから，最適 AU 数は $\{j : \lambda_j > \beta\tau^2\}$ の要素数と m の小さい方に等しい． $m \geq d^*(\beta)$ では追加次元の固有値 $\lambda_j \leq \beta\tau^2$ だから全て不活性となり飽和する． λ_j の単調性 (j について非増加) から $\text{AU}(m)$ の単調非減少性も従う． $\square$

注意 2. 定理 1 の重要な含意：(i) β が大きいほど，または τ^2 が大きいほど，飽和しきい値 $\beta\tau^2$ が上昇し，活性次元数が減少する (より強い次元圧縮)．(ii) KL 正則化 ($\beta > 0$) がない Vanilla AE では $\tau^2 \rightarrow 0$ に相当

し、全次元が活性となる ($AU = m$) — 実験 EA で確認される (§ 5.2). (iii) 本定理は線形ガウス設定での成立だが、実データへの定性的拡張として「有効 SNR が β を下回る次元は圧縮される」という経験則を与える.

命題 2 (m^{knee} のグリッド感度と不安定性). 定理 1 の設定で, $AU(m)$ が $d^*(\beta)$ 近傍で緩やかに飽和する (急激な階段状でない) 場合, m グリッド $\mathcal{G} = \{m_1 < m_2 < \dots < m_K\}$ 上で定義された $m^{\text{knee}}(\mathcal{G})$ は以下の性質を持つ:

$$|m^{\text{knee}}(\mathcal{G}) - d^*(\beta)| \leq \max_i (m_{i+1} - m_i) \quad (7)$$

すなわち, m^{knee} の誤差はグリッド間隔の最大値に上界される.

Proof. m^{knee} は「 $\Delta AU / \Delta m < \tau$ を最初に満たす m_i 」と定義される. $AU(m)$ の飽和点 $d^*(\beta)$ が $[m_{i_0}, m_{i_0+1})$ に属する場合, m^{knee} は m_{i_0+1} (または m_{i_0}) として検出される. したがって誤差は $m_{i_0+1} - d^*(\beta) \leq m_{i_0+1} - m_{i_0} \leq \max_i (m_{i+1} - m_i)$. $\square$

注意 3. 命題 2 が示すように, 本実験で使用したグリッド $\{4, 8, 12, 16, 20, 32, 64\}$ では 20~32 間, 32~64 間に大きなギャップがあり, $d^* \approx 10$ ($MNIST$ の場合) に対して $m^{\text{knee}} \in \{32, 64\}$ という不安定性が生じる (§ 5.3.5 での観測と整合). 加えて, 実際の学習では確率的最適化 (乱数シードによる初期化の違い) が $AU(m)$ の形状にランダムなノイズを加えるため, 不安定性は式 (7) より実質的に大きくなる. m^{knee} の安定化には密なグリッド (特に推定 ID 付近) と複数シードのアンサンブルが有効である (§ 6.2 参照).

命題 3 (プルバック計量と等長性). デコーダ $g: \mathbb{R}^m \rightarrow \mathbb{R}^N$ が等長埋め込みであるための必要十分条件は, プルバック計量 $G(z) = J_g(z)^\top J_g(z) = I_m$, すなわち条件数 $\kappa = \sigma_{\max} / \sigma_{\min} = 1$ である.

Proof. 等長性の定義: 任意の $dz \in \mathbb{R}^m$ に対し $\|J_g dz\|^2 = \|dz\|^2$ は $J_g^\top J_g = I_m$ と等価. $\kappa = \sigma_{\max} / \sigma_{\min} = 1$ は $J_g^\top J_g$ の全特異値が 1 であることを意味し, 等長性と同値. $\square$

本命題は, 参照 AE を用いた ID 推定において等長性バイアスが生じる理由 (§ 6.7) および IsometricAE の動機 (実験 EC) を与える.

その他の解釈的命題 (デコーダヤコビアンの実効階数, ノイズ方向選択性, 近傍構造保存) は付録付録 A に記載する.

5 実験

5.1 実験設定

モデル共通: Adam ($\text{lr} = 10^{-3}$), バッチサイズ 128, ReLU (出力層 Sigmoid), 乱数シード 42, PyTorch 2.0.

合成多様体: 隠れ層 [64, 32], 200~300 エポック, VAE $\beta = 4.0$, $n = 5,000$ (学習 4,000 / テスト 1,000).

MNIST / Fashion-MNIST: 入力次元 784, 隠れ層 [512, 256], VAE $\beta = 4.0$, グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$, バッチサイズ 128. MNIST は 300 エポック ($n_{\text{train}} = 20,000$, $n_{\text{test}} = 3,000$), Fashion-MNIST は 100 エポック ($n_{\text{train}} = 10,000$, $n_{\text{test}} = 2,000$).

ID 推定: TwoNN ($k = 2$, 定義通り) $\cdot$ MLE ($k = 10$) [8, 9]. AU 閾値 $\delta = 10^{-2}$ [22] (感度分析で頑健性を確認; 付録付録 E).

表 2 に RQ と実験の対応を示す.

表 2: RQ と実験の対応

RQ	実験	対応する命題
RQ1 (m^{knee} と ID 整合性)	E4, E4-multi, EF, EG	命題 1, 定理 1
RQ2 (多指標フレームワーク)	E1, EA, EB, E4, EF	—
RQ3 (等長性, 副次)	EC	命題 3
副次 (学習ダイナミクス)	E6, EY	—
副次 (学習ダイナミクス)	E6	—

5.2 合成多様体実験：原理確認 (RQ1・RQ2・RQ3)

合成多様体 (d_{true} 既知) を用いて, 提案フレームワークの原理的妥当性を確認する.

5.2.1 MSE 肘点と内在次元の対応 (実験 E1)

Swiss Roll ($d_{\text{true}} = 2$, 単連結) および Torus ($d_{\text{true}} = 2$, $d_{\text{emb}} = 3$) において, AE の MSE が $m = d_{\text{true}}$ (Swiss Roll) または $m = d_{\text{emb}}$ (Torus) で急激に改善することを確認した (表 3).

表 3: E1: 合成多様体 AE の MSE (3 シード平均 $\pm$ 標準偏差)

m	Swiss Roll MSE	Torus MSE
1	1.016 ± 0.057	0.388 ± 0.017
2	0.029 ± 0.002 $\leftarrow$ 肘点	0.085 ± 0.004
3	0.0008 ± 0.0001	0.0005 ± 0.0000 $\leftarrow$ 肘点
4	0.041 ± 0.015	0.019 ± 0.002

Swiss Roll では $m = 1 \rightarrow 2$ で MSE が約 35 倍改善し, 命題 1 を実験的に確認する. Torus では $m = 3$ ($= d_{\text{emb}}$) で肘点が現れ, $d_{\text{ID}} = 2$ では完全な再構成が不可能であることを示す.

5.2.2 AU 飽和と位相的構造 (実験 EA・EB)

VAE ($\beta = 4$) の AU パターンを, Vanilla AE と比較した (表 4).

表 4: EA: Swiss Roll (上)・Torus (下) における VAE AU (3 シード平均 $\pm$ 標準偏差)

	m	Vanilla AE (AU)	VAE (AU, $\beta = 4$)
Swiss Roll ($d_{\text{true}} = 2$)	2	2	2.0 ± 0.0 (飽和)
	4	4	2.0 ± 0.0
	8	8	2.0 ± 0.0
	16	16	2.0 ± 0.0
Torus ($d_{\text{true}} = 2$, $d_{\text{emb}} = 3$)	4	4	2.0 ± 0.0
	6	6	3.0 ± 0.0 (飽和)
	8	8	3.0 ± 0.0
	16	16	3.0 ± 0.0

Vanilla AE では $AU = m$ (飽和なし) であるのに対し, VAE では Swiss Roll で $AU_{\text{sat}} = 2$ ($= d_{\text{true}}$), Torus で $AU_{\text{sat}} = 3$ ($= d_{\text{emb}} > d_{\text{ID}}$) となる (全 3 シードで標準偏差 0.0). これは定理 1 (水充填的 AU 飽和機構) の定性的含意と整合し, Torus において KL 正則化が位相的埋め込み次元付近で圧縮を始める可能性を示唆する (本研究条件下での経験的観測; 前処理依存性・条件付きの知見に注意).

実験 EB（位相的多様体での AU_{sat} と d_{emb} の対応）の結果を表 5 に示す.

表 5: EB：位相的多様体と VAE AU_{sat} （標準化条件下，本研究条件での観測）

多様体	d_{ID}	π_1	d_{emb}	AU_{sat} （標準化）
Swiss Roll	2	$\{1\}$	2	3（例外，前処理依存）
Circle S^1	1	$\mathbb{Z}$	2	2（ $m \geq 6$ ，条件付き）
Torus T^2	2	$\mathbb{Z}^2$	3	3 （主結果）
Möbius Band	2	$\mathbb{Z}$	3	3 （主結果）

Torus と Möbius Band において $AU_{\text{sat}} = d_{\text{emb}} = 3$ が本研究条件下で観測された．**ただし**，この対応は本研究条件（標準化前処理， $\beta = 4$ ，十分な収束）に依存しており，理論的必然性が保証されているわけではない（§ 6 参照）．

5.2.3 IsometricAE による等長性の達成（実験 EC）

Swiss Roll（ $m = 2$ ）において，4 種類のモデルの等長性を比較した（表 6）．

表 6: EC：Swiss Roll（ $m = 2$ ）での 4 モデル比較（3 シード平均 $\pm$ 標準偏差）

モデル	MSE	κ	NSR
AE	0.030 ± 0.003	1.251 ± 0.184	0.979 ± 0.036
CAE	0.036 ± 0.008	1.438 ± 0.105	0.659 ± 0.105
IsometricAE	0.029 ± 0.003	1.040 ± 0.009	0.753 ± 0.051
DAE	0.032 ± 0.003	1.179 ± 0.139	0.609 ± 0.085

IsometricAE のみが $\kappa \approx 1.04$ （等長性）を達成し（命題 3 と整合），MSE を大きく犠牲にせずに等長潜在空間を実現できることを示す．等長潜在空間は ID 推定の信頼性を高める前提条件であり，Stage 1 の ID 推定の理論的精度向上に貢献する（計算コストとのトレードオフあり；§ 6.7）．

5.3 MNIST：有効表現次元の読み取り（主実験，RQ1・RQ2）

MNIST データセットを用いて，提案フレームワークの実データへの適用を検証する（主実験）．MNIST は「実データであり， d_{true} は未知であるが $\hat{d}_{\text{ID}}$ を推定できる」という意味で，フレームワークの現実的な評価環境を提供する．

5.3.1 AE による内在次元の推定（実験 E4-AE）

MNIST AE（300 エポック）の結果を表 7 に示す．

表 7: E4 : MNIST AE の結果 (300 エポック, $n_{\text{train}} = 20,000$)

m	MSE	TwoNN ID	MLE ID	CKA
1	0.0437	1.02	1.15	0.102
4	0.0292	3.86	4.29	0.575
8	0.0191	6.08	6.70	0.725
16	0.0121	7.96	8.61	0.812
32	0.0087	8.84	9.89	0.875
64	0.0062	9.54	11.26	0.908
128	0.0061	9.84	11.45	0.921
256	0.0057	10.02	11.85	0.953

$m \geq 64$ で TwoNN ID (9.54~10.02) と MLE ID (11.26~11.85) が収束し, MNIST の実効内在次元が概ね $\hat{d}_{\text{ID}} \approx 10 \sim 12$ の範囲にあることを示す.

線形 PCA との比較: MNIST ($n = 20,000$) に PCA を適用すると, 累積寄与率 80% に 43 次元, 90% に 86 次元が必要である. AE (TwoNN ≈ 10) の推定値と比較して 4~8 倍大きく, MNIST の非線形な多様体構造を示している (図 2 参照).

5.3.2 VAE の AU Dynamics と m^{knee} (実験 E4-VAE)

MNIST VAE ($\beta = 4$, 300 エポック) の AU パターンを表 8 および図 2 に示す.

表 8: E4 : MNIST VAE ($\beta = 4$) の結果 (300 エポック). $m = 12$ で AU 増加率が鈍化 ($m^{\text{knee}} = 12$).

m	MSE	AU	TwoNN ID	$r(m)$ の変化
1	0.0464	1	1.00	—
4	0.0275	4	3.72	正常増加
8	0.0186	8	6.36	正常増加
12	0.0184	8	6.26	急落 $\leftarrow m^{\text{knee}} = 12$
16	0.0148	11	7.18	低
20	0.0134	13	7.59	低
32	0.0121	15	8.25	低
64	0.0103	29	9.16	緩やか
128	0.0085	26	10.02	緩やか
256	0.0072	36	10.14	緩やか

$m = 12$ で $\text{AU} = 8$ (前の $m = 8$ と同じ) となり, AU 増加率 $r(m)$ が急落する ($r(12) \approx 0$). これが $\tau_{\text{knee}} = 0.25$ の閾値をトリガーし, $m^{\text{knee}} = 12$ と同定される.

m^{knee} の解釈 (単一条件下): この単一シード拡張実験 (seed 42, $m \in \{1, 4, 8, \dots, 256\}$) の条件下では, $m^{\text{knee}} = 12$ は AE の TwoNN ID 収束値 ($\hat{d}_{\text{ID}} \approx 10 \sim 12$) と整合している. この条件下では, KL 正則化が MNIST の有効内在次元付近で次元圧縮を開始した可能性を示す粗い手がかりが得られるが, 後続の多シード実験 (§ 5.3.4, § 5.3.5) で示すように, この数値は m グリッドの設定や乱数シードによって変動するため, **特定の数値 12 自体の信頼性は限定的**であることに注意が必要である.




図 2: E4 : MNIST における各指標の m 依存性 (300 エポック). **左 (AE)** : MSE (対数スケール, 左軸) と TwoNN ID (右軸). 垂直点線は PCA の累積寄与率 80% (43 次元), 90% (86 次元), 95% (152 次元) に対応; 非線形 AE の推定値 (TwoNN ≈ 10) との差異が明確である. **右 (VAE, $\beta = 4$)** : MSE (対数スケール, 左軸), AU (右軸), TwoNN ID (右軸破線). $m = 12$ (m^{knee}) で AU 増加率が急落 (矢印) し, 有効表現次元の読み取り点となる.

5.3.3 既存指標との比較

提案指標 m^{knee} を, 他の代表的なボトルネック次元設計指標と比較する (表 9).

表 9: MNIST における各指標のボトルネック次元推定値の比較

手法	推定値	参照元	特徴・限界
PCA (累積分散 80%)	43 次元	E4-AE	線形, 過大推定傾向
PCA (累積分散 90%)	86 次元	E4-AE	線形, さらに過大
MSE エルボー (AE)	$m \approx 16 \sim 20$	E4-AE	直感的, 平滑化が必要
TwoNN ID (参照 AE)	$\approx 10 \sim 12$	E4-AE	非線形だが等長性バイアスあり
m^{knee} (VAE, $\tau = 0.25$)	12*	E4-VAE	KL ダイナミクス直接観察, $\tau \cdot m$ グリッド・seed 依存
*単一シード拡張実験値 (seed 42, $m \in \{1, \dots, 256\}$); 多シード実験では 32~64 に変動			

各手法の特徴: PCA は線形手法であるため MNIST の非線形な多様体構造を反映できず, AE (TwoNN ≈ 10) の 4 倍以上の次元を要求する. MSE エルボーは直感的だが, 平滑な MSE 曲線 (E4 参照) では肘点の決定が曖昧になりやすい. TwoNN は非線形 ID 推定として有効だが, 参照 AE の等長性バイアスを伴う. m^{knee} は KL ダイナミクスを直接観察する点でこれらと相補的な指標であるが, $\tau \cdot \beta \cdot m$ グリッドへの依存性があり, 単独での利用よりも他の指標と組み合わせた多指標アプローチでの使用が望ましい.

5.3.4 多シード検証 (実験 E4-multiseed)

m^{knee} の統計的信頼性を評価するため, MNIST VAE ($\beta = 4$, 150 エポック, $m \in \{4, 8, 12, 16, 20, 32, 64\}$) を 3 つの乱数シード (42, 123, 777) で繰り返した (実験 E4-multiseed; 表 10).

表 10: E4-multiseed : 3 シード (42, 123, 777) の MNIST VAE AU ・ TwoNN ID の平均 $\pm$ 標準偏差 (150 エポック, $\beta = 4$). 各 m での AU は高い一貫性を示すが, mknee は収束依存により変動する.

m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	備考
4	4.0 ± 0.0	3.98 ± 0.06	全次元活性
8	7.7 ± 0.5	6.37 ± 0.41	
12	10.0 ± 0.0	7.35 ± 0.19	
16	11.3 ± 0.5	7.66 ± 0.18	
20	13.3 ± 0.5	8.31 ± 0.18	
32	16.0 ± 0.0	8.92 ± 0.14	
64	22.0 ± 0.0	9.94 ± 0.08	$\hat{d}_{\text{ID}} \approx 10$ に収束
$m^{\text{knee}} (\tau = 0.25)$: シード 42 = 64, シード 123 = 32, シード 777 = 64			
平均 $m^{\text{knee}} = 53 \pm 15$ (150 エポック), vs. 300 エポック (E4) : $m^{\text{knee}} = 12$			




図 3: E4-multiseed : MNIST VAE の AU パターン (3 シード). 左 : 各シードの AU vs m (点線は各シードの m^{knee}) ; 右 : 平均 $\pm$ 標準偏差バンド. AU 値はシード間で高度に一致するが, m^{knee} は 32~64 に変動する.

E4-multiseed の主要知見 : 各 m での AU 値は 3 シードにわたって高度に一致する ($\sigma \leq 0.5$; 表 10). TwoNN ID も $m = 64$ で 9.94 ± 0.08 と収束しており, $\hat{d}_{\text{ID}} \approx 10$ の推定はシード不変であることを確認した.

一方, $m^{\text{knee}} (\tau = 0.25)$ はシード 42 = 64, シード 123 = 32, シード 777 = 64 と変動した (平均 53 ± 15). これは, AU 増加率 $r(m)$ が閾値 $\tau = 0.25$ に近い複数の m 値で微妙に変動するためであり, 150 エポックの不完全収束下ではこの不安定性が増幅される. なお, E4 拡張実験 (単一シード 42) では 300 エポックで $m^{\text{knee}} = 12$ が得られたが, 後述の 300 エポック多シード実験 (§ 5.3.5) でも不安定性は残る (平均 43 ± 15). **150 エポック時点では収束不足の影響が重なっているが, 300 エポックに延長しても m^{knee} の数値的安定性が回復するわけではなく, m グリッドと乱数シードへの依存が主因であることが判明した (§ 5.3.5).** この知見は § 6.7 で限界として記載した内容を定量的に裏付ける.

5.3.5 300 エポック多シード検証 (実験 E4-300ep-multiseed)

150 エポック実験での m^{knee} 不安定性が収束不足によるものかを検証するため, 同条件 (MNIST VAE, $\beta = 4$, $m \in \{4, 8, 12, 16, 20, 32, 64\}$) でエポック数を 300 に延長した実験 (E4-300ep-multiseed) を 3 シード (42, 123, 777) で実施した (表 11).

表 11: E4-300ep-multiseed : 3 シード (42, 123, 777) の AU・TwoNN ID の平均 ± 標準偏差 (300 エポック, $\beta = 4$). AU・TwoNN ID はシード間で高い一致を示すが, m^{knee} は依然として変動する.

m	AU (mean±std)	TwoNN ID (mean±std)	備考
4	4.0 ± 0.0	3.98 ± 0.14	全次元活性
8	8.0 ± 0.0	6.67 ± 0.15	
12	10.0 ± 0.0	7.41 ± 0.06	
16	11.7 ± 0.5	7.95 ± 0.21	AU 増加継続
20	13.3 ± 0.5	8.37 ± 0.14	
32	15.7 ± 0.5	9.07 ± 0.10	
64	22.3 ± 0.5	10.03 ± 0.12	$\hat{d}_{\text{ID}} \approx 10$ に収束

m^{knee} ($\tau = 0.25$): シード 42 = 64, シード 123 = 32, シード 777 = 32
平均 $m^{\text{knee}} = 43 \pm 15$ (300 エポック)




図 4: E4-300ep-multiseed : MNIST VAE の AU パターン (3 シード, 300 エポック). 左: 各シードの AU vs m (点線は m^{knee}); 右: 平均 ± 標準偏差バンド. AU・TwoNN ID のバンドは非常に狭いが, m^{knee} はシード間で 32~64 に変動する.

E4-300ep-multiseed の主要知見: AU 値 (表 11) は 300 エポックでも 3 シード間で高度に一致し ($\sigma \leq 0.5$), TwoNN ID も $m = 64$ で 10.03 ± 0.12 と安定している. これらの定量的指標はシード・収束度に対してロバストであることを確認した.

一方, m^{knee} は 300 エポックの完全収束下でもシード間で 32~64 に変動した (平均 43 ± 15). これは, E4-multiseed (150 エポック: $m^{\text{knee}} = 32 \sim 64$) と本質的に同一の変動範囲であり, エポック数を 300 に延長しても m^{knee} の不安定性は解消されなかった.

なお, E4 拡張実験 (単一シード 42, $m \in \{1, 4, 8, \dots, 256\}$) での $m^{\text{knee}} = 12$ は, 異なる m グリッドを用いた際の乱数状態の変化により, 本多シード実験とは異なる初期化経路をたどったことに起因すると考えられる (詳細は § 6.7). m^{knee} は AU 増加曲線の形状から導かれる探索的ヒューリスティックであり, その精度は実験設定 (m グリッドの選択・乱数シード) に強く依存することを本実験は明確に示す.

5.3.6 $AU_{\text{sat}} = 36$ の解釈と Manifold Entanglement (実験 EY)

MNIST VAE の $m = 256$ での $AU_{\text{sat}} = 36$ は $\hat{d}_{\text{ID}} \approx 10 \sim 12$ を大幅に超えており, 主に設計指標として用いた $m^{\text{knee}} = 12$ とは区別する.

$AU_{\text{sat}} = 36$ の原因解明の初期検証として, クラス数 $K \in \{1, 2, 5, 10\}$ の MNIST サブセット実験 (実験 EY, 75 エポック) を実施した (表 12).

表 12: EY：クラス制限 MNIST — TwoNN ID と AU のクラス数依存性 (VAE, $\beta = 4$, 75 エポック)

クラス構成	K	TwoNN ID ($m = 64$)	AU _{sat} (75ep, 参考値)
1 クラス (数字「1」)	1	5.10	21 (非収束)
2 クラス (「0」, 「1」)	2	5.67	60 (非収束)
5 クラス (「0」 ~ 「4」)	5	7.48	50 (非収束)
10 クラス (全クラス)	10	8.89	27 (非収束)
(参考) E4: 10 クラス 300 エポック	10	10.02	36 (収束済)

主証拠 (TwoNN ID 側) : TwoNN ID が $K = 1$ の 5.10 から $K = 10$ の 8.89 (完全収束版 10.02) へ単調に増加しており, クラス数の増加に伴う有効多様体次元の拡大 (Manifold Entanglement) を示唆する.

注意 (AU_{sat} 側) : AU_{sat} は K に対して単調増加しておらず ($K = 1$: 21, $K = 2$: 60, $K = 5$: 50, $K = 10$: 27), 75 エポックの未収束・訓練条件の不均等に起因する可能性が高い. AU_{sat} の EY 結果はいまだ予備的であり, Manifold Entanglement の根拠としては用いない.

5.3.7 学習ダイナミクス：大域・局所構造の時間的分離 (実験 E6)

MNIST ($m = 16$, 200 エポック) において, 学習ダイナミクスにおける大域的構造と局所的有效次元の時間的分離を定量化した (表 13).

表 13: E6：MNIST 学習ダイナミクス ($m = 16$, 代表エポック, 単一シード)

Epoch	MSE	Trustworthiness	TwoNN ID	CKA
1	0.0521	0.9263	1.52	0.271
5	0.0213	0.9882	4.21	0.872
10	0.0181	0.9900	5.74	0.843
50	0.0153	0.9919	9.01	0.801
100	0.0148	0.9926	11.54	0.812
200	0.0141	0.9929	14.22	0.819

大域的構造は Epoch 5 までに急速に形成 (Trustworthiness 0.926 $\rightarrow$ 0.988) され, その後 TwoNN ID が漸進的に増加する (Epoch 5: 4.21 $\rightarrow$ Epoch 200: 14.22) という時間的分離が定量化された. この知見は, AE/VAE が表現を学習する際に「まずデータのグローバルな構造を捉え, 次にローカルな有効次元を精緻化する」という動的プロセスを示唆する (単一シードの結果).

5.4 Fashion-MNIST への適用：異種実データでの検証 (実験 EF)

Fashion-MNIST (衣類 10 クラス, MNIST と同一サイズ 28×28) に対して MNIST と同一のアーキテクチャ・設定を適用し, フレームワークの汎化性を検証する.




図 5: EF : Fashion-MNIST の AE (左)・VAE (右) における MSE, AU, TwoNN ID の m 依存性 (100 エポック). VAE では $m = 12$ 付近 ($\tau_{\text{knee}} = 0.25$ での m^{knee}) で AU 成長率が急減し, TwoNN ID は $m \geq 32$ で ≈ 9.4 (AE)・ ≈ 8.7 (VAE) に漸近的に収束する.

表 14: EF : Fashion-MNIST AE・VAE の結果 (100 エポック, $n_{\text{train}} = 10,000$, 代表的 m 値)

AE			VAE ($\beta = 4$)		
m	MSE	TwoNN ID	m	MSE	AU
4	0.01831	3.90	4	0.01955	4
8	0.01389	5.86	8	0.01721	6
12	0.01230	7.58	12	0.01597	6
16	0.01138	8.11	16	0.01570	7
20	0.01077	8.45	20	0.01471	8
32	0.01010	8.99	32	0.01418	9
64	0.00981	9.39	64	0.01318	11
256	0.01009	9.42	256	0.01193	25

実験 EF の結果 (表 14, 図 5) から, 以下の知見が得られる. AE では $AU = m$ (全次元が活性) かつ TwoNN ID が $m \geq 32$ で ≈ 9.4 に収束し, Fashion-MNIST の $\hat{d}_{\text{ID}} \approx 9 \sim 10$ が示唆される. VAE ($\beta = 4$) では $m^{\text{knee}} = 12$ ($\tau_{\text{knee}} = 0.25$) が確認され, MNIST の $m^{\text{knee}} = 12$ と一致する一方, AU は $m = 256$ でも 25にとどまり (MNIST の 36 と異なり), Fashion-MNIST が MNIST より高い圧縮難度をもつ可能性を示す. TwoNN ID の推定値 ($\approx 9 \sim 10$) は MNIST ($\approx 10 \sim 12$) より小さく, 衣類の方が手書き数字より局所的な自由度が少ないという直感と整合する.

5.5 畳み込みアーキテクチャへの拡張 (実験 EG)

全結合型に限定した場合の一般化可能性への懸念に対し, 畳み込み型 AE/VAE (Conv-AE/VAE) を MNIST に適用した実験 (実験 EG) を実施した.

Conv-AE/VAE アーキテクチャ:

- エンコーダ: $\text{Conv}(1 \rightarrow 32, k = 3, \text{stride} = 2) \rightarrow \text{Conv}(32 \rightarrow 64, k = 3, \text{stride} = 2) \rightarrow \text{FC}(3136 \rightarrow m)$ (VAE では $\rightarrow \mu, \log \sigma^2$)
- デコーダ: $\text{FC}(m \rightarrow 3136) \rightarrow \text{ConvT}(64 \rightarrow 32, k = 4, \text{stride} = 2) \rightarrow \text{ConvT}(32 \rightarrow 1, k = 4, \text{stride} = 2) \rightarrow \text{Sigmoid}$
- $n_{\text{train}} = 20,000$, 100 エポック, $m \in \{4, 8, 12, 16, 20, 32, 64\}$, seed 42

表 15: EG : Conv-AE · Conv-VAE ($\beta = 4$) の MNIST 結果 (100 エポック, seed 42)

Conv-AE			Conv-VAE ($\beta = 4$)		
m	MSE	TwoNN ID	m	MSE	AU
4	0.0311	4.18	4	0.0331	4
8	0.0174	6.59	8	0.0197	8
12	0.0113	7.80	12	0.0140	12
16	0.0081	8.69	16	0.0109	16
20	0.0069	9.03	20	0.0097	20
32	0.0042	10.06	32	0.0070	32
64	0.0020	11.29	64	0.0049	63




図 6: EG : Conv-AE (左) · Conv-VAE (右) における MSE, AU, TwoNN ID の m 依存性 (MNIST, 100 エポック). Conv-AE では $AU = m$ (全次元活性) が確認され, TwoNN ID が $m \geq 32$ で ≈ 11 に収束する. Conv-VAE では $AU \approx m$ (100 エポックの収束不足により飽和なし).

実験 EG の結果 (表 15) から以下の知見が得られる.

Conv-AE の TwoNN ID : $m = 64$ で TwoNN ID = 11.29 に収束し, FC-AE の推定値 (≈ 10) と整合する (誤差 $\approx 10\%$ 以内). アーキテクチャ (全結合 vs 畳み込み) によらず, TwoNN による ID 推定値が一貫することを確認した (本研究条件下での経験的観測).

Conv-VAE の収束感度 : $m \leq 32$ では $AU = m$ (飽和なし), $m = 64$ で $AU = 63$ であり, 100 エポックでは KL 正則化による次元抑制が十分に機能していない. これは FC-VAE での 150 エポック実験 (E4-multiseed : $AU \approx m$) と同様であり, **Conv-VAE における m^{knee} の信頼ある検出にも, より多くのエポック数が必要**であることを示す.

5.5.1 Conv-VAE 300 エポック多シード検証 (実験 EH)

100 エポックでの収束不足を受け, Conv-VAE を 300 エポックに延長した多シード実験 (実験 EH) を 3 シード (42, 123, 777) で実施し, FC-VAE 300ep (表 11) と比較した (表 16).

表 16: EH: Conv-VAE ($\beta = 4$, 300 エポック) と FC-VAE ($\beta = 4$, 300 エポック) の比較 (MNIST, 3 シード平均 $\pm$ 標準偏差). $m \leq 32$ では Conv-VAE の $AU = m$ (KL 飽和なし) が FC-VAE との明確な相違を示す.

m	Conv-VAE (実験 EH)		FC-VAE (実験 E4-300ep-multiseed)	
	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	AU (mean)	TwoNN ID (mean)
4	4.0 $\pm$ 0.0	3.97 $\pm$ 0.08	4.0	3.98
8	8.0 $\pm$ 0.0	6.74 $\pm$ 0.13	8.0	6.67
12	12.0 $\pm$ 0.0	8.14 $\pm$ 0.09	10.0	7.41
16	16.0 $\pm$ 0.0	9.01 $\pm$ 0.05	11.7	7.95
20	20.0 $\pm$ 0.0	9.64 $\pm$ 0.10	13.3	8.37
32	32.0 $\pm$ 0.0	11.43 $\pm$ 0.08	15.7	9.07
64	54.3 $\pm$ 0.5	13.10 $\pm$ 0.05	22.3	10.03

m^{knee} ($\tau = 0.25$): Conv-VAE 全 3 シード = 64 (範囲内 knee なし), FC-VAE = 43 ± 15 (32~64)




図 7: EH: Conv-VAE 300ep の AU パターンと FC-VAE との比較. 左: 各シードの AU vs m (点線は $m^{\text{knee}}=64$); 右: Conv-VAE と FC-VAE の平均 $\pm$ 標準偏差バンド比較. Conv-VAE は $m \leq 32$ で $AU = m$ (KL 飽和なし) であり, FC-VAE との顕著な差を示す.

実験 EH の主要知見:

AU 動態の FC-VAE との相違: Conv-VAE は 300 エポックでも $m \leq 32$ において $AU = m$ (飽和率 0%) を示した (表 16). FC-VAE 300ep では同条件で AU が m を大幅に下回る ($m = 32$ で $15.7/32 \approx 49\%$ の飽和率) のに対し, Conv-VAE では 300 エポックの学習では KL 正則化による次元圧縮がほとんど機能していない. $m = 64$ でのみ僅かな飽和 ($AU = 54.3 \pm 0.5$, 飽和率 $\approx 15\%$) が観測された.

TwoNN ID の膨張と AU 飽和の関係: Conv-VAE の TwoNN ID ($m = 64$: 13.10 ± 0.05) は FC-VAE (10.03 ± 0.12) を大幅に上回る. これは, AU 未飽和時に残存する余剰次元が近傍距離構造を歪め, TwoNN による ID 推定値を膨張させることを示す. すなわち, **十分な KL 飽和 ($AU \ll m$) は, 潜在空間からの信頼性ある TwoNN ID 推定の前提条件**であることが本比較から支持される.

フレームワーク上の位置づけ: この結果は, 多指標フレームワークが「 $AU \approx m$ パターンで収束不足を検出できる」ことを示す. 実際, AU パターンが $AU = m$ (全次元活性) である場合, それは「モデルがまだ KL 正則化の圧力を十分に学習していない」というシグナルとして解釈すべきであり, TwoNN ID の推定値は信頼できない (過大推定の可能性がある). Conv-VAE での m^{knee} 数値的安定性は全 3 シードで $m^{\text{knee}} = 64$ (完全一致) だが, これは「tested range [4,64] 内に knee が存在しない」ことを意味しており, FC-VAE での m^{knee} 変動 (32~64) とは異なる意味を持つ点に注意が必要である.

5.6 KL アニーリングによる Conv-VAE 収束改善（実験 EK）

実験 EH では固定 $\beta = 4$ の Conv-VAE が 300 エポックでも $AU \approx m$ を示した．査読者の指摘を踏まえ，KL サイクリックアニーリング [2] を導入した場合の AU 動態を検証した（実験 EK）．

実験設定： EH と同一アーキテクチャ（MNIST, $m \in \{4, 8, 12, 16, 20, 32, 64\}$, 300 エポック, 3 シード）で，次の 2 条件を比較する：

- **固定 β ：** $\beta = 4.0$ （EH と同設定）
- **サイクリックアニーリング：** $\beta(t) = \beta_{\max} \cdot \min(1, t/r)$ を 1 サイクルとして 4 サイクル繰り返し（ $\beta_{\max} = 4.0$, $r = 0.5$ ；Fu ら 2019[2]）

表 17: EK：固定 β （EH 条件）vs KL サイクリックアニーリングの AU 比較（MNIST Conv-VAE, 300 エポック, 3 シード平均 $\pm$ 標準偏差）．固定 β では $m = 64$ で $AU = 54.3 \pm 0.5$ （約 10 次元が崩壊），アニーリングでは全次元が活性（ $AU = m$ ）．いずれも潜在 TwoNN ID（ ≈ 13 –14）に比べ AU が大幅に上回り，Conv-VAE の AU 飽和には $m > 64$ の範囲での探索が必要であることを示す．

m	固定 $\beta = 4$ （EH 相当）		KL サイクリックアニーリング	
	AU (mean $\pm$ std)	TwoNN ID	AU (mean $\pm$ std)	TwoNN ID
4	4.0 ± 0.0	3.97 ± 0.08	4.0 ± 0.0	4.09 ± 0.02
8	8.0 ± 0.0	6.74 ± 0.13	8.0 ± 0.0	6.85 ± 0.09
12	12.0 ± 0.0	8.14 ± 0.09	12.0 ± 0.0	8.07 ± 0.05
16	16.0 ± 0.0	9.01 ± 0.05	16.0 ± 0.0	9.06 ± 0.08
20	20.0 ± 0.0	9.64 ± 0.10	20.0 ± 0.0	9.59 ± 0.21
32	32.0 ± 0.0	11.43 ± 0.08	32.0 ± 0.0	11.22 ± 0.11
64	54.3 ± 0.5	13.10 ± 0.05	64.0 ± 0.0	14.03 ± 0.02

m^{knee} ($\tau = 0.25$)：固定 $\beta=64$ （全 3 シード）；アニーリング=64（全 3 シード）．有意な飽和なし．




図 8: EK：固定 β （左）vs KL サイクリックアニーリング（中央）の各シード AU 曲線，および平均比較（右）．固定 β では $m = 64$ のみで部分的崩壊（ $AU \approx 54$ ）が生じるが，アニーリングでは全次元が常に活性（ $AU = m$ ）となり， $m \in [4, 64]$ の範囲ではいずれの条件でも明確な AU 飽和（AU が m を下回るプラトー）は観測されなかった．

実験 EK の結果と考察： 表 17 が示す主要な知見は 3 点である．第 1 に，固定 $\beta = 4$ 条件では $m \leq 32$ の全範囲で $AU = m$ （飽和なし）であり， $m = 64$ のみで $AU = 54.3 \pm 0.5$ （約 10 次元崩壊）が観測された．第 2 に，KL サイクリックアニーリング条件では $m = 64$ でも全次元が活性（ $AU = m$ ）であり，固定 β より崩壊が抑制される（ β 再上昇時に一旦崩壊した次元が再活性化されるサイクルが繰り返されるため）．第 3 に，いず

れの条件でも $m \in [4, 64]$ の範囲内では $AU < m$ となる明確な飽和プラトーは観測されず, m^{knee} は全シード全条件で 64 (テスト範囲の上限) となった.

この結果は, MNIST Conv-VAE の AU 飽和を観測するには $m > 64$ の探索が必要であることを示す. 潜在 TwoNN ID ($m = 64$ で約 13~14) は AU (54~64) を大幅に下回っており, Conv アーキテクチャが FC-VAE より高次元的な潜在表現を形成することが示唆される. 定理 1 の水充填的 AU 飽和機構は原理的に正しいが, Conv-VAE では有効な $d^*(\beta)$ が MLP-VAE の約 2~3 倍であるため, 同じ m グリッドでは飽和が観測されない. $m \in \{128, 256\}$ まで拡張した実験では自然画像 (CIFAR-10・SVHN) でこの挙動を追跡した (§ 5.7).

5.7 自然画像への適用：CIFAR-10・SVHN (実験 EI・EJ)

より複雑な自然画像データセット (CIFAR-10[3], SVHN[4]) に対して本フレームワークを適用し, Pope ら [17] の内在次元推定との比較を行った.

実験設定 (EI : CIFAR-10, EJ : SVHN) :

- アーキテクチャ : Conv-VAE (入力 $32 \times 32 \times 3$)
 - エンコーダ : $\text{Conv}(3 \rightarrow 32, k=4, s=2, p=1) \rightarrow \text{Conv}(32 \rightarrow 64, k=4, s=2, p=1) \rightarrow \text{Conv}(64 \rightarrow 128, k=4, s=2, p=1) \rightarrow \text{FC}(2048 \rightarrow m) \times 2 (\mu, \log \sigma^2)$
 - デコーダ : $\text{FC}(m \rightarrow 2048) \rightarrow \text{ConvT}(128 \rightarrow 64) \rightarrow \text{ConvT}(64 \rightarrow 32) \rightarrow \text{ConvT}(32 \rightarrow 3) \rightarrow \text{Sigmoid}$
- $n_{\text{train}} = 20,000$, 150 エポック, KL サイクリックアニーリング ($\beta_{\text{max}} = 4$, 3 サイクル)
- $m \in \{16, 32, 64, 128, 256\}$, seeds $\in \{42, 123, 777\}$

表 18: EI・EJ : CIFAR-10 (左)・SVHN (右) の Conv-VAE 実験結果 (3 シード平均 $\pm$ 標準偏差) と Pope ら [17] の報告値の比較 (KL サイクリックアニーリング, 150 エポック, 3 サイクル). CIFAR-10 では $m = 64$ で潜在 TwoNN ID が生データ TwoNN ID と一致 (≈ 25), Pope ら [17] の報告値 ($d_{\text{ID}} \approx 26$) を独立に支持する. SVHN では $m \geq 128$ で $AU < m$ (部分的崩壊) が観測される.

m	CIFAR-10 (EI)		SVHN (EJ)	
	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)
16	16.0 $\pm$ 0.0	13.12 $\pm$ 0.12	16.0 $\pm$ 0.0	11.30 $\pm$ 0.12
32	32.0 $\pm$ 0.0	19.26 $\pm$ 0.23	32.0 $\pm$ 0.0	15.08 $\pm$ 0.08
64	64.0 $\pm$ 0.0	25.21 $\pm$ 0.41	64.0 $\pm$ 0.0	19.97 $\pm$ 0.12
128	128.0 $\pm$ 0.0	28.83 $\pm$ 0.41	125.3 $\pm$ 0.5	24.60 $\pm$ 0.36
256	256.0 $\pm$ 0.0	30.91 $\pm$ 0.64	206.7 $\pm$ 1.2	27.08 $\pm$ 0.34
Raw TwoNN=25.20, MLE=26.56 ($\approx$ Pope 推定値 26)			Raw TwoNN=10.09, MLE=18.85	
m^{knee} ($\tau = 0.25$) : 全シード=256 (範囲内 knee なし)			m^{knee} : 全シード=256 (範囲内 knee なし)	




図 9: EI : CIFAR-10 Conv-VAE (KL サイクリックアニーリング) における AU・TwoNN ID の m 依存性 (3 シード). TwoNN ID は Pope ら [17] の報告値 ($d_{\text{ID}} \approx 26$) と収束傾向を示す.




図 10: EJ : SVHN Conv-VAE (KL サイクリックアニーリング) における AU・TwoNN ID の m 依存性 (3 シード).

自然画像実験 (EI・EJ) の主要知見 : 表 18 から次の 3 点が観測される.

第 1 に, CIFAR-10 実験 (EI) では $m = 64$ における潜在 TwoNN ID が 25.21 ± 0.41 となり, 生データ TwoNN ID (25.20) と一致した. これは Pope ら [17] の報告値 ($d_{\text{ID}} \approx 26$) の**独立した再現**であり, 本フレームワークの TwoNN ID 推定の外部妥当性を示す. CIFAR-10 では $AU = m$ が $m \leq 256$ の全範囲で維持され, AU 飽和には $m > 256$ が必要と考えられる.

第 2 に, SVHN 実験 (EJ) では $m \geq 128$ で $AU < m$ の部分的崩壊が観測された ($m = 128$: $AU = 125.3 \pm 0.5$, $m = 256$: $AU = 206.7 \pm 1.2$). SVHN の生データ TwoNN ID (10.09) は CIFAR-10 (25.20) より低く, SVHN の方が相対的に低次元な潜在表現を要求することと整合する.

第 3 に, 両データセットとも $m \in [16, 256]$ 内では $\tau = 0.25$ 基準による m^{knee} 検出には至らなかった (全シード $m^{\text{knee}} = 256$). SVHN では τ を小さく設定するか, m グリッドを拡張することで m^{knee} が特定できる可能性がある.

6 考察

6.1 RQ1 への回答と m^{knee} の位置づけ

RQ1 への総括：RQ1 「 m^{knee} は $\hat{d}_{\text{ID}}$ と対応する傾向があるか、またその対応はアーキテクチャや複数シードにわたって安定して観測されるか」に対しては、以下の2層の答えが得られた：

- **部分的支持：**Fashion-MNIST（単一シード）では $m^{\text{knee}} = 12$ が $\hat{d}_{\text{ID}} \approx 9 \sim 10$ と対応する傾向を示し、「AU 曲線形状の変化が有効次元の粗い目安を与える」という主張は支持された。
- **数値的安定性は不支持：**MNIST 多シード実験（150・300 エポック）では m^{knee} が 32~64 に変動し、数値的再現性は支持されなかった。 m グリッドの設計が乱数状態（初期化）を変えることが主因である。

TwoNN ID 推定と Conv-AE での整合性 (Conv-AE: 11.29 vs FC-AE: 10.02) は確認されたが、Conv-VAE での m^{knee} 検出には 100 エポックでは収束不足であった。全体として、 m^{knee} は探索的な設計目安として有用だが、安定した新指標とは言えないのが本研究の正直な結論であり、多指標フレームワーク全体の頑健性 (AU 値・TwoNN ID の安定性) が本研究の主要な貢献となる。

否定的結果の位置づけ：RQ1 に対して「数値的安定性は支持されなかった」という否定的結果は、単なる実験の失敗ではなく、「 m^{knee} の不安定性が m グリッドと乱数シードに起因する」というメカニズムの解明を含む積極的な知見である (§ 5.3.5)。この理解なしには、 m^{knee} を実際の設計場面で有効に活用することはできない。したがって、「いつ・なぜ m^{knee} が不安定になるか」の定量的解明は、本フレームワークの実用上の前提条件として本論文の重要な貢献の一つと位置づける。

$\hat{d}_{\text{ID}}$ (参照 AE 経由) は等長性バイアスを含む近似値であるため ($\kappa \approx 10^9$)、 m^{knee} と $\hat{d}_{\text{ID}}$ の「整合」は厳密な意味での理論的一致を意味しない。 m^{knee} は「KL 正則化が有意な次元圧縮を開始する可能性のある転換点」として粗い参照値を与えうる観測量として解釈するのが妥当であり (条件付き・探索的)、精確な数値の再現には以下の要因への注意が必要である：

- m グリッドの粒度 (点の間隔によって同定点が変わりうる)
- AU の離散性 (AU は整数値のため、小さい m では粗い増加率になる)
- 閾値 τ_{knee} (付録付録 C；Fashion-MNIST では境界感度あり)
- β の値 (予備実験： $\beta \in [2, 8]$ で AU パターン形状は安定するが、 m^{knee} の数値は m グリッドにも依存する；付録付録 E)
- 学習収束度 (未収束では AU パターンが変化する)

Fashion-MNIST では $m^{\text{knee}} = 12$ が確認された (実験 EF； $\hat{d}_{\text{ID}} \approx 9 \sim 10$)。MNIST の E4 拡張実験 (単一シード 42, $m \in \{1, 4, 8, \dots, 256\}$) でも $m^{\text{knee}} = 12$ が得られたが、E4-300ep-multiseed ($m \in \{4, 8, 12, 16, 20, 32, 64\}$, 3 シード) では m^{knee} が 32~64 (平均 43 ± 15) となり、 $m^{\text{knee}} = 12$ は再現されなかった (§ 5.3.5； m グリッドの差異に起因する乱数状態の変化が原因と考えられる)。この結果は、 m^{knee} が AU 増加曲線の「形状」を捉えるヒューリスティックとして有用である一方、**特定の数値 (例：12) の精確な再現性は保証されない**ことを示す。対照的に、AU 値 ($\sigma \leq 0.5$)・TwoNN ID ($m = 64$: 10.03 ± 0.12) は 300 エポック・3 シードにわたって高い再現性を持ち、MNIST の $\hat{d}_{\text{ID}} \approx 10$ の推定はロバストである (§ 5.3.5, 表 11)。

本論文のコアメッセージ：この対比——AU 値・TwoNN ID の安定性 vs. m^{knee} の不安定性——が本論文の最も情報量の多い発見である。多指標フレームワークの実践的価値は、 m^{knee} という一指標を鵜呑みにせず、頑健な指標 (AU 値・TwoNN ID) と探索的指標 (m^{knee}) を明確に区別して用いる点にある。本研究はその条件を定量的に解明した点で、単なる手法提案を超えた実用的な貢献を持つ。

6.2 m^{knee} 不安定性の最適化ダイナミクスの解釈と安定化戦略

勾配競合 (Gradient Conflict) による m^{knee} 不安定性の深層メカニズム：

命題 2 はグリッド感度を形式的に示したが、実際の学習では追加の不安定性因子が存在する。 β -ELBO の勾配は再構成項 $\nabla \mathcal{L}_{\text{rec}}$ と KL 項 $\nabla \mathcal{L}_{\text{KL}}$ の線形結合であり、これらは $m \approx d^*(\beta)$ (有効次元しきい値付近) において**勾配競合**を生じさせる：

- 再構成勾配 ($\nabla \mathcal{L}_{\text{rec}}$)：余剰次元 $j > d^*$ でも、学習初期は小さな再構成寄与 ($\lambda_j > 0$ なら正の利得) があり、次元を活性化しようとする。
- KL 勾配 ($\beta \nabla \mathcal{L}_{\text{KL}}$)：同次元を事前分布に回帰させようとする反対方向の圧力。
- この競合の解消速度は乱数シード (初期化)、 m グリッド (各 m で独立した最適化軌道)、および β の値に依存する。定理 1 の大域的最適解への収束経路は非線形最適化では一意でなく、sharpness の低い損失ランドスケープでは $m \approx d^*$ 付近の AU 曲線の傾きが初期条件に感度を持つ。

サイクリック KL アニールリング [2] は β を段階的に増加させることで、この勾配競合の解消を段階的に促し、大域的最適解への収束を改善する (実験 EK； § 5.6)。

m^{knee} の安定化のための実践的アプローチ：

本研究の知見から、 m^{knee} を実際の設計に用いる際の以下の推奨事項を提案する：

1. **密なグリッド設計**：推定 $\hat{d}_{\text{ID}}$ (TwoNN ID から得られる) の前後に密な点を配置する (例：ID ≈ 26 なら $m \in \{20, 24, 28, 32, 36\}$ を含む)。命題 2 より、グリッド間隔がそのまま m^{knee} の最大誤差になる。
2. **アンサンブル m^{knee}** ：複数シード $\{s_1, \dots, s_S\}$ での AU 曲線から各 $m^{\text{knee}(s_i)}$ を計算し、**メディアン**を採用する：

$$m^{\text{knee, ens}} = \text{median}\{m^{\text{knee}(s_1)}, \dots, m^{\text{knee}(s_S)}\} \quad (8)$$

本実験 (3 シード) でも、個別 m^{knee} の変動に対してメディアンは比較的安定した推定を与える。

3. **KL アニールリングの採用と m グリッドの拡張**：Conv-VAE では、アニールリングにより大きな m での不必要な崩壊が抑制されるが、AU 飽和の観測には m グリッドを $d^*(\beta)$ の推定値の 2 倍以上に拡張する必要がある (例：MNIST Conv-VAE では $m > 64$ ； § 5.6)。
4. **頑健な指標との照合**： m^{knee} の推定値は常に AU 値・TwoNN ID と照合し、三指標の整合性で最終判断を下す (表 19 参照)。

$\tau_{\text{knee}} = 0.25$ の**理論的・経験的根拠**：鈍化点の閾値 $\tau_{\text{knee}} = 0.25$ は、「AU 増加率が最大変化量の 25% 未満」を鈍化とする経験的選択であるが、以下の理論的根拠がある。定理 1 より、 $m = d^*(\beta)$ での AU 増加量 ΔAU は Δm の変化に対して $\Delta \text{AU} / \Delta m \rightarrow 0$ (飽和) の遷移が理論的に保証される。 $\tau = 0.25$ はこの遷移を「最大増加率の 1/4 以下」として捉えるものであり、飽和前 ($m < d^*$) と飽和後 ($m > d^*$) を合理的に分離する感度を持つ (付録付録 C 参照)。より厳密な閾値設定は AU(m) 曲線の二次微分 (曲率) 最大化に基づくことができるが、AU の離散性のため実データでは数値的に不安定である。

6.3 AU Dynamics が有効表現次元を反映するメカニズム

AU_{sat} vs. m^{knee} の使い分け：単連結な合成多様体 (Swiss Roll 等) では AU の急激な飽和 ($\text{AU}_{\text{sat}} = d_{\text{true}}$) が観測されるため、 AU_{sat} が有効表現次元の直接的な読み取り点となる。一方、実データのような複雑な分布 (多クラス、非連結な部分多様体) では、AU は単調に漸増し明確な飽和を示さない。この場合、 m^{knee} が「KL 正則化が有効に機能し始める点」として有効表現次元の**粗い実用的目安**となる (表 19；数値の精確な再現性は m グリッド・シードに依存する点に注意)。

表 19: AU_{sat} と m^{knee} の使い分け（本研究結果に基づく）

データ種別	AU パターン	推奨指標
合成多様体（単純，単連結）	急激な飽和	AU_{sat} （ $= d_{\text{true}}$ と整合）
合成多様体（位相的に非自明）	段階的飽和	AU_{sat} （ $= d_{\text{emb}}$ と整合傾向，条件付き）
実データ（MNIST, Fashion-MNIST）	漸増型	m^{knee} （粗い目安； m グリッド・シード依存）

6.4 位相的構造の AU_{sat} への刻印：条件と限界

位相的に非自明な合成多様体（Torus, Möbius Band）において $AU_{\text{sat}} = d_{\text{emb}}$ （ $= 3$ ）が本研究条件下で観測された（実験 EB）．この対応の理論的背景は，VAE の Gaussian 事前分布の台 $\mathbb{R}^m$ が収縮可能であるため，基本群 π_1 が非自明な多様体を自己交差なしに埋め込むには $d_{\text{emb}} > d_{\text{ID}}$ 次元が必要となるという位相幾何学的制約 [10, 11] にある．

しかし，この対応には以下の重要な条件と限界がある：

- **前処理依存性**：標準化（平均 0・分散 1）が必要であり，異なる正規化では AU_{sat} が変化する（§ 6.7）．
- **収束依存性**：十分な学習収束（ $\beta = 4$ ，十分なエポック）が必要．
- **実データへの非適用性**：MNIST の $AU_{\text{sat}} = 36$ は $\hat{d}_{\text{ID}} \approx 10 \sim 12$ を大幅に超えており，単純な $AU_{\text{sat}} = d_{\text{emb}}$ の解釈は成立しない（Manifold Entanglement と capacity leak の両解釈が可能；実験 EY は予備的）．

したがって， $AU_{\text{sat}} \approx d_{\text{emb}}$ という観測は本研究条件下での条件付き副次的知見であり，フレームワークの主要主張（ m^{knee} による有効表現次元の読み取り）から独立したものとして位置づける．

6.5 学習ダイナミクスと表現の時間的形成

実験 E6 の知見（Epoch 5 での大域的構造の急速形成，その後の TwoNN ID の漸進的増加）は，AE/VAE の表現学習における 2 フェーズの存在を示唆する：

フェーズ 1（初期）：データのグローバルな近傍構造（Trustworthiness）が急速に形成される．これは，ネットワークが最初に「どのサンプルが似ているか」を大域的に学習することを示す．

フェーズ 2（後期）：局所的な有効次元（TwoNN ID）が漸進的に増加する．これは，表現の「解像度」が徐々に精緻化されることを示す．

この時間的分離は，有効次元を読み取るためのモデル評価に実践的な示唆を与える：TwoNN ID による有効次元の読み取りには，Trustworthiness の収束後の十分な追加学習が必要である（単一シードの観測）．

6.6 幾何的正則化による表現の信頼性向上

IsometricAE（ $\kappa \approx 1.04$ ，実験 EC）は，潜在空間での ID 推定の前提条件（等長性）を実現できることを示した．これは Stage 1（ID 推定）の理論的精度向上に貢献する一方，デコーダやコビアン計算のコスト（ $O(m)$ 倍のバックワードパス）により大規模データへの適用が制限される（§ 6.7）．

現実的な位置づけとしては，IsometricAE は「 m^* が確定した後に潜在空間の等長性を検証する補助ツール」であり，主要な有効次元の読み取りには通常の VAE を用いる．

6.7 限界と今後の課題

(A) 評価データの範囲と一般化可能性

- **Conv-AE・Conv-VAE 検証** (実験 EG・EH・EK) : Conv-AE (EG) の TwoNN ID 一貫性を確認した. EH では固定 β Conv-VAE が 300 エポックでも $AU \approx m$ を示し, EK (KL アニール) でも MNIST $m \in [4, 64]$ 内ではどちらの条件でも明確な AU 飽和プラトーは観測されなかった (§ 5.6). これは Conv-VAE の有効 $d^*(\beta)$ が FC-VAE より高次元であることを示唆する. 本稿で実施した CIFAR-10・SVHN 実験 (EI・EJ) では, Pope ら [17] の $d_{ID} \approx 26$ との照合を行ったが (§ 5.7), 大規模自然画像 (ImageNet 等) への適用と, より深い Conv-VAE アーキテクチャでの系統的検証は今後の課題として残る.
- **高次元相多様体** : Klein Bottle 等の高次の位相不変量を持つ合成多様体での EB 実験の拡張が課題である.
- **主要実験の多シード検証** : E4 (300 エポック 単一シード)・E6 (学習ダイナミクス 単一シード)・EY (75 エポック予備実験) はいずれも単一シードのみであった. 本稿では E4-multiseed (150 エポック, 3 シード; § 5.3.4) および E4-300ep-multiseed (300 エポック, 3 シード; § 5.3.5) を追加した. いずれの条件でも AU・TwoNN ID のシード間一致は高い ($\sigma \leq 0.5$) が, m^{knee} は 150 エポック (43 ± 15)・300 エポック (43 ± 15) とともに 32~64 の範囲で変動し, E4 拡張実験での $m^{\text{knee}} = 12$ は再現されなかった. この不安定性は, 使用する m グリッドの差異により乱数状態 (初期化パス) が変化することに起因すると考えられ, m^{knee} の特定値への再現性はエポック数ではなく実験設定 (m グリッド・シード) に依存することが明らかになった. E6・EY の多シード検証は今後の課題である.

(B) 指標・ハイパーパラメータの感度

- **参照 AE の等長性バイアスと TwoNN ID への影響** : 命題 3 より, 等長性 ($\kappa = 1$) は ID 推定精度の理論的前提であるが, $m = 256$ の参照 AE の条件数 $\kappa \approx 10^9$ は等長性からの大きな逸脱を示す. 実験 EH では, Conv-VAE の AU 未飽和時 ($AU \approx m$) の TwoNN ID (13.10) が FC-VAE の AU 飽和時 (10.03) より大幅に膨張しており, **等長性バイアスは KL 飽和不足と相乗的に ID 推定値を歪める**ことが示された. IsometricAE (実験 EC) による $\kappa \approx 1$ の達成, または複数 m での ID 収束確認 (m 増加に対して TwoNN ID が安定する点の確認) が実用的な緩和策である. ランダム射影との比較による歪みの定量的評価は今後の課題である.
- τ_{knee} の非普遍性 : Fashion-MNIST では $\tau = 0.25$ 前後で m^{knee} が変化する境界感度が確認されており, 二階差分代替手法との併用を推奨する (付録付録 C).
- AU_{sat} の前処理依存性 : 正規化方法により AU_{sat} が変動する (実験 EB). $AU_{\text{sat}} \approx d_{\text{emb}}$ の再現には標準化 (平均 0・分散 1) が必要.
- β への依存性 : 予備実験 (50 エポック, $\beta \in \{1, 2, 4, 8\}$) から, $\beta = 1$ では $AU \approx m$ (正則化不足), $\beta = 8$ では過正則化の兆候が観測された (付録付録 D, 図 11). $\beta \in [2, 8]$ での AU パターンの安定性は確認されているが, m^{knee} の精確な値は m グリッドや乱数シードにも依存する (§ 6.1).

(C) 計算コスト

- IsometricAE のヤコビアン計算コスト ($O(m)$ 倍) により, CIFAR-10 (≈ 64 倍)・ImageNet ($\approx 3,000$ 倍) への直接適用は困難.
- 全 m スイープ (11 次元 $\times$ 300 エポック $\times$ 2 モデル) は数時間~数日を要する.

7 むすび

本論文では、AE/VAE の有効潜在次元を定量的に読む**多指標分析フレームワーク**を提案し、合成多様体・MNIST・Fashion-MNIST・CIFAR-10・SVHN での実験的検証を行った。理論面では、線形 β -VAE における AU 飽和しきい値を $\lambda_j > \beta\tau^2$ として厳密に証明し（定理 1）、 m^{knee} のグリッド感度の形式的解析（命題 2）と安定化戦略（式 (8), § 6.2）を提示した。

主要知見のまとめ：

1. **多指標フレームワークの有用性と頑健性：**TwoNN/MLE ID, AU 値, MSE エルボー, PCA の相補的活用により、単一指標では得られない信頼性の高い有効次元解釈が可能である。特に AU 値 ($\sigma \leq 0.5$)・TwoNN ID (MNIST $m = 64$: 10.03 ± 0.12) は 3 シード・300 エポックにわたって高再現性を示す (§ 5.3.5)。
2. **定理 1 と実験の整合：**線形 β -VAE の AU 飽和しきい値 $\lambda_j > \beta\tau^2$ は、KL 正則化のない Vanilla AE が $AU = m$ (全次元活性) となる実験的観測（実験 EA）と整合する。実験 EK では、固定 $\beta = 4$ では $m = 64$ で部分的崩壊 ($AU=54.3$)、サイクリックアニーリングでは $AU=64$ (崩壊抑制) となり、アニーリングが AU 動態に異なる影響を与えることを示す。いずれも MNIST Conv-VAE での $m \in [4, 64]$ 内の明確な飽和プラトーは観測されず、Conv-VAE の有効 $d^*(\beta)$ が FC-VAE より高次元であることが示唆される。
3. **自然画像への汎化：**CIFAR-10・SVHN への適用（実験 EI・EJ, § 5.7）において、本フレームワークの TwoNN ID 推定が Pope ら [17] の報告値 (CIFAR-10: $d_{\text{ID}} \approx 26$) と整合することで、本フレームワークの自然画像への汎化性が実証的に支持される。
4. **m^{knee} の探索的有用性と安定化戦略：**Fashion-MNIST では $m^{\text{knee}} = 12$ が $\hat{d}_{\text{ID}} \approx 9 \sim 10$ と対応し（部分的支持）。MNIST では $m^{\text{knee}} \in \{32, 64\}$ と変動（数値的安定性：不支持）。命題 2 による理論的根拠と、アンサンブル化・密グリッド・KL アニーリングによる実践的安定化戦略を提示した (§ 6.2)。

副次的知見（探索的・条件付き）：位相的に非自明な合成多様体での $AU_{\text{sat}} \approx d_{\text{emb}}$, MNIST での大域・局所構造形成の時間的分離, IsometricAE による $\kappa \approx 1$ の等長潜在空間の実現, Conv-AE での TwoNN ID の全結合型との整合性, および CIFAR-10 実験 (EI) での潜在 TwoNN ID が $m = 64$ で生データ TwoNN ID (25.20) と一致し Pope ら [17] の報告値を独立に再現した点。

今後の課題：以下を主要な研究課題として挙げる。

1. τ_{knee} の適応的設定と二階差分法：SVHN 実験 (EJ, § 5.7) では、 $m = 128$ で $AU = 125.3 < 128$ という部分的崩壊が観測されたにもかかわらず、固定閾値 $\tau = 0.25$ では m^{knee} が検出されなかった。これはデータセットに固有の $AU(m)$ 曲線形状（緩勾配での減衰）が一律閾値との不適合を生じることを示す。解決策として、 $AU(m)$ の**離散二階差分**

$$\Delta^2 AU(m_i) := AU(m_{i+1}) - 2AU(m_i) + AU(m_{i-1}) \quad (9)$$

の最大曲率点 ($|\Delta^2 AU|$ が最大となる m_i) を m^{knee} とする**曲率最大点法**, あるいはデータに応じた**適応型閾値選択**（例えば leave-one-out cross-validation による τ 最適化, または $AU(m)$ 正規化勾配 $r(m)/r_{\text{max}}$ への Kneedle アルゴリズム適用）の開発が重要な研究課題である。付録 § 付録 C に述べたように、 $\tau = 0.25$ は MNIST・Fashion-MNIST では安定して機能するが、SVHN のように内在次元が低く $AU(m)$ の飽和が緩やかなデータセットでは過大推定を招くことが確認された。

2. m^{knee} 安定化の定量的検証：密なグリッド（推定 ID 付近での細分化）とアンサンブル評価による m^{knee} の誤差評価（命題 2 の実証的検証）。
3. **大規模データへの拡張：**ImageNet 等への適用には Conv-VAE の大型化と計算コスト削減が必要であ

り、階層的 ID 推定（層ごとの TwoNN ID）との組み合わせが有望である。

4. **線形 VAE 定理の非線形設定への厳密な拡張**：定理 1 は線形ガウス設定での厳密な成立を示すが、非線形エンコーダ・デコーダへの拡張には局所線形化（接空間近似）に基づく解析が必要である。
5. **相互情報量・レート歪み曲線との定量比較**： $AU(m)$ 曲線と情報論的レート歪み関数 $R(D)$ の対応関係を実験的に精密化し、理論的水充填解との定量的一致を検証する。

参考文献

- [1] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Wiley-Interscience, Hoboken, NJ, 2006.
- [2] H. Fu, C. Tan, B. Peng, Z. Zhao, T. Yan, C. Chang, and L. Zhao, “Cyclical annealing schedule: A simple approach to mitigating KL vanishing,” in *Proceedings of NAACL-HLT 2019*, pp. 240–250, 2019.
- [3] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Technical Report, University of Toronto, 2009.
- [4] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, “Reading digits in natural images with unsupervised feature learning,” in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- [5] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *Journal of the Royal Statistical Society: Series B*, vol. 61, no. 3, pp. 611–622, 1999.
- [6] C. Fefferman, S. Mitter, and H. Narayanan, “Testing the manifold hypothesis,” *Journal of the American Mathematical Society*, vol. 29, no. 4, pp. 983–1049, 2016.
- [7] Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.
- [8] E. Facco, M. d’Errico, A. Rodriguez, and A. Laio, “Estimating the intrinsic dimension of datasets by a minimal neighborhood information,” *Scientific Reports*, vol. 7, p. 12140, 2017.
- [9] E. Levina and P. J. Bickel, “Maximum likelihood estimation of intrinsic dimension,” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 17, 2005.
- [10] A. Hatcher, *Algebraic Topology*, Cambridge University Press, Cambridge, 2002.
- [11] V. Guillemin and A. Pollack, *Differential Topology*, Prentice-Hall, Englewood Cliffs, NJ, 1974.
- [12] G. Carlsson, “Topology and data,” *Bulletin of the American Mathematical Society*, vol. 46, no. 2, pp. 255–308, 2009.
- [13] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in *International Conference on Learning Representations (ICLR)*, 2014.
- [14] K. Kato, J. Zhou, T. Sasaki, and A. Nakagawa, “Rate-distortion optimization guided autoencoder for isometric embedding in Euclidean latent space,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 119, 2020.
- [15] P. Nazari, S. Damrich, and F. A. Hamprecht, “Geometric autoencoders – what you see is what you decode,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 202, 2023.
- [16] C. Ceruti, S. Bassis, A. Rozza, G. Lombardi, E. Casiraghi, and P. Campadelli, “DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration,” *Pattern Recognition*, vol. 47,

- no. 8, pp. 2569–2581, 2014.
- [17] P. Pope, C. Zhu, A. Abdelkader, M. Goldblum, and T. Goldstein, “The intrinsic dimension of images and its impact on learning,” in *International Conference on Learning Representations (ICLR)*, 2021.
 - [18] A. Ansuini, A. Laio, J. H. Macke, and D. Zoccolan, “Intrinsic dimension of data representations in deep neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
 - [19] T. Birdal, A. Lou, L. J. Guibas, and U. Simsekli, “Intrinsic dimension, persistent homology and generalization in neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.
 - [20] L. Valeriani, D. Wood, G. Catania, S. Gherardini, A. Laio, and A. Ansuini, “The geometry of hidden representations of large transformer models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.
 - [21] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” in *International Conference on Learning Representations (ICLR)*, 2017.
 - [22] J. Lucas, G. Tucker, R. B. Grosse, and M. Norouzi, “Don’t blame the ELBO! A linear VAE perspective on posterior collapse,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
 - [23] S. Rifai, P. Vincent, X. Muller, X. Glorot, and Y. Bengio, “Contractive auto-encoders: Explicit invariance during feature extraction,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 28, 2011.
 - [24] G. Alain and Y. Bengio, “What regularized auto-encoders learn from the data-generating distribution,” *Journal of Machine Learning Research (JMLR)*, vol. 15, no. 1, pp. 3743–3773, 2014.
 - [25] N. Tishby, F. C. Pereira, and W. Bialek, “The information bottleneck method,” in *Proc. 37th Annual Allerton Conference on Communication, Control and Computing*, pp. 368–377, 1999.
 - [26] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 97, pp. 3519–3529, 2019.
 - [27] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform manifold approximation and projection for dimension reduction,” *arXiv preprint arXiv:1802.03426*, 2018.
 - [28] F. Chazal and B. Michel, “An introduction to topological data analysis: Fundamental and practical aspects for data scientists,” *Frontiers in Artificial Intelligence*, vol. 4, 2021.
 - [29] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *Journal of Machine Learning Research (JMLR)*, vol. 9, pp. 2579–2605, 2008.

付録 A 命題の証明スケッチ

命題 4 (デコーダヤコビアンの実効階数). 十分な容量を持つ AE が多様体 $\mathcal{M}$ を正確に再構成するとき、デコーダのヤコビ行列 $J_g(z)$ の有意特異値数は $\min(m, d_{\text{emb}})$ に等しい。

証明スケッチ: 正確な再構成時, g の値域は $\mathcal{M}$ の接空間 $T_{g(z)}\mathcal{M}$ に張られる. $\mathcal{M}$ が d 次元なら $\text{rank}(J_g) = d$ となり, 余剰次元の特異値は零に近づく. (有限容量・最適化誤差を無視.)

命題 5 (ノイズ方向選択性). DAE の最適再構成関数は, 多様体の法線方向のノイズを接線方向より選択的に

除去する.

証明スケッチ：Alain ら [24] より, DAE の再構成方向 $r(x) - x \approx \sigma^2 \nabla \log p(x)$ であり, $\nabla \log p(x)$ は多様体の法線方向を強く指す (多様体仮説のもと). (漸近的最適解を仮定; 有限ノイズ・有限容量での近似誤差を無視.)

命題 6 (近傍構造保存と最適ボトルネック). $m = d_{\text{true}}$ (または d_{emb}) において, *Trustworthiness* が最大化に向けて急激に改善し, それ以上の m への増加による改善は限定的となる.

証明スケッチ：命題 1 より, $m < d$ では連続単射が不可能で情報の衝突が不可避となり, *Trustworthiness* が低下する. $m \geq d$ で制約が解消され, $m > d$ では既に全多様体構造が表現可能であるため追加次元の効果は限定的. (有限サンプル・有限容量を無視.)

付録 B 定理 1 の詳細な導出

本付録では, 定理 1 (線形 β -VAE における AU 飽和しきい値) の証明において本文中で省略した式 (5) と式 (6) の間の代数的ステップを詳述する.

Step 1: 最適デコーダ重みの導出

スカラー問題として, 方向 j に対し $y_j \sim \mathcal{N}(0, \lambda_j)$ (データの第 j 主成分), エンコーダ: $q_j(z_j|y_j) = \mathcal{N}(a_j y_j, \sigma_j^2)$, デコーダ: $\hat{y}_j = b_j z_j$ を考える. デコーダ重み b_j について, 周辺化した再構成 MSE を最小化する (σ_j^2, a_j を固定したとき):

$$D_j(b_j) = \mathbb{E}_{y_j, z_j} [(y_j - b_j z_j)^2] = \lambda_j - 2a_j \lambda_j b_j + b_j^2 (a_j^2 \lambda_j + \sigma_j^2). \quad (10)$$

$\partial D_j / \partial b_j = 0$ を解くと, 最適デコーダ重みは

$$b_j^* = \frac{a_j \lambda_j}{a_j^2 \lambda_j + \sigma_j^2} =: \frac{a_j \lambda_j}{\rho_j}, \quad \rho_j := a_j^2 \lambda_j + \sigma_j^2. \quad (11)$$

Step 2: 最適 MSE と相互情報量の表示

式 (11) を式 (10) に代入すると:

$$D_j^* = \lambda_j - \frac{a_j^2 \lambda_j^2}{\rho_j} = \frac{\lambda_j \sigma_j^2}{\rho_j}. \quad (12)$$

また, $y_j \rightarrow z_j$ の通信路容量 (相互情報量) は:

$$I(z_j; y_j) = \frac{1}{2} \log \frac{\rho_j}{\sigma_j^2} = \frac{1}{2} \log \left(1 + \frac{a_j^2 \lambda_j}{\sigma_j^2} \right) =: R_j. \quad (13)$$

Step 3: β -ELBO のレート歪み表示

$b_j = b_j^*$ を固定したもとの, (σ_j^2, a_j) に関する β -ELBO 寄与は $L_j = -D_j/(2\tau^2) - \beta R_j$ と書ける (KL 最小化との等価性 [1]). ρ_j をパラメータとして $D_j^* = \lambda_j \sigma_j^2 / \rho_j$, $R_j = \frac{1}{2} \log(\rho_j / \sigma_j^2)$ を代入すると, 本文の式 (5) が得られる:

$$L_j = -\frac{\lambda_j \sigma_j^2}{2\tau^2 \rho_j} - \frac{\beta}{2} [\rho_j - 1 - \log \rho_j]. \quad (5 \text{ 再掲})$$

(ここで $\sigma_j^2 = \rho_j - a_j^2 \lambda_j$, $\rho_j \geq \sigma_j^2$).

Step 4：KKT 条件による最適歪み D_j^* の導出

歪み $D_j \in (0, \lambda_j)$ を主変数として $L_j = -D_j/(2\tau^2) - \beta R_j(D_j)$ を最大化する．ガウス通信路のレート歪み関係 $R_j(D_j) = \frac{1}{2} \log(\lambda_j/D_j)$ より：

$$\frac{\partial L_j}{\partial D_j} = -\frac{1}{2\tau^2} + \frac{\beta}{2D_j} = 0 \implies D_j^* = \beta\tau^2. \quad (14)$$

これが Shannon の水充填定理 [1] の「水面 (water level)」 $\mu = \beta\tau^2$ に対応する．ただし式 (14) の解は $D_j^* = \beta\tau^2 \leq \lambda_j$ (フィジビリティ制約) が満たされる場合にのみ実行可能 (*active*) であり, $\lambda_j < \beta\tau^2$ の場合は次元 j を符号化しない ($a_j = 0$, *dead*) が最適となる．

Step 5：活性・不活性の ELBO 値の計算

不活性 (dead) : $a_j = 0$, $\sigma_j^* = 1$ (KL = 0), $D_j = \lambda_j$ のとき

$$L_j^{(\text{dead})} = -\frac{\lambda_j}{2\tau^2}. \quad (15)$$

活性 (active) : $D_j^* = \beta\tau^2$ を代入すると, $R_j^* = \frac{1}{2} \log(\lambda_j/(\beta\tau^2))$ であるから：

$$L_j^{(\text{active})} = -\frac{\beta\tau^2}{2\tau^2} - \beta \cdot \frac{1}{2} \log \frac{\lambda_j}{\beta\tau^2} = -\frac{\beta}{2} - \frac{\beta}{2} \log \frac{\lambda_j}{\beta\tau^2}. \quad (16)$$

Step 6：ELBO 利得 ΔL_j の厳密な表示と符号解析

活性化の利得 $\Delta L_j := L_j^{(\text{active})} - L_j^{(\text{dead})}$ を計算する． $t := \lambda_j/(\beta\tau^2) > 0$ とおくと：

$$\Delta L_j = \left(-\frac{\beta}{2} - \frac{\beta}{2} \log t\right) - \left(-\frac{\beta\tau^2 \cdot t}{2\tau^2}\right) = \frac{\beta}{2}(t - 1 - \log t). \quad (17)$$

関数 $h(t) := t - 1 - \log t$ の解析：

- $h'(t) = 1 - 1/t = (t - 1)/t$ より, $t = 1$ で $h' = 0$ (唯一の停留点).
- $h''(t) = 1/t^2 > 0$ より, $t = 1$ は**大域的最小点**, $h(1) = 0$.
- $t > 0$, $t \neq 1$ のとき $h(t) > 0$ (大域最小値 0 より大).

したがって $\Delta L_j = (\beta/2) h(t)$ の符号は：

$$\Delta L_j > 0 \iff h(t) > 0 \iff t \neq 1. \quad (18)$$

Step 7：フィジビリティと飽和条件の統合

活性解のフィジビリティ条件 ($D_j^* = \beta\tau^2 \leq \lambda_j$) は $t \geq 1$ を要求する． $t < 1$ ($\lambda_j < \beta\tau^2$) では活性解が実行不可能であり dead が強制される． $t = 1$ ($\lambda_j = \beta\tau^2$) では $\Delta L_j = 0$ (無差別)． $t > 1$ ($\lambda_j > \beta\tau^2$) では活性が実行可能かつ $\Delta L_j > 0$ (優位)．

以上をまとめると：

$$\text{次元 } j \text{ が活性} \iff \lambda_j > \beta\tau^2, \quad (19)$$

すなわち定理 1 の飽和しきい値条件 (4) が成立する. □

注意 4. 本文の式 (6) は, 式 (17) の $h(t) = t - 1 - \log t$ を $t = 1$ 周りで 2 次展開した近似 $h(t) \approx (t - 1)^2/2$ (つまり $\Delta L_j \approx (\lambda_j - \beta\tau^2)^2/(2\beta\tau^4)$) の形で表記している．厳密な表示は式 (17) であり, 近似は説明の簡略化のためのものである．

付録 C τ_{knee} の感度分析と横断検証（実験 EZ）

$\tau_{\text{knee}} = 0.25$ の選択根拠

理論的根拠：定理 1 より， $AU(m)$ の増加率 $r(m) = \Delta AU / \Delta m$ は $m < d^*(\beta)$ （飽和前）で $r \approx 1$ （新たな次元が完全に活性化）， $m > d^*(\beta)$ （飽和後）で $r \rightarrow 0$ （追加次元は不活性）となる理論的な段差を持つ．実際の AU は離散整数値であるため，この遷移は滑らか（または離散的）に起こる． $\tau_{\text{knee}} = 0.25$ は「最大増加率の 1/4 以下」であり，飽和前（ $r \approx 1$ ）と飽和後（ $r \approx 0$ ）の中間点として「明確に鈍化した」領域の開始を捉えるバランスの良い閾値である．

AU の正規化増加率 $r(m)$ の指数飽和モデル：

$$r(m) = r_0 \cdot \exp(-\lambda(m - d_{\text{ID}})) \quad (20)$$

において， $r(m) < 0.25 \cdot r_{\text{max}}$ （全変化量の 25% 以下）となる点を鈍化点として定義する．

より厳密な閾値設定として， $AU(m)$ の離散二階差分が最大となる点（曲率最大点）を用いることが理論的に motivated であるが， AU の離散性により実データでは数値的に不安定になることが多い． $\tau = 0.25$ はこの曲率最大点付近の安定した代替として機能する（EZ 感度分析参照）．

経験的根拠：MNIST（E4 単一シード実験）では $\tau \in [0.1, 0.5]$ の全範囲で $m^{\text{knee}} = 12$ （安定）．Fashion-MNIST では $\tau \approx 0.25$ が境界感度を持つ（表 20）．境界感度の存在は， $AU(m)$ 曲線の勾配遷移が $\tau = 0.25$ 付近の値で起こることを示唆しており，この閾値の「効きやすさ」を逆に裏付ける．

データセット横断検証（実験 EZ）

Fashion-MNIST および Gaussian 混合分布（5 成分・10 成分）での横断検証結果を表 20 に示す．

表 20: EZ: τ_{knee} 頑健性の横断検証

データセット	AU_{sat}	TwoNN ID	$\tau = 0.1$	$\tau = 0.2$	$\tau = 0.25$	$\tau = 0.3$	$\tau = 0.4$	$\tau = 0.5$
Fashion-MNIST	10	7.00	20	20	20	8	8	8
GMix 5 成分	1	4.27	2	2	2	2	2	2
GMix 10 成分	3	3.02	2	2	2	2	2	2

Fashion-MNIST では $\tau = 0.25$ と 0.30 の境界で m^{knee} が 20 から 8 に変化する境界感度が確認された（ AU 増加率が境界値 0.25 に一致する複数の m が存在するため）．この場合，二階差分代替手法（式 (20)）の使用を推奨する（§ 3 参照）．

付録 D β 感度分析

MNIST サブセット（ $n = 5,000$, 50 エポック）で $\beta \in \{1, 2, 4, 8\}$ の AU Dynamics を比較した（図 11）．




図 11: β 感度分析：MNIST VAE の AU vs m ($\beta \in \{1, 2, 4, 8\}$, 50 エポック, サブセット). $\beta = 1$ では $AU \approx m$ (正則化不足), $\beta = 4$ では $m_{\text{knee}} = 12$ (垂直破線), $\beta = 8$ では $m < 8$ で AU が過度に抑制される兆候が見られる.

$\beta = 4$ を本実験のデフォルト値として採用した根拠： $\beta = 1$ では KL 正則化が弱く $AU \approx m$ のため m^{knee} が同定できない； $\beta = 8$ では過正則化により小さい m での AU が抑制され、 m^{knee} の同定点がずれる可能性がある。 $\beta \in [2, 8]$ では AU パターンの形状は安定することを確認したが、 m^{knee} の精確な数値は m グリッドにも依存する (§ 6.1).

付録 E AU 閾値 δ の感度分析

Swiss Roll・Torus において $\delta \in \{0.001, 0.01, 0.05, 0.1\}$ で AU パターンが完全に一致することを確認した (全 $m \cdot \delta$ の組み合わせで一致). 活性次元の分散 ($O(1)$) と非活性次元の分散 ($O(10^{-4})$ 以下) の間に 2 桁以上の差があるため、 δ の選択に対して頑健である.