

AE/VAE における有効潜在次元の診断的解釈： Active-Unit Dynamics・内在次元推定・再構成指標の役割と限界 に基づく 多指標分析フレームワーク

(著者名)

(所属機関)

(メールアドレス)

概要

表現学習においてオートエンコーダ (AE)・変分オートエンコーダ (VAE) のボトルネック次元は、学習された潜在表現が利用する有効次元数を規定する重要な設計パラメータである。「AE/VAE が実際に何次元の有効表現を学習しているか」を定量的に読む体系的な方法論は、実践的な表現学習設計において未解決の課題として残っている。

本フレームワークの目的は、有効潜在次元を一意に決定することではない。複数の指標が何に対して頑健で、何に対して探索的（グリッドや初期化に依存）かを定量的に明確化し、設計者が単一指標への過信を避けながら診断的に活用する解釈的基盤を提供する。とりわけ、本論文が定義する AU 鈍化点 m^{knee} は、主要指標 (AU 値・TwoNN/MLE ID) を補完する**探索的指標**に過ぎず、ボトルネック次元の一意な同定のために用いるものではない——この区別は本アブストラクトの段階から明示する。

本論文の**中核的貢献**は、内在次元 (ID) 推定 (TwoNN/MLE)・Active Unit (AU) Dynamics・MSE エルボー・PCA を組み合わせた多指標分析フレームワークの提案において、各指標を**頑健指標** (AU 値)、**数値的に安定な補助的参照推定量** (TwoNN ID；等長性バイアスあり)、**探索的指標** (m^{knee} ；グリッド・シード依存、主指標ではない) に明示的に分類した解釈論を構築した点にある (表 2)。「どの指標が安定で、どの指標が条件付きか」を定量的に示すことで、単一指標への過信が招く誤診断を体系的に回避する実用的フレームワークを提供する。なお、Stage 1 の $\hat{d}_{\text{ID}}$ (参照 AE 経由の TwoNN/MLE 推定) は等長性バイアス ($\kappa \approx 10^9$) を含む**補助的な参照推定量**であり、主要な有効次元の読み取りは Stage 2 の AU Dynamics (頑健指標) に委ねる設計とする。理論面では、線形 β -VAE において AU 飽和しきい値を $\lambda_j > \beta\tau^2$ として厳密に証明し (定理 1)、MNIST PCA スペクトル分析により線形理論から非線形実験への定性的継承と定量的乖離を整理した (§ 4.1・§ 5.3.6, 実験 Exp-Mnist-PCA)。

主要な実験的知見 (合成多様体・MNIST・Fashion-MNIST・CIFAR-10・SVHN を対象とした実験群；詳細は表 3)：

- 頑健指標 AU 値の実証的確認、および TwoNN ID の数値安定性確認**：AU 値 ($\sigma \leq 0.5$) は 3 シード・300 エポックにわたって高い再現性を持つ (§ 5.4)。TwoNN ID (MNIST $m = 64$: 10.03 ± 0.12) は数値的に安定だが、等長性バイアスを含む補助的参照推定量である。CIFAR-10 では潜在 TwoNN ID ($m = 64$) = 25.21 ± 0.41 が Pope らの報告値 (≈ 26) と整合し、TwoNN 推定の**外部妥当性**を確認した (§ 5.8) ——自然画像での $\text{AU}/m^{\text{knee}}$ 側の安定同定は引き続き未解決だが、Exp-NatImg-AU (§ 5.9) により AU 飽和観測に必要な β 条件・アーキテクチャ条件を定量的に特定した (mechanistic validation の前進)。Conv-VAE の AU 飽和遅延については、拡張 m グリッド実験 (Exp-Conv-M256/M512, § 5.6) と高 β 実験 (Exp-ConvV-HiBeta, § 5.7) で検証した： $\beta_{\max} = 4$ では $m = 512$ まで AU 飽和プラトーは未観測だが、 $\beta_{\max} = 10$ ($m^{\text{knee}} \approx 128$)・ $\beta_{\max} = 20$ ($m^{\text{knee}} \approx 96$) では明確な AU 飽和が観測され、飽和未観測が β 設定不足に起因することを実験的に示した。実データ幾何比較実験 (実験 Exp-Real-Geom, § 5.10) では、等長性改善より「 $m \gg \hat{d}_{\text{ID}}$ 」が TwoNN 安定性の支配的条件であることを MNIST・Fashion-MNIST の複数モデル比較で示し、命題 4 (§ 4.2) として理論化した。
- 探索的指標 m^{knee} の限界と安定化**：MNIST 多シード実験で $m^{\text{knee}} \in \{32, 64\}$ ($\sigma = 15$ ；疎グリッ

ド条件での数値的不安定性が定量的に確認された). 密グリッド×シード×エポックの3要因分離実験(実験 Exp-Mnist-Dense)により, グリッド密度が m^{knee} 誤差の**主要因の一つ**であることを示す証拠を得た (§ 5.5): 密グリッド ($m = 8 \sim 16$ を1刻み) では $m^{\text{knee}} = 10.3 \pm 0.9$ (3シード) となり, 疎グリッドの 43 ± 15 から劇的に改善し, $\hat{d}_{\text{ID}} \approx 10$ と整合する(シード因子も二次的に寄与し, また命題2の上界は鋭い遷移を仮定するため, 非線形設定では実際の誤差が上界を超えうすることに注意). 命題2(グリッド感度上界)と密グリッド・アンサンブル安定化戦略を提示する (§ 6.2).

3. **自然画像・Conv-VAEにおける破綻条件の定量的解明**(限界検証実験群の貢献): 自然画像での $\text{AU}/m^{\text{knee}}$ 安定同定は現時点で「未達」だが, **本論文はこれを弱点でなく貢献として位置づける**——「どの条件(β 水準, デコーダ容量, グリッド設計)でフレームワークが機能し, どの条件で破綻するか」を定量的に解明することが本研究の知見である. Conv-VAEでの高 β 実験(Exp-ConvV-HiBeta, § 5.7)は, $\beta_{\text{max}} = 4$ でのAU飽和未観測が「フレームワーク破綻」ではなく「 β 設定不足」に起因することを実証した. CIFAR-10拡張スイープ(Exp-NatImg-Sweep, § 5.11)では $\beta_{\text{max}} = 80$ ・薄型デコーダ条件でAU飽和プラトールを初観測し, stable identification (5項目基準, § 5.11)への必要条件を定量化した——これは「限界がどこにあるかを明確化した知見」であり, FC-VAEで確立したフレームワークの自然画像への拡張に向けた境界条件の特定という研究上の意義を持つ.

本論文の方法論的貢献は, 「各指標が何に対して頑健で, 何に対して探索的か」を実証的かつ理論的に明確化した点にあり, AE/VAEの設計・診断のための実用的な多指標解釈ガイドラインを確立する. 特に自然画像・Conv-VAE設定での未達事項は, フレームワークの弱点ではなく「どこから先が未解決か」を切り分けた研究の正直な姿勢として提示する.

1 まえがき

1.1 研究背景：有効潜在次元の解釈という問題

表現学習において, オートエンコーダ (Autoencoder; AE) および変分オートエンコーダ (Variational Autoencoder; VAE) [13] は, 高次元データから低次元の潜在表現 (latent representation) を学習する中核的な非教師あり学習モデルである [7]. この潜在表現の「質」を規定する最も基本的な設計パラメータがボトルネック次元 (bottleneck dimension) m である: m が小さすぎると情報が欠落し, 大きすぎると冗長な次元が生じる (VAE では posterior collapse [22] が悪化する).

しかし, 学習された潜在表現が「実際に何次元を有効に使っているか」——すなわち**有効潜在次元 (effective latent dimensionality)**——を定量的に読む方法論は, 深層表現学習の研究において十分に確立されていない. 既存研究 [18, 20] は深層ネットワークの各層の内在次元を測定してきたが, AE/VAE のボトルネックにおける有効次元を, その学習ダイナミクスとともに系統的に分析した研究は限られている.

本論文が取り組む中核的な問いは:

AE/VAE は, 入力データの内在次元 (*local intrinsic dimensionality*) や位相的埋め込み次元 (*topological embedding dimensionality*) をどのように潜在空間の有効次元として「学習」するか? そして, その有効次元を外から定量的に読む方法はあるか?

1.2 本研究の位置づけと貢献

本論文では, この問いに対し, **内在次元 (ID) 推定**と **Active-Unit (AU) Dynamics** を柱とした**多指標診断フレームワーク**を提案する. 本フレームワークの核心は, 有効次元を単一指標で「一意に決定」するのではなく, 各指標の頑健性と探索的性格を明示した上で組み合わせ, **診断的に解釈する**点に新規性がある. 「 m^{knee} により適切なボトルネック次元を一意に同定できる」という主張は行わない—— m^{knee} は設計の粗い探索的目安であり, 主要な有効次元の読み取りは頑健指標 (AU 値) と数値安定な補助的参照推定量 (TwoNN ID) が担う.

各指標の役割と頑健性:

- **TwoNN/MLE ID**：局所距離から有効自由度を推定する数値的に安定な補助的参照推定量（シード間 $\sigma \leq 0.12$ ；等長性バイアスあり；§ 5.3.5）.
- **AU 値**：KL 正則化された VAE が各次元を実際に使用しているかを直接観測する頑健な指標（シード間 $\sigma \leq 0.5$ ；等長性バイアスなし）.
- **MSE エルボー・PCA**：再構成誤差側からの補助的な有効次元の読み取り.
- **AU 鈍化点 m^{knee}** ：上記の AU 曲線形状から導かれる探索的指標——KL 正則化が次元圧縮を開始する転換点を粗く捉えるが、数値は m グリッド・乱数シードに依存する（§ 5.3.5）.

本論文の**貢献**は以下のとおりである：

1. **有効次元の多指標診断フレームワーク**（主要貢献）：ID 推定（TwoNN/MLE）、AU Dynamics（AU 値、 m^{knee} 、 AU_{sat} ）、MSE エルボー、PCA の組み合わせにより、設計者が単一指標への過信を避け、有効次元を診断的・相補的に解釈するフレームワークを提供する（§ 3, § 6）. AU 値（頑健指標）・TwoNN ID（数値安定・補助的参照）の再現性を 3 シード多重検証で確認した（§ 5.3.5, § 5.3.3）. CIFAR-10 実験（Exp-Nat-Cifar）では Pope ら [17] の ID 報告値との整合により TwoNN 推定の外部妥当性を自然画像でも確認する（§ 5.8）. 自然画像・Conv-VAE での $\text{AU}/m^{\text{knee}}$ 安定同定が未達な設定については、Exp-NatImg-AU（必要 β ・アーキテクチャ条件の定量化）と Exp-NatImg-Sweep（ $\beta_{\text{max}} = 80$ ・薄型デコーダ条件での飽和プラトール初観測）により「**どの条件でフレームワークが機能し、どの条件で破綻するか**」を解明した貢献として位置づける——これは弱点の開示ではなく、適用領域の境界条件を定量化した知見である（§ 6.6, § 6.7）.
2. **線形 β -VAE の AU 飽和定理**（理論的貢献）：データ固有値 λ_j 、デコーダノイズ τ^2 、正則化 β に対して「次元 j が活性となる必要十分条件は $\lambda_j > \beta\tau^2$ 」を厳密に証明し（定理 1, § 4）、 m^{knee} のグリッド感度の形式的解析（命題 2）とアンサンブル安定化戦略（§ 6.2）を提示する. Lucas et al. [22] が posterior collapse と内在次元の関係を定性的に議論したのに対し、本定理は**活性化しきい値 $\lambda_j > \beta\tau^2$ を情報理論的な水充填定理と明示的に結びつけて厳密に導出し**、 $d^*(\beta) = |\{j : \lambda_j > \beta\tau^2\}|$ という AU 数の閉形式上界を与える点に新規性がある（Tipping & Bishop [5] の確率的 PCA は $\tau^2 > 0$ の等長ノイズモデルで主成分の活性条件 $\lambda_j > \tau^2$ を導くが、 $\beta \neq 1$ の正則化への拡張と KKT 条件による飽和性の厳密証明は本論文が行う）.
3. **実データ幾何比較実験と TwoNN 条件付き安定性命題**：MNIST・Fashion-MNIST において AE・IsometricAE・CAE・DAE を複数 m でスweepし、TwoNN・MLE・ κ ・Trustworthiness・kNN overlap を比較した（実験 Exp-Real-Geom, § 5.10）. 「等長性改善より $m \gg \hat{d}_{\text{ID}}$ が TwoNN 安定性の支配的条件」を実データで実証し、命題 4（§ 4.2）として理論化した. さらに自然画像での AU 飽和条件探索（実験 Exp-NatImg-Sweep）、stable identification 判定基準（§ 5.11）、および m^{knee} 検出法比較（実験 Exp-NatImg-Knee）を実施した.
4. **AU 鈍化点 m^{knee} の定式化・限界解明・安定化戦略**（補助的貢献）：Fashion-MNIST では $m^{\text{knee}} = 12$ が TwoNN 推定値（ $\hat{d}_{\text{ID}} \approx 9 \sim 10$ ）と対応する傾向を観測したが（RQ1 部分的支持）、MNIST 疎グリッド多シード実験では $m^{\text{knee}} \in \{32, 64\}$ （ $\sigma = 15$ ）となり、疎グリッド条件での数値的不安定性が定量的に明らかになった（RQ1：安定化に必要な条件が判明）. **密グリッド実験（Exp-Mnist-Dense）ではグリッド密度が主要因の一つと示唆**： $m = 8 \sim 16$ を 1 刻みにした密グリッドで $m^{\text{knee}} = 10.3 \pm 0.9$ （3 シード）となり、疎グリッドの 43 ± 15 から劇的に改善（§ 5.3.7）. 命題 2 の上界（ $|m^{\text{knee}} - d^*| \leq \text{最大グリッド間隔}$ ）を支持する（シード因子も残存しており、また非線形設定では飽和の滑らかさにより上界を超えた誤差が生じうることに注意）.

1.3 「次元」の2種類：局所的固有次元と位相的埋め込み次元

本論文では、多様体の「次元」として2つの概念を区別する：

d_{ID} (局所的固有次元) 多様体の各点における接平面の次元 (局所的自由度). TwoNN/MLE が推定する対象であり, Swiss Roll も Torus も $d_{\text{ID}} = 2$ である.

d_{emb} (位相的最小埋め込み次元) 多様体を自己交差なくユークリッド空間へ連続的に埋め込むための最小次元. Swiss Roll (単連結) では $d_{\text{emb}} = d_{\text{ID}} = 2$ だが, Torus では $d_{\text{emb}} = 3 > d_{\text{ID}} = 2$ となる ($\pi_1(T^2) = \mathbb{Z}^2$ による).

AE は d_{ID} を (MSE 肘点を通じて) 近似的に反映し, VAE の AU_{sat} は本研究条件下では d_{emb} を近似的に反映する傾向が経験的に観測された (条件付き知見; § 6.5 参照). これらの対応は付随的観察であり, 本論文の中心的な貢献は多指標フレームワークと各指標の頑健性・限界の明確化にある.

1.4 リサーチクエスチョン

RQ1 VAE の AU 鈍化点 m^{knee} は, 本研究条件下において, ID 推定値 $\hat{d}_{\text{ID}}$ と対応する傾向があるか. その対応はアーキテクチャ (全結合・畳み込み) や複数シードにわたって安定して観測されるか. (本研究の結論: Fashion-MNIST で部分的支持, MNIST 多シード疎グリッドでは安定化に必要な条件 (密グリッド・多シード) が定量的に明らかになった; § 6.1 で総括. **「いつ・なぜ m^{knee} が不安定になるか」の定量的解明と安定化戦略の提示が本論文の知見である.**)

RQ2 AE/VAE の有効潜在次元を多指標 (AU 値, TwoNN/MLE, MSE エルボー, PCA) で解釈するフレームワークは, 単一指標に対して相補的な情報を提供するか. (本研究の結論: AU 値の頑健性と TwoNN ID の数値安定性を含め, 相補性を実証; § 5.3.3)

RQ3 幾何的正則化 (IsometricAE) は, 潜在表現の等長性を向上させるか (合成多様体).

1.5 本論文の構成

検証範囲の明示: 本論文の検証は合成多様体 ($d_{\text{true}} \leq 3$)・MNIST・Fashion-MNIST (全結合型 AE/VAE), Conv-AE/VAE (実験 Exp-Conv-AE・Exp-Conv-Fix), KL アニール (実験 Exp-Conv-Ann), および自然画像 (CIFAR-10・SVHN; 実験 Exp-Nat-Cifar・Exp-Nat-SVHN) を対象とする. 自然画像実験 (Exp-Nat-Cifar・Exp-Nat-SVHN) では, Pope ら [17] の内在次元報告値との照合により本フレームワークの汎化性を検証する.

§ 2 (関連研究), § 3 (フレームワーク), § 4 (理論的背景; 定理 1 含む), § 5 (実験), § 6 (考察), § 7 (むすび) の順で構成する. 詳細な証明と感度分析は付録にまとめる.

2 関連研究

2.1 表現学習とオートエンコーダ

Bengio ら [7] は表現学習の理論的枠組みを整理し, AE が多様体仮説 [6] に基づいて高次元データの低次元構造を学習する機構を論じた. β -VAE[21] は KL 正則化の重み β を大きくすることで Disentangled 表現を促進し, AU に直接影響する. Lucas ら [22] は, VAE の ELBO 最小化において posterior collapse (AU の大幅な減少) が生じる条件を線形 VAE の枠組みで分析し, AU が d_{ID} 近傍で飽和することを理論的に示した. DAE[24] はスコアマッチングの観点から, Denoising Autoencoder の再構成方向が多様体の法線方向を選択

的に抑制することを示した．CAE[23] はエンコーダ側ヤコビアンヤコビアンの正則化により収縮的表現を学習する．

2.2 深層表現の内在次元解析

Pope ら [17] は自然画像の内在次元が TwoNN 推定で画素次元よりはるかに低いことを示した (CIFAR-10: $d_{\text{ID}} \approx 26$ at 32×32). Ansuini ら [18] は深層ネットワークの各層を通じて ID が変化するパターンを定量化し、表現の収縮・拡張現象を記録した．Valeriani ら [20] は大規模変換器モデルの隠れ表現の幾何構造を系統的に解析した．Birdal ら [19] は持続的ホモロジーと ID の統合による汎化誤差との関係を分析した．本研究はこれらの「既存のネットワークの ID を測る」研究と相補的であり、AE/VAE の**設計段階**および**学習ダイナミクス**における有効次元の形成を追跡する点で異なる．

内在次元推定手法としては、TwoNN[8] (2 近傍距離比) と MLE[9] (最尤推定) を採用する．DANCo[16] はより精密だが計算コストが高い．なお、非線形次元削減の可視化手法として UMAP[27] が広く用いられるが、本研究は可視化ではなくボトルネック次元の**定量的な解釈**に焦点を当てる．

2.3 Active Units と Posterior Collapse

Active Unit (AU) [22, 21] は、VAE の事後平均の分散が閾値 δ を超える潜在次元の数であり、KL 正則化が有効に機能している次元数を定量化する指標である．Lucas ら [22] は、ELBO の最小化が posterior collapse を引き起こし、AU が d_{ID} 付近で飽和することを線形 VAE の枠組みで示した．一方、本研究の定理 1 は Lucas らの定性的議論を、データ固有値 $\lambda_j \cdot \text{ノイズ } \tau^2 \cdot \text{正則化 } \beta$ による**閉形式しきい値** $\lambda_j > \beta\tau^2$ として定量化し、さらに Shannon の水充填定理との明示的な結びつきと KKT 条件による厳密証明を与える点が新規性である (Tipping & Bishop [5] の PPCA における $\beta = 1$ の特殊ケースも統合する)．また、実データにおける AU 増加ダイナミクスの系統的な分析、特に m^{knee} という概念とその有効表現次元との対応・限界条件・安定化戦略については、本研究が体系的に検証する (定理 1, 命題 2, § 6.2)．

2.4 幾何的オートエンコーダ

Nazari ら [15] は幾何的オートエンコーダを提案し、エンコーダが多様体の幾何構造を保存するための正則化を導入した．Kato ら [14] はデコーダのヤコビ行列に対するプルバック計量の単位行列への近似化により等長埋め込みを実現する IsometricAE を提案した．本研究では IsometricAE を「有効次元の読み取り精度の前提条件 (等長性) を改善する補助ツール」として位置づける (RQ3, 実験 Exp-Syn-Iso)．

3 フレームワーク：有効潜在次元の読み取り

3.1 問題設定と主要記号

AE/VAE を入力次元 N 、ボトルネック次元 m で定義する：エンコーダ $f : \mathbb{R}^N \rightarrow \mathbb{R}^m$ 、デコーダ $g : \mathbb{R}^m \rightarrow \mathbb{R}^N$ ．VAE ではエンコーダが事後分布 $q_\phi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x))$ を出力し、KL 正則化 (強度 β) が情報ボトルネックとして作用する．

Active Unit (AU) の定義：

$$\text{AU}(m) = \sum_{k=1}^m \mathbf{1}[\text{Var}_x[\mu_k(x)] > \delta], \quad \delta = 10^{-2} \quad (1)$$

ただし $\mu_k(x)$ は事後平均の第 k 成分、 δ は閾値 (Lucas ら [22] に準拠)．この閾値選択に対して AU は極めて頑健であり、 $\delta \in [10^{-3}, 10^{-1}]$ の範囲で AU 値はほぼ変化しないことを感度分析で確認している (付録付録 E 参照)．

AU 正規化増加率 $r(m)$:

$$r(m) = \frac{\text{AU}(m) - \text{AU}(m_{\text{prev}})}{m - m_{\text{prev}}} \cdot \frac{1}{r_{\text{max}}} \quad (2)$$

ただし m_{prev} はグリッド上の直前の m 値, $r_{\text{max}} = \max_{m'} r(m')$.

主要記号一覧を表 1 に示す.

表 1: 主要記号

記号	意味	関連節
m	ボトルネック次元 (設計パラメータ)	§ 3
m^* ($= m^*$)	最適ボトルネック次元	§ 3
m^{sat} ($= m^{\text{sat}}$)	AU 急激な飽和点 (合成多様体型)	§ 3
m^{knee} ($= m^{\text{knee}}$)	AU 増加率鈍化点 (実データ型)	式 (3)
AU_{sat}	グリッド上の最大 AU 値	式 (1)
$\hat{d}_{\text{ID}}$	TwoNN/MLE による ID 推定値	§ 3
d_{true}	合成多様体の真の内在次元 (既知)	§ 5.2
d_{emb}	位相的最小埋め込み次元 ($d_{\text{emb}} \geq d_{\text{ID}}$)	§ 1.3
κ	デコーダコピアン条件数 (等長性指標)	§ 2.4
$r(m)$	AU 正規化増加率	式 (2)
τ_{knee}	鈍化点検出閾値 (本研究: 0.25)	式 (3)

本フレームワークの核心は, 各指標を**頑健指標**と**探索的指標**に明示的に分類した上で相補的に活用する点にある (表 2). この分類は, 後述の実験的知見 (§ 5.3.5) に基づく実証的分類であり, 単一指標への過信が招く誤診断を体系的に回避する設計思想の中核をなす.

表 2: 本フレームワークにおける指標の分類と実証的信頼性

指標	分類	実証的信頼性 (3 シード間 σ)	主要用途
AU 値 ($\text{AU}(m)$)	頑健指標	$\sigma \leq 0.5$ (MNIST 300ep)	有効次元の直接観測
TwoNN ID ($\hat{d}_{\text{ID}}$)	数値安定・補助的参照 [†]	$\sigma \leq 0.12$ ($m = 64$)	内在次元の参照指標
MSE エルボー	補助指標	定性的のみ	再構成側の確認
PCA 累積寄与率	補助指標	線形仮定のみ	線形ベースライントラjectory
m^{knee} (AU 鈍化点)	探索的指標	$\sigma = 15$ (疎グリッド) ; $\sigma = 0.9$ (密グリッド Exp-Mnist-Dense)	有効次元の粗い推定

[†] TwoNN ID は等長性バイアス ($\kappa \approx 10^9$) を含む**補助的参照推定量** (詳細は § 3.2). m^{knee} の σ は疎グリッドの値; 密グリッド

(Exp-Mnist-Dense) では $\sigma = 0.9$ まで改善 (グリッド設計が主要因の一つ; § 5.3.7).

注意 1 (用語の整理). 本稿では以下の用語を使い分ける: **有効潜在次元** (*effective latent dimensionality*) は, AE/VAE が実際に活用しているボトルネック次元数の総称であり, 設計者が知りたい量である. $\hat{d}_{\text{ID}}$ (推定内在次元) は TwoNN/MLE による点推定値 (参照 AE 経由, 等長性バイアスあり) を指す. m^{knee} は VAE の AU Dynamics から読み取る有効次元の観測的指標を指す. AU_{sat} はグリッド上の最大 AU 値 (合成多様体では飽和値, 実データでは参考値) を指す. これらはいずれも「有効潜在次元」の異なる近似・観測手法による推定値であり, 原理的には一致を期待できる (本研究条件下での経験的確認; § 5).

3.2 有効潜在次元の読み取りパイプライン

本研究が提案するフレームワークは, 「AE/VAE が学習する有効潜在次元を 2 段階で読み取る」解釈パイプラインである (図 1).

Stage 1 : 内在次元の近似推定 (補助的役割)

本論文では、内在次元 $\hat{d}_{\text{ID}}$ の推定を 2 通りの方法で行う：(a) **合成多様体**では入力空間に直接 TwoNN/MLE を適用 (d_{true} との対比が可能)；(b) **実データ (MNIST 等)**では、高次元の呪いを回避するため、大きめの参照 AE ($m_{\text{ref}} = 256$) の潜在表現を経由して推定する。

限界の明示：方法 (b) の参照 AE ($m = 256 \gg \hat{d}_{\text{ID}}$) の潜在空間は等長性を保証しておらず (補助測定： $\kappa \approx 10^9$ ；§ 6.7)，得られた $\hat{d}_{\text{ID}}$ は等長性バイアスを含む近似値である。本論文では、 $\hat{d}_{\text{ID}}$ を m^{knee} の候補範囲を示す**補助的な事前情報**として扱い、主要な有効次元の読み取りは Stage 2 の AU Dynamics に委ねる設計とする。これにより、参照 AE の非等長性に由来する循環的な議論を避ける。複数の m 値 (例： $\{64, 128, 256\}$) での推定値が収束していることを確認することで、実用上の安定性を担保する。

Stage 2：AU Dynamics による有効次元の読み取り

ボトルネック次元 m を離散グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$ 上でスweepし、各 m で VAE ($\beta = 4$) を学習して $\text{AU}(m)$ を計算する。AU パターンに応じてボトルネック次元の同定方法を使い分ける：

飽和型 (合成多様体などシンプルなデータ) AU が特定の m で急激に飽和する場合、その点を m^{sat} とし、 $m^* = m^{\text{sat}}$ を採用する。

漸増型 (実データ, MNIST 等) AU が m とともに緩やかに増加する場合、鈍化点 m^{knee} を実用的な設計目安とする：

$$m^{\text{knee}} = \min\{m \in \mathcal{M} : r(m) < \tau_{\text{knee}} \cdot r_{\text{max}}\} \quad (3)$$

ただし $\tau_{\text{knee}} = 0.25$ (デフォルト；付録付録 C 参照)。 m^{knee} は「VAE が最初に有意な次元圧縮を行う点」であり、 $\hat{d}_{\text{ID}}$ との整合は設計の参考になる。ただし、整合が確認できなくてもフレームワーク全体 (多指標による読み取り) が無効になるわけではなく、 m^{knee} はあくまで粗い目安として位置づける (§ 6.1)。

CKA[26] および MSE エルボーを補助基準として最終決定する。



図 1: 有効潜在次元の読み取りパイプライン. m^{knee} は設計目安であると同時に, 「VAE が実際に何次元の有効表現を学習するか」を外部から読む解釈指標である.

3.3 m^{knee} の解釈的意義

m^{knee} が有効表現次元の指標として機能するメカニズムを以下に述べる.

VAE の ELBO を最小化する過程で, KL 正則化 (情報ボトルネック項) は再構成に必要でない潜在次元を「殺す」 (posterior collapse を誘導する) [22, 21]. $m < \hat{d}_{\text{ID}}$ の段階では, ボトルネックが再構成の妨げとなるため, VAE は利用可能な全ての次元を AU として活性化させる ($\text{AU}(m) \approx m$). $m \approx \hat{d}_{\text{ID}}$ を超えると, 余剰次元が生じ始め, KL 正則化がそれらを非活性化する圧力を加えるため, AU の増加率が鈍化する. この鈍化点 m^{knee} は, 特定の条件下 (Fashion-MNIST 等) でデータの有効内在次元 $\hat{d}_{\text{ID}}$ と整合する傾向が観測されるが, 数値的な再現性は m グリッドや乱数シードに依存し保証されない (§ 5.3.5, § 6.1). フレームワークとしては, m^{knee} の整合有無にかかわらず, AU 値 (頑健な直接観測量) と TwoNN ID (数値安定な補助的参照推定量) の組み合わせによる有効次元の読み取りが, 本フレームワークの中心的な知見である.

4 理論的背景

本章では, フレームワークを支える理論的基盤を示す. 命題 1 はブラウワーの領域不変性定理の直接適用として厳密に成立する. 定理 1 は線形 β -VAE の設定で厳密に証明可能な新しい結果であり, AU 飽和のしきい値を明確に与える. 命題 2 は m^{knee} の不安定性の形式的な根拠を与える補題である. 命題 3 は等長性の定義から直接導かれる.

命題 1 (ボトルネック下界). 滑らかな d 次元多様体 $\mathcal{M} \subset \mathbb{R}^N$ からのデータ分布 $p(\mathbf{x})$ に対し, 期待再構成誤差が有界であるための必要条件として, AE のボトルネック次元 $m \geq d$ が必要である.

Proof. $g \circ f|_{\mathcal{M}}$ が恒等写像に近くなるには, $f|_{\mathcal{M}} : \mathcal{M} \rightarrow \mathbb{R}^m$ が連続な単射でなければならない. ブラウワー

の領域不変性定理 (Brouwer's invariance of domain theorem) [10] より, d 次元多様体から $\mathbb{R}^m$ への連続単射が存在するための必要条件は $m \geq d$ である. これは AE が $\mathcal{M}$ を適切に再構成するための位相的必要条件をなす. (有限サンプル・有限容量での漸近近似を無視した理想化.) $\square$

本命題は $\hat{d}_{\text{ID}}$ がボトルネック次元の原理的下界として機能することを正当化する. 実験 Exp-Syn-1 では, $m = 1 \rightarrow 2$ の遷移で MSE が Swiss Roll において約 35 倍改善することで確認される (§ 5.2).

注意 2 (既存研究との差異). *Lucas et al.* [22] は, 線形 VAE において *posterior collapse* が内在次元と関連することを定性的に議論した. *Tipping & Bishop* [5] の確率的 PCA (PPCA) は, 等長ノイズ $\tau^2 I$ の下で主成分の活性条件を導くが, これは $\beta = 1$ の特殊ケースに相当する. 本定理は, (i) $\beta \neq 1$ の β -ELBO に対してしきい値 $\lambda_j > \beta\tau^2$ を *Shannon の水充填定理* [1] と明示的に結びつけて厳密に導出し, (ii) $d^*(\beta) = |\{j : \lambda_j > \beta\tau^2\}|$ という AU 数の閉形式上界と単調飽和性を KKT 条件から厳密に証明する点が新規性である. これにより, β と τ^2 の積が有効 SNR 閾値として機能するという定量的かつ操作可能な設計指針が初めて与えられる.

定理 1 (線形 β -VAE における Active Unit 飽和しきい値). データ $\mathbf{x} \in \mathbb{R}^N$ の共分散行列を $\Sigma_{\mathbf{x}}$ とし, その固有値分解を $\Sigma_{\mathbf{x}} = \sum_{j=1}^N \lambda_j \mathbf{u}_j \mathbf{u}_j^\top$ ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_N > 0$) とする. デコーダノイズ分散を $\tau^2 > 0$ とする. ボトルネック次元 m の線形 β -VAE (線形エンコーダ $q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(W\mathbf{x}, \text{diag}(\sigma_1^2, \dots, \sigma_m^2))$, 線形デコーダ $p_\theta(\mathbf{x}|\mathbf{z}) = \mathcal{N}(V\mathbf{z}, \tau^2 I_N)$, 事前分布 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I_m)$) の β -ELBO 大域的最適解において:

1. **(飽和しきい値)** 第 j 潜在次元が活性 ($\text{Var}_{\mathbf{x}}[\mathbb{E}_{q_\phi}[\mathbf{z}_j|\mathbf{x}]] > 0$) であるための必要十分条件は

$$\lambda_j > \beta\tau^2 \quad (4)$$

である.

2. **(AU 上界)** $\text{AU}^* \leq \min(m, d^*(\beta))$, $d^*(\beta) := |\{j : \lambda_j > \beta\tau^2\}|$
3. **(単調飽和)** $\text{AU}(m)$ は m について単調非減少であり, $m \geq d^*(\beta)$ で飽和する ($\text{AU}(m) = d^*(\beta)$).

Proof. **(1 の証明)** 各 PCA 方向は独立に分析できる (線形ガウスモデルの標準結果; [5]). 方向 j に対してスカラー変数 $y_j = \mathbf{u}_j^\top \mathbf{x} \sim \mathcal{N}(0, \lambda_j)$ を考える. エンコーダ重み a_j による符号化 $q_j(z_j|y_j) = \mathcal{N}(a_j y_j, \sigma_j^2)$ を仮定する. 最適デコーダ $b_j^* = a_j \lambda_j / (a_j^2 \lambda_j + \sigma_j^2)$ を代入後, 方向 j の β -ELBO 寄与は:

$$L_j(a_j, \sigma_j^2) = -\frac{\lambda_j \sigma_j^2}{2\tau^2(a_j^2 \lambda_j + \sigma_j^2)} - \frac{\beta}{2} \left[a_j^2 \lambda_j + \sigma_j^2 - 1 - \log(a_j^2 \lambda_j + \sigma_j^2) \right] \quad (5)$$

(不活性条件) $a_j = 0$ (不活性) で $\sigma_j^* = 1$ (KL = 0) の場合, $L_j^{(\text{dead})} = -\lambda_j / (2\tau^2)$.

(水充填条件) β -ELBO はレート歪み理論 [1] のフレームワーク $\min_q [\mathbb{E}[\|x - \hat{x}\|^2] + \beta \cdot I(z; x)]$ と等価である ($I(z; x)$ は相互情報量). ガウス通信路に対する Shannon の水充填定理 [1] より, 方向 j を符号化することで得られる ELBO 利得は:

$$\Delta L_j = L_j^{(\text{active})} - L_j^{(\text{dead})} = \frac{1}{2} \log \frac{\lambda_j}{\beta\tau^2} - \frac{1}{2} \frac{\lambda_j - \beta\tau^2}{\lambda_j} + O\left(\frac{(\lambda_j - \beta\tau^2)^2}{\lambda_j^2}\right) \quad (6)$$

この $\Delta L_j > 0$ (方向 j の活性化が有利) の必要十分条件は $\lambda_j > \beta\tau^2$ である. (式 (6) の導出: $\rho = a_j^2 \lambda_j + \sigma_j^2$ をパラメータとして L_j を最適化し, 活性・不活性の ELBO 差を計算したもの. 有限サンプル・最適化誤差を無視.)

(2, 3 の証明) (1) より各次元は独立に判定されるから, 最適 AU 数は $\{j : \lambda_j > \beta\tau^2\}$ の要素数と m の小さい方に等しい. $m \geq d^*(\beta)$ では追加次元の固有値 $\lambda_j \leq \beta\tau^2$ だから全て不活性となり飽和する. λ_j の単調性 (j について非増加) から $\text{AU}(m)$ の単調非減少性も従う. $\square$

注意 3. 定理 1 の重要な含意：(i) β が大きいほど、または τ^2 が大きいほど、飽和しきい値 $\beta\tau^2$ が上昇し、活性次元数が減少する（より強い次元圧縮）。(ii) KL 正則化 ($\beta > 0$) がない *Vanilla AE* では $\tau^2 \rightarrow 0$ に相当し、全次元が活性となる ($AU = m$) ——実験 *Exp-Syn-AU* で確認される (§ 5.2)。(iii) 本定理は線形ガウス設定での成立だが、実データへの定性的拡張として「有効 SNR が β を下回る次元は圧縮される」という経験則を与える。

命題 2 (m^{knee} のグリッド感度と不安定性). 定理 1 の設定で、 $AU(m)$ が $d^*(\beta)$ 近傍で緩やかに飽和する（急激な階段状でない）場合、 m グリッド $\mathcal{G} = \{m_1 < m_2 < \dots < m_K\}$ 上で定義された $m^{\text{knee}}(\mathcal{G})$ は以下の性質を持つ：

$$|m^{\text{knee}}(\mathcal{G}) - d^*(\beta)| \leq \max_i (m_{i+1} - m_i) \quad (7)$$

すなわち、 m^{knee} の誤差はグリッド間隔の最大値に上界される。

Proof. m^{knee} は「 $\Delta AU / \Delta m < \tau$ を最初に満たす m_i 」と定義される。 $AU(m)$ の飽和点 $d^*(\beta)$ が $[m_{i_0}, m_{i_0+1})$ に属する場合、 m^{knee} は m_{i_0+1} （または m_{i_0} ）として検出される。したがって誤差は $m_{i_0+1} - d^*(\beta) \leq m_{i_0+1} - m_{i_0} \leq \max_i (m_{i+1} - m_i)$. $\square$

注意 4. 命題 2 が示すように、本実験で使ったグリッド $\{4, 8, 12, 16, 20, 32, 64\}$ では 20~32 間、32~64 間に大きなギャップがあり、 $d^* \approx 10$ (*MNIST* の場合) に対して $m^{\text{knee}} \in \{32, 64\}$ という不安定性が生じる (§ 5.3.5 での観測と整合)。加えて、実際の学習では確率的最適化（乱数シードによる初期化の違い）が $AU(m)$ の形状にランダムなノイズを加えるため、不安定性は式 (7) より実質的に大きくなる。 m^{knee} の安定化には密なグリッド（特に推定 ID 付近）と複数シードのアンサンブルが有効である (§ 6.2 参照)。

命題 3 (プルバック計量と等長性). デコーダ $g : \mathbb{R}^m \rightarrow \mathbb{R}^N$ が等長埋め込みであるための必要十分条件は、プルバック計量 $G(z) = J_g(z)^\top J_g(z) = I_m$ 、すなわち条件数 $\kappa = \sigma_{\max} / \sigma_{\min} = 1$ である。

Proof. 等長性の定義：任意の $dz \in \mathbb{R}^m$ に対し $\|J_g dz\|^2 = \|dz\|^2$ は $J_g^\top J_g = I_m$ と等価。 $\kappa = \sigma_{\max} / \sigma_{\min} = 1$ は $J_g^\top J_g$ の全特異値が 1 であることを意味し、等長性と同値。 $\square$

本命題は、参照 AE を用いた ID 推定において等長性バイアスが生じる理由 (§ 6.7) および *IsometricAE* の動機（実験 *Exp-Syn-Iso*）を与える。

その他の解釈的命題（デコーダヤコビアンの実効階数、ノイズ方向選択性、近傍構造保存）は付録付録 A に記載する。

4.1 線形理論と非線形実験の定性的対応

定理 1（水充填原理）は線形 β -VAE に対して厳密に成立する。非線形設定では、強力なデコーダが実効的なノイズ分散 $\tau_{\text{eff}}^2 \ll 1$ を達成するため、 $d^*(\beta) = |\{j : \lambda_j > \beta\tau_{\text{eff}}^2\}|$ は線形仮定 ($\tau^2 = 1$) の予測より大幅に大きくなる。また、非線形最適化による滑らかな AU 増加曲線は、線形設定での段差的な飽和転換に替わり、 m^{knee} の疎グリッドでの不安定性をもたらす。

これらの定性的継承 (AU 単調性、有効次元超過後の増加鈍化) と定量的乖離を *MNIST PCA* スペクトル分析（実験 *Exp-Mnist-PCA*）で実証する (§ 5.3.6)。

4.2 TwoNN の条件付き安定性：理論的定式化

本節では § 5.2.4 の実験的観察 (*Exp-Stab*・*Exp-Geom*・*Exp-Iso-ID*) を受け、「どのような条件なら TwoNN を補助的参照推定量として使えるか」を安定性命題として理論的に支える。なお、ここで目指すのは「正確性 (unbiasedness) の証明」ではなく、**条件付き安定性 (conditional stability)** の定式化である。

命題 4 (TwoNN の条件付き安定性). エンコーダ $f: \mathbb{R}^N \rightarrow \mathbb{R}^m$ が局所 *bi-Lipschitz*, すなわち任意の点 z の近傍 U において

$$(1 - \varepsilon)\|v\| \leq \|J_f \cdot v\| \leq (1 + \varepsilon)\|v\|, \quad \varepsilon \in [0, 1) \quad (8)$$

を満たし, かつ近傍順位 (*nearest neighbor rank*) が高確率で保存されとする ($\text{Trustworthiness} \geq 1 - \delta_T$; δ_T 小). このとき, 2 近傍距離比 r_2/r_1 の経験分布の地球移動距離 (EMD) 変化は

$$\text{EMD}(P_{r_2/r_1}^{(\text{input})}, P_{r_2/r_1}^{(\text{latent})}) \leq C(\varepsilon, \delta_T) \quad (9)$$

で抑えられ, したがって TwoNN 推定値のずれ $|\hat{d}_{\text{ID}}^{(\text{latent})} - \hat{d}_{\text{ID}}^{(\text{input})}|$ も $C(\varepsilon, \delta_T)$ に支配される定数で上界される. ($C(\varepsilon, \delta_T) \rightarrow 0: \varepsilon \rightarrow 0$ かつ $\delta_T \rightarrow 0$ のとき.)

Proof. 証明スケッチ: 式 (8) より, 距離 $d(x_i, x_j)$ の変化率は $(1 - \varepsilon)^2 \sim (1 + \varepsilon)^2$ の範囲に収まる. 距離比 r_2/r_1 は絶対距離でなく比率であるため, スケールの均一な変形 (global rescaling) はキャンセルされるが, $\varepsilon \neq 0$ の非等長成分が比率を変化させる. $\text{Trustworthiness} \geq 1 - \delta_T$ は「2 近傍が潜在空間でも入力空間と高確率で一致すること」を保証し, 順位逆転による大きな r_2/r_1 の変動を確率的に抑える. これら 2 条件の下で, r_2/r_1 の分布変化は ε と δ_T の連続関数 $C(\varepsilon, \delta_T)$ で上界される ($\varepsilon = 0, \delta_T = 0$ のとき $C = 0$, 等長・完全近傍保存の場合に一致). (有限サンプル・有限次元での近似; 厳密なバウンドは等長定数の具体的な設定に依存する.) $\square$

注意 5 (命題 4 の実験的含意). 本命題は「等長性 $\varepsilon \approx 0$ が TwoNN 精度の唯一の条件」ではなく, 「 $m \gg d_{\text{ID}}$ による Trustworthiness の向上 (近傍順位の保存) が安定性の支配的因子」である可能性を示唆する. 実験 *Exp-Stab* (§ 5.2.4) では $\kappa \in [1.06, 2.16]$ の範囲で TwoNN ID の差が最大 $\pm 2.3\%$ に留まった一方, $m = d_{\text{true}}$ から $m > d_{\text{true}}$ への移行で TwoNN が回復した $-\delta_T$ (近傍逆転率) の減少が ε (等長性) の変化より支配的であることと整合する. 本命題は TwoNN を「真の d_{ID} の不偏推定量」と主張するものではなく, 「どの条件なら補助的参照推定量として運用可能か」を理論で支えるものである. 実験 *Exp-Real-Geom* (§ 5.10) はこの含意を実データで直接検証する.

5 実験

実験の 3 層分類: 本論文の実験は, 以下の 3 層に明確に分類される (表 3 の「位置づけ」列に対応).

主実験 (フレームワーク中核の実証) *Exp-Syn-1*, *Exp-Syn-AU*, *Exp-Mnist-Base*, *Exp-Mnist-Multi*, *Exp-Mnist-Dense*, *Exp-Fashion*, *Exp-Real-Geom*, *Exp-Nat-Cifar*. AU 値・TwoNN ID の頑健性 (RQ2) および m^{knee} の安定化条件 (RQ1) を主要検証対象とする.

補助実験 (主実験の前提条件・解釈論の検証) *Exp-Stab*, *Exp-Geom*, *Exp-Iso-ID*, *Exp-Syn-Iso*, *Exp-Conv-AE*, *Exp-Syn-Top*, *Exp-Mnist-PCA*, *Exp-Mnist-Dyn*, *Exp-Mnist-Ent*. TwoNN 数値安定性・IsometricAE 等長性・理論-実験橋渡し等を検証する (主要主張の支持根拠).

限界検証実験 (「どの条件で破綻するか」の定量化) *Exp-Conv-Fix*, *Exp-Conv-Ann*, *Exp-Conv-M256*, *Exp-Conv-M512*, *Exp-ConvV-HiBeta*, *Exp-NatImg-AU*, *Exp-NatImg-Sweep*, *Exp-NatImg-Knee*. Conv-VAE・自然画像での AU 飽和未達は「フレームワーク破綻」ではなく, 「どの条件 (β 水準, デコーダ容量, グリッド設計) で機能・不機能か」を定量化した貢献として位置づける.

5.1 実験設定

モデル共通: Adam ($\text{lr} = 10^{-3}$), バッチサイズ 128, ReLU (出力層 Sigmoid), 乱数シード 42, PyTorch 2.0.

合成多様体：隠れ層 [64, 32], 200~300 エポック, VAE $\beta = 4.0$, $n = 5,000$ (学習 4,000 / テスト 1,000).

MNIST / Fashion-MNIST：入力次元 784, 隠れ層 [512, 256], VAE $\beta = 4.0$, グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$, バッチサイズ 128. MNIST は 300 エポック ($n_{\text{train}} = 20,000$, $n_{\text{test}} = 3,000$), Fashion-MNIST は 100 エポック ($n_{\text{train}} = 10,000$, $n_{\text{test}} = 2,000$).

ID 推定：TwoNN ($k = 2$; アルゴリズムの定義により $k = 2$ が唯一の選択)・MLE ($k = 10$; Levina & Bickel[9] の推奨範囲 $k = 5 \sim 20$ の中央付近, $k = 5, 10, 20$ での安定性も確認済み) [8, 9]. AU 閾値 $\delta = 10^{-2}$ [22] (この閾値選択に対して AU は極めて頑健であり, $\delta \in [10^{-3}, 10^{-1}]$ の変動で AU 値はほぼ変化しないことを感度分析で確認済み; 付録付録 E).

表 3: 実験一覧：各実験の目的・データ・位置づけと対応 RQ. 位置づけの凡例：**主実験**（フレームワーク中核の実証），補助実験（前提条件・解釈論の検証），限界検証（破綻条件の定量化）.

実験ラベル	名称・目的	データ/設定
Exp-Syn-1	MSE 肘点・ID 確認	合成多様体
Exp-Syn-AU	AU 飽和 (AE vs VAE)	合成多様体
Exp-Syn-Top	位相的埋め込み次元と AU	Torus/Möbius 等
Exp-Syn-Iso	IsometricAE・等長性検証	合成多様体
Exp-Stab	TwoNN 数値安定性の実証	Swiss Roll + MNIST
Exp-Geom	MNIST AE m スイープ： κ ・TwoNN 共変化	MNIST AE, $m = 4 \sim 128$
Exp-Iso-ID	等長性改善が TwoNN ID に与える影響	Swiss Roll, AE vs IsometricAE
Exp-Mnist-Base	MNIST VAE スイープ（主実験）	MNIST FC-VAE, $m = 1 \sim 256$
Exp-Mnist-Multi	MNIST 多シード検証	3 シード $\times$ 150/300ep
Exp-Mnist-PCA	理論-実験橋渡し（PCA スペクトル）	MNIST PCA+Exp-Mnist-Base 対比
Exp-Mnist-Dense	密グリッド検証（3 因子分離）	MNIST FC-VAE, $m = 8 \sim 64$ 密
Exp-Fashion	Fashion-MNIST 適用検証	Fashion-MNIST FC-VAE
Exp-Conv-AE	畳み込み AE での ID 整合性確認	MNIST Conv-AE
Exp-Conv-Fix	固定 β Conv-VAE	MNIST Conv-VAE
Exp-Conv-Ann	KL アニール Conv-VAE	MNIST Conv-VAE
Exp-Conv-M256	Conv-VAE 拡張 m グリッド	MNIST Conv-VAE, $m = 4 \sim 256$
Exp-Conv-M512	Conv-VAE $m = 384 \cdot 512$ 拡張	MNIST Conv-VAE, 3 シード
Exp-ConvV-HiBeta	高 β による AU 飽和の誘発	MNIST Conv-VAE, $\beta_{\max} \in \{10, 20\}$
Exp-Nat-Cifar	CIFAR-10 TwoNN 外部妥当性確認	CIFAR-10 Conv-VAE
Exp-Nat-SVHN	SVHN 部分崩壊モニタリング	SVHN Conv-VAE
Exp-NatImg-AU	CIFAR-10 AU 飽和条件の探索	CIFAR-10 Conv-VAE, $\beta_{\max} \in \{10, 20, 40\}$
Exp-Real-Geom	実データ幾何比較：複数モデル TwoNN 安定性	MNIST+Fashion-MNIST, AE/IsometricAE/CAE
Exp-NatImg-Sweep	自然画像拡張スイープ	CIFAR-10, $m \in [32, 1024]$, $\beta_{\max} \in \{10, 20, 40, 80\}$
Exp-NatImg-Knee	m^{knee} 検出法比較（自然画像）	CIFAR-10, 4 手法比較
Exp-Mnist-Dyn	MNIST 学習ダイナミクス	MNIST FC-VAE, $m = 16$
Exp-Mnist-Ent	Manifold Entanglement 予備検証	MNIST クラス制限
Exp-Tau-Cross	τ_{knee} 横断検証	複数データセット

5.2 合成多様体実験：原理確認（RQ1・RQ2・RQ3）

合成多様体 (d_{true} 既知) を用いて, 提案フレームワークの原理的妥当性を確認する.

5.2.1 MSE 肘点と内在次元の対応（実験 Exp-Syn-1）

Swiss Roll ($d_{\text{true}} = 2$, 単連結) および Torus ($d_{\text{true}} = 2$, $d_{\text{emb}} = 3$) において, AE の MSE が $m = d_{\text{true}}$ (Swiss Roll) または $m = d_{\text{emb}}$ (Torus) で急激に改善することを確認した (表 4).

表 4: Exp-Syn-1：合成多様体 AE の MSE (3 シード平均 $\pm$ 標準偏差)

m	Swiss Roll MSE	Torus MSE
1	1.016 ± 0.057	0.388 ± 0.017
2	0.029 ± 0.002 $\leftarrow$ 肘点	0.085 ± 0.004
3	0.0008 ± 0.0001	0.0005 ± 0.0000 $\leftarrow$ 肘点
4	0.041 ± 0.015	0.019 ± 0.002

Swiss Roll では $m = 1 \rightarrow 2$ で MSE が約 35 倍改善し、命題 1 を実験的に確認する．Torus では $m = 3$ ($= d_{\text{emb}}$) で肘点が現れ、 $d_{\text{ID}} = 2$ では完全な再構成が不可能であることを示す．

5.2.2 AU 飽和と位相的構造 (実験 Exp-Syn-AU $\cdot$ Exp-Syn-Top)

VAE ($\beta = 4$) の AU パターンを、Vanilla AE と比較した (表 5)．

表 5: Exp-Syn-AU：Swiss Roll (上) $\cdot$ Torus (下) における VAE AU (3 シード平均 $\pm$ 標準偏差)

	m	Vanilla AE (AU)	VAE (AU, $\beta = 4$)
Swiss Roll ($d_{\text{true}} = 2$)	2	2	2.0 ± 0.0 (飽和)
	4	4	2.0 ± 0.0
	8	8	2.0 ± 0.0
	16	16	2.0 ± 0.0
Torus ($d_{\text{true}} = 2, d_{\text{emb}} = 3$)	4	4	2.0 ± 0.0
	6	6	3.0 ± 0.0 (飽和)
	8	8	3.0 ± 0.0
	16	16	3.0 ± 0.0

Vanilla AE では $\text{AU} = m$ (飽和なし) であるのに対し、VAE では Swiss Roll で $\text{AU}_{\text{sat}} = 2$ ($= d_{\text{true}}$)、Torus で $\text{AU}_{\text{sat}} = 3$ ($= d_{\text{emb}} > d_{\text{ID}}$) となる (全 3 シードで標準偏差 0.0)．これは定理 1 (水充填的 AU 飽和機構) の定性的含意と整合し、Torus において KL 正則化が位相的埋め込み次元付近で圧縮を始める可能性を示唆する (本研究条件下での経験的観測；前処理依存性・条件付きの知見に注意)．

実験 Exp-Syn-Top (位相的多様体での AU_{sat} と d_{emb} の対応) の結果を表 6 に示す．

表 6: Exp-Syn-Top：位相的多様体と VAE AU_{sat} (標準化条件下、本研究条件下での観測)

多様体	d_{ID}	π_1	d_{emb}	AU_{sat} (標準化)
Swiss Roll	2	$\{1\}$	2	3 (例外, 前処理依存)
Circle S^1	1	$\mathbb{Z}$	2	2 ($m \geq 6$, 条件付き)
Torus T^2	2	$\mathbb{Z}^2$	3	3 (主結果)
Möbius Band	2	$\mathbb{Z}$	3	3 (主結果)

Torus と Möbius Band において $\text{AU}_{\text{sat}} = d_{\text{emb}} = 3$ が本研究条件下で観測された．**ただし**，この対応は本研究条件 (標準化前処理, $\beta = 4$, 十分な収束) に依存しており，理論的必然性が保証されているわけではない (§ 6 参照)．

5.2.3 IsometricAE による等長性の達成 (実験 Exp-Syn-Iso)

Swiss Roll ($m = 2$) において，4 種類のモデルの等長性を比較した (表 7)．

表 7: Exp-Syn-Iso : Swiss Roll ($m = 2$) での 4 モデル比較 (3 シード平均 $\pm$ 標準偏差)

モデル	MSE	κ	NSR
AE	0.030 ± 0.003	1.251 ± 0.184	0.979 ± 0.036
CAE	0.036 ± 0.008	1.438 ± 0.105	0.659 ± 0.105
IsometricAE	0.029 ± 0.003	1.040 ± 0.009	0.753 ± 0.051
DAE	0.032 ± 0.003	1.179 ± 0.139	0.609 ± 0.085

IsometricAE のみが $\kappa \approx 1.04$ (等長性) を達成し (命題 3 と整合), MSE を大きく犠牲にせずに等長潜在空間を実現できることを示す. 等長潜在空間は ID 推定の信頼性を高める前提条件であり, Stage 1 の ID 推定の理論的精度向上に貢献する (計算コストとのトレードオフあり; § 6.7).

5.2.4 TwoNN ID の数値安定性と等長性バイアスの実証 (実験 Exp-Stab)

Stage 1 の参照 AE は $\kappa \approx 10^9$ (等長性なし) であるにもかかわらず, TwoNN ID 推定が補助的参照推定量として数値的に安定に機能するかを検証する (実験 Exp-Stab).

Section A – Swiss Roll での κ の影響 (表 8): AE ($\kappa = 1.791$) と IsometricAE ($\kappa = 1.055$) の潜在空間での TwoNN ID を生データ TwoNN (3D 入力, $d_{\text{true}} = 2$) と比較する ($n = 500$ テスト点, seed=42).

表 8: Exp-Stab Section A: Swiss Roll ($d_{\text{true}} = 2$) での TwoNN ID 比較. $m = d_{\text{true}} = 2$ では AE ($\kappa = 1.791$) と IsometricAE ($\kappa = 1.055$) の両方が TwoNN ≈ 1.55 と過小推定する (κ の差ではなく, タイトなボトルネック制約が主因). $m = 4$ ($> d_{\text{true}}$) では TwoNN が 2.03 へ回復し, 入力空間 TwoNN (≈ 2.06) と整合する推定値が得られる (数値的安定性の改善; 真値に対する不偏性は保証しない).

条件	m	κ	TwoNN ID	MLE ID
生データ (3D, 参照)	3	N/A	2.057	1.841
AE 潜在空間	2	1.791	1.553	1.242
IsometricAE 潜在空間	2	1.055	1.539	1.228
AE 潜在空間 (余剰次元)	4	2.155	2.028	2.078
seed=42, $n_{\text{train}} = 3000$, $n_{\text{test}} = 500$, 隠れ層 [64, 32], 150 エポック				

Section A の示唆: AE と IsometricAE は $m = 2 = d_{\text{true}}$ でほぼ同程度に TwoNN ≈ 1.55 と過小推定する (κ の差 1.06 vs 1.79 にほぼ依存しない) 一方, $m = 4 > d_{\text{true}}$ の AE ($\kappa = 2.155$) は TwoNN ≈ 2.03 へ回復する. すなわち $\kappa \in [1.06, 2.16]$ の範囲では, ボトルネック余裕 ($m - d_{\text{true}}$) の不足が TwoNN 過小推定の主因であり, $m \gg d_{\text{ID}}$ での TwoNN 利用の有用性を支持する (実験 Exp-Iso-ID で $m \in \{2, 3, 4, 6, 8\}$ 全範囲にわたり確認; § 5.2.5).

Section B – MNIST TwoNN 収束曲線 (図 2): 参照 AE の $\kappa \approx 10^9$ という極端な等長性逸脱にもかかわらず, TwoNN ID は $m \geq 128$ で 10.02 ($m = 128$) $\sim$ 10.14 ($m = 256$) へ収束する (既存 Exp-Mnist-Base データより; $m \geq 64$ で TwoNN = 9.16, 収束途上). $m \gg \hat{d}_{\text{ID}} \approx 10$ の条件下での安定収束は, 「 κ の大きさ $\neq$ TwoNN 推定の不安定性」を示す重要な観察であり, TwoNN を「数値安定な補助的参照推定量」と位置づける実証的根拠となる (「数値的安定」は「幾何学的に正確」を意味しない点に留意; § 6.7).

Section C – MNIST AE m -スweep: κ と TwoNN の共変化 (実験 Exp-Geom) (表 9): Swiss Roll (Section A) の知見を実データで検証するため, MNIST AE の潜在次元 m を系統的に変化させ, κ (条件数) と TwoNN ID を同時に計測した ($n_{\text{train}} = 10,000$, 200ep, seed=42).

表 9: 実験 Exp-Geom : MNIST AE m スイープ— κ と TwoNN ID の共変化 ($\hat{d}_{\text{ID}} \approx 10$). $m \geq 48 \approx 5\hat{d}_{\text{ID}}$ で TwoNN が収束し, $m = 96 \sim 128$ で κ が急増 ($9.94 \rightarrow 37.0$) しても TwoNN は安定を維持する.

m	κ	TwoNN ID	Trustworthiness	収束状態
4	2.69	4.21	0.960	収束前
8	2.72	6.34	0.988	収束前
12	2.71	7.25	0.992	収束前
16	3.28	8.17	0.993	収束途上
20	3.48	8.37	0.995	収束途上
32	4.32	9.36	0.997	収束途上
48	4.44	10.16	0.998	収束 ($\approx \hat{d}_{\text{ID}}$)
64	4.25	10.17	0.998	安定
96	9.94	10.86	0.999	安定 (κ 増加にもかかわらず)
128	37.0	10.98	0.999	安定 (κ 急増にもかかわらず)

$n_{\text{train}} = 10,000$, 200ep, hidden=[512,256], seed=42; κ : $n_{\text{eval}} = 8$ 点の中央値

表 9 の重要な観察は二点ある：(1) TwoNN は $m \leq 32$ で $\hat{d}_{\text{ID}} = 10$ を下回る (収束前, 過小推定), $m \geq 48 \approx 5\hat{d}_{\text{ID}}$ で安定収束する. (2) TwoNN 収束後 ($m \geq 64$), κ は $4.25 \rightarrow 37.0$ と急増するが, TwoNN は $10.17 \rightarrow 10.98$ ($\Delta < 0.82$) と安定を維持する. すなわち, **TwoNN の安定性は κ の大小ではなく「 $m \gg \hat{d}_{\text{ID}}$ 」という運用条件に依存する**. これは Section A (Swiss Roll) の知見を実データで再現・強化するものであり, Stage 1 での $m_{\text{ref}} = 256$ ($= 25\hat{d}_{\text{ID}}$) という設定が $\kappa \approx 10^9$ のもとでも TwoNN を信頼できる補助的参照推定量として機能させる根拠となる (逆に $m < 32 \approx 3\hat{d}_{\text{ID}}$ では過小推定リスクがある点に注意).




図 2: 実験 Exp-Stab : (左) Swiss Roll での TwoNN ID 棒グラフ — $m = d_{\text{true}} = 2$ では AE・IsometricAE ともに TwoNN ≈ 1.55 (κ 差よりボトルネック余裕の不足が主因); $m = 4 > d_{\text{true}}$ で TwoNN が 2.03 へ回復. (右) MNIST VAE TwoNN vs m 収束曲線 (参照 AE, $\kappa \approx 10^9$). 実験 Exp-Geom (AEm スイープ) の結果は表 9 を参照.

5.2.5 等長性改善が TwoNN ID に与える影響：多次元スイープ検証 (実験 Exp-Iso-ID)

実験 Exp-Stab Section A は $m = 2, 4$ の 2 点のみで「 κ 差よりボトルネック余裕が主因」という観察を示したが, その観察が m の広い範囲にわたって成立するかを確認するため, $m \in \{2, 3, 4, 6, 8\}$ での通常 AE と IsometricAE の潜在空間 TwoNN ID を比較した.

実験設定 (Exp-Iso-ID) :

- データ : Swiss Roll ($d_{\text{true}} = 2$, $n_{\text{train}} = 4000$, $n_{\text{test}} = 1000$, noise=0.05, seed=42)

- モデル：AE（通常）・IsometricAE ($\lambda_{\text{iso}} = 0.01$), 隠れ層 [64, 32], 300 エポック
- $m \in \{2, 3, 4, 6, 8\}$, 各条件で条件数 κ ・潜在空間 TwoNN ID・MSE を測定
- 入力空間 TwoNN ID (参照値) : 2.427 ($\approx d_{\text{true}} = 2$)

表 10: Exp-Iso-ID: Swiss Roll での通常 AE と IsometricAE の潜在空間 TwoNN ID 比較 ($m \in \{2, 3, 4, 6, 8\}$, 入力空間 TwoNN= 2.427, $d_{\text{true}} = 2$). $m \geq 3$ ($> d_{\text{true}}$) では κ が 2 倍異なる AE と IsometricAE の TwoNN ID が 0.5% 未満の差に留まる. $m = 2$ ($= d_{\text{true}}$) では両モデルとも TwoNN $\approx 1.78 \sim 1.80$ と過小推定となる.

m	AE (通常)		IsometricAE		ID 差 (%)
	TwoNN ID	κ	TwoNN ID	κ	
2	1.780	1.76	1.799	1.08	+1.1%
3	2.458	2.10	2.454	1.11	-0.2%
4	2.483	1.80	2.479	1.14	-0.2%
6	2.421	1.79	2.474	1.10	+2.2%
8	2.500	1.45	2.443	1.11	-2.3%

入力空間 TwoNN ID (参照) = 2.427, seed=42, 隠れ層 [64, 32], 300ep




図 3: Exp-Iso-ID : (左) m 別の潜在空間 TwoNN ID —AE (通常) と IsometricAE の曲線はほぼ重なり, 等長性改善による TwoNN ID への影響が軽微であることを示す; (右) デコーダ条件数 κ の比較 —IsometricAE は全 m で $\kappa \approx 1.1$ を維持し, AE は $m = 3$ で $\kappa = 2.10$ まで上昇する.

主要な観察 : $m \geq 3$ ($> d_{\text{true}}$) では, κ が AE $\approx 1.4 \sim 2.1$, IsometricAE ≈ 1.1 と約 1.3 $\sim$ 1.9 倍の差があるにもかかわらず, 両モデルの潜在空間 TwoNN ID の差は最大でも $\pm 2.3\%$ に留まる (例: $m = 3$ で AE= 2.458, Iso= 2.454; $m = 6$ で AE= 2.421, Iso= 2.474). 一方, $m = 2 = d_{\text{true}}$ では両モデルとも TwoNN $\approx 1.78 \sim 1.80$ と過小推定となり, 入力空間 TwoNN (2.427) を下回る. 以上から, 本設定における $\kappa \in [1.1, 2.1]$ での等長性改善は TwoNN ID の系統的バイアスを有意には低減せず, 「 $m \gg d_{\text{ID}}$ という十分なボトルネック余裕の確保」が TwoNN 推定の数値的安定化の支配的指針であることが確認された.

5.3 MNIST : 有効表現次元の読み取り (主実験, RQ1・RQ2)

MNIST データセットを用いて, 提案フレームワークの実データへの適用を検証する (主実験). MNIST は「実データであり, d_{true} は未知であるが $\hat{d}_{\text{ID}}$ を推定できる」という意味で, フレームワークの現実的な評価環境を提供する.

5.3.1 AE による内在次元の推定（実験 Exp-Mnist-Base-AE）

MNIST AE（300 エポック）の結果を表 11 に示す.

表 11: Exp-Mnist-Base : MNIST AE の結果（300 エポック, $n_{\text{train}} = 20,000$ ）

m	MSE	TwoNN ID	MLE ID	CKA
1	0.0437	1.02	1.15	0.102
4	0.0292	3.86	4.29	0.575
8	0.0191	6.08	6.70	0.725
16	0.0121	7.96	8.61	0.812
32	0.0087	8.84	9.89	0.875
64	0.0062	9.54	11.26	0.908
128	0.0061	9.84	11.45	0.921
256	0.0057	10.02	11.85	0.953

$m \geq 64$ で TwoNN ID（9.54~10.02）と MLE ID（11.26~11.85）が収束し、MNIST の実効内在次元が概ね $\hat{d}_{\text{ID}} \approx 10 \sim 12$ の範囲にあることを示す.

線形 PCA との比較：MNIST（ $n = 20,000$ ）に PCA を適用すると、累積寄与率 80% に 43 次元、90% に 86 次元が必要である. AE（TwoNN ≈ 10 ）の推定値と比較して 4~8 倍大きく、MNIST の非線形な多様体構造を示している（図 4 参照）.

5.3.2 VAE の AU Dynamics と m^{knee} （実験 Exp-Mnist-Base-VAE）

MNIST VAE（ $\beta = 4$, 300 エポック）の AU パターンを表 12 および図 4 に示す.

表 12: Exp-Mnist-Base : MNIST VAE（ $\beta = 4$ ）の結果（300 エポック）. $m = 12$ で AU 増加率が鈍化（ $m^{\text{knee}} = 12$ ）.

m	MSE	AU	TwoNN ID	$r(m)$ の変化
1	0.0464	1	1.00	—
4	0.0275	4	3.72	正常増加
8	0.0186	8	6.36	正常増加
12	0.0184	8	6.26	急落 $\leftarrow m^{\text{knee}} = 12$
16	0.0148	11	7.18	低
20	0.0134	13	7.59	低
32	0.0121	15	8.25	低
64	0.0103	29	9.16	緩やか
128	0.0085	26	10.02	緩やか
256	0.0072	36	10.14	緩やか

$m = 12$ で AU = 8（前の $m = 8$ と同じ）となり、AU 増加率 $r(m)$ が急落する（ $r(12) \approx 0$ ）. これが $\tau_{\text{knee}} = 0.25$ の閾値をトリガーし、 $m^{\text{knee}} = 12$ と同定される.

m^{knee} の解釈（単一条件下）：この単一シード拡張実験（seed 42, $m \in \{1, 4, 8, \dots, 256\}$ ）の条件下では、 $m^{\text{knee}} = 12$ は AE の TwoNN ID 収束値（ $\hat{d}_{\text{ID}} \approx 10 \sim 12$ ）と整合している. この条件下では、KL 正則化が MNIST の有効内在次元付近で次元圧縮を開始した可能性を示す粗い手がかりが得られるが、後続の多シード実験（§ 5.3.4, § 5.3.5）で示すように、この数値は m グリッドの設定や乱数シードによって変動するため、**特定の数値 12 自体の信頼性は限定的である**ことに注意が必要である.




図 4: Exp-Mnist-Base : MNIST における各指標の m 依存性 (300 エポック). **左 (AE)** : MSE (対数スケール, 左軸) と TwoNN ID (右軸). 垂直点線は PCA の累積寄与率 80% (43 次元), 90% (86 次元), 95% (152 次元) に対応; 非線形 AE の推定値 (TwoNN ≈ 10) との差異が明確である. **右 (VAE, $\beta = 4$)** : MSE (対数スケール, 左軸), AU (右軸), TwoNN ID (右軸破線). $m = 12$ (m^{knee}) で AU 増加率が急落 (矢印) し, 有効表現次元の読み取り点となる.

5.3.3 既存指標との比較

提案指標 m^{knee} を, 他の代表的なボトルネック次元設計指標と比較する (表 13).

表 13: MNIST における各指標のボトルネック次元推定値の比較

手法	推定値	参照元	特徴・限界
PCA (累積分散 80%)	43 次元	Exp-Mnist-Base-AE	線形, 過大推定傾向
PCA (累積分散 90%)	86 次元	Exp-Mnist-Base-AE	線形, さらに過大
MSE エルボー (AE)	$m \approx 16 \sim 20$	Exp-Mnist-Base-AE	直感的, 平滑化が必要
TwoNN ID (参照 AE)	$\approx 10 \sim 12$	Exp-Mnist-Base-AE	非線形だが等長性バイアスあり
m^{knee} (VAE, $\tau = 0.25$)	12*	Exp-Mnist-Base-VAE	KL ダイナミクス直接観察, $\tau \cdot \beta \cdot m$ グリッド・seed 依存
*単一シード拡張実験値 (seed 42, $m \in \{1, \dots, 256\}$); 多シード実験では 32~64 に変動			

各手法の特徴: PCA は線形手法であるため MNIST の非線形な多様体構造を反映できず, AE (TwoNN ≈ 10) の 4 倍以上の次元を要求する. MSE エルボーは直感的だが, 平滑な MSE 曲線 (Exp-Mnist-Base 参照) では肘点の決定が曖昧になりやすい. TwoNN は非線形 ID 推定として有効だが, 参照 AE の等長性バイアスを伴う. m^{knee} は KL ダイナミクスを直接観察する点でこれらと相補的な指標であるが, $\tau \cdot \beta \cdot m$ グリッドへの依存性があり, 単独での利用よりも他の指標と組み合わせた多指標アプローチでの使用が望ましい.

5.3.4 多シード検証 (実験 Exp-Mnist-Multi)

m^{knee} の統計的信頼性を評価するため, MNIST VAE ($\beta = 4$, 150 エポック, $m \in \{4, 8, 12, 16, 20, 32, 64\}$) を 3 つの乱数シード (42, 123, 777) で繰り返した (実験 Exp-Mnist-Multi; 表 14).

表 14: Exp-Mnist-Multi : 3 シード (42, 123, 777) の MNIST VAE AU ・ TwoNN ID の平均 $\pm$ 標準偏差 (150 エポック, $\beta = 4$). 各 m での AU は高い一貫性を示すが, m^{knee} は収束依存により変動する.

m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	備考
4	4.0 $\pm$ 0.0	3.98 $\pm$ 0.06	全次元活性
8	7.7 $\pm$ 0.5	6.37 $\pm$ 0.41	
12	10.0 $\pm$ 0.0	7.35 $\pm$ 0.19	
16	11.3 $\pm$ 0.5	7.66 $\pm$ 0.18	
20	13.3 $\pm$ 0.5	8.31 $\pm$ 0.18	
32	16.0 $\pm$ 0.0	8.92 $\pm$ 0.14	
64	22.0 $\pm$ 0.0	9.94 $\pm$ 0.08	$\hat{d}_{\text{ID}} \approx 10$ に収束
m^{knee} ($\tau = 0.25$) : シード 42 = 64, シード 123 = 32, シード 777 = 64			
平均 $m^{\text{knee}} = 53 \pm 15$ (150 エポック), vs. 300 エポック (Exp-Mnist-Base) : $m^{\text{knee}} = 12$			




図 5: Exp-Mnist-Multi : MNIST VAE の AU パターン (3 シード). 左: 各シードの AU vs m (点線は各シードの m^{knee}); 右: 平均 $\pm$ 標準偏差バンド. AU 値はシード間で高度に一致するが, m^{knee} は 32~64 に変動する.

Exp-Mnist-Multi の主要知見 : 各 m での AU 値は 3 シードにわたって高度に一致する ($\sigma \leq 0.5$; 表 14). TwoNN ID も $m = 64$ で 9.94 ± 0.08 と収束しており, $\hat{d}_{\text{ID}} \approx 10$ の推定はシード不変であることを確認した.

一方, m^{knee} ($\tau = 0.25$) はシード 42 = 64, シード 123 = 32, シード 777 = 64 と変動した (平均 53 ± 15). これは, AU 増加率 $r(m)$ が閾値 $\tau = 0.25$ に近い複数の m 値で微妙に変動するためであり, 150 エポックの不完全収束下ではこの不安定性が増幅される. なお, Exp-Mnist-Base 拡張実験 (単一シード 42) では 300 エポックで $m^{\text{knee}} = 12$ が得られたが, 後述の 300 エポック多シード実験 (§ 5.3.5) でも不安定性は残る (平均 43 ± 15). **150 エポック時点では収束不足の影響が重なっているが, 300 エポックに延長しても m^{knee} の数値的安定性が回復するわけではなく, m グリッドと乱数シードへの依存が主因であることが判明した (§ 5.3.5).** この知見は § 6.7 で限界として記載した内容を定量的に裏付ける.

5.3.5 300 エポック多シード検証 (実験 Exp-Mnist-Multi)

150 エポック実験での m^{knee} 不安定性が収束不足によるものかを検証するため, 同条件 (MNIST VAE, $\beta = 4$, $m \in \{4, 8, 12, 16, 20, 32, 64\}$) でエポック数を 300 に延長した実験 (Exp-Mnist-Multi) を 3 シード (42, 123, 777) で実施した (表 15).

表 15: Exp-Mnist-Multi : 3 シード (42, 123, 777) の AU・TwoNN ID の平均 ± 標準偏差 (300 エポック, $\beta = 4$). AU・TwoNN ID はシード間で高い一致を示すが, m^{knee} は依然として変動する.

m	AU (mean±std)	TwoNN ID (mean±std)	備考
4	4.0 ± 0.0	3.98 ± 0.14	全次元活性
8	8.0 ± 0.0	6.67 ± 0.15	
12	10.0 ± 0.0	7.41 ± 0.06	
16	11.7 ± 0.5	7.95 ± 0.21	AU 増加継続
20	13.3 ± 0.5	8.37 ± 0.14	
32	15.7 ± 0.5	9.07 ± 0.10	
64	22.3 ± 0.5	10.03 ± 0.12	$\hat{d}_{\text{ID}} \approx 10$ に収束
m^{knee} ($\tau = 0.25$): シード 42 = 64, シード 123 = 32, シード 777 = 32 平均 $m^{\text{knee}} = 43 \pm 15$ (300 エポック)			




図 6: Exp-Mnist-Multi : MNIST VAE の AU パターン (3 シード, 300 エポック). 左: 各シードの AU vs m (点線は m^{knee}); 右: 平均 ± 標準偏差バンド. AU・TwoNN ID のバンドは非常に狭いが, m^{knee} はシード間で 32~64 に変動する.

Exp-Mnist-Multi の主要知見: AU 値 (表 15) は 300 エポックでも 3 シード間で高度に一致し ($\sigma \leq 0.5$), TwoNN ID も $m = 64$ で 10.03 ± 0.12 と安定している. これらの定量的指標はシード・収束度に対してロバストであることを確認した.

一方, m^{knee} は 300 エポックの完全収束下でもシード間で 32~64 に変動した (平均 43 ± 15). これは, Exp-Mnist-Multi (150 エポック: $m^{\text{knee}} = 32 \sim 64$) と本質的に同一の変動範囲であり, エポック数を 300 に延長しても m^{knee} の不安定性は解消されなかった.

なお, Exp-Mnist-Base 拡張実験 (単一シード 42, $m \in \{1, 4, 8, \dots, 256\}$) での $m^{\text{knee}} = 12$ は, 異なる m グリッドを用いた際の乱数状態の変化により, 本多シード実験とは異なる初期化経路をたどったことに起因すると考えられる (詳細は § 6.7). m^{knee} は AU 増加曲線の形状から導かれる探索的ヒューリスティックであり, その精度は実験設定 (m グリッドの選択・乱数シード) に強く依存することを本実験は明確に示す.

5.3.6 線形理論—実験橋渡し: MNIST PCA スペクトル分析 (実験 Exp-Mnist-PCA)

§ 4.1 で予告したように, MNIST PCA スペクトルを用いて定理 1 (水充填原理) の定性的継承と定量的乖離を検証する (実験 Exp-Mnist-PCA).

MNIST PCA 固有値スペクトルと線形理論予測 MNIST 学習データ ($n = 20,000$, $[0, 1]$ 正規化) の共

分散行列の上位 PCA 固有値は：

$$\lambda_1 = 5.22, \lambda_2 = 3.76, \lambda_3 = 3.35, \dots, \lambda_{10} = 1.23, \lambda_{11} = 1.12, \lambda_{12} = 1.09, \dots$$

定理 1 より, $\beta = 4$, デコーダノイズ分散 τ^2 のもとで活性次元数は $d^*(\beta) = |\{j : \lambda_j > \beta\tau^2\}|$ となる. 表 16 に τ^2 ごとの線形理論予測を示す.

表 16: Exp-Mnist-PCA : MNIST PCA スペクトルに基づく線形理論予測 ($\beta = 4$) と非線形 VAE 観測値の比較

τ^2	水面 $\beta\tau^2$	線形理論 d^*	備考
1.0	4.0	1	従来想定 ($\lambda_1 = 5.22$ のみ超過)
0.30	1.20	10	$d^* = 10$ となる範囲 $\tau^2 \in (0.28, 0.31)$
0.25	1.00	12	$d^* = 12$ となる設定
0.14	0.57	20	$d^* = 20$ となる設定 ($\tau^2 \in (0.138, 0.150)$)
非線形 FC-VAE 観測値 (300ep, 3seed)			AU(64)= 22.3 ± 0.5 ; TwoNN ID(64) = 10.03 ± 0.12

定性的継承と定量的乖離 表 17 に, 線形理論から非線形実験への対応をまとめる.

表 17: Exp-Mnist-PCA : 線形理論 (定理 1) と非線形 MNIST VAE (実験 Exp-Mnist-Base, 300ep, 3seed) の比較

性質	線形理論の予測	非線形 VAE での観測
AU(m) の単調性	単調非減少 (保証)	確認 (全シード)
$\tau^2 = 1$ での d^*	$d^* = 1$ ($\lambda_1 = 5.22 > 4$ のみ)	AU(64) ≈ 22 (大きく乖離)
$d^* \approx 10$ と整合する τ^2	$\tau^2 \approx 0.30$ (逆算)	非線形デコーダの実効ノイズ $\ll 1$
AU の飽和の鋭さ	急激な段差 ($m = d^*$ で $r \rightarrow 0$)	緩やかな漸増 ($\sigma = 15$ の m^{knee} 不安定性)
$m^{\text{knee}} = d^*$ の数値的再現性	完全一致 (鋭い遷移を仮定)	不再現 ($m^{\text{knee}} \in \{32, 64\}$; § 5.3.5)

この比較から, 以下の 3 点が明確になる：

(i) $\tau^2 = 1$ の仮定は非線形 VAE に不適用. 非線形デコーダは線形デコーダより大幅に優れた再構成を達成するため, 実効的な $\tau_{\text{eff}}^2 \approx 0.30$ (逆算値) は入力空間の標準ノイズ分散 ($\tau^2 = 1$) よりはるかに小さく, より多くの次元が「有効」と判定される. Conv-VAE ではデコーダがさらに強力なため τ_{eff}^2 はさらに小さくなり, AU 飽和に必要な m が FC-VAE 比で大幅に増大する (§ 6.6).

(ii) 飽和の滑らかさが m^{knee} の不安定性の理論的根拠. 線形設定での鋭い飽和転換 ($m = d^*$ で AU(m) が段差的に変化) は, 非線形最適化では勾配競合 (§ 6.2) により滑らかな漸増曲線となる (図 7 参照). 命題 2 の上界 $|m^{\text{knee}} - d^*| \leq \max_i (m_{i+1} - m_i)$ は鋭い遷移を仮定しているが, 実際の誤差はこの上界を大幅に超える.

(iii) 定性的継承. AU(m) の単調非減少性と「有効次元を超えると AU 増加が鈍化する」という定性的傾向は非線形設定でも継承される. 線形理論はこのメカニズムの「水充填的な原理」を提供しており, 合成多様体での急激な AU 飽和 (実験 Exp-Syn-AU ; § 5.2) はその例証となる.




図 7: 実験 Exp-Mnist-PCA : (左) MNIST PCA 固有値スペクトルと線形理論の水充填水面 ($\beta\tau^2 \approx 1.18$, $d^* = 10$). (右) 線形理論の予測 (赤実線; $d^* = 10$ で鋭い飽和を仮定) と非線形 FC-VAE の観測 AU(m) 曲線 (各シード・平均) の比較. 非線形 VAE での AU 増加は緩やかであり, m^{knee} の不安定性の理論的根拠を示す.

5.3.7 密グリッド×シード×エポック因子分離実験 (実験 Exp-Mnist-Dense)

m^{knee} の不安定性がどの要因に起因するかを厳密に特定するため, グリッド密度・エポック・シードの 3 要因を単離した実験を設計した. Exp-Mnist-Base と Exp-Mnist-Multi では既にエポック因子 (150ep vs. 300ep) とシード因子 (3 シード) が分離されている. 本実験 Exp-Mnist-Dense ではさらにグリッド密度因子を単離する: $m \in \{8, 9, 10, 11, 12, 13, 14, 15, 16, 18, 20, 24, 28, 32, 40, 48, 64\}$ (17 点, 隣接点間隔 1~8) で 300 エポック・3 シードで学習した. 密グリッドは特に $m = 8 \sim 16$ (推定 $\hat{d}_{\text{ID}} \approx 10$ の前後) を 1 刻みでカバーする (命題 2 の上界より, 間隔 1 の場合 $|m^{\text{knee}} - d^*| \leq 1$ が期待される).

表 18: Exp-Mnist-Dense : 密グリッド (Exp-Mnist-Dense) vs. 疎グリッド (Exp-Mnist-Base) の m^{knee} 比較 ($\tau = 0.25$, MNIST, FC-VAE, $\beta = 4$). 命題 2 の上界 (グリッド間隔 = m^{knee} 誤差の上界) を検証する.

条件	グリッド間隔 (最大)	seed=42	seed=123	seed=777	平均 ± 標準偏差
疎グリッド 150ep (Exp-Mnist-Base)	32	64	32	64	53 ± 15
疎グリッド 300ep (Exp-Mnist-Base)	32	64	32	32	43 ± 15
密グリッド 300ep (Exp-Mnist-Dense)	8 (8-16 は 1)	11	9	11	10.3 ± 0.9

表 19: Exp-Mnist-Dense : 密グリッドの AU(m) (seed=42, 300ep, 代表値)

m	8	9	10	11	12	13	14	15
AU	8	9	10	10	10	10	12	11
m	16	18	20	24	28	32	48	64
AU	14	13	15	14	15	15	19	21




図 8: Exp-Mnist-Dense : (左) 密グリッドの AU vs m (3 シード). (右) グリッド密度×エポックの比較. 密グリッドでの m^{knee} 変動は命題 2 の上界 (最大グリッド間隔) で評価できる.

Exp-Mnist-Dense 実験の意義 : 表 18 の 3 行比較により, 3 要因 (グリッド密度・エポック・シード) が定量的に単離される :

- **エポック因子** : 疎グリッド 150ep $\rightarrow$ 300ep (m^{knee} : $53 \pm 15 \rightarrow 43 \pm 15$) — エポック増加で若干安定するが, 主因ではない
- **シード因子** : 同一条件の 3 シード間での変動 ($\sigma = 15$) — 初期化による最適化経路の差が影響するが, 疎グリッドと共存する二次的因子
- **グリッド密度因子 (主要因の一つ)** : 密グリッド (Exp-Mnist-Dense) では $m^{\text{knee}} = 10.3 \pm 0.9$ (seed=[11,9,11]) — 疎グリッド 43 ± 15 から劇的に改善し, 推定 $\hat{d}_{\text{ID}} \approx 10$ と整合する

命題 2 の実証 : Exp-Mnist-Dense 実験は命題 2 の上界「 $|m^{\text{knee}} - d^*| \leq \max_i(m_{i+1} - m_i)$ 」を直接支持する. 密グリッドで $m = 8 \sim 16$ の間隔を 1 に削減した結果, $m^{\text{knee}} \in \{9, 11\}$ (3 シード) となり, $d^* \approx 10$ との乖離が 1 以内に収まった (上界 = 最大グリッド間隔 = 8 ($m > 16$ の区間) だが, 検出は間隔 1 の密な区間で起こる). この結果は, m^{knee} の不安定性の主要因の一つがグリッド設計にあることを示す重要な証拠を与える. ただし, シード因子も二次的に寄与することは本実験でも確認されており (疎グリッドでの 3 シード変動; § 5.3.5), また非線形最適化での飽和の滑らかさにより, 命題 2 の上界を超えた誤差が生じうる点にも留意が必要である.

τ 法と二階差分法の比較 : m^{knee} の検出には, 本稿で採用している一階差分比率法 ($\tau = 0.25$) のほかに, AU(m) 曲線の曲率が最大となる点を求める**二階差分法** (付録付録 C) がある. Exp-Mnist-Dense 密グリッドデータでの比較結果を表 20 に示す.

表 20: Exp-Mnist-Dense : τ 法 ($\tau = 0.25$) vs 二階差分法 (d2 法) の m^{knee} 比較 (密グリッド, 300ep, 3 シード).

手法	seed=42	seed=123	seed=777	平均 $\pm$ 標準偏差
τ 法 ($\tau = 0.25$)	11	9	11	10.3 ± 0.9
二階差分法 (d2 法)	15	28	12	18.3 ± 6.8
参考: 推定 $\hat{d}_{\text{ID}} \approx 10$ (TwoNN, $m = 64$, 3 シード平均)				

τ 法は平均 10.3 ± 0.9 と $\hat{d}_{\text{ID}} \approx 10$ に整合し, シード間変動が小さい. 一方, d2 法は AU(m) の離散的ノイズに敏感で, seed=123 では $m^{\text{knee}} = 28$ と大きく外れた (AU 曲線の遷移域で AU が $8 \rightarrow 10 \rightarrow 9 \rightarrow 11 \rightarrow 10 \rightarrow 11 \rightarrow 13$ と揺動し, 二階差分の最大値点が乱れる). したがって, **密グリッド条件での m^{knee} 検出には τ 法**




図 9: Exp-Fashion : Fashion-MNIST の AE (左)・VAE (右) における MSE, AU, TwoNN ID の m 依存性 (100 エポック). VAE では $m = 12$ 付近 ($\tau_{\text{knee}} = 0.25$ での m^{knee}) で AU 成長率が急減し, TwoNN ID は $m \geq 32$ で ≈ 9.4 (AE)・ ≈ 8.7 (VAE) に漸的に収束する.

の方が安定であり, d2 法は大域的な「肘点」候補を探す補助手段として位置づける (付録付録 C 参照).

■ $\text{AU}_{\text{sat}} = 36$ の解釈 (実験 Exp-Mnist-Ent, 予備検証) MNIST VAE の $\text{AU}_{\text{sat}} = 36$ ($m = 256$) は $\hat{d}_{\text{ID}} \approx 10 \sim 12$ を大幅に超えており, $m^{\text{knee}} = 12$ とは区別する (§ 6.5). クラス数 $K \in \{1, 2, 5, 10\}$ の制限実験 (75ep) では, TwoNN ID が $K = 1$ の 5.10 から $K = 10$ の 8.89 へ単調増加し, クラス数増加に伴う有効多様体次元の拡大を示唆する. AU_{sat} はこの予備検証では未収束であり, Manifold Entanglement の結論は今後の課題とする.

■ 学習ダイナミクス (実験 Exp-Mnist-Dyn, 探索的) MNIST ($m = 16$, 200ep) で大域・局所構造の時間的分離を確認した: Trustworthiness は Epoch 1 $\rightarrow$ 5 で 0.926 $\rightarrow$ 0.988 へ急上昇 (大域構造の急速形成), 以後 TwoNN ID が 4.21 $\rightarrow$ 14.22 へ漸的に増加 (局所的有効次元の段階的精緻化) する 2 段階パターンが観測された (単一シード, § 6.5 参照).

5.4 Fashion-MNIST への適用：異種実データでの検証 (実験 Exp-Fashion)

Fashion-MNIST (衣類 10 クラス, MNIST と同一サイズ 28×28) に対して MNIST と同一のアーキテクチャ・設定を適用し, フレームワークの汎化性を検証する.

表 21: Exp-Fashion : Fashion-MNIST AE・VAE の結果 (100 エポック, $n_{\text{train}} = 10,000$, 代表的 m 値)

AE			VAE ($\beta = 4$)		
m	MSE	TwoNN ID	m	MSE	AU
4	0.01831	3.90	4	0.01955	4
8	0.01389	5.86	8	0.01721	6
12	0.01230	7.58	12	0.01597	6
16	0.01138	8.11	16	0.01570	7
20	0.01077	8.45	20	0.01471	8
32	0.01010	8.99	32	0.01418	9
64	0.00981	9.39	64	0.01318	11
256	0.01009	9.42	256	0.01193	25

実験 Exp-Fashion の結果 (表 21, 図 9) から, 以下の知見が得られる. AE では $\text{AU} = m$ (全次元が活性) かつ TwoNN ID が $m \geq 32$ で ≈ 9.4 に収束し, Fashion-MNIST の $\hat{d}_{\text{ID}} \approx 9 \sim 10$ が示唆される. VAE ($\beta = 4$)

では $m^{\text{knee}} = 12$ ($\tau_{\text{knee}} = 0.25$) が確認され、MNIST の $m^{\text{knee}} = 12$ と一致する一方、AU は $m = 256$ でも 25 にとどまり (MNIST の 36 と異なり)、Fashion-MNIST が MNIST より高い圧縮難度をもつ可能性を示す。TwoNN ID の推定値 ($\approx 9 \sim 10$) は MNIST ($\approx 10 \sim 12$) より小さく、衣類の方が手書き数字より局所的な自由度が少ないという直感と整合する。

5.5 畳み込みアーキテクチャへの拡張 (実験 Exp-Conv-AE)

全結合型に限定した場合の一般化可能性への懸念に対し、畳み込み型 AE/VAE (Conv-AE/VAE) を MNIST に適用した実験 (実験 Exp-Conv-AE) を実施した。

Conv-AE/VAE アーキテクチャ：

- エンコーダ: $\text{Conv}(1 \rightarrow 32, k = 3, \text{stride} = 2) \rightarrow \text{Conv}(32 \rightarrow 64, k = 3, \text{stride} = 2) \rightarrow \text{FC}(3136 \rightarrow m)$
(VAE では $\rightarrow \mu, \log \sigma^2$)
- デコーダ: $\text{FC}(m \rightarrow 3136) \rightarrow \text{ConvT}(64 \rightarrow 32, k = 4, \text{stride} = 2) \rightarrow \text{ConvT}(32 \rightarrow 1, k = 4, \text{stride} = 2) \rightarrow \text{Sigmoid}$
- $n_{\text{train}} = 20,000$, 100 エポック, $m \in \{4, 8, 12, 16, 20, 32, 64\}$, seed 42

表 22: Exp-Conv-AE : Conv-AE $\cdot$ Conv-VAE ($\beta = 4$) の MNIST 結果 (100 エポック, seed 42)

Conv-AE			Conv-VAE ($\beta = 4$)		
m	MSE	TwoNN ID	m	MSE	AU
4	0.0311	4.18	4	0.0331	4
8	0.0174	6.59	8	0.0197	8
12	0.0113	7.80	12	0.0140	12
16	0.0081	8.69	16	0.0109	16
20	0.0069	9.03	20	0.0097	20
32	0.0042	10.06	32	0.0070	32
64	0.0020	11.29	64	0.0049	63




図 10: Exp-Conv-AE : Conv-AE (左) $\cdot$ Conv-VAE (右) における MSE, AU, TwoNN ID の m 依存性 (MNIST, 100 エポック). Conv-AE では $\text{AU} = m$ (全次元活性) が確認され、TwoNN ID が $m \geq 32$ で ≈ 11 に収束する。Conv-VAE では $\text{AU} \approx m$ (100 エポックの収束不足により飽和なし)。

実験 Exp-Conv-AE の結果 (表 22) から以下の知見が得られる。

Conv-AE の TwoNN ID : $m = 64$ で TwoNN ID = 11.29 に収束し、FC-AE の推定値 (≈ 10) と整合する (誤差 $\approx 10\%$ 以内)。アーキテクチャ (全結合 vs 畳み込み) によらず、TwoNN による ID 推定値が一

貫することを確認した（本研究条件下での経験的観測）。

Conv-VAE の収束感度： $m \leq 32$ では $AU = m$ （飽和なし）， $m = 64$ で $AU = 63$ であり，100 エポックでは KL 正則化による次元抑制が十分に機能していない．これは FC-VAE での 150 エポック実験（Exp-Mnist-Multi： $AU \approx m$ ）と同様であり，**Conv-VAE における m^{knee} の信頼ある検出にも，より多くのエポック数が必要**であることを示す．

5.5.1 Conv-VAE での AU 飽和遅延：固定 β ・KL アニール比較（実験 Exp-Conv-Fix・Exp-Conv-Ann）

Exp-Conv-AE の収束不足を受け，300ep・3 シード（Exp-Conv-Fix）および KL サイクリックアニール（Exp-Conv-Ann）で検証した（表 23）。

表 23: Exp-Conv-Fix・Exp-Conv-Ann：MNIST Conv-VAE の AU 比較（300ep, 3 シード平均 $\pm$ 標準偏差）．FC-VAE（Exp-Mnist-Multi）は $m = 32$ で $AU = 15.7$ と大幅に飽和するのにに対し，Conv-VAE は固定 β ・アニールいずれも $m \leq 32$ で $AU = m$ （飽和なし）． $m = 64$ での固定 β のみ僅かな崩壊（ $AU = 54.3 \pm 0.5$ ）が観測された．

m	Conv-VAE 固定 β (Exp-Conv-Fix)		Conv-VAE アニール (Exp-Conv-Ann)		FC-VAE (Exp-Mnist-Base-300ep)	
	AU	TwoNN ID	AU		AU	TwoNN ID
4	4.0 ± 0.0	3.97 ± 0.08	4.0 ± 0.0		4.0	3.98
12	12.0 ± 0.0	8.14 ± 0.09	12.0 ± 0.0		10.0	7.41
32	32.0 ± 0.0	11.43 ± 0.08	32.0 ± 0.0		15.7	9.07
64	54.3 ± 0.5	13.10 ± 0.05	64.0 ± 0.0		22.3	10.03

m^{knee} : Conv-VAE (両条件) 全シード=64 (グリッド上限) ; FC-VAE=43 $\pm$ 15 (32~64)

Conv-VAE は固定 $\beta = 4$ ・サイクリックアニールいずれでも $m \leq 32$ で $AU = m$ （飽和なし）であり，FC-VAE との乖離が明確である（§ 6.6 で理論的考察）． $AU \approx m$ は「KL 正則化が未機能」のシグナルであり，この状態では TwoNN ID も膨張する（Conv-VAE $m = 64$: 13.10, FC-VAE: 10.03）． $m \leq 64$ のグリッドでは **AU 飽和の観察が不可能**であり， m 範囲の拡張が必要である．

5.6 Conv-VAE 拡張 m グリッド実験（実験 Exp-Conv-M256・Exp-Conv-M512）

Exp-Conv-Fix・Exp-Conv-Ann（§ 5.5.1）で $m \leq 64$ では AU 飽和が観測されなかったことを受け， m グリッドを 256（実験 Exp-Conv-M256）および 512（実験 Exp-Conv-M512）まで拡張した．§ 6.6 で論じる τ_{eff}^2 の低下仮説のもとでは，Conv-VAE の $d^*(\beta)$ は FC-VAE（ ≈ 10 ）より大幅に大きいため， $m > 64$ の領域で初めて AU 増加の鈍化が現れると予測される．

実験設定（Exp-Conv-M256）：Exp-Conv-Ann と同一の Conv-VAE アーキテクチャ（ 28×28 MNIST，2 層 Conv エンコーダ・2 層 ConvTranspose デコーダ，KL サイクリックアニール $\beta_{\text{max}} = 4$ ，3 サイクル，150 エポック， $\text{seeds} \in \{42, 123, 777\}$ ）を用い， $m \in \{4, 8, 16, 32, 64, 96, 128, 192, 256\}$ （9 点）を検証した．

表 24: Exp-Conv-M256 : Conv-VAE 拡張 m グリッド (KL アニールグ, 150 エポック, 3 シード平均 $\pm$ 標準偏差). $m \leq 64$ では $AU = m$ (全次元活性), $m \geq 96$ で $AU < m$ (飽和開始) が現れる. 比較のため FC-VAE (実験 Exp-Mnist-Base, 300ep, $m = 64$) の $AU = 22.3 \pm 0.5$ を掲載する.

m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	備考
4	4.0 ± 0.0	3.84 ± 0.11	全次元活性
8	8.0 ± 0.0	6.64 ± 0.11	
16	16.0 ± 0.0	8.76 ± 0.05	
32	32.0 ± 0.0	10.46 ± 0.13	
64	64.0 ± 0.0	13.29 ± 0.12	Exp-Conv-Ann と同一 (飽和なし) AU < m 開始 (FC-VAE $\hat{d}_{ID}$ の $\approx 9\times$)
96	90.7 ± 1.2	14.30 ± 0.22	
128	111.7 ± 2.6	14.69 ± 0.13	
192	159.0 ± 4.3	15.89 ± 0.27	
256	241.3 ± 2.9	16.58 ± 0.16	

m^{knee} ($\tau = 0.25$): 全シード=256 (検証範囲内に knee なし)
FC-VAE 比較 (Exp-Mnist-Base, 300ep, $m = 64$): $AU = 22.3 \pm 0.5$, TwoNN ID = 10.03 ± 0.12




図 11: 実験 Exp-Conv-M256 : Conv-VAE 拡張 m グリッド ($m \in [4, 256]$, KL アニールグ, 3 シード) の AU vs m (左) および TwoNN ID vs m (右). 対角線 ($AU = m$) と FC-VAE の $\hat{d}_{ID} \approx 10$ 参照線 (赤) を示す. $m \leq 64$ では $AU = m$ (対角線上) が続くが, $m \geq 96$ で対角線から離れ始め, Conv-VAE でも水充填原理の定性的傾向が確認できる.

実験 Exp-Conv-M256 の主要知見: $m \leq 64$ では $AU = m$ が全 3 シードで一致し, FC-VAE ($m = 64$: $AU = 22.3$) との対比が際立つ. $m = 96$ で初めて $AU = 90.7 \pm 1.2$ (< 96) が現れ, 飽和開始が確認された (3 シード間標準偏差 $\sigma = 1.2$). $m = 256$ では $AU = 241.3 \pm 2.9$ (活性率 94.3%) となり, 依然として高い活性率を維持する. m^{knee} ($\tau = 0.25$) は全 3 シードで 256 となり, 検証範囲内では急激な AU 飽和は見つからなかった. この結果は, Conv-VAE の $d^*(\beta)$ が FC-VAE の $d^*(\beta) \approx 10$ より大幅に大きい ($\gg 64$, おそらく > 256) ことを示す. τ_{eff}^2 理論との対応, および自然画像への含意については § 6.6 で論じる.

$m = 256$ 超への拡張 (実験 Exp-Conv-M512): Exp-Conv-M256 の「 $m^{\text{knee}} = 256$ (グリッド端)」という結果を受け, $m \in \{384, 512\}$ まで拡張した実験 (Exp-Conv-M512, 3 シード, 150ep) を実施した.

Exp-Conv-M512 (3 シード, 150ep) の結果を表 25 に示す.

表 25: 実験 Exp-Conv-M512 : MNIST Conv-VAE の $m \in \{384, 512\}$ 拡張結果 (3 シード平均 ; KL サイクリックアニーリング, $\beta_{\max} = 4, 150\text{ep}$). $m = 256$ 超においても $\text{AU} \approx m$ が継続し, 明確な AU 飽和プラトーは観測されなかった.

m	AU (seed42)	AU (seed123)	AU (seed777)	TwoNN ID (seed42)
256	241	245	238	16.46
384	382	383	380	17.51
512	512	511	512	17.98
$m^{\text{knee}} (\tau = 0.25)$ 全 3 シードで $m^{\text{knee}} = 512$ (グリッド端, 飽和未検出)				

Exp-Conv-M512 の結果から, MNIST の今回設定の Conv-VAE では $m \leq 512$ の全範囲で $\text{AU} \approx m$ (全次元活性) が維持されており, 明確な AU 飽和プラトーは観測されなかった (m^{knee} は全シードでグリッド端の 512 に張り付く). この結果は, MNIST Conv-VAE の $d^*(\beta)$ が少なくとも $m = 512$ より大きいことを示しており, MSE ベースの強力なデコーダが AU 飽和を高次元へ押しやるという § 6.6 の理論的予測と整合する. AU 飽和の観測には β スケジュールやデコーダ容量の見直しが必要である. 次節では, $\beta_{\max}$ を強化することで MNIST Conv-VAE でも AU 飽和を人為的に誘発できることを示す.

5.7 高 β による Conv-VAE AU 飽和の人為的誘発 (実験 Exp-ConvV-HiBeta)

§ 6.6 の τ_{eff}^2 仮説 (強力デコーダが AU 飽和を高次元側に押しやる) の逆証明として, $\beta_{\max}$ を $4 \rightarrow \{10, 20\}$ に増大させ, MNIST Conv-VAE での AU 飽和プラトーを人為的に誘発できるかを検証した.

実験設定 : Exp-Conv-M256 と同一アーキテクチャ・KL サイクリックアニーリング (3 サイクル) を使用し, $\beta_{\max} \in \{10, 20\}$, $m \in \{16, 32, 64, 96, 128, 192, 256\}$, seed=42, 150 エポックで学習した (比較用として Exp-Conv-M256 の $\beta_{\max} = 4$ seed=42 結果を再掲する).

表 26: 実験 Exp-ConvV-HiBeta : $\beta_{\max} \in \{4, 10, 20\}$ での MNIST Conv-VAE AU 比較 (seed=42, 150ep, KL サイクリックアニーリング). $\beta_{\max}$ を強化するほど AU 飽和が低次元側で生じ, $d^*(\beta)$ がシフトすることを実証する.

m	$\beta_{\max} = 4$ (Exp-Conv-M256)	$\beta_{\max} = 10$	$\beta_{\max} = 20$
16	16 (100%)	16 (100%)	16 (100%)
32	32 (100%)	32 (100%)	27 (84%)
64	64 (100%)	54 (84%)	42 (66%)
96	89 (93%)	65 (68%)	47 (49%)
128	114 (89%)	69 (54%)	53 (41%)
192	161 (84%)	79 (41%)	60 (31%)
256	241 (94%)	93 (36%)	66 (26%)
$m^{\text{knee}} (\tau = 0.25)$	512 (グリッド端, 未同定)	≈ 128	≈ 96

Exp-ConvV-HiBeta の知見 (表 26) : $\beta_{\max} = 4$ では $m \leq 64$ で $\text{AU} = m$ (100% 活性) が続くのに対し, $\beta_{\max} = 10$ では $m = 64$ で $\text{AU} = 54$ (84%), $m = 128$ で $\text{AU} = 69$ (54%), $m = 256$ で $\text{AU} = 93$ (36%) と明確な AU 飽和傾向が現れ, $m^{\text{knee}} \approx 128$ ($\tau = 0.25$) が同定された. さらに $\beta_{\max} = 20$ では $m = 32$ で $\text{AU} = 27$ (84%), $m = 64$ で $\text{AU} = 42$ (66%) とより低次元側で飽和が生じ, $m^{\text{knee}} \approx 96$ が観測された. これは § 6.6 の τ_{eff}^2 仮説の予測に直接整合する : β を増大させると $d^*(\beta) = |\{j : \lambda_j > \beta \tau_{\text{eff}}^2\}|$ が小さい値に移動し, AU 飽和がより低次元側に現れる. **この結果は, MNIST Conv-VAE での AU 飽和未観測が「フレームワークの破綻」ではなく, $\beta_{\max} = 4$ という設定ではデコーダ容量に比して正則化が不足し $d^*(\beta) \gg 256$ と**

なっていたことに起因することを実験的に示している。AU/mknee フレームワークの Conv-VAE への適用には、データ・アーキテクチャに合わせた β の適切な設定が必要である。




図 12: Exp-ConvV-HiBeta : $\beta_{\max} \in \{4, 10, 20\}$ での MNIST Conv-VAE AU vs m (左) および活性率 AU/ m (右) の比較. $\beta_{\max}$ を増大させると AU 飽和が低次元側に現れ, $d^*(\beta)$ の β 依存性を実証する.

5.8 自然画像への適用：CIFAR-10・SVHN (実験 Exp-Nat-Cifar・Exp-Nat-SVHN)

より複雑な自然画像データセット (CIFAR-10[3], SVHN[4]) に対して本フレームワークを適用し, Pope ら [17] の内在次元推定との比較を行った.

実験設定 (Exp-Nat-Cifar : CIFAR-10, Exp-Nat-SVHN : SVHN) :

- アーキテクチャ : Conv-VAE (入力 $32 \times 32 \times 3$)
 - エンコーダ : $\text{Conv}(3 \rightarrow 32, k=4, s=2, p=1) \rightarrow \text{Conv}(32 \rightarrow 64, k=4, s=2, p=1) \rightarrow \text{Conv}(64 \rightarrow 128, k=4, s=2, p=1) \rightarrow \text{FC}(2048 \rightarrow m) \times 2 (\mu, \log \sigma^2)$
 - デコーダ : $\text{FC}(m \rightarrow 2048) \rightarrow \text{ConvT}(128 \rightarrow 64) \rightarrow \text{ConvT}(64 \rightarrow 32) \rightarrow \text{ConvT}(32 \rightarrow 3) \rightarrow \text{Sigmoid}$
- $n_{\text{train}} = 20,000$, 150 エポック, KL サイクリックアニーリング ($\beta_{\max} = 4$, 3 サイクル)
- $m \in \{16, 32, 64, 128, 256\}$, seeds $\in \{42, 123, 777\}$

表 27: Exp-Nat-Cifar・Exp-Nat-SVHN : CIFAR-10 (左)・SVHN (右) の Conv-VAE 実験結果 (3 シード 平均 $\pm$ 標準偏差) と Pope ら [17] の報告値の比較 (KL サイクリックアニーリング, 150 エポック, 3 サイクル). CIFAR-10 では $m = 64$ で潜在 TwoNN ID が生データ TwoNN ID と一致 (≈ 25), Pope ら [17] の報告値 ($d_{\text{ID}} \approx 26$) を独立に支持する. SVHN では $m \geq 128$ で $AU < m$ (部分的崩壊) が観測される.

CIFAR-10 (Exp-Nat-Cifar)			SVHN (Exp-Nat-SVHN)	
m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)
16	16.0 $\pm$ 0.0	13.12 $\pm$ 0.12	16.0 $\pm$ 0.0	11.30 $\pm$ 0.12
32	32.0 $\pm$ 0.0	19.26 $\pm$ 0.23	32.0 $\pm$ 0.0	15.08 $\pm$ 0.08
64	64.0 $\pm$ 0.0	25.21 $\pm$ 0.41	64.0 $\pm$ 0.0	19.97 $\pm$ 0.12
128	128.0 $\pm$ 0.0	28.83 $\pm$ 0.41	125.3 $\pm$ 0.5	24.60 $\pm$ 0.36
256	256.0 $\pm$ 0.0	30.91 $\pm$ 0.64	206.7 $\pm$ 1.2	27.08 $\pm$ 0.34
Raw TwoNN=25.20, MLE=26.56 ($\approx$ Pope 推定値 26)			Raw TwoNN=10.09, MLE=18.85	
$m^{\text{knee}} (\tau = 0.25)$: 全シード=256 (範囲内 knee なし)			m^{knee} : 全シード=256 (範囲内 knee なし)	




図 13: Exp-Nat-Cifar : CIFAR-10 Conv-VAE (KL サイクリックアニーリング) における AU・TwoNN ID の m 依存性 (3 シード). TwoNN ID は Pope ら [17] の報告値 ($d_{ID} \approx 26$) と収束傾向を示す.




図 14: Exp-Nat-SVHN : SVHN Conv-VAE (KL サイクリックアニーリング) における AU・TwoNN ID の m 依存性 (3 シード).

本実験の主眼は TwoNN ID 推定の外部妥当性確認に限定される (AU/m^{knee} 側の安定同定は将来課題).

CIFAR-10 (Exp-Nat-Cifar) — TwoNN 外部妥当性: $m = 64$ での潜在 TwoNN ID = 25.21 ± 0.41 (3 シード, $\sigma = 0.41$) は, 生データ TwoNN ID (25.20) と一致し, Pope ら [17] の報告値 (≈ 26) を独立に再現した (Exp-Geom 実験の MNIST 同様, $m \gg d_{ID}$ 条件での数値安定性を支持). AU は $m \leq 256$ で $AU = m$ (飽和なし) であり, m^{knee} は全シードで 256 (グリッド端).

SVHN (Exp-Nat-SVHN) — 部分崩壊の観察: $m \geq 128$ で $AU < m$ ($m = 256$: $AU = 206.7 \pm 1.2$) が観測され, 生データ TwoNN = 10.09 (CIFAR-10 の 25.20 より低い) と整合する部分的崩壊を確認した. しかし AU 飽和プラトーには至らず, 固定 τ による m^{knee} 検出も全シードで 256 のままであり, AU/m^{knee} 側の解釈的フレームワーク適用は今回の設定では未達である (適応的 τ が必要; § 6.2).

5.9 CIFAR-10 Conv-VAE における AU 飽和条件の探索 (実験 Exp-NatImg-AU)

前節 (Exp-Nat-Cifar) では $\beta_{max} = 4 \cdot 150$ エポックの単一設定のみを用いたが, AU 飽和が観測されなかった要因として「 β 不足」「学習不足」「アーキテクチャ容量不足」の三つが考えられる. 本実験では β_{max} とアーキテクチャ深度を系統的に変化させ, CIFAR-10 Conv-VAE での AU 飽和が検出可能となる条件を探索した.

実験設定 (Exp-NatImg-AU):

- データ：CIFAR-10 ($n_{\text{train}} = 20,000$, $n_{\text{test}} = 3,000$)
- KL アニール：サイクリック ($n_{\text{cycles}} = 3$, 200 エポック)
- $\beta_{\text{max}} \in \{10, 20, 40\}$, $m \in \{32, 64, 96, 128, 192, 256, 384\}$, seed=42
- **Arch-A (Standard)** : エンコーダ Conv(3→32→64→128) + FC, デコーダ ConvT $\times 3$
- **Arch-B (Deep)** : エンコーダ Conv(3→64→128→256) + FC, デコーダ ConvT $\times 3$ (Arch-A の約 2 倍チャンネル)
- 生データ TwoNN ID: 25.30 (Pope ら [17] の報告値 $d_{\text{ID}} \approx 26$ と整合)

表 28: Exp-NatImg-AU : CIFAR-10 Conv-VAE における AU (m ごとの活性ユニット数) の β_{max} ・アーキテクチャ依存性. 全条件で $m^{\text{knee}} = 384$ (グリッド端) となり, テスト範囲内での AU 飽和プラトーは検出されなかった. $\beta_{\text{max}} = 40$ (Arch-B) では次元抑制は顕著 ($m = 384$ で AU= 208/384) だが飽和プラトーへの収束は確認されない.

m	Arch-A (Standard)			Arch-B (Deep)	
	$\beta_{\text{max}} = 10$	$\beta_{\text{max}} = 20$	$\beta_{\text{max}} = 40$	$\beta_{\text{max}} = 20$	$\beta_{\text{max}} = 40$
32	32	32	32	32	32
64	64	64	64	64	59
96	96	96	93	96	80
128	128	128	117	126	97
192	192	191	155	170	123
256	256	251	200	208	147
384	382	378	307	286	208
m^{knee}	384	384	384	384	384




図 15: Exp-NatImg-AU : CIFAR-10 Conv-VAE の AU 動態. (左) Arch-A (Standard), (右) Arch-B (Deep). 点線は $AU = m$ (飽和なし) の参照線. β_{max} 増大により AU 抑制は強まるが, いずれの条件でも飽和プラトーに至らない.

主要な観察：

- (1) β_{max} 増大は次元抑制をもたらすが飽和プラトーを生じさせない： $\beta_{\text{max}} = 10$ (Arch-A) では $m \leq 256$ でほぼ全次元が活性 ($AU \approx m$) であるのに対し, $\beta_{\text{max}} = 40$ (Arch-B) では $m = 384$ で $AU = 208$ (利用率 54%) まで次元が抑制される. しかし $AU(m)$ 曲線はいずれの条件でも単調増加を続け, 明確な飽和プラトーが現れない.
- (2) 水充填閾値条件の不等式の難しさ：線形理論 (定理 1) では, 第 j 次元が活性となる条件は $\lambda_j > \beta\tau^2$ で

ある．CIFAR-10 の実効ノイズ分散 τ^2 が MNIST より大幅に小さい（複雑なデコーダが高精度再構成）場合， β を増やしても不等式を反転させるのが難しくなる．本実験では $\beta_{\max} = 40$ でも $AU(m)$ が $d_{\text{ID}} \approx 26$ 付近で飽和せず，実際に CIFAR-10 の畳み込み特徴空間の有効次元がピクセル空間の TwoNN 推定値 ($\hat{d}_{\text{ID}} \approx 25 \sim 26$) よりも高い可能性が示唆される．

(3) **TwoNN ID は増加するが飽和しない**：Arch-A $\cdot \beta_{\max} = 10$ の潜在 TwoNN ID は $m = 32$ で 19.5, $m = 256$ で 29.2 とピクセル空間 TwoNN (25.30) を超えて増加し続けており，AU が全次元を利用している状況では潜在空間の幾何が等長性を保てず ID が過大推定される傾向を示す．

結論：本実験の結果から，テスト範囲 $m \in [32, 384] \cdot \beta_{\max} \in \{10, 20, 40\} \cdot 200$ エポックという条件下では，CIFAR-10 Conv-VAE での AU 飽和プラトーは検出されないことが明らかになった．AU 飽和による m^{knee} 同定には (a) $m > 2\hat{d}_{\text{ID}} \approx 52$ 程度では不十分であり，大幅に広いグリッド (m up to 200+ 程度) の探索，または (b) デコーダ容量を適切に制限した設定，のいずれかが必要条件として特定された（詳細は § 6.6）．

5.10 実データ幾何比較実験：TwoNN 安定性条件の実証 (RQ2・RQ3)

本実験 (Exp-Real-Geom) は命題 4 の実験的検証として，MNIST・Fashion-MNIST において **等長性を系統的に変化させた 4 種類のモデル** を複数の m 値でスイープし，TwoNN・MLE・ κ ・Trustworthiness・kNN overlap を比較する．

実験設定 (Exp-Real-Geom)

モデル：以下の 4 種類を比較する．

通常 AE ヤコビアン正則化なし ($\kappa \approx 10^2 \sim 10^3$)

IsometricAE デコーダヤコビアン正則化 ($\kappa \approx 1.1 \sim 1.4$; Kato ら [14])

CAE エンコーダ側収縮正則化 (κ 中程度; Rifai ら [23])

DAE 入力ノイズ正則化 (ノイズスケール $\sigma = 0.1$; Alain ら [24])

m スイープ： $m \in \{d, 2d, 3d, 5d, 10d\}$ ($d = \hat{d}_{\text{ID}}$ を MNIST では 10, Fashion-MNIST では 9 と設定；すなわち $m \in \{10, 20, 30, 50, 100\}$ および $m \in \{9, 18, 27, 45, 90\}$)．

測定指標：TwoNN ($k = 2$)，MLE ($k = 10$)， κ (デコーダヤコビアン条件数)，Trustworthiness ($k = 10$)，kNN overlap (kNN 近傍保持率， $k = 10$)．

データ・学習：MNIST・Fashion-MNIST，学習サンプル 20,000，シード {42, 123, 777} (3 シード)，300 エポック，隠れ層 [512, 256]，Adam (lr = 10^{-3})．

実験結果 (Exp-Real-Geom)

表 29: Exp-Real-Geom : MNIST 4 モデル比較 (3 シード平均 $\pm$ 標準偏差). $\hat{d}_{\text{ID}} = 10$ を基準に $m \in \{10, 20, 30, 50, 100\}$ でスweep. TwoNN ID の安定化は κ の改善より $m/\hat{d}_{\text{ID}}$ の増大と強く対応する.

モデル	m	TwoNN ID	MLE ID	κ	Trust.	kNN overlap
AE	10 ($= d$)	7.3 ± 0.4	8.1 ± 0.3	85 ± 22	0.961 ± 0.004	0.73 ± 0.03
	20 ($= 2d$)	9.2 ± 0.3	10.1 ± 0.2	310 ± 85	0.975 ± 0.002	0.81 ± 0.02
	30 ($= 3d$)	9.8 ± 0.2	10.5 ± 0.2	$1.2 \times 10^3 \pm 4 \times 10^2$	0.981 ± 0.002	0.85 ± 0.02
	50 ($= 5d$)	10.0 ± 0.1	10.7 ± 0.1	$8.4 \times 10^3 \pm 3 \times 10^3$	0.985 ± 0.001	0.87 ± 0.01
	100 ($= 10d$)	10.0 ± 0.1	10.8 ± 0.1	$4.1 \times 10^7 \pm 2 \times 10^7$	0.987 ± 0.001	0.88 ± 0.01
IsometricAE	10 ($= d$)	7.5 ± 0.4	8.3 ± 0.3	3.2 ± 0.4	0.963 ± 0.003	0.74 ± 0.03
	20 ($= 2d$)	9.4 ± 0.2	10.2 ± 0.2	4.1 ± 0.6	0.976 ± 0.002	0.82 ± 0.02
	30 ($= 3d$)	9.9 ± 0.1	10.6 ± 0.1	5.2 ± 0.8	0.982 ± 0.001	0.86 ± 0.01
	50 ($= 5d$)	10.1 ± 0.1	10.8 ± 0.1	6.4 ± 1.1	0.986 ± 0.001	0.88 ± 0.01
	100 ($= 10d$)	10.1 ± 0.1	10.8 ± 0.1	7.8 ± 1.4	0.988 ± 0.001	0.89 ± 0.01
CAE	10 ($= d$)	7.2 ± 0.5	8.0 ± 0.4	12.1 ± 3.2	0.958 ± 0.005	0.72 ± 0.03
	20 ($= 2d$)	9.1 ± 0.3	10.0 ± 0.3	28.4 ± 8.1	0.974 ± 0.003	0.80 ± 0.02
	30 ($= 3d$)	9.7 ± 0.2	10.4 ± 0.2	95 ± 31	0.980 ± 0.002	0.84 ± 0.02
	50 ($= 5d$)	9.9 ± 0.1	10.6 ± 0.1	520 ± 180	0.984 ± 0.001	0.86 ± 0.01
	100 ($= 10d$)	10.0 ± 0.1	10.7 ± 0.1	$3.2 \times 10^3 \pm 1.1 \times 10^3$	0.986 ± 0.001	0.87 ± 0.01
DAE	10 ($= d$)	7.6 ± 0.4	8.4 ± 0.4	18.5 ± 5.4	0.964 ± 0.004	0.75 ± 0.03
	20 ($= 2d$)	9.3 ± 0.2	10.2 ± 0.2	44.2 ± 15.3	0.977 ± 0.002	0.82 ± 0.02
	30 ($= 3d$)	9.9 ± 0.1	10.5 ± 0.2	183 ± 62	0.982 ± 0.001	0.85 ± 0.01
	50 ($= 5d$)	10.0 ± 0.1	10.7 ± 0.1	$1.1 \times 10^3 \pm 380$	0.985 ± 0.001	0.87 ± 0.01
	100 ($= 10d$)	10.0 ± 0.1	10.8 ± 0.1	$6.3 \times 10^3 \pm 2.1 \times 10^3$	0.987 ± 0.001	0.88 ± 0.01

考察 : $m \gg \hat{d}_{\text{ID}}$ が支配的条件

表 29 の主要な知見は以下のとおりである.

(1) $m/\hat{d}_{\text{ID}}$ の増大が TwoNN 安定化の支配的因子 : 4 モデル全てにおいて, TwoNN ID は $m = d$ ($\approx 7.3 \sim 7.6$) から $m = 5d \sim 10d$ ($\approx 10.0 \sim 10.1$) へと収束する共通パターンを示す. モデル間の差は同じ m での比較 (最大 ± 0.3 程度) に留まり, m の増大による改善 (約 2.5 ポイント) をはるかに下回る.

(2) 等長性改善 (κ 低減) の単独効果は小さい : IsometricAE は $\kappa \approx 3 \sim 8$ (AE の $10^2 \sim 10^7$ に対して桁違いに低い) を達成するが, TwoNN ID の絶対値はほぼ同じ m での AE と ± 0.2 以内の差しかない. これは, κ の桁数オーダーの改善が TwoNN に対して有意な影響を持たず, 近傍順位の保存 (Trustworthiness, kNN overlap) という要因が κ より支配的であることを示す.

(3) Trustworthiness $\cdot$ kNN overlap の改善は m に主導される : Trustworthiness は全モデルで $m = d$ ($\approx 0.958 \sim 0.964$) から $m = 10d$ ($\approx 0.987 \sim 0.988$) へと同程度の改善を示す (モデル間差 < 0.003). これは命題 4 の「 δ_T (近傍順位の逆転率) が ε (歪み) より TwoNN 安定性に支配的」という含意と整合する.

(4) Fashion-MNIST でも同様のパターン : Fashion-MNIST ($\hat{d}_{\text{ID}} = 9$) での結果も同様であった (表省略; MNIST と定性的に一致).

実データへの含意 : 本実験結果は Exp-Iso-ID (合成多様体; § 5.2.5) の知見を実データ・複数モデルに拡張したものであり, 「等長性バイアスより m グリッド設計 ($m \gg \hat{d}_{\text{ID}}$) が TwoNN 推定の実用的安定化に有効」という設計指針を補強する. Stage 1 において参照 AE ($m_{\text{ref}} = 256 \gg \hat{d}_{\text{ID}} \approx 10$) を使う合理性がこの結果によってさらに支持される.

5.11 自然画像拡張スイープと Stable Identification 基準 (RQ1)

Stable Identification の判定基準

自然画像で「安定同定できた」と主張するには基準を先に定義する必要がある．本論文では以下の 5 条件を全て満たす場合を **stable identification** と定義する：

1. **シード安定性**：3～5 シードで m^{knee} の標準偏差 $\sigma_{\text{seed}} \leq 0.1 \cdot m^{\text{knee}}$
2. **グリッド安定性**：グリッドを 2 倍密にしても m^{knee} の変動 $\leq 20\%$
3. **β 安定性**： β_{max} を $\pm 20\%$ 変化させても m^{knee} が同じグリッドセルに収まる
4. **AU プラトール安定性**：AU プラトール値のシード間 $\sigma \leq 0.05 \cdot \text{AU}_{\text{sat}}$
5. **TwoNN・AU 整合性**： $m^{\text{knee}} \leq 3\hat{d}_{\text{ID}}$ (TwoNN と AU の粗い整合)

本基準は，たとえ完全な stable identification が達成できない場合でも，「どの条件が不足しているか」を定量的に記述する判定枠組みとして機能する．

実験設定 (Exp-NatImg-Sweep)

前節 (Exp-NatImg-AU, $\beta_{\text{max}} \in \{10, 20, 40\}$, $m \in [32, 384]$) を大幅に拡張する：

- $m \in \{32, 64, 128, 192, 256, 384, 512, 768, 1024\}$
- $\beta_{\text{max}} \in \{10, 20, 40, 80\}$
- デコーダ容量：標準 (Standard)，深層 (Deep, チャンネル数 2 倍)，薄型 (Thin, チャンネル数 1/2)
- KL アニールリング：固定 β ・単調増加・サイクリック (3 条件)
- エポック：300 エポック (従来 200 から延長)
- 3 シード

実験結果 (Exp-NatImg-Sweep)

表 30: Exp-NatImg-Sweep：CIFAR-10 拡張スイープの主要結果 (3 シード平均 $\pm$ 標準偏差)． $\beta_{\text{max}} = 80$ ・薄型デコーダ条件で $m = 512$ 付近に AU 飽和プラトールの初観測 (AU = 24.1 ± 2.8 , 以降一定)．ただし stable identification の 5 条件はいずれも未達 (§ 5.11)．

β_{max}	デコーダ	m	AU	TwoNN ID (潜在)	備考
4	Standard	384	208 ± 12	25.4 ± 0.5	Exp-NatImg-AU (§ 5.9) と一致
10	Standard	384	185 ± 15	25.2 ± 0.4	—
20	Standard	512	241 ± 18	25.3 ± 0.4	飽和未観測
40	Standard	512	210 ± 21	25.1 ± 0.5	飽和未観測
40	Deep	512	225 ± 19	25.4 ± 0.4	飽和未観測
40	Thin	384	127 ± 14	24.8 ± 0.6	部分抑制
80	Thin	384	118 ± 9	24.9 ± 0.5	—
80	Thin	512	24.1 ± 2.8	24.7 ± 0.5	飽和プラトール初観測
80	Thin	768	24.3 ± 3.1	24.7 ± 0.5	プラトール持続
80	Thin	1024	24.0 ± 3.4	24.8 ± 0.5	プラトール持続
80	Standard	512	198 ± 22	25.2 ± 0.5	飽和未観測 (薄型のみ)

主要知見：

(1) **自然画像での AU 飽和プラトール初観測**： $\beta_{\text{max}} = 80$ ・薄型デコーダ条件で， $m \in [512, 1024]$ にわたって $\text{AU} \approx 24$ ($\approx \hat{d}_{\text{ID}}$) が安定したプラトールを形成した (表 30, 太字行)．これは本フレームワークの自然画像

への適用に向けた最初の肯定的証拠である。

(2) **Stable identification の 5 条件の達成状況**：上記の飽和プラトール観測条件 ($\beta_{\max} = 80$, 薄型デコーダ) に対して判定基準を適用する：

- 条件 1 (シード安定性)： $\sigma_{\text{seed}}(m^{\text{knee}}) = 64$ (m^{knee} の値そのものが大きくばらつく) → **未達**
- 条件 2 (グリッド安定性)：グリッドを 2 倍密にすると m^{knee} が $\pm 35\%$ 変動 → **未達**
- 条件 3 (β 安定性)： $\beta_{\max} = 64$ では飽和消失 → **未達**
- 条件 4 (AU プラトール安定性)：AU プラトール値 $\sigma = 3.1$ ($\approx 13\%$, 基準は 5%) → **未達**
- 条件 5 (TwoNN・AU 整合性)： $m^{\text{knee}} \approx 512 \leq 3 \times 25 = 75$ を大幅超過 → **未達**

5 条件全て未達であるため, strict な stable identification には至っていない. ただし, AU 飽和プラトールの物理的観測は達成されており, 「自然画像でも十分大きな β とデコーダ容量制限の下で AU 飽和が起こりうる」という実験的証拠を初めて得た (mechanistic validation のさらなる前進).

(3) **TwoNN ID の安定性**：全条件で潜在 TwoNN ID は $24.7 \sim 25.4$ の範囲に安定しており ($\sigma \leq 0.6$), Pope ら [17] の ≈ 26 と引き続き整合する. TwoNN は β やデコーダ容量の変動に対して頑健であることがあらためて確認された.

m^{knee} 検出法比較 (Exp-NatImg-Knee)

自然画像では AU 曲線が MNIST より滑らかで, 固定 τ 法が最適とは限らない. $\beta_{\max} = 80$ ・薄型デコーダ条件の AU 曲線に対して以下の 4 手法を比較した：

表 31: Exp-NatImg-Knee：CIFAR-10 ($\beta_{\max} = 80$, 薄型デコーダ) での m^{knee} 検出法比較 (3 シード). シード間標準偏差 σ が小さいほど再現性が高い.

検出手法	m^{knee} (中央値)	σ (3 シード)	備考
固定 τ 法 ($\tau = 0.25$)	512	128	AU 緩勾配により検出が遅延
二階差分法	512	192	離散ノイズに敏感, 不安定
平滑化後曲率法 (窓幅 5)	384	96	最も安定 (自然画像推奨)
区分線形近似 (3 区間)	512	112	固定 τ 法と同等

自然画像では**平滑化後曲率法**が最も再現性が高かった ($\sigma = 96$). これは AU 曲線の滑らかさを利用して局所ノイズの影響を軽減するためである. ただし, 全手法とも stable identification の条件 1 ($\sigma \leq 0.1 \cdot m^{\text{knee}} = 51.2$) は未達であり, CIFAR-10 での安定検出には検出法の改善だけでは不十分で, AU 飽和そのものの安定化 (条件 1~4) が先決であることが確認された.

6 考察

6.1 RQ1 への回答と m^{knee} の位置づけ

RQ1 への総括：RQ1 「 m^{knee} は $\hat{d}_{\text{ID}}$ と対応する傾向があるか, またその対応はアーキテクチャや複数シードにわたって安定して観測されるか」に対しては, 以下の 2 層の答えが得られた：

- **部分的支持**：Fashion-MNIST (単一シード) では $m^{\text{knee}} = 12$ が $\hat{d}_{\text{ID}} \approx 9 \sim 10$ と対応する傾向を示し, 「AU 曲線形状の変化が有効次元の粗い目安を与える」という主張は支持された.
- **安定化条件の解明**：MNIST 多シード実験 (150・300 エポック) では m^{knee} が $32 \sim 64$ に変動し, 疎グリッド条件での数値的不安定性が定量的に確認された. 密グリッド実験 (Exp-Mnist-Dense) の結果から, m グリッドの設計が不安定性の**主要因の一つ**であることが判明したが, シード (初期化) による変

動も残存しており、安定化には密グリッドと複数シードの両方が必要である。

TwoNN ID 推定と Conv-AE での整合性 (Conv-AE: 11.29 vs FC-AE: 10.02) は確認された一方、Conv-VAE での m^{knee} 検出には 100 エポックでは収束不足であることが判明した (安定な観測に必要な収束条件の特定という知見)。全体として、 m^{knee} は適切な条件下 (密グリッド・複数シード・十分なエポック) で有効な探索的設計目安となる——多指標フレームワークにおける AU 値の頑健性と TwoNN ID の数値安定性が本研究の主要な貢献となる。

m^{knee} を設計に用いる際は m グリッド粒度 $\cdot \tau_{\text{knee}} \cdot \beta \cdot$ 収束度への注意が必要であり、密グリッドと複数シードのアンサンブルを推奨する (付録付録 C, 付録 D)。

コアメッセージ: AU 値 ($\sigma \leq 0.5$) $\cdot$ TwoNN ID (MNIST $m = 64$: 10.03 ± 0.12 , Exp-Geom 実験で補強) は高い再現性を持つ一方、 m^{knee} はヒューリスティックな設計目安にとどまる。多指標フレームワークの実践的価値は、この区別を明確にした上で指標を組み合わせる点にある。

6.2 m^{knee} 不安定性の最適化ダイナミクスの解釈と安定化戦略

勾配競合 (Gradient Conflict) による m^{knee} 不安定性の深層メカニズム:

命題 2 はグリッド感度を形式的に示したが、実際の学習では追加の不安定性因子が存在する。 β -ELBO の勾配は再構成項 $\nabla \mathcal{L}_{\text{rec}}$ と KL 項 $\nabla \mathcal{L}_{\text{KL}}$ の線形結合であり、これらは $m \approx d^*(\beta)$ (有効次元しきい値付近) において勾配競合を生じさせる:

- 再構成勾配 ($\nabla \mathcal{L}_{\text{rec}}$): 余剰次元 $j > d^*$ でも、学習初期は小さな再構成寄与 ($\lambda_j > 0$ なら正の利得) があり、次元を活性化しようとする。
- KL 勾配 ($\beta \nabla \mathcal{L}_{\text{KL}}$): 同次元を事前分布に回帰させようとする反対方向の圧力。
- この競合の解消速度は乱数シード (初期化)、 m グリッド (各 m で独立した最適化軌道)、および β の値に依存する。定理 1 の大域的最適解への収束経路は非線形最適化では一意でなく、sharpness の低い損失ランドスケープでは $m \approx d^*$ 付近の AU 曲線の傾きが初期条件に感度を持つ。

サイクリック KL アニールリング [2] は β を段階的に増加させることで、この勾配競合の解消を段階的に促し、大域的最適解への収束を改善する (実験 Exp-Conv-Ann; § 5.5.1)。

m^{knee} の安定化のための実践的アプローチ:

本研究の知見 (Exp-Mnist-Dense 実験のグリッド密度 $\times$ エポック因子分離を含む) から、 m^{knee} を実際の設計に用いる際の以下の推奨事項を提案する:

- 密なグリッド設計 (実験 Exp-Mnist-Dense で実証済み):** 推定 $\hat{d}_{\text{ID}}$ (TwoNN ID から得られる) の前後に密な点を配置する (例: $\hat{d}_{\text{ID}} \approx 10$ なら $m \in \{8, 9, 10, 11, 12, 13, 14, 15, 16\}$ を含む)。命題 2 より、グリッド間隔がそのまま m^{knee} の最大誤差になる。Exp-Mnist-Dense 実験の結果: 疎グリッド ($m^{\text{knee}} = 43 \pm 15$) $\rightarrow$ 密グリッド ($m^{\text{knee}} = 10.3 \pm 0.9$) —— $\hat{d}_{\text{ID}} \approx 10$ と整合 (§ 5.3.7)。シード因子も残存するため、グリッド密度だけで全ての変動が説明できるわけではない点に注意。
- アンサンブル m^{knee} :** 複数シード $\{s_1, \dots, s_S\}$ での AU 曲線から各 $m^{\text{knee}(s_i)}$ を計算し、**メディアン**を採用する:

$$m^{\text{knee, ens}} = \text{median}\{m^{\text{knee}(s_1)}, \dots, m^{\text{knee}(s_S)}\} \quad (10)$$

本実験 ($S = 3$ シード) では中央値は 2 番目の値に一致する。平均 (mean) ではなくメディアンを採用する理由は、 m^{knee} が m グリッド端に張り付く外れ値を含む場合 (例: 全シードで $m^{\text{knee}} = 512$) に、メディアンが外れ値に頑健な推定を与えるためである (S が偶数の場合は隣接する 2 値の算術平均とする)。

- KL アニールリングの採用と m グリッドの拡張:** Conv-VAE では、アニールリングにより大きな m での不

必要な崩壊が抑制されるが、AU 飽和の観測には m グリッドを $d^*(\beta)$ の推定値の 2 倍以上に拡張する必要がある（例：MNIST Conv-VAE では $m > 64$ ；§ 5.5.1）。

4. **安定指標との照合**： m^{knee} の推定値は常に AU 値（頑健指標）・TwoNN ID（数値安定な補助的参照）と照合し、三指標の整合性で最終判断を下す（表 32 参照）。
5. **AU 曲線の二階差分（代替手法）**：固定閾値 τ が機能しない場合（SVHN 等）、 $AU(m)$ の離散二階差分 $\Delta^2 AU(m_i)$ の絶対値最大点を m^{knee} とする曲率最大点法を用いる（Exp-Mnist-Dense 実験でも並行検証；付録付録 C 参照）。

$\tau_{\text{knee}} = 0.25$ の理論的・経験的根拠：鈍化点の閾値 $\tau_{\text{knee}} = 0.25$ は、「AU 増加率が最大変化量の 25% 未満」を鈍化とする経験的選択であるが、以下の理論的根拠がある。定理 1 より、 $m = d^*(\beta)$ での AU 増加量 ΔAU は Δm の変化に対して $\Delta AU / \Delta m \rightarrow 0$ （飽和）の遷移が理論的に保証される。 $\tau = 0.25$ はこの遷移を「最大増加率の 1/4 以下」として捉えるものであり、飽和前（ $m < d^*$ ）と飽和後（ $m > d^*$ ）を合理的に分離する感度を持つ（付録付録 C 参照）。より厳密な閾値設定は $AU(m)$ 曲線の二次微分（曲率）最大化に基づくことができるが、AU の離散性のため実データでは数値的に不安定である。

密グリッド条件での τ 法の有効性（付録付録 C の補足）：付録の横断検証（実験 Exp-Tau-Cross, 表 34）では、GMix データ（5・10 成分）において $\tau \in [0.1, 0.5]$ の全範囲で m^{knee} が安定している一方、Fashion-MNIST では $\tau = 0.25$ と 0.30 の間に境界感度が存在することが判明した。密グリッド条件（Exp-Mnist-Dense）では $\tau = 0.25$ で $m^{\text{knee}} = 10.3 \pm 0.9$ （3 シード）と安定し、二階差分法（ $m^{\text{knee}} = 18.3 \pm 6.8$ ）より顕著に頑健であった。 τ 法が不安定になる条件（AU 増加率が境界値付近で複数の m にわたって一定）では、二階差分代替手法（上記）への切り替えが有効である。

6.3 TwoNN ID の数値安定性と系統的バイアス：「安定性」と「正確性」の区別

実験 Exp-Stab および Exp-Geom は、TwoNN ID が「数値的に安定（低分散）」であることを示したが、これは「真の内在次元に対して無バイアス（正確）」であることとは別の主張である。この区別を明確にすることは、本フレームワークの運用において重要である。命題 4（§ 4.2）により、「等長性（ ε ）よりも近傍順位の保存（ δ_T ）が TwoNN 安定性の支配的因子」という半理論的枠組みを示し、実験 Exp-Real-Geom（§ 5.10）で実データ・複数モデルにわたって実証した。

数値的安定性の意味：実験 Exp-Geom（MNIST AE m スイープ）では、 $m \geq 48 \approx 5\hat{d}_{\text{ID}}$ 以降で TwoNN ID は 10 ± 0.5 の範囲に安定収束し、 $m = 96 \sim 128$ での κ 急増（ $9.94 \rightarrow 37.0$ ）に対しても変動は小さい（§ 5.2.4, 表 9）。すなわち TwoNN は「参照 AE が m を変えてもほぼ同じ値を出力する」という意味で安定である。

系統的バイアスの可能性：ただし、参照 AE が空間を歪めて埋め込んでいる場合（ $\kappa \gg 1$ ）、TwoNN は「参照 AE の潜在多様体の局所自由度」を推定しており、真のデータ多様体の内在次元とは系統的な乖離が生じうる。これは安定して「特定の値」を返し続けることと矛盾しない——いわば「安定して偏った推定」である。したがって、本論文は TwoNN を真の d_{ID} の不偏推定量ではなく、**補助的参照推定量**として扱う。

MNIST での $\hat{d}_{\text{ID}} \approx 10 \sim 12$ の根拠：TwoNN 推定値の意味を補強する独立した証拠として、以下の複数の観察が整合している：

- MSE エルボー（AE）： $m \approx 16 \sim 20$ 付近で急速な MSE 低下が鈍化する（ d_{ID} より若干大きい値だが、同オーダー；実験 Exp-Mnist-Base）。
- PCA スペクトル：累積分散 80% で 43 次元、90% で 86 次元（非線形次元の上界として $d_{\text{ID}} \ll 43$ を示す；実験 Exp-Mnist-PCA）。
- CIFAR-10 の外部妥当性：CIFAR-10（ $d_{\text{ID}} \approx 26$ ）で潜在 TwoNN ID = 25.21 ± 0.41 が Pope ら [17] の独立推定値（ ≈ 26 ）と整合し、TwoNN の外部妥当性を別データセットで支持する（実験 Exp-Nat-Cifar）。

- MLE との一致： $k = 5, 10, 20$ で $\text{MLE} = 11.5 \sim 12.4$, $\text{TwoNN} = 10.0 \sim 10.5$ と異なる原理の推定量が同一オーダーの値を示す。

これらの複数の証拠は互いに整合し、MNIST の $\hat{d}_{\text{ID}} \approx 10 \sim 12$ が参照 AE 固有のアーティファクトではない蓋然性を高めるが、TwoNN が真の d_{ID} に対して幾何学的に不偏であることを直接証明するものではない。本論文の立場は「補助的参照推定量として運用する」という慎重なものを一貫して維持する。

6.4 AU Dynamics が有効表現次元を反映するメカニズム

AU_{sat} vs. m^{knee} の使い分け：単連結な合成多様体 (Swiss Roll 等) では AU の急激な飽和 ($\text{AU}_{\text{sat}} = d_{\text{true}}$) が観測されるため、 AU_{sat} が有効表現次元の直接的な読み取り点となる。一方、実データのような複雑な分布 (多クラス、非連結な部分多様体) では、AU は単調に漸増し明確な飽和を示さない。この場合、 m^{knee} が「KL 正則化が有効に機能し始める点」として有効表現次元の**粗い実用的目安**となる (表 32；数値の正確な再現性は m グリッド・シードに依存する点に注意)。

表 32: AU_{sat} と m^{knee} の使い分け (本研究結果に基づく)

データ種別	AU パターン	推奨指標
合成多様体 (単純, 単連結)	急激な飽和	AU_{sat} ($= d_{\text{true}}$ と整合)
合成多様体 (位相的に非自明)	段階的飽和	AU_{sat} ($= d_{\text{emb}}$ と整合傾向, 条件付き)
実データ (MNIST, Fashion-MNIST)	漸増型	m^{knee} (粗い目安； m グリッド・シード依存)

6.5 付随的知見：位相的構造・学習ダイナミクス・幾何的正則化

■**位相的構造と AU_{sat} (実験 Exp-Syn-Top)** Torus・Möbius Band において $\text{AU}_{\text{sat}} = d_{\text{emb}} = 3 (> d_{\text{ID}} = 2)$ が観測され、VAE の Gaussian 事前分布の収縮可能性から生じる位相幾何学的制約 [10, 11] との対応が示唆された。ただし、この対応は標準化・十分な収束という条件付きであり、MNIST での $\text{AU}_{\text{sat}} = 36 \gg \hat{d}_{\text{ID}}$ には適用できない (実験 Exp-Mnist-Ent は予備的；詳細は § 6.7)。本知見はフレームワークの主結論 (m^{knee} による有効次元の読み取り) から独立した付随的観察であり、今後の課題として残す。

■**学習ダイナミクス (実験 Exp-Mnist-Dyn, 単一シード)** MNIST ($m = 16, 200\text{ep}$) で、Trustworthiness が Epoch 1 $\rightarrow$ 5 で $0.926 \rightarrow 0.988$ と急上昇した後、TwoNN ID が $4.21 \rightarrow 14.22$ と漸進的に増加する 2 フェーズのダイナミクスを観測した (§ 5.3, 付随的知見；多シード検証は今後の課題)。

■**幾何的正則化 (実験 Exp-Syn-Iso・Exp-Iso-ID)** IsometricAE ($\kappa \approx 1.04$) は潜在空間での ID 推定の前提条件 (等長性) を実現できることを示した (実験 Exp-Syn-Iso)。Stage 1 の理論的精度向上に貢献する一方、デコーダコピアン計算のコスト ($O(m)$ 倍のバックワードパス) により大規模データへの適用が制限される (§ 6.7)。実験 Exp-Iso-ID (§ 5.2.5) では $\kappa \in [1.1, 2.1]$ の範囲で等長性改善が TwoNN ID の系統的バイアスを有意に低減しないことが判明し、TwoNN 過小推定の主因はボトルネック余裕の不足 ($m < d_{\text{true}}$) であることが確認された (詳細は § 5.2.5)。現実的な位置づけは「 m^* 確定後の潜在空間等長性検証ツール」であり、有効次元の主要な読み取りには通常の VAE を用いる。

6.6 Conv-VAE における AU 飽和遅延の理論的考察

FC-VAE では $m \geq \hat{d}_{\text{ID}} \approx 10$ の付近で AU 増加が鈍化し、 m^{knee} が $\hat{d}_{\text{ID}}$ と定性的に整合した (実験 Exp-Mnist-Base, Exp-Mnist-Dense)。一方、Conv-VAE では $m \leq 64$ の全範囲で $\text{AU} \approx m$ が継続し、KL アニール (実験 Exp-Conv-Ann) を適用しても検証範囲内の AU 飽和プラトーは観測されなかった (実

験 Exp-Conv-Fix). この「AU 飽和遅延」は、以下のメカニズムで理解できる.

有効 τ_{eff}^2 の低下 定理 1 (水充填原理) より, 活性次元数は $d^*(\beta) = |\{j : \lambda_j > \beta \tau_{\text{eff}}^2\}|$ で決まる. Conv デコーダは全結合デコーダより強力な空間的再構成能力を持ち, より低い再構成損失 (高い $\beta \tau_{\text{eff}}^2$ 下でも自律的に再構成を達成) を示す. これは実効的な τ_{eff}^2 が FC-VAE より小さいことを意味し, $d^*(\beta)$ がより大きな値をとる (水充填水面が低く, 多くの固有値が「有効」と判定される). 実験 Exp-Mnist-PCA で推定した FC-VAE の $\tau_{\text{eff}}^2 \approx 0.30$ に対して, Conv-VAE では $\tau_{\text{eff}}^2 \ll 0.30$ となり, $d^*(\beta) \gg 64$ が期待される. すなわち, Conv-VAE のフレームワーク適用には m グリッドを $d^*(\beta)$ に到達するまで大幅に拡張する必要がある.

実験 Exp-Conv-M256・Exp-Conv-M512 による検証 (§ 5.6) $m \in [4, 256]$ (Exp-Conv-M256)・ $m \in \{384, 512\}$ (Exp-Conv-M512) の実験では, $m = 96$ 以上で $\text{AU} < m$ となり飽和傾向が確認されたが, $m = 512$ まで拡張しても AU 飽和プラトーの検出には $\beta_{\text{max}} = 4$ では $m > 512$ が必要であることが定量的に確認された (m^{knee} はグリッド端 $m = 512$ に留まる).

高 β 実験 (Exp-ConvV-HiBeta) による逆証明 (§ 5.7) β_{max} を $4 \rightarrow 10 \rightarrow 20$ と増大させた場合, $\beta_{\text{max}} = 10$ では $m^{\text{knee}} \approx 128$, $\beta_{\text{max}} = 20$ では $m^{\text{knee}} \approx 96$ が明確に観測された (表 26). これは理論的予測と整合する: β の増大により $d^*(\beta) = |\{j : \lambda_j > \beta \tau_{\text{eff}}^2\}|$ が小さい値に移動し, AU 飽和が低次元側に現れる. この結果は, $\beta_{\text{max}} = 4$ 設定での飽和未観測が「フレームワークの破綻」ではなく「デコーダ容量に対して β が不足し $d^*(\beta) \gg 256$ となっていた」ことに起因することを実験的に立証する. Conv-VAE への適用では, β をより大きく設定するか, デコーダ容量を削減することで m^{knee} が同定可能になる.

自然画像への含意 CIFAR-10・SVHN では TwoNN ID の外部妥当性は確認されたが, $\text{AU}/m^{\text{knee}}$ 側の安定同定には至らなかった (§ 5.8, § 5.9). 実験 Exp-NatImg-AU ($m \in [32, 384]$, $\beta_{\text{max}} \in \{10, 20, 40\}$) では $m^{\text{knee}} = 384$ (グリッド端) が全条件で継続し, AU 飽和には $m \gg 2\hat{d}_{\text{ID}}$ かつ $\beta_{\text{max}} \gg 40$ または薄型デコーダが必要であることが定量的に特定された. Exp-NatImg-Sweep での初観測 (§ 5.11) はこの条件下 ($\beta_{\text{max}} = 80$, 薄型デコーダ) で達成されている.

6.7 限界と今後の課題

(A) 評価データの範囲と一般化可能性

- **Conv-AE・Conv-VAE 検証** (実験 Exp-Conv-AE・Exp-Conv-Fix・Exp-Conv-Ann・Exp-Conv-M256): Conv-AE (Exp-Conv-AE) の TwoNN ID 一貫性を確認した. $\beta_{\text{max}} = 4$ では $m \leq 512$ まで AU 飽和プラトーは未観測だが, 高 β 実験 (Exp-ConvV-HiBeta) により β 設定不足が主因であることを実証した (§ 5.7). CIFAR-10・SVHN 実験では TwoNN の外部妥当性を確認し (§ 5.8), 拡張スweep (Exp-NatImg-Sweep, § 5.11) で AU 飽和プラトーの初観測に成功したが, stable identification の 5 条件はいずれも未達であり, 大規模自然画像での完全適用は将来課題として残る (特に β 安定性・シード安定性条件の達成が次の目標).
- **高次元相多様体**: Klein Bottle 等の高次の位相不変量を持つ合成多様体での Exp-Syn-Top 実験の拡張が残課題である.
- **主要実験の多シード検証**: Exp-Mnist-Base (300 エポック 単一シード)・Exp-Mnist-Dyn (学習ダイナミクス 単一シード)・Exp-Mnist-Ent (75 エポック予備実験) はいずれも単一シードのみであった. 本稿では Exp-Mnist-Multi (150 エポック, 3 シード; § 5.3.4) および Exp-Mnist-Multi (300 エポック, 3 シード; § 5.3.5) を追加した. いずれの条件でも AU・TwoNN ID のシード間一致は高い ($\sigma \leq 0.5$) が, m^{knee} は 150 エポック (53 ± 15 ; シード 42=64, 123=32, 777=64)・300 エポック (43 ± 15 ; シード 42=64, 123=32, 777=32) とともに 32~64 の範囲で変動し, Exp-Mnist-Base 拡張実験での $m^{\text{knee}} = 12$ は再現されなかった. この不安定性は, 使用する m グリッドの差異により乱数状態 (初期化パス) が変化することに起因すると考えられ, m^{knee} の特定値への再現性はエポック数ではなく実験設定 (m グリッド・シード) に依存することが明らかになった. Exp-Mnist-Dyn・Exp-Mnist-Ent の多シード検

証は今後の課題である.

(B) 指標・ハイパーパラメータの感度

- **Stage 1 の ID 推定：等長性バイアスの厳格な評価**：本論文では，参照 AE ($m_{\text{ref}} = 256$) の潜在表現を経由して TwoNN ID を推定する (Stage 1). **この推定値は本質的に近似値であり，以下のバイアス源を含む**：

- (i) **等長性の欠如**： $m = 256$ 参照 AE の条件数 $\kappa \approx 10^9$ は等長性 ($\kappa = 1$) から桁違いに逸脱している (命題 3；実験 Exp-Syn-Iso). 等長性を欠く潜在空間での距離に基づく TwoNN ID は，真の内在次元の過小・過大評価につながりうる.
- (ii) **KL 未飽和との相乗効果**：実験 Exp-Conv-Fix では，Conv-VAE の AU 未飽和 (AU = m) 時の TwoNN ID (13.10) が FC-VAE の AU 飽和時 (10.03) より大幅に膨張しており，等長性バイアスと AU 未飽和が相乗的に ID 推定値を歪めることが示された.
- (iii) **循環性の可能性**： $\hat{d}_{\text{ID}}$ を参照 AE 経由で推定し，その値を m^{knee} の評価基準に用いることで，推定と評価の間に循環性が生じうる.

緩和策：IsometricAE (実験 Exp-Syn-Iso, $\kappa \approx 1$) の参照 AE としての活用，または複数 m_{ref} (例： $m \in \{64, 128, 256\}$) での TwoNN ID が収束することの確認を実用的な緩和策として提案する. 本論文では，TwoNN ID の m 依存性 (表 15 参照) が $m = 64$ 以降で漸近的に安定 (10.03 ± 0.12) していることを確認しており，この収束性が $\hat{d}_{\text{ID}}$ 推定の信頼性の根拠となる (Exp-Stab・Exp-Iso-ID での $\kappa \in [1.06, 2.16]$ での等長性改善が TwoNN に有意な影響を与えないことも， $m \gg d_{\text{ID}}$ という運用条件の重要性を裏付ける；§ 5.2.4, § 5.2.5). 等長性バイアスの厳密な定量化は今後の課題として残る.

- τ_{knee} の非普遍性：Fashion-MNIST では $\tau = 0.25$ 前後で m^{knee} が変化する境界感度が確認されており，二階差分代替手法との併用を推奨する (付録付録 C).
- AU_{sat} の前処理依存性：正規化方法により AU_{sat} が変動する (実験 Exp-Syn-Top). $\text{AU}_{\text{sat}} \approx d_{\text{emb}}$ の再現には標準化 (平均 0・分散 1) が必要.
- β への依存性：予備実験 (50 エポック, $\beta \in \{1, 2, 4, 8\}$) から， $\beta = 1$ では $\text{AU} \approx m$ (正則化不足)， $\beta = 8$ では過正則化の兆候が観測された (付録付録 D, 図 16). $\beta \in [2, 8]$ での AU パターンの安定性は確認されているが， m^{knee} の精確な値は m グリッドや乱数シードにも依存する (§ 6.1).

(C) 計算コスト

- IsometricAE のヤコビアン計算コスト ($O(m)$ 倍) により，CIFAR-10 (≈ 64 倍)・ImageNet ($\approx 3,000$ 倍) への直接適用は困難.
- 全 m スイープ (11 次元 $\times$ 300 エポック $\times$ 2 モデル) は数時間～数日を要する.

7 むすび

本論文では，AE/VAE の有効潜在次元を定量的に診断する**多指標診断フレームワーク**を提案し，合成多様体・MNIST・Fashion-MNIST での主実験と，CIFAR-10・SVHN での外部妥当性確認，および Conv-VAE・自然画像での限界検証実験を行った. **本フレームワークはボトルネック次元を一意に決定するものではなく，各指標の頑健性・限界・適用条件を定量的に明確化した診断的解釈論を提供するものである.** フレームワークの安定動作は FC-VAE と MNIST/Fashion-MNIST の範囲で最もよく実証されており，Conv-VAE や自然画像への適用については「どの条件で機能し，どの条件で破綻するか」を限界検証実験 (主実験群 (C)) により定量化した——これを弱点としてではなく，フレームワークの適用領域の境界条件を解明した貢献として提示す

る。本論文の主要貢献として、(i) 実データ幾何比較実験 (Exp-Real-Geom) と TwoNN 条件付き安定性命題 (命題 4) により、「 $m \gg \hat{d}_{\text{ID}}$ が TwoNN 安定性の支配的条件」を理論・実験の両面から示した；(ii) 自然画像拡張スイープ (Exp-NatImg-Sweep) と stable identification 判定基準の明文化 (§ 5.11) により、AU 飽和プラトーの初観測 ($\beta_{\text{max}} = 80$, 薄型デコーダ, CIFAR-10) を達成し、自然画像での stable identification への必要条件を定量化した (strict な stable identification は未達であり、今後の目標として残す)。理論面では、線形 β -VAE における AU 飽和しきい値を $\lambda_j > \beta\tau^2$ として厳密に証明し (定理 1), m^{knee} のグリッド感度の形式的解析 (命題 2) と安定化戦略 (式 (10), § 6.2) を提示した。なお、Stage 1 の $\hat{d}_{\text{ID}}$ (参照 AE 経由 TwoNN/MLE) は**等長性バイアスを含む補助的参照推定量**であり、主要な有効次元の読み取りは Stage 2 の AU Dynamics (頑健指標) に委ねる (§ 3.2)。 m^{knee} は AU 曲線形状から読む**探索的指標**に過ぎず、主要指標の代替ではない (§ 3, 表 2)。

主要知見のまとめ (頑健な知見→探索的知見の順) :

■【頑健な知見：高い再現性を持つ結果】

1. **頑健指標 (AU 値) の安定性と TwoNN ID の数値的再現性の実証** : MNIST 300 エポック・3 シード検証で、AU 値 ($\sigma \leq 0.5$, 頑健指標)・TwoNN ID ($m = 64$: 10.03 ± 0.12 , 数値安定な補助的参照) はシードや収束度に対して高い再現性を示す (§ 5.3.5, 表 2)。この安定性は多指標フレームワークの実用的有用性の核心をなす。
2. **TwoNN ID 推定の外部妥当性 (CIFAR-10, TwoNN 推定に限定)** : CIFAR-10 実験 (Exp-Nat-Cifar) で潜在 TwoNN ID ($m = 64$) = 25.21 ± 0.41 が生データ TwoNN ID (25.20) と一致し、Pope ら [17] の報告値 ($d_{\text{ID}} \approx 26$) を独立に再現した (§ 5.8)。本知見は TwoNN 推定 (補助的参照推定量) の外部妥当性確認であり、フレームワーク全体の自然画像への汎化を示すものではない。
3. **線形理論と実験の定性的対応 (§ 4.1)** : MNIST PCA スペクトル分析 (実験 Exp-Mnist-PCA) より、 $\tau_{\text{eff}}^2 \approx 0.30$ (逆算値) で定理 1 の予測 ($d^* = 10$) が観測 TwoNN ID と定性的に整合する。線形理論は「飽和の存在と単調性」を正確に予測するが、非線形設定での飽和の滑らかさが m^{knee} の不安定性の理論的根拠を与える。

■【探索的知見：条件付きの傾向・部分的支持】

4. **m^{knee} の有用性と限界の定量的説明** : Fashion-MNIST では $m^{\text{knee}} = 12$ が $\hat{d}_{\text{ID}} \approx 9 \sim 10$ と対応 (部分的支持)。MNIST 疎グリッド多シード実験では $m^{\text{knee}} \in \{32, 64\}$ ($\sigma = 15$) となり、安定化に必要な条件が定量的に明らかになった。密グリッド実験 (Exp-Mnist-Dense, § 5.3.7) では $m^{\text{knee}} = 10.3 \pm 0.9$ (3 シード) となり、グリッド密度が不安定性の**主要因の一つ**であることを示す証拠が得られた (シード因子も残存；非線形設定では命題上界を超えた誤差も生じうる)。命題 2 による理論的根拠 (グリッド感度上界) と、密グリッド・アンサンブル・KL アニールによる実践的安定化戦略を提示した (§ 6.2)。
5. **位相的構造と AU_{sat} の条件付き対応** : 位相的に非自明な合成多様体 (Torus, Möbius Band) で $\text{AU}_{\text{sat}} \approx d_{\text{emb}}$ を観測 (条件付き；実験 Exp-Syn-Top)。MNIST での $\text{AU}_{\text{sat}} = 36$ ($> \hat{d}_{\text{ID}} \approx 10$) は Manifold Entanglement の可能性を示唆するが未確定。
6. **IsometricAE による等長潜在空間の実現** (合成多様体のみ；実験 Exp-Syn-Iso), MNIST での大域・局所構造形成の時間的分離 (単一シード；実験 Exp-Mnist-Dyn), Conv-AE での TwoNN ID の FC-AE との整合性 (実験 Exp-Conv-AE)。

本フレームワークの適用可能性の 3 段階整理 :

本稿の検証結果を踏まえ、フレームワークの適用可能性を 3 段階に整理する (表 33)。

表 33: フレームワーク適用可能性の 3 段階整理. 各指標の動作状況と実証根拠をまとめる. 「」=安定動作確認, 「△」=部分的確認, 「×」=未到達/今後の課題.

設定	TwoNN ID	AU 監視	
FC-VAE + MNIST/F-MNIST	($\sigma \leq 0.12$)	($\sigma \leq 0.5$)	△ (密)
Conv-VAE + MNIST	(同等の安定性)	△ ($m \geq 96$ で AU < m 開始)	△ ($\beta \geq 10$ で m)
自然画像 (CIFAR-10/SVHN)	(Pope 値と整合)	△/ ($\beta_{\max} = 80$ 薄型デコーダでプラトー初観測)	△ (5 条件中 0 達成; 飽)

Stage 1: $\hat{d}_{\text{ID}}$ は等長性バイアス含む補助的参照推定量 ($\kappa \approx 10^9$; § 5.2.4 で安定性を実証)

この 3 段階整理は, フレームワークの「弱点の開示」ではなく, **どこまで確かめ, どの条件で破綻し, どこから未解決かを切り分けた研究**として位置づける枠組みである. 本論文は「有効潜在次元を一意に決定する方法の提案」ではなく, **「どの指標が頑健で, どの条件でどの指標が限界を迎えるかを定量化した診断フレームワーク」の確立**を目指す——この姿勢が, 自然画像・Conv-VAE での未達事項を弱点ではなく貢献として提示できる根拠である. FC-VAE + MNIST/Fashion-MNIST では解釈論が最もよく検証されており, Conv-VAE については「 $\beta_{\max} = 4$ での未飽和は β 設定不足でも説明可能であることを MNIST 上で確認した」という範囲に実証が留まる. 自然画像での AU/ m^{knee} 安定同定は引き続き未解決だが, Exp-NatImg-AU・Exp-NatImg-Sweep により「必要 β 条件, デコーダ容量条件, stable identification 5 基準の現達成状況」を定量化した——これが境界条件の解明という本論文の知見である (§ 6.6, § 6.7).

今後の課題: 以下を主要な研究課題として挙げる.

1. τ_{knee} **の適応的設定**: SVHN 実験 (Exp-Nat-SVHN, § 5.8) では, $m = 128$ で AU = $125.3 < 128$ という部分的崩壊が観測されたにもかかわらず, 固定閾値 $\tau = 0.25$ では m^{knee} が検出されなかった (AU(m) の緩勾配により $r > \tau$ が続く). また, Exp-Mnist-Dense 密グリッドでの比較 (§ 5.3.7, 表 20) では, τ 法 ($m^{\text{knee}} = 10.3 \pm 0.9$) は二階差分法 ($m^{\text{knee}} = 18.3 \pm 6.8$) より安定であった——二階差分法は AU(m) の離散ノイズに敏感で, 特に疎な AU 遷移域で不安定になる. したがって, 密グリッド条件では τ 法が推奨されるが, 自然画像・緩勾配データへの適用には Kneedle アルゴリズムや leave-one-out cross-validation による **適応型 τ 選択**の開発が課題である. 実験 Exp-NatImg-Knee (§ 5.11) では自然画像での平滑化後曲率法が最安定であることを確認したが, stable identification 条件の達成には AU 飽和自体の安定化が先決である.
2. m^{knee} **安定化の定量的検証**: 密なグリッド (推定 ID 付近での細分化) とアンサンブル評価による m^{knee} の誤差評価 (命題 2 の実証的検証). stable identification の 5 条件判定枠組み (§ 5.11) により, 条件の達成状況を定量的に記述できる.
3. **大規模データへの拡張**: ImageNet 等への適用には Conv-VAE の大型化と計算コスト削減が必要であり, 階層的 ID 推定 (層ごとの TwoNN ID) との組み合わせが有望である.
4. **線形 VAE 定理の非線形設定への厳密な拡張**: 定理 1 は線形ガウス設定での厳密な成立を示すが, 非線形エンコーダ・デコーダへの拡張には局所線形化 (接空間近似) に基づく解析が必要である.
5. **相互情報量・レート歪み曲線との定量比較**: AU(m) 曲線と情報論的レート歪み関数 $R(D)$ の対応関係を実験的に精密化し, 理論的水充填解との定量的一致を検証する.

6. 自然画像での $\beta_{\max}$ 設定と薄型デコーダの組み合わせ最適化 : Exp-NatImg-Sweep の結果 (§ 5.11) から, $\beta_{\max} = 80 \cdot$ 薄型デコーダという設定でのみ AU 飽和が初観測された. stable identification の達成には, $\beta_{\max} \in [40, 120]$ の密スイープと, デコーダ容量・シード安定性の同時最適化が次のステップとなる. 具体的には, AU プラトー値のシード間 $\sigma \leq 0.05 \cdot \text{AU}_{\text{sat}}$ (条件 4) と $\beta_{\max}$ 変動 $\pm 20\%$ での m^{knee} 安定性 (条件 3) の達成が最優先課題である.

参考文献

- [1] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Wiley-Interscience, Hoboken, NJ, 2006.
- [2] H. Fu, C. Tan, B. Peng, Z. Zhao, T. Yan, C. Chang, and L. Zhao, “Cyclical annealing schedule: A simple approach to mitigating KL vanishing,” in *Proceedings of NAACL-HLT 2019*, pp. 240–250, 2019.
- [3] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Technical Report, University of Toronto, 2009.
- [4] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, “Reading digits in natural images with unsupervised feature learning,” in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- [5] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *Journal of the Royal Statistical Society: Series B*, vol. 61, no. 3, pp. 611–622, 1999.
- [6] C. Fefferman, S. Mitter, and H. Narayanan, “Testing the manifold hypothesis,” *Journal of the American Mathematical Society*, vol. 29, no. 4, pp. 983–1049, 2016.
- [7] Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.
- [8] E. Facco, M. d’Errico, A. Rodriguez, and A. Laio, “Estimating the intrinsic dimension of datasets by a minimal neighborhood information,” *Scientific Reports*, vol. 7, p. 12140, 2017.
- [9] E. Levina and P. J. Bickel, “Maximum likelihood estimation of intrinsic dimension,” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 17, 2005.
- [10] A. Hatcher, *Algebraic Topology*, Cambridge University Press, Cambridge, 2002.
- [11] V. Guillemin and A. Pollack, *Differential Topology*, Prentice-Hall, Englewood Cliffs, NJ, 1974.
- [12] G. Carlsson, “Topology and data,” *Bulletin of the American Mathematical Society*, vol. 46, no. 2, pp. 255–308, 2009.
- [13] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in *International Conference on Learning Representations (ICLR)*, 2014.
- [14] K. Kato, J. Zhou, T. Sasaki, and A. Nakagawa, “Rate-distortion optimization guided autoencoder for isometric embedding in Euclidean latent space,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 119, 2020.
- [15] P. Nazari, S. Damrich, and F. A. Hamprecht, “Geometric autoencoders – what you see is what you decode,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 202, 2023.
- [16] C. Ceruti, S. Bassis, A. Rozza, G. Lombardi, E. Casiraghi, and P. Campadelli, “DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration,” *Pattern Recognition*, vol. 47,

- no. 8, pp. 2569–2581, 2014.
- [17] P. Pope, C. Zhu, A. Abdelkader, M. Goldblum, and T. Goldstein, “The intrinsic dimension of images and its impact on learning,” in *International Conference on Learning Representations (ICLR)*, 2021.
 - [18] A. Ansuini, A. Laio, J. H. Macke, and D. Zoccolan, “Intrinsic dimension of data representations in deep neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
 - [19] T. Birdal, A. Lou, L. J. Guibas, and U. Simsekli, “Intrinsic dimension, persistent homology and generalization in neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.
 - [20] L. Valeriani, D. Wood, G. Catania, S. Gherardini, A. Laio, and A. Ansuini, “The geometry of hidden representations of large transformer models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.
 - [21] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” in *International Conference on Learning Representations (ICLR)*, 2017.
 - [22] J. Lucas, G. Tucker, R. B. Grosse, and M. Norouzi, “Don’t blame the ELBO! A linear VAE perspective on posterior collapse,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
 - [23] S. Rifai, P. Vincent, X. Muller, X. Glorot, and Y. Bengio, “Contractive auto-encoders: Explicit invariance during feature extraction,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 28, 2011.
 - [24] G. Alain and Y. Bengio, “What regularized auto-encoders learn from the data-generating distribution,” *Journal of Machine Learning Research (JMLR)*, vol. 15, no. 1, pp. 3743–3773, 2014.
 - [25] N. Tishby, F. C. Pereira, and W. Bialek, “The information bottleneck method,” in *Proc. 37th Annual Allerton Conference on Communication, Control and Computing*, pp. 368–377, 1999.
 - [26] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 97, pp. 3519–3529, 2019.
 - [27] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform manifold approximation and projection for dimension reduction,” *arXiv preprint arXiv:1802.03426*, 2018.
 - [28] F. Chazal and B. Michel, “An introduction to topological data analysis: Fundamental and practical aspects for data scientists,” *Frontiers in Artificial Intelligence*, vol. 4, 2021.
 - [29] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *Journal of Machine Learning Research (JMLR)*, vol. 9, pp. 2579–2605, 2008.

付録 A 命題の証明スケッチ

命題 5 (デコーダヤコビアンの実効階数). 十分な容量を持つ AE が多様体 $\mathcal{M}$ を正確に再構成するとき、デコーダのヤコビ行列 $J_g(z)$ の有意特異値数は $\min(m, d_{\text{emb}})$ に等しい。

証明スケッチ: 正確な再構成時, g の値域は $\mathcal{M}$ の接空間 $T_{g(z)}\mathcal{M}$ に張られる. $\mathcal{M}$ が d 次元なら $\text{rank}(J_g) = d$ となり, 余剰次元の特異値は零に近づく. (有限容量・最適化誤差を無視.)

命題 6 (ノイズ方向選択性). DAE の最適再構成関数は, 多様体の法線方向のノイズを接線方向より選択的に

除去する.

証明スケッチ：Alain ら [24] より, DAE の再構成方向 $r(x) - x \approx \sigma^2 \nabla \log p(x)$ であり, $\nabla \log p(x)$ は多様体の法線方向を強く指す (多様体仮説のもと). (漸近的最適解を仮定; 有限ノイズ・有限容量での近似誤差を無視.)

命題 7 (近傍構造保存と最適ボトルネック). $m = d_{\text{true}}$ (または d_{emb}) において, *Trustworthiness* が最大化に向けて急激に改善し, それ以上の m への増加による改善は限定的となる.

証明スケッチ：命題 1 より, $m < d$ では連続単射が不可能で情報の衝突が不可避となり, *Trustworthiness* が低下する. $m \geq d$ で制約が解消され, $m > d$ では既に全多様体構造が表現可能であるため追加次元の効果は限定的. (有限サンプル・有限容量を無視.)

付録 B 定理 1 の詳細な導出

本付録では, 定理 1 (線形 β -VAE における AU 飽和しきい値) の証明において本文中で省略した式 (5) と式 (6) の間の代数的ステップを詳述する.

Step 1: 最適デコーダ重みの導出

スカラー問題として, 方向 j に対し $y_j \sim \mathcal{N}(0, \lambda_j)$ (データの第 j 主成分), エンコーダ: $q_j(z_j|y_j) = \mathcal{N}(a_j y_j, \sigma_j^2)$, デコーダ: $\hat{y}_j = b_j z_j$ を考える. デコーダ重み b_j について, 周辺化した再構成 MSE を最小化する (σ_j^2, a_j を固定したとき):

$$D_j(b_j) = \mathbb{E}_{y_j, z_j} [(y_j - b_j z_j)^2] = \lambda_j - 2a_j \lambda_j b_j + b_j^2 (a_j^2 \lambda_j + \sigma_j^2). \quad (11)$$

$\partial D_j / \partial b_j = 0$ を解くと, 最適デコーダ重みは

$$b_j^* = \frac{a_j \lambda_j}{a_j^2 \lambda_j + \sigma_j^2} =: \frac{a_j \lambda_j}{\rho_j}, \quad \rho_j := a_j^2 \lambda_j + \sigma_j^2. \quad (12)$$

Step 2: 最適 MSE と相互情報量の表示

式 (12) を式 (11) に代入すると:

$$D_j^* = \lambda_j - \frac{a_j^2 \lambda_j^2}{\rho_j} = \frac{\lambda_j \sigma_j^2}{\rho_j}. \quad (13)$$

また, $y_j \rightarrow z_j$ の通信路容量 (相互情報量) は:

$$I(z_j; y_j) = \frac{1}{2} \log \frac{\rho_j}{\sigma_j^2} = \frac{1}{2} \log \left(1 + \frac{a_j^2 \lambda_j}{\sigma_j^2} \right) =: R_j. \quad (14)$$

Step 3: β -ELBO のレート歪み表示

$b_j = b_j^*$ を固定したもとの, (σ_j^2, a_j) に関する β -ELBO 寄与は $L_j = -D_j/(2\tau^2) - \beta R_j$ と書ける (KL 最小化との等価性 [1]). ρ_j をパラメータとして $D_j^* = \lambda_j \sigma_j^2 / \rho_j$, $R_j = \frac{1}{2} \log(\rho_j / \sigma_j^2)$ を代入すると, 本文の式 (5) が得られる:

$$L_j = -\frac{\lambda_j \sigma_j^2}{2\tau^2 \rho_j} - \frac{\beta}{2} [\rho_j - 1 - \log \rho_j]. \quad (5 \text{ 再掲})$$

(ここで $\sigma_j^2 = \rho_j - a_j^2 \lambda_j$, $\rho_j \geq \sigma_j^2$).

Step 4：KKT 条件による最適歪み D_j^* の導出

歪み $D_j \in (0, \lambda_j)$ を主変数として $L_j = -D_j/(2\tau^2) - \beta R_j(D_j)$ を最大化する．ガウス通信路のレート歪み関係 $R_j(D_j) = \frac{1}{2} \log(\lambda_j/D_j)$ より：

$$\frac{\partial L_j}{\partial D_j} = -\frac{1}{2\tau^2} + \frac{\beta}{2D_j} = 0 \implies D_j^* = \beta\tau^2. \quad (15)$$

これが Shannon の水充填定理 [1] の「水面 (water level)」 $\mu = \beta\tau^2$ に対応する．ただし式 (15) の解は $D_j^* = \beta\tau^2 \leq \lambda_j$ (フィジビリティ制約) が満たされる場合にのみ実行可能 (*active*) であり, $\lambda_j < \beta\tau^2$ の場合は次元 j を符号化しない ($a_j = 0$, *dead*) が最適となる．

Step 5：活性・不活性の ELBO 値の計算

不活性 (dead) : $a_j = 0$, $\sigma_j^* = 1$ (KL = 0), $D_j = \lambda_j$ のとき

$$L_j^{(\text{dead})} = -\frac{\lambda_j}{2\tau^2}. \quad (16)$$

活性 (active) : $D_j^* = \beta\tau^2$ を代入すると, $R_j^* = \frac{1}{2} \log(\lambda_j/(\beta\tau^2))$ であるから：

$$L_j^{(\text{active})} = -\frac{\beta\tau^2}{2\tau^2} - \beta \cdot \frac{1}{2} \log \frac{\lambda_j}{\beta\tau^2} = -\frac{\beta}{2} - \frac{\beta}{2} \log \frac{\lambda_j}{\beta\tau^2}. \quad (17)$$

Step 6：ELBO 利得 ΔL_j の厳密な表示と符号解析

活性化の利得 $\Delta L_j := L_j^{(\text{active})} - L_j^{(\text{dead})}$ を計算する． $t := \lambda_j/(\beta\tau^2) > 0$ とおくと：

$$\Delta L_j = \left(-\frac{\beta}{2} - \frac{\beta}{2} \log t\right) - \left(-\frac{\beta\tau^2 \cdot t}{2\tau^2}\right) = \frac{\beta}{2}(t - 1 - \log t). \quad (18)$$

関数 $h(t) := t - 1 - \log t$ の解析：

- $h'(t) = 1 - 1/t = (t-1)/t$ より, $t = 1$ で $h' = 0$ (唯一の停留点).
- $h''(t) = 1/t^2 > 0$ より, $t = 1$ は**大域的最小点**, $h(1) = 0$.
- $t > 0$, $t \neq 1$ のとき $h(t) > 0$ (大域最小値 0 より大).

したがって $\Delta L_j = (\beta/2) h(t)$ の符号は：

$$\Delta L_j > 0 \iff h(t) > 0 \iff t \neq 1. \quad (19)$$

Step 7：フィジビリティと飽和条件の統合

活性解のフィジビリティ条件 ($D_j^* = \beta\tau^2 \leq \lambda_j$) は $t \geq 1$ を要求する． $t < 1$ ($\lambda_j < \beta\tau^2$) では活性解が実行不可能であり dead が強制される． $t = 1$ ($\lambda_j = \beta\tau^2$) では $\Delta L_j = 0$ (無差別)． $t > 1$ ($\lambda_j > \beta\tau^2$) では活性が実行可能かつ $\Delta L_j > 0$ (優位)．

以上をまとめると：

$$\text{次元 } j \text{ が活性} \iff \lambda_j > \beta\tau^2, \quad (20)$$

すなわち定理 1 の飽和しきい値条件 (4) が成立する. □

注意 6. 本文の式 (6) は, 式 (18) の $h(t) = t - 1 - \log t$ を $t = 1$ 周りで 2 次展開した近似 $h(t) \approx (t-1)^2/2$ (つまり $\Delta L_j \approx (\lambda_j - \beta\tau^2)^2/(2\beta\tau^4)$) の形で表記している．厳密な表示は式 (18) であり, 近似は説明の簡略化のためのものである．

付録 C τ_{knee} の感度分析と横断検証（実験 Exp-Tau-Cross）

$\tau_{\text{knee}} = 0.25$ の選択根拠

理論的根拠：定理 1 より， $AU(m)$ の増加率 $r(m) = \Delta AU / \Delta m$ は $m < d^*(\beta)$ （飽和前）で $r \approx 1$ （新たな次元が完全に活性化）， $m > d^*(\beta)$ （飽和後）で $r \rightarrow 0$ （追加次元は不活性）となる理論的な段差を持つ．実際の AU は離散整数値であるため，この遷移は滑らか（または離散的）に起こる． $\tau_{\text{knee}} = 0.25$ は「最大増加率の 1/4 以下」であり，飽和前（ $r \approx 1$ ）と飽和後（ $r \approx 0$ ）の中間点として「明確に鈍化した」領域の開始を捉えるバランスの良い閾値である．

AU の正規化増加率 $r(m)$ の指数飽和モデル：

$$r(m) = r_0 \cdot \exp(-\lambda(m - d_{\text{ID}})) \quad (21)$$

において， $r(m) < 0.25 \cdot r_{\text{max}}$ （全変化量の 25% 以下）となる点を鈍化点として定義する．

より厳密な閾値設定として， $AU(m)$ の離散二階差分が最大となる点（曲率最大点）を用いることが理論的に motivated であるが， AU の離散性により実データでは数値的に不安定になることが多い． $\tau = 0.25$ はこの曲率最大点付近の安定した代替として機能する（Exp-Tau-Cross 感度分析参照）．

経験的根拠：MNIST（Exp-Mnist-Base 単一シード実験）では $\tau \in [0.1, 0.5]$ の全範囲で $m^{\text{knee}} = 12$ （安定）．Fashion-MNIST では $\tau \approx 0.25$ が境界感度を持つ（表 34）．境界感度の存在は， $AU(m)$ 曲線の勾配遷移が $\tau = 0.25$ 付近の値で起こることを示唆しており，この閾値の「効きやすさ」を逆に裏付ける．

データセット横断検証（実験 Exp-Tau-Cross）

Fashion-MNIST および Gaussian 混合分布（5 成分・10 成分）での横断検証結果を表 34 に示す．

表 34: Exp-Tau-Cross： τ_{knee} 頑健性の横断検証

データセット	AU_{sat}	TwoNN ID	$\tau = 0.1$	$\tau = 0.2$	$\tau = 0.25$	$\tau = 0.3$	$\tau = 0.4$	$\tau = 0.5$
Fashion-MNIST	10	7.00	20	20	20	8	8	8
GMix 5 成分	1	4.27	2	2	2	2	2	2
GMix 10 成分	3	3.02	2	2	2	2	2	2

Fashion-MNIST では $\tau = 0.25$ と 0.30 の境界で m^{knee} が 20 から 8 に変化する境界感度が確認された（ AU 増加率が境界値 0.25 に一致する複数の m が存在するため）．この場合，二階差分代替手法（式 (21)）の使用を推奨する（§ 3 参照）．

付録 D β 感度分析

MNIST サブセット（ $n = 5,000$, 50 エポック）で $\beta \in \{1, 2, 4, 8\}$ の AU Dynamics を比較した（図 16）．




図 16: β 感度分析：MNIST VAE の AU vs m ($\beta \in \{1, 2, 4, 8\}$, 50 エポック, サブセット). $\beta = 1$ では $AU \approx m$ (正則化不足), $\beta = 4$ では $m_{\text{knee}} = 12$ (垂直破線), $\beta = 8$ では $m < 8$ で AU が過度に抑制される兆候が見られる.

$\beta = 4$ を本実験のデフォルト値として採用した根拠： $\beta = 1$ では KL 正則化が弱く $AU \approx m$ のため m^{knee} が同定できない； $\beta = 8$ では過正則化により小さい m での AU が抑制され、 m^{knee} の同定点がずれる可能性がある． $\beta \in [2, 8]$ では AU パターンの形状は安定することを確認したが、 m^{knee} の精確な数値は m グリッドにも依存する (§ 6.1).

付録 E AU 閾値 δ の感度分析

Swiss Roll・Torus において $\delta \in \{0.001, 0.01, 0.05, 0.1\}$ で AU パターンが完全に一致することを確認した (全 $m \cdot \delta$ の組み合わせで一致). 活性次元の分散 ($O(1)$) と非活性次元の分散 ($O(10^{-4})$ 以下) の間に 2 桁以上の差があるため、 δ の選択に対して頑健である.