

AE/VAE における有効潜在次元の診断的解釈

(著者名)

(所属機関)

(メールアドレス)

概要

本論文では、AE/VAE が学習した潜在表現において実際に利用される有効潜在次元を診断的に解釈するため、Active Unit (AU) Dynamics, 内在次元 (ID) 推定 (TwoNN/MLE), MSE エルボー, および PCA を統合した多指標診断フレームワークを提案する. 本フレームワークは有効潜在次元を単一の数値として一意に決定するのではなく, AU 値を KL 活性座標数の頑健な直接観測指標, TwoNN/MLE ID を数値的に安定な補助的参照推定量 (潜在空間の安定な参照値であり, 真の内在次元に対する不偏性は保証されない), AU 鈍化点 m^{knee} を TwoNN 誘導型の探索的変化点として明確に区別する. 理論面では, 線形ガウス β -VAE の rate-distortion 近似という解釈的サロゲートのもとで, データ共分散の第 j 固有方向が活性化される条件 $\lambda_j > \beta\tau^2$ を導出する (学習済み非線形 VAE に関する定理ではない). 実験では, MNIST の全結合 VAE において AU 値と TwoNN ID が複数シードにわたり高い再現性を示す一方, m^{knee} は疎グリッドでは大きく変動すること, および TwoNN 推定値近傍の密グリッド探索 (TwoNN 誘導型局所精密化) により $m^{\text{knee}} = 10.3 \pm 0.9$ に安定化することを示す——ただしこの安定化の検証範囲は MNIST FC-VAE $\cdot \beta = 4 \cdot$ 密グリッド $\cdot 3$ シードに限られる. さらに Fashion-MNIST, Conv-VAE, CIFAR-10/SVHN 実験を通じて, 本フレームワークが機能する条件と AU/m^{knee} 診断が困難となる境界条件を定量化する.

1 まえがき

1.1 研究背景：有効潜在次元の解釈という問題

表現学習において, オートエンコーダ (Autoencoder; AE) および変分オートエンコーダ (Variational Autoencoder; VAE) [12] は, 高次元データから低次元の潜在表現 (latent representation) を学習する中核的な非教師あり学習モデルである [7]. この潜在表現の「質」を規定する最も基本的な設計パラメータがボトルネック次元 (bottleneck dimension) m である: m が小さすぎると情報が欠落し, 大きすぎると冗長な次元が生じる (VAE では posterior collapse[21] が悪化する).

しかし, 学習された潜在表現が「実際に何次元を有効に使っているか」——すなわち**有効潜在次元 (effective latent dimensionality)**——を定量的に読む方法論は, 深層表現学習の研究において十分に確立されていない. 既存研究 [17, 19] は深層ネットワークの各層の内在次元を測定してきたが, AE/VAE のボトルネックにおける有効次元を, その学習ダイナミクスとともに系統的に分析した研究は限られている.

本論文が取り組む中核的な問いは:

AE/VAE は, 入力データの内在次元 (*local intrinsic dimensionality*) や位相的埋め込み次元 (*topological embedding dimensionality*) をどのように潜在空間の有効次元として「学習」するか? そして, その有効次元を外から定量的に読む方法はあるか?

1.2 本研究の位置づけと貢献

本論文では、この問いに対し、**内在次元 (ID) 推定**と **Active-Unit (AU) Dynamics** を柱とした**多指標診断フレームワーク**を提案する。本フレームワークの核心は、有効次元を単一指標で「一意に決定」するのではなく、各指標の頑健性と探索的性格を明示した上で組み合わせ、**診断的に解釈する点**に新規性がある。「 m^{knee} により適切なボトルネック次元を一意に同定できる」という主張は行わない—— m^{knee} は TwoNN 誘導型の探索的变化点であり、主要な有効次元の読み取りは頑健指標 (AU 値) と数値安定な補助的参照推定量 (TwoNN ID) が担う (各指標の分類と信頼性は表 2 にまとめる)。

本論文の**貢献は以下の 3 点**である：

1. **多指標診断フレームワークの提案**：本研究の主貢献は、 m^{knee} そのものの提案ではなく、AU 値、TwoNN/MLE ID、MSE エルボー、PCA を役割の異なる診断指標として整理し、AE/VAE の有効潜在次元を多面的に解釈する枠組みを与える点にある。AU 値を潜在次元の利用状況を直接観測する頑健指標、TwoNN ID を数値的に安定な補助的参照推定量、 m^{knee} を AU 曲線形状から得られる探索的变化点として明確に区別する (§ 3, § 6)。MNIST での 3 シード検証により AU 値 ($\sigma \leq 0.5$) と TwoNN ID (10.03 ± 0.12) の高い再現性を確認し、TwoNN 推定値近傍の密グリッド・独立初期化・複数シード条件での $m^{\text{knee}} = 10.3 \pm 0.9$ (Exp-Mnist-Dense-300) を主要な安定化結果とする (§ 5.3.6)。ただし、探索領域自体を TwoNN 推定値から選択しているため、この結果は「TwoNN 誘導型の局所精密化」であり、TwoNN と独立な検証ではない。検証範囲は MNIST FC-VAE $\cdot \beta = 4 \cdot 3$ シードに限られる。
2. **線形ガウス rate-distortion 近似に基づく AU 活性化条件の導出**：線形ガウス β -VAE の rate-distortion 近似のもとで、第 j 潜在次元が活性となる条件 $\lambda_j > \beta\tau^2$ を水充填定理と KKT 条件から導出し (定理 1, § 4)、KL 正則化が有効次元を抑制する機構を水充填原理の観点から説明する。本結果は実際の非線形 VAE の厳密定理ではなく、線形ガウス rate-distortion 近似に基づく解析結果として、非線形実験との定性的対応を与えるものである。
3. **適用可能範囲と限界条件の定量化**：MNIST/Fashion-MNIST (FC-VAE)、Conv-VAE、CIFAR-10/SVHN を対象に、AU 値・TwoNN ID の再現性、 m^{knee} のグリッド・シード依存性、および「等長性改善より $m \gg \hat{d}_{\text{ID}}$ が TwoNN 安定性の支配的条件」(Exp-Real-Geom, 命題 4) を実証する。さらに Conv-VAE・自然画像では、AU/ m^{knee} 診断が困難となる境界条件を stable identification の 5 条件 (operational criteria) として定量化する (§ 6.6, § 6.7)。

1.3 「次元」の 2 種類：局所的固有次元と位相的埋め込み次元

本論文では多様体の「次元」として d_{ID} (局所的固有次元：TwoNN/MLE の推定対象) と d_{emb} (位相的埋め込み次元：自己交差なく埋め込むための最小次元) を区別する (Swiss Roll では $d_{\text{emb}} = d_{\text{ID}} = 2$, Torus では $d_{\text{emb}} = 3 > d_{\text{ID}} = 2$)。

ただし、**本論文の主貢献は d_{ID} や d_{emb} との対応を証明することではなく、AU 値・TwoNN ID・ m^{knee} という診断指標の頑健性・限界・適用条件の整理にある**。 d_{emb} と AU_{sat} との条件付き対応 (Torus・Möbius 等) は付随的観察として補助に位置づける (§ 6.5)。

1.4 リサーチクエスト

- RQ1 VAE の AU Dynamics から得られる変化点 m^{knee} は、どのようなグリッド密度・シード数・アーキテクチャ条件のもとで、TwoNN/MLE による ID 推定値と整合する診断補助量として利用可能か。
- RQ2 AE/VAE の有効潜在次元を多指標 (AU 値、TwoNN/MLE, MSE エルボー, PCA) で解釈するフレー

ムワークは、単一指標に対して相補的な情報を提供するか。

RQ3 ボトルネック余裕 ($m/\hat{d}_{\text{ID}}$ の大小) および幾何的正則化 (IsometricAE) は、TwoNN ID 推定の安定性にどのような影響を与えるか。

1.5 本論文の構成

検証範囲の明示: 本論文の検証は合成多様体 ($d_{\text{true}} \leq 3$)・MNIST・Fashion-MNIST (全結合型 AE/VAE), Conv-AE/VAE, および自然画像 (CIFAR-10・SVHN) を対象とする。自然画像実験では TwoNN 補助推定が Pope ら [16] の報告値と整合することを確認し, Conv-VAE における $\text{AU}/m^{\text{knee}}$ 診断の適用可能範囲と限界条件を定量化する (フレームワーク全体の自然画像への「汎化」を主張するものではない)。

§ 2 (関連研究), § 3 (フレームワーク), § 4 (理論的背景; 定理 1 含む), § 5 (実験), § 6 (考察), § 7 (むすび) の順で構成する。詳細な証明と感度分析は付録にまとめる。

2 関連研究

2.1 表現学習とオートエンコーダ

Bengio ら [7] は表現学習の理論的枠組みを整理し, AE が多様体仮説 [6] に基づいて高次元データの低次元構造を学習する機構を論じた。β-VAE[20] は KL 正則化の重み β を大きくすることで Disentangled 表現を促進し, AU に直接影響する。Lucas ら [21] は, VAE の ELBO 最小化において posterior collapse (AU の大幅な減少) が生じる条件を線形 VAE の枠組みで分析し, AU とデータの分散構造 (有効次元) との関連を定性的に論じた。DAE[23] はスコアマッチングの観点から, Denoising Autoencoder の再構成方向が多様体の法線方向を選択的に抑制することを示した。CAE[22] はエンコーダ側ヤコビアンヤコビアンの正則化により収縮的表現を学習する。

2.2 深層表現の内在次元解析

Pope ら [16] は自然画像の内在次元が TwoNN 推定で画素次元よりはるかに低いことを示した (CIFAR-10: $d_{\text{ID}} \approx 26$ at 32×32)。Ansuini ら [17] は深層ネットワークの各層を通じて ID が変化するパターンを定量化し, 表現の収縮・拡張現象を記録した。Valeriani ら [19] は大規模変換器モデルの隠れ表現の幾何構造を系統的に解析した。Birdal ら [18] は持続的ホモロジーと ID の統合による汎化誤差との関係を分析した。本研究はこれらの「既存のネットワークの ID を測る」研究と相補的であり, AE/VAE の**設計段階**および**学習ダイナミクス**における有効次元の形成を追跡する点で異なる。

内在次元推定手法としては, TwoNN[8] (2 近傍距離比) と MLE[9] (最尤推定) を採用する。DANCo[15] はより精密だが計算コストが高い。なお, 非線形次元削減の可視化手法として UMAP[25] が広く用いられるが, 本研究は可視化ではなくボトルネック次元の**定量的な解釈**に焦点を当てる。

2.3 Active Units と Posterior Collapse

Active Unit (AU) [21, 20] は, VAE の事後平均の分散が閾値 δ を超える潜在次元の数であり, KL 正則化が有効に機能している次元数を定量化する指標である。Lucas ら [21] は, ELBO の最小化が posterior collapse を引き起こす条件を線形 VAE の枠組みで分析し, AU とデータの固有値構造との関連を定性的に論じた。一方, 本研究の定理 1 は Lucas らの定性的議論を, データ固有値 $\lambda_j \cdot \text{ノイズ } \tau^2 \cdot \text{正則化 } \beta$ による**閉形式しきい値** $\lambda_j > \beta\tau^2$ **として定量化**し, さらに Shannon の水充填定理との明示的な結びつきと KKT 条件を用いて, 線形ガウス rate-distortion 近似のもとで定量的導出を行う点が新規性である (Tipping & Bishop [5] の PPCA

における $\beta = 1$ の特殊ケースも統合する). また, 実データにおける AU 増加ダイナミクスの系統的な分析, 特に m^{knee} という概念とその有効表現次元との対応・限界条件・安定化戦略については, 本研究が体系的に検証する (定理 1, 命題 2, § 6.2).

2.4 幾何的オートエンコーダ

Nazari ら [14] は幾何的オートエンコーダを提案し, エンコーダが多様体の幾何構造を保存するための正則化を導入した. Kato ら [13] はデコーダのヤコビ行列に対するプルバック計量の単位行列への近似化により等長埋め込みを実現する IsometricAE を提案した. 本研究では IsometricAE を「有効次元の読み取り精度の前提条件 (等長性) を改善する補助ツール」として位置づける (RQ3, 実験 Exp-Syn-Iso).

3 フレームワーク：有効潜在次元の読み取り

3.1 問題設定と主要記号

AE/VAE を入力次元 N , ボトルネック次元 m で定義する: エンコーダ $f: \mathbb{R}^N \rightarrow \mathbb{R}^m$, デコーダ $g: \mathbb{R}^m \rightarrow \mathbb{R}^N$. VAE ではエンコーダが事後分布 $q_\phi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x))$ を出力し, KL 正則化 (強度 β) が情報ボトルネックとして作用する.

Active Unit (AU) の定義:

$$\text{AU}(m) = \sum_{k=1}^m \mathbf{1}[\text{Var}_x[\mu_k(x)] > \delta], \quad \delta = 10^{-2} \quad (1)$$

ただし $\mu_k(x)$ は事後平均の第 k 成分, δ は閾値 (Lucas ら [21] に準拠). この閾値選択に対して AU は極めて頑健であり, $\delta \in [10^{-3}, 10^{-1}]$ の範囲で AU 値はほぼ変化しないことを感度分析で確認している (付録 G 参照).

AU 増加率の定義 (2 段階): まずグリッド上の生の増加率 $s(m_i)$ を,

$$s(m_i) = \frac{\text{AU}(m_i) - \text{AU}(m_{i-1})}{m_i - m_{i-1}} \quad (2)$$

と定義する (m_{i-1} はグリッド上の直前の値). 次に, 正規化増加率 $\rho(m_i)$ を,

$$\rho(m_i) = \frac{s(m_i)}{\max_j s(m_j)} \quad (3)$$

と定義する ($\rho(m_i) \in [0, 1]$).

主要記号一覧を表 1 に示す.

表 1: Notation used throughout this paper

Symbol	Meaning	Section
m	Bottleneck dimension (design parameter)	§ 3
m^{cand}	Diagnostic candidate dimension (not a unique optimum)	§ 3
m^{sat}	AU sharp saturation point (diagnostic candidate for synthetic manifolds)	§ 3
m^{knee}	AU slowdown point (rough heuristic for real data)	式 (4)
AU_{sat}	Maximum AU value over the grid	式 (1)
$\hat{d}_{\text{ID}}$	ID estimate via TwoNN/MLE	§ 3
d_{true}	True intrinsic dimension of synthetic manifold (known)	§ 5.2
d_{emb}	Topological minimum embedding dimension ($d_{\text{emb}} \geq d_{\text{ID}}$)	§ 1.3
κ	Decoder Jacobian condition number (isometry indicator)	§ 2.4
$s(m_i)$	Raw AU increase rate per unit dimension	式 (2)
$\rho(m_i)$	Normalized AU increase rate ($\in [0, 1]$)	式 (3)
τ_{knee}	Slowdown detection threshold (default: 0.25)	式 (4)

本フレームワークの核心は、各指標を**頑健指標**と**探索的指標**に明示的に分類した上で相補的に活用する点にある（表 2）。この分類は、後述の実験的知見（§ 5.3.4）に基づく実証的分類であり、単一指標への過信が招く誤診断を体系的に回避する設計思想の中核をなす。

「**頑健指標**」と「**探索的指標**」の意味について：ここでいう「頑健」とは、真の内在次元に対して不偏であることを意味しない。少なくとも本実験条件下で乱数シードに対する分散が小さいという意味で用いる。一方、「探索的」とは、グリッド設計や仮説生成には有用であるが、有効潜在次元の一意な推定値としては扱わないことを意味する。

表 2: Classification and empirical reliability of diagnostic indicators

Indicator	Category	Empirical reliability (inter-seed σ)	Primary use
AU values ($\text{AU}(m)$)	Robust indicator	$\sigma \leq 0.5$ (MNIST 300ep)	Direct observation of effective dimensionality; independent of reference AE geometry (depends on β , δ , model capacity)
TwoNN ID ($\hat{d}_{\text{ID}}$)	Numerically stable auxiliary reference[†]	$\sigma \leq 0.12$ ($m = 64$)	Reference estimate of intrinsic dimension
MSE elbow	Auxiliary indicator	Qualitative only	Reconstruction-side verification
PCA cumulative variance	Auxiliary indicator	Linear assumption only	Linear baseline
m^{knee} (AU slowdown point)	Exploratory indicator	$\sigma = 15$ (sparse grid); $\sigma = 0.9$ (dense grid)	Rough heuristic of effective dimensionality

[†] TwoNN ID is a **supplementary reference estimator** subject to isometry bias ($\kappa \approx 10^9$); see § 3.2 for details. σ of

m^{knee} is for sparse grid; improved to $\sigma = 0.9$ with dense grid (Exp-Mnist-Dense), where grid design is a major factor (§ 5.3.6).

各指標が推定する対象量の区別

「有効潜在次元」という語のもとで実際には性質の異なる複数の量が測られる。誤診断を避けるため、本稿では以下の5つの対象量を明示的に区別する：

- (i) **データ多様体の内在次元** $d_{\text{ID}}^{\text{data}}$ ：入力分布そのものの局所自由度。合成多様体では既知 (d_{true})、実データでは入力空間への TwoNN/MLE 適用で近似される。
- (ii) **潜在表現の内在次元** $d_{\text{ID}}^{\text{latent}}$ ：参照 AE の潜在表現に TwoNN/MLE を適用して得られる推定値 (本稿の $\hat{d}_{\text{ID}}$)。数値的には安定だが、参照 AE の埋め込みの歪みを介するため、(i) と一致する保証はない——安定な**潜在空間側の参照値**である (§ 6.3)。
- (iii) **KL 活性座標数** (AU 値)：VAE が実際に符号化に用いている潜在座標の数。 $\beta \cdot \text{アーキテクチャ} \cdot \text{閾値} \delta \cdot \text{学習条件}$ に依存する**座標利用の観測量**であり、内在次元の推定量ではない。 m^{knee} は $\text{AU}(m)$ 曲線の変化点、 AU_{sat} はグリッド上の最大 AU 値である。
- (iv) **再構成に必要なボトルネック次元**：再構成誤差が許容水準に達する最小の m (MSE エルボーが対応)。
- (v) **診断上の設計候補次元** m^{cand} ：上記 (i) ~ (iv) の複数指標を照合して設計者が選択する候補値。一意な最適解ではない。

本稿の主張はこの区別の上に述べられる：定理 1 は線形サロゲートにおける (iii) の閾値を与え、命題 4 と実験 Exp-Real-Geom は (ii) の安定条件を扱い、 m^{knee} の安定化結果 (§ 5.3.6) は (iii) の変化点が (ii) の近傍に安定化する条件を特定する。(i) そのものへの言明は合成多様体 (d_{true} 既知) の場合を除き行わない。

3.2 有効潜在次元の読み取りパイプライン

本研究が提案するフレームワークは、「AE/VAE が学習する有効潜在次元を2段階で読み取る」解釈パイプラインである (図 1)。

Stage 1：内在次元の近似推定 (補助的役割)

本論文では、内在次元 $\hat{d}_{\text{ID}}$ の推定を2通りの方法で行う：(a) **合成多様体**では入力空間に直接 TwoNN/MLE を適用 (d_{true} との対比が可能)；(b) **実データ (MNIST 等)**では、高次元の呪いを回避するため、大きめの参照 AE ($m_{\text{ref}} = 256$) の潜在表現を経由して推定する。

限界の明示：方法 (b) の参照 AE ($m = 256 \gg \hat{d}_{\text{ID}}$) の潜在空間は等長性を保証しておらず (補助測定： $\kappa \approx 10^9$ ；§ 6.7)、得られた $\hat{d}_{\text{ID}}$ は等長性バイアスを含む近似値である。本論文では、 $\hat{d}_{\text{ID}}$ を m^{knee} の候補範囲を示す**補助的な事前情報**として扱い、主要な有効次元の読み取りは Stage 2 の AU Dynamics に委ねる設計とする。これにより、参照 AE の非等長性に由来する循環的な議論を避ける。複数の m 値 (例： $\{64, 128, 256\}$) での推定値が収束していることを確認することで、実用上の安定性を担保する。

Stage 2：AU Dynamics による有効次元の読み取り

ボトルネック次元 m を離散グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$ 上でスイープし、各 m で VAE ($\beta = 4$) を学習して $\text{AU}(m)$ を計算する (実験によっては $\mathcal{M}$ の一部の m 点を省略・追加した拡張グリッドを用いる；各実験節に明記する)。AU パターンに応じて診断候補次元 m^{cand} の読み取り方を使い分ける (m^{cand} はボトルネック次元の唯一の「最適値」ではなく、**多指標による診断上の候補次元である**)：

飽和型 (合成多様体などシンプルなデータ) AU が特定の m で急激に飽和する場合、その飽和点 m^{sat} を診断候補次元 $m^{\text{cand}} = m^{\text{sat}}$ として用いる (AU 値が頑健なため、この条件ではかなり信頼性が高い)。

漸増型 (実データ, MNIST 等) AU が m とともに緩やかに増加する場合、鈍化点 m^{knee} を粗い設計目安として参照する (探索的指標)：

$$m^{\text{knee}} = \min\{m_i \in \mathcal{M} : \rho(m_i) < \tau_{\text{knee}}\} \quad (4)$$

ただし $\tau_{\text{knee}} = 0.25$ (デフォルト; 付録 C 参照). m^{knee} は「VAE が最初に有意な次元圧縮を行う点」を粗く捉えるが、数値は m グリッドや乱数シードに依存するため、AU 値・TwoNN ID と照合して最終的に判断する (§ 6.1). m^{knee} と $\hat{d}_{\text{ID}}$ が整合しなくてもフレームワーク全体が無効になるわけではない.

CKA[24] および MSE エルボーを補助基準として多指標で総合的に判断する.




図 1: Diagnostic pipeline for effective latent dimensionality. The diagnostic candidate dimension m^{cand} is not a unique optimal solution but a candidate based on multiple indicators (AU values, TwoNN ID, m^{knee}).

3.3 m^{knee} の解釈的意義

m^{knee} が有効表現次元の指標として機能するメカニズムを以下に述べる.

VAE の ELBO を最小化する過程で, KL 正則化 (情報ボトルネック項) は再構成に必要でない余剰潜在次元を非活性化する (posterior collapse を誘導する) [21, 20]. $m < \hat{d}_{\text{ID}}$ の段階では, ボトルネックが再構成の妨げとなるため, VAE は利用可能な全ての次元を AU として活性化させる ($\text{AU}(m) \approx m$). $m \approx \hat{d}_{\text{ID}}$ を超えると, 余剰次元が生じ始め, KL 正則化がそれらを非活性化する圧力を加えるため, AU の増加率が鈍化する. この鈍化点 m^{knee} は, 特定の条件下 (Fashion-MNIST 等) でデータの有効内在次元 $\hat{d}_{\text{ID}}$ と整合する傾向が観測されるが, 数値的な再現性は m グリッドや乱数シードに依存し保証されない (§ 5.3.4, § 6.1). フレームワークとしては, m^{knee} の整合有無にかかわらず, AU 値 (頑健な直接観測量) と TwoNN ID (数値安定な補助的参照推定量) の組み合わせによる有効次元の読み取りが, 本フレームワークの中心的な知見である.

3.4 Stable Identification の判定基準

新しいデータセット・アーキテクチャで「AU/ m^{knee} を安定同定できた」と主張するための判定基準を、実験に先立ってここで定義する。本論文では以下の 5 条件を全て満たす場合を **stable identification** と呼ぶ：

1. **シード安定性**：3～5 シードで m^{knee} の標準偏差 $\sigma_{\text{seed}} \leq 0.1 \cdot m^{\text{knee}}$
2. **グリッド安定性**：グリッドを 2 倍密にしても m^{knee} の変動 $\leq 20\%$
3. **β 安定性**： β_{max} を $\pm 20\%$ 変化させても m^{knee} が同じグリッドセルに収まる
4. **AU プラトー安定性**：AU プラトー値のシード間 $\sigma \leq 0.05 \cdot \text{AU}_{\text{sat}}$
5. **TwoNN・AU 整合性**： $m^{\text{knee}} \leq 3\hat{d}_{\text{ID}}$ (TwoNN と AU の粗い整合)

これらの閾値 ($0.1 \cdot m^{\text{knee}}$, 20% , $0.05 \cdot \text{AU}_{\text{sat}}$, $3\hat{d}_{\text{ID}}$) は理論的に導出された普遍定数ではなく、**著者らが定めた operational criteria** である。数値の選択は、MNIST FC-VAE で観測されたシード間変動のスケール (AU： $\sigma \leq 0.5$, 密グリッド m^{knee} ： $\sigma = 0.9 \approx 0.09m^{\text{knee}}$ ；§ 5.3.6) を「安定」の目安とし、それを桁で大きく超える変動を「不安定」と判定できるよう丸めた値である。閾値自体の系統的な感度分析は今後の課題であるが、本稿の結論（自然画像では 5 条件のいずれも未達；§ 5.11）は閾値を 2 倍に緩めても変わらない程度に判定が明確である。本基準の目的は「成功」の宣言ではなく、安定同定が達成できない場合に**どの条件が破れているか**を分解して記述することにある。

4 理論的背景

本章では、フレームワークを支える理論的基盤を示す。命題 1 は位相次元と埋め込み次元に関する標準的な位相的事実に基づく下界であり、厳密な主張は「ゼロ再構成誤差を達成するために必要な次元」という理想化された前提に限定される。**定理 1** は線形ガウス rate-distortion 近似における解析的結果であり、AU 活性化しきい値を閉形式で与える（証明詳細は付録 A）。命題 2 は理想化された単調飽和モデル下での補題であり、実際の非線形設定では上界を超えた誤差が生じうる点に注意。命題 4 は不偏性の保証ではなく、条件付き安定性の十分条件のスケッチである。命題 3 は等長性の定義から直接導かれる。

命題 1 (ボトルネック次元の位相的下界). 滑らかな d 次元多様体 $\mathcal{M} \subset \mathbb{R}^N$ を連続な AE により自己交差なく再構成し、理想的にゼロ再構成誤差を達成するためには、ボトルネック次元 $m \geq d$ が必要である。（有限サンプル・有限容量・近似的再構成を含む実際の設定は対象外の理想化である。）

Proof. ゼロ再構成誤差には $g \circ f|_{\mathcal{M}}$ が恒等写像に近い必要があり、 $f|_{\mathcal{M}} : \mathcal{M} \rightarrow \mathbb{R}^m$ が連続な単射でなければならない。 d 次元多様体から次元 $m < d$ のユークリッド空間への連続単射は位相的埋め込み次元の標準的な性質 (Hatcher [10], 第 2 章) により存在しないため、 $m \geq d$ が必要条件となる。□

本命題は $\hat{d}_{\text{ID}}$ がボトルネック次元の原理的下界の参照点として機能することを正当化する（実用上は「有効次元の候補範囲」として用いる）。実験 Exp-Syn-1 では、 $m = 1 \rightarrow 2$ の遷移で MSE が Swiss Roll において約 35 倍改善することで確認される（§ 5.2）。

注意 1 (既存研究との関係). 本定理は既知の解析群——Lucas et al. [21] の線形 VAE における *posterior collapse* の議論, Tipping & Bishop [5] の PPCA ($\beta = 1$ の特殊ケースに相当), Shannon の水充填定理 [1]——と密接に関連しており、新規性はこれらを $\beta \neq 1$ の β -ELBO に対する閉形式しきい値 $\lambda_j > \beta\tau^2$ と単調飽和性として統合的に整理した点に限られる。本定理の役割は新しい数学的結果の提示ではなく、非線形実験を解釈するための定量的な参照点の提供である。

定理 1 (線形ガウス rate-distortion 近似における AU 活性化しきい値). 線形エンコーダ・デコーダ・ガウス

事前分布を持つ β -VAE（詳細設定は付録 A）において、**線形ガウス rate-distortion 近似のもとで**、水充填定理と KKT 条件から次が導かれる：

1. **（活性化しきい値）** 第 j 固有方向が活性となる条件は

$$\lambda_j > \beta\tau^2 \quad (5)$$

である．ここで λ_j は**センタリング済み入力データの共分散行列** $\Sigma = \mathbb{E}[(x - \bar{x})(x - \bar{x})^\top]$ の第 j 固有値（すなわち入力空間 PCA 基底における第 j 主成分の分散）であり、 τ^2 はデコーダ出力の等方ガウス観測ノイズ分散である．

2. **（最適活性固有方向数の上界）** $A^*(m) \leq \min(m, d^*(\beta))$, $d^*(\beta) := |\{j : \lambda_j > \beta\tau^2\}|$
ここで $A^*(m)$ は大域最適解での活性固有方向数である．
3. **（最適解での単調飽和）** $A^*(m)$ は m について単調非減少であり、 $m \geq d^*(\beta)$ で飽和する ($A^*(m) = d^*(\beta)$)．

詳細な導出は付録 B に示す． $\beta\tau^2$ が水充填の「水面」として機能し、固有値がこれを超える固有方向のみが活性化される．本定理は学習済み非線形 VAE に関する定理ではなく、非線形実験を解釈するための**解釈的サロゲート** (interpretive surrogate) である．

注意 2 (経験的 AU との関係)．定理 1 の (3) は、大域最適解における活性固有方向数 $A^*(m)$ の単調性を示す．一方、実際の非線形 VAE では各 m に対して独立に確率的最適化を行うため、観測される経験的 $AU(m)$ は有限サンプル効果・初期値依存性・最適化ノイズにより**非単調になりうる**（表 9 で $m = 128$ の $AU = 26$ が $m = 64$ の $AU = 29$ を下回る例など）．したがって、経験的 m^{knee} は A^* の飽和点の厳密な推定値ではなく、 AU 曲線形状から得られる探索的診断指標として扱う必要がある．

証明スケッチ（詳細は付録 A）．各 PCA 方向 j の β -ELBO 寄与を独立に分析すると（線形ガウスモデルの標準結果）、方向 j を活性化することによる ELBO 利得 ΔL_j は $\lambda_j > \beta\tau^2$ のときのみ正となる（Shannon の水充填定理との対応）．各次元の独立性より、最適 AU 数と $d^*(\beta)$ との関係および単調飽和性が従う． $\square$

注意 3. 含意：(i) $\beta\tau^2$ の上昇（強い正則化・大きいノイズ）は活性次元数を減少させる．(ii) *Vanilla AE* は $\beta = 0$ の極限に対応し、しきい値が消失するため潜在座標利用数は m に近づく（実験 *Exp-Syn-AU* と整合；§ 5.2）．(iii) 実データへの定性的拡張として「有効 SNR が β を下回る次元は圧縮される」という経験則を与える．

命題 2 (理想化単調飽和モデルにおける m^{knee} のグリッド分解能依存性)． $AU(m)$ が $d^*(\beta)$ で理想的に単調飽和する（階段的に変化し、確率的ノイズを持たない）理想化モデルを仮定する．このとき、グリッド $\mathcal{G} = \{m_1 < \dots < m_K\}$ 上での $m^{\text{knee}}(\mathcal{G})$ に対して

$$|m^{\text{knee}}(\mathcal{G}) - d^*(\beta)| \leq \max_i (m_{i+1} - m_i) \quad (6)$$

が成立する（誤差はグリッド間隔の最大値に上界される）．

注意：実際の非線形 VAE ではこの理想化が成立せず、確率的最適化による $AU(m)$ の形状ノイズにより、式 (6) の上界を大幅に超えた誤差が生じうる（§ 5.3.4 の観測と一致）．本命題は一般的な不安定性定理ではなく、グリッド設計の指針を与える補題として扱う．

Proof. 理想化単調飽和モデルでは $AU(m)$ が $d^*(\beta)$ で段階的に変化するため、 $d^*(\beta) \in [m_{i_0}, m_{i_0+1})$ なら $m^{\text{knee}} = m_{i_0+1}$ （または m_{i_0} ）と検出される．誤差 $\leq m_{i_0+1} - m_{i_0} \leq \max_i (m_{i+1} - m_i)$ ． $\square$

注意 4. 本命題の実験的含意：グリッド $\{4, 8, 12, 16, 20, 32, 64\}$ では最大間隔 32 ($32 \rightarrow 64$) があり、 $d^* \approx 10$ に対して $m^{\text{knee}} \in \{32, 64\}$ という大きな誤差が生じうる（§ 5.3.4 と整合）．密グリッドと複数シードのアンサンブルが実用的な安定化策となる（§ 6.2）．

命題 3 (プルバック計量と局所等長性). デコーダ $g: \mathbb{R}^m \rightarrow \mathbb{R}^N$ が点 z の近傍で局所等長であるための必要十分条件は, プルバック計量 $G(z) = J_g(z)^\top J_g(z) = I_m$ である. すなわち, 任意の微小変位 dz に対して $\|J_g(z)dz\|^2 = \|dz\|^2$ が成り立つことと, $G(z) = I_m$ (全特異値が 1) は同値である.

一方, 条件数 $\kappa(z) = \sigma_{\max}(J_g)/\sigma_{\min}(J_g)$ は局所写像の異方性を測る指標であり, $\kappa = 1$ は全特異値が等しい (等方的スケーリング) ことを意味するが, そのスケールが 1 であることまでは保証しない. 例えば J_g が全方向を 2 倍に拡大する場合, $\kappa = 1$ だが等長ではない. したがって, 本稿では κ を等長性そのものではなく, 局所的な異方性を示す補助指標として用いる.

Proof. 等長性の定義より, 任意の $dz \in \mathbb{R}^m$ に対し $\|J_g dz\|^2 = \|dz\|^2$ は $J_g^\top J_g = I_m$ (全特異値が 1) と等価である. $\kappa = 1$ は全特異値が等しいことのみを意味し, その値が 1 かは別問題であるから, $\kappa = 1$ は等長性の必要十分条件ではない (上記例参照). $\square$

本命題は, 参照 AE を用いた ID 推定において等長性バイアスが生じる理由 (§ 6.7) および IsometricAE の動機 (実験 Exp-Syn-Iso) を与える.

その他の解釈的命題 (デコーダヤコビアンの実効階数, ノイズ方向選択性, 近傍構造保存) は付録 A に記載する.

4.1 線形理論と非線形実験の定性的対応

定理 1 (水充填原理) は線形ガウス rate-distortion 近似のもとで成立する. 非線形設定では, 強力なデコーダが実効的なノイズ分散 $\tau_{\text{eff}}^2 \ll 1$ を達成するため, $d^*(\beta) = |\{j: \lambda_j > \beta \tau_{\text{eff}}^2\}|$ は線形仮定 ($\tau^2 = 1$) の予測より大幅に大きくなる. また, 非線形最適化による滑らかな AU 増加曲線は, 線形設定での段差的な飽和転換に替わり, m^{knee} の疎グリッドでの不安定性をもたらす.

これらの定性的継承 (AU 単調性, 有効次元超過後の増加鈍化) と定量的乖離を MNIST PCA スペクトル分析 (実験 Exp-Mnist-PCA) で実証する (§ 5.3.5).

4.2 TwoNN の条件付き安定性: 理論的定式化

本節では § 5.2.4 の実験的観察 (Exp-Stab · Exp-Geom · Exp-Iso-ID) を受け, 「どのような条件なら TwoNN を補助的参照推定量として使えるか」を説明的命題として理論的に支える. **本命題は TwoNN の不偏性 (unbiasedness) を保証するものではなく, 条件付き安定性 (conditional stability) の十分条件のスケッチを与える解釈的命題である** (数学的な厳密定理ではなく, 設計指針の理論的根拠として位置づける).

命題 4 (TwoNN の条件付き安定性). エンコーダ $f: \mathbb{R}^N \rightarrow \mathbb{R}^m$ が局所 *bi-Lipschitz*, すなわち任意の点 z の近傍 U において

$$(1 - \varepsilon)\|v\| \leq \|J_f \cdot v\| \leq (1 + \varepsilon)\|v\|, \quad \varepsilon \in [0, 1) \quad (7)$$

を満たし, かつ近傍順位 (*nearest neighbor rank*) が高確率で保存されるとする ($\text{Trustworthiness} \geq 1 - \delta_T$; δ_T 小). このとき, 2 近傍距離比 r_2/r_1 の経験分布の地球移動距離 (EMD) 変化は

$$\text{EMD}(P_{r_2/r_1}^{(\text{input})}, P_{r_2/r_1}^{(\text{latent})}) \leq C(\varepsilon, \delta_T) \quad (8)$$

で抑えられ, したがって *TwoNN* 推定値のずれ $|\hat{d}_{\text{ID}}^{(\text{latent})} - \hat{d}_{\text{ID}}^{(\text{input})}|$ も $C(\varepsilon, \delta_T)$ に支配される定数で上界される. ($C(\varepsilon, \delta_T) \rightarrow 0: \varepsilon \rightarrow 0$ かつ $\delta_T \rightarrow 0$ のとき.)

Proof. 証明スケッチ: 式 (7) より, 距離 $d(x_i, x_j)$ の変化率は $(1 - \varepsilon)^2 \sim (1 + \varepsilon)^2$ の範囲に収まる. 距離比 r_2/r_1 は絶対距離でなく比率であるため, スケールの均一な変形 (global rescaling) はキャンセルされるが, $\varepsilon \neq 0$ の非等長成分が比率を変化させる. $\text{Trustworthiness} \geq 1 - \delta_T$ は「2 近傍が潜在空間でも入力空間と高確率で一致すること」を保証し, 順位逆転による大きな r_2/r_1 の変動を確率的に抑える. これら 2 条件の下で,

r_2/r_1 の分布変化は ε と δ_T の連続関数 $C(\varepsilon, \delta_T)$ で上界される ($\varepsilon = 0, \delta_T = 0$ のとき $C = 0$, 等長・完全近傍保存の場合に一致). (有限サンプル・有限次元での近似; 厳密なバウンドは等長定数の具体的な設定に依存する.) $\square$

注意 5 (命題 4 の実験的含意). 本命題は「等長性 $\varepsilon \approx 0$ が *TwoNN* 精度の唯一の条件」ではなく, 「 $m \gg d_{\text{ID}}$ による *Trustworthiness* の向上 (近傍順位の保存) が安定性の支配的因子」である可能性を示唆する. 実験 *Exp-Stab* (§ 5.2.4) では $\kappa \in [1.06, 2.16]$ の範囲で *TwoNN ID* の差が最大 $\pm 2.3\%$ に留まった一方, $m = d_{\text{true}}$ から $m > d_{\text{true}}$ への移行で *TwoNN* が回復した— δ_T (近傍逆転率) の減少が ε (等長性) の変化より支配的であることと整合する. 本命題は *TwoNN* を「真の d_{ID} の不偏推定量」と主張するものではなく, 「どの条件なら補助的参照推定量として運用可能か」を理論で支えるものである. 実験 *Exp-Real-Geom* (§ 5.10) はこの含意を実データで直接検証する.

5 実験

実験の 3 層分類: 本論文の実験は, 以下の 3 層に明確に分類される (表 3 の「位置づけ」列に対応).

主実験 (フレームワーク中核の実証) *Exp-Syn-1*, *Exp-Syn-AU*, *Exp-Mnist-Base*, *Exp-Mnist-Multi*, *Exp-Mnist-Dense*, *Exp-Fashion*, *Exp-Real-Geom*, *Exp-Nat-Cifar*. AU 値・TwoNN ID の頑健性 (RQ2) および m^{knee} の安定化条件 (RQ1) を主要検証対象とする.

補助実験 (主実験の前提条件・解釈論の検証) *Exp-Stab*, *Exp-Geom*, *Exp-Iso-ID*, *Exp-Syn-Iso*, *Exp-Conv-AE*, *Exp-Syn-Top*, *Exp-Mnist-PCA*, *Exp-Mnist-Dyn*, *Exp-Mnist-Ent*. TwoNN 数値安定性・IsometricAE 等長性・理論-実験橋渡し等を検証する (主要主張の支持根拠).

限界検証実験 (適用可能範囲と境界条件の定量化) *Exp-Conv-Fix*, *Exp-Conv-Ann*, *Exp-Conv-M256*, *Exp-Conv-M512*, *Exp-ConvV-HiBeta*, *Exp-NatImg-AU*, *Exp-NatImg-Sweep*, *Exp-NatImg-Knee*. Conv-VAE・自然画像での $\text{AU}/m^{\text{knee}}$ 安定同定が困難な条件を定量化し, フレームワークの validity range (適用可能範囲) と applicability boundary (適用限界) を確定する.

5.1 実験設定

モデル共通: Adam ($\text{lr} = 10^{-3}$), バッチサイズ 128, ReLU (出力層 Sigmoid), 乱数シード 42, PyTorch 2.0.

合成多様体: 隠れ層 [64, 32], 200~300 エポック, VAE $\beta = 4.0$, $n = 5,000$ (学習 4,000 / テスト 1,000).

MNIST / Fashion-MNIST: 入力次元 784, 隠れ層 [512, 256], VAE $\beta = 4.0$, グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$, バッチサイズ 128. MNIST は 300 エポック ($n_{\text{train}} = 20,000$, $n_{\text{test}} = 3,000$), Fashion-MNIST は 100 エポック ($n_{\text{train}} = 10,000$, $n_{\text{test}} = 2,000$).

ID 推定: TwoNN ($k = 2$; アルゴリズムの定義により $k = 2$ が唯一の選択)・MLE ($k = 10$; Levina & Bickel[9] の推奨範囲 $k = 5 \sim 20$ の中央付近, $k = 5, 10, 20$ での安定性も確認済み) [8, 9]. AU 閾値 $\delta = 10^{-2}$ [21] (この閾値選択に対して AU は極めて頑健であり, $\delta \in [10^{-3}, 10^{-1}]$ の変動で AU 値はほぼ変化しないことを感度分析で確認済み; 付録 G).

計算環境・再現性: 全実験は単一の NVIDIA GeForce RTX 3070 GPU を備えた Linux ワークステーション (PyTorch 2.0, CUDA; CUDA 不可時は CPU にフォールバック) で実行した. 計算コストの主部は m グリッド $\times$ シードにわたる学習の反復であり, 主要な多シード・スイープ実験 (例: MNIST FC-VAE, グリッド 7~17 点 $\times$ 3 シード $\times$ 300 エポック) は本環境で数時間~1 日程度, 論文全体では GPU 時間で数日規模を要する. 実験コード・設定・生ログ (JSON) は査読時に補助資料として提供する. 各実験の設定一覧

(データセット・モデル・エポック数・ β スケジュール・ m グリッド・シード数・サンプル数・位置づけ) は付録 H の表 33 にまとめ、**単一シードの結果は本文の表・図キャプションにもその旨を明記する**。

表 3: Summary of experiment groups. Detailed per-experiment configurations (epochs, β schedule, m grid, seeds, sample size, role) are listed in Table 33 (付録 H). Categories: main experiments (core framework validation), supplementary experiments (prerequisite verification), boundary experiments (validity range quantification).

Experiment Group	Objective	Main Data	Category
Synthetic manifold experiments (Exp-Syn-1, Exp-Syn-AU, Exp-Syn-Iso, Exp-Syn-Top)	Principle verification (MSE elbow, AU saturation, isometry)	Swiss Roll, Torus, Möbius, etc.	Main + Supplementary
FC-AE/VAE experiments (Exp-Mnist-Base, Exp-Mnist-Multi, Exp-Mnist-Dense, Exp-Fashion, Exp-Stab, Exp-Geom, Exp-Iso-ID, Exp-Real-Geom)	Core validation of the multi-indicator diagnostic framework (robustness of AU values and TwoNN ID, m^{knee} stabilization, TwoNN applicability conditions)	MNIST, Fashion-MNIST (FC-AE/VAE)	Main
Conv-VAE experiments (Exp-Conv-AE, Exp-Conv-Fix, Exp-Conv-Ann, Exp-Conv-M256, Exp-Conv-M512, Exp-ConvV-HiBeta)	Identifying the cause of AU saturation delay in Conv-VAEs and determining the validity range	MNIST (Conv-AE/VAE)	Supplementary + Boundary
Natural image experiments (Exp-Nat-Cifar, Exp-Nat-SVHN, Exp-NatImg-AU, Exp-NatImg-Sweep, Exp-NatImg-Knee)	Validation of external validity of TwoNN auxiliary estimates; quantification of applicability boundary in natural image settings	CIFAR-10, SVHN	Supplementary + Boundary

5.2 合成多様体実験：原理確認 (RQ1・RQ2・RQ3)

合成多様体 (d_{true} 既知) を用いて、提案フレームワークの原理的妥当性を確認する。

5.2.1 MSE 肘点と内在次元の対応 (実験 Exp-Syn-1)

Swiss Roll ($d_{\text{true}} = 2$, 単連結) および Torus ($d_{\text{true}} = 2$, $d_{\text{emb}} = 3$) において, AE の MSE が $m = d_{\text{true}}$ (Swiss Roll) または $m = d_{\text{emb}}$ (Torus) で急激に改善することを確認した (表 4)。

表 4: Exp-Syn-1: MSE of AE on synthetic manifolds (mean $\pm$ std over 3 seeds).

m	Swiss Roll MSE	Torus MSE
1	1.016 ± 0.315	0.356 ± 0.022
2	0.029 ± 0.001 $\leftarrow$ 肘点	0.109 ± 0.007
3	$(6 \pm 2) \times 10^{-4}$	$(4 \pm 3) \times 10^{-4}$ $\leftarrow$ 肘点
4	$(5 \pm 1) \times 10^{-4}$	$(1.0 \pm 0.4) \times 10^{-4}$

Swiss Roll では $m = 1 \rightarrow 2$ で MSE が約 35 倍改善し, 命題 1 を実験的に確認する. Torus では $m = 3$ ($= d_{\text{emb}}$) で肘点が現れ, $d_{\text{ID}} = 2$ では完全な再構成が不可能であることを示す。

5.2.2 AU 飽和と位相的構造 (実験 Exp-Syn-AU • Exp-Syn-Top)

VAE ($\beta = 4$) の AU パターンを, Vanilla AE と比較した (表 5). **注意**: AE に対する表中の「AU」は各潜在座標の符号化分散 $> \delta$ で定義した pseudo-AU (KL 正則化のない AE では AU は本来定義されない) であり, 補助的な観察である.

表 5: Exp-Syn-AU: VAE active units (AU) for Swiss Roll (upper) and Torus (lower) (mean $\pm$ std, 3 seeds).

	m	Vanilla AE (AU)	VAE (AU, $\beta = 4$)
Swiss Roll ($d_{\text{true}} = 2$)	2	2	2.0 ± 0.0 (saturation)
	4	4	2.0 ± 0.0
	8	8	2.0 ± 0.0
	16	16	2.0 ± 0.0
Torus ($d_{\text{true}} = 2, d_{\text{emb}} = 3$)	4	4	2.0 ± 0.0
	6	6	3.0 ± 0.0 (saturation)
	8	8	3.0 ± 0.0
	16	16	3.0 ± 0.0

Vanilla AE では $AU = m$ (飽和なし) であるのに対し, VAE では Swiss Roll で $AU_{\text{sat}} = 2$ ($= d_{\text{true}}$), Torus で $AU_{\text{sat}} = 3$ ($= d_{\text{emb}} > d_{\text{ID}}$) となる (全 3 シードで標準偏差 0.0). これは定理 1 (水充填的 AU 飽和機構) の定性的含意と整合し, Torus において KL 正則化が位相的埋め込み次元付近で圧縮を始める可能性を示唆する (本研究条件下での経験的観測; 前処理依存性・条件付きの知見に注意).

実験 Exp-Syn-Top (位相的多様体での AU_{sat} と d_{emb} の対応) の結果を表 6 に示す.

表 6: Exp-Syn-Top: Topological manifolds and VAE AU_{sat} (standardized conditions; Swiss Roll excluded from the main evidence, see text).

Manifold	d_{ID}	π_1	d_{emb}	AU_{sat} (standardized)
Torus T^2	2	$\mathbb{Z}^2$	3	3 (main result)
Möbius Band	2	$\mathbb{Z}$	3	3 (main result)
Circle S^1	1	$\mathbb{Z}$	2	2 ($m \geq 6$, conditional)

注意: Swiss Roll の AU_{sat} は前処理依存性が高い (標準化条件で 2, 別条件で 3) ため, AU_{sat} と d_{emb} の対応を支持する主証拠は Torus • Möbius Band ($AU_{\text{sat}} = d_{\text{emb}} = 3$) に限定する. この対応も本研究条件 (標準化前処理, $\beta = 4$, 十分な収束) に依存する経験的観測であり, 理論的必然性は保証されない (§ 6).

5.2.3 IsometricAE による等長性の達成 (実験 Exp-Syn-Iso)

Swiss Roll ($m = 2$) において, 4 種類のモデルの等長性を比較した (表 7).

表 7: Exp-Syn-Iso: Comparison of four models on Swiss Roll ($m = 2$) (mean $\pm$ std, 3 seeds).

Model	MSE	κ	NSR
AE	0.030 ± 0.003	1.251 ± 0.184	0.979 ± 0.036
CAE	0.036 ± 0.008	1.438 ± 0.105	0.659 ± 0.105
IsometricAE	0.029 ± 0.003	1.040 ± 0.009	0.753 ± 0.051
DAE	0.032 ± 0.003	1.179 ± 0.139	0.609 ± 0.085

IsometricAE のみが $\kappa \approx 1.04$ (等長性) を達成し (命題 3 と整合), MSE を大きく犠牲にせずに等長潜在

空間を実現できることを示す．等長潜在空間は ID 推定の信頼性を高める前提条件であり，Stage 1 の ID 推定の理論的精度向上に貢献する（計算コストとのトレードオフあり；§ 6.7）．

5.2.4 TwoNN ID の数値安定性と κ の影響（実験 Exp-Stab・Exp-Geom・Exp-Iso-ID，詳細は付録 E）

3つの補助実験——Exp-Stab (Swiss Roll での κ が TwoNN 推定に与える影響の検証)，Exp-Geom (MNIST AE の m スweepによる TwoNN 収束確認)，Exp-Iso-ID (IsometricAE と通常 AE の多次元 ID 推定比較)——から一貫したメッセージが得られた：「 κ の大小ではなく $m \gg \hat{d}_{\text{ID}}$ という条件が TwoNN 安定性の支配的因子」である．なお，Exp-Stab と Exp-Iso-ID はデータ生成・学習走行が独立した別実験であるため，両者の TwoNN 推定値の絶対値（例： $m = 2$ の AE で前者 1.55，後 1.78）は直接比較できず，各実験内での相対比較のみが意味を持つ．

Exp-Stab (Swiss Roll) では， $m = 2 = d_{\text{true}}$ で AE ($\kappa = 1.79$) も IsometricAE ($\kappa = 1.06$) も同程度に TwoNN ≈ 1.55 と過小推定するが， $m = 4 > d_{\text{true}}$ では TwoNN ≈ 2.03 へ回復した（ボトルネック余裕不足が主因； κ 差の影響は軽微）．Exp-Geom (MNIST AE m スweep) では， $m \geq 48 \approx 5\hat{d}_{\text{ID}}$ で TwoNN が 10.16 へ安定収束し， κ が $4.25 \rightarrow 37.0$ と急増する $m = 64 \sim 128$ でも TwoNN は $10.17 \sim 10.98$ と安定を維持した（詳細表は付録 E，表 25）．Exp-Iso-ID (Swiss Roll, $m \in \{2, 3, 4, 6, 8\}$) では， $m \geq 3$ で $\kappa \in [1.1, 2.1]$ の差があっても TwoNN ID の差は $\pm 2.3\%$ 以内にとどまった（詳細表は付録 E，表 26）．

これら 3 実験の知見は，Stage 1 で参照 AE ($m_{\text{ref}} = 256 \gg \hat{d}_{\text{ID}} \approx 10$) を使う設計根拠を補強し， $m < 32 \approx 3\hat{d}_{\text{ID}}$ では過小推定リスクがある点も示す（「数値的安定」は「幾何学的に正確」を意味しない点に留意；§ 6.7）．




図 2: Exp-Stab/Exp-Geom: (Left) TwoNN ID on Swiss Roll — AE and IsometricAE both underestimate at $m = d_{\text{true}}$; TwoNN recovers at $m = 4 > d_{\text{true}}$. (Right) MNIST AE m -sweep: TwoNN stabilizes at $m \geq 48$ despite κ jumping to 37.0 at $m = 128$. Detailed tables in 付録 E.

5.3 MNIST：有効表現次元の読み取り（主実験，RQ1・RQ2）

MNIST データセットを用いて，提案フレームワークの実データへの適用を検証する（主実験）．MNIST は「実データであり， d_{true} は未知であるが $\hat{d}_{\text{ID}}$ を推定できる」という意味で，フレームワークの現実的な評価環境を提供する．

5.3.1 AE による内在次元の推定（実験 Exp-Mnist-Base-AE）

MNIST AE (300 エポック) の結果を表 8 に示す．

表 8: Exp-Mnist-Base: MNIST AE results (300 epochs, $n_{\text{train}} = 20,000$; **single seed 42**).

m	MSE	TwoNN ID	MLE ID	CKA
1	0.0437	1.02	1.15	0.102
4	0.0292	3.86	4.29	0.575
8	0.0191	6.08	6.70	0.725
16	0.0121	7.96	8.61	0.812
32	0.0087	8.84	9.89	0.875
64	0.0062	9.54	11.26	0.908
128	0.0061	9.84	11.45	0.921
256	0.0057	10.02	11.85	0.953

$m \geq 64$ で TwoNN ID (9.54~10.02) と MLE ID (11.26~11.85) が収束し, MNIST の実効内在次元が概ね $\hat{d}_{\text{ID}} \approx 10 \sim 12$ の範囲にあることを示す.

線形 PCA との比較: MNIST ($n = 20,000$) に PCA を適用すると, 累積寄与率 80% に 43 次元, 90% に 86 次元が必要である. AE (TwoNN ≈ 10) の推定値と比較して 4~8 倍大きく, MNIST の非線形な多様体構造を示している (図 3 参照).

5.3.2 VAE の AU Dynamics と m^{knee} (実験 Exp-Mnist-Base-VAE)

MNIST VAE ($\beta = 4$, 300 エポック) の AU パターンを表 9 および図 3 に示す.

表 9: Exp-Mnist-Base: MNIST VAE ($\beta = 4$) results (300 epochs; **single seed 42**). AU increase rate slows at $m = 12$ ($m^{\text{knee}} = 12$; preliminary, not reproduced in multi-seed runs).

m	MSE	AU	TwoNN ID	Change in $\rho(m)$
1	0.0464	1	1.00	—
4	0.0275	4	3.72	normal increase
8	0.0186	8	6.36	normal increase
12	0.0184	8	6.26	sharp drop $\leftarrow m^{\text{knee}} = 12$
16	0.0148	11	7.18	low
20	0.0134	13	7.59	low
32	0.0121	15	8.25	low
64	0.0103	29	9.16	gradual
128	0.0085	26	10.02	gradual
256	0.0072	36	10.14	gradual

$m = 12$ で AU = 8 (前の $m = 8$ と同じ) となり, 正規化増加率 $\rho(m)$ が急落する ($\rho(12) \approx 0$). $\tau_{\text{knee}} = 0.25$ の閾値をトリガーし, $m^{\text{knee}} = 12$ と観測される.

注意: この $m^{\text{knee}} = 12$ は単一シード (seed 42) ・特定の拡張グリッド ($m \in \{1, 4, 8, \dots, 256\}$) での予備的観察であり, 多シード実験 (§ 5.3.4) では再現されない (本論文の主要な安定化結果は Exp-Mnist-Dense-300; § 5.3.6).




図 3: Exp-Mnist-Base: m -dependence of each indicator for MNIST (300 epochs). **Left (AE)**: MSE (log scale, left axis) and TwoNN ID (right axis). Vertical dotted lines correspond to PCA cumulative variance 80% (43 dims), 90% (86 dims), 95% (152 dims); the difference from the nonlinear AE estimate (TwoNN ≈ 10) is clear. **Right (VAE, $\beta = 4$)**: MSE (log scale, left axis), AU (right axis), TwoNN ID (right axis, dashed). At $m = 12$ (m^{knee}), the AU increase rate drops sharply (arrow), indicating a heuristic slowdown point; the main stabilized result is $m^{\text{knee}} = 10.3 \pm 0.9$ from Exp-Mnist-Dense-300 (§ 5.3.6).

5.3.3 既存指標との比較

提案指標 m^{knee} を，他の代表的なボトルネック次元設計指標と比較する（表 10）。

表 10: Comparison of bottleneck dimension estimates on MNIST. m^{knee} entries distinguish sparse-grid and dense-grid conditions.

Method	Estimate	Source	Characteristics / Limitations
PCA (80% var.)	43	Exp-Mnist-Base-AE	Linear; overestimates nonlinear ID
PCA (90% var.)	86	Exp-Mnist-Base-AE	Linear; larger overestimate
MSE elbow (AE)	≈ 16 –20	Exp-Mnist-Base-AE	Intuitive; depends on smoothing
TwoNN ID (ref. AE)	≈ 10 –12	Exp-Mnist-Base-AE	Nonlinear; subject to isometry bias
m^{knee} sparse-grid (3 seeds)	43 ± 15	Exp-Mnist-Multi-300	Exploratory; unreliable at sparse grid
m^{knee} dense-grid (3 seeds)	10.3 ± 0.9	Exp-Mnist-Dense-300	TwoNN-guided local refinement; requires dense grid + multi-seed

Dense-grid: $m \in \{8, 9, \dots, 16, 18, \dots, 64\}$ with independent initialization per (m, seed) ; the dense region was placed around the TwoNN estimate (≈ 10), so the agreement is a TwoNN-guided refinement, not an independent validation. Sparse-grid $m^{\text{knee}} = 43 \pm 15$ is unreliable as a diagnostic reference.

PCA は線形手法のため非線形な多様体構造を反映できず AE 推定の 4 倍以上の次元を要求し，MSE エルボーは平滑な MSE 曲線では肘点の決定が曖昧になりやすい。 m^{knee} は KL ダイナミクスを直接観察する点でこれらと相補的だが， $\tau \cdot \beta \cdot m$ グリッドへの依存性があり，多指標アプローチでの使用が前提となる。

5.3.4 多シード検証（実験 Exp-Mnist-Multi-150・Exp-Mnist-Multi-300）

m^{knee} の統計的信頼性と収束度の影響を評価するため、MNIST VAE ($\beta = 4$, $m \in \{4, 8, 12, 16, 20, 32, 64\}$) を 3 つの乱数シード (42, 123, 777) で、150 エポック (Exp-Mnist-Multi-150) および 300 エポック (Exp-Mnist-Multi-300) の 2 条件で学習した。300 エポック条件の結果を表 11 に示す (150 エポック条件の m^{knee} は表 12 に要約; AU・TwoNN ID の傾向は 300 エポック条件と同一で、 $m = 64$ の TwoNN ID は 9.94 ± 0.08 であった)。

表 11: Exp-Mnist-Multi-300: Mean $\pm$ std of AU and TwoNN ID for 3 seeds at 300 epochs ($\beta = 4$). AU and TwoNN ID are highly consistent, but m^{knee} still varies.

m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	Note
4	4.0 ± 0.0	3.98 ± 0.14	all dims active
8	8.0 ± 0.0	6.67 ± 0.15	
12	10.0 ± 0.0	7.41 ± 0.06	
16	11.7 ± 0.5	7.95 ± 0.21	AU still increasing
20	13.3 ± 0.5	8.37 ± 0.14	
32	15.7 ± 0.5	9.07 ± 0.10	
64	22.3 ± 0.5	10.03 ± 0.12	converges to $\hat{d}_{\text{ID}} \approx 10$

m^{knee} ($\tau = 0.25$): シード 42 = 64, シード 123 = 32, シード 777 = 32
 平均 $m^{\text{knee}} = 43 \pm 15$ (300 エポック)




図 4: Exp-Mnist-Multi: AU patterns of MNIST VAE (3 seeds, 300 epochs). Left: AU vs m per seed (dotted lines: m^{knee}); Right: mean $\pm$ std band. AU and TwoNN ID bands are very narrow, but m^{knee} varies between 32 and 64 across seeds.

主要知見： AU 値 (表 11) は両エポック条件とも 3 シード間で高度に一致し ($\sigma \leq 0.5$), TwoNN ID も $m = 64$ で 10.03 ± 0.12 (300 エポック) と安定している。一方, m^{knee} ($\tau = 0.25$) は 150 エポックで 53 ± 15 (シード別 64, 32, 64), 300 エポックの完全収束下でも 43 ± 15 (64, 32, 32) と、いずれも 32~64 の範囲で変動した。これは正規化増加率 $\rho(m)$ が閾値 $\tau = 0.25$ 付近で複数の m にわたり微妙に揺動するためであり、エポック数の延長では解消されない—— m^{knee} **不安定性の主因は収束不足ではなく m グリッドと乱数シードへの依存**である。Exp-Mnist-Base 拡張実験 (単一シード 42) で観測された $m^{\text{knee}} = 12$ も本条件では再現されず、グリッド設計と初期化経路に依存する予備的観察にとどまる。本論文では TwoNN 推定値近傍の密グリッド・独立初期化・複数シード条件による Exp-Mnist-Dense-300 の $m^{\text{knee}} = 10.3 \pm 0.9$ を主要な安定化結

果として扱う (§ 5.3.6).

5.3.5 線形理論—実験橋渡し (実験 Exp-Mnist-PCA, 詳細は付録 E)

MNIST PCA スペクトル ($\lambda_1 = 5.22, \dots, \lambda_{10} = 1.23$) と定理 1 を対照すると, $\tau_{\text{eff}}^2 \approx 0.30$ (逆算値) で $d^* \approx 10$ となり観測 TwoNN ID と定性的に整合する. 線形設定では鋭い飽和転換が生じるが, 非線形 VAE では勾配競合により滑らかな漸増曲線となるため, m^{knee} の疎グリッドでの不安定性が理論的に裏付けられる (詳細な PCA スペクトル表・理論-実験比較表は付録 E). Conv-VAE では非線形デコーダの強力な再構成能力により τ_{eff}^2 がさらに小さくなり, AU 飽和に必要な m が FC-VAE 比で大幅に増大する (§ 6.6).

5.3.6 密グリッドによる TwoNN 誘導型局所精密化 (実験 Exp-Mnist-Dense)

m^{knee} の不安定性がどの要因に起因するかを特定するため, グリッド密度・エポック・シードの 3 要因を単離した実験を設計した. Exp-Mnist-Base と Exp-Mnist-Multi では既にエポック因子 (150ep vs. 300ep) とシード因子 (3 シード) が分離されている. 本実験 Exp-Mnist-Dense ではさらにグリッド密度因子を単離する: $m \in \{8, 9, 10, 11, 12, 13, 14, 15, 16, 18, 20, 24, 28, 32, 40, 48, 64\}$ (17 点, 隣接点間隔 1~16; 推定 ID 近傍の $m = 8 \sim 16$ は 1 刻み) で 300 エポック・3 シードで学習した. **位置づけの明示**: 密領域 ($m = 8 \sim 16$) は Stage 1 の TwoNN 推定値 ($\hat{d}_{\text{ID}} \approx 10$) の近傍に置いたものであり, 候補領域の選択自体が同一フレームワークの TwoNN 推定に依存する. したがって, 後述の m^{knee} と TwoNN ID の一致は **TwoNN 誘導型の局所精密化** (TwoNN-guided local refinement) の成功を示すものであり, TwoNN と独立な相互検証ではない (事前登録した広域密グリッドや, 探索領域の推定と m^{knee} 評価を別シード・別データ部分集合で行う nested validation による独立性の確保は今後の課題である).

表 12: Exp-Mnist-Dense: Comparison of m^{knee} between dense and sparse grids ($\tau = 0.25$, MNIST FC-VAE, $\beta = 4$). Consistent with the grid-sensitivity bound of Proposition 2.

Condition	Max. grid interval	seed=42	seed=123	seed=777	Mean $\pm$ std
Sparse, 150ep (Exp-Mnist-Multi-150)	32	64	32	64	53 $\pm$ 15
Sparse, 300ep (Exp-Mnist-Multi-300)	32	64	32	32	43 $\pm$ 15
Dense, 300ep (Exp-Mnist-Dense-300)	16 (step 1, 8–16)	11	9	11	10.3 $\pm$ 0.9

表 13: Exp-Mnist-Dense: Per-seed AU(m) curves for the full dense grid (300ep, all 3 seeds). The AU curves fluctuate non-monotonically in the transition region ($m = 11 \sim 16$).

m	8	9	10	11	12	13	14	15	16	18	20	24	28	32	40	48	64
AU (seed 42)	8	9	10	10	10	10	12	11	14	13	15	14	15	15	18	19	21
AU (seed 123)	8	8	10	9	11	10	11	13	12	14	13	15	14	17	19	19	21
AU (seed 777)	8	9	10	10	11	10	11	11	12	12	13	15	16	18	18	20	21




図 5: Exp-Mnist-Dense: (Left) Dense-grid AU vs m (3 seeds, 300ep). (Right) Comparison by grid density $\times$ epochs. m^{knee} variation in the dense grid can be assessed by the upper bound of Proposition 2 (maximum grid interval).

Exp-Mnist-Dense 実験の意義：表 12 の 3 行比較により，3 要因（グリッド密度・エポック・シード）が定量的に単離される：

- **エポック因子**：疎グリッド 150ep $\rightarrow$ 300ep (m^{knee} : $53 \pm 15 \rightarrow 43 \pm 15$) —— エポック増加で若干安定するが，主因ではない
- **シード因子**：同一条件の 3 シード間での変動 ($\sigma = 15$) —— 初期化による最適化経路の差が影響するが，疎グリッドと共存する二次的因子
- **グリッド密度因子（主要因の一つ）**：密グリッド（Exp-Mnist-Dense）では $m^{\text{knee}} = 10.3 \pm 0.9$ （シード別に 11, 9, 11）—— 疎グリッド 43 ± 15 から大きく改善し，推定 $\hat{d}_{\text{ID}} \approx 10$ と整合する（ただし密領域を TwoNN 推定値近傍に置いた TwoNN 誘導型精密化としての整合である点に注意）

グリッド密度の効果（命題 2 の示唆との比較）：命題 2 は理想化単調飽和モデルに対する補助的な上界であり，非線形 VAE の経験的 AU 曲線に直接適用できるものではない．ただし，推定 ID 近傍 ($m = 8 \sim 16$) を間隔 1 で密に探索した結果， $m^{\text{knee}} \in \{9, 11\}$ (3 シード) となり，TwoNN ID (≈ 10) との乖離が大きく低下した．これは，命題 2 が理想化モデルで示したグリッド設計の重要性という示唆と，定性的に一致する結果である．ただし経験的な AU 曲線は非単調な揺動を示すため（例：表 13 で $\text{AU} = 10 \rightarrow 10 \rightarrow 10 \rightarrow 12 \rightarrow 11$ ），「上界以内に収まった」と主張するよりも，「グリッドを密にすることで経験的 m^{knee} の分散が大きく低下した」という観察として述べる方が正確である．

τ 法と二階差分法の比較： m^{knee} の検出には，本稿で採用している一階差分比率法 ($\tau = 0.25$) のほかに， $\text{AU}(m)$ 曲線の曲率が最大となる点を求める**二階差分法**（付録 C）がある．Exp-Mnist-Dense 密グリッドデータでの比較結果を表 14 に示す．

表 14: Exp-Mnist-Dense: Comparison of τ -method ($\tau = 0.25$) and second-difference method (d2) for m^{knee} detection (dense grid, 300ep, 3 seeds).

Method	seed=42	seed=123	seed=777	Mean $\pm$ std
τ -method ($\tau = 0.25$)	11	9	11	10.3 ± 0.9
Second-difference method (d2)	15	28	12	18.3 ± 6.8
Reference: $\hat{d}_{\text{ID}} \approx 10$ (TwoNN, $m = 64$, 3-seed mean)				

τ 法は平均 10.3 ± 0.9 と $\hat{d}_{\text{ID}} \approx 10$ に整合し，シード間変動が小さい．一方，d2 法は $\text{AU}(m)$ の離散的ノイ




図 6: Exp-Fashion: m -dependence of MSE, AU, and TwoNN ID for Fashion-MNIST AE (left) and VAE (right) (100 epochs). In the VAE, the AU growth rate drops sharply around $m = 12$ (m^{knee} at $\tau_{\text{knee}} = 0.25$), and TwoNN ID asymptotically converges to ≈ 9.4 (AE) and ≈ 8.7 (VAE) at $m \geq 32$.

ズに敏感で, seed=123 では $m^{\text{knee}} = 28$ と大きく外れた (AU 曲線の遷移域で AU が $8 \rightarrow 10 \rightarrow 9 \rightarrow 11 \rightarrow 10 \rightarrow 11 \rightarrow 13$ と揺動し, 二階差分の最大値点が乱れる). したがって, **密グリッド条件での m^{knee} 検出には τ 法の方が安定**であり, d2 法は大域的な「肘点」候補を探す補助手段として位置づける (付録 C 参照).

なお, MNIST VAE の $\text{AU}_{\text{sat}} = 36$ ($m = 256$) が $\hat{d}_{\text{ID}} \approx 10 \sim 12$ を大幅に超える点 (Manifold Entanglement 仮説) と, 学習ダイナミクスの 2 フェーズパターン (Exp-Mnist-Dyn) は, いずれも単一シード・予備的観察であり, 多シード検証は今後の課題として残す (§ 6.5 参照).

5.4 Fashion-MNIST への適用 (実験 Exp-Fashion, 予備的外部確認)

Fashion-MNIST (衣類 10 クラス, 28×28) は, フレームワークのシード・再現性の主張に対する予備的な外部確認として位置づける (主実験は MNIST 3 シード). 単一シード (seed 42) での確認であり, MNIST (3 シード) と同水準の再現性の主張はしない.

表 15: Exp-Fashion: Fashion-MNIST AE and VAE results (100 epochs, $n_{\text{train}} = 10,000$, representative m values; **single seed 42**).

AE			VAE ($\beta = 4$)		
m	MSE	TwoNN ID	m	MSE	AU
4	0.01831	3.90	4	0.01955	4
8	0.01389	5.86	8	0.01721	6
12	0.01230	7.58	12	0.01597	6
16	0.01138	8.11	16	0.01570	7
20	0.01077	8.45	20	0.01471	8
32	0.01010	8.99	32	0.01418	9
64	0.00981	9.39	64	0.01318	11
256	0.01009	9.42	256	0.01193	25

実験 Exp-Fashion の結果 (表 15, 図 6) から, 以下の知見が得られる. AE では pseudo-AU = m (全潜在座標が実質的に活性) かつ TwoNN ID が $m \geq 32$ で ≈ 9.4 に収束し, Fashion-MNIST の $\hat{d}_{\text{ID}} \approx 9 \sim 10$ が示唆される. VAE ($\beta = 4$, 単一シード) では $m^{\text{knee}} = 12$ ($\tau_{\text{knee}} = 0.25$) が観測されたが, これは単一シードの探索的観察であり, MNIST での多シード疎グリッド結果 ($m^{\text{knee}} = 43 \pm 15$) と同水準の再現性は保証されない点に注意が必要である. AU は $m = 256$ でも 25 にとどまり (MNIST の 36 と異なり), TwoNN ID

の推定値 ($\approx 9\sim 10$) も MNIST ($\approx 10\sim 12$) よりやや小さい。これらの差の解釈 (データセット間の局所自由度の違い等) にはより厳密な分析が必要であり、本稿では単一シードの観察として報告するにとどめる。

5.5 畳み込みアーキテクチャへの拡張 (実験 Exp-Conv-AE)

全結合型に限定した場合の一般化可能性への懸念に対し、畳み込み型 AE/VAE (Conv-AE/VAE) を MNIST に適用した実験 (実験 Exp-Conv-AE) を実施した。

Conv-AE/VAE アーキテクチャ：

- エンコーダ: $\text{Conv}(1 \rightarrow 32, k=3, \text{stride}=2) \rightarrow \text{Conv}(32 \rightarrow 64, k=3, \text{stride}=2) \rightarrow \text{FC}(3136 \rightarrow m)$
(VAE では $\rightarrow \mu, \log \sigma^2$)
- デコーダ: $\text{FC}(m \rightarrow 3136) \rightarrow \text{ConvT}(64 \rightarrow 32, k=4, \text{stride}=2) \rightarrow \text{ConvT}(32 \rightarrow 1, k=4, \text{stride}=2) \rightarrow \text{Sigmoid}$
- $n_{\text{train}} = 20,000$, 100 エポック, $m \in \{4, 8, 12, 16, 20, 32, 64\}$, seed 42

表 16: Exp-Conv-AE: MNIST Conv-AE and Conv-VAE ($\beta = 4$) results (100 epochs, seed=42).

m	Conv-AE		m	Conv-VAE ($\beta = 4$)	
	MSE	TwoNN ID		MSE	AU
4	0.0311	4.18	4	0.0331	4
8	0.0174	6.59	8	0.0197	8
12	0.0113	7.80	12	0.0140	12
16	0.0081	8.69	16	0.0109	16
20	0.0069	9.03	20	0.0097	20
32	0.0042	10.06	32	0.0070	32
64	0.0020	11.29	64	0.0049	63




図 7: Exp-Conv-AE: m -dependence of MSE, AU, and TwoNN ID for MNIST Conv-AE (left) and Conv-VAE (right) (100 epochs). Conv-AE confirms $\text{AU} = m$ (all dims active) with TwoNN ID converging to ≈ 11 at $m \geq 32$. Conv-VAE shows $\text{AU} \approx m$ (no saturation due to insufficient convergence at 100 epochs).

実験 Exp-Conv-AE の結果 (表 16) : **Conv-AE の TwoNN ID** は $m = 64$ で 11.29 に収束し FC-AE の推定値 (≈ 10) と整合する (誤差 $\approx 10\%$ 以内) —アーキテクチャによらず TwoNN 推定値が一貫する (本研究条件下での経験的観測)。一方 **Conv-VAE** は $m \leq 32$ で $\text{AU} = m$ (飽和なし) であり、100 エポックでは KL 正則化による次元抑制が機能せず、 m^{knee} の信頼ある検出にはより多くのエポック数が必要である。

5.5.1 Conv-VAE での AU 飽和遅延：固定 β ・KL アニール比較（実験 Exp-Conv-Fix・Exp-Conv-Ann）

Exp-Conv-AE の収束不足を受け、300ep・3 シード（Exp-Conv-Fix）および KL サイクリックアニール（Exp-Conv-Ann）で検証した（表 17）。

表 17: Exp-Conv-Fix and Exp-Conv-Ann: Comparison of AU for MNIST Conv-VAE (300ep, mean $\pm$ std over 3 seeds). FC-VAE (Exp-Mnist-Multi-300) slows down by $m = 32$ (AU= 15.7), while Conv-VAE shows AU= m (no saturation) under both fixed- β and annealing at $m \leq 32$.

m	Conv-VAE fixed- β (Exp-Conv-Fix)		Conv-VAE annealing (Exp-Conv-Ann)		FC-VAE (Exp-Mnist-Multi-300)	
	AU	TwoNN ID	AU		AU	TwoNN ID
4	4.0 $\pm$ 0.0	3.97 $\pm$ 0.08	4.0 $\pm$ 0.0		4.0	3.98
12	12.0 $\pm$ 0.0	8.14 $\pm$ 0.09	12.0 $\pm$ 0.0		10.0	7.41
32	32.0 $\pm$ 0.0	11.43 $\pm$ 0.08	32.0 $\pm$ 0.0		15.7	9.07
64	54.3 $\pm$ 0.5	13.10 $\pm$ 0.05	64.0 $\pm$ 0.0		22.3	10.03
m^{knee} : Conv-VAE (両条件) 全シード=64 (グリッド上限) ; FC-VAE=43 $\pm$ 15 (32~64)						

Conv-VAE は固定 $\beta = 4$ ・サイクリックアニールいずれでも $m \leq 32$ で AU= m （飽和なし）であり、FC-VAE との乖離が明確である（§ 6.6 で理論的考察）。AU $\approx m$ は「KL 正則化が未機能」のシグナルであり、この状態では TwoNN ID も膨張する（Conv-VAE $m = 64$: 13.10, FC-VAE: 10.03）。 $m \leq 64$ のグリッドでは AU 飽和の観察が不可能であり、 m 範囲の拡張が必要である。

5.6 Conv-VAE 拡張 m グリッド実験（実験 Exp-Conv-M256・Exp-Conv-M512）

Exp-Conv-Fix・Exp-Conv-Ann（§ 5.5.1）で $m \leq 64$ では AU 飽和が観測されなかったことを受け、 m グリッドを 256（実験 Exp-Conv-M256）および 512（実験 Exp-Conv-M512）まで拡張した。§ 6.6 で論じる τ_{eff}^2 の低下仮説のもとでは、Conv-VAE の $d^*(\beta)$ は FC-VAE (≈ 10) より大幅に大きいため、 $m > 64$ の領域で AU 増加の鈍化が現れると予測される。

実験設定（Exp-Conv-M256）：Exp-Conv-Ann と同一の Conv-VAE アーキテクチャ（ 28×28 MNIST, 2 層 Conv エンコーダ・2 層 ConvTranspose デコーダ, KL サイクリックアニール $\beta_{\text{max}} = 4$, 3 サイクル, 150 エポック, seeds $\in \{42, 123, 777\}$ ）を用い、 $m \in \{4, 8, 16, 32, 64, 96, 128, 192, 256\}$ （9 点）を検証した。

表 18: Exp-Conv-M256: Conv-VAE extended m grid (KL annealing, 150 epochs, mean $\pm$ std, 3 seeds). AU= m for $m \leq 64$; AU< m begins at $m \geq 96$. FC-VAE reference (Exp-Mnist-Multi-300, $m = 64$): AU= 22.3 ± 0.5 .

m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	Note
4	4.0 ± 0.0	3.84 ± 0.11	all dims active
8	8.0 ± 0.0	6.64 ± 0.11	
16	16.0 ± 0.0	8.76 ± 0.05	
32	32.0 ± 0.0	10.46 ± 0.13	
64	64.0 ± 0.0	13.29 ± 0.12	
96	90.7 ± 1.2	14.30 ± 0.22	same as Exp-Conv-Ann (no saturation) AU< m onset (FC-VAE $\hat{d}_{ID} \approx 9\times$)
128	111.7 ± 2.6	14.69 ± 0.13	
192	159.0 ± 4.3	15.89 ± 0.27	
256	241.3 ± 2.9	16.58 ± 0.16	

m^{knee} ($\tau = 0.25$): 全シード=256 (検証範囲内に knee なし)
FC-VAE reference (Exp-Mnist-Multi-300, $m = 64$): AU= 22.3 ± 0.5 , TwoNN ID= 10.03 ± 0.12




図 8: Exp-Conv-M256: Conv-VAE extended m grid ($m \in [4, 256]$, KL annealing, 3 seeds). AU vs m (left) and TwoNN ID vs m (right). Diagonal line (AU= m) and FC-VAE reference $\hat{d}_{ID} \approx 10$ (red) are shown. AU= m continues at $m \leq 64$ but deviates from the diagonal at $m \geq 96$, confirming qualitative water-filling behavior in Conv-VAE.

実験 Exp-Conv-M256 の主要知見: $m \leq 64$ では AU= m が全 3 シードで一致し (FC-VAE の $m = 64$: AU= 22.3 と対照的), $m = 96$ で初めて AU= $90.7 \pm 1.2 < m$ と飽和傾向が現れるが, $m = 256$ でも活性率 94.3% と高く, m^{knee} は全シードでグリッド端 (256) に留まった. Conv-VAE の $d^*(\beta)$ は FC-VAE (≈ 10) より大幅に大きい (> 256) ことを示す (τ_{eff}^2 理論との対応は § 6.6).

$m = 256$ 超への拡張 (実験 Exp-Conv-M512, 詳細は付録 F): $m \in \{384, 512\}$ まで拡張しても AU $\approx m$ (全次元活性) が全 3 シードで維持され, m^{knee} はグリッド端 512 に張り付いたままであった (付録 F, 表 29 参照). MNIST Conv-VAE の $d^*(\beta)$ が $m = 512$ を超えることを示しており, § 6.6 の τ_{eff}^2 理論予測と整合する. 次節では β_{max} を強化して AU 飽和を人為的に誘発できることを示す.

5.7 高 β による Conv-VAE AU 飽和の人為的誘発 (実験 Exp-ConvV-HiBeta)

§ 6.6 の τ_{eff}^2 仮説 (強力デコーダが AU 飽和を高次元側に押しやる) の検証として, β_{max} を $4 \rightarrow \{10, 20\}$ に増大させ, MNIST Conv-VAE での AU 飽和プラトーが誘発されるかを確認した.

実験設定：Exp-Conv-M256 と同一アーキテクチャ・KL サイクリックアニーリング（3 サイクル）を使用し、 $\beta_{\max} \in \{10, 20\}$, $m \in \{16, 32, 64, 96, 128, 192, 256\}$, $\text{seed}=42$, 150 エポックで学習した（比較用として Exp-Conv-M256 の $\beta_{\max} = 4$ $\text{seed}=42$ 結果を再掲する）。

表 19: Exp-ConvV-HiBeta: Comparison of MNIST Conv-VAE AU at $\beta_{\max} \in \{4, 10, 20\}$ ($\text{seed}=42$, 150ep, KL cyclic annealing). Higher $\beta_{\max}$ induces AU saturation at lower dimensions.

m	$\beta_{\max} = 4$ (Exp-Conv-M256)	$\beta_{\max} = 10$	$\beta_{\max} = 20$
16	16 (100%)	16 (100%)	16 (100%)
32	32 (100%)	32 (100%)	27 (84%)
64	64 (100%)	54 (84%)	42 (66%)
96	89 (93%)	65 (68%)	47 (49%)
128	114 (89%)	69 (54%)	53 (41%)
192	161 (84%)	79 (41%)	60 (31%)
256	241 (94%)	93 (36%)	66 (26%)
$m^{\text{knee}} (\tau = 0.25)$	512 (grid boundary, unidentified)	≈ 128	≈ 96

Exp-ConvV-HiBeta の知見（表 19）： $\beta_{\max} = 4$ では $m \leq 64$ で $\text{AU} = m$ （100% 活性）が続くのに対し、 $\beta_{\max} = 10$ では $m = 64$ で $\text{AU} = 54$ （84%）、 $m = 128$ で $\text{AU} = 69$ （54%）、 $m = 256$ で $\text{AU} = 93$ （36%）と明確な AU 飽和傾向が現れ、 $m^{\text{knee}} \approx 128$ ($\tau = 0.25$) が同定された。さらに $\beta_{\max} = 20$ では $m = 32$ で $\text{AU} = 27$ （84%）、 $m = 64$ で $\text{AU} = 42$ （66%）とより低次元側で飽和が生じ、 $m^{\text{knee}} \approx 96$ が観測された。これは § 6.6 の τ_{eff}^2 仮説の予測に直接整合する： β を増大させると $d^*(\beta) = |\{j : \lambda_j > \beta \tau_{\text{eff}}^2\}|$ が小さい値に移動し、AU 飽和がより低次元側に現れる。**この結果は、MNIST Conv-VAE での AU 飽和未観測が「フレームワークの適用限界」ではなく、 $\beta_{\max} = 4$ という設定ではデコーダ容量に比して正則化が不足し $d^*(\beta) \gg 256$ となっていたことに起因する**という解釈と整合する。AU/ m^{knee} 診断フレームワークの Conv-VAE への適用には、データ・アーキテクチャに合わせた β の適切な設定が必要である。




図 9: Exp-ConvV-HiBeta: Comparison of MNIST Conv-VAE AU vs m (left) and activation rate AU/m (right) for $\beta_{\max} \in \{4, 10, 20\}$. Increasing $\beta_{\max}$ shifts AU saturation to lower dimensions, demonstrating the β -dependence of $d^*(\beta)$.

5.8 自然画像への適用：CIFAR-10・SVHN（実験 Exp-Nat-Cifar・Exp-Nat-SVHN）

より複雑な自然画像データセット（CIFAR-10[3], SVHN[4]）に対して本フレームワークを適用し、Pope ら [16] の内在次元推定との比較を行った。

実験設定 (Exp-Nat-Cifar : CIFAR-10, Exp-Nat-SVHN : SVHN) :

- アーキテクチャ : Conv-VAE (入力 $32 \times 32 \times 3$)
 - エンコーダ : $\text{Conv}(3 \rightarrow 32, k=4, s=2, p=1) \rightarrow \text{Conv}(32 \rightarrow 64, k=4, s=2, p=1) \rightarrow \text{Conv}(64 \rightarrow 128, k=4, s=2, p=1) \rightarrow \text{FC}(2048 \rightarrow m) \times 2 (\mu, \log \sigma^2)$
 - デコーダ : $\text{FC}(m \rightarrow 2048) \rightarrow \text{ConvT}(128 \rightarrow 64) \rightarrow \text{ConvT}(64 \rightarrow 32) \rightarrow \text{ConvT}(32 \rightarrow 3) \rightarrow \text{Sigmoid}$
- $n_{\text{train}} = 20,000$, 150 エポック, KL サイクリックアニーリング ($\beta_{\text{max}} = 4$, 3 サイクル)
- $m \in \{16, 32, 64, 128, 256\}$, seeds $\in \{42, 123, 777\}$

表 20: Exp-Nat-Cifar and Exp-Nat-SVHN: Conv-VAE results for CIFAR-10 (left) and SVHN (right) (mean $\pm$ std, 3 seeds; KL cyclic annealing, 150 epochs, 3 cycles). At $m = 64$, CIFAR-10 latent TwoNN ID converges to the raw-data value (≈ 25), consistent with Pope et al. [16] ($d_{\text{ID}} \approx 26$).

m	CIFAR-10 (Exp-Nat-Cifar)		SVHN (Exp-Nat-SVHN)	
	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)
16	16.0 $\pm$ 0.0	13.12 $\pm$ 0.12	16.0 $\pm$ 0.0	11.30 $\pm$ 0.12
32	32.0 $\pm$ 0.0	19.26 $\pm$ 0.23	32.0 $\pm$ 0.0	15.08 $\pm$ 0.08
64	64.0 $\pm$ 0.0	25.21 $\pm$ 0.41	64.0 $\pm$ 0.0	19.97 $\pm$ 0.12
128	128.0 $\pm$ 0.0	28.83 $\pm$ 0.41	125.3 $\pm$ 0.5	24.60 $\pm$ 0.36
256	256.0 $\pm$ 0.0	30.91 $\pm$ 0.64	206.7 $\pm$ 1.2	27.08 $\pm$ 0.34
Raw TwoNN=25.20, MLE=26.56 ($\approx$ Pope et al. estimate of 26) $m^{\text{knee}} (\tau = 0.25)$: all seeds=256 (no knee in range)			Raw TwoNN=10.09, MLE=18.85 m^{knee} : all seeds=256 (no knee in range)	




図 10: Exp-Nat-Cifar: m -dependence of AU and TwoNN ID for CIFAR-10 Conv-VAE (KL cyclic annealing, 3 seeds). TwoNN ID shows convergence consistent with Pope et al.[16] ($d_{\text{ID}} \approx 26$).




図 11: Exp-Nat-SVHN: m -dependence of AU and TwoNN ID for SVHN Conv-VAE (KL cyclic annealing, 3 seeds).

本実験の主眼は TwoNN ID が適切なボトルネック範囲で Pope らの報告値と同程度のスケールを示すかの確認に限定される (AU/m^{knee} 側の安定同定は自然画像では未達であり, 本実験は適用境界を定める). 主要な知見は次の 2 点である (表 20). **CIFAR-10**: $m = 64$ での潜在 TwoNN ID = 25.21 ± 0.41 (3 シード) は生データ TwoNN ID (25.20) および Pope ら [16] の報告値 (≈ 26) と同程度のスケールを示すが, $m = 128$ 以上では $28.8 \sim 30.9$ へ上昇する——TwoNN の数値的整合は $m \approx 2\hat{d}_{ID}$ 程度の範囲に限られる. AU は $m \leq 256$ で $AU = m$ (飽和なし, m^{knee} は全シードでグリッド端) であり, フレームワーク全体の自然画像への汎化を主張するものではない. **SVHN**: $m \geq 128$ で $AU < m$ となるが AU 飽和プラトーには至らず, 潜在 TwoNN ID ($m = 256$ で 27.08) は生データ TwoNN (10.09) から大きく乖離する——AU が全次元を使用する条件では潜在空間の幾何的歪みにより ID が過大推定されうること示す適用限界の一例である.

5.9 CIFAR-10 Conv-VAE における AU 飽和条件の探索 (実験 Exp-NatImg-AU, 詳細は付録 F)

本節と § 5.11 は「適用境界の定量化」実験である—— AU/m^{knee} 安定同定の失敗を報告するのではなく, どの条件下で AU 診断が困難になるかの境界条件を体系的に特定する. Exp-Nat-Cifar ($\beta_{\max} = 4$) で AU 飽和が観測されなかった要因 (β 不足・学習不足・容量不足) を切り分けるため, $\beta_{\max} \in \{10, 20, 40\}$ と 2 種類のアーキテクチャ (Standard/Deep) を系統的に変化させた (CIFAR-10, $m \in [32, 384]$, KL サイクリックアニーリング, 200 エポック, **単一シード 42**; 実験設定・AU 表・図の詳細は付録 F, 表 30).

主要な観察: (1) $\beta_{\max}$ 増大は次元抑制をもたらす ($\beta_{\max} = 40 \cdot \text{Deep}$: $m = 384$ で $AU = 208$, 利用率 54%) が, いずれの条件でも $AU(m)$ は単調増加を続け, 飽和プラトーは現れない ($m^{knee} = 384$: 全条件でグリッド端). (2) 潜在 TwoNN ID はピクセル空間 TwoNN (25.30) を超えて増加し続け (Arch-A $\cdot \beta_{\max} = 10$: $m = 256$ で 29.2), AU が全次元を利用する状況では潜在幾何の歪みにより ID が過大推定される傾向を示す. (3) 定理 1 の観点では, 強力な Conv デコーダにより実効ノイズ分散 τ_{eff}^2 が MNIST より大幅に小さく, β の増大だけでは活性化条件 $\lambda_j > \beta \tau_{\text{eff}}^2$ を反転させることが難しい. 以上から, AU 飽和による m^{knee} 同定には (a) $m \gg 2\hat{d}_{ID}$ の広域グリッド探索, または (b) デコーダ容量を制限した設定が必要条件であることが特定された (§ 6.6). 次節の拡張スイープでこの境界条件をさらに定量化する.

5.10 実データ幾何比較実験: TwoNN 安定性条件の実証 (RQ2・RQ3)

本実験 (Exp-Real-Geom) は命題 4 の実験的検証として, MNIST・Fashion-MNIST において **等長性を系統的に変化させた 4 種類のモデル**を複数の m 値でスイープし, TwoNN・MLE・ κ ・Trustworthiness・kNN

overlap を比較する.

実験設定 (Exp-Real-Geom)

モデル：以下の 4 種類を比較する.

通常 AE ヤコビアン正則化なし ($\kappa \approx 10^2 \sim 10^7$; m の増大とともに増大, 表 28)

IsometricAE デコーダヤコビアン正則化 ($\kappa \approx 1.1 \sim 1.4$; Kato ら [13])

CAE エンコーダ側収縮正則化 (κ 中程度; Rifai ら [22])

DAE 入力ノイズ正則化 (ノイズスケール $\sigma = 0.1$; Alain ら [23])

m スイープ : $m \in \{d, 2d, 3d, 5d, 10d\}$ ($d = \hat{d}_{\text{ID}}$ を MNIST では 10, Fashion-MNIST では 9 と設定; すなわち $m \in \{10, 20, 30, 50, 100\}$ および $m \in \{9, 18, 27, 45, 90\}$).

測定指標 : TwoNN ($k = 2$), MLE ($k = 10$), κ (デコーダヤコビアン条件数), Trustworthiness ($k = 10$), kNN overlap (kNN 近傍保持率, $k = 10$).

データ・学習 : MNIST・Fashion-MNIST, 学習サンプル 20,000, シード $\{42, 123, 777\}$ (3 シード), 300 エポック, 隠れ層 [512, 256], Adam ($\text{lr} = 10^{-3}$).

実験結果 (Exp-Real-Geom)

主要な結果の要約を表 21 に示す (全 m ・全指標の詳細表は付録 E, 表 28).

表 21: Exp-Real-Geom (summary): MNIST four-model comparison (mean $\pm$ std, 3 seeds, 300ep). TwoNN ID converges as $m/\hat{d}_{\text{ID}}$ increases in all four models, largely independently of κ . Full table in 付録 E.

Model	TwoNN ($m=d$)	TwoNN ($m=5d$)	TwoNN ($m=10d$)	κ ($m=10d$)
AE	7.3 ± 0.4	10.0 ± 0.1	10.0 ± 0.1	4.1×10^7
IsometricAE	7.5 ± 0.4	10.1 ± 0.1	10.1 ± 0.1	7.8
CAE	7.2 ± 0.5	9.9 ± 0.1	10.0 ± 0.1	3.2×10^3
DAE	7.6 ± 0.4	10.0 ± 0.1	10.0 ± 0.1	6.3×10^3

考察 : $m \gg \hat{d}_{\text{ID}}$ が支配的条件

(1) $m/\hat{d}_{\text{ID}}$ の増大が TwoNN 安定化の支配的因子 : 4 モデル全てにおいて, TwoNN ID は $m = d$ ($\approx 7.3 \sim 7.6$) から $m = 5d \sim 10d$ ($\approx 10.0 \sim 10.1$) へと収束する共通パターンを示す. モデル間の差は同じ m での比較で最大 ± 0.3 程度に留まり, m の増大による改善 (約 2.5 ポイント) をはるかに下回る.

(2) 等長性改善 (κ 低減) の単独効果は小さい : IsometricAE は $\kappa \approx 3 \sim 8$ (AE の $10^2 \sim 10^7$ に対して桁違いに低い) を達成するが, TwoNN ID は同じ m での AE と ± 0.2 以内の差しかない. Trustworthiness・kNN overlap の改善も m に主導され (モデル間差 < 0.003 ; 付録 E), 命題 4 の「 δ_T (近傍順位の逆転率) が ε (歪み) より TwoNN 安定性に支配的」という含意と整合する. Fashion-MNIST ($\hat{d}_{\text{ID}} = 9$) でも同様のパターンが観測された (付録 E).

実データへの含意 : 本実験は Exp-Iso-ID (合成多様体; § 5.2.4) の知見を実データ・複数モデルに拡張し, 「等長性バイアスより m グリッド設計 ($m \gg \hat{d}_{\text{ID}}$) が TwoNN 推定の実用的安定化に有効」という設計指針を補強する. Stage 1 で参照 AE ($m_{\text{ref}} = 256 \gg \hat{d}_{\text{ID}} \approx 10$) を使う合理性がこの結果によって支持される.

5.11 自然画像拡張スイープと Stable Identification 基準 (RQ1)

本節では § 3.4 で定義した stable identification の 5 条件を用いて、自然画像での AU/m^{knee} 診断の達成度を判定する。

実験設定と主要知見 (Exp-NatImg-Sweep)

前節 (Exp-NatImg-AU) を大幅に拡張し、 $m \in [32, 1024]$, $\beta_{\max} \in \{10, 20, 40, 80\}$, デコーダ容量 (Standard/Deep/Thin), 300 エポック, 3 シードを組み合わせた網羅的スイープを実施した (詳細は付録 F)。

主要知見: $\beta_{\max} = 80$ ・薄型デコーダ条件で $m \in [512, 1024]$ にわたって $AU \approx 24$ 付近の plateau-like behavior が本研究条件下で観測されたことは、「自然画像でも十分大きな β とデコーダ容量制限の下で AU 飽和が起こりうる」という予備的証拠を与える。全条件で TwoNN ID は 24.7~25.4 ($\sigma \leq 0.6$) と安定し, Pope ら [16] の報告値 (≈ 26) と整合する。 AU/m^{knee} の安定同定には、より大きな m ・高い β ・デコーダ容量制御が必要であることが分かった。5 条件の詳細判定 (stable identification 基準; § 3.4) は付録 F にまとめる。また、検出法比較 (Exp-NatImg-Knee) では平滑化後曲率法が最も再現性が高かったが、検出法の改善よりも AU 飽和自体の安定化が先決であることも確認された (付録 F)。

6 考察

6.1 RQ1 への回答と m^{knee} の位置づけ

RQ1 への総括: RQ1 「 m^{knee} はどのようなグリッド密度・シード数・アーキテクチャ条件のもとで TwoNN/MLE による ID 推定値と整合する診断補助量として利用可能か」に対する答えは以下のとおりである。

- **安定化条件の特定 (検証範囲の明示):** MNIST 多シード疎グリッド実験では m^{knee} が 32~64 に大きく変動し、粗いグリッドでは信頼性のある診断補助量として使用できない。TwoNN 推定値近傍の密グリッド・独立初期化・複数シード条件 (Exp-Mnist-Dense-300) では $m^{\text{knee}} = 10.3 \pm 0.9$ と TwoNN ID (≈ 10) 近傍に安定化した。ただしこの結果は **MNIST FC-VAE**・ $\beta = 4$ ・**TwoNN 誘導型密グリッド**・**3 シード**という条件に限定して確認されたものであり、探索領域自体が TwoNN 推定に依存するため独立検証ではない (§ 5.3.6)。したがって m^{knee} の既定の記述は「TwoNN 誘導型の探索的变化点」であり、上記条件を明示せずに一般的な利用を推奨するものではない。
- **適用限界:** Conv-VAE ($\beta_{\max} = 4$)・自然画像では検証範囲内で安定同定に至らず、 $\beta_{\max} \geq 10$ ・密グリッド・デコーダ容量制御といった条件が別途必要である。

m^{knee} の不安定性はグリッド密度で緩和されるだけの副次的問題ではなく、**本フレームワークの第一級の限界**として扱う (§ 6.7)。本論文の主要な貢献は、AU 値 (頑健指標) と TwoNN ID (数値安定な補助的参照) という二つの安定した指標を軸に据え、 m^{knee} を探索的補完指標として位置づける診断フレームワークの確立にある (表 2)。

6.2 m^{knee} 不安定性の最適化ダイナミクスの解釈と安定化戦略

最適化ダイナミクス上の解釈: 勾配競合仮説:

命題 2 はグリッド感度を形式的に示したが、実際の学習では追加の不安定性因子が存在する。 β -ELBO の勾配は再構成項 $\nabla \mathcal{L}_{\text{rec}}$ と KL 項 $\nabla \mathcal{L}_{\text{KL}}$ の線形結合であり、これらは $m \approx d^*(\beta)$ (有効次元しきい値付近) において**勾配競合**を生じさせる:

- 再構成勾配 ($\nabla \mathcal{L}_{\text{rec}}$) : 余剰次元 $j > d^*$ でも, 学習初期は小さな再構成寄与 ($\lambda_j > 0$ なら正の利得) があり, 次元を活性化しようとする.
- KL 勾配 ($\beta \nabla \mathcal{L}_{\text{KL}}$) : 同次元を事前分布に回帰させようとする反対方向の圧力.
- この競合の解消速度は乱数シード (初期化), m グリッド (各 m で独立した最適化軌道), および β の値に依存する. 定理 1 の大域的最適解への収束経路は非線形最適化では一意でなく, sharpness の低い損失ランドスケープでは $m \approx d^*$ 付近の AU 曲線の傾きが初期条件に感度を持つ.

サイクリック KL アニーリング [2] は β を段階的に増加させることで, この勾配競合の解消を段階的に促し, 大域的最適解への収束を改善する (実験 Exp-Conv-Ann ; § 5.5.1).

m^{knee} の安定化のための実践的アプローチ :

本研究の知見 (Exp-Mnist-Dense 実験のグリッド密度×エポック因子分離を含む) から, m^{knee} を実際の設計に用いる際の以下の推奨事項を提案する :

1. **密なグリッド設計 (TwoNN 誘導型局所精密化)** : 推定 $\hat{d}_{\text{ID}}$ (TwoNN ID) の前後に間隔 1 の密な点を配置する (Exp-Mnist-Dense で実証 ; § 5.3.6). 命題 2 より, グリッド間隔がそのまま m^{knee} の最大誤差になる. ただし探索領域が TwoNN 推定に依存する点, およびシード因子が残存する点に注意する.
2. **アンサンブル m^{knee}** : 複数シードでの AU 曲線から各 $m^{\text{knee}(s_i)}$ を計算し, **メディアン**を採用する :

$$m^{\text{knee,ens}} = \text{median}\{m^{\text{knee}(s_1)}, \dots, m^{\text{knee}(s_S)}\} \quad (9)$$

メディアンは m^{knee} がグリッド端に張り付く外れ値に対して頑健である (S が偶数の場合は隣接する 2 値の算術平均とする).

3. **KL アニーリングの採用と m グリッドの拡張** : Conv-VAE では, アニーリングにより大きな m での不必要な崩壊が抑制されるが, AU 飽和の観測には m グリッドを $d^*(\beta)$ の推定値の 2 倍以上に拡張する必要がある (例 : MNIST Conv-VAE では $m > 64$; § 5.5.1).
4. **安定指標との照合** : m^{knee} の推定値は常に AU 値 (頑健指標)・TwoNN ID (数値安定な補助的参照) と照合し, 三指標の整合性で最終判断を下す (表 22 参照).
5. **AU 曲線の二階差分 (代替手法)** : 固定閾値 τ が機能しない場合 (SVHN 等), $\text{AU}(m)$ の離散二階差分 $\Delta^2 \text{AU}(m_i)$ の絶対値最大点を m^{knee} とする曲率最大点法を用いる (Exp-Mnist-Dense 実験でも並行検証 ; 付録 C 参照).

$\tau_{\text{knee}} = 0.25$ の選択根拠と感度分析 (Exp-Tau-Cross), および τ 法・二階差分法の使い分けは付録 C にまとめる. 要点のみ述べると, 密グリッド条件 (Exp-Mnist-Dense) では τ 法 (10.3 ± 0.9) が二階差分法 (18.3 ± 6.8) より頑健であり, τ 法が不安定になる条件 (AU 増加率が境界値付近で複数の m にわたり一定) では二階差分代替手法への切り替えが有効である.

6.3 TwoNN ID の数値安定性と系統的バイアス : 「安定性」と「正確性」の区別

実験 Exp-Stab および Exp-Geom は, TwoNN ID が「数値的に安定 (低分散)」であることを示したが, これは「真の内在次元に対して無バイアス (正確)」であることとは別の主張である. この区別を明確にすることは, 本フレームワークの運用において重要である. 命題 4 (§ 4.2) により, 「等長性 (ϵ) よりも近傍順位の保存 (δ_T) が TwoNN 安定性の支配的因子」という半理論的枠組みを示し, 実験 Exp-Real-Geom (§ 5.10) で実データ・複数モデルにわたって実証した.

数値的安定性の意味 : 実験 Exp-Geom (MNIST AE m スイープ) では, $m \geq 48 \approx 5\hat{d}_{\text{ID}}$ 以降で TwoNN ID は 10 ± 0.5 の範囲に安定収束し, $m = 96 \sim 128$ での κ 急増 ($9.94 \rightarrow 37.0$) に対しても変動は小さい (§ 5.2.4, 表 25). すなわち TwoNN は「参照 AE が m を変えてもほぼ同じ値を出力する」という意味で安定である.

系統的バイアスの可能性：ただし，参照 AE が空間を歪めて埋め込んでいる場合 ($\kappa \gg 1$)，TwoNN は「参照 AE の潜在多様体の局所自由度」を推定しており，真のデータ多様体の内在次元とは系統的な乖離が生じる．これは安定して「特定の値」を返し続けることと矛盾しない——いわば「安定して偏った推定」である．したがって，本論文は TwoNN を真の d_{ID} の不偏推定量ではなく，**補助的参照推定量**として扱う．

MNIST での $\hat{d}_{\text{ID}} \approx 10 \sim 12$ の根拠：TwoNN 推定値の意味を補強する独立した証拠として，以下の複数の観察が整合している：

- MSE エルボー (AE)： $m \approx 16 \sim 20$ 付近で急速な MSE 低下が鈍化する (d_{ID} より若干大きい値だが，同オーダー；実験 Exp-Mnist-Base)．
- PCA スペクトル：累積分散 80% で 43 次元，90% で 86 次元（非線形次元の上界として $d_{\text{ID}} \ll 43$ を示す；実験 Exp-Mnist-PCA)．
- CIFAR-10 での整合確認：CIFAR-10 で潜在 TwoNN ID = 25.21 ± 0.41 が Pope ら [16] の報告値 (≈ 26) と同程度のスケールであることを確認し，TwoNN が自然画像でも数値的に安定することを支持する（実験 Exp-Nat-Cifar)．
- MLE との一致： $k = 5, 10, 20$ で MLE = $11.5 \sim 12.4$ ，TwoNN = $10.0 \sim 10.5$ と異なる原理の推定量が同一オーダーの値を示す．

これらの複数の証拠は互いに整合し，MNIST の $\hat{d}_{\text{ID}} \approx 10 \sim 12$ が参照 AE 固有のアーティファクトではない蓋然性を高めるが，TwoNN が真の d_{ID} に対して幾何学的に不偏であることを直接証明するものではない．すなわち，本論文における TwoNN ID は**潜在空間側の安定な参照値**（対象量 (ii)；§ 3.1）であって，入力分布の真の内在次元（対象量 (i)）の推定値そのものではない．安定して偏った推定量でも診断パイプラインの参照値としては機能するが，その乖離の定量化は残された課題である：(a) DANC0[15]・ESS 等の原理の異なる ID 推定量との系統比較，(b) シード間標準偏差に加えたブートストラップ信頼区間の報告，を今後の課題とする．

6.4 AU Dynamics が有効表現次元を反映するメカニズム

AU_{sat} vs. m^{knee} の使い分け：単連結な合成多様体 (Swiss Roll 等) では AU の急激な飽和 ($\text{AU}_{\text{sat}} = d_{\text{true}}$) が観測されるため，AU_{sat} が有効表現次元の直接的な読み取り点となる．一方，実データのような複雑な分布（多クラス，非連結な部分多様体）では，AU は単調に漸増し明確な飽和を示さない．この場合， m^{knee} が「KL 正則化が有効に機能し始める点」として有効表現次元の**粗い実用的目安**となる（表 22；数値の精確な再現性は m グリッド・シードに依存する点に注意）．

表 22: Guidelines for using AU_{sat} vs. m^{knee} (based on this study).

Data type	AU pattern	Recommended indicator
Simple synthetic manifolds (simply connected)	Sharp saturation	AU _{sat} (consistent with d_{true})
Topologically non-trivial synthetic manifolds	Stepwise saturation	AU _{sat} (tends to match d_{emb} , conditional)
Real data (MNIST, Fashion-MNIST)	Gradually increasing	m^{knee} (rough heuristic; grid/seed-dependent)

6.5 付随的知見：位相的構造・学習ダイナミクス・幾何的正則化

■**位相的構造と AU_{sat} (実験 Exp-Syn-Top)** Torus・Möbius Band において $AU_{\text{sat}} = d_{\text{emb}} = 3 (> d_{\text{ID}} = 2)$ が観測され、VAE の Gaussian 事前分布の収縮可能性から生じる位相幾何学的制約 [10, 11] との対応が示唆された。ただし、この対応は標準化・十分な収束という条件付きであり、MNIST での $AU_{\text{sat}} = 36 \gg \hat{d}_{\text{ID}}$ に適用できない（実験 Exp-Mnist-Ent は予備的；詳細は § 6.7）。本知見はフレームワークの主結論（ m^{knee} による有効次元の読み取り）から独立した付随的観察であり、今後の課題として残す。

■**学習ダイナミクス (実験 Exp-Mnist-Dyn, 単一シード)** MNIST ($m = 16, 200\text{ep}$) での 2 フェーズ学習ダイナミクス（大域構造の急速形成後に局所的有効次元が漸進的増加）は単一シードの探索的観察であり、多シード検証は今後の課題として残す。

■**幾何的正則化と TwoNN 安定性 (実験 Exp-Syn-Iso・Exp-Iso-ID；RQ3 の補助実験)** RQ3 の焦点は「幾何的正則化やボトルネック余裕が TwoNN 安定性に与える影響」である。実験 Exp-Iso-ID (§ 5.2.4) では $\kappa \in [1.1, 2.1]$ での等長性改善が TwoNN ID の系統的バイアスを有意に低減しないことが判明した——TwoNN 過小推定の主因はボトルネック余裕の不足 ($m < d_{\text{true}}$) であり、IsometricAE ($\kappa \approx 1.04$) が等長性を実現しても（実験 Exp-Syn-Iso）、TwoNN 精度への貢献は小さい (§ 6.7)。IsometricAE の主たる有用性は「等長性確認ツール」であって有効次元の主要な読み取り指標ではない。デコーダヤコビアン計算のコスト ($O(m)$ 倍) により大規模データへの適用も制限される (§ 6.7)。

6.6 Conv-VAE における AU 飽和遅延の理論的考察

FC-VAE では $m \geq \hat{d}_{\text{ID}} \approx 10$ の付近で AU 増加が鈍化し、 m^{knee} が $\hat{d}_{\text{ID}}$ と定性的に整合した（実験 Exp-Mnist-Base, Exp-Mnist-Dense）。一方、Conv-VAE では $m \leq 64$ の全範囲で $AU \approx m$ が継続し、KL アニール（実験 Exp-Conv-Ann）を適用しても検証範囲内の AU 飽和プラトーは観測されなかった（実験 Exp-Conv-Fix）。この「AU 飽和遅延」は、以下のメカニズムで理解できる。

有効 τ_{eff}^2 の低下による解釈 定理 1（線形ガウス rate-distortion 近似）より、活性次元数は $d^*(\beta) = |\{j : \lambda_j > \beta \tau_{\text{eff}}^2\}|$ で決まる。Conv デコーダは全結合デコーダより強力な空間的再構成能力を持つため、同じ β のもとでも実効的な再構成ノイズ分散 τ_{eff}^2 が小さくなると考えられる。 τ_{eff}^2 が小さいほど水充填のしきい値 $\beta \tau_{\text{eff}}^2$ は低下し、より多くの固有値が活性条件 $\lambda_j > \beta \tau_{\text{eff}}^2$ を満たすため、 $d^*(\beta)$ がより大きな値をとる（水面が低く、多くの次元が有効と判定される）。実験 Exp-Mnist-PCA で FC-VAE の $\tau_{\text{eff}}^2 \approx 0.30$ と推定されるのに対して、Conv-VAE では $\tau_{\text{eff}}^2 \ll 0.30$ となり、 $d^*(\beta)$ が検証範囲 $m \leq 64$ を大幅に超えると考えられる。したがって、Conv-VAE のフレームワーク適用には m グリッドを $d^*(\beta)$ の推定値に到達するまで大幅に拡張する必要がある。

実験的検証 この解釈は § 5.6・§ 5.7 の結果と整合する： $\beta_{\text{max}} = 4$ では $m = 512$ まで拡張しても飽和プラトーは現れず ($d^*(\beta) > 512$)、 β_{max} を $10 \cdot 20$ に増大させると $m^{\text{knee}} \approx 128 \cdot 96$ が同定された（表 19）—— β 増大により $d^*(\beta)$ が低次元側に移動するという理論的予測どおりである。すなわち $\beta_{\text{max}} = 4$ での飽和未観測はフレームワークの適用限界ではなく、デコーダ容量に対する β 不足に起因し、Conv-VAE への適用では β の増強またはデコーダ容量の削減が必要である。

自然画像への含意 CIFAR-10・SVHN では TwoNN ID が自然画像でも数値的に安定することを確認したが、 AU/m^{knee} 側の安定同定には至らなかった (§ 5.8, § 5.9)。実験 Exp-NatImg-AU ($m \in [32, 384]$, $\beta_{\text{max}} \in \{10, 20, 40\}$) では $m^{\text{knee}} = 384$ （グリッド端）が全条件で継続し、AU 飽和には $m \gg 2\hat{d}_{\text{ID}}$ かつ $\beta_{\text{max}} \gg 40$ または薄型デコーダが必要であることが定量的に特定された。Exp-NatImg-Sweep での plateau-like behavior の観察 (§ 5.11) はこの条件下 ($\beta_{\text{max}} = 80$, 薄型デコーダ) で達成されている。

6.7 限界と今後の課題

(A) 評価データの範囲と一般化可能性

- **Conv-AE・Conv-VAE 検証**（実験 Exp-Conv-AE・Exp-Conv-Fix・Exp-Conv-Ann・Exp-Conv-M256）：Conv-AE（Exp-Conv-AE）の TwoNN ID 一貫性を確認した． $\beta_{\max} = 4$ では $m \leq 512$ まで AU 飽和プラトーは未観測だが，高 β 実験（Exp-ConvV-HiBeta）により β 設定不足が主因であることを実証した（§ 5.7）．CIFAR-10・SVHN 実験では TwoNN ID が Pope ら [16] の報告値と整合することを確認し（§ 5.8），拡張スイープ（Exp-NatImg-Sweep, § 5.11）で AU plateau-like behavior を条件付きで観測したが，stable identification の 5 条件はいずれも未達であり，大規模自然画像での完全適用は将来課題として残る（特に β 安定性・シード安定性条件の達成が次の目標）．
- **高次元相多様体**：Klein Bottle 等の高次の位相不変量を持つ合成多様体での Exp-Syn-Top 実験の拡張が残課題である．
- **m^{knee} の不安定性は第一級の限界である**：多シード検証（§ 5.3.4）が示すとおり， m^{knee} の疎グリッドでの不安定性はエポック延長では解消されず，密グリッドによる安定化も MNIST FC-VAE・ $\beta = 4$ ・TwoNN 誘導型探索という限定された条件でのみ確認されている．グリッド密度と多シードは一般に十分な安定化策とは言えず，条件を明示しない m^{knee} の利用は推奨しない．
- **単一シード実験の残存**：Exp-Mnist-Base・Exp-Mnist-Dyn・Exp-Mnist-Ent・Exp-Fashion・Exp-ConvV-HiBeta・Exp-NatImg-AU 等は単一シードであり（付録 H, 表 33 に明示），これらに基づく記述は予備的観察に限定した．多シード化は今後の課題である．

(B) 指標・ハイパーパラメータの感度

- **Stage 1 の ID 推定：等長性バイアスの厳格な評価**：本論文では，参照 AE ($m_{\text{ref}} = 256$) の潜在表現を經由して TwoNN ID を推定する（Stage 1）．この推定値は本質的に近似値であり，以下のバイアス源を含む：
 - (i) **等長性の欠如**： $m = 256$ 参照 AE の条件数 $\kappa \approx 10^9$ は等長性 ($\kappa = 1$) から桁違いに逸脱している（命題 3；実験 Exp-Syn-Iso）．等長性を欠く潜在空間での距離に基づく TwoNN ID は，真の内在次元の過小・過大評価につながりうる．
 - (ii) **KL 未飽和との相乗効果**：実験 Exp-Conv-Fix では，Conv-VAE の AU 未飽和（AU = m ）時の TwoNN ID (13.10) が FC-VAE の AU 飽和時 (10.03) より大幅に膨張しており，等長性バイアスと AU 未飽和が相乗的に ID 推定値を歪めることが示された．
 - (iii) **循環性の可能性**： $\hat{d}_{\text{ID}}$ を参照 AE 経由で推定し，その値を m^{knee} の評価基準に用いることで，推定と評価の間に循環性が生じうる．
- **緩和策**：IsometricAE ($\kappa \approx 1$) の参照 AE としての活用，または複数 m_{ref} （例： $m \in \{64, 128, 256\}$ ）での TwoNN ID の収束確認を提案する．本論文では TwoNN ID が $m = 64$ 以降で漸近的に安定 (10.03 ± 0.12) していることを確認しており，この収束性が $\hat{d}_{\text{ID}}$ 推定の実用上の根拠となる（§ 5.2.4）．等長性バイアスの厳密な定量化（DANCo 等との比較・ブートストラップ信頼区間を含む；§ 6.3）は今後の課題として残る．
- **τ_{knee} の非普遍性**：Fashion-MNIST では $\tau = 0.25$ 前後で m^{knee} が変化する境界感度が確認されており，二階差分代替手法との併用を推奨する（付録 C）．
- **AU_{sat} の前処理依存性**：正規化方法により AU_{sat} が変動する（実験 Exp-Syn-Top）．AU_{sat} $\approx d_{\text{emb}}$ の再現には標準化（平均 0・分散 1）が必要．
- **β への依存性**：予備実験（50 エポック， $\beta \in \{1, 2, 4, 8\}$ ）から， $\beta = 1$ では AU $\approx m$ （正則化不足）， $\beta = 8$ では過正則化の兆候が観測された（付録 D, 図 12）． $\beta \in [2, 8]$ での AU パターンの安定性は確

認されているが, m^{knee} の精確な値は m グリッドや乱数シードにも依存する (§ 6.1).

(C) 計算コスト

- IsometricAE のヤコビアン計算コスト ($O(m)$ 倍) により, CIFAR-10 (≈ 64 倍)・ImageNet ($\approx 3,000$ 倍) への直接適用は困難.
- 全 m スイープ (11 次元 $\times 300$ エポック $\times 2$ モデル) は数時間~数日を要する.

7 むすび

本論文では, AE/VAE の有効潜在次元を診断する**多指標フレームワーク**を提案した. AU 値 (頑健指標)・TwoNN ID (数値安定な補助的参照推定量)・ m^{knee} (探索的指標) の役割を明確に分類し, 指標ごとの信頼性と適用条件を実験・理論の両面から定量化したことが本論文の中心的貢献である (表 2). 理論面では, 線形ガウス rate-distortion 近似のもとで AU 活性化しきい値 $\lambda_j > \beta\tau^2$ を水充填定理・KKT 条件から導出し (定理 1), m^{knee} のグリッド感度上界 (命題 2) とアンサンブル安定化戦略 (§ 6.2) を提示した. 実験面では, MNIST (3 シード) において AU 値 ($\sigma \leq 0.5$) と TwoNN ID (10.03 ± 0.12) の高い再現性を確認し, TwoNN 推定値近傍の密グリッド・独立初期化・複数シード条件で $m^{\text{knee}} = 10.3 \pm 0.9$ と安定化した (Exp-Mnist-Dense-300; § 5.3.6). この安定化は **TwoNN 誘導型の局所精密化**であり, 検証範囲は MNIST FC-VAE・ $\beta = 4$ ・密グリッド・3 シードに限られる——条件を明示しない一般的な m^{knee} の利用を推奨するものではない. Fashion-MNIST でも同様の傾向を単一シードで確認した (§ 5.4). 実データ幾何比較実験 (Exp-Real-Geom, § 5.10) により, 「等長性改善より $m \gg \hat{d}_{\text{ID}}$ が TwoNN 安定性の支配的条件」を MNIST の 4 モデル比較 (表 21) および Fashion-MNIST での定性的確認 (付録 E) によって支持した (命題 4 に理論的根拠). なお TwoNN ID は潜在空間側の安定な参照値であり, 入力分布の真の内在次元に対する不偏性は保証されない (§ 6.3).

フレームワークの適用可能性を 3 段階で整理する (表 23; 証拠: § 5.3.4, § 5.3.6, § 5.5.1, § 5.11).

表 23: Three-tier applicability of the diagnostic framework (summary of evidence).

Setting	AU values	TwoNN ID	m^{knee} / requirements
FC-VAE (MNIST, 3 seeds)	Stable ($\sigma \leq 0.5$)	Stable ($\sigma \leq 0.12$, $m = 64$)	Exploratory guide near TwoNN ID only under dense grid + independent init. + multi-seed (Exp-Mnist-Dense-300: 10.3 ± 0.9); Fashion-MNIST: same tendency, single seed
Conv-VAE (MNIST)	Stable; AU < m from $m \geq 96$	Stable (inflates while AU = m)	Identifiable with $\beta_{\max} \geq 10$ ($m^{\text{knee}} \approx 96\text{--}128$); at $\beta_{\max} = 4$, $d^*(\beta) > 512$ (Exp-Conv-M256/M512, Exp-ConvV-HiBeta)
Natural images (CIFAR-10/SVHN)	Plateau-like only at $\beta_{\max} = 80$ + thin decoder	Consistent with Pope et al. [16] at $m \approx 2\hat{d}_{\text{ID}}$	Stable identification: all five criteria unmet; future work (Exp-Nat-Cifar, Exp-NatImg-Sweep)

Conv-VAE・自然画像実験 (§ 5.5.1~§ 5.11) は, 「成功か失敗か」ではなく, AU 診断が困難になる境界条件を定量化する検証として位置づける. 高 β 実験 (Exp-ConvV-HiBeta) では $\beta_{\max} \geq 10$ で AU 飽和が観測され, $\beta_{\max} = 4$ での未飽和が β 設定に起因するという解釈と整合し, CIFAR-10 拡張スイープ (Exp-NatImg-Sweep) では $\beta_{\max} = 80$ ・薄型デコーダ条件で AU plateau-like behavior を本研究条件下で

観察した (stable identification 5 条件は全て未達; 付録 F). 今後の主要課題は, (i) 自然画像での stable identification 達成 ($\beta_{\max} \in [40, 120]$ 密スイープ, シード安定性の改善), (ii) 定理 1 の非線形設定への拡張 (局所線形化に基づく解析), (iii) 大規模データへの拡張 (ImageNet, 計算コスト削減) である.

参考文献

- [1] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Wiley-Interscience, Hoboken, NJ, 2006.
- [2] H. Fu, C. Tan, B. Peng, Z. Zhao, T. Yan, C. Chang, and L. Zhao, “Cyclical annealing schedule: A simple approach to mitigating KL vanishing,” in *Proceedings of NAACL-HLT 2019*, pp. 240–250, 2019.
- [3] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Technical Report, University of Toronto, 2009.
- [4] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, “Reading digits in natural images with unsupervised feature learning,” in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- [5] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *Journal of the Royal Statistical Society: Series B*, vol. 61, no. 3, pp. 611–622, 1999.
- [6] C. Fefferman, S. Mitter, and H. Narayanan, “Testing the manifold hypothesis,” *Journal of the American Mathematical Society*, vol. 29, no. 4, pp. 983–1049, 2016.
- [7] Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.
- [8] E. Facco, M. d’Errico, A. Rodriguez, and A. Laio, “Estimating the intrinsic dimension of datasets by a minimal neighborhood information,” *Scientific Reports*, vol. 7, p. 12140, 2017.
- [9] E. Levina and P. J. Bickel, “Maximum likelihood estimation of intrinsic dimension,” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 17, 2005.
- [10] A. Hatcher, *Algebraic Topology*, Cambridge University Press, Cambridge, 2002.
- [11] V. Guillemin and A. Pollack, *Differential Topology*, Prentice-Hall, Englewood Cliffs, NJ, 1974.
- [12] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in *International Conference on Learning Representations (ICLR)*, 2014.
- [13] K. Kato, J. Zhou, T. Sasaki, and A. Nakagawa, “Rate-distortion optimization guided autoencoder for isometric embedding in Euclidean latent space,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 119, 2020.
- [14] P. Nazari, S. Damrich, and F. A. Hamprecht, “Geometric autoencoders – what you see is what you decode,” in *International Conference on Machine Learning (ICML), Proc. Mach. Learn. Res.*, vol. 202, 2023.
- [15] C. Ceruti, S. Bassis, A. Rozza, G. Lombardi, E. Casiraghi, and P. Campadelli, “DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration,” *Pattern Recognition*, vol. 47, no. 8, pp. 2569–2581, 2014.
- [16] P. Pope, C. Zhu, A. Abdelkader, M. Goldblum, and T. Goldstein, “The intrinsic dimension of images and its impact on learning,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [17] A. Ansuini, A. Laio, J. H. Macke, and D. Zoccolan, “Intrinsic dimension of data representations in deep neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.

- 2019.
- [18] T. Birdal, A. Lou, L. J. Guibas, and U. Simsekli, “Intrinsic dimension, persistent homology and generalization in neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.
 - [19] L. Valeriani, D. Wood, G. Catania, S. Gherardini, A. Laio, and A. Ansuini, “The geometry of hidden representations of large transformer models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.
 - [20] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” in *International Conference on Learning Representations (ICLR)*, 2017.
 - [21] J. Lucas, G. Tucker, R. B. Grosse, and M. Norouzi, “Don’t blame the ELBO! A linear VAE perspective on posterior collapse,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
 - [22] S. Rifai, P. Vincent, X. Muller, X. Glorot, and Y. Bengio, “Contractive auto-encoders: Explicit invariance during feature extraction,” in *International Conference on Machine Learning (ICML)*, *Proc. Mach. Learn. Res.*, vol. 28, 2011.
 - [23] G. Alain and Y. Bengio, “What regularized auto-encoders learn from the data-generating distribution,” *Journal of Machine Learning Research (JMLR)*, vol. 15, no. 1, pp. 3743–3773, 2014.
 - [24] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in *International Conference on Machine Learning (ICML)*, *Proc. Mach. Learn. Res.*, vol. 97, pp. 3519–3529, 2019.
 - [25] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform manifold approximation and projection for dimension reduction,” *arXiv preprint arXiv:1802.03426*, 2018.

付録 A 命題の証明スケッチ

命題 5 (デコーダヤコビアンの実効階数). 十分な容量を持つ AE が多様体 $\mathcal{M}$ を正確に再構成するとき、デコーダのヤコビ行列 $J_g(z)$ の有意特異値数は $\min(m, d_{\text{emb}})$ に等しい.

証明スケッチ: 正確な再構成時, g の値域は $\mathcal{M}$ の接空間 $T_{g(z)}\mathcal{M}$ に張られる. $\mathcal{M}$ が d 次元なら $\text{rank}(J_g) = d$ となり, 余剰次元の特異値は零に近づく. (有限容量・最適化誤差を無視.)

命題 6 (ノイズ方向選択性). DAE の最適再構成関数は, 多様体の法線方向のノイズを接線方向より選択的に除去する.

証明スケッチ: Alain ら [23] より, DAE の再構成方向 $r(x) - x \approx \sigma^2 \nabla \log p(x)$ であり, $\nabla \log p(x)$ は多様体の法線方向を強く指す (多様体仮説のもと). (漸近的最適解を仮定; 有限ノイズ・有限容量での近似誤差を無視.)

命題 7 (近傍構造保存と最適ボトルネック). $m = d_{\text{true}}$ (または d_{emb}) において, *Trustworthiness* が最大化に向けて急激に改善し, それ以上の m への増加による改善は限定的となる.

証明スケッチ: 命題 1 より, $m < d$ では連続単射が不可能で情報の衝突が不可避となり, *Trustworthiness* が低下する. $m \geq d$ で制約が解消され, $m > d$ では既に全多様体構造が表現可能であるため追加次元の効果は限定的. (有限サンプル・有限容量を無視.)

付録 B 定理 1 の詳細な導出

本付録では定理 1 の証明スケッチで省略した代数的ステップを詳述する.

注意 6 (近似の前提). 本導出における $L_j = -D_j/(2\tau^2) - \beta R_j$ という β -ELBO 寄与の表示は, VAE の期待 KL ダイバージェンス $\mathbb{E}_x KL(q(z_j|x)||p(z_j))$ を相互情報量 $R_j = I(z_j; y_j)$ と同一視する *rate-distortion surrogate* 近似を暗黙に含む. 実際の VAE の平均 KL は *aggregated posterior* と *prior* のずれも含むため, 本導出は「線形ガウス *rate-distortion* 近似のもとでの AU 活性条件」として解釈すべきである (定理 1 の前提に明示している通り).

Step 1: 最適デコーダ重みの導出

スカラー問題として, 方向 j に対し $y_j \sim \mathcal{N}(0, \lambda_j)$ (データの第 j 主成分), エンコーダ: $q_j(z_j|y_j) = \mathcal{N}(a_j y_j, \sigma_j^2)$, デコーダ: $\hat{y}_j = b_j z_j$ を考える. デコーダ重み b_j について, 周辺化した再構成 MSE を最小化する (σ_j^2, a_j を固定したとき):

$$D_j(b_j) = \mathbb{E}_{y_j, z_j} [(y_j - b_j z_j)^2] = \lambda_j - 2a_j \lambda_j b_j + b_j^2 (a_j^2 \lambda_j + \sigma_j^2). \quad (10)$$

$\partial D_j / \partial b_j = 0$ を解くと, 最適デコーダ重みは

$$b_j^* = \frac{a_j \lambda_j}{a_j^2 \lambda_j + \sigma_j^2} =: \frac{a_j \lambda_j}{\rho_j}, \quad \rho_j := a_j^2 \lambda_j + \sigma_j^2. \quad (11)$$

Step 2: 最適 MSE と相互情報量の表示

式 (11) を式 (10) に代入すると:

$$D_j^* = \lambda_j - \frac{a_j^2 \lambda_j^2}{\rho_j} = \frac{\lambda_j \sigma_j^2}{\rho_j}. \quad (12)$$

また, $y_j \rightarrow z_j$ の通信路容量 (相互情報量) は:

$$I(z_j; y_j) = \frac{1}{2} \log \frac{\rho_j}{\sigma_j^2} = \frac{1}{2} \log \left(1 + \frac{a_j^2 \lambda_j}{\sigma_j^2} \right) =: R_j. \quad (13)$$

Step 3: β -ELBO のレート歪み表示

$b_j = b_j^*$ を固定したもとの, (σ_j^2, a_j) に関する β -ELBO 寄与は $L_j = -D_j/(2\tau^2) - \beta R_j$ と書ける (KL 最小化との等価性 [1]). ρ_j をパラメータとして $D_j^* = \lambda_j \sigma_j^2 / \rho_j$, $R_j = \frac{1}{2} \log(\rho_j / \sigma_j^2)$ を代入すると, 本付録で用いる β -ELBO 寄与の式が得られる:

$$L_j = -\frac{\lambda_j \sigma_j^2}{2\tau^2 \rho_j} - \frac{\beta}{2} [\rho_j - 1 - \log \rho_j]. \quad (14)$$

(ここで $\sigma_j^2 = \rho_j - a_j^2 \lambda_j$, $\rho_j \geq \sigma_j^2$).

Step 4: KKT 条件による最適歪み D_j^* の導出

歪み $D_j \in (0, \lambda_j)$ を主変数として $L_j = -D_j/(2\tau^2) - \beta R_j(D_j)$ を最大化する. ガウス通信路のレート歪み関係 $R_j(D_j) = \frac{1}{2} \log(\lambda_j / D_j)$ より:

$$\frac{\partial L_j}{\partial D_j} = -\frac{1}{2\tau^2} + \frac{\beta}{2D_j} = 0 \implies D_j^* = \beta\tau^2. \quad (15)$$

これが Shannon の水充填定理 [1] の「水面 (water level)」 $\mu = \beta\tau^2$ に対応する。ただし式 (15) の解は $D_j^* = \beta\tau^2 \leq \lambda_j$ (フィジビリティ制約) が満たされる場合にのみ実行可能 (active) であり, $\lambda_j < \beta\tau^2$ の場合は次元 j を符号化しない ($a_j = 0$, dead) が最適となる。

Step 5 : 活性・不活性の ELBO 値の計算

不活性 (dead) : $a_j = 0$, $\sigma_j^* = 1$ (KL = 0), $D_j = \lambda_j$ のとき

$$L_j^{(\text{dead})} = -\frac{\lambda_j}{2\tau^2}. \quad (16)$$

活性 (active) : $D_j^* = \beta\tau^2$ を代入すると, $R_j^* = \frac{1}{2} \log(\lambda_j/(\beta\tau^2))$ であるから :

$$L_j^{(\text{active})} = -\frac{\beta\tau^2}{2} - \beta \cdot \frac{1}{2} \log \frac{\lambda_j}{\beta\tau^2} = -\frac{\beta}{2} - \frac{\beta}{2} \log \frac{\lambda_j}{\beta\tau^2}. \quad (17)$$

Step 6 : ELBO 利得 ΔL_j の厳密な表示と符号解析

活性化の利得 $\Delta L_j := L_j^{(\text{active})} - L_j^{(\text{dead})}$ を計算する。 $t := \lambda_j/(\beta\tau^2) > 0$ とおくと :

$$\Delta L_j = \left(-\frac{\beta}{2} - \frac{\beta}{2} \log t\right) - \left(-\frac{\beta\tau^2 \cdot t}{2\tau^2}\right) = \frac{\beta}{2}(t - 1 - \log t). \quad (18)$$

関数 $h(t) := t - 1 - \log t$ の解析 :

- $h'(t) = 1 - 1/t = (t-1)/t$ より, $t = 1$ で $h' = 0$ (唯一の停留点).
- $h''(t) = 1/t^2 > 0$ より, $t = 1$ は大域的最低点, $h(1) = 0$.
- $t > 0$, $t \neq 1$ のとき $h(t) > 0$ (大域最小値 0 より大).

したがって $\Delta L_j = (\beta/2) h(t)$ の符号は :

$$\Delta L_j > 0 \iff h(t) > 0 \iff t \neq 1. \quad (19)$$

Step 7 : フィジビリティと飽和条件の統合

活性解のフィジビリティ条件 ($D_j^* = \beta\tau^2 \leq \lambda_j$) は $t \geq 1$ を要求する。 $t < 1$ ($\lambda_j < \beta\tau^2$) では活性解が実行不可能であり dead が強制される。 $t = 1$ ($\lambda_j = \beta\tau^2$) では $\Delta L_j = 0$ (無差別)。 $t > 1$ ($\lambda_j > \beta\tau^2$) では活性が実行可能かつ $\Delta L_j > 0$ (優位)。

以上をまとめると :

$$\text{次元 } j \text{ が活性} \iff \lambda_j > \beta\tau^2, \quad (20)$$

すなわち定理 1 の飽和しきい値条件 (5) が成立する。 □

注意 7. 式 (18) の $h(t) = t - 1 - \log t$ は, $t = 1$ の近傍では 2 次展開により $h(t) \approx (t-1)^2/2$ (すなわち $\Delta L_j \approx (\lambda_j - \beta\tau^2)^2/(2\beta\tau^4)$) と近似できる。厳密な表示は式 (18) であり, この近似は活性化利得がしきい値 $\lambda_j = \beta\tau^2$ の近傍で 2 次的に小さくなることを直観的に示す補足である。

付録 C τ_{knee} の感度分析と横断検証 (実験 Exp-Tau-Cross)

$\tau_{\text{knee}} = 0.25$ の選択根拠

理論的根拠 : 定理 1 より, $\text{AU}(m)$ の生の増加率 $s(m) = \Delta \text{AU} / \Delta m$ (式 (2)) は $m < d^*(\beta)$ (飽和前) で $s \approx 1$ (新たな次元が完全に活性化), $m > d^*(\beta)$ (飽和後) で $s \rightarrow 0$ (追加次元は不活性) となる理論的な段

差を持つ。実際の AU は離散整数値であるため、この遷移は滑らか（または離散的）に起こる。 $\tau_{\text{knee}} = 0.25$ は「最大増加率の 1/4 以下」であり、飽和前 ($s \approx 1$) と飽和後 ($s \approx 0$) の中間点として「明確に鈍化した」領域の開始を捉えるバランスの良い閾値である。

正規化増加率 $\rho(m)$ (式 (3)) を指数飽和モデルで近似すると、

$$\rho(m) \approx \exp(-\gamma(m - d_{\text{ID}})) \quad (21)$$

となる。 $\rho(m) < \tau_{\text{knee}} = 0.25$ (正規化後の 25% 未満) となる点を鈍化点として定義する (式 (4))。

より厳密な閾値設定として、 $AU(m)$ の離散二階差分が最大となる点 (曲率最大点) を用いることが理論的に motivated であるが、AU の離散性により実データでは数値的に不安定になることが多い。 $\tau = 0.25$ はこの曲率最大点付近の安定した代替として機能する (Exp-Tau-Cross 感度分析参照)。

経験的根拠: MNIST (Exp-Mnist-Base 単一シード実験) では $\tau \in [0.1, 0.5]$ の全範囲で $m^{\text{knee}} = 12$ (安定)。 Fashion-MNIST では $\tau \approx 0.25$ が境界感度を持つ (表 24)。境界感度の存在は、 $AU(m)$ 曲線の勾配遷移が $\tau = 0.25$ 付近の値で起こることを示唆しており、この閾値の「効きやすさ」を逆に裏付ける。

データセット横断検証 (実験 Exp-Tau-Cross)

Fashion-MNIST および Gaussian 混合分布 (5 成分・10 成分) での横断検証結果を表 24 に示す。

表 24: Exp-Tau-Cross: Cross-dataset robustness verification of τ_{knee} (single run per dataset; protocol independent of Exp-Fashion, see text).

Dataset	AU_{sat}	TwoNN ID	$\tau = 0.1$	$\tau = 0.2$	$\tau = 0.25$	$\tau = 0.3$	$\tau = 0.4$	$\tau = 0.5$
Fashion-MNIST	10	7.00	20	20	20	8	8	8
GMix 5-comp.	1	4.27	2	2	2	2	2	2
GMix 10-comp.	3	3.02	2	2	2	2	2	2

Fashion-MNIST では $\tau = 0.25$ と 0.30 の境界で m^{knee} が 20 から 8 に変化する境界感度が確認された (AU 増加率が境界値 0.25 に一致する複数の m が存在するため)。この場合、二階差分代替手法 (§ 6.2 の安定化戦略参照) の使用を推奨する。

なお、表 24 の Fashion-MNIST の数値 ($AU_{\text{sat}} = 10$, TwoNN ID= 7.00, $\tau = 0.25$ で $m^{\text{knee}} = 20$) は、本横断検証専用の設定 (150 エポック, 横断検証用の疎グリッド, 独立の学習走行) で得られたものであり、§ 5.4 の Exp-Fashion (100 エポック, $m \leq 256$ の拡張グリッド) とは実験条件が異なる。したがって両者の絶対値は直接比較できず、本付録の目的は同一走行内での τ 感度の相対比較に限られる。

付録 D β 感度分析

MNIST サブセット ($n = 5,000$, 50 エポック) で $\beta \in \{1, 2, 4, 8\}$ の AU Dynamics を比較した (図 12)。




図 12: β -sensitivity analysis: AU vs m for MNIST VAE ($\beta \in \{1, 2, 4, 8\}$, 50 epochs, subset). At $\beta = 1$, $AU \approx m$ (insufficient regularization); at $\beta = 4$, $m_{\text{knee}} = 12$ (vertical dashed line); at $\beta = 8$, signs of excessive AU suppression at small m .

$\beta = 4$ を本実験のデフォルト値として採用した根拠: $\beta = 1$ では KL 正則化が弱く $AU \approx m$ のため m^{knee} が同定できない; $\beta = 8$ では過正則化により小さい m での AU が抑制され, m^{knee} の同定点がずれる可能性がある. $\beta \in [2, 8]$ では AU パターンの形状は安定することを確認したが, m^{knee} の精確な数値は m グリッドにも依存する (§ 6.1).

付録 E TwoNN 安定性・線形理論橋渡しの詳細 (Exp-Geom, Exp-Iso-ID, Exp-Mnist-PCA)

Exp-Geom: MNIST AE m -sweep

表 25: Exp-Geom: MNIST AE m -sweep — co-variation of κ and TwoNN ID. TwoNN stabilizes at $m \geq 48 \approx 5\hat{d}_{\text{ID}}$ despite κ jumping at $m = 96$ –128.

m	κ	TwoNN ID	Trustworthiness	Convergence
4	2.69	4.21	0.960	not yet converged
8	2.72	6.34	0.988	not yet converged
16	3.28	8.17	0.993	converging
32	4.32	9.36	0.997	converging
48	4.44	10.16	0.998	converged
64	4.25	10.17	0.998	stable
96	9.94	10.86	0.999	stable (despite κ increase)
128	37.0	10.98	0.999	stable (despite κ jump)

$n_{\text{train}} = 10,000$, 200ep, hidden=[512,256], seed=42

Exp-Iso-ID: Standard AE vs. IsometricAE on Swiss Roll

表 26: Exp-Iso-ID: Latent-space TwoNN ID comparison ($m \in \{2, 3, 4, 6, 8\}$, Swiss Roll, $d_{\text{true}} = 2$). At $m \geq 3$, TwoNN difference stays below $\pm 2.3\%$ despite κ differing by factor 2.

m	AE		IsometricAE		ID diff. (%)
	TwoNN ID	κ	TwoNN ID	κ	
2	1.780	1.76	1.799	1.08	+1.1%
3	2.458	2.10	2.454	1.11	-0.2%
4	2.483	1.80	2.479	1.14	-0.2%
6	2.421	1.79	2.474	1.10	+2.2%
8	2.500	1.45	2.443	1.11	-2.3%
Input-space TwoNN ID (reference) = 2.427; seed=42, hidden=[64, 32], 300ep					

Exp-Mnist-PCA: Linear Theory Bridge

MNIST PCA 固有値スペクトル (上位 12 成分): $\lambda_1 = 5.22$, $\lambda_2 = 3.76$, $\lambda_3 = 3.35$, $\dots$, $\lambda_{10} = 1.23$, $\lambda_{11} = 1.12$, $\lambda_{12} = 1.09$

表 27: Exp-Mnist-PCA: Linear theory $d^*(\beta = 4)$ for different τ^2 vs. nonlinear FC-VAE (300ep, 3 seeds).

τ^2	Water level $\beta\tau^2$	Linear d^*	Note
1.0	4.0	1	Conventional $\tau^2 = 1$ assumption; underestimates
0.30	1.20	10	Consistent with observed TwoNN ID
0.25	1.00	12	—
Nonlinear FC-VAE (300ep)			AU(64)= 22.3 ± 0.5 ; TwoNN(64)= 10.03 ± 0.12

定性的継承: AU(m) の単調性と「有効次元超過後の増加鈍化」は非線形設定でも継承される。定量的乖離: 非線形デコーダにより $\tau_{\text{eff}}^2 \approx 0.30 \ll 1$ となり, $d^* \approx 10$ が観測値と整合。飽和の滑らかさ (線形設定の急峻な遷移→非線形設定の漸増曲線) が m^{knee} の疎グリッド不安定性の理論的根拠である。

Exp-Real-Geom: MNIST 4 モデル比較 (全表)

§ 5.10 の要約表 (表 21) に対応する全 $m \cdot$ 全指標の結果を表 28 に示す。

表 28: Exp-Real-Geom: MNIST four-model comparison (mean $\pm$ std, 3 seeds). m -sweep with $\hat{d}_{\text{ID}} = 10$ as baseline ($m \in \{10, 20, 30, 50, 100\}$). TwoNN ID stabilization is strongly associated with increasing $m/\hat{d}_{\text{ID}}$, not with κ improvement.

Model	m	TwoNN ID	MLE ID	κ	Trust.	kNN overlap
AE	10 ($= d$)	7.3 ± 0.4	8.1 ± 0.3	85 ± 22	0.961 ± 0.004	0.73 ± 0.03
	20 ($= 2d$)	9.2 ± 0.3	10.1 ± 0.2	310 ± 85	0.975 ± 0.002	0.81 ± 0.02
	30 ($= 3d$)	9.8 ± 0.2	10.5 ± 0.2	$1.2 \times 10^3 \pm 4 \times 10^2$	0.981 ± 0.002	0.85 ± 0.02
	50 ($= 5d$)	10.0 ± 0.1	10.7 ± 0.1	$8.4 \times 10^3 \pm 3 \times 10^3$	0.985 ± 0.001	0.87 ± 0.01
	100 ($= 10d$)	10.0 ± 0.1	10.8 ± 0.1	$4.1 \times 10^7 \pm 2 \times 10^7$	0.987 ± 0.001	0.88 ± 0.01
IsometricAE	10 ($= d$)	7.5 ± 0.4	8.3 ± 0.3	3.2 ± 0.4	0.963 ± 0.003	0.74 ± 0.03
	20 ($= 2d$)	9.4 ± 0.2	10.2 ± 0.2	4.1 ± 0.6	0.976 ± 0.002	0.82 ± 0.02
	30 ($= 3d$)	9.9 ± 0.1	10.6 ± 0.1	5.2 ± 0.8	0.982 ± 0.001	0.86 ± 0.01
	50 ($= 5d$)	10.1 ± 0.1	10.8 ± 0.1	6.4 ± 1.1	0.986 ± 0.001	0.88 ± 0.01
	100 ($= 10d$)	10.1 ± 0.1	10.8 ± 0.1	7.8 ± 1.4	0.988 ± 0.001	0.89 ± 0.01
CAE	10 ($= d$)	7.2 ± 0.5	8.0 ± 0.4	12.1 ± 3.2	0.958 ± 0.005	0.72 ± 0.03
	20 ($= 2d$)	9.1 ± 0.3	10.0 ± 0.3	28.4 ± 8.1	0.974 ± 0.003	0.80 ± 0.02
	30 ($= 3d$)	9.7 ± 0.2	10.4 ± 0.2	95 ± 31	0.980 ± 0.002	0.84 ± 0.02
	50 ($= 5d$)	9.9 ± 0.1	10.6 ± 0.1	520 ± 180	0.984 ± 0.001	0.86 ± 0.01
	100 ($= 10d$)	10.0 ± 0.1	10.7 ± 0.1	$3.2 \times 10^3 \pm 1.1 \times 10^3$	0.986 ± 0.001	0.87 ± 0.01
DAE	10 ($= d$)	7.6 ± 0.4	8.4 ± 0.4	18.5 ± 5.4	0.964 ± 0.004	0.75 ± 0.03
	20 ($= 2d$)	9.3 ± 0.2	10.2 ± 0.2	44.2 ± 15.3	0.977 ± 0.002	0.82 ± 0.02
	30 ($= 3d$)	9.9 ± 0.1	10.5 ± 0.2	183 ± 62	0.982 ± 0.001	0.85 ± 0.01
	50 ($= 5d$)	10.0 ± 0.1	10.7 ± 0.1	$1.1 \times 10^3 \pm 380$	0.985 ± 0.001	0.87 ± 0.01
	100 ($= 10d$)	10.0 ± 0.1	10.8 ± 0.1	$6.3 \times 10^3 \pm 2.1 \times 10^3$	0.987 ± 0.001	0.88 ± 0.01

Exp-Real-Geom: Fashion-MNIST 4 モデル比較（補足）

Fashion-MNIST ($\hat{d}_{\text{ID}} = 9$, $m \in \{9, 18, 27, 45, 90\}$) についても Exp-Real-Geom と同一の 4 モデル・測定指標で実験を実施した。MNIST との定性的一致 ($m/\hat{d}_{\text{ID}}$ 増大が TwoNN 安定性の支配的因子) が確認された (定性的確認であり, 本稿では数値表を収録しない)。表 28 (MNIST, § 5.10) と同傾向: $m = d$ では TwoNN が過小推定, $m = 5d \sim 10d$ で収束, 等長性 (κ) 改善の TwoNN への影響は m 増大の効果より小さい。

付録 F Conv-VAE M512 拡張・自然画像スイープの詳細 (Exp-Conv-M512, Exp-NatImg-Sweep, Exp-NatImg-Knee)

Exp-Conv-M512 : MNIST Conv-VAE $m \in \{384, 512\}$ 拡張

表 29: Exp-Conv-M512: MNIST Conv-VAE with $m \in \{256, 384, 512\}$ (per seed; KL cyclic annealing, $\beta_{\text{max}} = 4$, 150ep). No AU saturation plateau observed up to $m = 512$.

m	AU (seed42)	AU (seed123)	AU (seed777)	TwoNN ID (seed42)
256	241	245	238	16.46
384	382	383	380	17.51
512	512	511	512	17.98
$m^{\text{knee}} (\tau = 0.25)$	All 3 seeds: $m^{\text{knee}} = 512$ (grid boundary, no saturation detected)			

$m \leq 512$ の全範囲で $AU \approx m$ が維持され, $d^*(\beta) > 512$ であることを示す (§ 5.6, § 6.6).

Exp-NatImg-AU : CIFAR-10 AU 飽和条件探索の詳細

§ 5.9 の実験設定と全結果を示す (単一シード 42).

実験設定 (Exp-NatImg-AU) :

- データ : CIFAR-10 ($n_{\text{train}} = 20,000$, $n_{\text{test}} = 3,000$)
- KL アニエリング : サイクリック ($n_{\text{cycles}} = 3$, 200 エポック)
- $\beta_{\text{max}} \in \{10, 20, 40\}$, $m \in \{32, 64, 96, 128, 192, 256, 384\}$, seed=42
- **Arch-A (Standard)** : エンコーダ Conv(3→32→64→128) + FC, デコーダ ConvT $\times 3$
- **Arch-B (Deep)** : エンコーダ Conv(3→64→128→256) + FC, デコーダ ConvT $\times 3$ (Arch-A の約 2 倍チャンネル)
- 生データ TwoNN ID: 25.30 (Pope ら [16] の報告値 $d_{\text{ID}} \approx 26$ と整合)

表 30: Exp-NatImg-AU: AU dependence on β_{max} and architecture in CIFAR-10 Conv-VAE (**single seed 42**). $m^{\text{knee}} = 384$ (grid boundary) for all conditions; no AU plateau detected within the tested range.

m	Arch-A (Standard)			Arch-B (Deep)	
	$\beta_{\text{max}} = 10$	$\beta_{\text{max}} = 20$	$\beta_{\text{max}} = 40$	$\beta_{\text{max}} = 20$	$\beta_{\text{max}} = 40$
32	32	32	32	32	32
64	64	64	64	64	59
96	96	96	93	96	80
128	128	128	117	126	97
192	192	191	155	170	123
256	256	251	200	208	147
384	382	378	307	286	208
m^{knee}	384	384	384	384	384




図 13: Exp-NatImg-AU: AU dynamics of CIFAR-10 Conv-VAE (single seed 42). (Left) Arch-A (Standard), (Right) Arch-B (Deep). Dotted line: $AU=m$ reference (no saturation). Increasing β_{max} strengthens AU suppression, but no saturation plateau is reached under any condition.

Exp-NatImg-Sweep : CIFAR-10 拡張スイープ詳細

表 31: Exp-NatImg-Sweep: Main results of CIFAR-10 extended sweep (mean $\pm$ std, 3 seeds). $\beta_{\max} = 80$, Thin decoder shows plateau-like AU ≈ 24 at $m \in [512, 1024]$. All five stable-identification criteria remain unmet.

$\beta_{\max}$	Decoder	m	AU	TwoNN ID	Note
10	Standard	384	185 $\pm$ 15	25.2 $\pm$ 0.4	—
20	Standard	512	241 $\pm$ 18	25.3 $\pm$ 0.4	no saturation
40	Standard	512	210 $\pm$ 21	25.1 $\pm$ 0.5	no saturation
40	Thin	384	127 $\pm$ 14	24.8 $\pm$ 0.6	partial suppression
80	Thin	512	24.1 $\pm$ 2.8	24.7 $\pm$ 0.5	plateau-like (conditional)
80	Thin	768	24.3 $\pm$ 3.1	24.7 $\pm$ 0.5	plateau continues
80	Thin	1024	24.0 $\pm$ 3.4	24.8 $\pm$ 0.5	plateau continues
80	Standard	512	198 $\pm$ 22	25.2 $\pm$ 0.5	no saturation (thin decoder only)

Stable identification 5 条件の達成状況 (§ 3.4, $\beta_{\max} = 80$, 薄型デコーダ): (1) シード安定性: $\sigma(m^{\text{knee}}) = 64 \rightarrow$ 未達, (2) グリッド安定性: 密化で $\pm 35\%$ 変動 $\rightarrow$ 未達, (3) β 安定性: $\beta_{\max} = 64$ では飽和消失 $\rightarrow$ 未達, (4) AU プラトー安定性: $\sigma = 13\%$ (基準 5%) $\rightarrow$ 未達, (5) TwoNN $\cdot$ AU 整合性: $m^{\text{knee}} \approx 512 \gg 3\hat{d}_{\text{ID}} = 75 \rightarrow$ 未達.

Exp-NatImg-Knee : m^{knee} 検出法比較

表 32: Exp-NatImg-Knee: Comparison of m^{knee} detection methods for CIFAR-10 ($\beta_{\max} = 80$, thin decoder, 3 seeds).

Detection method	m^{knee} (median)	σ (3 seeds)	Note
Fixed- τ method ($\tau = 0.25$)	512	128	Delayed detection due to gradual AU slope
Second-difference method	512	192	Sensitive to discrete noise, unstable
Smoothed curvature method (window=5)	384	96	Most stable (recommended for natural images)
Piecewise linear approximation (3 segments)	512	112	Comparable to fixed- τ method

全手法とも条件 1 ($\sigma \leq 51.2$) は未達であり, AU 飽和自体の安定化が先決である.

付録 G AU 閾値 δ の感度分析

Swiss Roll $\cdot$ Torus において $\delta \in \{0.001, 0.01, 0.05, 0.1\}$ で AU パターンが完全に一致することを確認した (全 $m \cdot \delta$ の組み合わせで一致). 活性次元の分散 ($O(1)$) と非活性次元の分散 ($O(10^{-4})$ 以下) の間に 2 桁以上の差があるため, δ の選択に対して頑健である.

付録 H 実験設定一覧

本論文の全実験の設定と位置づけを表 33 にまとめる。シード数 1 の実験は単一シードの結果であり，対応する本文の表・図キャプションにも明記している。

表 33: Full list of experimental configurations. Seeds = 1 marks single-seed results. Role: Main = core framework validation; Supp. = prerequisite/interpretive support; Boundary = validity-range quantification; Prelim. = preliminary observation.

Experiment	Data / Model	Epochs / β	m grid	Seeds	n_{train}	Role
Exp-Syn-1	Swiss Roll, Torus / AE	200–300 / —	$\{1, 2, 3, 4\}$	3	4,000	Main
Exp-Syn-AU	Swiss Roll, Torus / AE, VAE	200–300 / 4	$\{2, 4, 6, 8, 16\}$	3	4,000	Main
Exp-Syn-Top	Circle, Torus, Möbius / VAE	200–300 / 4	$\{1, \dots, 10\}$	1	4,000	Supp. (Prelim.)
Exp-Syn-Iso	Swiss Roll / AE, CAE, DAE, IsometricAE	300 / —	2	3	4,000	Supp.
Exp-Stab	Swiss Roll / AE, IsometricAE	300 / —	$\{2, 4\}$	1	4,000	Supp.
Exp-Iso-ID	Swiss Roll / AE, IsometricAE	300 / —	$\{2, 3, 4, 6, 8\}$	1	4,000	Supp.
Exp-Geom	MNIST / AE	200 / —	$\{4, \dots, 128\}$	1	10,000	Supp.
Exp-Mnist-Base	MNIST / AE, VAE	300 / 4	$\{1, 4, 8, \dots, 256\}$	1	20,000	Main (Prelim. m^{knee})
Exp-Mnist-Multi-150	MNIST / VAE	150 / 4	$\{4, 8, \dots, 64\}$	3	20,000	Main
Exp-Mnist-Multi-300	MNIST / VAE	300 / 4	$\{4, 8, \dots, 64\}$	3	20,000	Main
Exp-Mnist-Dense-300	MNIST / VAE	300 / 4	17 pts (step 1 near $\hat{d}_{\text{ID}}$)	3	20,000	Main
Exp-Mnist-PCA	MNIST / PCA	— / —	—	—	20,000	Supp.
Exp-Mnist-Dyn	MNIST / VAE	200 / 4	16	1	20,000	Prelim.
Exp-Mnist-Ent	MNIST / VAE	75 / 4	—	1	20,000	Prelim.
Exp-Fashion	Fashion-MNIST / AE, VAE	100 / 4	$\{1, 4, \dots, 256\}$	1	10,000	Prelim. external check
Exp-Real-Geom	MNIST, Fashion / AE, CAE, DAE, IsometricAE	300 / —	$\{d, 2d, 3d, 5d, 10d\}$	3	20,000	Main
Exp-Conv-AE	MNIST / Conv-AE, Conv-VAE	100 / 4	$\{4, \dots, 64\}$	1	20,000	Supp.
Exp-Conv-Fix, Exp-Conv-Ann	MNIST / Conv-VAE	300 / 4 (fixed, cyclic)	$\{4, \dots, 64\}$	3	20,000	Boundary
Exp-Conv-M256	MNIST / Conv-VAE	150 / cyclic 4	$\{4, \dots, 256\}$	3	20,000	Boundary
Exp-Conv-M512	MNIST / Conv-VAE	150 / cyclic 4	$\{384, 512\}$	3	20,000	Boundary
Exp-ConvV-HiBeta	MNIST / Conv-VAE	150 / cyclic $\{10, 20\}$	$\{16, \dots, 256\}$	1	20,000	Boundary
Exp-Nat-Cifar, Exp-Nat-SVHN	CIFAR-10, SVHN / Conv-VAE	150 / cyclic 4	$\{16, \dots, 256\}$	3	20,000	Boundary
Exp-NatImg-AU	CIFAR-10 / Conv-VAE (2 arch.)	200 / cyclic $\{10, 20, 40\}$	$\{32, \dots, 384\}$	1	20,000	Boundary
Exp-NatImg-Sweep	CIFAR-10 / Conv-VAE (3 decoders)	300 / cyclic $\{10, \dots, 80\}$	$[32, 1024]$	3	20,000	Boundary
Exp-NatImg-Knee	CIFAR-10 / Conv-VAE	300 / cyclic 80	$[32, 1024]$	3	20,000	Boundary
Exp-Tau-Cross	Fashion, GMix / VAE	150 / 4	sparse	1	—	Supp.
β -sensitivity	MNIST subset / VAE	50 / $\{1, 2, 4, 8\}$	$\{4, \dots, 64\}$	1	5,000	Supp.