

入力データの内在次元に基づく AE/VAE ボトルネック次元の 選定：

ID 誘導型プロトコルと Active-Unit 検証

(著者名)

(所属機関)

(メールアドレス)

概要

オートエンコーダ (AE) および変分オートエンコーダ (VAE) のボトルネック次元 m は、表現の質を左右する最も基本的な設計パラメータであるにもかかわらず、実務では試行錯誤や慣習により選ばれることが多い。本論文は、多様体仮説のもとで m を入力データの内在次元 (多様体次元) の推定値 $\hat{d}_{\text{ID}}$ から選定し、その選定を VAE の Active Units (AU) で検証するという ID 誘導型選定プロトコル (推定→設定→検証の 3 ステップ) を提案する。理論面では、(i) 自己交差のない再構成に $m \geq d_{\text{emb}} \geq d_{\text{ID}}$ が必要という位相的下界と、(ii) 線形ガウス設定における水充填型のサロゲート活性化条件 $\lambda_j > \beta \tau^2$ (λ_j : 入力共分散の固有値, τ^2 : 観測ノイズ分散) を根拠として、「 m は $\hat{d}_{\text{ID}}$ より大きめに設定すれば、VAE の KL 正則化が余剰次元を自動遮断し、AU がその遮断結果を報告する」という選定原理を与える。実験面では、真の次元が既知の合成多様体 (3 シード) でプロトコルが正しい次元を返すこと (Swiss Roll: $\text{AU}_{\text{sat}} = d_{\text{true}} = 2$, Torus: $\text{AU}_{\text{sat}} = d_{\text{emb}} = 3$), MNIST (3 シード) で $\hat{d}_{\text{ID}} = 10.03 \pm 0.12$ (TwoNN) と AU 増加の鈍化領域が整合することを示す。さらに、プロトコルの適用限界を定量化する: 内在次元推定は $m \gg \hat{d}_{\text{ID}}$ の参照表現でのみ安定し (4 モデル比較, MNIST・Fashion-MNIST, 3 シード), 自然画像では $m \approx 2\hat{d}_{\text{ID}}$ を超えると推定値が膨張する; Conv-VAE では β が小さいと AU 遮断が機能しない ($\beta = 4$ で $d^*(\beta) > 512$)。本検証は中規模データ・全結合型 VAE を中心とし、大規模自然画像への完全適用と変化点検出の独立検証は今後の課題である。

1 まえがき

1.1 研究背景：ボトルネック次元をどう選ぶか

オートエンコーダ (Autoencoder; AE) および変分オートエンコーダ (Variational Autoencoder; VAE) [1] は、高次元データから低次元の潜在表現を学習する中核的な非教師あり学習モデルである [2]。その最も基本的な設計パラメータがボトルネック次元 m である: m が小さすぎると情報が欠落し、大きすぎると冗長な次元が生じ、VAE では posterior collapse[3] の解釈を複雑にする。にもかかわらず、 m の選定は実務では「32 や 64 などの切りのよい値」や試行錯誤に委ねられることが多く、データに根ざした選定原理は十分に確立されていない。

一方、多様体仮説 [4] によれば、自然データは高次元の入力空間 $\mathbb{R}^N$ 内の低次元多様体の近傍に集中しており、その局所的な自由度は内在次元 (intrinsic dimension) $d_{\text{ID}} \ll N$ で特徴づけられる。実際、自然画像の d_{ID} が画素数よりはるかに小さいことが TwoNN[5] 等の推定量で報告されている [7]。この見方に立てば、**ボトルネック次元 m の適切な大きさは、モデル側の慣習ではなく、入力データ側の量——多様体次元——によって決まるはず**である。本論文が取り組む問いは次のとおりである：

AE/VAE のボトルネック次元 m を、入力データの内在次元 (多様体次元) の推定値から原理的に選定できるか？そして、その選定が適切であったことを学習後に検証する手段はあるか？

1.2 中心アイデアと貢献

本論文の中心的主張は一文で述べられる：

ボトルネック次元 m は入力データの内在次元の推定値 $\hat{d}_{\text{ID}}$ から「 $m \gtrsim \hat{d}_{\text{ID}}$ (位相的余裕を含む)」として選定でき、VAE の Active Units (AU) ——KL 正則化が実際に使用している座標数——がその選定の学習後検証信号として機能する。

この主張の根拠は理論と実験の両面から与えられる。理論面では、(i) d 次元多様体を自己交差なく再構成するには $m \geq d_{\text{emb}} \geq d_{\text{ID}}$ が必要という位相的下界 (命題 1) と、(ii) 線形ガウス設定の水充填解析から得られる活性化条件 $\lambda_j > \beta\tau^2$ (命題 2) である。後者は「 m を $\hat{d}_{\text{ID}}$ より大きめに設定しても、VAE の KL 正則化が余剰次元を自動的に遮断 (posterior collapse) し、AU が実効的な使用次元数を報告する」ことを理想化設定で保証する——すなわち、AE では m の選定そのものが表現次元を決めるのに対し、VAE では「大きめの $m + \text{AU}$ による読み取り」という安全側の運用が可能になる。

本論文の貢献は次の 3 点である：

1. **ID 誘導型ボトルネック次元選定プロトコル** (§ 3) : (S1) $\hat{d}_{\text{ID}}$ の推定 (TwoNN/MLE ; 実データでは $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ の参照 AE 経由), (S2) m の設定 (AE : $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}] + \text{位相的余裕}$; VAE : $m \gtrsim 2\hat{d}_{\text{ID}}$ の大きめ設定), (S3) AU・再構成誤差による学習後検証, の 3 ステップからなる実行可能な手順を, 判定規則・失敗モード・報告要件とともに与える。
2. **選定原理の理論的根拠** (§ 4) : 位相的下界 (命題 1) と, 線形ガウス rate-distortion 近似におけるサロゲート活性化条件 $\lambda_j > \beta\tau^2$ (命題 2 ; τ^2 は等方ガウス観測ノイズ分散, KL 項と相互情報量の対応は aggregated-posterior 項を無視した近似である点を主張本体に明記) を整理し, 「VAE は m の過剰を自動修復するが, その遮断閾値は β に依存する」という運用上の含意を導く。
3. **多シード実証と適用境界の定量化** (§ 5) : 真の次元既知の合成多様体 (3 シード) でプロトコルが正しい次元を返すことを確認し, MNIST (3 シード) で $\hat{d}_{\text{ID}} \approx 10\text{--}12$ と AU 鈍化域の整合を示す。さらに適用限界を定量化する : (a) $\hat{d}_{\text{ID}}$ 推定は $m \gg \hat{d}_{\text{ID}}$ の参照表現でのみ安定であり, 等長性の改善は副次的である (4 モデル比較, MNIST・Fashion-MNIST, 3 シード ; 命題 3) ; (b) 自然画像では TwoNN 推定が $m \approx 2\hat{d}_{\text{ID}}$ までは既報値 [7] と整合するがそれ以上で膨張する ; (c) Conv-VAE では $\beta = 4$ で遮断閾値 $d^*(\beta)$ が 512 を超え, AU 検証には β の増強が必要である。

既存研究との違い : 深層表現の内在次元を「測る」研究 [8, 7, 9] が学習済みネットワークの解析にとどまるのに対し, 本研究は内在次元推定を**ボトルネック次元の設計**に用い, その設計の妥当性を AU で閉ループ検証する手順として定式化する。posterior collapse の線形解析 [3] が定性的議論にとどまるのに対し, 本研究は閉形式閾値 $\lambda_j > \beta\tau^2$ として整理し (新規性は統合的整理にある ; § 4), 選定プロトコルの根拠として運用する。

1.3 「多様体次元のようなもの」の 2 つの顔 : d_{ID} と d_{emb}

本論文では「入力データの多様体次元」として 2 つの量を区別する : **局所的内在次元** d_{ID} (多様体の局所自由度 ; TwoNN/MLE の推定対象) と **位相的最小埋め込み次元** d_{emb} (自己交差なくユークリッド空間に埋め込むための最小次元)。Swiss Roll では $d_{\text{emb}} = d_{\text{ID}} = 2$ だが, Torus では $d_{\text{emb}} = 3 > d_{\text{ID}} = 2$ である。ボトルネックに必要なのは d_{emb} (命題 1) であり, d_{ID} しか推定できない実データでは, この差 (位相的障害) が「 $\hat{d}_{\text{ID}}$ より大きめに取る」余裕の一因となる (§ 3.2.2)。

1.4 本論文の限界（要約）

本論文の検証は、真の次元既知の合成多様体 ($d_{\text{true}} \leq 3$), MNIST・Fashion-MNIST (全結合型 AE/VAE, 3 シード), および適用境界の定量化としての Conv-VAE・自然画像 (CIFAR-10・SVHN) に限られる. $\hat{d}_{\text{ID}}$ (TwoNN/MLE) は「数値的に安定」であっても「真の内在次元に対して不偏」とは限らず (安定性と妥当性の区別; § 6.2), 本論文は $\hat{d}_{\text{ID}}$ を選定の**参照値**として扱う (真値の推定を主張しない). AU 曲線上の変化点 (knee) の自動検出は, グリッド・シード依存性が強い本プロトコルの名前付き出力とはせず, 探索的解析として付録付録 B に位置づける. 大規模自然画像への完全適用は今後の課題である.

以降, § 2 で関連研究, § 3 でプロトコル, § 4 で理論的根拠, § 5 で実験, § 6 で考察, § 7 でむすびを述べる. 証明・感度分析・探索的実験は付録にまとめる.

2 関連研究

表現学習とオートエンコーダ: Bengio ら [2] は, AE が多様体仮説 [4] に基づき高次元データの低次元構造を学習する枠組みを整理した. β -VAE[11] は KL 正則化の重み β により表現の圧縮度を制御し, AU に直接影響する. DAE[13]・CAE[14] は正則化により多様体構造の学習を促す変種であり, 本論文では内在次元推定の参照表現としての適性を比較する対象となる (§ 5.4).

深層表現の内在次元解析: Pope ら [7] は自然画像の内在次元が画素次元よりはるかに低いことを示し (CIFAR-10: $d_{\text{ID}} \approx 26$), Ansuini ら [8] は深層ネットワーク各層の ID 変化を定量化した. Valeriani ら [9] は大規模 Transformer の隠れ表現幾何を解析し, Birdal ら [10] は ID と汎化の関係を論じた. これらは学習済みモデルを「測る」研究であり, 本研究は測定値を**ボトルネック次元の設計と検証**に用いる点で相補的である. ID 推定量としては TwoNN[5] と MLE[6] を採用する (DANCo[17] はより精密だが計算コストが高く, 今後の課題とする).

Active Units と posterior collapse: AU[11, 3] は事後平均の分散が閾値 δ を超える潜在次元数であり, KL 正則化が実際に使用している座標数を測る. Lucas ら [3] は線形 VAE で posterior collapse の機構を分析した. 本研究は, この機構を「 m の過剰設定を自動修復する安全装置」として選定プロトコルに組み込み, その定量的根拠として水充填型の活性化条件 (命題 2; Tipping & Bishop[12] の PPCA は $\beta = 1$ の特殊ケース) を用いる.

幾何的オートエンコーダ: Nazari ら [16]・Kato ら [15] は潜在空間の幾何 (等長性) を保つ正則化を提案した. 本研究では, 等長性が ID 推定の安定性に与える影響を「ボトルネック余裕 $m/\hat{d}_{\text{ID}}$ 」と比較し, 後者が支配的であることを示す (§ 5.4).

3 ID 誘導型ボトルネック次元選定プロトコル

3.1 問題設定と主要記号

AE/VAE を入力次元 N , ボトルネック次元 m , エンコーダ $f: \mathbb{R}^N \rightarrow \mathbb{R}^m$, デコーダ $g: \mathbb{R}^m \rightarrow \mathbb{R}^N$ で定義する. VAE ではエンコーダが事後分布 $q_\phi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x))$ を出力し, KL 正則化 (強度 β) が情報ボトルネックとして作用する.

Active Units (AU) を

$$\text{AU}(m) = \sum_{k=1}^m \mathbf{1}[\text{Var}_x[\mu_k(x)] > \delta], \quad \delta = 10^{-2} \quad (1)$$

で定義する ($\mu_k(x)$ は事後平均の第 k 成分; 閾値 δ は Lucas ら [3] に準拠し, $\delta \in [10^{-3}, 10^{-1}]$ で AU 値がほぼ不変であることを確認済み; 付録付録 D). AU はテストデータ上で計算する (学習・テストの別は各実験節

に明記する).

表 1: Main symbols. Each quantity is distinguished so that the protocol’s claims are stated without conflating targets and estimators.

Symbol	Meaning	Role in the protocol
m	Bottleneck dimension	Design parameter to be chosen
d_{ID}	Intrinsic dimension of the data manifold	Target quantity (unknown for real data)
d_{emb}	Topological minimum embedding dimension ($\geq d_{\text{ID}}$)	Lower bound for m (Prop. 1)
$\hat{d}_{\text{ID}}$	TwoNN/MLE estimate of d_{ID}	Reference value for Step 1 (may be biased)
$\text{AU}(m)$	Number of KL-active coordinates, Eq. (1)	Verification signal for Step 3
AU_{sat}	Saturated (plateau) AU value	Read-out of effective dimension (VAE)
$d^*(\beta)$	Water-filling threshold count (Prop. 2)	Idealized prediction of AU_{sat}
κ	Decoder Jacobian condition number	Isometry (distortion) indicator

ここで強調すべき区別が 2 つある. 第一に, $\hat{d}_{\text{ID}}$ は**参照値であって真値ではない**: TwoNN/MLE は数値的に安定 (低分散) であっても, 参照表現の幾何的歪みによる系統的バイアスを持ちうる (安定性と妥当性の区別; § 6.2). 第二に, AU は**内在次元の推定量ではない**: AU は「KL 正則化が使用を許した座標数」という観測量であり, $\beta \cdot \delta$ ・アーキテクチャに依存する. プロトコルはこの 2 つの異なる量を突き合わせることで, 単一指標への過信を避ける設計になっている.

3.2 プロトコル本体



図 1: ID-guided protocol for choosing the bottleneck dimension m . The protocol closes the loop: the data-side estimate $\hat{d}_{\text{ID}}$ determines the design, and the model-side observable AU verifies the design after training.

3.2.1 Step 1：内在次元の推定

合成データや低次元データでは、入力空間に TwoNN/MLE を直接適用すればよい。高次元の実データ（例：MNIST の $N = 784$ ）では距離集中により直接推定が不安定になるため、**大きめの参照 AE** ($m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ ；**本論文では** $m_{\text{ref}} = 256$) **の潜在表現を経由して推定する**。このとき次の 2 点を必須とする：(i) 複数の m_{ref} （例： $\{64, 128, 256\}$ ）で推定値の収束を確認する；(ii) 原理の異なる 2 推定量（TwoNN と MLE）を併記し、同一オーダーであることを確認する。 $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ という条件が推定の安定性の支配的条件であることは命題 3 と実験 (§ 5.4) で裏づける。逆に、 $m_{\text{ref}} \lesssim 3\hat{d}_{\text{ID}}$ では系統的な過小推定が生じ、自然画像では $m_{\text{ref}} \gg 2\hat{d}_{\text{ID}}$ で逆に膨張が生じる (§ 5.5) —Step 1 の信頼域は m_{ref} に対して有界である点に注意する。

3.2.2 Step 2：ボトルネック次元の設定

AE の場合： $m < d_{\text{emb}}$ では原理的に自己交差なしの再構成が不可能であり（命題 1）、 m の過剰は冗長次元として残る（AE には自動遮断がない）。よって $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}]$ を候補範囲とし、位相的障害 ($d_{\text{emb}} > d_{\text{ID}}$ ；Torus 型) の可能性を余裕として吸収する。用途が再構成精度重視なら範囲の上側、圧縮重視なら下側を選ぶ。

VAE の場合：命題 2 の含意により、 m が必要次元を超えても KL 正則化が余剰次元を遮断するため、 $m \gtrsim 2\hat{d}_{\text{ID}}$ と**大きめに設定するのが安全側の運用**である。ただし遮断閾値は β に依存する ($d^*(\beta) = |\{j : \lambda_j > \beta\tau^2\}|$)： β が小さすぎると遮断が機能せず $\text{AU} = m$ のまま張り付く（Step 3 で検出可能）。

3.2.3 Step 3：学習後検証

学習後、設計の妥当性を次の 2 つの信号で検証する（いずれも複数シードで）：

- **VAE：AU 検証**. $\text{AU}(m)$ が m より小さく飽和（または増加が鈍化）し、その水準が $\hat{d}_{\text{ID}}$ と同一オーダーにあれば、「データの多様体次元を反映した圧縮が起きている」ことの証拠となる。単純な多様体では急峻な飽和 ($\text{AU}_{\text{sat}} = d_{\text{true}}$ または d_{emb}) が、実データでは緩やかな鈍化が現れる (§ 5.3)。
- **AE：MSE 検証**. $\text{MSE}(m)$ の急速な改善が $m \approx \hat{d}_{\text{ID}} \sim 2\hat{d}_{\text{ID}}$ で鈍化するかを目視確認する（アルゴリズム的な肘点検出器は提案しない；変化点の自動検出はグリッド・シード依存性が強く、付録付録 B の探索的解析にとどめる）。

検証が不整合の場合の失敗モードを表 2 に整理する。これは本プロトコルを新しいデータ・アーキテクチャに適用する読者のための診断チェックリストである。

表 2: Failure modes in Step 3 and their diagnoses. Each row is backed by the experiments in § 5.

Symptom	Likely cause	Remedy / interpretation
$\text{AU} = m$ for all tested m (no truncation)	β too small relative to decoder power ($d^*(\beta) \gg m$)	Increase β or restrict decoder capacity; see Conv-VAE boundary (§ 5.5)
AU saturates far above $\hat{d}_{\text{ID}}$	Step-1 underestimate (m_{ref} too small), or entangled multi-class structure	Re-check Step 1 convergence in m_{ref} ; treat AU_{sat} as upper reference
$\hat{d}_{\text{ID}}$ inflates as m_{ref} grows (no convergence)	Latent geometry distortion at large m_{ref} (natural images)	Restrict to $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$ and cross-check with input-space estimate
MSE keeps improving beyond $2\hat{d}_{\text{ID}}$	Topological obstruction ($d_{\text{emb}} > d_{\text{ID}}$) or noise fitting	Allow larger margin; inspect reconstruction quality

報告要件：本プロトコルの適用結果を報告する際は、(i) シード数と $\hat{d}_{\text{ID}} \cdot \text{AU}$ のシード間分散、(ii) m グリッドと m_{ref} の値、(iii) $\beta \cdot \delta$ ・前処理、(iv) TwoNN と MLE の両推定値、を最低限記載する。本論文の全

実験もこの要件に従う.

3.3 適用可能範囲（先出し要約）

本プロトコルがどの設定で機能し、どこで境界に達するかを表 3 に先出しする（証拠は § 5）. 読者はまずこの表で自分の設定が適用域にあるかを確認されたい.

表 3: Applicability of the ID-guided protocol (summary of the evidence in § 5). “Stable” means low inter-seed variance under our experimental conditions, not unbiasedness.

Setting	Step 1 ($\hat{d}_{\text{ID}}$)	Step 3 (AU verification)	Overall
Synthetic manifolds ($d_{\text{true}} \leq 3$, 3 seeds)	Direct input-space estimate; matches d_{true}	Sharp saturation at $d_{\text{true}} / d_{\text{emb}} (\sigma = 0)$	Fully applicable (ground-truth validated)
FC-VAE on MNIST / Fashion-MNIST (3 seeds)	Stable: $10.03 \pm 0.12 / \approx 9$	Gradual slowdown consistent with $\hat{d}_{\text{ID}}$	Applicable
Conv-VAE on MNIST	Stable (inflates while $\text{AU} = m$)	Requires $\beta_{\text{max}} \geq 10$; at $\beta_{\text{max}} = 4$, $d^*(\beta) > 512$	Applicable only with strong β (exploratory)
Natural images (CIFAR-10 / SVHN, 3 seeds)	Consistent with Pope et al. [7] at $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$; inflates beyond	No AU saturation within tested range	Step 1 usable with care; Step 3 open problem

4 選定原理の理論的根拠

本章の結果の位置づけを先に明示する. 命題 1 は理想化（ゼロ再構成誤差）のもとでの厳密な下界, 命題 2 は線形ガウス設定に限定した解析結果であり, 非線形 VAE への適用は定性的な指針（解釈的サロゲート）にとどまる. 命題 3 は Step 1 の設計根拠を与える条件付き安定性のスケッチである.

4.1 必要条件：位相的下界

命題 1 (ボトルネック次元の位相的下界). 滑らかな d 次元多様体 $\mathcal{M} \subset \mathbb{R}^N$ を連続な AE により自己交差なく再構成し, 理想的にゼロ再構成誤差を達成するためには, $m \geq d_{\text{emb}} \geq d$ が必要である (d_{emb} は $\mathcal{M}$ の位相的最小埋め込み次元).

Proof. ゼロ再構成誤差には $f|_{\mathcal{M}} : \mathcal{M} \rightarrow \mathbb{R}^m$ が連続な単射である必要があり, d 次元多様体の $\mathbb{R}^m$ ($m < d_{\text{emb}}$) への連続単射埋め込みは位相的埋め込み次元の定義より存在しない [21]. $\square$

これが Step 2 の下側限界の根拠である. 実データでは d_{emb} は未知だが $d_{\text{emb}} \geq d_{\text{ID}}$ なので, $\hat{d}_{\text{ID}}$ は「これ未満は原理的に不足」という参照点を与え, $d_{\text{emb}} > d_{\text{ID}}$ の可能性 (Torus 型の位相的障害) が「 $\hat{d}_{\text{ID}}$ より大きめに取る」余裕の一因となる. 実験では Swiss Roll ($d_{\text{emb}} = 2$) と Torus ($d_{\text{emb}} = 3 > d_{\text{ID}} = 2$) でこの下界が MSE の肘点として現れることを確認する (§ 5.2).

4.2 十分条件側の機構：水充填型サロゲート活性化条件

命題 2 (線形ガウス rate-distortion 近似におけるサロゲート活性化条件). 線形エンコーダ・デコーダとガウス事前分布を持つ β -VAE を考える (詳細は付録付録 A). ここで τ^2 はデコーダ出力の等方ガウス観測ノイズ分散 (尤度 $p(x|z) = \mathcal{N}(g(z), \tau^2 I)$ の分散パラメータ), λ_j はセンタリング済み入力データの共分散行列の第

j 固有値である．さらに， KL 項を相互情報量で置き換える *rate-distortion* 近似を用いる（この置き換えは *aggregated-posterior* と事前分布の不一致項を無視した近似であり，本命題の成立範囲はこの近似の範囲内に限られる）．このとき，水充填定理と KKT 条件から：

1. (活性化しきい値) 第 j 固有方向が活性となる必要十分条件は

$$\lambda_j > \beta\tau^2. \quad (2)$$

2. (最適活性数) 大域最適解の活性固有方向数は $A^*(m) = \min(m, d^*(\beta))$, $d^*(\beta) := |\{j : \lambda_j > \beta\tau^2\}|$.

3. (単調飽和) $A^*(m)$ は m について単調非減少で， $m \geq d^*(\beta)$ で飽和する．

本命題は学習済み非線形 VAE に関する定理ではなく，非線形実験を解釈するための**解釈的サロゲート**である（導出は付録付録 A）．

注意 1 (プロトコルへの含意)．(i) $m > d^*(\beta)$ の余剰次元は最適解で遮断される——これが Step 2「VAE では大きめの m が安全」の根拠である．(ii) 遮断閾値 $\beta\tau^2$ は β に比例する—— β が小さすぎれば $d^*(\beta) > m$ となり遮断が起きない ($AU = m$)．これが表 2 第 1 行の失敗モードであり，Conv-VAE・自然画像で実際に観測される (§ 5.5)．(iii) $\beta = 0$ (*vanilla AE*) では閾値が消失し全次元が使用される——AE に自動遮断がなく，Step 2 で m 自体を絞る必要がある理由である．

注意 2 (経験的 AU との乖離)．実際の非線形 VAE では各 m で独立に確率的最適化を行うため，経験的 $AU(m)$ は非単調な揺らぎを持ち，線形設定の鋭い飽和は緩やかな鈍化に置き換わる (§ 5.3)．また，非線形デコーダの実効ノイズ分散を「観測された有効次元と整合するよう逆算した」校正值 τ_{eff}^2 で置き換える議論 (§ 5.5) は，本命題の帰結ではなく**ヒューリスティックな外挿**である．

4.3 Step 1 の根拠：内在次元推定の条件付き安定性

命題 3 (TwoNN の条件付き安定性 (スケッチ))．エンコーダ f が局所 *bi-Lipschitz* (歪み $\varepsilon \in [0, 1)$) であり，かつ近傍順位が高確率で保存される ($\text{Trustworthiness} \geq 1 - \delta_T$, δ_T 小) ならば，2 近傍距離比 r_2/r_1 の分布変化は ε と δ_T の連続関数 $C(\varepsilon, \delta_T)$ ($\varepsilon, \delta_T \rightarrow 0$ で $C \rightarrow 0$) で上界され，入力空間と潜在空間の *TwoNN* 推定値の差もこれに支配される．本命題は不偏性の保証ではなく，条件付き安定性の十分条件のスケッチである（証明スケッチは付録付録 A）．

実験 (§ 5.4) では， ε (等長性) の改善よりも $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ による δ_T (近傍順位保存) の改善が支配的であることを示す——これが Step 1 で「等長正則化よりもボトルネック余裕」を優先する設計根拠である．

5 実験

実験は 3 層で構成する：(i) **原理検証**——真の次元既知の合成多様体でプロトコルが正しい次元を返すか (§ 5.2)；(ii) **実データ検証**——MNIST・Fashion-MNIST でプロトコル全体が機能するか (§ 5.3, § 5.4)；(iii) **適用境界**——Conv-VAE・自然画像でどの条件が破れるか (§ 5.5)．**本文の結果はすべて 3 シード (42, 123, 777) 以上の多シード実験**であり，単一シードの探索的観察は付録付録 C に分離した（例外は本文中に明記する）．

5.1 実験設定

共通：Adam (lr = 10^{-3} , $\beta_1 = 0.9$, $\beta_2 = 0.999$, weight decay なし)，バッチサイズ 128, ReLU (出力層 Sigmoid), PyTorch 2.0, 単一 NVIDIA GeForce RTX 3070 GPU (CUDA 不可時は CPU)．前処理は

画素値の $[0, 1]$ 正規化のみ（合成多様体は標準化：平均 0・分散 1）．学習・テスト部分集合は公式分割の先頭 $n_{\text{train}} \cdot n_{\text{test}}$ サンプルを固定順で使用．AU・TwoNN・MLE はテスト部分集合上で計算する．

合成多様体：隠れ層 $[64, 32]$ ，200–300 エポック，VAE $\beta = 4.0$ ， $n = 5,000$ （学習 4,000／テスト 1,000）．

MNIST / Fashion-MNIST：入力次元 784，隠れ層 $[512, 256]$ ，VAE $\beta = 4.0$ ， m グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$ （実験ごとの変更は明記），MNIST：300 エポック（ $n_{\text{train}} = 20,000$ ， $n_{\text{test}} = 3,000$ ），Fashion-MNIST：300 エポック（Exp-Real-Geom； $n_{\text{train}} = 20,000$ ）．

ID 推定：TwoNN ($k = 2$) [5]，MLE ($k = 10$ ； $k \in \{5, 10, 20\}$ で安定性確認済み) [6]．AU 閾値 $\delta = 10^{-2}$ （付録付録 D）．

再現性：実験コード・設定・乱数シード・学習ログ（JSON）・主要な表と図の再生成スクリプトは査読時に補助資料として添付し，採録時に公開リポジトリ（GitHub/Zenodo）の URL と DOI を確定する．

5.2 原理検証：真の次元既知の合成多様体

Swiss Roll ($d_{\text{true}} = d_{\text{emb}} = 2$) と Torus ($d_{\text{true}} = 2$ ， $d_{\text{emb}} = 3$) でプロトコルの 3 ステップを ground truth に対して検証した（3 シード）．

Step 1：入力空間の TwoNN は Swiss Roll で ≈ 2.0 ，Torus で ≈ 2.0 と d_{true} に一致する．

Step 3 (AE：MSE 検証)：表 4 のとおり，MSE の急改善は Swiss Roll で $m = 2 = d_{\text{emb}}$ ，Torus で $m = 3 = d_{\text{emb}}$ で止まる——命題 1 の下界が実際に MSE 肘点として現れ，Torus では「 $d_{\text{ID}} = 2$ では足りない」という位相的障害が観測される．これが Step 2 の余裕（ $\hat{d}_{\text{ID}}$ より大きめ）の実験的根拠である．

表 4: Synthetic manifolds (Exp-Syn-1): AE reconstruction MSE (mean $\pm$ std, 3 seeds). The elbow appears exactly at $m = d_{\text{emb}}$.

m	Swiss Roll MSE	Torus MSE
1	1.016 ± 0.315	0.356 ± 0.022
2	0.029 ± 0.001 $\leftarrow$ elbow ($= d_{\text{emb}}$)	0.109 ± 0.007
3	$(6 \pm 2) \times 10^{-4}$	$(4 \pm 3) \times 10^{-4}$ $\leftarrow$ elbow ($= d_{\text{emb}}$)
4	$(5 \pm 1) \times 10^{-4}$	$(1.0 \pm 0.4) \times 10^{-4}$

Step 3 (VAE：AU 検証)：表 5 のとおり， m を d_{emb} より大きく設定しても，VAE ($\beta = 4$) の AU は Swiss Roll で $\text{AU}_{\text{sat}} = 2 = d_{\text{true}}$ ，Torus で $\text{AU}_{\text{sat}} = 3 = d_{\text{emb}}$ に全シードで飽和した（標準偏差 0.0）．一方，vanilla AE の潜在座標使用数は m に張り付く（自動遮断なし）——命題 2 の含意 (i) (iii) と整合し，「VAE は大きめの m を自動修復し，AU がその結果を報告する」というプロトコルの中核機構が ground truth 上で確認された．

表 5: Synthetic manifolds (Exp-Syn-AU): active units of the VAE ($\beta = 4$) vs. the coordinate usage of the vanilla AE (mean $\pm$ std, 3 seeds). “AU” for the AE is a pseudo-AU defined by the encoding variance threshold (auxiliary observation).

	m	Vanilla AE	VAE ($\beta = 4$)
Swiss Roll	2	2	2.0 ± 0.0 (saturation = d_{true})
$(d_{\text{true}} = d_{\text{emb}} = 2)$	4	4	2.0 ± 0.0
	8	8	2.0 ± 0.0
	16	16	2.0 ± 0.0
Torus	4	4	2.0 ± 0.0
$(d_{\text{true}} = 2, d_{\text{emb}} = 3)$	6	6	3.0 ± 0.0 (saturation = d_{emb})
	8	8	3.0 ± 0.0
	16	16	3.0 ± 0.0

Torus $\cdot$ Möbius Band での $\text{AU}_{\text{sat}} = d_{\text{emb}}$ の対応は前処理（標準化）と十分な収束に依存する条件付きの経験的観測であり，理論的必然性は主張しない（単一シードの位相多様体実験は付録付録 C）。

5.3 実データ検証：MNIST

5.3.1 Step 1: $\hat{d}_{\text{ID}}$ の推定

参照 AE（300 エポック）の潜在表現で TwoNN/MLE を計算した（表 6）。 $m_{\text{ref}} \geq 64$ で TwoNN は 10.0 前後に収束し（3 シードで 10.03 ± 0.12 ; $m_{\text{ref}} = 64$ ），MLE（11.3–11.9）も同一オーダーを与える。複数 m_{ref} での収束と 2 推定量の一致という Step 1 の要件を満たし，**MNIST の参照値 $\hat{d}_{\text{ID}} \approx 10$ –12** を得る。対照として線形 PCA は累積寄与率 80% に 43 次元，90% に 86 次元を要し，非線形多様体構造を線形法が大幅に過大評価することがわかる（図 2 左）。

表 6: MNIST Step 1: TwoNN/MLE estimates through reference AEs of increasing m_{ref} (300 epochs, single seed 42 for the sweep; the 3-seed value at $m_{\text{ref}} = 64$ is 10.03 ± 0.12).

m_{ref}	MSE	TwoNN ID	MLE ID	CKA
8	0.0191	6.08	6.70	0.725
16	0.0121	7.96	8.61	0.812
32	0.0087	8.84	9.89	0.875
64	0.0062	9.54	11.26	0.908
128	0.0061	9.84	11.45	0.921
256	0.0057	10.02	11.85	0.953

5.3.2 Step 2: 候補範囲の設定

$\hat{d}_{\text{ID}} \approx 10$ –12 より，AE の候補範囲は $m \in [10, 24]$ ，VAE は $m \gtrsim 20$ の大きめ設定となる。

5.3.3 Step 3: AU $\cdot$ MSE による検証（3 シード）

VAE ($\beta = 4$, 300 エポック, 3 シード) の $\text{AU}(m)$ を表 7 に示す。AU はシード間で高度に再現し ($\sigma \leq 0.5$)， $m \leq 12$ ではほぼ全次元が活性（AU $\approx m$ ）である一方， $m > 12$ で増加が明確に鈍化し， $m = 64$ でも AU = 22.3 にとどまる——**KL 遮断が $\hat{d}_{\text{ID}} \approx 10$ –12 の近傍から効き始める**という，Step 3 が期待する検証信号が得られた。AE 側でも MSE の急改善は $m \approx 16$ –20 で鈍化し（表 6），候補範囲 $[10, 24]$ と整合する。

表 7: MNIST Step 3 (Exp-Mnist-Multi-300): AU and TwoNN ID of the VAE ($\beta = 4$, 300 epochs, mean $\pm$ std over 3 seeds). The AU growth slows beyond $m \approx \hat{d}_{\text{ID}}$, and the latent TwoNN converges to $\hat{d}_{\text{ID}} \approx 10$.

m	AU (mean $\pm$ std)	TwoNN ID (mean $\pm$ std)	Note
4	4.0 ± 0.0	3.98 ± 0.14	all dims active
8	8.0 ± 0.0	6.67 ± 0.15	
12	10.0 ± 0.0	7.41 ± 0.06	slowdown begins near $\hat{d}_{\text{ID}}$
16	11.7 ± 0.5	7.95 ± 0.21	
20	13.3 ± 0.5	8.37 ± 0.14	
32	15.7 ± 0.5	9.07 ± 0.10	
64	22.3 ± 0.5	10.03 ± 0.12	




图 2: MNIST: m -dependence of the indicators (300 epochs). **Left (AE)**: MSE (log scale, left axis) and TwoNN ID (right axis); vertical dotted lines mark the PCA 80/90/95% dimensions (43/86/152), far above the nonlinear estimate $\hat{d}_{\text{ID}} \approx 10$. **Right (VAE, $\beta = 4$)**: MSE, AU, and TwoNN ID; the AU growth slows beyond $m \approx \hat{d}_{\text{ID}}$.




图 3: MNIST: multi-seed reproducibility of the AU verification signal (3 seeds, 300 epochs). Left: per-seed $\text{AU}(m)$; right: mean $\pm$ std band. AU values are highly reproducible ($\sigma \leq 0.5$).

5.3.4 鈍化域の細密観察と変化点検出の注意

鈍化の開始位置をより細かく見るため、 $\hat{d}_{\text{ID}}$ 近傍を 1 刻みにした密グリッド ($m = 8\text{--}16$ を 1 刻み, 以降 $m \in \{18, 20, 24, 28, 32, 40, 48, 64\}$; 計 17 点, 300 エポック, 3 シード) で AU 曲線を観察した. $\text{AU}(m)$ は $m = 8\text{--}10$ でほぼ対角 ($\text{AU} = m$) に乗り, $m \geq 11$ で対角から離れ始める——一階差分比率に基づく変化点検出 (閾値 $\tau_{\text{knee}} = 0.25$; 付録付録 B) をこの密グリッドに適用すると変化点は 10.3 ± 0.9 (シード別 11, 9, 11) となり, $\hat{d}_{\text{ID}} \approx 10$ と整合する.

ただし, この整合には 2 つの重要な限定がある. 第一に, 密グリッド領域は Step 1 の TwoNN 推定値の近傍に置いたものであり, この結果は **TwoNN 由来の探索窓に条件付けられた局所的な曲線要約**であって独立な相互検証ではない. 第二に, 同じ検出器を疎グリッド $\{4, 8, 12, 16, 20, 32, 64\}$ に適用すると変化点は 43 ± 15 と大きく変動する——**変化点の自動検出はグリッド設計に強く依存し, プロトコルの名前付き出力として運用すべきでない**. このため本プロトコルの Step 3 は「AU 鈍化域が $\hat{d}_{\text{ID}}$ と同一オーダーにあるか」という頑健な読み取り (AU 値そのものの多シード比較) を主とし, 変化点検出はグリッド設計の補助にとどめる (詳細な感度分析は付録付録 B).

5.3.5 Fashion-MNIST

Fashion-MNIST では Exp-Real-Geom (§ 5.4; 3 シード, 300 エポック) により $\hat{d}_{\text{ID}} \approx 9$ (TwoNN, $m_{\text{ref}} = 5\hat{d}_{\text{ID}}\text{--}10\hat{d}_{\text{ID}}$ で $9.9\text{--}10.1$ に収束) を得た. VAE の AU 検証を含むフルプロトコルの多シード適用は, 単一シードの予備観察 (付録付録 C) で MNIST と同傾向を確認したが, 多シード再現は今後の課題である.

5.4 Step 1 の妥当性条件：何が内在次元推定を安定にするか

Step 1 は参照 AE の潜在表現を経由するため, 「参照表現の幾何的歪みが推定を壊さないか」が焦点となる. 実験 Exp-Real-Geom では, 等長性の異なる 4 モデル (通常 AE / IsometricAE[15] / CAE[14] / DAE[13]) を MNIST・Fashion-MNIST 上で $m_{\text{ref}} \in \{d, 2d, 3d, 5d, 10d\}$ ($d = \hat{d}_{\text{ID}}$; MNIST は 10, Fashion-MNIST は 9) でスweepし, TwoNN・MLE・ κ ・Trustworthiness・kNN overlap を比較した (3 シード, 300 エポック).

表 8: Exp-Real-Geom (MNIST, mean $\pm$ std, 3 seeds): TwoNN through four reference models. Convergence is driven by the bottleneck margin $m_{\text{ref}}/\hat{d}_{\text{ID}}$, largely independently of the isometry (condition number κ).

Model	TwoNN ($m_{\text{ref}} = d$)	TwoNN ($m_{\text{ref}} = 5d$)	TwoNN ($m_{\text{ref}} = 10d$)	κ ($m_{\text{ref}} = 10d$)
AE	7.3 ± 0.4	10.0 ± 0.1	10.0 ± 0.1	4.1×10^7
IsometricAE	7.5 ± 0.4	10.1 ± 0.1	10.1 ± 0.1	7.8
CAE	7.2 ± 0.5	9.9 ± 0.1	10.0 ± 0.1	3.2×10^3
DAE	7.6 ± 0.4	10.0 ± 0.1	10.0 ± 0.1	6.3×10^3

結果 (表 8) は明確である: (1) 4 モデルすべてで TwoNN は $m_{\text{ref}} = d$ の過小推定 ($\approx 7.3\text{--}7.6$) から $m_{\text{ref}} \geq 5d$ で ≈ 10 へ収束し, モデル間差 (± 0.3 以内) は m_{ref} 増大の効果 (約 2.5 ポイント) より 1 桁小さい; (2) IsometricAE は κ を 10^7 から 8 前後まで改善するが, TwoNN への効果は ± 0.2 以内にとどまる. Fashion-MNIST でも同一のパターンを得た. すなわち「**等長性の改善**」ではなく「**ボトルネック余裕 $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ が Step 1 の安定性の支配的条件**であり (命題 3 の δ_T 支配の含意と整合), Step 1 で $m_{\text{ref}} = 256 \gg \hat{d}_{\text{ID}}$ の通常 AE を使う設計が正当化される.




図 4: Step-1 stability: (left) on Swiss Roll, TwoNN recovers once $m_{\text{ref}} > d_{\text{true}}$ regardless of isometry; (right) on MNIST, TwoNN stabilizes for $m_{\text{ref}} \geq 48 \approx 5\hat{d}_{\text{ID}}$ even where the condition number κ grows sharply.

5.5 適用境界：Conv-VAE と自然画像

本節はプロトコルの「失敗の報告」ではなく、表 2 の失敗モードが実際にどの条件で発生するかの定量化である。

5.5.1 Conv-VAE： β 不足による遮断の不発（3 シード）

MNIST Conv-VAE (2 層 Conv + 2 層 ConvTranspose, KL サイクリックアニーリング $\beta_{\text{max}} = 4$ [19], 150 エポック, 3 シード) を $m \in \{4, 8, 16, 32, 64, 96, 128, 192, 256\}$ でスweepした (Exp-Conv-M256). $m \leq 64$ では $\text{AU} = m$ (遮断なし) が全シードで継続し, $m = 96$ で初めて $\text{AU} = 90.7 \pm 1.2 < m$ となるが, $m = 256$ でも活性率 94% と高い. $m \in \{384, 512\}$ への拡張 (Exp-Conv-M512) でも $\text{AU} \approx m$ が維持された——すなわち $\beta_{\text{max}} = 4$ では遮断閾値 $d^*(\beta) > 512$ であり, **AU 検証は「 β がデコーダ容量に対して小さすぎる」状態を $\text{AU} = m$ という明確な信号で検出する** (表 2 第 1 行).

サロゲート条件 (命題 2) の観点では, 強力な Conv デコーダは実効ノイズ分散 τ_{eff}^2 を小さくし (FC-VAE の逆算校正值 ≈ 0.30 に対し Conv-VAE では $\ll 0.30$; ヒューリスティックな外挿), 閾値 $\beta\tau_{\text{eff}}^2$ を下げて $d^*(\beta)$ を膨張させる. この解釈は β 増強実験と整合する: $\beta_{\text{max}} = 10$ では $m = 256$ で $\text{AU} = 93$ (36%), $\beta_{\text{max}} = 20$ では $\text{AU} = 66$ (26%) と明確な飽和傾向が誘発された (Exp-ConvV-HiBeta; **単一シードの探索的観察**, 詳細は付録付録 C). β の増大で遮断が低次元側へ移動するという定性的予測が的中しており, Conv-VAE でのプロトコル適用には「データ・アーキテクチャに応じた β の増強」が必要条件であることが特定された.




図 5: Boundary condition (Exp-Conv-M256): MNIST Conv-VAE with $\beta_{\max} = 4$ keeps $AU = m$ (no truncation) up to $m = 64$ and stays at 94% activation even at $m = 256$ — the failure mode “ β too small relative to decoder power” detected by the AU signal.

5.5.2 自然画像：Step 1 の有界な信頼域と Step 3 の未達（3 シード）

CIFAR-10・SVHN の Conv-VAE (3 層 Conv, $\beta_{\max} = 4$, 150 エポック, 3 シード, $m \in \{16, 32, 64, 128, 256\}$) では次の 2 点が観測された (表 9)。第一に, **Step 1 は条件付きで機能する**: CIFAR-10 の潜在 TwoNN は $m = 64 \approx 2\hat{d}_{\text{ID}}$ で 25.21 ± 0.41 となり, 生データ推定 (25.20) および Pope ら [7] の報告値 (≈ 26) と整合する。しかし $m \geq 128$ では $28.8\text{--}30.9$ へ単調に膨張する——**自然画像では $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$ 付近でのみ推定が信頼でき, 「大きいほど良い」は成り立たない** (表 2 第 3 行の失敗モード)。MNIST ($m_{\text{ref}} = 25\hat{d}_{\text{ID}}$ でも安定) との違いは, $AU = m$ のまま全次元が使用され続ける (遮断が効かない) ことによる潜在幾何の歪みに起因すると解釈される。SVHN では乖離がさらに大きい ($m = 256$ で潜在 27.1 vs. 生データ 10.1)。第二に, **Step 3 は未達である**: AU 飽和は $m \leq 256$ では現れず (SVHN で $m \geq 128$ から $AU < m$ となるのみ), AU 検証には β 増強・デコーダ容量制限・より大きな m 域の探索が必要である ($\beta_{\max} = 80$ ・薄型デコーダでの plateau-like behavior の予備観察は付録付録 C)。

表 9: Natural images (Exp-Nat-Cifar / Exp-Nat-SVHN): Conv-VAE with KL cyclic annealing ($\beta_{\max} = 4$, 150 epochs, mean $\pm$ std, 3 seeds). Step 1 agrees with Pope et al. [7] only near $m \approx 2\hat{d}_{\text{ID}}$; Step 3 (AU saturation) is not reached in the tested range.

m	CIFAR-10		SVHN	
	AU	TwoNN ID	AU	TwoNN ID
16	16.0 ± 0.0	13.12 ± 0.12	16.0 ± 0.0	11.30 ± 0.12
32	32.0 ± 0.0	19.26 ± 0.23	32.0 ± 0.0	15.08 ± 0.08
64	64.0 ± 0.0	25.21 ± 0.41	64.0 ± 0.0	19.97 ± 0.12
128	128.0 ± 0.0	28.83 ± 0.41	125.3 ± 0.5	24.60 ± 0.36
256	256.0 ± 0.0	30.91 ± 0.64	206.7 ± 1.2	27.08 ± 0.34
Raw-input TwoNN = 25.20, MLE = 26.56			Raw-input TwoNN = 10.09, MLE = 18.85	

6 考察

6.1 従来のモデル選択基準と何が違うか

実務で m を選ぶ従来手段は、検証再構成誤差・ELBO の m スイープや下流タスク性能である。これらは「性能が頭打ちになる m 」を教えるが、(i) グリッド全域のスイープを要し、(ii) 頭打ちの原因（データの多様体次元か、モデル容量か、最適化か）を区別しない。本プロトコルはこれらを置き換えるのではなく**補完**する：Step 1 がスイープに先立って候補範囲を $\hat{d}_{\text{ID}}$ 近傍に絞り込み（探索コストの削減）、Step 3 の AU が「性能とは独立に、何次元が実際に使われているか」を報告することで冗長次元の有無を直接可視化する。実際、MNIST では MSE 検証・AU 検証・ $\hat{d}_{\text{ID}}$ の 3 者が同一の候補範囲 $[10, 24]$ を支持した。一方、本論文は下流タスク精度や disentanglement 指標との系統比較は行っておらず、「ID 誘導型の選定が下流性能の観点でも最適か」の検証は今後の課題である。

6.2 安定性と妥当性： $\hat{d}_{\text{ID}}$ は何を推定しているか

本論文が一貫して維持する区別は、「TwoNN/MLE が**数値的に安定**（シード・ m_{ref} に対して低分散）」であることと「**真の内在次元に対して不偏**」であることは別だ、という点である。参照 AE の潜在空間は等長でなく（ κ は 10^7 に達する；表 8）、TwoNN が推定するのは厳密には「参照表現の局所自由度」である。MNIST の $\hat{d}_{\text{ID}} \approx 10\text{--}12$ は、(i) 複数 m_{ref} での収束、(ii) TwoNN と MLE の一致、(iii) モデル 4 種での一致（表 8）、(iv) CIFAR-10 での既報値との整合、という複数の間接証拠に支えられているが、不偏性の直接証明ではない。このため本プロトコルは $\hat{d}_{\text{ID}}$ を「候補範囲の中心を与える参照値」として運用し、Step 3 の検証で閉ループを構成する。残された課題として、原理の異なる推定量（DANCo[17]・ESS）との系統比較とブートストラップ信頼区間の報告を挙げる。

6.3 AU 検証の限界：変化点検出を名前付き出力にしない理由

先行版の枠組み（本研究の前身）では AU 鈍化点 m^{knee} を診断指標の一つとしていたが、本論文はこれを名前付き出力から外した。理由は § 5.3.4 で示したとおり、(i) 疎グリッドでの検出値 (43 ± 15) はグリッド間隔に支配され、(ii) 安定化には TwoNN 由来の探索窓が必要で独立検証にならず、(iii) 検出器（閾値法・二階差分法）の選択にも感度を持つ（付録付録 B）からである。AU 検証の頑健な部分は「AU 値そのもの（多シードで $\sigma \leq 0.5$ ）が $\hat{d}_{\text{ID}}$ と同一オーダーで鈍化・飽和するか」という読み取りであり、プロトコルはこの頑健な部分のみに依存するよう設計した。探索窓の推定と変化点評価を別シード・別データ部分集合で行う nested validation は今後の課題である。

6.4 限界と今後の課題

- **検証範囲**：フルプロトコルの多シード検証は合成多様体と MNIST に限られる（Fashion-MNIST は Step 1 のみ多シード）。Conv-VAE の β 増強による回復（Exp-ConvV-HiBeta）は単一シードの探索的観察であり、多シード再現が必要である。
- **自然画像での Step 3**：AU 飽和の安定同定は未達であり、 $\beta_{\text{max}} \in [40, 120]$ の密スイープ・デコーダ容量制御・シード安定性の改善が今後の課題である（付録付録 C）。
- **β 依存性**：AU 検証の読み取りは β に依存する（ $\beta \in [2, 8]$ で AU パターンの安定性を確認済み；付録付録 D）。 $d^*(\beta)$ の β 依存性を積極的に利用した「 β スイープによるスペクトル読み取り」は興味深い拡張である。
- **理論の射程**：命題 2 は線形ガウス近似であり、非線形への外挿は τ_{eff}^2 による事後的な整合確認にとどま

る。非線形設定での活性化条件の導出は未解決である。

- **計算コスト** : Step 3 の多シード m スイープは GPU 時間で数時間～1 日規模を要する。Step 1 による候補絞り込みでスイープ域は縮小するが、さらなる軽量化（早期エポックでの AU 予測等）は今後の課題である。

7 むすび

本論文は、「AE/VAE のボトルネック次元 m は入力データの多様体次元から決められるか」という問いに対し、**ID 誘導型選定プロトコル**—— (S1) $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ の参照表現による内在次元推定, (S2) $\hat{d}_{\text{ID}}$ に位相的余裕を加えた m の設定 (VAE は大きめ + KL 自動遮断), (S3) AU・MSE による学習後検証——として肯定的かつ運用可能な回答を与えた。理論面では位相的下界と水充填型サロゲート活性化条件 $\lambda_j > \beta\tau^2$ がプロトコルの各ステップを根拠づけ、実験面では真の次元既知の合成多様体 ($\text{AU}_{\text{sat}} = d_{\text{true}}$ または d_{emb} ; 3 シード, $\sigma = 0$) と MNIST ($\hat{d}_{\text{ID}} = 10.03 \pm 0.12$ と AU 鈍化域の整合; 3 シード) で機能を確認した。同時に、適用境界を定量化した: 内在次元推定はボトルネック余裕 $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ でのみ安定であり (等長性改善は副次的; 4 モデル比較), 自然画像では $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$ を超えると膨張する; Conv-VAE では β 不足が $\text{AU} = m$ という信号として検出され, β 増強で遮断が回復する。今後の主要課題は、自然画像での AU 検証の安定同定、変化点検出の nested validation, および原理の異なる ID 推定量による Step 1 の相互検証である。

参考文献

- [1] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2014.
- [2] Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 35, no. 8, pp. 1798–1828, 2013.
- [3] J. Lucas, G. Tucker, R. B. Grosse, and M. Norouzi, “Don’t blame the ELBO! A linear VAE perspective on posterior collapse,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [4] C. Fefferman, S. Mitter, and H. Narayanan, “Testing the manifold hypothesis,” *J. Amer. Math. Soc.*, vol. 29, no. 4, pp. 983–1049, 2016.
- [5] E. Facco, M. d’Errico, A. Rodriguez, and A. Laio, “Estimating the intrinsic dimension of datasets by a minimal neighborhood information,” *Sci. Rep.*, vol. 7, 12140, 2017.
- [6] E. Levina and P. J. Bickel, “Maximum likelihood estimation of intrinsic dimension,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 17, 2005.
- [7] P. Pope, C. Zhu, A. Abdelkader, M. Golub, and T. Goldstein, “The intrinsic dimension of images and its impact on learning,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2021.
- [8] A. Ansuini, A. Laio, J. H. Macke, and D. Zoccolan, “Intrinsic dimension of data representations in deep neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [9] L. Valeriani, D. Doimo, F. Cuturello, A. Laio, A. Ansuini, and A. Cazzaniga, “The geometry of hidden representations of large transformer models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.
- [10] T. Birdal, A. Lou, L. J. Guibas, and U. Simsekli, “Intrinsic dimension, persistent homology and generalization in neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.

- [11] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2017.
- [12] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *J. Roy. Statist. Soc. Ser. B*, vol. 61, no. 3, pp. 611–622, 1999.
- [13] G. Alain and Y. Bengio, “What regularized auto-encoders learn from the data-generating distribution,” *J. Mach. Learn. Res.*, vol. 15, pp. 3743–3773, 2014.
- [14] S. Rifai, P. Vincent, X. Muller, X. Glorot, and Y. Bengio, “Contractive auto-encoders: Explicit invariance during feature extraction,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2011.
- [15] K. Kato, J. Zhou, T. Sasaki, and A. Nakagawa, “Rate-distortion optimization guided autoencoder for isometric embedding in Euclidean latent space,” in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR vol. 119, 2020.
- [16] P. Nazari, S. Damrich, and F. A. Hamprecht, “Geometric autoencoders—what you see is what you decode,” in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR vol. 202, 2023.
- [17] C. Ceruti, S. Bassis, A. Rozza, G. Lombardi, E. Casiraghi, and P. Campadelli, “DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration,” *Pattern Recognit.*, vol. 47, no. 8, pp. 2569–2581, 2014.
- [18] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR vol. 97, pp. 3519–3529, 2019.
- [19] H. Fu, C. Tan, B. Peng, Z. Zhao, T. Yan, C. Chang, and L. Zhao, “Cyclical annealing schedule: A simple approach to mitigating KL vanishing,” in *Proc. NAACL-HLT*, pp. 240–250, 2019.
- [20] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ: Wiley-Interscience, 2006.
- [21] A. Hatcher, *Algebraic Topology*. Cambridge, UK: Cambridge University Press, 2002.
- [22] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Technical Report, University of Toronto, 2009.
- [23] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, “Reading digits in natural images with unsupervised feature learning,” in *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- [24] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [25] H. Xiao, K. Rasul, and R. Vollgraf, “Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms,” *arXiv preprint arXiv:1708.07747*, 2017.

付録 A 証明と導出

A.1 命題 2 (サロゲート活性化条件) の導出スケッチ

線形エンコーダ $f(x) = W_e x$, 線形デコーダ $g(z) = W_d z$, 事前分布 $p(z) = \mathcal{N}(0, I_m)$, 尤度 $p(x|z) = \mathcal{N}(W_d z, \tau^2 I_N)$ の β -VAE を考える. 入力を PCA 基底に取り, 共分散を $\Sigma = \text{diag}(\lambda_1, \dots, \lambda_N)$ ($\lambda_1 \geq \lambda_2 \geq \dots$) とすると, 線形ガウスモデルでは β -ELBO が固有方向ごとに分離する. 第 j 方向に割り当てるレート (KL 寄与) を $R_j \geq 0$, そのときの歪み低減を $D_j(R_j)$ とすると, ガウス rate-distortion 関数より

$D_j(R_j) = \lambda_j e^{-2R_j}$ (nats) であり, β -ELBO の該当項は

$$\mathcal{L}_j(R_j) = -\frac{1}{2\tau^2} \lambda_j e^{-2R_j} - \beta R_j + \text{const.} \quad (3)$$

R_j についての最適化は凹計画であり, KKT 条件 $\partial \mathcal{L}_j / \partial R_j = 0$ から $R_j^* = \max(0, \frac{1}{2} \log(\lambda_j / \beta \tau^2))$ を得る. $R_j^* > 0 \iff \lambda_j > \beta \tau^2$ が活性化条件 (式 (2)) である. これは Shannon の水充填定理 [20] の「水面」を $\beta \tau^2$ とした形に一致し, $\beta = 1$ では PPCA [12] の既知の結果に帰着する. m 本の座標が使えるとき, 最適解は上位 $\min(m, d^*(\beta))$ 方向を活性化するので主張 (2) (3) が従う.

近似の内容: この導出は, VAE の期待 KL 項 $\mathbb{E}_x[\text{KL}(q_\phi(z|x) \| p(z))]$ を相互情報量 $I(x; z)$ (レート) で置き換えている. 両者の差は aggregated posterior $q_\phi(z)$ と事前分布 $p(z)$ の不一致 $\text{KL}(q_\phi(z) \| p(z)) \geq 0$ であり, この項を無視できる範囲でのみ本命題は成立する. また学習された非線形 VAE の勾配ダイナミクスは扱っておらず, 本命題の非線形設定への含意はあくまで定性的である.

A.2 命題 3 (TwoNN 条件付き安定性) の証明スケッチ

bi-Lipschitz 条件より各距離の変化率は $(1 \mp \varepsilon)^2$ の範囲に収まる. TwoNN 統計量 r_2/r_1 は距離の比であるため一様スケーリングはキャンセルされ, 非等長成分 ($\varepsilon \neq 0$) のみが比を歪める. Trustworthiness $\geq 1 - \delta_T$ は 2 近傍の順位保存を高確率で保証し, 順位逆転による r_2/r_1 の大変動を確率的に抑える. 両条件下で r_2/r_1 の経験分布の変化 (EMD) は連続関数 $C(\varepsilon, \delta_T)$ で上界され, TwoNN 推定値のずれもこれに支配される ($\varepsilon = \delta_T = 0$ で $C = 0$). 有限サンプル・有限次元での近似であり, 厳密な定数は設定に依存する.

A.3 その他の解釈的命題

ブルバック計量と局所等長性: デコーダ g が局所等長であるための必要十分条件は $G(z) = J_g(z)^\top J_g(z) = I_m$ である. 条件数 $\kappa = \sigma_{\max}(J_g) / \sigma_{\min}(J_g)$ は異方性の指標であり, $\kappa = 1$ は等方性のみを意味し等長性までは保証しない. 本論文の κ は歪みの補助指標として用いる.

デコーダヤコビアンの実効階数: 十分な容量の AE が多様体 $\mathcal{M}$ を正確に再構成するとき, $J_g(z)$ の有意特異値数は $\min(m, d_{\text{emb}})$ に一致する (有限容量・最適化誤差は無視した理想化).

付録 B AU 変化点検出の探索的解析

本付録は, AU 曲線上の変化点 (knee) m^{knee} の自動検出を名前付きプロトコル出力としない判断 (§ 6.3) の根拠となる感度データをまとめる.

B.1 定義

グリッド $\mathcal{M} = \{m_1 < \dots < m_K\}$ 上の AU 増加率を $s(m_i) = [\text{AU}(m_i) - \text{AU}(m_{i-1})] / (m_i - m_{i-1})$, 正規化増加率を $\rho(m_i) = s(m_i) / \max_j s(m_j)$ とし,

$$m^{\text{knee}} = \min\{m_i \in \mathcal{M} : \rho(m_i) < \tau_{\text{knee}}\}, \quad \tau_{\text{knee}} = 0.25 \quad (4)$$

と定義する (一階差分比率法). 代替として $\text{AU}(m)$ の離散二階差分の絶対値最大点を取る二階差分法 (d2 法) がある.

B.2 グリッド感度

理想化された単調飽和モデル (AU が $d^*(\beta)$ で段差的に飽和し, ノイズなし) では $|m^{\text{knee}}(\mathcal{M}) - d^*(\beta)| \leq \max_i (m_{i+1} - m_i)$ が成り立つ (検出誤差はグリッド最大間隔で上界される). 実際の MNIST FC-VAE ($\beta = 4$,

300 エポック, 3 シード) では経験的 AU 曲線の確率的揺らぎによりこの上界を超える変動が生じる (表 10).

表 10: Grid sensitivity of the change-point detector on MNIST FC-VAE ($\tau_{\text{knee}} = 0.25$, 3 seeds). The sparse-grid value is dominated by the grid interval; the dense grid is placed around the TwoNN estimate and is therefore a TwoNN-conditioned curve summary, not independent validation.

Condition	Max. interval	seed 42	seed 123	seed 777	Mean $\pm$ std
Sparse grid, 150 ep	32	64	32	64	53 $\pm$ 15
Sparse grid, 300 ep	32	64	32	32	43 $\pm$ 15
Dense grid, 300 ep	16 (step 1 in 8–16)	11	9	11	10.3 $\pm$ 0.9

エポック延長 (150 $\rightarrow$ 300) はほとんど効かず, 主因は収束不足ではなくグリッド設計とシードである. また, 単一シード・別グリッドの予備観察では $m^{\text{knee}} = 12$ も観測されており (Exp-Mnist-Base), グリッド・初期化への依存が明確である.

B.3 検出法・閾値の感度

密グリッドデータに対する τ 法と d2 法の比較を表 11 に示す. d2 法は遷移域の AU 揺らぎ (8 $\rightarrow$ 10 $\rightarrow$ 9 $\rightarrow$ 11 $\rightarrow$ 10 $\rightarrow$ 11 $\rightarrow$ 13 等) に敏感で, シード 123 で $m^{\text{knee}} = 28$ と大きく外れた. $\tau_{\text{knee}} = 0.25$ は本研究の作業的既定値であり, Fashion-MNIST では τ の境界感度 (τ 前後で検出値が変わる) が確認されている—— τ_{knee} に一般的な意味は主張しない.

表 11: Detector sensitivity on the dense grid (300 ep, 3 seeds).

Method	seed 42	seed 123	seed 777	Mean $\pm$ std
τ -method ($\tau = 0.25$)	11	9	11	10.3 $\pm$ 0.9
Second difference (d2)	15	28	12	18.3 $\pm$ 6.8
Reference: $\hat{d}_{\text{ID}} \approx 10$ (TwoNN, 3-seed mean)				

B.4 結論

変化点検出はグリッド・シード・検出器・閾値のすべてに感度を持ち, 安定化には TwoNN 由来の探索窓という循環的条件が必要である. したがって本プロトコルでは, 変化点はグリッド設計の補助 ($\hat{d}_{\text{ID}}$ 近傍を密にサンプリングする位置の目安) にとどめ, 検証の判定は AU 値そのものの多シード比較で行う. 探索窓推定と変化点評価を分離した nested validation は今後の課題である.

付録 C 単一シード・探索の実験

本付録の実験はすべて**単一シード (42) の探索的観察**であり, 本文の主張の直接の根拠には用いていない.

C.1 Conv-VAE の高 β 誘発実験 (Exp-ConvV-HiBeta)

MNIST Conv-VAE (KL サイクリックアニーリング, 150 エポック, $m \in \{16, 32, 64, 96, 128, 192, 256\}$) で β_{max} を増強した結果を表 12 に示す. $\beta_{\text{max}} = 10$ で活性率が $m = 256$ において 36% まで低下し, 変化点検出 (τ 法) は ≈ 128 を返す; $\beta_{\text{max}} = 20$ ではさらに低次元側 (≈ 96) へ移動する. β 増大で遮断が低次元側へ移動するというサロゲート条件の定性的予測と整合する.

表 12: Exp-ConvV-HiBeta (single seed 42, exploratory): AU of the MNIST Conv-VAE under strengthened $\beta_{\max}$ (activation rate in parentheses).

m	$\beta_{\max} = 4$	$\beta_{\max} = 10$	$\beta_{\max} = 20$
32	32 (100%)	32 (100%)	27 (84%)
64	64 (100%)	54 (84%)	42 (66%)
128	114 (89%)	69 (54%)	53 (41%)
256	241 (94%)	93 (36%)	66 (26%)




図 6: Exp-ConvV-HiBeta (single seed, exploratory): increasing $\beta_{\max}$ shifts the AU truncation to lower dimensions, consistent with the surrogate activation condition.

C.2 自然画像での AU プラットー探索 (Exp-NatImg-Sweep)

CIFAR-10 Conv-VAE で $m \in [32, 1024]$, $\beta_{\max} \in \{10, 20, 40, 80\}$, デコーダ容量 (Standard/Deep/Thin) を組み合わせたスイープでは, $\beta_{\max} = 80$ ・薄型デコーダ条件で $m \in [512, 1024]$ にわたり $AU \approx 24$ 付近の plateau-like behavior が観測された (予備的証拠). 全条件で潜在 TwoNN は 24.7–25.4 と安定し, Pope ら [7] の報告値と整合した. シード安定性・グリッド安定性を含む安定同定は未達であり, 今後の課題である.

C.3 Fashion-MNIST の VAE 予備観察 (Exp-Fashion)

Fashion-MNIST VAE ($\beta = 4$, 100 エポック, 単一シード) では, AE 側で TwoNN が $m_{\text{ref}} \geq 32$ で ≈ 9.4 に収束し, AU 鈍化域が $\hat{d}_{\text{ID}} \approx 9$ –10 と同一オーダーで観測された (MNIST と同傾向). 多シード再現は今後の課題である (Step 1 の多シード値は Exp-Real-Geom ; § 5.4).

C.4 位相多様体での AU_{sat} 観察 (Exp-Syn-Top)

Torus・Möbius Band (いずれも $d_{\text{ID}} = 2$, $d_{\text{emb}} = 3$) で $AU_{\text{sat}} = 3 = d_{\text{emb}}$, Circle S^1 ($d_{\text{emb}} = 2$) で $AU_{\text{sat}} = 2$ ($m \geq 6$, 条件付き) が観測された. Swiss Roll の AU_{sat} は前処理に依存する (標準化で 2, 別条件で 3) ため, $AU_{\text{sat}} = d_{\text{emb}}$ 対応の主証拠は Torus・Möbius に限定される. 条件付きの付随的観察であり, 理論的必然性は主張しない.

付録 D 感度分析と実験一覧

AU 閾値 δ : $\delta \in [10^{-3}, 10^{-1}]$ の変動で AU 値はほぼ変化しない (MNIST FC-VAE, 300 エポック).

β 感度 : 予備実験 (50 エポック, $\beta \in \{1, 2, 4, 8\}$) では, $\beta = 1$ で $AU \approx m$ (正則化不足), $\beta = 8$ で過正則化の兆候が観測され, $\beta \in [2, 8]$ で AU パターンは安定であった. 本論文の既定値 $\beta = 4$ はこの安定域の中央である.

MLE の k 感度 : $k \in \{5, 10, 20\}$ で $MLE = 11.5\text{--}12.4$ (MNIST) と安定.

表 13: Experiment overview. All main-text results use 3 seeds (42, 123, 777); appendix experiments marked “single” use seed 42 only.

Experiment	Data / model	Epochs	Seeds	Section
Exp-Syn-1 / Exp-Syn-AU	Swiss Roll, Torus / AE, VAE	200–300	3	§ 5.2
Exp-Mnist-Base	MNIST / AE (m_{ref} sweep)	300	1 (sweep)	§ 5.3
Exp-Mnist-Multi-300	MNIST / FC-VAE	300	3	§ 5.3
Exp-Mnist-Dense-300	MNIST / FC-VAE (dense grid)	300	3	§ 5.3.4
Exp-Real-Geom	MNIST, F-MNIST / AE, IsoAE, CAE, DAE	300	3	§ 5.4
Exp-Conv-M256 / M512	MNIST / Conv-VAE	150	3	§ 5.5
Exp-Nat-Cifar / Exp-Nat-SVHN	CIFAR-10, SVHN / Conv-VAE	150	3	§ 5.5
Exp-ConvV-HiBeta	MNIST / Conv-VAE (β_{max} up)	150	single	App. 付録 C
Exp-NatImg-Sweep	CIFAR-10 / Conv-VAE	300	partial	App. 付録 C
Exp-Fashion	F-MNIST / AE, VAE	100	single	App. 付録 C
Exp-Syn-Top	Torus, Möbius, S^1 / VAE	300	single	App. 付録 C