

入力データの内在次元に基づく AE/VAE ボトルネック次元の 選定：

ID 誘導型プロトコルと Active-Unit 検証

(著者名)

(所属機関)

(メールアドレス)

概要

オートエンコーダ (AE) および変分オートエンコーダ (VAE) のボトルネック次元 m は最も基本的な設計パラメータでありながら、実務では試行錯誤や慣習により選ばれることが多い。本論文は、多様体仮説のもとで m の候補範囲を入力データの内在次元の推定値 $\hat{d}_{\text{ID}}$ から導き (AE: $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}]$, VAE: $m \geq 2\hat{d}_{\text{ID}}$)、学習後に VAE の Active Units (AU) で「余剰次元が実際に遮断されたか」を診断する、条件付き・診断型の ID 誘導プロトコル (推定→設定→検証の 3 ステップ) を提案する。根拠は、自己交差のない再構成に $m \geq d_{\text{emb}} \geq d_{\text{ID}}$ を要する位相的下界と、線形ガウスサロゲートの水充填型活性化条件 $\lambda_j > \beta\tau^2$ である。真の次元既知の合成多様体と MNIST の全結合 VAE (いずれも 3 シード以上) では、3 ステップが再現可能な合否判定規則のもとで機能し (Swiss Roll: $\text{AU}_{\text{sat}} = d_{\text{true}} = 2$; Torus: $\text{AU}_{\text{sat}} = d_{\text{emb}} = 3$, ただし境界域 $m \leq 4$ の過剰刈り込みは MSE 検証が検出; MNIST: $\hat{d}_{\text{ID}} = 10.03 \pm 0.12$ と AU 鈍化域が整合), ID 誘導の探索窓は、本論文の MNIST グリッド構成ではフルグリッド探索の学習ランを約 6~8 割削減しつつ、グリッド全域での最良の下流分類精度 (線形プローブ) を窓内で達成した。適用境界も定量化する: 内在次元推定は $m \gg \hat{d}_{\text{ID}}$ の参照表現でのみ安定で自然画像では $m \approx 2\hat{d}_{\text{ID}}$ を超えると膨張し、Conv-VAE では $\beta = 4$ で AU 遮断が働かない (β 増強で遮断は回復するが、単一シードの探索的観察にとどまる)。すなわち本プロトコルは m 選定の一般解ではなく、 $\hat{d}_{\text{ID}}$ が候補範囲を与え、適切な β とアーキテクチャのもとで AU が遮断の成否を診断する枠組みである。

1 まえがき

1.1 研究背景：ボトルネック次元をどう選ぶか

オートエンコーダ (Autoencoder; AE) および変分オートエンコーダ (Variational Autoencoder; VAE) [1] は、高次元データから低次元の潜在表現を学習する中核的な非教師あり学習モデルである [2]。その最も基本的な設計パラメータがボトルネック次元 m である: m が小さすぎると情報が欠落し、大きすぎると冗長な次元が生じ、VAE では posterior collapse[3] の解釈を複雑にする。にもかかわらず、 m の選定は実務では「32 や 64 などの切りのよい値」や試行錯誤に委ねられることが多く、データに根ざした選定原理は十分に確立されていない。

一方、多様体仮説 [4] によれば、自然データは高次元の入力空間 $\mathbb{R}^N$ 内の低次元多様体の近傍に集中しており、その局所的な自由度は内在次元 (intrinsic dimension) $d_{\text{ID}} \ll N$ で特徴づけられる。実際、自然画像の d_{ID} が画素数よりはるかに小さいことが TwoNN[5] 等の推定量で報告されている [7]。この見方に立てば、**ボトルネック次元 m の適切な大きさは、モデル側の慣習ではなく、入力データ側の量——多様体次元——によって決まるはず**である。本論文が取り組む問いは次のとおりである：

AE/VAE のボトルネック次元 m を、入力データの内在次元 (多様体次元) の推定値から原理的に選定できるか？そして、その選定が適切であったことを学習後に検証する手段はあるか？

1.2 中心アイデアと貢献

本論文の中心的主張は一文で述べられる：

ボトルネック次元 m の候補範囲は入力データの内在次元の推定値 $\hat{d}_{\text{ID}}$ から「AE： $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}]$ ，VAE： $m \geq 2\hat{d}_{\text{ID}}$ 」として導け，VAE の Active Units (AU) ——KL 正則化が実際に使用している座標数——が，適切な β とアーキテクチャのもとで，余剰次元が実際に遮断されたかを診断する学習後検証信号として機能する．

これは m 選定の一般解の主張ではなく，**条件付き・診断型のワークフロー**の提案である（適用条件は表 3）．その根拠は理論と実験の両面から与えられる．理論面では，(i) d 次元多様体を自己交差なく再構成するには $m \geq d_{\text{emb}} \geq d_{\text{ID}}$ が必要という位相的下界（命題 1）と，(ii) 線形ガウス設定の水充填解析から得られる活性化条件 $\lambda_j > \beta\tau^2$ （命題 2）である．後者は「 m を $\hat{d}_{\text{ID}}$ より大きめに設定しても，VAE の KL 正則化が余剰次元を遮断（posterior collapse）し，AU が実効的な使用次元数を報告する」ことを**線形ガウスサロゲートの範囲で予測する**——すなわち，AE では m の選定そのものが表現次元を決めるのに対し，VAE では「**大きめの $m + \text{AU}$ による診断**」という安全側の運用が期待できる（この期待が成立するか自体を Step 3 の判定規則で確認する）．

本論文の貢献は次の 3 点である：

1. **ID 誘導型ボトルネック次元選定プロトコル**（§ 3）：(S1) $\hat{d}_{\text{ID}}$ の推定（TwoNN/MLE；実データでは $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ の参照 AE 経由），(S2) m の設定（AE： $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}]$ + 位相的余裕；VAE： $m \geq 2\hat{d}_{\text{ID}}$ の大きめ設定），(S3) AU・再構成誤差による学習後検証，の 3 ステップからなる診断型ワークフローを，**再現可能な合否判定規則**（式 (2)–(3))・失敗モード・報告要件とともに与える．
2. **選定原理の理論的根拠**（§ 4）：位相的下界（命題 1）と，線形ガウス rate-distortion 近似におけるサロゲート活性化条件 $\lambda_j > \beta\tau^2$ （命題 2； τ^2 は等方ガウス観測ノイズ分散，KL 項と相互情報量の対応は aggregated-posterior 項を無視した近似である点を主張本体に明記）を整理し，「サロゲートモデルは m の過剰の遮断を予測するが，その遮断閾値は β に依存する」という運用上の含意を導く．
3. **多シード実証と適用境界の定量化**（§ 5）：フルプロトコルの多シード検証は，真の次元既知の合成多様体（十分な余裕のもとで $d_{\text{true}} \cdot d_{\text{emb}}$ を返し，Torus 境界域の過剰刈り込みは MSE 検証が検出する；3–5 シード）と MNIST の全結合 VAE（ $\hat{d}_{\text{ID}} \approx 10$ –12 と AU 鈍化域の整合；3 シード）で与える．Step 1 にはサブサンプリング信頼区間と原理の異なる推定量（DANCo・ESS）による相互検証を付す．また ID 誘導範囲が探索コストを削減しつつ下流分類精度を保持することを線形プローブで示す（§ 5.4）．さらに適用限界を定量化する：(a) $\hat{d}_{\text{ID}}$ 推定は $m \gg \hat{d}_{\text{ID}}$ の参照表現でのみ安定であり，等長性の改善は副次的である（4 モデル比較，MNIST・Fashion-MNIST，3 シード；命題 3）；(b) 自然画像では TwoNN 推定が $m \approx 2\hat{d}_{\text{ID}}$ までは既報値 [7] と整合するがそれ以上で膨張する；(c) Conv-VAE では $\beta = 4$ で遮断閾値 $d^*(\beta)$ が 512 を超え，AU 検証には β の増強が必要である．なお，Fashion-MNIST の Step 3・Conv-VAE の β 増強・自然画像の AU プラトーは単一シードの探索的観察であり（付録 C），自然画像での Step 3 は未解決である——貢献の範囲はこの限定を含めて主張する．

既存研究との違い：深層表現の内在次元を「測る」研究 [8, 7, 9] が学習済みネットワークの解析にとどまるのに対し，本研究は内在次元推定を**ボトルネック次元の設計**に用い，その設計の妥当性を AU で閉ループ検証する手順として定式化する．posterior collapse の線形解析 [3] が定性的議論にとどまるのに対し，本研究は閉形式閾値 $\lambda_j > \beta\tau^2$ として整理し（新規性は統合的整理にある；§ 4），選定プロトコルの根拠として運用する．

1.3 「多様体次元のようなもの」の2つの顔： d_{ID} と d_{emb}

本論文では「入力データの多様体次元」として2つの量を区別する：**局所的内在次元** d_{ID} （多様体の局所自由度；TwoNN/MLE の推定対象）と**位相的最小埋め込み次元** d_{emb} （自己交差なくユークリッド空間に埋め込むための最小次元）。Swiss Roll では $d_{\text{emb}} = d_{\text{ID}} = 2$ だが、Torus では $d_{\text{emb}} = 3 > d_{\text{ID}} = 2$ である。ボトルネックに必要なのは d_{emb} （命題 1）であり、 d_{ID} しか推定できない実データでは、この差（位相的障害）が「 $\hat{d}_{\text{ID}}$ より大きめに取る」余裕の一因となる（§ 3.2.2）。

1.4 本論文の限界（要約）

本論文の検証は、真の次元既知の合成多様体（ $d_{\text{true}} \leq 3$ ）、MNIST・Fashion-MNIST（全結合型 AE/VAE, 3 シード）、および適用境界の定量化としての Conv-VAE・自然画像（CIFAR-10・SVHN）に限られる。 $\hat{d}_{\text{ID}}$ （TwoNN/MLE）は「数値的に安定」であっても「真の内在次元に対して不偏」とは限らず（安定性と妥当性の区別；§ 6.2）、本論文は $\hat{d}_{\text{ID}}$ を選定の**参照値**として扱う（真値の推定を主張しない）。AU 曲線上の変化点（knee）の自動検出は、グリッド・シード依存性が強い本プロトコルの名前付き出力とはせず、探索的解析として付録 B に位置づける。大規模自然画像への完全適用は今後の課題である。

以降、§ 2 で関連研究、§ 3 でプロトコル、§ 4 で理論的根拠、§ 5 で実験、§ 6 で考察、§ 7 でむすびを述べる。証明・感度分析・探索的実験は付録にまとめる。

2 関連研究

表現学習とオートエンコーダ：Bengio ら [2] は、AE が多様体仮説 [4] に基づき高次元データの低次元構造を学習する枠組みを整理した。 β -VAE[11] は KL 正則化の重み β により表現の圧縮度を制御し、AU に直接影響する。DAE[15]・CAE[16] は正則化により多様体構造の学習を促す変種であり、本論文では内在次元推定の参照表現としての適性を比較する対象となる（§ 5.5）。

深層表現の内在次元解析：Pope ら [7] は自然画像の内在次元が画素次元よりはるかに低いことを示し（CIFAR-10： $d_{\text{ID}} \approx 26$ ）、Ansuini ら [8] は深層ネットワーク各層の ID 変化を定量化した。Valeriani ら [9] は大規模 Transformer の隠れ表現幾何を解析し、Birdal ら [10] は ID と汎化の関係を論じた。これらは学習済みモデルを「測る」研究であり、本研究は測定値を**ボトルネック次元の設計と検証**に用いる点で相補的である。ID 推定量としては TwoNN[5] と MLE[6] を採用する（DANCo[19] はより精密だが計算コストが高く、今後の課題とする）。

Active Units と posterior collapse：AU[11, 3] は事後平均の分散が閾値 δ を超える潜在次元数であり、KL 正則化が実際に使用している座標数を測る。Lucas ら [3] は線形 VAE で posterior collapse の機構を分析した。本研究は、この機構を「 m の過剰設定を遮断しうる安全装置」として選定プロトコルに組み込み（遮断が実際に起きたかは Step 3 で診断する）、その理論的根拠（rationale）として水充填型の活性化条件（命題 2；Tipping & Bishop[12] の PPCA は $\beta = 1$ の特殊ケース）を用いる。

潜在次元数の自動決定：線形・確率モデルの範囲では、ARD（automatic relevance determination）事前分布を用いた Bayesian PCA[13] が主成分数を、Indian Buffet Process 等の Bayesian ノンパラメトリック潜在変数モデル [14] が潜在特徴数を、それぞれ学習中に自動決定する。 β -VAE の KL 遮断はこれらと類似の「余剰次元の自動刈り込み」を非線形設定で行うが、刈り込み結果は β とアーキテクチャに依存する（§ 5.6）。本研究はモデル側の自動決定に頼らず、データ幾何側の $\hat{d}_{\text{ID}}$ から候補範囲を導き、刈り込み結果（AU）との突き合わせで検証する点でこれらと相補的である。

幾何的オートエンコーダ：Nazari ら [18]・Kato ら [17] は潜在空間の幾何（等長性）を保つ正則化を提案した。本研究では、等長性が ID 推定の安定性に与える影響を「ボトルネック余裕 $m/\hat{d}_{\text{ID}}$ 」と比較し、後者が支

配的であることを示す (§ 5.5).

3 ID 誘導型ボトルネック次元選定プロトコル

3.1 問題設定と主要記号

AE/VAE を入力次元 N , ボトルネック次元 m , エンコーダ $f: \mathbb{R}^N \rightarrow \mathbb{R}^m$, デコーダ $g: \mathbb{R}^m \rightarrow \mathbb{R}^N$ で定義する. VAE ではエンコーダが事後分布 $q_\phi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x))$ を出力し, KL 正則化 (強度 β) が情報ボトルネックとして作用する.

Active Units (AU) を

$$\text{AU}(m) = \sum_{k=1}^m \mathbf{1}[\text{Var}_x[\mu_k(x)] > \delta], \quad \delta = 10^{-2} \quad (1)$$

で定義する ($\mu_k(x)$ は事後平均の第 k 成分; 閾値 δ は Lucas ら [3] に準拠し, $\delta \in [10^{-3}, 10^{-1}]$ で AU 値がほぼ不変であることを確認済み; 付録 D). AU はテストデータ上で計算する (学習・テストの別は各実験節に明記する).

表 1: Main symbols. Each quantity is distinguished so that the protocol’s claims are stated without conflating targets and estimators.

Symbol	Meaning	Role in the protocol
m	Bottleneck dimension	Design parameter to be chosen
d_{ID}	Intrinsic dimension of the data manifold	Target quantity (unknown for real data)
d_{emb}	Topological minimum embedding dimension ($\geq d_{\text{ID}}$)	Lower bound for m (Prop. 1)
$\hat{d}_{\text{ID}}$	TwoNN/MLE estimate of d_{ID}	Reference value for Step 1 (may be biased)
$\text{AU}(m)$	Number of KL-active coordinates, Eq. (1)	Verification signal for Step 3
AU_{sat}	Saturated (plateau) AU value	Read-out of effective dimension (VAE)
$d^*(\beta)$	Water-filling threshold count (Prop. 2)	Idealized prediction of AU_{sat}
κ	Decoder Jacobian condition number	Isometry (distortion) indicator

ここで強調すべき区別が 2 つある. 第一に, $\hat{d}_{\text{ID}}$ は**参照値であって真値ではない**: TwoNN/MLE は数値的に安定 (低分散) であっても, 参照表現の幾何的歪みによる系統的バイアスを持ちうる (安定性と妥当性の区別; § 6.2). 第二に, AU は**内在次元の推定量ではない**: AU は「KL 正則化が使用を許した座標数」という観測量であり, $\beta \cdot \delta \cdot \text{アーキテクチャ}$ に依存する. プロトコルはこの 2 つの異なる量を突き合わせることで, 単一指標への過信を避ける設計になっている.

3.2 プロトコル本体




図 1: ID-guided protocol for choosing the bottleneck dimension m . The protocol closes the loop: the data-side estimate $\hat{d}_{\text{ID}}$ determines the design, and the model-side observable AU verifies the design after training.

3.2.1 Step 1: 内在次元の推定

合成データや低次元データでは、入力空間に TwoNN/MLE を直接適用すればよい。高次元の実データ（例：MNIST の $N = 784$ ）では距離集中により直接推定が不安定になるため、**大きめの参照 AE** ($m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ ；**本論文では $m_{\text{ref}} = 256$**) の**潜在表現を経由して**推定する。このとき次の 2 点を必須とする：(i) 複数の m_{ref} （例： $\{64, 128, 256\}$ ）で推定値の収束を確認する；(ii) 原理の異なる 2 推定量（TwoNN と MLE）を併記し、同一オーダーであることを確認する。 $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ という条件が推定の安定性の支配的条件であることは命題 3 と実験 (§ 5.5) で裏づける。逆に、 $m_{\text{ref}} \lesssim 3\hat{d}_{\text{ID}}$ では系統的な過小推定が生じ、自然画像では $m_{\text{ref}} \gg 2\hat{d}_{\text{ID}}$ で逆に膨張が生じる (§ 5.6) ——Step 1 の信頼域は m_{ref} に対して有界である点に注意する。

3.2.2 Step 2: ボトルネック次元の設定

AE の場合： $m < d_{\text{emb}}$ では原理的に自己交差なしの再構成が不可能であり（命題 1）、 m の過剰は冗長次元として残る（AE には自動遮断がない）。よって $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}]$ を**既定探索窓 (default search window)** とし、位相的障害 ($d_{\text{emb}} > d_{\text{ID}}$ ；Torus 型) の可能性を余裕として吸収する。用途が再構成精度重視なら窓の上側、圧縮重視なら下側を選ぶ。係数 2 は原理から導かれる値ではなく本論文の実験で機能した既定値であり、位相・ノイズ・クラス混在・再構成忠実度の要求によってはより大きな余裕が必要になりうる（Torus では窓の上端 $2\hat{d}_{\text{ID}} = 4$ で過剰刈り込みが生じ、必要次元の活性化は $m \geq 5$ で安定する；§ 5.2）——窓はあくまで探索の出発点であって上限の保証ではない。

VAE の場合：命題 2 はサロゲートモデルにおいて「 m が必要次元を超えても KL 正則化が余剰次元を遮断する」ことを予測するため、 $m \geq 2\hat{d}_{\text{ID}}$ と**大きめに設定するのが安全側の運用**である（遮断が実際に起きたか

は Step 3 の V1 で確認する). ただし遮断閾値は β に依存する ($d^*(\beta) = |\{j : \lambda_j > \beta\tau^2\}|$): β が小さすぎると遮断が機能せず $AU = m$ のまま張り付く (Step 3 で検出可能).

3.2.3 Step 3 : 学習後検証

学習後, 設計の妥当性を次の 2 つの信号で検証する (いずれも複数シードで).

VAE : AU 検証 (合否判定規則つき). 検証点 m_{ver} はテストグリッド中 $2\hat{d}_{\text{ID}}$ 以上の最小の点として AU 曲線を観察する前に指定する (事後選択を避けるため; 複数の m_{ver} での確認を推奨する). m_{ver} で学習した VAE の AU (多シード平均) に対し, 次の 2 条件を判定する:

$$\text{V1 (遮断の発生): } AU(m_{\text{ver}})/m_{\text{ver}} \leq 0.9, \quad (2)$$

$$\text{V2 (オーダー整合): } \hat{d}_{\text{ID}} \leq AU(m_{\text{ver}}) \leq 3\hat{d}_{\text{ID}}. \quad (3)$$

両方成立で**合格** (データの多様体次元と同一オーダーへの圧縮の証拠), V1 不成立は「 β がデコーダ容量に対して小さすぎる», V2 の上側不成立は「Step 1 の過小推定または遮断の不足», 下側不成立は「過正則化 (β 過大)」を示唆する (表 2). V1/V2 は**統計的に検証された検定ではなく, 保守的な報告規約**である: 閾値 $0.9 \cdot$ 係数 3 は作業既定値であり, 本論文の全設定で判定は V1 閾値 $\in (0.67, 0.94) \cdot$ V2 係数 $\in (2.3, 6.6)$ の範囲で不変, かつ全多シード設定でシード毎判定も全会一致であった (§ 5; 補助資料の解析スクリプトで再計算できる). V2 の帯 $[\hat{d}_{\text{ID}}, 3\hat{d}_{\text{ID}}]$ が広いのは, AU が $\beta \cdot$ アーキテクチャ依存の観測量であって内在次元の推定量ではない (§ 3.1) ことの帰結であり, V2 が検証するのは「AU がある次元量に一致する」ことではなくオーダー整合のみである——特に, 合格は $AU_{\text{sat}} = d_{\text{emb}}$ を含意しない (Torus の境界域挙動; § 5.2). 単純な多様体では急峻な飽和が, 実データでは緩やかな鈍化が現れる (§ 5.3).

MSE 検証 (定性的診断; AE · VAE 共通). $MSE(m)$ の急速な改善が $m \approx \hat{d}_{\text{ID}} \sim 2\hat{d}_{\text{ID}}$ で鈍化するかを目視確認する (アルゴリズム的な肘点検出器は提案しない; 変化点の自動検出はグリッド・シード依存性が強く, 付録 B の探索的解析にとどめる). VAE では MSE 検証を V1/V2 と**必ず併読**する: AU が合格でも MSE が m_{ver} を超えて大きく改善し続ける場合は位相的障害 ($d_{\text{emb}} > d_{\text{ID}}$) による過剰刈り込みを疑い, 余裕を広げる (表 2 第 4 行; Torus での実例は § 5.2). すなわち本プロトコルは, V1/V2 という機械的判定とプロット・統計量の報告 (後述の報告要件) を組み合わせた**診断型ワークフロー**であり, 単一数値を出力する選定アルゴリズムではない.

検証が不整合の場合の失敗モードを表 2 に整理する. これは本プロトコルを新しいデータ・アーキテクチャに適用する読者のための診断チェックリストである.

表 2: Failure modes in Step 3 and their diagnoses. Each row is backed by the experiments in § 5.

Symptom	Likely cause	Remedy / interpretation
AU = m for all tested m (no truncation)	β too small relative to decoder power ($d^*(\beta) \gg m$)	Increase β or restrict decoder capacity; see Conv-VAE boundary (§ 5.6)
AU saturates far above $\hat{d}_{\text{ID}}$	Step-1 underestimate (m_{ref} too small), or entangled multi-class structure	Re-check Step 1 convergence in m_{ref} ; treat AU_{sat} as upper reference
$\hat{d}_{\text{ID}}$ inflates as m_{ref} grows (no convergence)	Latent geometry distortion at large m_{ref} (natural images)	Restrict to $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$ and cross-check with input-space estimate
MSE keeps improving beyond $2\hat{d}_{\text{ID}}$	Topological obstruction ($d_{\text{emb}} > d_{\text{ID}}$) or noise fitting	Allow larger margin; inspect reconstruction quality

報告要件: 本プロトコルの適用結果を報告する際は, (i) シード数と $\hat{d}_{\text{ID}} \cdot AU$ のシード間分散, (ii) m グ

リッドと m_{ref} の値, (iii) $\beta \cdot \delta$ ・前処理, (iv) TwoNN と MLE の両推定値, を最低限記載する. 本論文の全実験もこの要件に従う.

3.3 適用可能範囲 (先出し要約)

本プロトコルがどの設定で機能し, どこで境界に達するかを表 3 に先出しする (証拠は § 5). 読者はまずこの表で自分の設定が適用域にあるかを確認されたい.

表 3: Applicability of the ID-guided protocol (summary of the evidence in § 5). “Stable” means low inter-seed variance under our experimental conditions, not unbiasedness.

Setting	Step 1 ($\hat{d}_{\text{ID}}$)	Step 3 (AU verification)	Overall
Synthetic manifolds ($d_{\text{true}} \leq 3$, 3–5 seeds)	Direct input-space estimate; matches d_{true}	Pass: saturation at $d_{\text{true}} / d_{\text{emb}}$ with sufficient margin ($\sigma = 0$); Torus boundary over-pruning ($m \leq 4$) caught by the MSE cross-check	Fully applicable (ground-truth validated)
FC-VAE on MNIST (3 seeds) / Fashion-MNIST (Step 1: 3 seeds; Step 3: single seed)	Stable: $10.03 \pm 0.12 / \approx 9$	Pass (V1/V2) on MNIST; Fashion-MNIST exploratory	Applicable (MNIST fully validated)
Conv-VAE on MNIST	Stable (inflates while $\text{AU} = m$)	Fail at $\beta_{\text{max}} = 4$ (V1); $\beta_{\text{max}} \geq 10$ restores V1 only (single seed)	Applicable only with strong β (exploratory)
Natural images (CIFAR-10 / SVHN, 3 seeds)	Consistent with Pope et al. [7] at $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$; inflates beyond	Unresolved: no V1/V2 pass within tested range	Step 1 usable with care; Step 3 open problem

4 選定原理の理論的根拠

本章の結果の位置づけを先に明示する. 命題 1 は理想化 (ゼロ再構成誤差) のもとでの厳密な下界, 命題 2 は線形ガウス設定に限定した解析結果であり, 非線形 VAE への適用は定性的な指針 (解釈的サロゲート) にとどまる. 命題 3 は Step 1 の設計根拠を与える条件付き安定性のスケッチである.

4.1 必要条件: 位相的下界

命題 1 (ボトルネック次元の位相的下界). $\mathcal{M} \subset \mathbb{R}^N$ をコンパクトかつ滑らかな d 次元多様体, $f: \mathbb{R}^N \rightarrow \mathbb{R}^m \cdot g: \mathbb{R}^m \rightarrow \mathbb{R}^N$ を連続なエンコーダ・デコーダとする. $g \circ f$ が $\mathcal{M}$ 上で恒等写像 (ゼロ再構成誤差) となるためには, $m \geq d_{\text{emb}} \geq d$ が必要である (d_{emb} は $\mathcal{M}$ の位相的最小埋め込み次元).

Proof. $g(f(x)) = x$ ($x \in \mathcal{M}$) より $f|_{\mathcal{M}}$ は連続な単射である. コンパクト空間からハウスドルフ空間への連続単射は像への同相写像なので, $f|_{\mathcal{M}}$ は位相的埋め込みであり, d 次元多様体の $\mathbb{R}^m$ ($m < d_{\text{emb}}$) への位相的埋め込みは d_{emb} の定義より存在しない [24]. $\square$

本命題はゼロ誤差・連続性という理想化のもとでの必要条件であり, 有限誤差・ノイズ・小集合上の非単射性を持つ実際のニューラル AE にはそのままは適用されない (近似的な下界の目安として運用する).

これが Step 2 の下側限界の根拠である．実データでは d_{emb} は未知だが $d_{\text{emb}} \geq d_{\text{ID}}$ なので， $\hat{d}_{\text{ID}}$ は「これ未満は原理的に不足」という参照点を与え， $d_{\text{emb}} > d_{\text{ID}}$ の可能性（Torus 型の位相的障害）が「 $\hat{d}_{\text{ID}}$ より大きめに取る」余裕の一因となる．実験では Swiss Roll ($d_{\text{emb}} = 2$) と Torus ($d_{\text{emb}} = 3 > d_{\text{ID}} = 2$) でこの下界が MSE の肘点として現れることを確認する (§ 5.2).

4.2 十分条件側の機構：水充填型サロゲート活性化条件

命題 2 (線形ガウス rate-distortion 近似におけるサロゲート活性化条件). 線形エンコーダ・デコーダとガウス事前分布を持つ β -VAE を考える（詳細は付録 A）. ここで τ^2 は**デコーダ出力の等方ガウス観測ノイズ分散**（尤度 $p(x|z) = \mathcal{N}(g(z), \tau^2 I)$ の分散パラメータ）， λ_j は**センタリング済み入力データの共分散行列の第 j 固有値**である．さらに， KL 項を相互情報量で置き換える *rate-distortion* 近似を用いる（この置き換えは *aggregated-posterior* と事前分布の不一致項を無視した**近似**であり，本命題の成立範囲はこの近似の範囲内に限られる）. このとき，水充填定理と KKT 条件から：

1. (活性化しきい値) 第 j 固有方向が活性となる必要十分条件は

$$\lambda_j > \beta \tau^2. \quad (4)$$

2. (最適活性数) 大域最適解の活性固有方向数は $A^*(m) = \min(m, d^*(\beta))$, $d^*(\beta) := |\{j : \lambda_j > \beta \tau^2\}|$.
3. (単調飽和) $A^*(m)$ は m について単調非減少で， $m \geq d^*(\beta)$ で飽和する.

本命題は学習済み非線形 VAE に関する定理ではなく，非線形実験を解釈するための**解釈的サロゲート**である（導出は付録 A）.

注意 1 (プロトコルへの含意). 以下はいずれも**サロゲートモデルにおける予測**であり，非線形 VAE では診断的期待として運用する（成否は Step 3 で判定する）. (i) $m > d^*(\beta)$ の余剰次元はサロゲートの最適解で遮断される——これが Step 2 「VAE では大きめの m が安全」の根拠である. (ii) 遮断閾値 $\beta \tau^2$ は β に比例する—— β が小さすぎれば $d^*(\beta) > m$ となり遮断が起きない ($AU = m$). これが表 2 第 1 行の失敗モードであり，Conv-VAE・自然画像で実際に観測される (§ 5.6). (iii) $\beta = 0$ (*vanilla AE*) では閾値が消失し全次元が使用される——AE に自動遮断がなく，Step 2 で m 自体を絞る必要がある理由である.

注意 2 (サロゲートのレートと経験的 AU の対応). 命題 2 が数えるのは正のレート $R_j^* > 0$ を持つ固有方向数，経験的 AU (式 (1)) が数えるのは事後平均の分散が閾値を超える座標数であり，両者は定義上は別物である．線形ガウス設定では両者は一致する：最適解において $R_j^* > 0 \iff$ 第 j 座標の事後平均 $\mu_j(x)$ が x に依存 ($\text{Var}_x[\mu_j] > 0$) $\iff AU$ が活性と数える， $R_j^* = 0 \iff \mu_j \equiv 0$ (*collapse*) である．非線形 VAE ではこの対応は**定性的な期待**にとどまる：各 m で独立に確率的最適化を行うため経験的 $AU(m)$ は非単調な揺らぎを持ち，線形設定の鋭い飽和は緩やかな鈍化に置き換わる (§ 5.3). 本論文はサロゲートが非線形の AU 値を定量的に予測するとは主張しない．また，非線形デコーダの実効ノイズ分散を「観測された有効次元と整合するよう逆算した」校正值 τ_{eff}^2 で置き換える議論 (§ 5.6) は，本命題の帰結ではなく**ヒューリスティックな外挿**である．

4.3 Step 1 の根拠：内在次元推定の条件付き安定性

命題 3 (TwoNN の条件付き安定性 (スケッチ)). エンコーダ f が局所 *bi-Lipschitz* (歪み $\varepsilon \in [0, 1)$) であり，かつ近傍順位が高確率で保存される ($\text{Trustworthiness} \geq 1 - \delta_T$, δ_T 小) ならば，2 近傍距離比 r_2/r_1 の分布変化は ε と δ_T の連続関数 $C(\varepsilon, \delta_T)$ ($\varepsilon, \delta_T \rightarrow 0$ で $C \rightarrow 0$) で上界され，入力空間と潜在空間の *TwoNN* 推定値の差もこれに支配される．本命題は不偏性の保証ではなく，条件付き安定性の十分条件のスケッチである（証明スケッチは付録 A）.

実験 (§ 5.5) では, ε (等長性) の改善よりも $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ による δ_T (近傍順位保存) の改善が支配的であることを示す——これが Step 1 で「等長正則化よりもボトルネック余裕」を優先する設計根拠である。

5 実験

実験は 3 層で構成する：(i) **原理検証**——真の次元既知の合成多様体でプロトコルが正しい次元を返すか (§ 5.2)；(ii) **実データ検証**——MNIST・Fashion-MNIST でプロトコル全体が機能し、実用価値（探索コスト・下流性能）があるか (§ 5.3–§ 5.5)；(iii) **適用境界**——Conv-VAE・自然画像でどの条件が破れるか (§ 5.6). **本文の結果はすべて 3 シード (42, 123, 777) 以上の多シード実験**であり、単一シードの探索的観察は付録 C に分離した（例外は本文中に明記する）。

5.1 実験設定

共通：Adam ($\text{lr} = 10^{-3}$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, weight decay なし), バッチサイズ 128, ReLU (出力層 Sigmoid), PyTorch 2.0, 単一 NVIDIA GeForce RTX 3070 GPU (CUDA 不可時は CPU). 前処理は画素値の $[0, 1]$ 正規化のみ（合成多様体は標準化：平均 0・分散 1). 学習・テスト部分集合は公式分割の先頭 $n_{\text{train}} \cdot n_{\text{test}}$ サンプルを固定順で使用. AU・TwoNN・MLE はテスト部分集合上で計算する.

合成多様体：隠れ層 $[64, 32]$, 200–300 エポック, VAE $\beta = 4.0$, $n = 5,000$ (学習 4,000 / テスト 1,000).

MNIST / Fashion-MNIST：入力次元 784, 隠れ層 $[512, 256]$, VAE $\beta = 4.0$, m グリッド $\mathcal{M} = \{1, 2, 4, 8, 12, 16, 20, 32, 64, 128, 256\}$ (実験ごとの変更は明記), MNIST：300 エポック ($n_{\text{train}} = 20,000$, $n_{\text{test}} = 3,000$), Fashion-MNIST：300 エポック (Exp-Real-Geom; $n_{\text{train}} = 20,000$).

ID 推定：TwoNN ($k = 2$) [5], MLE ($k = 10$; $k \in \{5, 10, 20\}$ で安定性確認済み) [6]. AU 閾値 $\delta = 10^{-2}$ (付録 D).

再現性と補助資料の構成：補助資料は次の 4 点で構成する：(i) 実験スクリプト（表 15 の実験名と 1 対 1 対応）, (ii) 本文の全表・全図を学習ログから再生成する解析スクリプト, (iii) 学習ログ (JSON; 全シード), (iv) 乱数シード・ライブラリバージョン等の環境情報. 表の数値が同梱スクリプトの出力と一致することを投稿前に確認済みである. 査読時は補助資料として添付し、採録時に公開リポジトリ (GitHub/Zenodo) の URL と DOI を確定する.

5.2 原理検証：真の次元既知の合成多様体

Swiss Roll ($d_{\text{true}} = d_{\text{emb}} = 2$) と Torus ($d_{\text{true}} = 2$, $d_{\text{emb}} = 3$) でプロトコルの 3 ステップを ground truth に対して検証した (3 シード).

Step 1：入力空間の TwoNN は Swiss Roll で ≈ 2.0 , Torus で ≈ 2.0 と d_{true} に一致する.

Step 3 (AE：MSE 検証)：表 4 のとおり, MSE の急改善は Swiss Roll で $m = 2 = d_{\text{emb}}$, Torus で $m = 3 = d_{\text{emb}}$ で止まる——命題 1 の下界が実際に MSE 肘点として現れ, Torus では「 $d_{\text{ID}} = 2$ では足りない」という位相的障害が観測される. これが Step 2 の余裕 ($\hat{d}_{\text{ID}}$ より大きめ) の実験的根拠である.

表 4: Synthetic manifolds (Exp-Syn-1): AE reconstruction MSE (mean $\pm$ std, 3 seeds). The elbow appears exactly at $m = d_{\text{emb}}$.

m	Swiss Roll MSE	Torus MSE
1	1.016 ± 0.315	0.356 ± 0.022
2	$0.029 \pm 0.001 \leftarrow \text{elbow} (= d_{\text{emb}})$	0.109 ± 0.007
3	$(6 \pm 2) \times 10^{-4}$	$(4 \pm 3) \times 10^{-4} \leftarrow \text{elbow} (= d_{\text{emb}})$
4	$(5 \pm 1) \times 10^{-4}$	$(1.0 \pm 0.4) \times 10^{-4}$

Step 3 (VAE : AU 検証) : 表 5 のとおり, VAE ($\beta = 4$) の AU は Swiss Roll ではテストした全域 $m \in [2, 16]$ で $AU_{\text{sat}} = 2 = d_{\text{true}}$, Torus では $m \geq 5$ で $AU_{\text{sat}} = 3 = d_{\text{emb}}$ に全シードで飽和した (標準偏差 0.0 ; $m = 5$ の活性化は細分グリッド実験 Exp-Syn-Verify による). 一方, vanilla AE の潜在座標使用数は m に張り付く (遮断機構なし) — 命題 2 の含意 (i) (iii) と整合し, 「VAE は大きめの m の余剰次元を遮断し, AU がその結果を報告する」というサロゲートモデルの予測が, この設定では ground truth 上で確認された. ただし **Torus の境界域 $m \in \{3, 4\}$ では $AU = 2 < d_{\text{emb}}$ への過剰刈り込みが生じる** — 次項で詳述する.

表 5: Synthetic manifolds (Exp-Syn-AU): active units of the VAE ($\beta = 4$) vs. the coordinate usage of the vanilla AE (mean $\pm$ std, 3 seeds). “AU” for the AE is a pseudo-AU defined by the encoding variance threshold (auxiliary observation).

	m	Vanilla AE	VAE ($\beta = 4$)
Swiss Roll ($d_{\text{true}} = d_{\text{emb}} = 2$)	2	2	2.0 ± 0.0 (saturation = d_{true})
	4	4	2.0 ± 0.0
	8	8	2.0 ± 0.0
	16	16	2.0 ± 0.0
Torus ($d_{\text{true}} = 2, d_{\text{emb}} = 3$)	4	4	2.0 ± 0.0 (over-pruned , $< d_{\text{emb}}$; see text)
	6	6	3.0 ± 0.0 (saturation = d_{emb})
	8	8	3.0 ± 0.0
	16	16	3.0 ± 0.0

境界域の過剰刈り込みと MSE 検証による検出 (Exp-Syn-Verify) : Torus の $m \in \{3, 4\}$ では $AU = 2 < d_{\text{emb}} = 3$ となる. これは表記誤りでも偶発でもなく, **シード間で完全に再現する真の現象**である: 境界域を細分した確認実験 ($m \in \{3, 4, 5, 6, 8\}$, 5 シード; Exp-Syn-Verify) でも, $m \in \{3, 4\}$ では全シードで $AU = 2$, $m \geq 5$ では全シードで $AU = 3$ と, 遷移は $m = 5$ で決定的に生じた. 過剰刈り込みは再構成品質に明確な代償を伴う: MSE は $m = 4$ の 0.220 ± 0.002 から, 第 3 座標が活性化する $m = 5$ で 0.138 ± 0.001 , $m = 6$ で 0.073 ± 0.006 へと急速に改善する (自己交差のない埋め込みが可能になるため). 解釈としては, $\beta = 4$ の KL 圧力のもとで, 余剰次元がわずかしかな境界域では第 3 座標を保持する再構成利得が KL コストに勝てず, 自己交差する 2 次元的な表現 (immersion) に押し込まれる — **位相的に必要な次元の活性化が全シードで安定するのは, 既定探索窓の上端 $2\hat{d}_{\text{ID}} = 4$ を超えた $m \geq 5$ から**である. この観察は 2 つの運用上の含意を与える. 第一に, Step 2 の余裕の必要性を ground truth 上で示す: Torus では $d_{\text{emb}} > d_{\text{ID}}$ の位相的ギャップにより既定窓 $[\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}] = [2, 4]$ では不足し, 窓の外側で初めて安定する — 既定探索窓が出発点であって上限の保証ではない理由である (§ 3.2.2). 第二に, **V1/V2 の限界を明示する**: 事前指定の検証点 $m_{\text{ver}} = 4 = 2\hat{d}_{\text{ID}}$ では $AU = 2$ は V1 ($r = 0.5$) $\cdot$ V2 ($2 \leq 2 \leq 6$) をともに通過する — V1/V2 が検証するのは「 $\hat{d}_{\text{ID}}$ とのオーダー整合」であって「 $AU_{\text{sat}} = d_{\text{emb}}$ 」ではないからである. この取りこぼしを検出するのが併読する MSE 検証である: MSE は $m_{\text{ver}} = 4$ を超えて大幅に改善し続ける ($0.22 \rightarrow 0.07$) ため, 表 2 第 4 行 (位相的障害) が発火し, 余裕の拡大が指示される.

解釈上の注意 ($d_{\text{ID}} \cdot d_{\text{emb}} \cdot AU$ の区別) : この結果を「AU が d_{emb} を推定する」と読んではいならない. TwoNN/MLE が推定するのは局所的内在次元 d_{ID} , 命題 1 の下界に現れるのは位相的埋め込み次元 d_{emb} , AU は $\beta \cdot \delta \cdot$ アーキテクチャに依存する「使用座標数」という観測量であり, 三者は定義の異なる量である (表 1). Torus での $AU_{\text{sat}} = d_{\text{emb}}$ は, 十分な β と収束・標準化前処理・十分な余裕 (Torus では $m \geq 5$) のもとで「KL 遮断後に残った座標数が埋め込みに必要な次元数と一致した」という**条件付きの経験的対応**であって理論的必然ではない (Torus $\cdot$ Möbius Band 以外への一般化は未確認; 単一シードの位相多様体実験は付録 C).

判定 (Step 3 規則; m_{ver} はグリッド中 $2\hat{d}_{\text{ID}}$ 以上の最小点として事前指定): Swiss Roll ($m_{\text{ver}} = 4 = 2\hat{d}_{\text{ID}}$:

AU = 2.0, 活性率 0.50) は V1 · V2 · MSE 検証すべて成立で**合格** (3 シード, $\sigma = 0$). Torus ($m_{\text{ver}} = 4$) は V1 · V2 は成立するが **MSE 検証が位相的障害を検出** (m_{ver} 超で MSE が 3 倍改善) — 表 2 第 4 行に従い余裕を拡大し, $m = 6$ で全検証が成立して**合格** ($\text{AU}_{\text{sat}} = 3 = d_{\text{emb}}$; 3 シード, $\sigma = 0$). この 2 段階の経過自体が, AU 単独でなく MSE と併読する診断型ワークフローの動作例である.

5.3 実データ検証：MNIST

5.3.1 Step 1: $\hat{d}_{\text{ID}}$ の推定

参照 AE (300 エポック) の潜在表現で TwoNN/MLE を計算した (表 6). $m_{\text{ref}} \geq 64$ で TwoNN は 10.0 前後に収束し (VAE 側潜在の 3 シード値は 10.03 ± 0.12 ; 表 8), MLE (11.3–11.9) も同一オーダーを与える. 複数 m_{ref} での収束と 2 推定量の一致という Step 1 の要件を満たし, **MNIST の参照値** $\hat{d}_{\text{ID}} \approx 10$ –12 を得る. なお表 6 の各行は通常 AE の m スイープそのものであるため, MSE 列は後述の Step 3 (AE 側 MSE 検証) にもそのまま用いる. 対照として線形 PCA は累積寄与率 80% に 43 次元, 90% に 86 次元を要する (図 2 左) — 累積寄与率次元は内在次元の推定量ではないため直接のベースラインではないが, 線形圧縮に必要な次元数が非線形推定値 $\hat{d}_{\text{ID}} \approx 10$ –12 よりはるかに大きいことを示す例示的対照である.

表 6: MNIST Step 1: TwoNN/MLE estimates through reference AEs of increasing m_{ref} . **All rows are a single-seed (42) exploratory sweep** (300 epochs); statistical uncertainty at $m_{\text{ref}} \in \{64, 128, 256\}$ is quantified separately by subsampling CIs and estimator cross-checks in Table 7 (Section 5.3.2), and the 3-seed reproducibility of the latent estimate is reported in Table 8.

m_{ref}	MSE	TwoNN ID	MLE ID	CKA
8	0.0191	6.08	6.70	0.725
16	0.0121	7.96	8.61	0.812
32	0.0087	8.84	9.89	0.875
64	0.0062	9.54	11.26	0.908
128	0.0061	9.84	11.45	0.921
256	0.0057	10.02	11.85	0.953

5.3.2 Step 1 の統計的頑健性：サブサンプリング CI と推定量相互検証

$\hat{d}_{\text{ID}}$ は候補範囲の中心を与えるため, その統計的不確かさを定量化する (Exp-Boot-CI; 学習済み参照 AE の潜在表現の再解析). kNN 系推定量では復元抽出ブートストラップが重複点により破綻するため, 非復元サブサンプリング ($n = 1500$, 200 反復) による 95% パーセンタイル区間を報告する. また, 原理の異なる推定量として DANCo[19] と ESS[20] (scikit-dimension 実装) を同一潜在表現に適用し, TwoNN/MLE とのオーダー一致を確認する.

表 7: Exp-Boot-CI (MNIST): statistical robustness of Step 1. Subsampling 95% intervals ($n = 1500$, 200 repeats, without replacement) and cross-check estimators (DANCo, ESS) on the same reference-AE latents (single seed 42 models; the uncertainty quantified here is sampling variability of the estimators).

Representation	TwoNN [95% CI]	MLE [95% CI]	DANCo	ESS
Raw input ($N = 784$)	12.63	14.46	784 (degenerate)	18.67
AE latents, $m_{\text{ref}} = 64$	9.56 [8.92, 10.24]	11.14 [10.91, 11.41]	10.04	13.17
AE latents, $m_{\text{ref}} = 128$	9.72 [9.22, 10.23]	11.33 [11.08, 11.56]	10.03	13.72
AE latents, $m_{\text{ref}} = 256$	9.93 [9.37, 10.68]	11.67 [11.45, 11.90]	10.95	14.98

結果（表 7）は 3 点にまとめられる．第一に，**サブサンプリング 95% 区間は幅 1.0–1.3 (TwoNN)・0.5 (MLE) と狭く**， $\hat{d}_{\text{ID}} \approx 10\text{--}12$ という候補範囲の中心の読み取りは標本変動に対して頑健である．第二に，**原理の異なる DANC0 は 10.0–10.9 と TwoNN に密接に一致し**，ESS は 13–15 とやや高いが同一オーダーにある——Step 1 の読み取りが TwoNN の挙動に固有のものではないことを示す．生入力空間では TwoNN (12.63)・MLE (14.46) は潜在推定値からの乖離が中程度にとどまる一方，DANC0 は環境次元 784 に退化し（環境次元がサンプル数に比して大きいときに角度・ノルム統計の校正が破綻する既知の失敗モードであり，ソフトウェア障害ではない），ESS も 18.7 へ上振れする．すなわち**参照 AE 経路は，採用した推定量群を本論文の条件下で安定化させる実用的な経路**であり，生入力推定が常に不可能という意味ではない（推定量によっては生入力でも同一オーダーを与える）．第三に，サブサンプルサイズ感度（ $n = 500\text{--}2500$ ，付録の補助資料参照）では TwoNN 平均が n とともに単調に上昇する（例： $m_{\text{ref}} = 64$ で $9.07 \rightarrow 9.72$ ）——TwoNN が「数値的に安定だが標本サイズ依存のバイアスを持つ」という本論文の位置づけ（§ 6.2）を直接例証する（サブサンプル平均が表 6 のフルサンプル値よりわずかに低いのはこのバイアスによる）．

5.3.3 Step 2：候補範囲の設定

$\hat{d}_{\text{ID}} \approx 10\text{--}12$ より，AE の候補範囲は $m \in [10, 24]$ ，VAE は $m \geq 20$ の大きめ設定となる．

5.3.4 Step 3：AU・MSE による検証（3 シード）

VAE ($\beta = 4$, 300 エポック, 3 シード) の $\text{AU}(m)$ を表 8 に示す．AU はシード間で高度に再現し ($\sigma \leq 0.5$)， $m \leq 12$ ではほぼ全次元が活性 ($\text{AU} \approx m$) である一方， $m > 12$ で増加が明確に鈍化し， $m = 64$ でも $\text{AU} = 22.3$ にとどまる——**KL 遮断が $\hat{d}_{\text{ID}} \approx 10\text{--}12$ の近傍から効き始める**という，Step 3 が期待する検証信号が得られた．AE 側でも MSE の急改善は $m \approx 16\text{--}20$ で鈍化し（表 6 の MSE 列＝通常 AE の m スイープ），候補範囲 $[10, 24]$ と整合する．

判定 (Step 3 規則； $m_{\text{ver}} = 20$ はグリッド中 $2\hat{d}_{\text{ID}}$ 以上の最小点として事前指定)： $\text{AU} = 13.3 \pm 0.5$ ，活性率 $0.67 \leq 0.9$ (V1 成立)， $\hat{d}_{\text{ID}} = 10 \leq 13.3 \leq 30 = 3\hat{d}_{\text{ID}}$ (V2 成立) で**合格**（シード毎判定も 3/3 で一致）． $m_{\text{ver}} \in \{32, 64\}$ でも同様に合格する（活性率 $0.49 \cdot 0.35$ ， $\text{AU} = 15.7 \cdot 22.3$ ）．併読する MSE 検証も，急改善が $m \approx 16\text{--}20$ で鈍化しており位相的障害の兆候を示さない．

表 8: MNIST Step 3 (Exp-Mnist-Multi-300): AU and TwoNN ID of the VAE ($\beta = 4$, 300 epochs, mean±std over 3 seeds). The AU growth slows beyond $m \approx \hat{d}_{\text{ID}}$, and the latent TwoNN converges to $\hat{d}_{\text{ID}} \approx 10$.

m	AU (mean±std)	TwoNN ID (mean±std)	Note
4	4.0 ± 0.0	3.98 ± 0.14	all dims active slowdown begins near $\hat{d}_{\text{ID}}$
8	8.0 ± 0.0	6.67 ± 0.15	
12	10.0 ± 0.0	7.41 ± 0.06	
16	11.7 ± 0.5	7.95 ± 0.21	
20	13.3 ± 0.5	8.37 ± 0.14	
32	15.7 ± 0.5	9.07 ± 0.10	
64	22.3 ± 0.5	10.03 ± 0.12	




図 2: MNIST: m -dependence of the indicators (300 epochs). **Left (AE)**: MSE (log scale, left axis) and TwoNN ID (right axis); vertical dotted lines mark the PCA 80/90/95% dimensions (43/86/152), far above the nonlinear estimate $\hat{d}_{ID} \approx 10$. **Right (VAE, $\beta = 4$)**: MSE, AU, and TwoNN ID; the AU growth slows beyond $m \approx \hat{d}_{ID}$.




図 3: MNIST: multi-seed reproducibility of the AU verification signal (3 seeds, 300 epochs). Left: per-seed $AU(m)$ with the ID-guided candidate range $[\hat{d}_{ID}, 2\hat{d}_{ID}]$ shaded; right: mean±std band with the Step-1 reference $\hat{d}_{ID} \approx 10$. AU values are highly reproducible ($\sigma \leq 0.5$). Change-point (knee) estimates are deliberately not shown here; they are exploratory only (Appendix 付録 B).

5.3.5 鈍化域の細密観察と変化点検出の注意

鈍化の開始位置をより細かく見るため、 $\hat{d}_{ID}$ 近傍を 1 刻みにした密グリッド ($m = 8-16$ を 1 刻み, 以降 $m \in \{18, 20, 24, 28, 32, 40, 48, 64\}$; 計 17 点, 300 エポック, 3 シード) で AU 曲線を観察した。AU(m) は $m = 8-10$ でほぼ対角 ($AU = m$) に乗り, $m \geq 11$ で対角から離れ始める——一階差分比率に基づく変化点検出 (閾値 $\tau_{knee} = 0.25$; 付録 B) をこの密グリッドに適用すると変化点は 10.3 ± 0.9 (シード別 11, 9, 11) となり, $\hat{d}_{ID} \approx 10$ と整合する。

ただし, この整合には 2 つの重要な限定がある。第一に, 密グリッド領域は Step 1 の TwoNN 推定値の近傍に置いたものであり, この結果は **TwoNN 由来の探索窓に条件付けられた局所的な曲線要約**であって独立な相互検証ではない。第二に, 同じ検出器を疎グリッド $\{4, 8, 12, 16, 20, 32, 64\}$ に適用すると変化点は 43 ± 15 と大きく変動する——**変化点の自動検出はグリッド設計に強く依存し, プロトコルの名前付き出力として運用すべきでない**。このため本プロトコルの Step 3 は「AU 鈍化域が $\hat{d}_{ID}$ と同一オーダーにあるか」という頑健

な読み取り（AU 値そのものの多シード比較）を主とし，変化点検出はグリッド設計の補助にとどめる（詳細な感度分析は付録 B）。

5.3.6 Fashion-MNIST

Fashion-MNIST では Exp-Real-Geom (§ 5.5 ; 3 シード, 300 エポック) により $\hat{d}_{\text{ID}} \approx 9$ (TwoNN, $m_{\text{ref}} = 5\hat{d}_{\text{ID}} - 10\hat{d}_{\text{ID}}$ で 9.9–10.1 に収束) を得た。VAE の AU 検証を含むフルプロトコルの多シード適用は，単一シードの予備観察（付録 C）で MNIST と同傾向を確認したが，多シード再現は今後の課題である。

5.4 ベースライン比較：探索コストと下流性能

ID 誘導型選定の実用価値を，「フル m グリッド探索」との比較で定量化する (Exp-Downstream)。評価指標は潜在表現上の線形プローブ（多クラスロジスティック回帰）によるテスト分類精度と再構成 MSE である。

AE (参照 AE スイープの再利用, 300 エポック, シード 42)：表 9 左のとおり，線形プローブ精度は $m = 8$ –12 で頭打ちとなり (92.3%, $m = 12$)， $m = 256$ まで増やしても改善しない (91.8%；生ピクセル 784 次元では 91.6%)。フルグリッド (11 点) 上の最良精度 92.3% は ID 誘導候補範囲 [10, 24] の内部 ($m = 12$) で達成され，範囲内の他の点 ($m = 16, 20$) との差も 1.4 ポイント以内である。

VAE ($\beta = 4$, 300 エポック, 3 シード)：表 9 右のとおり，VAE 側でも同じ構図が成り立つ：線形プローブ精度はグリッド $\{4, \dots, 64\}$ 全体の最良値 $89.1 \pm 0.4\%$ を候補範囲内の $m = 12$ で達成し， $m \geq 12$ ではほぼ横ばいである (VAE 経路の検証点 $m = 20 = 2\hat{d}_{\text{ID}}$ でも $88.2 \pm 0.4\%$ と最良値との差は 1 ポイント未満)。なお本表の AU・MSE は表 8 (Exp-Mnist-Multi-300) の再学習による再現値であり，両者は一致した (再現性の追加確認)。

探索コスト：本論文の MNIST フルグリッドは m 11 点 $\times$ 3 シード = 33 ランを要する。これに対し ID 誘導経路は，Step 1 の参照 AE ($m_{\text{ref}} \in \{64, 128, 256\}$ の収束確認；単一シードで 3 ラン) ののち，(a) AE 経路：候補範囲 [10, 24] 内のグリッド点 $\{12, 16, 20\}$ を 3 シードで学習 (9 ラン) ——計 12 ラン (**約 64% 削減**)；(b) VAE 経路： $m = 2\hat{d}_{\text{ID}} = 20$ の 1 点を 3 シードで学習し AU で検証 (3 ラン) ——計 6 ラン (**約 82% 削減**)，のいずれでも探索コストを大幅に削減する。なおこの会計は Step 1 を単一シードで数えている (本論文の Step 1 はサブサンプリング CI と推定量相互検証で不確かさを別途定量化しているため)；Step 1 も 3 シードで行う対称な会計では AE 経路 18 ラン (約 45% 削減)・VAE 経路 12 ラン (約 64% 削減) となる。保持される性能は上記のとおり最良値とほぼ同等である。ただしこの比較は本論文の MNIST グリッド構成・線形プローブに限られ，一般の削減率を主張するものではない (§ 6.1)。

表 9: Exp-Downstream (MNIST): linear-probe test accuracy and MSE vs. m . Left: AE latents (300 epochs, single seed 42; reuse of the reference-AE sweep). Right: FC-VAE ($\beta = 4$) latents (300 epochs, mean $\pm$ std, 3 seeds). Bold m values lie in the ID-guided candidate range $[10, 24]$, which contains the best accuracy over the full grid. Raw-pixel baseline: 91.6%.

AE (single seed)			VAE ($\beta = 4$, 3 seeds)			
m	Probe acc. (%)	MSE	m	Probe acc. (%)	AU	MSE
1	60.0	0.0437	4	85.0 ± 0.5	4.0 ± 0.0	0.0282
2	60.0	0.0399	8	87.7 ± 0.1	8.0 ± 0.0	0.0182
4	81.7	0.0292	12	89.1 ± 0.4	10.0 ± 0.0	0.0154
8	91.7	0.0191	16	89.0 ± 0.2	11.7 ± 0.5	0.0138
12	92.3	0.0148	20	88.2 ± 0.4	13.3 ± 0.5	0.0126
16	92.0	0.0121	32	88.1 ± 0.2	15.7 ± 0.5	0.0112
20	90.9	0.0114	64	88.7 ± 0.3	22.3 ± 0.5	0.0089
32	91.2	0.0087				
64	91.8	0.0062				
128	92.2	0.0061				
256	91.8	0.0057				

5.5 Step 1 の妥当性条件：何が内在次元推定を安定にするか

Step 1 は参照 AE の潜在表現を経由するため、「参照表現の幾何的歪みが推定を壊さないか」が焦点となる。実験 Exp-Real-Geom では、等長性の異なる 4 モデル（通常 AE / IsometricAE[17] / CAE[16] / DAE[15]）を MNIST・Fashion-MNIST 上で $m_{\text{ref}} \in \{d, 2d, 3d, 5d, 10d\}$ ($d = \hat{d}_{\text{ID}}$; MNIST は 10, Fashion-MNIST は 9) でスweepし、TwoNN・MLE・ κ ・Trustworthiness・kNN overlap を比較した（3 シード, 300 エポック）。

表 10: Exp-Real-Geom (MNIST, mean $\pm$ std, 3 seeds): TwoNN through four reference models. Convergence is driven by the bottleneck margin $m_{\text{ref}}/\hat{d}_{\text{ID}}$, largely independently of the isometry (condition number κ).

Model	TwoNN ($m_{\text{ref}} = d$)	TwoNN ($m_{\text{ref}} = 5d$)	TwoNN ($m_{\text{ref}} = 10d$)	κ ($m_{\text{ref}} = 10d$)
AE	7.3 ± 0.4	10.0 ± 0.1	10.0 ± 0.1	4.1×10^7
IsometricAE	7.5 ± 0.4	10.1 ± 0.1	10.1 ± 0.1	7.8
CAE	7.2 ± 0.5	9.9 ± 0.1	10.0 ± 0.1	3.2×10^3
DAE	7.6 ± 0.4	10.0 ± 0.1	10.0 ± 0.1	6.3×10^3

結果（表 10）は明確である：(1) 4 モデルすべてで TwoNN は $m_{\text{ref}} = d$ の過小推定（ ≈ 7.3 – 7.6 ）から $m_{\text{ref}} \geq 5d$ で ≈ 10 へ収束し、モデル間差（ ± 0.3 以内）は m_{ref} 増大の効果（約 2.5 ポイント）より 1 桁小さい；(2) IsometricAE は κ を 10^7 から 8 前後まで改善するが、TwoNN への効果は ± 0.2 以内にとどまる。Fashion-MNIST でも同一のパターンを得た。すなわち「等長性の改善」ではなく「ボトルネック余裕 $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ 」が Step 1 の安定性の支配的条件であり（命題 3 の δ_T 支配の含意と整合）、Step 1 で $m_{\text{ref}} = 256 \gg \hat{d}_{\text{ID}}$ の通常 AE を使う設計が正当化される。




図 4: Step-1 stability: (left) on Swiss Roll, TwoNN recovers once $m_{\text{ref}} > d_{\text{true}}$ regardless of isometry; (right) on MNIST, TwoNN stabilizes for $m_{\text{ref}} \geq 48 \approx 5\hat{d}_{\text{ID}}$ even where the condition number κ grows sharply.

5.6 適用境界：Conv-VAE と自然画像

本節はプロトコルの「失敗の報告」ではなく、表 2 の失敗モードが実際にどの条件で発生するかの定量化である。

5.6.1 Conv-VAE： β 不足による遮断の不発（3 シード）

MNIST Conv-VAE (2 層 Conv + 2 層 ConvTranspose, KL サイクリックアニーリング $\beta_{\text{max}} = 4$ [22], 150 エポック, 3 シード) を $m \in \{4, 8, 16, 32, 64, 96, 128, 192, 256\}$ でスイープした (Exp-Conv-M256). $m \leq 64$ では $\text{AU} = m$ (遮断なし) が全シードで継続し, $m = 96$ で初めて $\text{AU} = 90.7 \pm 1.2 < m$ となるが, $m = 256$ でも活性率 94% と高い. $m \in \{384, 512\}$ への拡張 (Exp-Conv-M512) でも $\text{AU} \approx m$ が維持された——すなわち $\beta_{\text{max}} = 4$ では遮断閾値 $d^*(\beta) > 512$ であり, **AU 検証は「 β がデコーダ容量に対して小さすぎる」状態を $\text{AU} = m$ という明確な信号で検出する** (表 2 第 1 行).

サロゲート条件 (命題 2) の観点では, 強力な Conv デコーダは実効ノイズ分散 τ_{eff}^2 を小さくし (FC-VAE の逆算校正值 ≈ 0.30 に対し Conv-VAE では $\ll 0.30$; ヒューリスティックな外挿), 閾値 $\beta\tau_{\text{eff}}^2$ を下げて $d^*(\beta)$ を膨張させる. この解釈は β 増強実験と整合する: $\beta_{\text{max}} = 10$ では $m = 256$ で $\text{AU} = 93$ (36%), $\beta_{\text{max}} = 20$ では $\text{AU} = 66$ (26%) と明確な飽和傾向が誘発された (Exp-ConvV-HiBeta; **単一シードの探索的観察**, 詳細は付録 C). β の増大で遮断が低次元側へ移動するという定性的予測と整合しており, Conv-VAE でのプロトコル適用には「データ・アーキテクチャに応じた β の増強」が必要条件であることが特定された.

判定 (MNIST Conv-VAE): Step 1——使用可 (FC 参照 AE 経由の $\hat{d}_{\text{ID}} \approx 10$ を流用); Step 2——候補範囲取得可 ($m \geq 20$); Step 3—— $\beta_{\text{max}} = 4$ では**不合格** ($m = 256$ で活性率 $0.94 > 0.9$, V1 不成立). $\beta_{\text{max}} \in \{10, 20\}$ では V1 は成立する (活性率 $0.36 \cdot 0.26$) が, $\text{AU} = 93 \cdot 66 > 3\hat{d}_{\text{ID}} = 30$ のため V2 は不成立のままであり (かつ単一シードの探索的観察), 「遮断は誘発できたが $\hat{d}_{\text{ID}}$ とのオーダー整合は未達」と判定する.




図 5: Boundary condition (Exp-Conv-M256): MNIST Conv-VAE with $\beta_{\max} = 4$ keeps $AU = m$ (no truncation) up to $m = 64$ and stays at 94% activation even at $m = 256$ — the failure mode “ β too small relative to decoder power” detected by the AU signal.

5.6.2 自然画像：Step 1 の有界な信頼域と Step 3 の未達（3 シード）

CIFAR-10・SVHN の Conv-VAE (3 層 Conv, $\beta_{\max} = 4$, 150 エポック, 3 シード, $m \in \{16, 32, 64, 128, 256\}$) では次の 2 点が観測された (表 11)。第一に, **Step 1 は条件付きで機能する**: CIFAR-10 の潜在 TwoNN は $m = 64 \approx 2\hat{d}_{ID}$ で 25.21 ± 0.41 となり, 生データ推定 (25.20) および Pope ら [7] の報告値 (≈ 26) と整合する。しかし $m \geq 128$ では 28.8–30.9 へ単調に膨張する——**自然画像では $m_{\text{ref}} \approx 2\hat{d}_{ID}$ 付近でのみ推定が既報値と整合し, 「大きいほど良い」は成り立たない** (真の内在次元は未知なので「整合」以上は主張できない; 表 2 第 3 行の失敗モード)。MNIST ($m_{\text{ref}} = 25\hat{d}_{ID}$ でも安定) との違いは, $AU = m$ のまま全次元が使用され続ける (遮断が効かない) ことによる潜在幾何の歪みに起因すると解釈される。SVHN では乖離がさらに大きい ($m = 256$ で潜在 27.1 vs. 生データ 10.1)。第二に, **Step 3 は未達である**: AU 飽和は $m \leq 256$ では現れず (SVHN で $m \geq 128$ から $AU < m$ となるのみ), AU 検証には β 増強・デコーダ容量制限・より大きな m 域の探索が必要である ($\beta_{\max} = 80$ ・薄型デコーダでの plateau-like behavior の予備観察は付録 C)。

判定 (自然画像): Step 1—— $m_{\text{ref}} \approx 2\hat{d}_{ID}$ の範囲でのみ使用可 (CIFAR-10: 25.21 ± 0.41 , 既報値と整合; それ以上は膨張); Step 2——候補範囲は条件付きで取得可 (CIFAR-10: $m \geq 50$); Step 3——**未解決** (CIFAR-10: $m = 256$ で活性率 1.0, V1 不成立; SVHN: 活性率 0.81 で V1 成立も $AU = 206.7 \gg 3\hat{d}_{ID}$ で V2 不成立)。

表 11: Natural images (Exp-Nat-Cifar / Exp-Nat-SVHN): Conv-VAE with KL cyclic annealing ($\beta_{\max} = 4$, 150 epochs, mean $\pm$ std, 3 seeds). Step 1 agrees with Pope et al. [7] only near $m \approx 2\hat{d}_{ID}$; Step 3 (AU saturation) is not reached in the tested range.

m	CIFAR-10		SVHN	
	AU	TwoNN ID	AU	TwoNN ID
16	16.0 ± 0.0	13.12 ± 0.12	16.0 ± 0.0	11.30 ± 0.12
32	32.0 ± 0.0	19.26 ± 0.23	32.0 ± 0.0	15.08 ± 0.08
64	64.0 ± 0.0	25.21 ± 0.41	64.0 ± 0.0	19.97 ± 0.12
128	128.0 ± 0.0	28.83 ± 0.41	125.3 ± 0.5	24.60 ± 0.36
256	256.0 ± 0.0	30.91 ± 0.64	206.7 ± 1.2	27.08 ± 0.34
Raw-input TwoNN = 25.20, MLE = 26.56			Raw-input TwoNN = 10.09, MLE = 18.85	

6 考察

6.1 従来のモデル選択基準と何が違うか

実務で m を選ぶ従来手段は、検証再構成誤差・ELBO の m スイープや下流タスク性能である。これらは「性能が頭打ちになる m 」を教えるが、(i) グリッド全域のスイープを要し、(ii) 頭打ちの原因（データの多様体次元か、モデル容量か、最適化か）を区別しない。本プロトコルはこれらを置き換えるのではなく**補完**する：Step 1 がスイープに先立って候補範囲を $\hat{d}_{\text{ID}}$ 近傍に絞り込み（探索コストの削減）、Step 3 の AU が「性能とは独立に、何次元が実際に使われているか」を報告することで冗長次元の有無を直接可視化する。実際、MNIST では MSE 検証・AU 検証・ $\hat{d}_{\text{ID}}$ ・線形プローブ精度の 4 者が同一の候補範囲 [10, 24] を支持し (§ 5.4)、候補範囲内の m の選択は、本論文の MNIST グリッド構成ではフルグリッド探索に対して学習ラン数を約 6~8 割削減しつつ下流分類精度をほぼ保持した（一般の削減率を主張するものではない）。一方、この比較は線形プローブと MNIST に限られ、非線形の下流タスクや disentanglement 指標との系統比較は今後の課題である。

6.2 安定性と妥当性： $\hat{d}_{\text{ID}}$ は何を推定しているか

本論文が一貫して維持する区別は、「TwoNN/MLE が**数値的に安定**（シード・ m_{ref} に対して低分散）」であることと「**真の内在次元に対して不偏**」であることは別だ、という点である。参照 AE の潜在空間は等長でなく（ κ は 10^7 に達する；表 10）、TwoNN が推定するのは厳密には「参照表現の局所自由度」である。MNIST の $\hat{d}_{\text{ID}} \approx 10\text{--}12$ は、(i) 複数 m_{ref} での収束、(ii) TwoNN と MLE の一致、(iii) モデル 4 種での一致（表 10）、(iv) サブサンプリング CI の狭さと原理の異なる推定量（DANCo・ESS）とのオーダー一致（表 7）、(v) CIFAR-10 での既報値との整合、という複数の間接証拠に支えられているが、不偏性の直接証明ではない。このため本プロトコルは $\hat{d}_{\text{ID}}$ を「候補範囲の中心を与える参照値」として運用し、Step 3 の検証で閉ループを構成する。残された課題として、合成データ以外での真値に対する校正（推定量のバイアス特性の系統評価）を挙げる。

6.3 AU 検証の限界：変化点検出を名前付き出力にしない理由

先行版の枠組み（本研究の前身）では AU 鈍化点 m^{knee} を診断指標の一つとしていたが、本論文はこれを名前付き出力から外した。理由は § 5.3.5 で示したとおり、(i) 疎グリッドでの検出値 (43 ± 15) はグリッド間隔に支配され、(ii) 安定化には TwoNN 由来の探索窓が必要で独立検証にならず、(iii) 検出器（閾値法・二階差分法）の選択にも感度を持つ（付録 B）からである。AU 検証の頑健な部分は「AU 値そのもの（多シードで $\sigma \leq 0.5$ ）が $\hat{d}_{\text{ID}}$ と同一オーダーで鈍化・飽和するか」という読み取りであり、プロトコルはこの頑健な部分のみを判定規則（式 (2)–(3)；変化点検出を含まない）に用いるよう設計した。探索窓の推定と変化点評価を別シード・別データ部分集合で行う nested validation は今後の課題である。

6.4 限界と今後の課題

- **検証範囲**：フルプロトコルの多シード検証は合成多様体と MNIST に限られる（Fashion-MNIST は Step 1 のみ多シード）。Conv-VAE の β 増強による回復（Exp-ConvV-HiBeta）は単一シードの探索的観察であり、多シード再現が必要である。
- **自然画像での Step 3**：AU 飽和の安定同定は未達であり、 $\beta_{\text{max}} \in [40, 120]$ の密スイープ・デコーダ容量制御・シード安定性の改善が今後の課題である（付録 C）。
- **β 依存性と判定閾値**：AU 検証の読み取りは β に依存する（ $\beta \in [2, 8]$ で AU パターンの安定性を確認

済み；付録 D). $d^*(\beta)$ の β 依存性を積極的に利用した「 β スイープによるスペクトル読み取り」は興味深い拡張である。また判定規則の閾値（活性率 0.9・係数 3）は本論文の設定で合格・不合格を大きなマージンで分離する作業既定値であり、より多様なデータでの校正は今後の課題である。

- **理論の射程**：命題 2 は線形ガウス近似であり、非線形への外挿は τ_{eff}^2 による事後的な整合確認にとどまる。非線形設定での活性化条件の導出は未解決である。
- **計算コスト**：Step 3 の多シード m スイープは GPU 時間で数時間～1 日規模を要する。Step 1 による候補絞り込みでスイープ域は縮小するが、さらなる軽量化（早期エポックでの AU 予測等）は今後の課題である。

7 むすび

本論文は、「AE/VAE のボトルネック次元 m は入力データの多様体次元から決められるか」という問いに対し、**条件付き・診断型の ID 誘導プロトコル**——(S1) $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ の参照表現による内在次元推定、(S2) $\hat{d}_{\text{ID}}$ に位相的余裕を加えた m の設定 (AE: $m \in [\hat{d}_{\text{ID}}, 2\hat{d}_{\text{ID}}]$, VAE: $m \geq 2\hat{d}_{\text{ID}}$)、(S3) 合否判定規則 V1/V2 を備えた AU・MSE による学習後検証——という回答を与えた。主張は一般解ではなく次の条件付きの形をとる： **$\hat{d}_{\text{ID}}$ は候補範囲を与え、適切な β とアーキテクチャのもとで AU が「VAE が余剰次元を実際に遮断したか」を診断する**。理論面では位相的下界と水充填型サロゲート活性化条件 $\lambda_j > \beta\tau^2$ が各ステップの理論的根拠 (rationale) を与え、実験面では真の次元既知の合成多様体（十分な余裕のもとで $\text{AU}_{\text{sat}} = d_{\text{true}}$ または d_{emb} ；Torus 境界域 $m \leq 4$ の過剰刈り込みは MSE 検証が検出；3-5 シード, $\sigma = 0$) と MNIST の全結合 VAE ($\hat{d}_{\text{ID}} = 10.03 \pm 0.12$ と AU 鈍化域の整合；3 シード) でフルプロトコルが判定規則のもとで機能し、ID 誘導範囲が本論文の MNIST グリッド構成でフルグリッド探索の学習ランを約 6~8 割削減しつつ下流分類精度を保持することを確認した。同時に、適用境界を定量化した：内在次元推定はボトルネック余裕 $m_{\text{ref}} \gg \hat{d}_{\text{ID}}$ でのみ安定であり（等長性改善は副次的；4 モデル比較）、自然画像では $m_{\text{ref}} \approx 2\hat{d}_{\text{ID}}$ を超えると膨張する；Conv-VAE では β 不足が $\text{AU} = m$ (V1 不成立) として検出され、 β 増強で遮断は回復するが $\hat{d}_{\text{ID}}$ とのオーダー整合 (V2) は未達である（単一シードの探索的観察）。今後の主要課題は、自然画像・Conv-VAE での Step 3 の多シード安定同定、変化点検出の nested validation、および $\hat{d}_{\text{ID}}$ のバイアス校正である。

参考文献

- [1] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2014.
- [2] Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 35, no. 8, pp. 1798–1828, 2013.
- [3] J. Lucas, G. Tucker, R. B. Grosse, and M. Norouzi, “Don’t blame the ELBO! A linear VAE perspective on posterior collapse,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [4] C. Fefferman, S. Mitter, and H. Narayanan, “Testing the manifold hypothesis,” *J. Amer. Math. Soc.*, vol. 29, no. 4, pp. 983–1049, 2016.
- [5] E. Facco, M. d’Errico, A. Rodriguez, and A. Laio, “Estimating the intrinsic dimension of datasets by a minimal neighborhood information,” *Sci. Rep.*, vol. 7, 12140, 2017.
- [6] E. Levina and P. J. Bickel, “Maximum likelihood estimation of intrinsic dimension,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 17, 2005.
- [7] P. Pope, C. Zhu, A. Abdelkader, M. Goldblum, and T. Goldstein, “The intrinsic dimension of images and its impact on learning,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2021.

- [8] A. Ansuini, A. Laio, J. H. Macke, and D. Zoccolan, “Intrinsic dimension of data representations in deep neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [9] L. Valeriani, D. Doimo, F. Cuturello, A. Laio, A. Ansuini, and A. Cazzaniga, “The geometry of hidden representations of large transformer models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.
- [10] T. Birdal, A. Lou, L. J. Guibas, and U. Simsekli, “Intrinsic dimension, persistent homology and generalization in neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.
- [11] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, “ β -VAE: Learning basic visual concepts with a constrained variational framework,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2017.
- [12] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *J. Roy. Statist. Soc. Ser. B*, vol. 61, no. 3, pp. 611–622, 1999.
- [13] C. M. Bishop, “Bayesian PCA,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 11, pp. 382–388, 1999.
- [14] Z. Ghahramani and T. L. Griffiths, “Infinite latent feature models and the Indian buffet process,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 18, 2005.
- [15] G. Alain and Y. Bengio, “What regularized auto-encoders learn from the data-generating distribution,” *J. Mach. Learn. Res.*, vol. 15, pp. 3743–3773, 2014.
- [16] S. Rifai, P. Vincent, X. Muller, X. Glorot, and Y. Bengio, “Contractive auto-encoders: Explicit invariance during feature extraction,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2011.
- [17] K. Kato, J. Zhou, T. Sasaki, and A. Nakagawa, “Rate-distortion optimization guided autoencoder for isometric embedding in Euclidean latent space,” in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR vol. 119, 2020.
- [18] P. Nazari, S. Damrich, and F. A. Hamprecht, “Geometric autoencoders—what you see is what you decode,” in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR vol. 202, 2023.
- [19] C. Ceruti, S. Bassis, A. Rozza, G. Lombardi, E. Casiraghi, and P. Campadelli, “DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration,” *Pattern Recognit.*, vol. 47, no. 8, pp. 2569–2581, 2014.
- [20] K. Johnsson, C. Soneson, and M. Fontes, “Low bias local intrinsic dimension estimation from expected simplex skewness,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 37, no. 1, pp. 196–202, 2015.
- [21] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR vol. 97, pp. 3519–3529, 2019.
- [22] H. Fu, C. Tan, B. Peng, Z. Zhao, T. Yan, C. Chang, and L. Zhao, “Cyclical annealing schedule: A simple approach to mitigating KL vanishing,” in *Proc. NAACL-HLT*, pp. 240–250, 2019.
- [23] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ: Wiley-Interscience, 2006.
- [24] A. Hatcher, *Algebraic Topology*. Cambridge, UK: Cambridge University Press, 2002.
- [25] A. Krizhevsky, “Learning multiple layers of features from tiny images,” Technical Report, University of Toronto, 2009.
- [26] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, and A. Y. Ng, “Reading digits in natural images with unsupervised feature learning,” in *NIPS Workshop on Deep Learning and Unsupervised Feature*

Learning, 2011.

- [27] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [28] H. Xiao, K. Rasul, and R. Vollgraf, “Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms,” *arXiv preprint arXiv:1708.07747*, 2017.

付録 A 証明と導出

A.1 命題 2（サロゲート活性化条件）の導出スケッチ

線形エンコーダ $f(x) = W_e x$, 線形デコーダ $g(z) = W_d z$, 事前分布 $p(z) = \mathcal{N}(0, I_m)$, 尤度 $p(x|z) = \mathcal{N}(W_d z, \tau^2 I_N)$ の β -VAE を考える. 入力を PCA 基底に取り, 共分散を $\Sigma = \text{diag}(\lambda_1, \dots, \lambda_N)$ ($\lambda_1 \geq \lambda_2 \geq \dots$) とすると, 線形ガウスモデルでは β -ELBO が固有方向ごとに分離する. 第 j 方向に割り当てるレート (KL 寄与) を $R_j \geq 0$, そのときの歪み低減を $D_j(R_j)$ とすると, ガウス rate-distortion 関数より $D_j(R_j) = \lambda_j e^{-2R_j}$ (nats) であり, β -ELBO の該当項は

$$\mathcal{L}_j(R_j) = -\frac{1}{2\tau^2} \lambda_j e^{-2R_j} - \beta R_j + \text{const.} \quad (5)$$

R_j についての最適化は凹計画であり, KKT 条件 $\partial \mathcal{L}_j / \partial R_j = 0$ から $R_j^* = \max(0, \frac{1}{2} \log(\lambda_j / \beta \tau^2))$ を得る. $R_j^* > 0 \iff \lambda_j > \beta \tau^2$ が活性化条件 (式 (4)) である. これは Shannon の水充填定理 [23] の「水面」を $\beta \tau^2$ とした形に一致し, $\beta = 1$ では PPCA[12] の既知の結果に帰着する. m 本の座標が使えるとき, 最適解は上位 $\min(m, d^*(\beta))$ 方向を活性化するので主張 (2) (3) が従う.

近似の内容: この導出は, VAE の期待 KL 項 $\mathbb{E}_x[\text{KL}(q_\phi(z|x) \| p(z))]$ を相互情報量 $I(x; z)$ (レート) で置き換えている. 両者の差は aggregated posterior $q_\phi(z)$ と事前分布 $p(z)$ の不一致 $\text{KL}(q_\phi(z) \| p(z)) \geq 0$ であり, この項を無視できる範囲でのみ本命題は成立する. また学習された非線形 VAE の勾配ダイナミクスは扱っておらず, 本命題の非線形設定への含意はあくまで定性的である.

A.2 命題 3（TwoNN 条件付き安定性）の証明スケッチ

bi-Lipschitz 条件より各距離の変化率は $(1 \mp \varepsilon)^2$ の範囲に収まる. TwoNN 統計量 r_2/r_1 は距離の比であるため一様スケーリングはキャンセルされ, 非等長成分 ($\varepsilon \neq 0$) のみが比を歪める. Trustworthiness $\geq 1 - \delta_T$ は 2 近傍の順位保存を高確率で保証し, 順位逆転による r_2/r_1 の大変動を確率的に抑える. 両条件下で r_2/r_1 の経験分布の変化 (EMD) は連続関数 $C(\varepsilon, \delta_T)$ で上界され, TwoNN 推定値のずれもこれに支配される ($\varepsilon = \delta_T = 0$ で $C = 0$). 有限サンプル・有限次元での近似であり, 厳密な定数は設定に依存する.

A.3 その他の解釈的命題

ブルバック計量と局所等長性: デコーダ g が局所等長であるための必要十分条件は $G(z) = J_g(z)^\top J_g(z) = I_m$ である. 条件数 $\kappa = \sigma_{\max}(J_g) / \sigma_{\min}(J_g)$ は異方性の指標であり, $\kappa = 1$ は等方性のみを意味し等長性までは保証しない. また κ は局所的な計量診断であって, TwoNN を左右する近傍順位の歪みを完全には特徴づけない. 本論文の κ は歪みの補助指標として用いる.

デコーダヤコビアンの実効階数: 十分な容量の AE が多様体 $\mathcal{M}$ を正確に再構成するとき, $J_g(z)$ の有意特異値数は $\min(m, d_{\text{emb}})$ に一致する (有限容量・最適化誤差は無視した理想化).

付録 B AU 変化点検出の探索的解析

本付録は、AU 曲線上の変化点 (knee) m^{knee} の自動検出を名前付きプロトコル出力としない判断 (§ 6.3) の根拠となる感度データをまとめる。

B.1 定義

グリッド $\mathcal{M} = \{m_1 < \dots < m_K\}$ 上の AU 増加率を $s(m_i) = [\text{AU}(m_i) - \text{AU}(m_{i-1})]/(m_i - m_{i-1})$, 正規化増加率を $\rho(m_i) = s(m_i)/\max_j s(m_j)$ とし,

$$m^{\text{knee}} = \min\{m_i \in \mathcal{M} : \rho(m_i) < \tau_{\text{knee}}\}, \quad \tau_{\text{knee}} = 0.25 \quad (6)$$

と定義する (一階差分比率法). 代替として AU(m) の離散二階差分の絶対値最大点を取る二階差分法 (d2 法) がある.

B.2 グリッド感度

理想化された単調飽和モデル (AU が $d^*(\beta)$ で段差的に飽和し, ノイズなし) では $|m^{\text{knee}}(\mathcal{M}) - d^*(\beta)| \leq \max_i(m_{i+1} - m_i)$ が成り立つ (検出誤差はグリッド最大間隔で上界される). 実際の MNIST FC-VAE ($\beta = 4$, 300 エポック, 3 シード) では経験的 AU 曲線の確率的揺らぎによりこの上界を超える変動が生じる (表 12).

表 12: Grid sensitivity of the change-point detector on MNIST FC-VAE ($\tau_{\text{knee}} = 0.25$, 3 seeds). The sparse-grid value is dominated by the grid interval; the dense grid is placed around the TwoNN estimate and is therefore a TwoNN-conditioned curve summary, not independent validation.

Condition	Max. interval	seed 42	seed 123	seed 777	Mean $\pm$ std
Sparse grid, 150 ep	32	64	32	64	53 $\pm$ 15
Sparse grid, 300 ep	32	64	32	32	43 $\pm$ 15
Dense grid, 300 ep	16 (step 1 in 8–16)	11	9	11	10.3 $\pm$ 0.9

エポック延長 (150 $\rightarrow$ 300) はほとんど効かず, 主因は収束不足ではなくグリッド設計とシードである. また, 単一シード・別グリッドの予備観察では $m^{\text{knee}} = 12$ も観測されており (Exp-Mnist-Base), グリッド・初期化への依存が明確である.

B.3 検出法・閾値の感度

密グリッドデータに対する τ 法と d2 法の比較を表 13 に示す. d2 法は遷移域の AU 揺らぎ (8 $\rightarrow$ 10 $\rightarrow$ 9 $\rightarrow$ 11 $\rightarrow$ 10 $\rightarrow$ 11 $\rightarrow$ 13 等) に敏感で, シード 123 で $m^{\text{knee}} = 28$ と大きく外れた. $\tau_{\text{knee}} = 0.25$ は本研究の作業的既定値であり, Fashion-MNIST では τ の境界感度 (τ 前後で検出値が変わる) が確認されている—— τ_{knee} に一般的な意味は主張しない.

表 13: Detector sensitivity on the dense grid (300 ep, 3 seeds).

Method	seed 42	seed 123	seed 777	Mean $\pm$ std
τ -method ($\tau = 0.25$)	11	9	11	10.3 $\pm$ 0.9
Second difference (d2)	15	28	12	18.3 $\pm$ 6.8
Reference: $\hat{d}_{\text{ID}} \approx 10$ (TwoNN, 3-seed mean)				

B.4 結論

変化点検出はグリッド・シード・検出器・閾値のすべてに感度を持ち、安定化には TwoNN 由来の探索窓という循環的条件が必要である。したがって本プロトコルでは、変化点はグリッド設計の補助 ($\hat{d}_{ID}$ 近傍を密にサンプリングする位置の目安) にとどめ、検証の判定は AU 値そのものの多シード比較で行う。探索窓推定と変化点評価を分離した nested validation は今後の課題である。

付録 C 単一シード・探索の実験

本付録の実験はすべて**単一シード (42) の探索的観察**であり、本文の主張の直接の根拠には用いていない。

C.1 Conv-VAE の高 β 誘発実験 (Exp-ConvV-HiBeta)

MNIST Conv-VAE (KL サイクリックアニーリング, 150 エポック, $m \in \{16, 32, 64, 96, 128, 192, 256\}$) で $\beta_{\max}$ を増強した結果を表 14 に示す。 $\beta_{\max} = 10$ で活性率が $m = 256$ において 36% まで低下し、変化点検出 (τ 法) は ≈ 128 を返す; $\beta_{\max} = 20$ ではさらに低次元側 (≈ 96) へ移動する。 β 増大で遮断が低次元側へ移動するというサロゲート条件の定性的予測と整合する。

表 14: Exp-ConvV-HiBeta (single seed 42, exploratory): AU of the MNIST Conv-VAE under strengthened $\beta_{\max}$ (activation rate in parentheses).

m	$\beta_{\max} = 4$	$\beta_{\max} = 10$	$\beta_{\max} = 20$
32	32 (100%)	32 (100%)	27 (84%)
64	64 (100%)	54 (84%)	42 (66%)
128	114 (89%)	69 (54%)	53 (41%)
256	241 (94%)	93 (36%)	66 (26%)




図 6: Exp-ConvV-HiBeta (single seed, exploratory): increasing $\beta_{\max}$ shifts the AU truncation to lower dimensions, consistent with the surrogate activation condition.

C.2 自然画像での AU プラットー探索 (Exp-NatImg-Sweep)

CIFAR-10 Conv-VAE で $m \in [32, 1024]$, $\beta_{\max} \in \{10, 20, 40, 80\}$, デコーダ容量 (Standard/Deep/Thin) を組み合わせたスイープでは, $\beta_{\max} = 80$ ・薄型デコーダ条件で $m \in [512, 1024]$ にわたり $AU \approx 24$ 付近の

plateau-like behavior が観測された（予備的証拠）．全条件で潜在 TwoNN は 24.7–25.4 と安定し，Pope ら [7] の報告値と整合した．シード安定性・グリッド安定性を含む安定同定は未達であり，今後の課題である．

C.3 Fashion-MNIST の VAE 予備観察（Exp-Fashion）

Fashion-MNIST VAE ($\beta = 4$, 100 エポック, 単一シード) では, AE 側で TwoNN が $m_{\text{ref}} \geq 32$ で ≈ 9.4 に収束し, AU 鈍化域が $\hat{d}_{\text{ID}} \approx 9\text{--}10$ と同一オーダーで観測された (MNIST と同傾向)．多シード再現は今後の課題である (Step 1 の多シード値は Exp-Real-Geom ; § 5.5)．

C.4 位相多様体での AU_{sat} 観察（Exp-Syn-Top）

Torus $\cdot$ Möbius Band (いずれも $d_{\text{ID}} = 2$, $d_{\text{emb}} = 3$) で $\text{AU}_{\text{sat}} = 3 = d_{\text{emb}}$, Circle S^1 ($d_{\text{emb}} = 2$) で $\text{AU}_{\text{sat}} = 2$ ($m \geq 6$, 条件付き) が観測された．Swiss Roll の AU_{sat} は前処理に依存する (標準化で 2, 別条件で 3) ため, $\text{AU}_{\text{sat}} = d_{\text{emb}}$ 対応の主証拠は Torus $\cdot$ Möbius に限定される．条件付きの付随的観察であり, 理論的必然性は主張しない．

付録 D 感度分析と実験一覧

AU 閾値 δ : $\delta \in [10^{-3}, 10^{-1}]$ の変動で AU 値はほぼ変化しない (MNIST FC-VAE, 300 エポック)．

β 感度 : 予備実験 (50 エポック, $\beta \in \{1, 2, 4, 8\}$) では, $\beta = 1$ で $\text{AU} \approx m$ (正則化不足), $\beta = 8$ で過正則化の兆候が観測され, $\beta \in [2, 8]$ で AU パターンは安定であった．本論文の既定値 $\beta = 4$ はこの安定域の中央である．

MLE の k 感度 : $k \in \{5, 10, 20\}$ で $\text{MLE} = 11.5\text{--}12.4$ (MNIST) と安定．

表 15: Experiment overview. All main-text results use 3 seeds (42, 123, 777); appendix experiments marked “single” use seed 42 only.

Experiment	Data / model	Epochs	Seeds	Section
Exp-Syn-1 / Exp-Syn-AU	Swiss Roll, Torus / AE, VAE	200–300	3	§ 5.2
Exp-Syn-Verify	Torus, Swiss Roll / VAE ($m = 3-8$)	200	5	§ 5.2
Exp-Mnist-Base	MNIST / AE (m_{ref} sweep)	300	1 (sweep)	§ 5.3
Exp-Mnist-Multi-300	MNIST / FC-VAE	300	3	§ 5.3
Exp-Mnist-Dense-300	MNIST / FC-VAE (dense grid)	300	3	§ 5.3.5
Exp-Boot-CI	MNIST / ref.-AE latents (re-analysis)	—	subsamp.	§ 5.3.2
Exp-Downstream	MNIST / AE probe, FC-VAE probe	300	1 (AE), 3 (VAE)	§ 5.4
Exp-Real-Geom	MNIST, F-MNIST / AE, IsoAE, CAE, DAE	300	3	§ 5.5
Exp-Conv-M256 / M512	MNIST / Conv-VAE	150	3	§ 5.6
Exp-Nat-Cifar / Exp-Nat-SVHN	CIFAR-10, SVHN / Conv-VAE	150	3	§ 5.6
Exp-ConvV-HiBeta	MNIST / Conv-VAE (β_{max} up)	150	single	App. 付録 C
Exp-NatImg-Sweep	CIFAR-10 / Conv-VAE	300	partial	App. 付録 C
Exp-Fashion	F-MNIST / AE, VAE	100	single	App. 付録 C
Exp-Syn-Top	Torus, Möbius, S^1 / VAE	300	single	App. 付録 C