

内在次元誘導によるボトルネック次元選定の再検証： 探索方策，品質目標，診断の限界

小幡 千佳，大井 瑞生，神野 健哉

東京都市大学 情報工学部 知能情報工学科

〒158-8557 東京都世田谷区玉堤 1-28-1

g2332016@tcu.ac.jp (C.O.), g2591402@tcu.ac.jp (M.D.)

連絡著者：kjinno@tcu.ac.jp, 電話：+81-3-5707-0104 (K.J.)

概要

潜在次元の選択は，診断情報とそれを使う探索方策の双方に依存する。4 種類の画像データセット，5 学習シード，5 正則化重みの保存済み VAE 候補に対して，6 方策を事後的に比較する。検証アンカーで品質目標を定め，単一の統一時間スナップショットで各要求に費用を付ける。従来の内在次元探索窓には構造的に冗長な処理が含まれるため，費用差だけでは次元情報の価値を識別できない。改訂した局所方策と対応する中点対照は，要求数と最小適格次元のトレードオフを示す。引き継いだ既定値では，ID を初期値とする方策は全 100 条件で全グリッド最小値に一致し，中点対照は 98 条件で一致する。ただし前者は 3 データセットで昇順 fallback を使う。係数・閾値を変えた事後的な 10,000 設定では，局所探索の 155 出力が品質を満たしながらグリッド最小値を逃す。参照モデル群の取得と再利用によって費用の解釈は変わる。新しい MNIST の 1 シード実験では Monte Carlo ELBO による選択を評価し，剪定変更実装は別の実装監査として扱う。活性ユニットによる予測は，天井に近い課題で追加の利得を確立しない。これらの結果は，次元選択法の普遍的順位ではなく，探索・品質・費用の仕様を明示する必要性を支持する。

キーワード：変分自己符号化器，潜在次元，内在次元，活性ユニット，モデル選択，再構成品質，再現性

本稿は英語版 MAKE51 の日本語版であり，節・図表・式番号は英語版に対応する。参考文献の書誌情報は原文表記を保持する。

1 はじめに

変分自己符号化器 (VAE) [1] の潜在次元数は，表現に利用できる容量を規定する。候補グリッド上で検証性能を比較して次元数を選ぶ方法は単純だが，複数のモデルの学習を要する。代替手段には，内在次元 (ID) の推定 [2, 3]，標本化した潜在表現と事後平均表現の比較 [4]，活性度の診断 [5, 6]，再構成制約や関連度事前分布を用いる剪定 [7, 8] がある。これらの指標が答える問いは異なり，幾何学的次元，座標の利用状況，再構成品質，ネットワークの幅は必ずしも一致しない。

本研究では，ID の利用が潜在次元探索の判断と学習要求をどのように変えるか，活性ユニット (AU) の診断が他の記録量に加えて予測上の価値を持つか，また，これらの測定が品質目標と読み取り設定にどう依存するかを検討する。共通の候補モデル群と固定したデータ分割のもとで探索方策を比較し，探索順序，停止規則，品質達成，品質を満たす最小グリッド次元との一致を別々に測定する。

本研究の貢献は，探索方策とその精度・費用のトレードオフの事後的比較，および個々の記録に基づ

く監査である。従来の固定探索窓方式を、ID を初期値とする局所探索、ID を使わず同じ局所規則に従う対照、昇順探索、全グリッド参照と比較する。対象は4種類の画像データセット、候補学習の5シード、5通りの正則化重みである。ID 係数と信頼性閾値の全組合せに対する感度を示し、ID 参照モデル群の取得費用と再利用時の費用を区別する。

既存の剪定実装は、主たる探索方策比較とは別の実装監査として扱う。関連度の正規化した読み取りと、範囲を限定した新たな native モデル診断により、特定の実装上の問題を検証する。いずれも原著の剪定法の再現とは位置づけない。さらに、MNIST を再学習する独立の実験で Monte Carlo ELBO による容量選択を評価する。3 節から 5 節で手順を定義し、6 節で結果を示し、7 節で推論の適用範囲を述べる。

2 関連研究

2.1 次元、再構成、潜在変数の活性

PCA[9], Isomap[10], 局所線形埋め込み [11] は低次元表現を構成する。一方、ID 推定量は標本の幾何から局所的な次元を定量化する。本研究は TwoNN と照合用の MLE を用いるが、他にも DANCo, 期待単体歪度, 測地エントロピーグラフなどがある [12–14]。推定量の制約と標本分布への依存性が、複数推定量による照合の動機となる [15, 16]。グラフ系手法は本実験の対象外であり、それらが観測された不一致を解消または再現するとは推論しない。最小全域木に基づく Isolation Forest も異常度評価にグラフの幾何を用いる [17] が、その目的は再構成目標のもとで VAE の次元数を選ぶこととは異なる。深層ネットワークの学習済み表現で ID が低下することも報告されている [18, 19]。

FONDUE[4] は、標本表現と事後平均表現の ID 推定値が乖離する直前の容量を探索する。同論文の付録では、潜在変数の型から個数を選ぶ FONDUE-VAR も示されている。AU と変数型は未使用座標への関心を共有するが、統計量としては異なる。AU はデータ間の事後平均の分散を閾値処理し、型分類器は事後分散のモーメントを用いる [6]。最終的な個数が一致しても、安定性や情報量が同等であるとは限らない。

L_0 正則化を伴う GECO は、再構成制約のもとで、KL 項とゲート数の項を持つゲート付き VAE を最適化する [7, 20]。原著は ARM を用いるが、本研究の変更実装は hard-concrete ゲートを用いる [21]。非凸最適化も本実装も、大域的な最小容量を保証しない。検証用アンカーモデルに許容幅を加える本研究の規則は、外部の品質基準を設定する一方式であり、原著の制約と同一の実装ではない。

ARD-VAE は階層的な関連度事前分布を用いる [8]。原著は正則化重みを調整し、閉形式の KL にガウス近似を用い、ヤコビアンで重み付けした分散スコアの 99% を説明する軸を選ぶ。したがって閾値を持たない方法ではない。本研究の変更実装には、有限刻み幅のデコーダスコアや選択段階の重みの固定など、さらに相違がある。詳細は付録 C.2 に示す。

2.2 先行会議論文および以前の原稿との関係

著者らの NOLTA2025 論文 [22] は、入力 ID と潜在空間容量の関係を扱った。比較に利用できる会議原稿には、4 種類の全結合構造と 2 種類の畳み込み構造、4 シードによる MNIST クラス別実験が記載されている。したがって CNN と複数シードの利用自体は、本改訂の新規事項ではない。利用した会議原稿の作業題名は公表題名と異なるため、参考文献には著者所属機関の業績記録にある題名とページを用いる。表 1 で先行研究と本比較の範囲を区別する。MAKE47 は以前の学術誌投稿稿を指し、独立

した出版物ではない。

表 1: 会議論文, 以前の学術誌投稿稿, 本改訂の対象範囲。

項目	NOLTA2025	MAKE47	本改訂
問い	入力・潜在 ID と容量	ID 誘導選択と AU 検証	選択の品質, 費用, 診断の限界
モデル	全結合 4 構造と CNN 2 構造, MNIST クラス別, 4 シード	全結合・CNN と合成・画像への拡張	画像 4 データセットの固定候補群, 候補学習 5 シード
比較対象	構造と容量の比較	容量走査と診断	FONDUE の変種, 剪定の変更実装, グリッド基準, 昇順探索
読み取り	ID 推定値	AU による運用上の検査	同一 checkpoint での型・AU 推移と対応付き予測解析
証拠	会議論文の設定	旧損失規約	損失修正後の記録, 明示的な目標, 最終 test 指標, 費用計上の限界

3 評価の枠組み

3.1 モデルと品質目標

推定用の表現を与える *ID 参照 AE*, 最大候補次元の通常 VAE である **品質アンカー**, 次元選択後に評価する通常 VAE である **選択モデル**を区別する。候補グリッドを $\mathcal{M}$, 学習シードを s , 決定論的再構成 $g(\mu(x))$ の検証データにおける画素平均 MSE を $D_s(m, \beta)$ とする。実装された目標は次式である。

$$m_a = \max \mathcal{M}, \quad T_{D,s}(\beta) = D_s(m_a, \beta) + \max\{0.10D_s(m_a, \beta), 0.001 \text{Var}(X_{\text{val}})\}. \quad (1)$$

分散は検証配列の全要素にわたって計算する。記録されたすべての画像条件で相対項が支配的であり, $T_{D,s} = 1.10D_s(m_a, \beta)$ となる。当初の設定にはシード間 SD の 3 倍の項もあったが, 実行時の目標関数にはアンカーが 1 個ずつ渡され, その項は省略された。ここでは実装された規則を報告し, シードをまとめた目標であったかのように記述しない。付録 A に, データセットと β の全組合せのアンカーと目標を示す。

シードと β を固定した探索中は, 目標も固定する。 β を変えると別のアンカーから目標を再計算する。したがって β の走査は学習表現と品質基準の双方を変えるものであり, 品質を固定した介入ではない。有効な次元数を返した手法が, この外部目標を達成するとは限らない。各最終モデルの品質達成を別に評価する。

3.2 再評価用の統一単価と過去の費用記録

探索の再評価には, 変更しない単一の候補記録スナップショットを用いる。論理キーにはデータセット, 次元数, 学習シード, 指定 epoch 数, 早期停止の有無, β が含まれる。構造, 尤度, データ分割はデータセット設定で固定する。品質アンカーを含め, 要求した一意なキーごとに, そのスナップショットの所要時間を 1 回だけ計上する。したがって異なる方策が同じキーを要求した場合, 指標も単価も同じである。これは保存記録を対応付けて利用したものであり, 独立の再学習ではない。

過去の手法別費用記録では、同じ論理キーに異なる所要時間が付いていることがある。検証・test の集計指標が完全に一致しても、過去の重みと実行識別子が欠けているため、checkpoint の同一性は証明できない。このため、新たな方策比較ではそれらの単価を混在させない。付録 B.1 に過去の費用計上を残し、補足 CSV でアンカー・最終モデルの各役割をキー、出典、利用可能な 2 種類の時間に対応付ける。各再評価での品質アンカーとその単価には同一記録を用いる。

要求候補の統一単価の合計を C_{cand} 、9 個の AE からなる参照モデル群の記録済み学習費用を C_{ref} とする。初回利用 (cold) では ID 方策に $C_{\text{cand}} + C_{\text{ref}}$ を課し、参照群が構築済みの再利用 (warm) では C_{cand} を課す。1 データセットで 5 シードと 5 重みを扱う 25 課題の一括利用では、課題当たり $C_{\text{ref}}/25$ を配分する。この配分によって、共有参照群に基づく結果が独立な ID 反復になるわけではない。いずれの費用にも、記録のない ID 計算時間や一部の学習後評価時間は含まれない。これは帰属させた学習費用の推定であり、新たに測定した一連の処理の実時間ではない。過去のプローブ評価と FONDUE の校正費用は、探索再評価の方策とは別に報告する。

3.3 出力と終了状態

各試行では、返された未変換の次元数、評価したモデルの次元数、該当する場合の ID 信頼性判定、代替探索への切替 (fallback)、記録された終了状態、予算フラグ、品質達成、最終次元がアンカーより小さいかを記録する。これらの事象は重なり得る。特に、fallback でも品質目標を満たす小容量モデルを返すことがある。旧ログの SUCCESS は通常終了を意味し、それ自体は品質目標達成の証拠ではない。

予算超過試行も、消費時間と、モデルが返されていればその次元数・指標を集計に含める。未変換の次元数が 1 未満なら退化出力として報告する。その時間と失敗件数は残すが、最終モデルが存在しないため MSE は欠測とする。元の実装は呼出しの完了後に予算を確認し、その後も最終モデルを取得し得る。したがって制限は強制中断ではなく、費用計上上のソフトな上限である。結果表ではこれらを区別する。

3.4 参照モデル群と信頼性検査

参照モデル群は 3 種類の次元数と固定した 3 参照シードを用い、5 候補シード間で共有する。参照次元 r における TwoNN 推定値の平均を $\bar{d}_r$ 、 $\hat{d} = \text{mean}_r \bar{d}_r$ 、同じ参照群にわたる MLE 推定値の平均を $\bar{d}_{\text{MLE}}$ とする。検査は次式である。

$$R = \frac{\max_r \bar{d}_r - \min_r \bar{d}_r}{\text{median}_r \bar{d}_r} \leq 0.15, \quad A = \frac{|\hat{d} - \bar{d}_{\text{MLE}}|}{\hat{d}} \leq 0.25. \quad (2)$$

$c = 2$, $R_{\text{max}} = 0.15$, $A_{\text{max}} = 0.25$ は、9 月 12–13 日の仕様に記録された内部的な経験則である。係数 2 には幾何学的な動機があるが、この統計的課題に対して導出された値ではない。信頼性の許容値も、誤棄却率に対して校正したものではない。品質許容幅の実験で正当化するのではなく、数値が果たす役割を事後解析で調べる。

3.5 事後的に定義した探索方策

以下の再評価手順は、先の結果と査読を受けて 9 月 19 日に定義した。全グリッド参照は $m^* = \min\{m \in \mathcal{M} : D_s(m, \beta) \leq T_{D,s}\}$ を返す。昇順探索はアンカーを取得した後、次元数を小さい順に調べ、最初の合格で停止する。再構成誤差の単調性を仮定せずに m^* を同定できる。従来の ID 手順は、

ID が採用されれば低次元側の探索窓をすべて評価し、採用されなければ最小 MSE を選ぶ粗い探索を行う。実行された手順全体の疑似コードを付録 C.1 に残す。

改訂した *ID-local* は、ID から網羅的な探索窓を作る代わりに、開始次元を選ぶ。開始点が合格なら小さい側へ進んで最初の不合格で止まり、不合格なら大きい側へ進んで最初の合格で止まる。多数の候補を省略できる一方、合否列が単調でない場合には、より小さな適格次元を見逃し得る。ID 参照群が棄却された場合は、従来の粗い MSE 探索ではなく昇順 Q 探索へ切り替える。この fallback の変更も、事後的に定義した方策の一部である。

アルゴリズム 1 (*ID-local* の再評価と対応する対照方策).

入力：グリッド、シード、重み、検証記録と統一単価、参照モデル群、 c , $R_{\max}$, $A_{\max}$ 。test 指標は用いない。

1. 最大次元を 1 回要求し、式 1 から目標を計算する。検証 MSE が目標以下なら合格とする。
2. *ID-local* では参照群の費用を計上し、式 2 を計算する。いずれかの閾値を満たさなければ昇順に次元を要求し、最初の合格を返す。
3. 採用された場合は $c\hat{d}$ 以上の最小グリッド次元から開始し、該当値がなければ最大次元とする。midpoint 対照では参照費用をすべて省き、0 始まりの添字 $\lfloor (|\mathcal{M}| - 1)/2 \rfloor$ から開始する。
4. 開始点が不合格なら、より大きい次元を順に要求し、最初の合格を返す。アンカーにより、適格次元が必ず返される。
5. 開始点が合格なら、隣接する小さい次元を降順に要求し、最初の不合格または最小次元への到達で止め、最後の合格を返す。
6. 最小性を確認する ID 変種では、局所探索の返却値より小さい未評価次元を昇順に調べ、最初の合格で停止する。これにより単調性なしに全グリッドでの最小性を確認する。
7. 異なる候補ごとに 1 回計上する。次元数、要求キー、候補数、参照・候補費用、ソフト予算フラグを返す。選択を固定してから test 指標を付与する。

全グリッド Q 、昇順 Q 、従来経路、*ID-local*、midpoint-local、最小性確認付き *ID-local* の 6 方策を、データセット・重み・シードの全 100 条件で再評価する。経路は保存グリッド内、最大 12 個の異なる候補で完了させる。元の時間上限は、この反実仮想的評価を中断する代わりにフラグとして記録する。従来手順の行には、元の fallback を含む実行経路と出力を残す。品質、次元差 $m - m^*$ 、完全一致、候補要求数、統一費用を報告する。midpoint-local は、ID 取得を除いた同じ局所停止規則の対照である。再評価用に固定した単純な対照であり、調整済みまたは普遍的に最適な開始点ではない。

係数集合 $\{1, 1.5, 2, 3, 4\}$ は以前の設定を引き継ぐ。事後解析の信頼性グリッドは $R_{\max} \in \{0.10, 0.15, 0.25, 0.50\}$, $A_{\max} \in \{0.15, 0.25, 0.40, 0.85, 2.00\}$ とする。厳しい設定と、観測されたデータセット判定の両側の設定を含める。最も緩い値はストレス試験であり、推奨既定値ではない。これらのパラメータと 100 記録条件の全 10,000 組合せを残し、最も良い閾値で元の既定値を置き換えることはしない。

4 理論的背景

理想的な滑らかな d 次元多様体について、Whitney の埋め込み定理は $\mathbb{R}^{2d}$ への埋め込みを与える [23]。単射の符号器を通じた厳密かつ連続な再構成には埋め込みが必要となる。しかし、雑音を含む有限標本の ID 推定や近似的なニューラル再構成が、これらの仮定を自動的に満たすわけではない。したがって係数 2 は評価対象の経験則であり、品質保証でも、測定 ID から推論した下界でもない。

線形ガウス潜在変数モデルでは、情報を持つ方向は共分散のスペクトルと雑音尺度に依存する。線形 VAE と事後崩壊の解析はこの関係を明確にしている [9, 24]。VAE と主成分方向との整合も研究されている [25]。これらは正則化が座標利用にどう影響するかを測定する動機となるが、非線形 VAE の AU

を内在次元や最小埋め込み次元と同一視するものではない。AU は潜在座標系と計数用の閾値にも依存する。

5 実験設定

5.1 データ，構造，最適化

表 2 に，実際の画像データ設定を示す。MNIST[26]，Fashion-MNIST[27]，CIFAR-10[28] では，公式の学習用・test 用データ集合から無作為に部分集合を取り出す。シード 20260912 の順列で学習用 20,000 例を選び，別のシード 20260913 の順列で 90:10 に分割する。test の 3000 例にはシード 20260914 を用いる。公式の学習・test 分割がない dSprites[29] では，737,280 画像の 1 つの順列の先頭 20,000 個と続く 3000 個を重複しないデータ集合とする。20,000 個を 90:10 に分け，各添字リストを読み込み前に整列する。画像は $[0, 1]$ にスケーリングし，データ拡張は行わない。学習シードは 42, 123, 777, 2024, 31337 であり，分割は学習シードによらず固定する。

表 2: 候補 VAE の画像データ設定。すべて 18,000 学習例，2000 検証例，3000 test 例を用いる。G：ガウス，B：ベルヌーイ。予算は記録時間の上限であり，候補学習呼出しの共通上限は 12 回。ID 参照 AE は別途加わる。

データセット	入力	尤度	候補次元数	予算 (秒)
MNIST	$1 \times 28 \times 28$	G	2, 4, 6, 8, 10, 12, 16, 20, 24, 32, 48, 64	1470
Fashion-MNIST	$1 \times 28 \times 28$	G	MNIST と同じ	1470
dSprites	$1 \times 64 \times 64$	B	MNIST と同じ	5163
CIFAR-10	$3 \times 32 \times 32$	G	8, 16, 24, 32, 48, 64, 96, 128, 192, 256	2924

MNIST と Fashion-MNIST の符号器は，幅 512 と 256 の全結合層，ReLU 活性化，平均と対数分散を別々に出力する線形ヘッドを持つ。復号器は幅 256 と 512 の層を持ち，出力は線形とする。CIFAR-10 の符号器のチャンネル数は 32, 64, 128 であり，dSprites では 256 を追加する。畳み込みはカーネル 4，ストライド 2，パディング 1，ReLU を用い， 4×4 の特徴マップの後に線形の事後分布ヘッドを置く。線形写像と ReLU，逆順の転置畳み込み，最後の sigmoid で復号器を構成する。ID 参照 AE は入力を平坦化し，幅 $512-256-r$ の全結合符号器とその逆順の復号器，線形出力を用いる。候補 CNN とは別のモデルである。

通常の候補モデルには Adam，学習率 10^{-3} ，既定のモーメント (0.9, 0.999)， $\epsilon = 10^{-8}$ ，重み減衰なし，バッチサイズ 128，最大 300 epochs を用いる。最後のバッチは 80 例であり，1 epoch 当たり 141 更新となる。ID 参照 AE には同じ最適化器とバッチサイズを用い，100 epochs 学習する。早期停止の patience は 30 とする。記録上の plateau フラグは，直近 50 個の検証監視値について $(\max h - \min h) / |\text{mean } h| < 0.01$ を要求するが，追加の停止規則ではない。代表的な学習推移を調べる実行は，常に 300 epochs を完了する。

候補モデルの学習損失を次式とする。

$$\mathcal{L}_\beta = \frac{1}{B} \sum_{i=1}^B \left[\ell(x_i, g(z_i)) + \beta \sum_{j=1}^m \frac{\mu_{ij}^2 + \exp(v_{ij}) - 1 - v_{ij}}{2} \right], \quad z_i \sim q_\phi(z | x_i), \quad (3)$$

ここで v は対数分散である。ガウス再構成には二乗誤差和を用い，これは加法定数を除けば観測分散

1/2 の固定に等しい。dSprites には二値交差エントロピーの和を用いる。主設定の重みは 1, 走査する値は $\{0.25, 0.5, 1, 2, 4\}$ で、各実行中は一定とする。周期的アニーリング [30] は用いない。尤度が異なる場合、数値上同じ β でも同じ正則化強度とは限らない。

保存された「ELBO」という名前の検証監視値は、 $h = -[\ell(x, g(\mu(x))) + \text{KL}]$ を例ごとに平均したものである。事後標本に関する期待値ではなく事後平均による再構成を使うため、これは **ELBO の代理値 (proxy)** であり、不偏な ELBO 推定値でも保証された下界でもない。学習時に別の β を用いた場合も、checkpoint 選択では KL 重みを 1 にする。本研究はこれらの checkpoint を保持し、監視値を正確に呼び分ける。選択コードに test 指標は入らない。ただし、候補キャッシュは手法による選択前に、学習した全候補の test 指標を評価するため、最終 test 評価を 1 回しか実行していないという主張は正しくない。表では検証データで選択したモデルの test 指標だけを示す。これは選択と評価のコード上の分離であり、test を事前に封印した手順ではない。

5.2 手法と読み取り

グリッド探索は、検証 MSE, ELBO proxy, または線形プローブの検証正解率で選択する。プローブは事後平均、多項ロジスティック回帰、最大 2000 反復を用い、 $C \in \{0.01, 0.1, 1, 10\}$ を検証データで選ぶ。ラベルは数字、衣服、CIFAR のクラス、および dSprites の 3 形状である。プローブによる選択では、容量とプローブ正則化の両方に検証ラベルを用いる。潜在表現の中心化、スケーリング、白色化は行わず、ロジスティック回帰には既定の切片を用いる。粗い探索はアルゴリズム A1 の部分集合を使い、固定基準には次元数 32 を用いる。

FONDUE は、TwoNN と固定した ID 差閾値 $0.2d_0$ を使う本研究の PyTorch 実装である。通常の候補グリッドの外も含む整数次元を探索し、選ばれた次元をそのまま学習する。 $\beta = 1$ での短期学習は、MNIST と dSprites で 1 epoch, Fashion-MNIST と CIFAR-10 で 2 epochs とする。dSprites では原著の epoch 設定を使う。他ではシード 42 で校正し、連続する 2 回の予測が一致するまで epoch 数を増やし、最大 5 で止める。一致判定は 1 epoch と 2 epochs の実行後に初めて行う。 $e - 1$ と e の予測が一致したら返す epoch 数は $e - 1$ であり、両方の校正費用を計上する。他の β ごとの値は付録 C に示す。FONDUE+Q は返却次元をグリッド上で上側に丸め、アンカーを取得し、品質を満たすか予算フラグが立つまで大きい側へ拡張する。これは FONDUE に外部の再構成規則を追加したものである。

FONDUE-VAR は $\text{round}(2d_0)$ から始め、定めた型条件が成立するまで次元数を倍増する。混合型を保持する設定では、非活性型が現れた時点で活性型と混合型の合計を返す。保持しない設定では、混合型または非活性型が現れた時点で活性型の個数を返す。記述に基づく分類器を実装し、対数分散から事後分散への指数変換は **1 回だけ** 行う。ある座標の事後分散について、データ間分散が 0.1 未満で平均が $[0.9, 1.1]$ なら非活性型、データ間分散が 0.1 未満で平均が 0.1 以下なら活性型、それ以外を混合型とする。監査した公開コードの版を付録 C.2 に示すが、そのコードのすべての実行経路や公表実験設定を再現したとは主張しない。

AU はこれとは独立に次式で定義する。

$$\text{AU}_\delta = \sum_{j=1}^m \mathbf{1}\{\text{Var}_{x \in X_{\text{est}}} \mu_j(x) > \delta\}, \quad \delta \in \{10^{-3}, 10^{-2}, 10^{-1}\}, \quad (4)$$

主設定は $\delta = 10^{-2}$ とする。AU, 変数型, 品質目標の下限に用いる例間分散の分母は n (母分散) であり、報告するシード間 SD の分母は $n - 1$ とする。ID と活性度の読み取りには、シード 20260915 で非

復元抽出した同じ 10,000 学習例を用いる。MLE の照合には $k = 10$ 近傍を用いる。AU は診断量であり、手法比較に追加する選択器ではない。

GECO と ARD の変更実装は、最大グリッド次元から開始して 300 epochs 実行する。未変換の座標数を最近傍の候補次元に写し、同距離なら小さい方を選んで最終的な通常 VAE を得る。付録 C.2 に、独自の目的関数、更新規則、読み取りの相違を示す。したがって評価 MSE は、次元を転用した通常 VAE のものであり、元のモデル自身の MSE ではない。

5.3 実行環境と事前仕様の範囲

保存された画像実験の環境は、Python 3.12.3, PyTorch 2.7.1+cu118, CUDA 11.8, cuDNN 90100 (9.1.0), NVIDIA driver 570.211.01, NVIDIA GeForce RTX 3070, Linux 6.8.0-124-generic, x86-64, glibc 2.39 である。これらの実験には GPU の環境記録があり、GPU 学習に加えて CPU で数値処理とプローブ評価を行う。以前の MAKE47 にも PyTorch 2.0, RTX 3070, CPU への切替は記載されていたが、CUDA・cuDNN・driver の完全な環境は示されていないかった。

設定ファイルは 2026 年 9 月 12 日に作成し、9 月 12–13 日の変更も記録した。これらは内部の仕様記録であり、公開の事前登録ではない。dSprites の尤度など、一部の変更には校正結果が反映されている。剪定法の追加と重みの全走査は 9 月 14–17 日に実行した。対応付き無作為特徴量比較と最初の費用監査は、9 月 18 日付の事後的改訂である。探索の再評価、閾値の全組合せ解析、正規化した ARD の読み取り、限定的なモデル検証は 9 月 19 日に追加した。MNIST など既に調べたデータセットを、科学的に完全に未見の条件とは呼ばない。予測解析という「評価条件」は、その予測器の適合に使わなかった条件を意味する。

記録されたコード識別子 8c2c6c28224b3450 は、共通モジュールと設定だけのハッシュであり、実験実装全体のハッシュではない。以前の学習推移記録の識別子は 99cb5eb7404ff6e7 である。新たな SHA-256 ファイル一覧で、確認したスナップショットを特定する。付録 F に、数値結果と元ファイルの対応、来歴に関する残る制約を示す。

5.4 範囲を限定した新規モデル検証

MAKE49 の学習済みモデルは、互換性のある checkpoint としては利用できない。実際の ELBO を評価するため、同じ 18,000/2000/3000 分割、構造、最適化器、300 epochs の上限、patience 30 を用い、 $\beta = 1$ 、シード 42 で独立の MNIST グリッドを学習する。これは CPU 上の 1 シード検証実験であり、5 シードの CUDA 比較を置き換えるものではない。環境は macOS 26.6.2 (arm64), Python 3.11.11, PyTorch 2.7.1, NumPy 2.3.2, CPU 4 スレッドである。この実験の時間を GPU 記録と比較しない。

各次元では事後平均 proxy が最良の checkpoint を保持し、その後、次式を評価する。

$$\hat{\mathcal{L}}_K = \frac{1}{nK} \sum_{i=1}^n \sum_{k=1}^K \log p_{\theta}(x_i | z_i^{(k)}) - \frac{1}{n} \sum_{i=1}^n \text{KL}\{q_{\phi}(z | x_i) \| p(z)\}, \quad z_i^{(k)} \sim q_{\phi}(z | x_i). \quad (5)$$

$K = 32$ 、評価シードは 20260919、 $p_{\theta}(x | z) = \mathcal{N}(g_{\theta}(z), \frac{1}{2}I)$ とする。ガウス分布の正規化定数も含める。同じ 64 次元の正規乱数を、小さな次元では切り詰めて用いる。Monte Carlo 標準誤差 (MC SE) は、32 回の標本化ごとに求めた検証平均の標本 SD を $\sqrt{32}$ で割った値であり、学習シードの不確実性ではなく評価時の雑音を表す。検証 MSE, proxy, 推定 ELBO の各基準で別々に容量を選び、選択を

ファイルに記録してから test を評価する。したがってこの ELBO 比較は、*proxy* で選ばれた *checkpoint* 群から容量を選ぶものであり、各 epoch を ELBO で選び直す比較ではない。

別途、シード 42, 300 epochs の MNIST 実行で、本研究の hard-concrete (HC) 剪定実装に記録機能を加える。目標には新しい通常 VAE の次元 64 アンカーを用いる。native モデル自身の再構成、制約、ゲート、乗数の推移を保持し、native 出力と次元転用後の出力を比較する。これは 1 条件での独自実装の挙動確認であり、ARM の再現でも、データセット横断で妥当性が確認された剪定基準でもない。新しい checkpoint はすべて保存する。

6 結果

6.1 探索の判断と統一費用

従来の MNIST 費用差は、最小適格次元が初期探索窓内にあり、 $m_0 < m_a$ で、予算による中断がない場合、構造的に次式で決まる。

$$C_{\text{window}} - C_{\text{ascending}} = C_{\text{ref}} + \sum_{m^* < m \leq m_0} C_m \geq 0. \quad (6)$$

両手順ともアンカーを評価するため、その費用は相殺される。主設定では $\hat{d} = 11.68$ から $m_0 = 24$ となる。探索窓は 2, 4, 6, 8, 10, 12, 16, 20, 24 次元を要求し、昇順探索は 6 で停止する。過去の費用記録の差は $715.4 - 182.0 = 533.4 = 205.5 + (400.7 - 72.8)$ 秒である (付録 B.1)。これはこれらの経路に関する費用計上の恒等式であり、ID 情報の価値を実証的に識別した結果ではない。

表 3 と表 4 は、停止の機会が異なる方策を、単一スナップショットの統一単価で評価する。MNIST での候補要求数は ID-local が 9, 従来の探索窓が 10, 昇順探索が 4 であり、いずれも 6 次元を返す。初回利用の統一費用はそれぞれ 636, 672, 177 秒である。単価を統一したため、これらは過去の費用記録の値とは異なる。midpoint 対照は 6 候補を要求し、費用は 279 秒である。したがって経路の短縮だけでは、ID 固有の利得を示せない。

表 3: $\beta = 1$, 5 シードでの事後的な探索再評価。Q: 目標達成; 一致: 全グリッドの最小適格次元との一致; Δm : 平均超過次元数。呼出し数にはアンカーを含む。費用はキーごとの単一の保存単価に, ID 方策では参照群全体の費用を加えた秒数であり, 新たな実時間測定ではない。dSprites はベルヌーイ, 他はガウス尤度。

方策	次元数	Q	一致	Δm	要求数	初回費用
<i>MNIST</i>						
全グリッド Q	6.0 ± 0.0	5/5	5/5	0.0	12.0	572
昇順 Q	6.0 ± 0.0	5/5	5/5	0.0	4.0	177
従来探索窓	6.0 ± 0.0	5/5	5/5	0.0	10.0	672
ID-local	6.0 ± 0.0	5/5	5/5	0.0	9.0	636
midpoint-local	6.0 ± 0.0	5/5	5/5	0.0	6.0	279
ID 最小性確認	6.0 ± 0.0	5/5	5/5	0.0	10.0	672
<i>Fashion-MNIST</i>						
全グリッド Q	4.0 ± 0.0	5/5	5/5	0.0	12.0	645
昇順 Q	4.0 ± 0.0	5/5	5/5	0.0	3.0	209
従来探索窓	6.4 ± 3.3	5/5	3/5	2.4	4.0	457
ID-local	4.0 ± 0.0	5/5	5/5	0.0	3.0	416
midpoint-local	4.0 ± 0.0	5/5	5/5	0.0	7.0	407
ID 最小性確認	4.0 ± 0.0	5/5	5/5	0.0	3.0	416

表 4: $\beta = 1$, 5 シードでの事後的な探索再評価。Q: 目標達成; 一致: 全グリッドの最小適格次元との一致; Δm : 平均超過次元数。呼出し数にはアンカーを含む。費用はキーごとの単一の保存単価に, ID 方策では参照群全体の費用を加えた秒数であり, 新たな実時間測定ではない。dSprites はベルヌーイ, 他はガウス尤度。

方策	次元数	Q	一致	Δm	要求数	初回費用
<i>dSprites</i>						
全グリッド Q	20.0 ± 4.0	5/5	5/5	0.0	12.0	2563
昇順 Q	20.0 ± 4.0	5/5	5/5	0.0	9.0	1797
従来探索窓	64.0 ± 0.0	5/5	0/5	44.0	4.0	999
ID-local	20.0 ± 4.0	5/5	5/5	0.0	9.0	2092
midpoint-local	20.0 ± 4.0	5/5	5/5	0.0	4.0	941
ID 最小性確認	20.0 ± 4.0	5/5	5/5	0.0	9.0	2092
<i>CIFAR-10</i>						
全グリッド Q	24.0 ± 0.0	5/5	5/5	0.0	10.0	428
昇順 Q	24.0 ± 0.0	5/5	5/5	0.0	4.0	157
従来探索窓	131.2 ± 113.9	5/5	0/5	107.2	4.0	499
ID-local	24.0 ± 0.0	5/5	5/5	0.0	4.0	498
midpoint-local	24.0 ± 0.0	5/5	5/5	0.0	5.0	213
ID 最小性確認	24.0 ± 0.0	5/5	5/5	0.0	4.0	498

局所探索は要求数を減らし得る。dSprites では, midpoint-local の要求数は昇順探索の 9 に対して 4 であり, 統一費用は 1797 秒に対して 941 秒で, 主設定の各シードで同じ適格次元を返す。このデータでは ID が棄却されるため, ID-local は昇順探索を行ったうえで参照群の費用も負担する。データセッ

ト・重み・シードの全 100 条件では、ID-local とその最小性確認付き変種は全 100 条件で全グリッド最小値と一致する。midpoint-local は 98 条件で一致し、最大超過次元数は 8 である。これら新方策の出力はすべて検証目標を満たし、再評価で元のソフト費用上限を超えるものはない。これは既に学習したグリッドに条件付けた観測であり、新たなデータへの保証ではない。

6.2 係数、信頼性、再利用に対する感度

MNIST の主設定では、 c を 1 から 4 に変えても選択次元は 6 のままだが、ID-local の要求数は 6 から 11 へ、初回費用は 487 秒から 743 秒へ変わる。元の信頼性閾値では、他の 3 データセットはどの係数でも同じ昇順 fallback を用いる。したがってその不変性は、ID 係数が頑健である証拠にはならない。

$c = 2$ で $A_{\max}$ を 0.40 まで緩めると Fashion-MNIST で ID を採用し、主設定の要求数が 3 から 10 へ増えるが、選択次元は改善しない。0.85 では CIFAR-10 でも ID を採用する。dSprites の採用にはさらに、 $R_{\max} = 0.50$, $A_{\max} = 2.00$ という緩いストレス設定が必要となる。このように閾値は、ID が実際に判断へ関与するデータセットを変える。表 A4 と表 A5 に主設定の全係数結果と代表的な信頼性の対比を示し、補足資料には全組合せの各行を含める。

感度解析の全 10,000 行で品質は満たされるが、155 出力は全グリッド最小値を逃し、最大超過次元数は 56 である。見逃しはすべて $\beta = 1$ 以外で生じる。1 設定で見かけ上単調であっても、局所停止の最小性を保証できない理由がここにある。各行は記録と参照群を再利用しており、10,000 は再評価設定の数であって独立した実験反復数ではない。表 5 で、初回利用、構築済み参照群の再利用、25 課題で参照群の 1 回分の構築費を共有する利用を区別する。

表 5: 5 重みと 5 候補シード (各データセット 25 課題) にわたる ID-local の費用。初回利用は毎回参照群を計上し、再利用は構築済み参照群を前提とする。一括利用は 1 回の参照群学習費用を 25 課題に配分する。いずれも記録のない ID・評価の処理時間を除く。非単調は、次元増加に伴い合格から不合格へ変わる合否列の件数。

データセット	参照群 (秒)	初回 (秒)	再利用 (秒)	一括 (秒)	一致	非単調
MNIST	207.5	705.2	497.7	506.0	25/25	1/25
Fashion-MNIST	207.1	352.9	145.8	154.1	25/25	2/25
dSprites	295.8	2127.2	1831.4	1843.3	25/25	13/25
CIFAR-10	340.5	507.2	166.7	180.3	25/25	4/25

6.3 記録された選択器の品質

表 6 と表 7 には、 $\beta = 1$ での通常の実験の結果を残し、5 学習シードの標本 SD を示す。モデル次元数、検証・test 誤差、目標達成を報告し、時間記録は新たな再評価の統一単価と分ける。既存の ARD・GECO 行はこの主比較から除き、元の結果と追加確認を付録 C.2 の実装監査にまとめる。

表 6: $\beta = 1$ での次元選択（ガウス尤度）。値は 5 候補学習シードの平均 $\pm$ 標本 SD。 m_{final} は評価した通常 VAE の次元数。MSE は 10^3 倍し、 Q は検証目標の達成数。過去の時間記録は付録 B.1 に分け、再評価費用には単一の統一スナップショットを用いる。

手法	m_{final}	検証 MSE	test MSE	Q
<i>MNIST</i>				
グリッド (MSE)	12.8 ± 6.4	20.98 ± 0.24	20.50 ± 0.26	5/5
FONDUE	7.0 ± 0.0	21.93 ± 0.77	21.54 ± 0.78	5/5
FONDUE + Q	8.0 ± 0.0	21.72 ± 0.50	21.33 ± 0.55	5/5
昇順 +Q	6.0 ± 0.0	22.44 ± 0.15	22.05 ± 0.17	5/5
従来 ID 探索窓	6.0 ± 0.0	22.44 ± 0.15	22.05 ± 0.17	5/5
<i>Fashion-MNIST</i>				
グリッド (MSE)	22.8 ± 15.6	18.33 ± 0.20	18.08 ± 0.19	5/5
FONDUE	6.8 ± 0.4	19.29 ± 0.16	19.01 ± 0.16	5/5
FONDUE + Q	7.6 ± 0.9	19.00 ± 0.33	18.75 ± 0.34	5/5
昇順 +Q	4.0 ± 0.0	19.38 ± 0.24	19.06 ± 0.25	5/5
従来 ID 探索窓	6.4 ± 3.3	19.03 ± 0.61	18.73 ± 0.57	5/5

表 7: $\beta = 1$ での次元選択（dSprites はベルヌーイ、CIFAR-10 はガウス尤度）。値は 5 候補学習シードの平均 $\pm$ 標本 SD。 m_{final} は評価した通常 VAE の次元数。MSE は 10^3 倍し、 Q は検証目標の達成数。過去の時間記録は付録 B.1 に分け、再評価費用には単一の統一スナップショットを用いる。

手法	m_{final}	検証 MSE	test MSE	Q
<i>dSprites</i>				
グリッド (MSE)	57.6 ± 14.3	1.16 ± 0.01	1.15 ± 0.01	5/5
FONDUE	4.2 ± 0.4	5.50 ± 1.31	5.42 ± 1.28	0/5
FONDUE + Q	20.0 ± 4.0	1.26 ± 0.05	1.24 ± 0.05	5/5
昇順 +Q	20.0 ± 4.0	1.26 ± 0.05	1.24 ± 0.05	5/5
従来 ID 探索窓	64.0 ± 0.0	1.17 ± 0.02	1.16 ± 0.03	5/5
<i>CIFAR-10</i>				
グリッド (MSE)	140.8 ± 53.5	13.83 ± 0.04	14.07 ± 0.04	5/5
FONDUE	14.4 ± 0.5	17.79 ± 0.30	18.10 ± 0.30	0/5
FONDUE + Q	24.0 ± 0.0	15.12 ± 0.14	15.36 ± 0.13	5/5
昇順 +Q	24.0 ± 0.0	15.12 ± 0.14	15.36 ± 0.13	5/5
従来 ID 探索窓	131.2 ± 113.9	14.01 ± 0.13	14.25 ± 0.14	5/5

通常の FONDUE は dSprites で約 4 次元を返すが、検証 MSE は 0.00550 であり、昇順探索の 0.00126 より大きい。通常終了は品質達成を意味しない。FONDUE+Q には、予算を超過してもモデルを返した dSprites の 1 試行があり、そのモデルも集計に残す。独立に数えた各状態の件数は付録 A.1 に示す。Fashion-MNIST, dSprites, CIFAR-10 の従来 ID 行は粗い MSE 探索へ切り替えたものであり、CIFAR-10 の大きな次元変動はその fallback に由来する。ここで自然カラー画像のベンチマークは CIFAR-10 だけである。

6.4 ID の表現依存性と標本数依存性

表 8 に Fashion-MNIST を含む参照群の完全な要約を示す。両方の検査を通過するのは MNIST だけである。同一の参照群を再利用するため、同じ合否が 5 回現れても ID 推定の独立な 5 反復ではない。

表 8: ID 参照 AE の次元数と TwoNN 推定値 (3 参照シードの平均 $\pm$ SD), 安定性 R , 推定量の不一致 A 。上限は $R \leq 0.15$, $A \leq 0.25$ 。同じ参照群を候補シードと β をまたいで再利用する。

データセット	次元数：推定値	R	A
MNIST	55: 10.93 ± 0.08 ; 111: 11.78 ± 0.12 ; 221: 12.32 ± 0.09	0.118	0.150
Fashion-MNIST	49: 9.91 ± 0.06 ; 98: 10.45 ± 0.04 ; 197: 10.83 ± 0.05	0.088	0.361
dSprites	30: 3.96 ± 0.48 ; 61: 3.91 ± 1.12 ; 122: 2.10 ± 0.02	0.474	1.816
CIFAR-10	81: 13.60 ± 0.09 ; 162: 13.44 ± 0.71 ; 325: 12.34 ± 0.50	0.094	0.834

図 1 に、標本数解析と PCA 解析を分けて示す。生入力 1000 例では、両推定量は 4 データセットすべてで相対許容値 0.25 以内に一致するが、10,000 例では MNIST だけが一致する。これは生入力の検査であり、選択器が使う AE 潜在表現の検査とは別である。dSprites ではこの診断の入力 TwoNN は 7.70, PCA 後の推定値は 2.68–4.32, 個々の AE 推定値は 2.08–4.56 である。全体の最大・最小比は約 3.7 倍であり、MNIST の対応する比は約 1.7 倍である。これらは表現に依存する推定値であり、既知の真値に対する競合測定ではない。




図 1: 左：推定標本数を変えた生入力の $|d_{\text{TwoNN}} - d_{\text{MLE}}|/d_{\text{TwoNN}}$ 。破線は 0.25。右：PCA 前処理後の TwoNN。PCA 次元、標本数、表現は別の介入であり、AE 結果は表 8 に示す。

6.5 正則化と品質条件への依存

手法 a , データセット d について報告する変動幅を次式で定義する。

$$S_{a,d} = \max_{\beta \in \mathcal{B}} \bar{m}_{a,d}(\beta) - \min_{\beta \in \mathcal{B}} \bar{m}_{a,d}(\beta), \quad \bar{m}_{a,d}(\beta) = \frac{1}{5} \sum_{s=1}^5 m_{a,d,s}(\beta), \quad \mathcal{B} = \{0.25, 0.5, 1, 2, 4\}. \quad (7)$$

これは返された未変換の次元数をシード間で平均した値の範囲であり、シード内の変動幅を平均した値ではない。FONDUE-VAR の行では、未変換のゼロを含め、各設定で 5 個すべての出力が定義される。検討した重み列に対する記述的な範囲であり、新たなパラメータ不要の頑健性指標ではない。

表 9: $\beta \in \{0.25, 0.5, 1, 2, 4\}$ にわたる, 返却次元数のシード平均の範囲。剪定変更実装は実装監査に限定する。固定 32 は設計上の定数であり, fallback の変動幅は ID の頑健性ではない。dSprites はベルヌーイ, 他はガウス尤度。

手法	MNIST	Fashion	dSprites	CIFAR-10
グリッド (MSE)	14.8	20.8	40.0	91.2
粗い探索	33.6	37.2	0.0	214.4
固定 32	0.0	0.0	0.0	0.0
FONDUE	3.8	0.8	0.8	8.8
FONDUE-VAR (混合型保持)	50.6	63.0	106.2	68.8
昇順 +Q	6.0	3.6	15.2	52.8
FONDUE + Q	3.6	1.6	28.0	44.8
従来 ID 探索窓	6.0	37.2	0.0	214.4

変動幅は手法とデータセットで異なり, 大小関係は明確に逆転する。例えば, 昇順探索と FONDUE+Q の変動幅は MNIST で 6.0 と 3.6, dSprites では 15.2 と 28.0 である。従来 ID 探索窓の CIFAR-10 での 214.4 という変動幅は fallback に由来する。固定次元は設計上変動幅がゼロであり, dSprites の ID fallback も粗い探索が常に 64 を返すため変動幅がゼロになる。どちらも選択の有用な頑健性を示さない。尺度が異なるグリッド間で変動幅を平均せず, 別条件へ移せる順位も主張しない。

ARD の呼出しでは選択段階の重みを変えておらず, GECO では β そのものではなくアンカー由来の制約を変えている。両者は実装監査の対象であり, 図 2 の通常 VAE の正則化比較には含めない。

AU 閾値への介入は checkpoint を固定して式 (4) を再計算する。一方, 品質許容幅への介入は, 保存モデルのうちどれが目標を満たすかを変える。いずれも学習時の β を変えることとは異なる。これらの読み取り・品質解析は別に報告する (6.7 節, 付録 C.3)。未検討の FONDUE 停止閾値や ARD 累積関連度比率について, 感度の主張は行わない。

6.6 学習曲線, test 評価, 選択基準

図 3 は, 主設定で昇順 Q により選ばれた, 実際に早期停止した候補キャッシュの記録を用い, MNIST の 6 次元と CIFAR-10 を含む。各実行は記録された epoch までを示し, proxy で選んだ checkpoint に印を付ける。これらのキャッシュには検証曲線だけがあり, epoch ごとの学習曲線はない。欠けた学習測定値は補完しない。別途行った新しい MNIST 実行で, 6 次元の対応する学習・検証曲線を示す (付録 E)。

保存された学習推移実験には, MNIST の 12, 32, 64 次元と dSprites の 6, 16, 32 次元について, 各 5 シードの学習・検証曲線がある (図 4)。学習 MSE は, シード 20260919 で抽出した固定 2000 学習例の部分集合上で, 決定論的モードにより評価する。学習・検証の双方が改善するが, 検証誤差の方が高い。これら 30 実行のどれも, 最終 50 epochs の厳しい plateau 判定を満たさない。300 epochs の完了は収束の証明ではない。この曲線は代表的な設定を対象とし, 4 データセットすべてを網羅しない。




図 2: 5 条件で返された未変換次元数。5 候補シードの平均 $\pm$ SD。dSprites はベルヌーイ、他はガウス尤度。これらの通常 VAE 選択器では学習時の β を変える。従来 ID 探索窓は、重み列全体で Fashion-MNIST, dSprites, CIFAR-10 に fallback を用いる。

表 10: $\beta = 1$, 5 シードでの選択基準比較。test MSE は 10^3 倍、プローブ test 正解率は %。プローブはクラスラベル (dSprites では形状) を使い、容量選択にも使うのはグリッド (プローブ) だけである。時間はアンカー補完を含む過去の記録であり、再評価の統一単価ではない。記録済みプローブ時間はその選択器に課す。他の表示プローブ正解率は補助評価であり、費用は加算していない。尤度は表 2 による。

データセット	基準	m	test MSE	正解率	時間 (秒)
MNIST	グリッド (MSE)	12.8 ± 6.4	20.50 ± 0.26	89.4 ± 0.9	628 ± 35
MNIST	グリッド (ELBO proxy)	10.0 ± 2.0	20.54 ± 0.25	89.3 ± 0.7	628 ± 35
MNIST	グリッド (プローブ)	51.2 ± 13.4	23.01 ± 0.55	92.7 ± 0.5	696 ± 36
Fashion-MNIST	グリッド (MSE)	22.8 ± 15.6	18.08 ± 0.19	75.5 ± 2.6	645 ± 42
Fashion-MNIST	グリッド (ELBO proxy)	15.6 ± 8.0	18.12 ± 0.27	74.4 ± 2.6	645 ± 42
Fashion-MNIST	グリッド (プローブ)	57.6 ± 8.8	18.99 ± 0.46	78.4 ± 0.6	750 ± 40
dSprites	グリッド (MSE)	57.6 ± 14.3	1.15 ± 0.01	47.7 ± 2.3	2565 ± 82
dSprites	グリッド (ELBO proxy)	57.6 ± 14.3	1.15 ± 0.01	47.7 ± 2.3	2565 ± 82
dSprites	グリッド (プローブ)	64.0 ± 0.0	1.16 ± 0.03	49.8 ± 3.0	2589 ± 84
CIFAR-10	グリッド (MSE)	140.8 ± 53.5	14.07 ± 0.04	44.3 ± 2.6	428 ± 16
CIFAR-10	グリッド (ELBO proxy)	192.0 ± 45.3	14.11 ± 0.08	46.1 ± 1.1	428 ± 16
CIFAR-10	グリッド (プローブ)	256.0 ± 0.0	14.30 ± 0.12	47.3 ± 1.0	574 ± 15

表 10 に、以前は示していなかった MSE, ELBO proxy, 線形プローブによるグリッド選択を示す。




図 3: 実際に選ばれた候補の検証 MSE。 $\beta = 1$, 5 シード, dSprites はベルヌーイ, 他はガウス尤度。次元は昇順 Q で選び, 黒い十字は proxy 選択 epoch を示す。曲線は記録上の停止時点で終わる。図 4 の固定 300 epochs の診断実行とは異なる。

目的が違えば, 選択次元と再構成誤差も異なり得る。プローブの test 正解率は補助的な教師ありの結果であり, 教師なしの再構成品質を測るものではない。この比較は同じ分割と保存候補を用い, ラベル付き検証データによる選択を明記している。

表 11 の独立した新しい MNIST 比較では, 5.4 節の固定 Monte Carlo 手順で, 実際に対数尤度の期待値を評価する。保存 MSE と KL から復元した値ではない。検証 MSE は 12 次元, proxy は 12 次元, Monte Carlo ELBO も 12 次元を選ぶ。この実行での一致は, proxy が ELBO 推定量であることを意味しない。全グリッドのスコア, MC 誤差, 選択 epoch を付録 E に示す。新たな学習の 1 シードだけでは, どの基準についてもデータセット全体での優位性は確立できない。

表 11: 新しい MNIST のシード 42 による容量選択。 $\beta = 1$, ガウス分散 $1/2$ 。すべての基準が同じ 12 個の proxy 選択 checkpoint から選ぶ。MSE は 10^3 倍, ELBO は例当たりの平均 nats。 $\pm$ は Monte Carlo SE ($K = 32$) であり, 学習シード間 SD ではない。検証データによる選択を固定してから test を評価する。

基準	次元数	検証 MSE	test MSE	MC ELBO $\pm$ MC SE
MSE	12	20.98	20.43	-478.067 ± 0.012
ELBO proxy	12	20.98	20.43	-478.067 ± 0.012
MC ELBO	12	20.98	20.43	-478.067 ± 0.012




図 4: 学習・検証 MSE。5 シードの平均と ± 1 SD 帯を示す。MNIST はガウス, dSprites はベルヌーイ尤度, $\beta = 1$ 。黒い十字は各実行の検証 ELBO proxy で選んだ checkpoint。この診断実行には早期停止を用いない。

6.7 活性度の読み取り：推移、閾値、予測

図 5 と表 12 は、同一 checkpoint で 2 種類の個数を比較する。MNIST の 64 次元では、epoch 5 の変数型による個数は 9.8 ± 3.8 , AU は 49.4 ± 8.1 であるが、epoch 300 ではいずれも 6.4 ± 0.5 となる。この例では、平均の一致とシード間の変動を区別できる。表には epoch 50 から 300 までの同一実行内の变化も示す。変化の大きさは条件に依存するため、最終値の一致から一般的な安定性の優位を推論しない。

表 12: 変数型の個数 V (活性型と混合型の和) と AU 数 A 。5 シード, $\beta = 1$, MNIST はガウス, dSprites はベルヌーイ尤度。平均 $\pm$ SD はシード間変動を表す。最終列は V/A について epoch 50 から 300 までの実行内絶対変化の平均であり, 時間方向の分散ではない。

データセット	m	V_5	A_5	V_{300}	A_{300}	変化
MNIST	12	7.2 ± 0.8	8.0 ± 1.6	6.4 ± 0.5	6.4 ± 0.5	0.0/0.0
MNIST	32	8.2 ± 1.5	20.8 ± 4.2	6.0 ± 0.0	6.0 ± 0.0	0.0/0.0
MNIST	64	9.8 ± 3.8	49.4 ± 8.1	6.4 ± 0.5	6.4 ± 0.5	0.4/2.6
dSprites	6	6.0 ± 0.0	6.0 ± 0.0	6.0 ± 0.0	6.0 ± 0.0	0.0/0.0
dSprites	16	16.0 ± 0.0	16.0 ± 0.0	14.2 ± 0.4	13.4 ± 0.5	1.8/1.8
dSprites	32	32.0 ± 0.0	31.8 ± 0.4	14.2 ± 1.1	14.4 ± 1.1	12.4/4.2




図 5: epoch 1, 2, 5, 50, 300 の同一 checkpoint から得た変数型の個数 (活性型と混合型の和) と AU。平均とシード SD を示し, 線は観測された checkpoint 間だけを結ぶ。 $\beta = 1$, MNIST はガウス, dSprites はベルヌーイ尤度。全容量に等しい個数が一定でも, 診断の安定性の証拠にはならない。

図6の閾値だけを変える比較では、 $\beta = 1$ のcheckpointを固定する。CIFAR-10では、 $\delta = 0.001$ は検討したすべてのグリッド次元で全座標を数えるが、 $\delta = 0.1$ は大きな容量で数える座標がはるかに少ない。したがって「未使用座標がない」という推論はこの閾値に依存する。閾値の正規化は診断の定義を変えるものであり、次元推定を確立するものではない。




図6: 同じ $\beta = 1$ 候補に対する3閾値でのAU。平均 $\pm$ シードSD。dSpritesはベルヌーイ、他はガウス尤度。対角線は容量である。これは読み取り閾値への介入であり、図2の学習・条件への介入とは異なる。

予測課題は、1つ小さいグリッド候補が、同じシードの品質目標を満たすかを判定することである。各行は、最小グリッド次元以外の容量で検証データにより選ばれた1個のcheckpointである。基準特徴量は、検証MSE, KL, ELBO proxy, 次元数, 次元数と入力IDの比, 直近20記録epochsの検証MSEの傾きである。追加する3つのAU特徴量は、AU, AU/次元数, AU/入力IDとする。標準化は開発用の行だけで適合する。 L_2 ロジスティック予測器をMNISTの55行に適合し、開発データを3シードと2シードに分けて $C = 10$ を選ぶ。評価はdSpritesの55行, Fashion-MNISTの55行, CIFAR-10の45行で行い、各5シードを用いる。設定されていたMNIST-CNNの予測条件は実行していない。

開発用分割ではシード42, 123, 777で内部適合を行い、2024, 31337で C を選んだ後、5シードすべてで再適合する。予測器の最大反復数は5000とする。各評価データセット・シードのブロックは、そのシードの最小次元を除く全グリッド次元で採点する。checkpointの各行を独立な観測として再標本化しない。

当初の内部仕様に基づく解析では、AUを追加した予測器と基準予測器のAUROC差は+0.108であ

り、シード記録を用いた 2000 回の bootstrap の 95% 区間は $[+0.059, +0.157]$ と報告されていた。後から追加した対照は、独立な 3 個の標準正規特徴量と 1 つの雑音実現（生成器シード 7）を用い、その改善量は別に $+0.098$ 、区間は $[-0.025, +0.227]$ と報告された。これらの区間の重なりは、両者の差の検定でも同等性の証明でもない。これらの保存値は元の解析の記録として残すが、妥当性が確認された正の所見とは扱わない。その AUROC 計算は、データセット間の分布変化により数値的に飽和し得る確率値を用いていた。

表 13: $\beta = 1$ の対応付き AU 事後比較。飽和確率の同順位を避けるためロジスティック決定スコアを用いる。各値は、各シードの最小次元を除く全容量で評価した AUROC を 5 シードで平均したもの。無作為特徴量は生成器シード 7 の標準正規乱数 3 列。全手法が同じ行とラベルを用いる。

評価条件	行数	基準	基準 + AU	基準 + 無作為	AU - 無作為
dSprites	55	0.950	0.858	0.898	-0.041
Fashion-MNIST	55	0.980	1.000	0.880	+0.120
CIFAR-10	45	1.000	1.000	1.000	+0.000

基準 AUROC は既に、dSprites で 0.950、Fashion-MNIST で 0.980、CIFAR-10 で 1.000 である。特に CIFAR-10 には AUROC を上げる余地がない。この結果は、特定の天井に近い予測課題での追加価値に関するものであり、AU 一般の情報量を論じるものではない。

本改訂では $\beta = 1$ を明示的に固定し、対象行を宣言されたグリッドに限定して両予測器を再構成し、ロジスティック回帰の決定スコアから AUROC を計算する。元のキャッシュ読出し処理には β のフィルタもグリッドの制限もなく、キャッシュ拡張後に再実行すると対象行も曖昧になる。決定スコアは、sigmoid 確率がちょうど 1 へ丸められると失われる順位を保持する。飽和件数は付録 C.3 に示す。これは修正した事後解析であり、保存されていた確率の厳密な再現ではない。AU 追加から基準を引いた差は -0.024 、区間は $[-0.102, +0.027]$ となる。AU 予測器と無作為特徴量予測器も、同じデータセット・シードのブロックで比較する。対応差の平均は $+0.026$ であり、事後的な階層 bootstrap の 95% 区間は $[-0.040, +0.133]$ である（2000 反復）。各反復では、3 評価データセットを再標本化し、選ばれたデータセット内で 5 シードブロックを再標本化する。ブロック内の全容量と両予測器の対応は保持する。モデルは固定するため、この区間は開発モデルの適合に関する不確実性を含まない。評価データセットは 3 つしかなく、条件をまたぐ推論の精度は限られる。補助解析では 100 個の雑音実現（シード 0-99）で対照を平均し、同じ再標本化で対応差 -0.007 、区間 $[-0.064, +0.039]$ を得た。どちらの解析も、これらの評価条件で AU 固有の利得を確立しない。AU に情報がなく、両予測器が同等である、あるいは有意差がないことが検出力不足を証明する、とは主張しない。

6.8 実装監査と退化出力

独自実装で 2 件の尺度不整合が見つかった。第 1 に、以前の VAE 損失は潜在次元について KL を平均する一方、再構成は入力次元について和を取っていた。代数的には $\beta_{\text{effective}} = \beta_{\text{nominal}}/m$ となる。本論文の画像結果は、潜在次元について和を取るよう修正した規約から得たものである。この代数的関係は、 β の名前を変えるだけで最適化過程全体や AU 数が再現されることを意味しない。以前の「1.7 ユニット以内」という主張は用いない。

第 2 に、途中段階の GECO 変更実装は、画素平均の制約値を、尺度が整合しない他の項と組み合わせていた。修正した実装は二乗誤差和を用い、画素平均の目標に入力次元数を掛ける。目的関数、目標、

乗数の尺度が整合していれば、和の規約も平均の規約も成立し得る。この hard-concrete 変更実装で観測した挙動を、原著の ARM 実装に帰属させない。

FONDUE-VAR の活性型のみを残す設定がゼロを返すことは、別の現象であり、3 件目の和・平均の欠陥ではない。MNIST の 1 epoch 設定では 5 試行すべてがゼロを返し、最終 VAE は存在しない。表 14 に両設定と品質・有効モデルの件数を示す。

表 14: $\beta = 1$ の FONDUE-VAR。混合型保持の両設定、有効モデル数、品質達成数、test MSE (10^3 倍)、記録学習時間。未変換のゼロ出力も次元集計に残すが、モデルが存在しない場合に MSE はない。5 シード、尤度は表 2 による。

データセット	混合型保持	未変換 m	有効	Q	test MSE	時間 (秒)
MNIST	はい	9.8 ± 8.5	5/5	5/5	22.53 ± 0.89	113 ± 22
MNIST	いいえ	0.0 ± 0.0	0/5	0/5	—	63 ± 10
Fashion-MNIST	はい	14.4 ± 3.8	5/5	5/5	18.96 ± 0.39	91 ± 11
Fashion-MNIST	いいえ	2.0 ± 0.0	5/5	0/5	25.27 ± 0.06	120 ± 18
dSprites	はい	26.0 ± 49.5	4/5	1/5	9.53 ± 9.62	412 ± 118
dSprites	いいえ	1.2 ± 1.6	2/5	0/5	7.71 ± 0.02	278 ± 49
CIFAR-10	はい	34.2 ± 1.3	5/5	5/5	14.40 ± 0.15	103 ± 13
CIFAR-10	いいえ	3.2 ± 0.8	5/5	0/5	31.65 ± 2.68	96 ± 13

7 考察

探索設計により、費用比較で識別できるものが変わる。低次元側の ID 探索窓をすべて調べる手順には、昇順探索に十分な処理が既に含まれる。その高い費用の大部分は設計で決まる。新たな再評価は、候補要求を減らすことと、品質を満たす最小次元を確認することのトレードオフを示す。ID を使わない局所対照も要求数を減らせる。したがって、全グリッド探索からの削減をすべて ID 情報の効果とはみなさない。

ID-local は、引き継いだ既定値では記録された重み列全体でグリッド最小値と一致するが、3 データセットでは fallback に依存する。全組合せ解析では、信頼性閾値による判断の変化と、別設定での非最小出力の双方が現れる。参照群の共有、単一の分割、事後的な方策設計、少数のデータセットという条件が一般化を制約する。取得費用と再利用費用は異なる利用上の問いに答えるものであり、1 つの普遍的な順位にまとめられない。

正則化に対する変動幅と AU 閾値への応答は別の測定である。大きな次元変動の一部は fallback、グリッド尺度、変化する品質目標を反映する。一定の出力も、設計や変更されない実装引数によって固定されている場合がある。したがって証拠が支持するのは、手法・データセットに依存する応答であり、普遍的な頑健性順位ではない。保存されていた AU 対基準の正の結果は、丸められた確率ではなくロジスティック決定スコアの順位を保持すると維持されない。修正した予測比較は、対応する無作為特徴量対照に対する AU 固有の優位性を確立しない。

剪定の証拠は主比較から外して扱う。保存された ARD 摂動を正規化すると特定できた 1 つの読み取り誤りは修正されるが、事前分布の更新手順が妥当になるわけでも、無限小のヤコビアンが復元されるわけでもない。native HC の推移は新しい 1 件の実装診断であり、広範な原著手法の妥当性確認ではない。新しい MC ELBO 比較も、MNIST の 1 シードと proxy 選択 checkpoint に限られ、4 データセット・5 シードの ELBO 研究を完了するものではない。ARM および原著 ARD の厳密な再現、独立した

参照群による反復、欠けている自然画像の学習曲線、一連の処理全体の計時は未解決である。本研究の貢献は、明示した探索方策と診断上の仮定の再現可能な比較であり、確立された剪定法の決定的な順位付けではない。

付録 D の合成実験は、尺度依存性と、低分散座標をゼロにした影響を例示する。個数は特定の損失と座標系のもとでの観測であり、位相から活性軸の数が予測できることを示さない。また、その前処理のため、これらを適切に分離されたデータに対する汎化性能の推定とは扱えない。

8 結論

潜在次元探索の判断を、診断の読み取りと実装の履歴から分けた。従来の固定探索窓の費用差だけでは、ID 情報の価値は検証できない。事後的な局所探索と対応対照の再評価により、候補削減、参照取得費用、全グリッド最小値からの差を定量化した。信頼性閾値は ID を利用するデータセットを変え、一部の局所方策はより小さい適格次元を見逃す。対応付き AU 解析は、天井に近い予測課題で AU 固有の利得を確立しない。範囲を限定した新しい ELBO 実験と関連度の修正監査は測定の妥当性を改善するが、原著手法の検証はなお未完了である。効率的な容量選択の主張には、明示的な探索規則、品質目標、費用の単位、実装の証拠が必要である。

■**著者の貢献** 構想：C.O., M.D., K.J.; 方法論：C.O., K.J.; ソフトウェア：C.O., M.D.; 検証：C.O., M.D., K.J.; 形式的解析：C.O., K.J.; 調査：C.O., M.D., K.J.; 初稿執筆：C.O., K.J.; 原稿のレビューと編集：C.O., M.D., K.J.; 研究指導とプロジェクト管理：K.J.

■**研究資金** 本研究は、JSPS 科研費 JP24K15115 および JP26K14984、東京都市大学重点推進研究「知的技術最適化研究ユニット：ORBIT」、東北大学電気通信研究所共同プロジェクト研究、電気通信普及財団（TAF）の研究助成を受けた。

■**倫理審査** 該当しない。

■**インフォームド・コンセント** 該当しない。

■**データの利用可能性** 画像データセットは引用した出典で公開されている。同梱の査読用補足資料 MAKE51_reproducibility.zip には、設定、元の結果記録、再評価表、解析コード、依存関係、分割添字、新しい MNIST checkpoint, SHA-256 一覧を含める。展開後は README.md に従うこと。付録 F に内容の対応を示す。過去の MAKE49 checkpoint は利用できない。このアーカイブは本改訂に添付するものであり、公開寄託されたデータセットとは呼ばず、アーカイブ DOI もない。

■**謝辞** 以前の原稿作成では、実験コードの草案・リファクタリングと英文編集に生成 AI の支援を用いた。本改訂の記録監査、再集計、追加モデル検証、図の作成、原稿改訂には OpenAI Codex の支援を用いた。科学的内容の責任は著者らにある。

■**利益相反** 著者らに利益相反はない。

A 品質目標と結果の計上

表 A1: 品質アンカーと目標。MSE の単位は 10^{-3} ，5 シードの平均 $\pm$ SD。各判定は表示平均ではなく，そのシード固有の目標を用いる。相対許容幅は 10% で，絶対下限は有効にならない。dSprites はベルヌーイ，他はガウス尤度。

データセット	β	アンカー MSE	目標 $T_{D,s}$
MNIST	0.25	15.843 $\pm$ 0.562	17.428 $\pm$ 0.618
MNIST	0.5	19.202 $\pm$ 0.497	21.122 $\pm$ 0.546
MNIST	1	23.712 $\pm$ 0.532	26.084 $\pm$ 0.585
MNIST	2	30.061 $\pm$ 0.560	33.068 $\pm$ 0.617
MNIST	4	38.977 $\pm$ 0.673	42.875 $\pm$ 0.740
Fashion-MNIST	0.25	15.591 $\pm$ 0.678	17.150 $\pm$ 0.746
Fashion-MNIST	0.5	17.408 $\pm$ 0.513	19.148 $\pm$ 0.564
Fashion-MNIST	1	19.679 $\pm$ 0.162	21.647 $\pm$ 0.179
Fashion-MNIST	2	22.416 $\pm$ 0.527	24.658 $\pm$ 0.580
Fashion-MNIST	4	25.967 $\pm$ 0.587	28.564 $\pm$ 0.645
dSprites	0.25	1.015 $\pm$ 0.032	1.117 $\pm$ 0.036
dSprites	0.5	1.040 $\pm$ 0.032	1.144 $\pm$ 0.035
dSprites	1	1.170 $\pm$ 0.024	1.287 $\pm$ 0.026
dSprites	2	1.453 $\pm$ 0.038	1.598 $\pm$ 0.041
dSprites	4	2.144 $\pm$ 0.064	2.358 $\pm$ 0.070
CIFAR-10	0.25	9.407 $\pm$ 0.610	10.348 $\pm$ 0.671
CIFAR-10	0.5	11.151 $\pm$ 0.200	12.266 $\pm$ 0.220
CIFAR-10	1	14.064 $\pm$ 0.108	15.470 $\pm$ 0.119
CIFAR-10	2	17.806 $\pm$ 0.262	19.587 $\pm$ 0.288
CIFAR-10	4	22.399 $\pm$ 0.286	24.638 $\pm$ 0.314

A.1 各状態の独立した集計

以下の表は，元の複合状態と，各フラグおよび最終モデルの品質を分ける。予算フラグは ID fallback と同時に立ち得る。剪定用ラッパーは学習中に通常選択器の予算を強制していないため，予算フラグがゼロであることは同じ予算管理の証拠ではない。予算超過試行を含め，有効な返却モデルはすべて主設定の平均に含める。退化出力は未変換個数と費用の要約に含めるが，MSE には含めない。

表 A2: $\beta = 1$ の結果監査。すべて 5 試行中の件数。S: 記録上の成功; I: ID 信頼性不足; B: 予算超過; D: 退化; N: 小容量の代替なし。FB は fallback フラグ。予算, 検証品質 Q , 最終 VAE の小容量化は, それぞれ独立に再計算するかフラグから読み取る。

データセット	手法	状態	FB	予算超過	Q	小容量化
MNIST	グリッド (MSE)	S5	0	0	5	5
MNIST	FONDUE	S5	0	0	5	5
MNIST	FONDUE + Q	S5	0	0	5	5
MNIST	GECO 変更実装	S5	0	0	5	5
MNIST	ARD 変更実装	S5	0	0	5	5
MNIST	昇順 + Q	S5	0	0	5	5
MNIST	従来 ID 探索窓	S5	0	0	5	5
MNIST	FONDUE-VAR (混合型保持)	S5	0	0	5	5
MNIST	FONDUE-VAR (活性型のみ)	D5	0	0	0	0
Fashion-MNIST	グリッド (MSE)	S5	0	0	5	5
Fashion-MNIST	FONDUE	S5	0	0	5	5
Fashion-MNIST	FONDUE + Q	S5	0	0	5	5
Fashion-MNIST	GECO 変更実装	S5	0	0	5	5
Fashion-MNIST	ARD 変更実装	S5	0	0	4	5
Fashion-MNIST	昇順 + Q	S5	0	0	5	5
Fashion-MNIST	従来 ID 探索窓	I5	5	0	5	5
Fashion-MNIST	FONDUE-VAR (混合型保持)	S5	0	0	5	5
Fashion-MNIST	FONDUE-VAR (活性型のみ)	S5	0	0	0	5

表 A3: $\beta = 1$ の結果監査。すべて 5 試行中の件数。S: 記録上の成功; I: ID 信頼性不足; B: 予算超過; D: 退化; N: 小容量の代替なし。FB は fallback フラグ。予算, 検証品質 Q , 最終 VAE の小容量化は, それぞれ独立に再計算するかフラグから読み取る。

データセット	手法	状態	FB	予算超過	Q	小容量化
dSprites	グリッド (MSE)	S5	0	0	5	1
dSprites	FONDUE	S5	0	0	0	5
dSprites	FONDUE + Q	B1, S4	0	1	5	5
dSprites	GECO 変更実装	S5	0	0	5	0
dSprites	ARD 変更実装	S5	0	0	0	5
dSprites	昇順 + Q	S5	0	0	5	5
dSprites	従来 ID 探索窓	I5	5	0	5	0
dSprites	FONDUE-VAR (混合型保持)	D1, S4	0	0	1	3
dSprites	FONDUE-VAR (活性型のみ)	D3, S2	0	0	0	2
CIFAR-10	グリッド (MSE)	S5	0	0	5	5
CIFAR-10	FONDUE	S5	0	0	0	5
CIFAR-10	FONDUE + Q	S5	0	0	5	5
CIFAR-10	GECO 変更実装	S5	0	0	2	5
CIFAR-10	ARD 変更実装	S5	0	0	0	5
CIFAR-10	昇順 + Q	S5	0	0	5	5
CIFAR-10	従来 ID 探索窓	I5	5	0	5	3
CIFAR-10	FONDUE-VAR (混合型保持)	S5	0	0	5	5
CIFAR-10	FONDUE-VAR (活性型のみ)	S5	0	0	0	5

B 探索感度と時間記録の来歴

これらの表は、アルゴリズム 1 の事後的な方策を用いる。元の実験を定義し直すものではない。

表 A4: $\beta = 1$, $R \leq 0.15$, $A \leq 0.25$ での ID-local 再評価の係数感度。5 係数すべてを示し、棄却されたデータセットは同じ昇順 fallback を使う。5 シード、尤度は表 2 による。

データセット	c	次元数	Q	一致	要求数	初回費用 (秒)
MNIST	1	6.0 ± 0.0	5/5	5/5	6.0	487
MNIST	1.5	6.0 ± 0.0	5/5	5/5	8.0	584
MNIST	2	6.0 ± 0.0	5/5	5/5	9.0	636
MNIST	3	6.0 ± 0.0	5/5	5/5	11.0	743
MNIST	4	6.0 ± 0.0	5/5	5/5	11.0	743
Fashion-MNIST	1	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	1.5	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	2	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	3	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	4	4.0 ± 0.0	5/5	5/5	3.0	416
dSprites	1	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	1.5	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	2	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	3	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	4	20.0 ± 4.0	5/5	5/5	9.0	2092
CIFAR-10	1	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	1.5	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	2	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	3	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	4	24.0 ± 0.0	5/5	5/5	4.0	498

表 A5: $\beta = 1$, $c = 2$ での信頼性閾値感度。ID: ID を開始点とする局所探索; FB: 昇順 fallback。極端な許容値はストレス条件であり、推奨閾値ではない。各結果は 5 シードと同じ参照群を用いる。全組合せの解析は補足資料に含める。

$R_{\max}/A_{\max}$	データセット	利用	平均次元	Q	一致	要求数
0.1/0.25	MNIST	FB	6.0	5/5	5/5	4.0
0.1/0.25	Fashion-MNIST	FB	4.0	5/5	5/5	3.0
0.1/0.25	dSprites	FB	20.0	5/5	5/5	9.0
0.1/0.25	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.15/0.25	MNIST	ID	6.0	5/5	5/5	9.0
0.15/0.25	Fashion-MNIST	FB	4.0	5/5	5/5	3.0
0.15/0.25	dSprites	FB	20.0	5/5	5/5	9.0
0.15/0.25	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.25/0.25	MNIST	ID	6.0	5/5	5/5	9.0
0.25/0.25	Fashion-MNIST	FB	4.0	5/5	5/5	3.0
0.25/0.25	dSprites	FB	20.0	5/5	5/5	9.0
0.25/0.25	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.15/0.4	MNIST	ID	6.0	5/5	5/5	9.0
0.15/0.4	Fashion-MNIST	ID	4.0	5/5	5/5	10.0
0.15/0.4	dSprites	FB	20.0	5/5	5/5	9.0
0.15/0.4	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.15/0.85	MNIST	ID	6.0	5/5	5/5	9.0
0.15/0.85	Fashion-MNIST	ID	4.0	5/5	5/5	10.0
0.15/0.85	dSprites	FB	20.0	5/5	5/5	9.0
0.15/0.85	CIFAR-10	ID	24.0	5/5	5/5	4.0
0.5/2	MNIST	ID	6.0	5/5	5/5	9.0
0.5/2	Fashion-MNIST	ID	4.0	5/5	5/5	10.0
0.5/2	dSprites	ID	20.0	5/5	5/5	6.0
0.5/2	CIFAR-10	ID	24.0	5/5	5/5	4.0

B.1 過去の時間計上と統一時間計上

表 A7 には、元の記録で省かれたアンカーの補完を含め、MAKE50 の過去の費用記録を残す。これは新たな再評価の単価基準ではない。例えば MNIST の平均アンカー単価は、一部の早期記録で 69.3 秒、後の統一スナップショットでは 62.6 秒であり、6 次元の最終モデルの単価はそれぞれ 39.9 秒と 37.6 秒である。これらの一致項目では、論理条件は e300|es1|b1 のままである。集計指標と指定条件の一致から、2 つの時間スナップショットが異なる理由は分からず、モデルがビット単位で同一であることも証明できない。異なるハードウェアや停止設定といった、裏付けのない原因は割り当てない。

補足の results/make51/cost_lineage.csv には、データセット・手法・重み・シードごとに、アンカーと最終モデルの役割、完全なキー、元の trace キー、ファイル・記録の出典、元の所要時間、統一所要時間、可能な範囲での指標同一性の確認を示す。保存されていないグリッド外候補は利用不可と記す。過去のアンカー計上が存在しない場合は、時間ゼロとは区別する。再評価が要求するのは保持されたグリッド候補だけであるため、要求される各アンカーと最終モデルには、利用可能な単一の統一指

標・単価記録を用いる。

表 A6: $\beta = 1$ でのアンカー・最終モデルの時間監査。各項目は手法・役割・シードの記録であり、独立した学習実行ではない。同じ論理キーに異なる単価が付く場合がある。完全なキー、出典、両方の所要時間を `cost_lineage.csv` に示す。保存された集計指標から checkpoint の同一性は確立できない。

データセット	照合項目数	時間の相違	最大差 (秒)
MNIST	117	107	14.53
Fashion-MNIST	130	0	0.00
dSprites	119	109	0.42
CIFAR-10	130	0	0.00

表 A7: 過去の MNIST 学習時間の内訳。 $\beta = 1$, 5 シードの平均秒数。最終モデルは 1 回計上し、他候補列から除く。ID 計算と学習後評価は別に計時されていない。FONDUE の epoch 校正ではデータセット・ β 設定ごとに 4.14 秒を 1 回加えるが、以下には含めない。

手法	アンカー	ID 参照 AE	他の学習	最終	合計
グリッド (MSE)	69.3	0.0	502.0	56.2	627.5
FONDUE	62.6	0.0	1.4	39.9	103.9
FONDUE + Q	69.3	0.0	1.4	55.3	125.9
GECO 変更実装	62.6	0.0	175.4	39.6	277.6
ARD 変更実装	62.6	0.0	138.0	37.6	238.2
昇順 + Q	69.3	0.0	72.8	39.9	182.0
従来 ID 探索窓	69.3	205.5	400.7	39.9	715.4

C 実行範囲と実装の詳細

表 A8: 実行した範囲。画像手法の各行は、記載した条件ごとに 5 学習シードを持つ。追加診断ではそれぞれのシード単位を用いる。

実験	対象データセット	条件・件数
通常選択器・対照 14 種	画像 4 種類すべて	β は 5 値； $14 \times 4 \times 5 \times 5 = 1400$ 手法記録
GECO 変更実装	4 種類すべて	アンカー由来の制約 5 種類；100 記録
ARD 変更実装	4 種類すべて	選択段階の重みは 1 に固定；5 条件で反復，100 記録
ID 参照群	4 種類すべて	各 3 次元数 $\times$ 3 シード，条件間で共有
学習・検証・読み取り推移	MNIST：12, 32, 64；dSprites：6, 16, 32	$\beta = 1$ ，各 5 シード；30 実行
AU 予測	開発：MNIST；評価：dSprites, Fashion-MNIST, CIFAR-10	$\beta = 1$ ；開発 55 行，評価 155 行
合成診断	Swiss roll とトーラス	6 容量，3 シード，2 スケーリング設定；72 実行

通常の 14 手法記録は、MSE・ELBO proxy・プローブによるグリッド選択、粗い探索、固定次元、FONDUE、FONDUE-VAR の 2 設定、AU 記録あり・なしの ID 誘導、昇順 + Q 、および粗い探索・FONDUE・FONDUE-VAR に Q を追加したものからなる。AU の記録を除いても ID 選択の判断は変わらず、AU の処理時間は別に計測されていない。紙面には主要な比較だけを載せる場合でも、機械可読の結果には 14 手法すべてを含める。

表 A9: 保存ローダーと固定シードから再構成した分割の識別子。ローダーの規約に従い、int64 の学習・検証・test 添字配列を連結した SHA-256 の先頭 16 桁の 16 進文字を用いる。公式の学習・test 集合は別々の添字空間を持つ。

データセット	再構成した分割識別子
MNIST	cffaecf5bccbb333
Fashion-MNIST	cffaecf5bccbb333
dSprites	1ea516804f7f9ac7
CIFAR-10	55e0bcf8f4474c19

分割添字配列はローダー仕様から再構成したものであり、実行時に独立して保存された分割ファイルを復元したものではない。MNIST と Fashion-MNIST の識別子が一致するのは、公式データ集合のサイズと添字規則が同じためであり、画像自体は異なる。圧縮した配列を `results/make51/reconstructed_split_indices.npz` として提供する。TwoNN はユークリッド最近傍距離を用い、第 1 近傍距離がゼロの点と経験累積分布の終点を除き、距離比の対数に対して生存関数の対数を原点通過で当てはめる。照合用の MLE は、 $k = 10$ の有効点における局所的な平均対数距離比の逆数を平均する。独自実装では両推定値に 1 の下限を設ける。

表 A10: FONDUE の短期学習 epoch 数と校正時間（データセット・条件ごとに 1 回, 選択器時間とは別）。dSprites は校正せず原著設定を使う。他データの安定欄は, 連続した校正予測が一致したことを意味する。

データセット	β	epoch 数	校正 (秒)	安定
MNIST	0.25	2	9.64	はい
MNIST	0.5	2	9.55	はい
MNIST	1	1	4.14	はい
MNIST	2	2	8.12	はい
MNIST	4	2	9.38	はい
Fashion-MNIST	0.25	1	4.16	はい
Fashion-MNIST	0.5	1	3.64	はい
Fashion-MNIST	1	2	9.07	はい
Fashion-MNIST	2	3	13.70	はい
Fashion-MNIST	4	1	3.80	はい
dSprites	0.25	1	0.00	対象外 (原著設定)
dSprites	0.5	1	0.00	対象外 (原著設定)
dSprites	1	1	0.00	対象外 (原著設定)
dSprites	2	1	0.00	対象外 (原著設定)
dSprites	4	1	0.00	対象外 (原著設定)
CIFAR-10	0.25	3	30.34	はい
CIFAR-10	0.5	2	15.56	はい
CIFAR-10	1	2	22.72	はい
CIFAR-10	2	3	29.69	はい
CIFAR-10	4	4	42.98	はい

C.1 従来の固定探索窓手順

以前の手順は, ID から導いた上限次元以下の候補をすべて評価した。評価済み集合に品質アンカーが含まれるため, 予定されていた拡張分岐には入れなかった。これを有効な拡張探索とは呼ばず, 固定探索窓の監査として残す。以前の V1/V2 活性度検査は選択分岐ではなく, AU 記録によって選択次元は変わらない。

アルゴリズム A1 (従来の固定探索窓 ID 手順 (監査)).

入力: データ分割, $\mathcal{M}$, シード s , β , 目標許容幅 10%, 下限係数 0.001, 入力 TwoNN d_0 , 参照シード $\{42, 123, 777\}$, 閾値 (0.15, 0.25), 表 2 の予算。

1. 品質アンカーを取得し, 式 (1) から $T_{D,s}$ を固定する。fallback では, これは粗い選択器の制約ではなく外部監査の段階であり, 学習費用を計上する。
2. $k \in \{4, 8, 16\}$ について $r_k = \text{round}(kd_0)$ とする (最近整数, 同距離なら偶数へ丸め, グリッドには合わせない)。各次元と各参照シードで全結合 AE を学習し, 固定 10,000 学習例で TwoNN と MLE を計算する。 R , A , $\hat{d}$ を計算する。
3. いずれかの検査が不合格なら ID 信頼性不足を記録し, 粗い部分集合を評価する。0 始まりの添字は $\text{round}(\text{geomspace}(1, |\mathcal{M}|, 4)) - 1$ の重複を除いた値である。検証 MSE が最小の候補を返し, 手順 6 へ進む。
4. それ以外は $m_0 = \min\{m \in \mathcal{M} : m \geq 2\hat{d}\}$ とし, 集合が空なら m_a とする。評価済み集合をアンカーで初期化し, 残りの $m \leq m_0$ を昇順に評価する。完了した呼出しが予算を超えたら停止する。
5. 評価済み集合内で目標を満たす最小次元を返す。それがアンカーなら小容量の代替なしと記録する。アンカーは常に適格なので, コードが予定した「適格な評価済み候補がない場合」の拡張分岐には入らない。
6. 返却次元の通常 VAE を取得または再利用する。 $m < 1$ ならモデルなしの退化出力を返す。モデルを返しても予算フラグは保持する。 AU は m を変えない診断として記録する。
7. 未変換・最終次元, モデル指標, ID 診断, fallback・予算フラグ, 品質・圧縮指標, 費用計上を返す。

C.2 剪定・関連度手法の変更実装

GECO 変更実装は, Adam の学習率 10^{-3} , 保存順序でのバッチ 128, 300 epochs, hard-concrete のパラメータ $\gamma = -0.1$, $\zeta = 1.1$, 温度 2/3 を用いる。初期ゲート対数オッズは 2 とする。制約は再構成二乗誤差和から $D_{\text{input}}T_{D,s}$ を引いた値であり, 移動平均係数は 0.99 である。softplus の二乗の乗数を $[10^{-6}, 10^6]$ に制限し, 移動平均制約違反に対する上昇法で更新する。KL はゲートでマスクし, 期待ゲート罰則は移動平均制約が満たされた場合だけ有効にする。最終読み取りは, 決定論的ゲート値が 0.5 を超えるものを数える。学習制約は dSprites でも二乗誤差を用いる一方, 次元転用先の通常 VAE はベルヌーイ再構成を用いる。したがって候補モデルの尤度規約から, 剪定段階の目的関数も同一であるとはいえない。

表 A11: 主条件での未変換の保持個数と, 次元転用先の通常 VAE の次元数。制約は GECO 学習の最終更新時の移動平均, Q は最終通常 VAE の検証品質であり, 異なるモデル・量进行评估する。ARD には GECO 制約はない。

データセット	変更実装	未変換個数	最終次元	制約	Q
MNIST	GECO	7.2 ± 0.4	6.4 ± 0.9	0/5	5/5
MNIST	ARD	6.0 ± 0.0	6.0 ± 0.0	—	5/5
Fashion-MNIST	GECO	4.2 ± 0.4	4.0 ± 0.0	1/5	5/5
Fashion-MNIST	ARD	3.8 ± 0.4	3.6 ± 0.9	—	4/5
dSprites	GECO	64.0 ± 0.0	64.0 ± 0.0	0/5	5/5
dSprites	ARD	9.2 ± 1.5	8.4 ± 1.7	—	0/5
CIFAR-10	GECO	20.0 ± 1.0	19.2 ± 4.4	5/5	2/5
CIFAR-10	ARD	14.2 ± 0.4	16.0 ± 0.0	—	0/5

過去の GECO 行の制約は, 学習ミニバッチ上で事後分布から標本化した潜在変数と確率的 hard-concrete ゲートを用いる。これは, 例当たりの二乗誤差和から決定論的な検証アンカー目標と入力次元数の積を引いた値の指数移動平均である。native モデルの検証再構成と推移は保存されていない。したがって最終制約達成数が MNIST 0/5, Fashion-MNIST 1/5, dSprites 0/5, CIFAR-10 5/5 であるこ

とだけでは、バグを特定することも、実装の妥当性を確認することもできない。

新しい MNIST 診断では、これら不足していた推移を保存する（図 A1）。評価には検証・test の全例を用い、事後平均または 32 回の事後標本化と、決定論的な連続ゲート値または明示的な二値マスクを組み合わせる。これらの評価量は、学習中の確率的ゲートによる再構成とは異なる。最終的な学習移動平均制約は二乗誤差和の単位で $+0.045$ 、計数ゲートは 7 個、乗数は 0.844 である。転用先のグリッド次元は 6 である。最終時点の学習制約はなお違反している。したがってこの診断により、HC 実装を妥当性確認済みの剪定基準と位置づけることはしない。

表 A12: 新しい MNIST の HC 診断と次元転用、シード 42。MSE は 10^3 倍し、同単位の目標は 25.223。HC 次元はゲート閾値を超える個数であるが、連続値での推論では非二値ゲート値も保持する。標本評価は潜在変数 32 標本と決定論的な連続ゲートを用いる。通常 VAE は最近傍のグリッド次元を使う。

出力・再構成	次元数	検証 MSE	test MSE	Q
HC：連続/平均	7	22.424	21.950	はい
HC：連続/標本	7	27.019	26.519	いいえ
HC：二値/平均	7	22.424	21.950	はい
次元転用後の通常 VAE	6	22.343	21.933	はい




図 A1: 新しい MNIST の hard-concrete 実装診断。シード 42, 300 epochs。学習制約は標本化した潜在変数とゲートを用い、検証は事後平均を用いる。制約と再構成の推移に加え、ゲート数と乗数を示す。独自 HC 実装の 1 実行であり、原著 ARM の再現ではない。

ARD 変更実装は、学習配列の先頭 10% (1800 例) を事前分布の推定に確保し、残りで学習する。10 epochs ごとと学習終了後に $p_j = \text{mean}(\mu_j^2 + \sigma_j^2)$ を更新し、 $[10^{-6}, 10^6]$ に制限する。これは固定部分集合で解析的な事後 2 次モーメントを使うものであり、符号化データ集合を定期的に再標本化するものではない。選択段階の学習は、再構成と重み 1 のガウス KL を用いる。先頭 512 学習例について次式を計算する。

$$w_j = \text{mean}_{x,k} [g_k(\mu(x) + \sqrt{p_j} e_j) - g_k(\mu(x))]^2, \quad q_j = w_j p_j, \quad (\text{A1})$$

スコアを降順に並べ、合計の 99% に達する最小の個数を残す。この有限差分は刻み幅の二乗で割っていない。局所的には既に p_j の因子を含むため、さらに p_j を掛けると、ヤコビアン二乗と分散の積によるスコアとは異なる。したがって保存個数は ARD 変更実装と呼び、文章の修正だけでこの相違は解消できない。ガウス近似自体は原著からの逸脱ではない。条件間で関連度配列と個数が同じであることを数値監査で確認した。これは固定設定の反復であり、 β の走査ではない。

保存された q_j と p_j があれば、checkpoint なしでも有限刻み幅の余分な因子を除ける。 $h_j = \sqrt{p_j}$ とすると、正しく正規化した有限刻み幅のスコアは次式となる。

$$\tilde{q}_j = p_j \text{mean}_{x,k} \left[\frac{g_k(\mu + h_j e_j) - g_k(\mu)}{h_j} \right]^2 = \frac{q_j}{p_j}. \quad (\text{A2})$$

保存された p_j はすべて正である。累積 99% の個数を再計算し、同じ最近傍グリッド規則で次元を転用する。表 A13 では、CIFAR-10 の未変換個数の平均は 14.2 から 26.0 へ変わり、24 次元へ写すと 5 試行すべてで Q を満たす。これは保存数値の精度の範囲での、有限刻み幅の読み取りに対する代数的修正である。刻み幅が大きい可能性と事前分布更新の変更は残るため、厳密なヤコビアンや原著 ARD のベンチマークではない。

表 A13: 主条件の保存スコアと事前分散から修正した、有限刻み幅の関連度読み取り。同じ保存摂動を刻み幅の二乗で正規化してから分散で重み付けし、新しい ARD 学習は行わない。検証するのは代数的な読み取り修正であり、厳密なヤコビアン関連度や原著学習手順ではない。test MSE (10^3 倍) は次元転用先の通常 VAE の値。

データセット	修正前個数	修正後個数	転用次元	Q	test MSE
MNIST	6.0 ± 0.0	6.2 ± 0.4	6.0 ± 0.0	5/5	22.05 ± 0.17
Fashion-MNIST	3.8 ± 0.4	4.0 ± 0.0	4.0 ± 0.0	5/5	19.06 ± 0.25
dSprites	9.2 ± 1.5	10.6 ± 0.5	10.0 ± 0.0	0/5	1.47 ± 0.05
CIFAR-10	14.2 ± 0.4	26.0 ± 0.0	24.0 ± 0.0	5/5	15.36 ± 0.13

FONDUE の記述に基づく分類器は、公開リポジトリ https://github.com/bonheml/VAE_learning_dynamics の commit f6d6e66b536bcbe635392d3438338949d4dc8730 と照合した。独自実装は、1 回の指数変換による事後分散の分類と TwoNN を用いる。公開コードの実行経路や元の実験設定との同等性は主張しない。過去の参照値として、原著は 1 epoch の dSprites 選択を 12.2 ± 0.4 と報告する [4] が、本研究の $\beta = 1$ では 4.2 ± 0.4 である。条件が揃っていないこの差は、実装誤りの証拠でも、元のベンチマークの再現でもない。別の制御フロー検査では、保存された ID 差系列に対し、原著アルゴリズムの上下限更新を再実行した。FONDUE の全 100 経路と返却次元が疑似コードと一致し、通常終了した。この検査は、それらの入力に対する探索更新ロジックを検証するものであり、推定量の実装、学習フレームワークの同等性、公表ベンチマークを検証するものではない。行ごとの結果を results/make51/fondue_control_flow.json に含める。

C.3 閾値のみの解析と品質許容幅の解析

事後的予測解析は Python 3.11.11, NumPy 2.3.2, scikit-learn 1.7.1 を用いる。表 A14 は、この再構成での確率飽和を示す。元の予測器の完全な環境と行ごとの確率は保存されていないため、集計値だけからその浮動小数点結果を厳密に確認できない。今回の再構成の行ごとの決定スコアと確率は `results/make51/au_predictions.csv` に保存する。

表 A14: 今回の予測器再構成における確率の数値飽和。AUROC 計算前にちょうど 1 へ丸められた予測の件数を示す。決定スコアではこれらの行の順位が保持される。

評価条件	基準	基準 +AU	基準 + 無作為
dSprites	55/55	44/55	49/55
Fashion-MNIST	0/55	0/55	0/55
CIFAR-10	45/45	40/45	36/45

本文の AU 閾値図では、3つの δ すべてに同じ checkpoint を用いる。重み列全体について、CIFAR-10 のグリッド・シード候補のうち、AU が容量に等しい割合を以下に示す。各 β で 10 次元数と 5 シードを用いた件数であり、50 個の独立したデータセットではない。

表 A15: CIFAR-10 (ガウス尤度) で、AU が容量に等しい候補の割合 (%)。分母は次元数・シードの 50 候補であり、各列では同じ checkpoint から各閾値の個数を読み直す。

δ	$\beta = .25$	.5	1	2	4
0.001	100	100	100	98	60
0.01	60	50	36	22	10
0.1	48	38	32	20	10

別の事後的な品質許容幅検査では、 $\beta = 1$ の保存済み全グリッドを固定し、再学習やアンカー変更をせず、各許容幅で目標を満たす最小次元を読み取る。表 A16 はこの全グリッド基準を報告するもので、制限された探索窓の選択器の経路や費用を報告するものではない。FONDUE の閾値や ARD の 99% 基準に対する感度学習は実行していないため、それら独自の読み取り閾値への応答は主張しない。

表 A16: $\beta = 1$ で相対許容幅を変えた場合の、品質を満たす最小の保存次元数。5 シードの平均 $\pm$ SD。検証分散の 0.001 倍という絶対下限は固定する。dSprites はベルヌーイ、他はガウス尤度。

データセット	1%	5%	10%	25%	50%
MNIST	6.0 $\pm$ 0.0	6.0 $\pm$ 0.0	6.0 $\pm$ 0.0	4.0 $\pm$ 0.0	4.0 $\pm$ 0.0
Fashion-MNIST	4.0 $\pm$ 0.0	4.0 $\pm$ 0.0	4.0 $\pm$ 0.0	4.0 $\pm$ 0.0	2.0 $\pm$ 0.0
dSprites	51.2 $\pm$ 17.5	36.0 $\pm$ 16.5	20.0 $\pm$ 4.0	12.0 $\pm$ 0.0	9.6 $\pm$ 0.9
CIFAR-10	41.6 $\pm$ 8.8	32.0 $\pm$ 0.0	24.0 $\pm$ 0.0	16.0 $\pm$ 0.0	16.0 $\pm$ 0.0

D 合成データの尺度・除去診断

Swiss roll の点は $(t \cos t, h, t \sin t)$ で、 $t \sim U[1.5\pi, 4.5\pi]$, $h \sim U[0, 1]$ とする。トーラスの点は $((3 + \cos \phi) \cos \theta, (3 + \cos \phi) \sin \theta, \sin \phi)$ で、角度は独立に $[0, 2\pi]$ 上の一様分布から得る。各データは 5000 例、生成シード 0 とし、座標ごとに独立な標準偏差 0.01 のガウス雑音を加える。先頭 4500 例を適合、残り 500 例を報告する診断に用いる。保存実験では、各座標の標準化を分割前の全 5000 例に適合した。これを前処理の情報漏洩として明示し、結果は記述的なものであり、情報漏洩のない独立 test 推定値とは扱わない。

全結合 VAE は幅 128, 64 と逆順の復号器、隠れ層の ReLU, 線形出力, Adam の学習率 10^{-3} , バッチ 128, 300 epochs, $\beta = 1$, シード 42, 123, 777 を用いる。最後の checkpoint で、500 診断例上の事後平均分散が 0.01 以下の座標をゼロにし、同じ例上で MSE を再計算する。表 A17 は標準化した実行を報告する。この保存実験には別の test 集合はない。

表 A17: 合成データの尺度・除去診断。ガウス尤度, $\beta = 1$, $\delta = 0.01$, 3 学習シード。標準化は分割前に行ったため、記述的な検証結果であり、情報漏洩のない汎化推定ではない。変化は実行ごとの MSE 相対変化の平均 (%)。

データ	m	AU	除去前 MSE	除去後 MSE	変化
Swiss roll	1	1.0 ± 0.0	0.3511 ± 0.0267	0.3511 ± 0.0267	+0.000
Swiss roll	2	2.0 ± 0.0	0.1997 ± 0.0177	0.1997 ± 0.0177	+0.000
Swiss roll	3	3.0 ± 0.0	0.1407 ± 0.0018	0.1407 ± 0.0018	+0.000
Swiss roll	4	3.0 ± 0.0	0.1404 ± 0.0136	0.1406 ± 0.0135	+0.147
Swiss roll	6	3.0 ± 0.0	0.1365 ± 0.0023	0.1368 ± 0.0022	+0.183
Swiss roll	8	3.0 ± 0.0	0.1437 ± 0.0089	0.1440 ± 0.0089	+0.165
トーラス	1	1.0 ± 0.0	0.3217 ± 0.0163	0.3217 ± 0.0163	+0.000
トーラス	2	2.0 ± 0.0	0.1654 ± 0.0242	0.1654 ± 0.0242	+0.000
トーラス	3	3.0 ± 0.0	0.1083 ± 0.0036	0.1083 ± 0.0036	+0.000
トーラス	4	3.0 ± 0.0	0.1124 ± 0.0050	0.1124 ± 0.0050	+0.063
トーラス	6	3.0 ± 0.0	0.1095 ± 0.0035	0.1096 ± 0.0035	+0.107
トーラス	8	3.0 ± 0.0	0.1104 ± 0.0069	0.1105 ± 0.0069	+0.156

雑音のない両生成曲面の内在次元は 2 であり、ここでは 3 次元の外部座標で表現されている。だからといって、Swiss roll のパッチの最小埋め込み次元が 3 になるわけではない。この損失のもとで活性座標が 3 個観測されることは、位相の定理ではない。以前の原稿は合成座標を標準化したと記載していたが、実装監査ではその記述と実行された前処理の不一致が見つかった。未標準化の Swiss roll では高さ座標の分散が他の座標よりはるかに小さく、二乗誤差上はその省略が安価になる。この尺度の観測だけで、以前の AU 結果すべての因果説明が完了するわけではない。

E 新しい MNIST モデルの記録

新実験は、候補となる 12 通りの次元数すべて、学習シード 42, 固定シードから再構成した元の分割を用いる。モデル構造と目的関数は通常の MNIST 手順に一致するが、CPU 環境は過去の CUDA 実行と異なる。表 A18 に、各 proxy 選択 checkpoint の検証基準をすべて示す。MC SE は、事後標準化による評価雑音だけを表す。容量選択を固定したファイルを、最終 test 評価に先立って保存する。重み、epoch 曲線、標準化ごとの ELBO 平均を査読用補足資料に含める。この 1 シード検証から、学習シー

ド間の信頼区間は推論しない。

表 A18: 新たに学習した MNIST の全グリッド。シード 42, $\beta = 1$, ガウス尤度。選択 epoch は決定論的 proxy で選び, 停止 epoch は実際の学習最終時点。proxy はガウス正規化定数と事後期待値を省くが, MC ELBO は両方を含む。MSE は 10^3 倍。

次元数	選択 epoch	停止 epoch	検証 MSE	proxy	MC ELBO $\pm$ SE
2	81	111	37.406	-34.647	-484.386 ± 0.009
4	85	115	27.840	-29.304	-480.108 ± 0.009
6	169	199	22.343	-26.696	-478.174 ± 0.010
8	73	103	22.417	-26.544	-478.285 ± 0.009
10	70	100	22.954	-26.663	-478.627 ± 0.009
12	196	226	20.983	-26.055	-478.067 ± 0.012
16	107	137	23.030	-26.774	-478.592 ± 0.009
20	144	174	21.327	-26.156	-478.134 ± 0.010
24	132	162	22.977	-26.956	-478.664 ± 0.008
32	136	166	23.402	-27.042	-478.869 ± 0.012
48	114	144	24.177	-27.411	-479.310 ± 0.013
64	217	247	22.930	-26.946	-479.043 ± 0.011




図 A2: 新しい MNIST のシード 42, 6 次元と 64 次元の学習・検証 MSE。ガウス尤度, $\beta = 1$ 。学習曲線は固定 2000 例の部分集合, 検証は分離した全 2000 例を用いる。黒い十字は proxy 選択 epoch。新たに保存した実行であり, 過去の CUDA checkpoint の学習曲線を復元したものではない。

F 再現資料の一覧と残る記録上の制約

再集計の実行入口は `src/make51/rebuild_review.py` である。保存 JSON と設定を読み, 過去の記録から数値表, 6 個の図, 対応付き予測解析を生成する。新たな探索解析は `src/make51/replay_search.py`, 限定的なモデル検証は `src/make51/validate_models.py`, そ

の出力の要約は `src/make51/summarize_validation.py` で行う。英語原稿の組立て入口は `src/make51/build_manuscript.py` である。生成した英語 TeX は表を本文に埋め込み、図の PDF を参照する。プロジェクト直下から `pdflatex` を参照が確定するまで繰り返す。同梱の `MAKE51_reproducibility.zip` は、この一覧だけでなく実ファイルを提供する。README は軽量な再集計と任意の再学習を区別し、依存関係の版と利用できない過去の成果物を示す。MANIFEST.sha256 で同梱内容を特定する。アーカイブには固定したソースのスナップショットがあり、非公開リポジトリにアクセスしなくても利用できる。

表 A19: 本改訂の出典と出力の対応。パスはプロジェクト直下からの相対パスである。

証拠	ファイル・ディレクトリ
設定	<code>config/experiment_config_MAKE49.json</code>
通常手法の記録	<code>results/make49/stage4_methods.json</code>
剪定記録	<code>results/make49/stage7_b7b8.json</code>
候補指標と潜在分散	<code>results/make49/stage4_cache/</code>
学習・検証・読み取り推移	<code>results/make49/stage3_e7a_e2.json</code>
ID 表現診断	<code>results/make49/stage5_e3_reference.json</code>
元の AU 予測結果	<code>results/make49/stage5_e4_au_value.json</code>
合成実行	<code>results/make49/stage6_e6_synthetic.json</code>
監査した全手法行	<code>results/make51/method_results.csv</code>
対応付き AU 解析	<code>results/make51/au_paired.json</code>
探索再評価と感度	<code>results/make51/search_replay.csv</code> ; <code>results/make51/search_sensitivity.csv</code>
時間記録の来歴	<code>results/make51/cost_lineage.csv</code>
新モデル記録	<code>results/make51/model_validation/</code>
スナップショットの識別	<code>results/make51/source_manifest.json</code>
図	<code>results/figures/NN51/</code>

手法単位の行の識別子は、データセット、手法、候補シード、 β または条件である。候補キーには次元数、指定 epoch 数、停止設定も含まれる。主たる手法記録の各設定・データセット・手法・条件の組合せに 5 シードがあることを、再集計中に確認する。ARD の反復によって、異なる選択重み条件が 5 個生じるわけではない。初期のグリッド外キャッシュ項目はすべて残っているわけではないが、最終指標と学習 trace は手法記録に残る。元の test 予測、過去の完全なモデル checkpoint、独立した ID・評価時間は、欠けたファイルから復元しない。

内部の変更記録には、9 月 12 日の初期仕様、崩壊診断後の dSprites のベルヌーイ尤度への変更、不可能な 100,000 例標本から学習データを用いる検証への ID 推定標本の変更、早期停止なしの推移実行、9 月 13 日の参照次元・実行費用計上・退化出力の明確化が記録されている。主要な予測解析の後には無作為特徴量対照を追加した。本改訂のアンカー費用補完、対応付き AU 推論、品質許容幅の読み直し、明示的実装監査は事後的である。いずれも公開の事前登録済み検定とは言い換えない。9 月 19 日の局所方策、閾値の全組合せ、正規化した ARD 読み取り、新たな 1 シード検証は、先の結果の後に仕様を定めた。補足資料には、それぞれの仕様と出力場所を保持する。

■日本語版の生成 日本語本文の組立ては `src/nn51/build_japanese.py`、図の表示文字の日本語化は `src/nn51/render_figures.py` による。日本語 TeX のコンパイルには、プロジェクト直下で `lualatex main_paper_NN51.tex` を参照が確定するまで繰り返す。日本語図は `results/figures/NN51/` に保存する。

参考文献

- [1] Kingma, D.P.; Welling, M. Auto-encoding variational Bayes. In *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, Banff, AB, Canada, 14–16 April 2014. arXiv:1312.6114. <https://doi.org/10.48550/arXiv.1312.6114>.
- [2] Facco, E.; d’Errico, M.; Rodriguez, A.; Laio, A. Estimating the intrinsic dimension of datasets by a minimal neighborhood information. *Sci. Rep.* **2017**, *7*, 12140. <https://doi.org/10.1038/s41598-017-11873-y>.
- [3] Levina, E.; Bickel, P.J. Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems*, **2004**, *17*. <https://proceedings.neurips.cc/paper/2004/hash/74934548253bcab8490ebd74afed7031-Abstract.html>.
- [4] Bonheme, L.; Grzes, M. FONDUE: An algorithm to find the optimal dimensionality of the latent representations of variational autoencoders. arXiv **2022**, arXiv:2209.12806. <https://doi.org/10.48550/arXiv.2209.12806>.
- [5] Burda, Y.; Grosse, R.; Salakhutdinov, R. Importance weighted autoencoders. In *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, San Juan, Puerto Rico, 2–4 May 2016. arXiv:1509.00519. <https://doi.org/10.48550/arXiv.1509.00519>.
- [6] Bonheme, L.; Grzes, M. Be more active! Understanding the differences between mean and sampled representations of variational autoencoders. *J. Mach. Learn. Res.* **2023**, *24*(324), 1–30. <https://jmlr.org/papers/v24/21-1145.html>.
- [7] De Boom, C.; Wauthier, S.; Verbelen, T.; Dhoedt, B. Dynamic narrowing of VAE bottlenecks using GECO and L_0 regularization. arXiv **2020**, arXiv:2003.10901. <https://doi.org/10.48550/arXiv.2003.10901>.
- [8] Saha, S.; Joshi, S.; Whitaker, R. ARD-VAE: A statistical formulation to find the relevant latent dimensions of variational autoencoders. arXiv **2025**, arXiv:2501.10901. <https://doi.org/10.48550/arXiv.2501.10901>.
- [9] Tipping, M.E.; Bishop, C.M. Probabilistic principal component analysis. *J. R. Stat. Soc. Ser. B* **1999**, *61*, 611–622. <https://doi.org/10.1111/1467-9868.00196>.
- [10] Tenenbaum, J.B.; de Silva, V.; Langford, J.C. A global geometric framework for nonlinear dimensionality reduction. *Science* **2000**, *290*, 2319–2323. <https://doi.org/10.1126/science.290.5500.2319>.
- [11] Roweis, S.T.; Saul, L.K. Nonlinear dimensionality reduction by locally linear embedding. *Science* **2000**, *290*, 2323–2326. <https://doi.org/10.1126/science.290.5500.2323>.
- [12] Ceruti, C.; Bassis, S.; Rozza, A.; Lombardi, G.; Casiraghi, E.; Campadelli, P. DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration. *Pattern Recognit.* **2014**, *47*, 2569–2581. <https://doi.org/10.1016/j.patcog.2014.02.013>.
- [13] Johnsson, K.; Soneson, C.; Fontes, M. Low bias local intrinsic dimension estimation from expected simplex skewness. *IEEE Trans. Pattern Anal. Mach. Intell.* **2015**, *37*, 196–202. <https://doi.org/10.1109/TPAMI.2014.2343220>.

- [14] Costa, J.A.; Hero, A.O. Geodesic entropic graphs for dimension and entropy estimation in manifold learning. *IEEE Trans. Signal Process.* **2004**, *52*, 2210–2221. <https://doi.org/10.1109/TSP.2004.831130>.
- [15] Camastra, F.; Staiano, A. Intrinsic dimension estimation: Advances and open problems. *Inf. Sci.* **2016**, *328*, 26–41. <https://doi.org/10.1016/j.ins.2015.08.029>.
- [16] Allegra, M.; Facco, E.; Denti, F.; Laio, A.; Mira, A. Data segmentation based on the local intrinsic dimension. *Sci. Rep.* **2020**, *10*, 16449. <https://doi.org/10.1038/s41598-020-72222-0>.
- [17] Gałka, Ł.; Karczmarek, P.; Tokovarov, M. Isolation Forest Based on Minimal Spanning Tree. *IEEE Access* **2022**, *10*, 74175–74186. <https://doi.org/10.1109/ACCESS.2022.3190505>.
- [18] Ansuini, A.; Laio, A.; Macke, J.H.; Zoccolan, D. Intrinsic dimension of data representations in deep neural networks. In *NeurIPS 2019*, Vol. 32, 2019. https://proceedings.neurips.cc/paper_files/paper/2019/file/cfcce0621b49c983991ead4c3d4d3b6b-Paper.pdf.
- [19] Pope, P.; Zhu, C.; Abdelkader, A.; Goldblum, M.; Goldstein, T. The intrinsic dimension of images and its impact on learning. In *ICLR 2021*, 2021. arXiv:2104.08894. <https://doi.org/10.48550/arXiv.2104.08894>.
- [20] Rezende, D.J.; Viola, F. Taming VAEs. arXiv **2018**, arXiv:1810.00597. <https://doi.org/10.48550/arXiv.1810.00597>.
- [21] Louizos, C.; Welling, M.; Kingma, D.P. Learning sparse neural networks through L_0 regularization. In *Proceedings of the 6th International Conference on Learning Representations (ICLR)*, Vancouver, BC, Canada, 30 April–3 May 2018. arXiv:1712.01312. <https://doi.org/10.48550/arXiv.1712.01312>.
- [22] Obata, C.; Jin’no, K. Analysis of the relationship between manifold structure and latent space capacity of input data using VAE. In *Proceedings of the 2025 International Symposium on Nonlinear Theory and Its Applications (NOLTA2025)*, Okinawa, Japan, 27–31 October 2025; pp. 32–35. Publication record: https://www.comm.tcu.ac.jp/nel/list_j_2025.html (accessed on 18 September 2026).
- [23] Whitney, H. The self-intersections of a smooth n -manifold in $2n$ -space. *Ann. Math.* **1944**, *45*, 220–246. <https://doi.org/10.2307/1969265>.
- [24] Lucas, J.; Tucker, G.; Grosse, R.B.; Norouzi, M. Don’t blame the ELBO! A linear VAE perspective on posterior collapse. In *NeurIPS 2019*, Vol. 32, 2019. <https://proceedings.neurips.cc/paper/2019/file/7e3315fe390974fcf25e44a9445bd821-Paper.pdf>.
- [25] Rolinek, M.; Zietlow, D.; Martius, G. Variational autoencoders pursue PCA directions (by accident). In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA, 15–20 June 2019; pp. 12406–12415. <https://doi.org/10.1109/CVPR.2019.01269>.
- [26] LeCun, Y.; Bottou, L.; Bengio, Y.; Haffner, P. Gradient-based learning applied to document recognition. *Proc. IEEE* **1998**, *86*, 2278–2324. <https://doi.org/10.1109/5.726791>.

- [27] Xiao, H.; Rasul, K.; Vollgraf, R. Fashion-MNIST: A Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv* **2017**, 1708.07747. <https://doi.org/10.48550/arXiv.1708.07747>.
- [28] Krizhevsky, A. Learning multiple layers of features from tiny images. *Technical Report*; University of Toronto: Toronto, ON, Canada, 2009.
- [29] Matthey, L.; Higgins, I.; Hassabis, D.; Lerchner, A. dSprites: Disentanglement testing sprites dataset. 2017. Available online: <https://github.com/google-deepmind/dsprites-dataset> (accessed on 12 September 2026).
- [30] Fu, H.; Li, C.; Liu, X.; Gao, J.; Celikyilmaz, A.; Carin, L. Cyclical annealing schedule: A simple approach to mitigating KL vanishing. In *Proceedings of NAACL-HLT 2019*, Minneapolis, MN, USA, 2019; pp. 240–250. <https://doi.org/10.18653/v1/N19-1021>.