

1 理論的背景

本節では、AE による多様体抽出の妥当性を支える理論的基盤を述べる。各項目について、数学的証明あるいは先行研究に基づく論理的根拠を付す。

定理 1 (ボトルネック下界). 滑らかな d 次元多様体 $\mathcal{M} \subset \mathbb{R}^N$ に対し、AE が $\mathcal{M}$ 上で恒等写像を実現 ($g \circ f = \text{id}_{\mathcal{M}}$) するためには、エンコーダおよびデコーダが連続であれば $m \geq d$ が必要である。

証明. $g \circ f$ が $\mathcal{M}$ 上の恒等写像であるとき、制限写像 $f|_{\mathcal{M}}: \mathcal{M} \rightarrow \mathbb{R}^m$ は連続な単射でなければならない。ブラウワーの領域不変性定理、あるいは位相幾何学的な次元の不変性によれば、 d 次元多様体から $\mathbb{R}^m$ への連続な単射が存在するための必要条件是 $m \geq d$ である。したがって、 $m < d$ では必ず情報の衝突が生じ、再構成誤差をゼロにすることはできない。□

命題 1 (デコーダヤコビアンの実効階数). 十分な容量を持つ AE が多様体 $\mathcal{M}$ を学習したとき、デコーダのヤコビ行列 $J_g(z)$ の実効的なランクは $\min(m, d)$ に一致することが期待される。

証明. AE が多様体を正確に表現しているとき、デコーダ g の値域は $\mathcal{M}$ の（局所的な）近傍を覆う。微分幾何学において、写像 g の微分（ヤコビ行列） J_g の像は多様体の接空間 $T_{g(z)}\mathcal{M}$ を構成する。 $\mathcal{M}$ が d 次元であれば接空間の次元も d であり、ヤコビ行列の階数は $\text{rank}(J_g) = \dim(\text{Im}(J_g)) = d$ となる。潜在空間の次元 m が d より大きい場合、余剰な $m - d$ 方向の特異値はゼロに近づくため、実効階数は $\min(m, d)$ となる。□

定理 2 (等長埋め込みとプルバック計量). デコーダ $g: \mathbb{R}^m \rightarrow \mathbb{R}^N$ が等長埋め込みであるための必要十分条件は、任意の潜在変数 z においてプルバック計量 $G(z) = J_g(z)^\top J_g(z)$ が単位行列 I_m に一致することである。

証明. 潜在空間上の微小変化 dz に対し、像の微小距離の平方 ds^2 は $ds^2 = \|J_g dz\|^2 = dz^\top (J_g^\top J_g) dz$ と書ける。等長性の定義により、潜在空間のユークリッド距離が保存される条件 $ds^2 = \|dz\|^2 = dz^\top I_m dz$ が任意の dz で成立するためには、 $J_g^\top J_g = I_m$ が必要十分である。□

命題 2 (ノイズ方向選択性). デノイジング AE (DAE) は、多様体 $\mathcal{M}$ の法線方向の誤差を優先的に除去する。

証明. Alain らの研究によれば、DAE の再構成関数 $r(x)$ はデータ密度 $p(x)$ のスコア関数 $\nabla \log p(x)$ を近似し、 $r(x) - x \propto \sigma^2 \nabla \log p(x)$ が成立する。多様体仮説の下では、データ密度は多様体の法線方向に急峻に減衰し、接線方向には緩やかに変化する。したがって、勾配ベクトル $\nabla \log p(x)$ は法線方向を強く指し、再構成処理は法線方向のノイズを選択的に抑制するように働く。□

命題 3 (AU 飽和条件). Vanilla AE では AU が m まで増加し続けるのに対し、VAE では KL 正則化によって AU が内在次元付近で飽和する。

証明. VAE の目的関数は $\mathcal{L} = \text{再構成誤差} + \beta D_{KL}(q(z|x)||p(z))$ である。再構成に必要な次元（内在次元）を超える余剰次元において、 D_{KL} 項は事後分布を標準正規分布 $p(z)$ に強制的に一致させる（すなわち情報の流路を遮断する）。この結果、余剰次元の平均および分散の寄与が消滅し、AU の数はデータ再現に必要な最小限の次元数（内在次元）に抑制される。□

命題 4 (近傍構造保存の改善). ボトルネック次元 m が多様体の内在次元 d に達したとき、近傍構造保存指標 (Trustworthiness) は急激に改善する。

証明. 定理1より、 $m < d$ では連続な単射（埋め込み）が不可能なため、データ空間で離れた点が潜在空間で近接する「情報の衝突」が不可避に生じる。これにより、潜在空間での近傍集合にデータ空間での非近傍が含まれることになり、Trustworthiness が低下する。 $m \geq d$ においてはこの制約が解消され、ホメオモルフィックな（同相な）写像を学習する十分条件が満たされるため、構造保存性が飛躍的に向上する。□

表1に理論項目と実験の対応をまとめる.

表 1: 理論と実験の対応 (改訂版)

項目	種別	対応実験
定理1 (下界)	定理	E1
命題1 (実効階数)	命題	E2
定理2 (等長性)	定理	EC
命題2 (ノイズ選択)	命題	E3
命題3 (AU 飽和)	命題	EA
命題4 (構造保存)	命題	E5