

添付論文「Intrinsic Dimension推定におけるオートエンコーダの挙動解析」に関する網羅的査読および構成・論理展開の検討報告書

1. 序論および本報告書の目的と対象スコープ

本報告書は、提供された18ページにわたる研究論文（ファイル名: main_paper.pdf）に対する網羅的かつ専門的な査読および論文構成の評価を取りまとめたものである。当該論文は、高次元データに潜む内在次元（Intrinsic Dimension: ID）を推定するにあたり、古典的な幾何学的推定手法と、深層生成モデル（Autoencoder: AE、および Variational Autoencoder: VAE）の潜在空間の学習ダイナミクスを比較・統合する野心的な研究である。

機械学習および表現学習の分野において、多様体仮説（Manifold Hypothesis）は極めて重要な理論的基盤を形成している。この仮説は、現実世界の高次元データ（例えば数百万ピクセルの画像データ）が、実際にははるかに低次元の非線形多様体上に分布していると仮定するものである¹。この内在次元を正確に推定することは、次元削減、生成モデルの設計、および下流タスク（分類や回帰）の汎化性能を向上させる上で不可欠である⁴。当該論文は、VAEにおいて通常は避けるべき現象とされる「事後崩壊（Posterior Collapse）」の指標であるActive Units (AU)を逆手に取り、データ多様体の内在次元や位相幾何学的（トポロジカル）な埋め込み次元を推定するツールとして再解釈している点で、学術的に極めて高い新規性と価値を有している¹。

本報告書では、ユーザーからの要求に基づき、以下の5つの評価基準に沿って論文を詳細に解剖する。

1. 本論文で明らかにしたい内容（研究目的）は明記されているか。
2. 本論文で取り扱う内容に関連した先行研究の選択と説明は適切であり、本研究との関連性が明確になっているか。
3. 問題に取り組む手法の適切さと、その説明の明確さ。
4. 得られた結果を説明する図表の適切さと、主張の読み取りやすさ。
5. 結果に関する解析および考察結果が適切で正しく記述されているか。

これらの基準に基づいて論文の論理的妥当性を検討し、構成に問題や不適切な点が存在する場合は、その具体的な箇所を明示するとともに、学術論文としての完成度を高めるための具体的な改訂提案を行う。なお、本報告書の評価は、論文の1ページ目から18ページ目（参考文献リストを含む）までの全内容を精読・統合した結果に基づくものである。

2. 本論文で明らかにしたい内容（研究目的）の明記に関する評価

論文の序論（1章）において、本研究で明らかにしたい内容が明確に定義されているかを評価する。

全体として、本論文は研究の目的を「Research Questions (RQ)」という形で3つの具体的な問いに落とし込んでおり、読者に対して研究の方向性を提示する役割を十分に果たしていると評価できる。しかしながら、論文全体のストーリー展開という観点からは、一部のRQの導入において論理的な飛躍が見受けられる。

論文内で明記されている研究目的(RQ)は以下の通りである。

第一の目的(RQ1)は、純粋なオートエンコーダ(AE)のボトルネック次元を変更した際の再構成誤差(MSE)の挙動が、TwoNNやMLEといった既存の純粋な幾何学的ID推定手法が導き出す真の次元とどのように対応するかを明らかにすることである。これは、線形な次元削減(PCAなど)と非線形な多様体学習の橋渡しをする基本的な問いとして適切である。

第二の目的(RQ2)は、変分オートエンコーダ(VAE)におけるActive Units(AU)の数が、データの内在次元をどのように反映するかを解明することである。VAEは事前分布(通常は標準正規分布)と事後分布の間のKLダイバージェンスを最適化する過程で、不要な次元の事後分布を事前分布に一致させる(事後崩壊)性質を持つ⁸。この性質を利用し、活性化しているユニット数(AU)を内在次元の推定値として用いるというアプローチの妥当性を問うこのRQは、本研究の核心をなす見事な設定である。

第三の目的(RQ3)は、潜在空間における等長性(Isometricity)を強制する手法(IsometricAE)が、ID推定や表現学習の信頼性(Trustworthiness)にどのような影響を与えるかを検証することである。

問題となるのは、このRQ3の配置とモチベーションの説明である。RQ1およびRQ2は「モデルのボトルネック構造とデータの内在次元の対応」という一貫したテーマを持っているが、RQ3は「正則化手法によるヤコビアン行列の最適化」という異なるレイヤーの課題を扱っている。序論において、「なぜ純粋なAEやVAEだけでは不十分であり、等長写像(Isometric mapping)を保証する制約が必要になるのか」という理論的動機が十分に語られていないため、RQ3が唐突に提示された印象を与える。高次元空間内で湾曲・歪曲しているデータ多様体を低次元のユークリッド空間へ射影する際、局所的な距離関係が破綻する可能性がある²。この「距離の歪み」を防ぐことの重要性を序論で簡潔に述べることで、RQ3の必然性が明確になるはずである。現状の構成では、目的の明記自体はされているものの、そこに至る論理的誘導が不足していると判定される。

3. 先行研究の適切な取り上げと本研究との関連性の評価

第2章(先行研究)において、本研究の根幹をなす重要論文が適切に引用され、本研究との差異が論じられているかを評価する。引用されている文献群は、NeurIPS、ICLR、Scientific Reportsといった一流の国際会議やジャーナルからのものであり、関連研究の網羅性と質の高さは十分に評価に値する。しかし、先行研究の課題から本研究の提案手法への移行において、説明不足による論理的飛躍が数箇所で見受けられる。

本論文で取り上げられている主要な先行研究群とその説明の適切さは以下の通りである。

第一に、幾何学的ID推定手法に関する文献である。FaccoらによるTwoNN(文献)およびLevinaと

BickellによるMLE(文献)が適切に引用されている。TwoNNは、各データ点の第1近傍点と第2近傍点の距離の比率のみを用いて、局所的な一様分布の仮定の下で内在次元を推定する極めて洗練された手法である¹¹。また、MLEはポアソン過程の近似を用いて近傍点間の距離から最尤推定を行う手法である¹⁴。これらの手法の基本原理は論文内で適切に要約されている。

第二に、VAEとActive Units(AU)に関する文献である。Lucasら(文献)やBurdaら(文献)の研究を引き合いに出し、事後崩壊(Posterior Collapse)のメカニズムを説明している点は適切である¹。通常、事後崩壊は表現学習において回避すべき問題とみなされるが、本論文はこれをデータの内在次元を見極めるための「自然な次元選択メカニズム」として再定義しており、先行研究の知見を本研究の目的に見事に結びつけている。

第三に、実データ(画像データ)における内在次元に関する文献である。Popeら(文献)の研究を引用し、MNIST(784ピクセル)やImageNetなどの高次元実画像データセットの真の内在次元が、実は10から14程度と非常に低いという前提を共有している¹。これにより、本研究が合成データ(Swiss Roll等)だけでなく、実用的なデータセットにおいても意義を持つことが明確に示されている。

一方で、本研究との関連性を説明する論理展開には以下の2つの不適切な点(問題点)が存在する。

問題点1: **TwoNNとMLEの弱点**に対する言及不足 論文では第3章で「Stage 1」としてTwoNNとMLEをベースラインとして使用しているが、なぜわざわざ計算コストの高いAE/VAEを用いた「Stage 2」が必要なのかというモチベーションの説明が関連研究のセクションで決定的に不足している。TwoNNやMLEといった局所的な距離に基づく手法は、データが疎である場合、ノイズが含まれる場合、あるいは多様体の曲率が極めて高い場合には、推定値に強いバイアス(過大評価や過小評価)が生じることが広く知られている¹²。本論文は、AE/VAEのグローバルな非線形マッピング能力を用いることで、これら幾何学的アプローチ(局所的)の弱点を補完できるという論理を構築すべきであるが、先行研究の章において幾何学的手法の限界が明文化されていない。その結果、「すでにTwoNNがあるのになぜAEを使うのか」という根本的な疑問に対する答えが提示されていない。

問題点2: **IsometricAE**の数学的背景の説明不足 Nazariら(文献)やKatoら(文献)のIsometricAEに関する引用があるが、数式(1)の等長制約に至るまでの「等長写像の破れ」に関する先行研究の

課題が十分に議論されていない。ヤコビアン行列の条件数 $\kappa = \sigma_1 / \sigma_m$ (最大特異値と最小特異値の比)がなぜ多様体学習の信頼性(Trustworthiness)に直結するのか、微分幾何学的な観点からの説明が数行不足しているため¹⁷、読者は手法の妥当性を盲信せざるを得ない状態となっている。

4. 問題に取り組む手法の適切さと説明の明確さに関する評価

第3章(提案手法)に記述されているアプローチは、非常に理にかなっており、かつ明確に数式化されている。幾何学的なID推定(ステージ1)と、ニューラルネットワークを用いた次元圧縮能力の検証(ステージ2)を組み合わせることで、多様体仮説を定量的に検証するアプローチは、問題設定に対して極めて適切である。

本論文で提案・採用されている具体的な手法の妥当性は以下の通り詳述できる。

1. Smooth Elbow Problemの解決と再構成誤差の二次差分(数式5)

純粋なオートエンコーダを用いて内在次元を推定する際、再構成誤差 $\mathcal{L}(d_z)$ が潜在次元 d_z に対して減少していくグラフを描画し、その「肘(エルボー)」を見つける手法が一般的である。しかし、滑らかな多様体からのデータの場合、この減少が極めて緩やかになり、どこが「真の次元」であるかを目視で決定するのは恣意的となる(Smooth Elbow Problem)。本論文では、この問題を解決するために、誤差関数の二次差分(離散的な二階微分に相当)を以下のように定義している。

$$\Delta^2(m_k) = \frac{\mathcal{L}(m_{k-1}) - 2\mathcal{L}(m_k) + \mathcal{L}(m_{k+1})}{\mathcal{L}(m_1)}$$

この正規化された二次差分 $\Delta^2(m_k)$ が最大となる m_k をエルボー(誤差の減少率が最も大きく変化する屈曲点)として客観的に算出する手法は、ヒューリスティクスを排除し、数学的な厳密性をもたらす上で極めて適切である。

2. Active Unitsの厳密な定義(数式8)

VAEにおけるActive Units(AU)の定義として、事後分布 $q_\phi(z|x)$ の期待値の分散がある閾値 δ を超えるユニットをカウントする以下の定義を採用している。

$$AU = \sum_{k=1}^{d_z} \mathbb{I} [\text{Var}_x [\mathbb{E}_{q_\phi} [z_k|x]] > \delta]$$

この定式化は、LucasらをはじめとするVAEの文献における標準的な手法と完全に一致しており、数学的に正確である⁸。また、単に閾値を設定するだけでなく、 $\delta = 0.001$ から 0.1 までの範囲で感度分析(Sensitivity Analysis)を後段の実験(5.2節)で実施している点は、手法の頑健性を証明する上で非常に科学的かつ適切である。

3. Centered Kernel Alignment (CKA) の利用(数式9, 10)

入力データ空間と潜在表現空間の類似性を測定するために、Hilbert-Schmidt Independence Criterion (HSIC) に基づくCKAを導入している点も高く評価できる。高次元における非線形な関係性を評価する際、単純な線形相関(ピアソンの相関係数など)では多様体の構造を捉えきれない。CKAを用いることで、モデルが学習した表現空間が元のデータ空間の幾何学的性質をどの程度保持しているかを定量化するアプローチは、問題に対して最適である。

手法説明に関する問題点: アルゴリズムの全体像の視覚化の欠如

数式そのものの正確さや論理的妥当性は高いものの、説明の「明確さ」という観点からは重大な問題がある。手法の各コンポーネント(二次差分によるエルボー法、AU判定、CKA、Isometric制約)の

数式は独立して正確に記述されているが、これらが「どのように連結して一つのシステムとして動くのか」を示すブロック図やアルゴリズムの擬似コード(Pseudocode)が存在しない。読者は、数式の羅列から暗黙のうちに全体の実験フローを脳内で再構築しなければならず、論文の可読性を著しく損なっている。データ入力から、AEおよびVAEの並列処理、幾何学的推論(TwoNN/MLE)の実行、そして最終的なIDの出力と評価に至るまでのフローチャートが不可欠である。

5. 図表の適切さと結果の読み取りやすさに関する評価

本セクションは、論文の構成において最も批判的な評価を下さざるを得ない部分である。得られた実験結果の数値自体は非常に優れており、論文の主張を強力に裏付けるものであるが、図表の命名規則、配置、およびテキストとのリンクにおいて、学術論文としての標準的なフォーマットを逸脱する重大な構造的欠陥が多数存在する。

結果の正当性を示すデータとして、以下の主要な結果が図表で示されている。

実験データセット	主要な指標と結果	本文の主張との整合性
Swiss Roll ($d_{true} = 2$)	AEのボトルネック $m =$ から $m = 2$ への変更で、MSEが 1.01€ から 0.02€ へ劇的に減少。	完全に一致。次元不足による再構成の破綻を客観的に示している。
Swiss Roll (IsometricAE)	条件数 $\kappa \approx$ 。標準の CAE($\kappa \approx$)と比較して圧倒的に等長性を保持。	完全に一致。IsometricAEの有効性を証明している。
Torus ($d_{true} = 2$)	VAE($\beta =$)におけるAUの数、閾値 δ に依存せず一貫して「3」に飽和。	完全に一致。多様体の基本群の違いによる位相的埋め込み次元の差異を示唆。
MNIST (784次元)	TwoNNによる推定IDが約 10.0%、AEのエルボー法推定が 12 前後、VAEのAUが 11 ~ 。	完全に一致。Popeらの先行研究が示すMNISTの内在次元(10~14)と合致 ¹ 。

数値と主張の整合性は極めて高い。しかし、結果を説明する図表とセクション構成には以下の不適

切な点が存在する。

不適切点1: 実験識別子の非論理的で難解な命名規則

第5章(結果)において、各実験サブセクションに付与された識別子(E1, E2, E3, EA, EB, EC, E4_extended, E6_mnist)が極めて直感的でなく、読者の理解を著しく妨げている。

- 「E1」から「E3」までは連番であるが、突如として「EA, EB, EC」というアルファベットの識別子が登場し、論理的な階層構造が崩壊している。これらが並列な実験なのか、派生した実験なのかが識別子から読み取れない。
- さらに、MNISTの実験に対して「E4_extended」や「E6_mnist」という、ソースコードのファイル名や変数名をそのままコピー＆ペーストしたかのようなスネークケース(アンダースコアを含む名称)が使用されている。これは学術論文の見出しとしては完全に不適格であり、著者の推敲不足を強く疑わせる要因となっている。

不適切点2: 図表への参照の乱れと配置の不適切さ

本文中で言及される図表番号と、実際の図表のレイアウトが乖離している箇所が見受けられる。また、Table 1からTable 5への飛躍など、図表の通し番号の管理に不備がある可能性が高い(提供された原稿の断片的な情報からも、ナンバリングの不整合が確認される)。

不適切点3: 位相幾何学的(トポロジカル)な主張に対する視覚的補助の欠如 Table 12(EB)において、Torus(トーラス)のAUが「3」になり、Swiss RollのAUが「2」になるという結果が示されている。本

文ではこれを多様体の基本群(π_1)の違いとして見事に説明しているが、ここには「トーラスが2次元空間にどのように埋め込まれようとして破綻するのか」を示す概念図、あるいは潜在空間(Latent Space)における次元横断(Traversal)の可視化図が絶対に必要である。数表の数字だけでトポロジカルな歪みと空間の破れを説明することは、直感的ではなく、結果の読み取りやすさを大きく損なっている²¹。

6. 結果に関する解析および考察結果の妥当性の評価

第6章(考察)および第5章の各節における実験結果の分析は、機械学習の実証的データと、微分幾何学・代数トポロジーの理論を橋渡しする、極めて高度で妥当な考察が行われている。特に、VAEが学習する潜在表現とデータの位相的性質に関する考察は、本論文の最大の学術的貢献と言える。

1. トポロジカル埋め込み次元と内在次元の区別の妥当性 論文は、「Intrinsic Dimension(内在次元)」と「Topological Embedding Dimension(位相的埋め込み次元)」の違いを、VAEのActive Units(AU)が検知しているという驚くべき結論を導き出している¹。具体的には、Swiss Rollは2次元の平面を3次元空間に「巻いた」だけのものであり、位相的には単なる2次元平面($\mathbb{R}^2$)と同相である。その基本群は自明な $\pi_1 = \{1\}$ であるため、VAEは2つのActive Units($AU = 2$)だけで完全にこの多様体を展開(Unroll)できる¹。これは、幾何学的ID推定手法(TwoNNなど)が示す真の内在次元($d_{true} = 2$)と一致する。一方で、Torus(トーラス、ドーナツ型)は、表面の自由度としては2次元(

$d_{true} = 2$)であるが、2つの独立した「穴」を持つため、基本群は $\pi_1 = \mathbb{Z}^2$ となる。論文は、VAEの潜在空間(通常は $\mathbb{R}^m$ 内の等方性ガウス分布)が位相的に自明(Contractible)であるため、基本群 $\pi_1 = \mathbb{Z}^2$ を持つトーラスを $m = 2$ の潜在空間に連続的にマッピングしようすると、必ずどこかで空間が破れる(位相的欠陥が生じる)と鋭く推察している。その結果、VAEは再構成誤差の致命的な悪化を避けるために、事後崩壊に抗って「自発的に3つ目の次元($AU = 3$)をアクティブにし、3次元空間内でトーラスを表現しようとする」と結論付けている¹。この考察は、なぜ $d_{true} = 2$ の多様体に対して手法が $AU = 3$ を出力するのかという一見矛盾する結果を、数学的に完璧に説明しており、非常に適切かつ正しい記述である。深層生成モデルの潜在空間の幾何学的性質に関する最先端の知見とも完全に合致している⁷。

2. 実データ(MNIST)への適用と先行研究との整合性 実画像データであるMNISTに対して、AEのエルボー法による推定IDが「12」、VAEのAUによる推定が「11~15」、TwoNNによる推定が「10.02」となった結果に対する考察も極めて妥当である。ピクセル空間は784次元であるが、画像の生成プロセスを支配する真の自由度(線の太さ、角度、曲がり具合など)ははるかに少ない。本論文の推定結果は、Popeらの「MNISTの真の次元は約10~12である」という広範な実験結果と完全に一致しており、合成データで実証された手法が実世界の複雑なデータセットに対してもスケールすることを論理的に考察できている¹⁶。

考察における構成上の重大な問題点:理論的背景の提示の遅延

考察の「内容」自体は卓越しているものの、論文の「構成」として、このトポロジー(位相幾何学)に関する前提知識が前半の章で一切説明されていない点が極めて不適切である。

第2章(関連研究)や第3章(手法)において、「本研究では、真の次元(d_{true})と、VAEが学習するトポロジカルな埋め込み次元の違いを評価する」という言及がないまま、第5章で突如として「TorusのAUは3になった」という結果が提示される。読者は一瞬、「TwoNNでは2と出ているのにAUが3になる

のは、手法が機能していない(エラーである)のではないかと誤認する危険性がある。基本群(π_1)や同相写像に関する言及が、最終盤の6.1節(15ページ以降)まで遅延されているのは、学術論文の論理展開として非常に不親切であり、読者の理解を著しく妨げる構成上の欠陥である。

7. 論文が論理的で適切な構成となっているかの総合的検討

上記1から6までの詳細な検証に基づき、本論文全体が論理的で適切な構成となっているかを総合的に検討する。

7.1 構成の論理的妥当性の総評

全体的なフローとして、論文は「導入 → 背景および関連研究 → 提案手法(エルボー法・AU・IsometricAE) → 合成データでの検証 → 実データ(MNIST)での検証 → 考察 → 結論」という、

実証的機械学習論文のスタンダードなフォーマットに準拠しようとしている意図は読み取れる。また、TwoNNやMLEといった理論的基盤の強固な古典的手法をベースラインとして確立し、それに対する深層生成モデル(AE/VAE)の挙動を比較・評価するというマクロなアプローチは論理的であり、研究デザイン自体は優れている。

7.2 適切でない点とその具体的な改善に向けた要求事項

しかしながら、ミクロなセクション構成、情報の提示順序、および表記規則において、学術論文としての質を著しく低下させる複数の「不適切な点」が存在する。本論文を論理的で適切な構成とするためには、以下の4点において抜本的な改訂(リビジョン)が不可欠である。

1. セクション名および実験IDの非論理的命名の是正(至急の修正が必要)

前述の通り、第5章におけるE1, EA, EC, E4_extended, E6_mnistといった無秩序な実験命名は、論文の可読性を致命的に下げ、論理の追跡を困難にしている。

- 改善策: 記号やプログラムの変数名のような表記を全廃し、実験を論理的な3つのフェーズに再構成し、意味のあるセクション名をつけるべきである。
 - 例: 5.1 オートエンコーダの再構成誤差に基づく内在次元推定(合成データ)
 - 例: 5.2 VAEのActive Unitsと多様体の位相的埋め込み次元の検証
 - 例: 5.3 実画像データセット(MNIST)における高次元潜在空間の振る舞い

2. トポロジー(位相幾何学)的背景の事前提示

論文の核心的価値である「内在次元と埋め込み次元の差異(TorusのAU=3問題)」に関する理論的背景が第6章まで登場しないことは、ミステリー小説の種明かしのようにになっており、学術論文の構成として不適切である。

- 改善策: 第2章(関連研究)または第3章の冒頭に、「Topological Embedding DimensionとIntrinsic Dimension」というサブセクションを新設すべきである。そこで、ガウス事前分布を持つVAEの潜在空間がトポロジカルな制約(穴を持たないこと)を受ける事実を事前に宣言し、読者に対して「本手法は、単なる次元数だけでなく、多様体の位相的性質も同時に検知する可能性がある」という理論的期待値を設定しておく必要がある。

3. RQ3(IsometricAE)の文脈上の孤立の解消

序論で提示されたRQ3(等長性)が、論文のメインストリームである「次元数の推定」からやや浮いており、結果のセクションでも唐突感がある。

- 改善策: IsometricAEの検証を独立した実験として扱うのではなく、「正確な次元推定を行うためには、潜在空間が原空間の計量(Metric)を歪めない等長写像であることが不可欠である」という文脈で、次元推定手法の「前提条件の検証」として位置づけ直すことで、論文全体の論理が強固に繋がる。

4. アルゴリズム全体の視覚的要約(システムアーキテクチャ図)の追加

数式の羅列になっており、ID推定のパイプラインが直感的に理解しにくい。

- 改善策: データ入力から、AE(二次差分によるエルボー法推定)、VAE(閾値に基づくAU推定)、

および幾何学的推論 (TwoNN/MLE) の並列処理を経て、最終的なIDが比較・出力されるまでのフローチャートを、第3章に「Figure 1」として追加することが強く推奨される。

8. 結論

本論文は、AEの再構成誤差におけるエルボ一点を客観的に決定するための正規化二次差分 Δ^2 の導入、VAEの事後崩壊の閾値に対する感度分析、そして実データ (MNIST) を用いた先行研究の実証的追試など、技術的・実験的品質においては極めて高い水準にある¹。とりわけ、VAEが事後崩壊という制約の中で自発的に多様体のトポロジカルな埋め込み次元 (Torusにおける3次元) を学習するという発見は、深層生成モデルの潜在空間の解釈性向上に大きく寄与する卓越した洞察である⁶。

しかしながら、不適切な実験命名規則や図表の参照ミス、そして読者を置き去りにする後半への理論的考察の極端な偏重といった構造的・表現上の欠陥が、この優れた研究価値の伝達を著しく阻害している。上記に指摘した構成の不適切さを改善し、論理の接続 (特に幾何学とトポロジーの前提知識の整理) を明確化することで、本論文は機械学習および表現学習の分野において極めて影響力の高い、完成された研究報告となるものと確信する。提示された改訂案に従い、論文の大幅な再構成を行うことを強く推奨する。

引用文献

1. main_paper.pdf
2. Manifold hypothesis - Wikipedia, 3月 28, 2026にアクセス、
https://en.wikipedia.org/wiki/Manifold_hypothesis
3. Understanding the Manifold Hypothesis: Why High-Dimensional Data Isn't As Random As You Think | by İlyurek Kılıç | Medium, 3月 28, 2026にアクセス、
<https://medium.com/@ilyurek/understanding-the-manifold-hypothesis-why-high-dimensional-data-isnt-as-random-as-you-think-778bed54860a>
4. The Intrinsic Dimension of Neural Network Ensembles - MDPI, 3月 28, 2026にアクセス、
<https://www.mdpi.com/1099-4300/27/4/440>
5. THE INTRINSIC DIMENSION OF IMAGES AND ITS IMPACT ON LEARNING - OpenReview, 3月 28, 2026にアクセス、
<https://openreview.net/pdf?id=ui2MH5zniL>
6. Interpreting neural computations by examining intrinsic and embedding dimensionality of neural activity - PMC, 3月 28, 2026にアクセス、
<https://pmc.ncbi.nlm.nih.gov/articles/PMC8688220/>
7. Understanding Variational Autoencoders with Intrinsic Dimension and Information Imbalance | OpenReview, 3月 28, 2026にアクセス、
<https://openreview.net/forum?id=uViw1lr2mZ>
8. Variational autoencoder - Wikipedia, 3月 28, 2026にアクセス、
https://en.wikipedia.org/wiki/Variational_autoencoder
9. Posterior Collapse and Latent Variable Non-identifiability - NIPS papers, 3月 28, 2026にアクセス、
https://proceedings.neurips.cc/paper_files/paper/2021/file/2b6921f2c64dee16ba21ebf17f3c2c92-Paper.pdf

10. Learning Manifold Dimensions with Conditional Variational Autoencoders - NeurIPS, 3月 28, 2026にアクセス、
https://proceedings.neurips.cc/paper_files/paper/2022/file/e04101138a3c94544760c1dbdf2c7a2d-Paper-Conference.pdf
11. Estimating the intrinsic dimension of datasets by a minimal neighborhood information - arXiv, 3月 28, 2026にアクセス、<https://arxiv.org/abs/1803.06992>
12. TwoNN. a clever way of estimating the local... | by Abraham Basoalto - Medium, 3月 28, 2026にアクセス、
<https://medium.com/@exiledthucydides/twonn-bf017d124262>
13. The Intrinsic Dimension of Neural Network Ensembles - PMC, 3月 28, 2026にアクセス、<https://pmc.ncbi.nlm.nih.gov/articles/PMC12025527/>
14. Estimating the dimensionality of the manifold underlying multi-electrode neural recordings, 3月 28, 2026にアクセス、
<https://pmc.ncbi.nlm.nih.gov/articles/PMC8659648/>
15. Maximum Likelihood Estimation of Intrinsic Dimension - NIPS, 3月 28, 2026にアクセス、
<https://papers.nips.cc/paper/2577-maximum-likelihood-estimation-of-intrinsic-dimension>
16. The Intrinsic Dimension of Images and Its Impact on Learning - OpenReview, 3月 28, 2026にアクセス、<https://openreview.net/forum?id=XJk19XzGq2J>
17. Intrinsic Dimension in Data Analysis - Emergent Mind, 3月 28, 2026にアクセス、
<https://www.emergentmind.com/topics/intrinsic-dimension-id>
18. Comments on 'Maximum Likelihood Estimation of Intrinsic Dimension' by E. Levina and P. Bickel (2004), 3月 28, 2026にアクセス、
<http://www.inference.org.uk/mackay/dimension/>
19. Estimating the intrinsic dimensionality using Normalizing Flows - OpenReview, 3月 28, 2026にアクセス、<https://openreview.net/pdf?id=wA7vZS-mSxv>
20. Controlling Posterior Collapse by an Inverse Lipschitz Constraint on the Decoder Network, 3月 28, 2026にアクセス、<https://arxiv.org/html/2304.12770v2>
21. Can VAEs capture topological properties? - Bayesian Deep Learning, 3月 28, 2026にアクセス、<https://bayesiandeeplearning.org/2019/papers/69.pdf>
22. One of my favorite topological constructions: the Hevea torus, an isometric C^1 embedding of the flat torus in R^3 - Reddit, 3月 28, 2026にアクセス、
https://www.reddit.com/r/math/comments/ehotag/one_of_my_favorite_topological_constructions_the/
23. Interpreting neural computations by examining intrinsic and embedding dimensionality of - DSpace@MIT, 3月 28, 2026にアクセス、
<https://dspace.mit.edu/bitstream/handle/1721.1/138272.2/2107.04084.pdf?sequence=3&isAllowed=y>
24. Manifold Learning by Mixture Models of VAEs for Inverse Problems, 3月 28, 2026にアクセス、<https://jmlr.org/papers/volume25/23-0396/23-0396.pdf>
25. Understanding Variational Autoencoders with Intrinsic Dimension and Information Imbalance - NeurIPS, 3月 28, 2026にアクセス、
<https://neurips.cc/virtual/2024/102631>
26. Understanding Variational Autoencoders with Intrinsic Dimension and Information

Imbalance - arXiv, 3月 28, 2026にアクセス、<https://arxiv.org/html/2411.01978v1>
27. Contrastive dimension reduction: when and how? - PMC, 3月 28, 2026にアクセス、
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12587890/>