

変分自己符号化器の内在次元誘導による ボトルネック選択と活性ユニット診断

小端 千佳, 代 美月, 神野 健哉

東京都市大学 情報工学部 知能情報工学科

〒158-8557 東京都世田谷区玉堤 1-28-1

g2332016@tcu.ac.jp (C.O.), g2591402@tcu.ac.jp (M.D.)

連絡著者: kjinno@tcu.ac.jp, 電話: +81-3-5707-0104 (K.J.)

概要

内在次元推定と活性ユニット診断は、変分自己符号化器のボトルネック選択の異なる側面を扱う。4 種類の画像データセット, 5 学習シード, 5 正則化重みについて, 検証品質目標と共通の保存候補費用を用いて探索方策を評価する。開始次元数のアブレーションでは, 信頼性判定, fallback, 参照群の費用計上を固定する。ID が採用されるのは MNIST の 25 条件だけである。ID 由来の開始点と判定付き中点は同じ次元数を選び, 平均要求候補数はそれぞれ 8.84 件, 5.84 件である。残る 75 条件は同じ昇順 fallback を用いる。100 種類の係数・閾値組合せと 100 種類のデータセット・重み・シード条件からなる 10,000 件の replay 評価で, 局所探索の 155 出力が品質を満たす最小次元を逃す。各データセット 3 シードの剪定実験では, 選択された native モデルの再構成と, 通常の変分自己符号化器への次元転用を区別する。ローカルな関連度事前分布の変種では, 非選択軸のマスクにより dSprites の検証誤差が 126.3% 増え, 30 epochs の復号器微調整により, 全次元モデルより 37.1% 高い水準まで低下する。全次元モデルを含む 4 評価条件すべてが, このデータセットの品質目標に届かない。活性ユニットの予測は, 天井に近い課題で追加の利益を確立しない。これらの知見は選択規則と診断の統制された実証評価を支持するが, 一般的な効率改善や剪定の保証を与えない。

キーワード: 変分自己符号化器, ボトルネック次元, 内在次元, 活性ユニット, モデル選択, 再構成品質, 再現性

本稿は英語版 MAKE53 の日本語版であり, 節・図表・式番号は英語版に対応する。参考文献の書誌情報は原文表記を保持する。

1 はじめに

変分自己符号化器 (VAE) [1] の潜在次元数は, 表現に利用できる容量を規定する。候補グリッド上で検証性能を比較して次元数を選ぶ方法は単純だが, 複数のモデルの学習を要する。代替手段には, 内在次元 (ID) の推定 [2, 3], 標本化した潜在表現と事後平均表現の比較 [4], 活性度の診断 [5, 6], 再構成制約や関連度事前分布を用いる剪定 [7, 8] がある。これらの指標が答える問いは異なり, 幾何学的次元, 座標の利用状況, 再構成品質, ネットワークの幅は必ずしも一致しない。

本研究では, ID の利用が潜在次元探索の判断と学習要求をどのように変えるか, 活性ユニット (AU) の診断が他の記録量に加えて予測上の価値を持つか, また, これらの測定が品質目標と読み取り設定にどう依存するかを検討する。共通の候補モデル群と固定したデータ分割のもとで探索方策を比較し, 探

索順序、停止規則、品質達成、品質を満たす最小グリッド次元との一致を別々に測定する。

本研究の貢献は、品質と費用の定義を明示したうえで、ID 誘導によるボトルネック選択と AU 診断を実証的に評価することである。対象は 4 種類の画像データセット、候補学習の 5 シード、5 通りの正則化重みである。開始次元数のアブレーションでは、参照群の取得、信頼性判定、fallback を固定し、ID から定める開始次元数の効果を探索規則の効果から切り分ける。さらに、ID 係数と信頼性閾値の全組合せを解析する。

各データセット 3 シードの追加実験で、確率的ゲートによる剪定と厳密ヤコビアンによる関連度の読み取りを評価する。ローカル ARD 変種について、全次元モデル、選択軸によるマスク、固定予算での復号器微調整、通常 VAE への次元転用を比較する。成分の検証は、原著の剪定手法全体の再現を確立するものではない。別の MNIST・1 シード実験では、証拠下限 (ELBO) の Monte Carlo 推定値による容量選択を評価する。3-5 節でプロトコルを定義し、6 節で結果を示し、7 節で推論の適用範囲を述べる。

2 関連研究

2.1 次元、再構成、潜在変数の活性

PCA[9], Isomap[10], 局所線形埋め込み [11] は低次元表現を構成する。一方、ID 推定量は標本の幾何から局所的な次元を定量化する。本研究は TwoNN と照合用の MLE を用いるが、他にも DANCo, 期待単体歪度, 測地エントロピーグラフなどがある [12-14]。推定量の制約と標本分布への依存性が、複数推定量による照合の動機となる [15, 16]。グラフ系手法は本実験の対象外であり、それらが観測された不一致を解消または再現するとは推論しない。最小全域木に基づく Isolation Forest も異常度評価にグラフの幾何を用いる [17] が、その目的は再構成目標のもとで VAE の次元数を選ぶこととは異なる。深層ネットワークの学習済み表現で ID が低下することも報告されている [18, 19]。

FONDUE[4] は、標本表現と事後平均表現の ID 推定値が乖離する直前の容量を探索する。同論文の付録では、潜在変数の型から個数を選ぶ FONDUE-VAR も示されている。AU と変数型は未使用座標への関心を共有するが、統計量としては異なる。AU はデータ間の事後平均の分散を閾値処理し、型分類器は事後分散のモーメントを用いる [6]。最終的な個数が一致しても、安定性や情報量が同等であるとは限らない。

L_0 正則化を伴う GECO は、再構成制約のもとでゲート付き VAE を最適化する [7, 20]。原著は ARM を用いるが、従来のローカル変更実装は hard-concrete (HC) ゲートを用いていた [21]。追加した ARM 実装ではこの勾配成分を原著に合わせた一方、初期化、制約の適用手順、KL の尺度に相違が残る (5.5 節)。本研究の検証アンカーは、外部の品質基準を与える。

ARD-VAE は階層的な関連度事前分布を用いる [8]。原著は正則化重みを調整し、閉形式の KL にガウス近似を用い、ヤコビアンで重み付けした分散スコアの 99% を説明する軸を選ぶ。したがってガウス近似は原著と共通する。従来の有限刻み幅スコアとその正規化監査を付録 C.3 に示す。新しい検証では自動微分によるヤコビアンを用いる。原著のゼロ中心による分散更新と、追加の標本平均を中心とする分散更新を区別し、学習と標本抽出にはローカルな設定を用いる。

2.2 先行会議論文および以前の原稿との関係

著者らの NOLTA2025 論文 [22] は、入力 ID と潜在空間容量の関係を扱った。比較に利用できる会議原稿には、4 種類の全結合構造と 2 種類の畳み込み構造、4 シードによる MNIST クラス別実験が記

載されている。したがって CNN と複数シードの利用自体は、本改訂の新規事項ではない。利用した会議原稿の作業題名は公表題名と異なるため、参考文献には著者所属機関の業績記録にある題名とページを用いる。表 1 で先行研究と本比較の範囲を区別する。MAKE47 は以前の学術誌投稿稿を指し、独立した出版物ではない。

本研究の貢献は統制された実証比較であり、元のヒューリスティックの一般的な優越性を主張するものではない。以前の学習呼出し回数 60–80% 削減という主張を、一般的な効率改善の主張としては撤回する。以前の AU 検査 V1/V2 は最終的な次元選択に用いず、本研究ではそれらの追加的な予測価値も確立しない。理論的な埋め込みの考察は実験の動機づけであり、ID から次元数を決める数値規則を保証しない。

表 1: 会議論文, 以前の学術誌投稿稿, 本改訂の対象範囲。

項目	NOLTA2025	MAKE47	本改訂
問い	入力・潜在 ID と容量	ID 誘導選択と AU 検証	選択の品質, 費用, 診断の限界
モデル	全結合 4 構造と CNN 2 構造, MNIST クラス別, 4 シード	全結合・CNN と合成・画像への拡張	画像 4 データセットの固定候補群, 候補学習 5 シード
比較対象	構造と容量の比較	容量走査と診断	FONDUE の変種, グリッド基準, 探索方策; 別途の剪定検証
読み取り	ID 推定値	AU による運用上の検査	同一 checkpoint での型・AU 推移と対応付き予測解析
証拠	会議論文の設定	旧損失規約	損失修正後の記録, 明示的な目標, 最終 test 指標, 費用計上の限界

3 評価の枠組み

3.1 モデルと品質目標

推定用の表現を与える ID 参照 AE, 最大候補次元の通常 VAE である品質アンカー, 次元選択後に評価する通常 VAE である選択モデルを区別する。候補グリッドを $\mathcal{M}$, 学習シードを s , 決定論的再構成 $g(\mu(x))$ の検証データにおける画素平均 MSE を $D_s(m, \beta)$ とする。実装された目標は次式である。

$$m_a = \max \mathcal{M}, \quad T_{D,s}(\beta) = D_s(m_a, \beta) + \max\{0.10D_s(m_a, \beta), 0.001 \text{Var}(X_{\text{val}})\}. \quad (1)$$

分散は検証配列の全要素にわたって計算する。記録されたすべての画像条件で相対項が支配的であり, $T_{D,s} = 1.10D_s(m_a, \beta)$ となる。当初の設定にはシード間 SD の 3 倍の項もあったが, 実行時の目標関数にはアンカーが 1 個ずつ渡され, その項は省略された。ここでは実装された規則を報告し, シードをまとめた目標であったかのように記述しない。付録 A に, データセットと β の全組合せのアンカーと目標を示す。

シードと β を固定した探索中は, 目標も固定する。 β を変えると別のアンカーから目標を再計算する。したがって β の走査は学習表現と品質基準の双方を変えるものであり, 品質を固定した介入ではない。有効な次元数を返した手法が, この外部目標を達成するとは限らない。各最終モデルの品質達成を別に評価する。

3.2 再評価用の統一単価と過去の費用記録

探索の再評価には、変更しない単一の候補記録スナップショットを用いる。論理キーにはデータセット、次元数、学習シード、指定 epoch 数、早期停止の有無、 β が含まれる。構造、尤度、データ分割はデータセット設定で固定する。品質アンカーを含め、要求した一意なキーごとに、そのスナップショットの所要時間を 1 回だけ計上する。したがって異なる方策が同じキーを要求した場合、指標も単価も同じである。これは保存記録を対応付けて利用したものであり、独立の再学習ではない。

過去の手法別費用記録では、同じ論理キーに異なる所要時間が付いていることがある。検証・test の集計指標が完全に一致しても、過去の重みと実行識別子が欠けているため、checkpoint の同一性は証明できない。このため、新たな方策比較ではそれらの単価を混在させない。付録 B.1 に過去の費用計上を残し、補足 CSV でアンカー・最終モデルの各役割をキー、出典、利用可能な 2 種類の時間に対応付ける。各再評価での品質アンカーとその単価には同一記録を用いる。

要求候補の統一単価の合計を C_{cand} 、9 個の AE からなる参照モデル群の記録済み学習費用を C_{ref} とする。初回利用 (cold) では ID 方策に $C_{\text{cand}} + C_{\text{ref}}$ を課し、参照群が構築済みの再利用 (warm) では C_{cand} を課す。1 データセットで 5 シードと 5 重みを扱う 25 課題の一括利用では、課題当たり $C_{\text{ref}}/25$ を配分する。この配分によって、共有参照群に基づく結果が独立な ID 反復になるわけではない。いずれの費用にも、記録のない ID 計算時間や一部の学習後評価時間は含まれない。これは帰属させた学習費用の推定であり、新たに測定した一連の処理の実時間ではない。過去のプローブ評価と FONDUE の校正費用は、探索再評価の方策とは別に報告する。

3.3 出力と終了状態

各試行では、返された未変換の次元数、評価したモデルの次元数、該当する場合の ID 信頼性判定、代替探索への切替 (fallback)、記録された終了状態、予算フラグ、品質達成、最終次元がアンカーより小さいかを記録する。これらの事象は重なり得る。特に、fallback でも品質目標を満たす小容量モデルを返すことがある。旧ログの SUCCESS は通常終了を意味し、それ自体は品質目標達成の証拠ではない。

予算超過試行も、消費時間と、モデルが返されていればその次元数・指標を集計に含める。未変換の次元数が 1 未満なら退化出力として報告する。その時間と失敗件数は残すが、最終モデルが存在しないため MSE は欠測とする。元の実装は呼出しの完了後に予算を確認し、その後も最終モデルを取得し得る。したがって制限は強制中断ではなく、費用計上上のソフトな上限である。結果表ではこれらを区別する。

3.4 参照モデル群と信頼性検査

参照モデル群は 3 種類の次元数と固定した 3 参照シードを用い、5 候補シード間で共有する。参照次元 r における TwoNN 推定値の平均を $\bar{d}_r$ 、 $\hat{d} = \text{mean}_r \bar{d}_r$ 、同じ参照群にわたる MLE 推定値の平均を $\bar{d}_{\text{MLE}}$ とする。検査は次式である。

$$R = \frac{\max_r \bar{d}_r - \min_r \bar{d}_r}{\text{median}_r \bar{d}_r} \leq 0.15, \quad A = \frac{|\hat{d} - \bar{d}_{\text{MLE}}|}{\hat{d}} \leq 0.25. \quad (2)$$

$c = 2$, $R_{\text{max}} = 0.15$, $A_{\text{max}} = 0.25$ は、9 月 12–13 日の仕様に記録された内部的な経験則である。係数 2 には幾何学的な動機があるが、この統計的課題に対して導出された値ではない。信頼性の許容値も、

誤棄却率に対して校正したものではない。品質許容幅の実験で正当化するのではなく、数値が果たす役割を事後解析で調べる。

3.5 事後的に定義した探索方策

以下の再評価手順は、先の結果と査読を受けて 9 月 19 日に定義した。全グリッド参照は $m^* = \min\{m \in \mathcal{M} : D_s(m, \beta) \leq T_{D,s}\}$ を返す。昇順探索はアンカーを取得した後、次元数を小さい順に調べ、最初の合格で停止する。再構成誤差の単調性を仮定せずに m^* を同定できる。従来の ID 手順は、ID が採用されれば低次元側の探索窓をすべて評価し、採用されなければ最小 MSE を選ぶ粗い探索を行う。実行された手順全体の疑似コードを付録 C.1 に残す。

改訂した ID-local は、ID から網羅的な探索窓を作る代わりに、開始次元を選ぶ。開始点が合格なら小さい側へ進んで最初の不合格で止まり、不合格なら大きい側へ進んで最初の合格で止まる。多数の候補を省略できる一方、合否列が単調でない場合には、より小さな適格次元を見逃し得る。ID 参照群が棄却された場合は、従来の粗い MSE 探索ではなく昇順 Q 探索へ切り替える。この fallback の変更も、事後的に定義した方策の一部である。

アルゴリズム 1 (ID-local の再評価と開始次元数の対照).

入力：グリッド、シード、重み、検証記録と統一単価、参照群、 c , $R_{\max}$, $A_{\max}$ 。test 指標は使用しない。

1. 最大次元数を 1 回要求し、式 1 から目標を計算する。検証 MSE がその目標以下なら合格とする。
2. ID-local と ID-gated midpoint では、参照群の費用を計上して式 2 を計算する。いずれかの閾値を満たさなければ、次元数を昇順に要求し、最初の合格を返す。参照群を使わない中点方策はこの段階を省く。
3. ID を採用した ID-local では、 cd 以上の最小グリッド次元から開始し、該当次元がなければ最大次元数に制限する。どちらの中点方策も、0 始まりの添字 $\lfloor (|\mathcal{M}| - 1)/2 \rfloor$ から開始する。
4. 開始点が不合格なら、より大きい次元数を順に要求し、最初の合格を返す。アンカーがあるため、品質を満たす次元数を必ず返せる。
5. 開始点が合格なら、隣接する小さい次元数を降順に要求し、最初の不合格または最小次元に達した時点で、最後の合格を返す。
6. 任意の最小性確認付き ID 方策では、局所解より小さい未照会の次元数を昇順に調べ、最初の合格で停止する。これにより単調性を仮定せず全グリッド最小値を確認できる。
7. 異なる候補はそれぞれ 1 回だけ計上する。次元数、要求キー、要求数、参照群・候補の費用、soft budget フラグを返す。選択を固定してから test 指標を付加する。

全グリッド Q 、昇順 Q 、従来経路、ID-local、参照群を使わない midpoint-local、最小性確認付き ID-local を、データセット・重み・シードの全 100 条件で再評価する。追加の ID-gated midpoint 対照で 100 再評価を加え、合計 7 方策・700 行とする。経路は保存グリッド内（異なる候補は最大 12 個）で完了させ、元の制限時間はこの反実仮想評価を打ち切るためでなくフラグとして記録する。従来方策の行では、元の fallback を含め、実行された経路と出力を保持する。品質、次元差 $m - m^*$ 、完全一致、候補要求数、統一費用を報告する。参照群を使わない中点方策は信頼性判定と fallback も除くため、ID-local との比較だけでは開始次元数の効果を分離できない。ID-gated midpoint では、これらの構成要素と費用計上を固定し、ID 採用時の開始次元数だけを変更する。中点は固定した対照であり、調整済みまたは普遍的に最適な開始点ではない。

係数集合 $\{1, 1.5, 2, 3, 4\}$ は以前の設定を引き継ぐ。事後解析の信頼性グリッドは $R_{\max} \in \{0.10, 0.15, 0.25, 0.50\}$, $A_{\max} \in \{0.15, 0.25, 0.40, 0.85, 2.00\}$ とする。厳しい設定と、観測されたデータセット判定の両側の設定を含める。最も緩い値はストレス試験であり、推奨既定値ではない。これらのパラメータと 100 記録条件の全 10,000 組合せを残し、最も良い閾値で元の既定値を置き換えること

はしない。

4 理論的背景

理想的な滑らかな d 次元多様体について、Whitney の埋め込み定理は $\mathbb{R}^{2d}$ への埋め込みを与える [23]。単射の符号器を通じた厳密かつ連続な再構成には埋め込みが必要となる。しかし、雑音を含む有限標本の ID 推定や近似的なニューラル再構成が、これらの仮定を自動的に満たすわけではない。したがって係数 2 は評価対象の経験則であり、品質保証でも、測定 ID から推論した下界でもない。

線形ガウス潜在変数モデルでは、情報を持つ方向は共分散のスペクトルと雑音尺度に依存する。線形 VAE と事後崩壊の解析はこの関係を明確にしている [9, 24]。VAE と主成分方向との整合も研究されている [25]。これらは正則化が座標利用にどう影響するかを測定する動機となるが、非線形 VAE の AU を内在次元や最小埋め込み次元と同一視するものではない。AU は潜在座標系と計数用の閾値にも依存する。

5 実験設定

5.1 データ、構造、最適化

表 2 に、実際の画像データ設定を示す。MNIST[26]、Fashion-MNIST[27]、CIFAR-10[28] では、公式の学習用・test 用データ集合から無作為に部分集合を取り出す。シード 20260912 の順列で学習用 20,000 例を選び、別のシード 20260913 の順列で 90:10 に分割する。test の 3000 例にはシード 20260914 を用いる。公式の学習・test 分割がない dSprites[29] では、737,280 画像の 1 つの順列の先頭 20,000 個と続く 3000 個を重複しないデータ集合とする。20,000 個を 90:10 に分け、各添字リストを読み込み前に整列する。画像は $[0, 1]$ にスケーリングし、データ拡張は行わない。学習シードは 42, 123, 777, 2024, 31337 であり、分割は学習シードによらず固定する。

表 2: 候補 VAE の画像データ設定。すべて 18,000 学習例、2000 検証例、3000 test 例を用いる。G: ガウス, B: ベルヌーイ。予算は記録時間の上限であり、候補学習呼出しの共通上限は 12 回。ID 参照 AE は別途加わる。

データセット	入力	尤度	候補次元数	予算 (秒)
MNIST	$1 \times 28 \times 28$	G	2, 4, 6, 8, 10, 12, 16, 20, 24, 32, 48, 64	1470
Fashion-MNIST	$1 \times 28 \times 28$	G	MNIST と同じ	1470
dSprites	$1 \times 64 \times 64$	B	MNIST と同じ	5163
CIFAR-10	$3 \times 32 \times 32$	G	8, 16, 24, 32, 48, 64, 96, 128, 192, 256	2924

MNIST と Fashion-MNIST の符号器は、幅 512 と 256 の全結合層、ReLU 活性化、平均と対数分散を別々に出力する線形ヘッドを持つ。復号器は幅 256 と 512 の層を持ち、出力は線形とする。CIFAR-10 の符号器のチャンネル数は 32, 64, 128 であり、dSprites では 256 を追加する。畳み込みはカーネル 4, スライド 2, パディング 1, ReLU を用い、 4×4 の特徴マップの後に線形の事後分布ヘッドを置く。線形写像と ReLU, 逆順の転置畳み込み、最後の sigmoid で復号器を構成する。ID 参照 AE は入力を平坦化し、幅 $512-256-r$ の全結合符号器とその逆順の復号器、線形出力を用いる。候補 CNN とは別のモデルである。

通常の候補モデルには Adam, 学習率 10^{-3} , 既定のモーメント (0.9, 0.999), $\epsilon = 10^{-8}$, 重み減衰なし, バッチサイズ 128, 最大 300 epochs を用いる。最後のバッチは 80 例であり, 1 epoch 当たり 141 更新となる。ID 参照 AE には同じ最適化器とバッチサイズを用い, 100 epochs 学習する。早期停止の patience は 30 とする。記録上の plateau フラグは, 直近 50 個の検証監視値について $(\max h - \min h) / |\text{mean } h| < 0.01$ を要求するが, 追加の停止規則ではない。代表的な学習推移を調べる実行は, 常に 300 epochs を完了する。

候補モデルの学習損失を次式とする。

$$\mathcal{L}_\beta = \frac{1}{B} \sum_{i=1}^B \left[\ell(x_i, g(z_i)) + \beta \sum_{j=1}^m \frac{\mu_{ij}^2 + \exp(v_{ij}) - 1 - v_{ij}}{2} \right], \quad z_i \sim q_\phi(z | x_i), \quad (3)$$

ここで v は対数分散である。ガウス再構成には二乗誤差和を用い, これは加法定数を除けば観測分散 $1/2$ の固定に等しい。dSprites には二値交差エントロピーの和を用いる。主設定の重みは 1, 走査する値は $\{0.25, 0.5, 1, 2, 4\}$ で, 各実行中は一定とする。周期的アニーリング [30] は用いない。尤度が異なる場合, 数値上同じ β でも同じ正則化強度とは限らない。

保存された「ELBO」という名前の検証監視値は, $h = -[\ell(x, g(\mu(x))) + \text{KL}]$ を例ごとに平均したものである。事後標本に関する期待値ではなく事後平均による再構成を使うため, これは *ELBO の代理値 (proxy)* であり, 不偏な ELBO 推定値でも保証された下界でもない。学習時に別の β を用いた場合も, checkpoint 選択では KL 重みを 1 にする。本研究はこれらの checkpoint を保持し, 監視値を正確に呼び分ける。選択コードに test 指標は入らない。ただし, 候補キャッシュは手法による選択前に, 学習した全候補の test 指標を評価するため, 最終 test 評価を 1 回しか実行していないという主張は正しくない。表では検証データで選択したモデルの test 指標だけを示す。これは選択と評価のコード上の分離であり, test を事前に封印した手順ではない。

5.2 手法と読み取り

グリッド探索は, 検証 MSE, ELBO proxy, または線形プローブの検証正解率で選択する。プローブは事後平均, 多項ロジスティック回帰, 最大 2000 反復を用い, $C \in \{0.01, 0.1, 1, 10\}$ を検証データで選ぶ。ラベルは数字, 衣服, CIFAR のクラス, および dSprites の 3 形状である。プローブによる選択では, 容量とプローブ正則化の両方に検証ラベルを用いる。潜在表現の中心化, スケーリング, 白色化は行わず, ロジスティック回帰には既定の切片を用いる。粗い探索はアルゴリズム A1 の部分集合を使い, 固定基準には次元数 32 を用いる。

FONDUE は, TwoNN と固定した ID 差閾値 $0.2d_0$ を使う本研究の PyTorch 実装である。通常の候補グリッドの外も含む整数次元を探索し, 選ばれた次元をそのまま学習する。 $\beta = 1$ での短期学習は, MNIST と dSprites で 1 epoch, Fashion-MNIST と CIFAR-10 で 2 epochs とする。dSprites では原著の epoch 設定を使う。他ではシード 42 で校正し, 連続する 2 回の予測が一致するまで epoch 数を増やし, 最大 5 で止める。一致判定は 1 epoch と 2 epochs の実行後に初めて行う。 $e - 1$ と e の予測が一致したら返す epoch 数は $e - 1$ であり, 両方の校正費用を計上する。他の β ごとの値は付録 C に示す。FONDUE+Q は返却次元をグリッド上で上側に丸め, アンカーを取得し, 品質を満たすか予算フラグが立つまで大きい側へ拡張する。これは FONDUE に外部の再構成規則を追加したものである。

FONDUE-VAR は $\text{round}(2d_0)$ から始め, 定めた型条件が成立するまで次元数を倍増する。混合型を保持する設定では, 非活性型が現れた時点で活性型と混合型の合計を返す。保持しない設定では, 混合

型または非活性型が現れた時点で活性型の個数を返す。記述に基づく分類器を実装し、対数分散から事後分散への指数変換は **1 回だけ** 行う。ある座標の事後分散について、データ間分散が 0.1 未満で平均が [0.9, 1.1] なら非活性型、データ間分散が 0.1 未満で平均が 0.1 以下なら活性型、それ以外を混合型とする。監査した公開コードの版を付録 C.3 に示すが、そのコードのすべての実行経路や公表実験設定を再現したとは主張しない。

AU はこれとは独立に次式で定義する。

$$AU_{\delta} = \sum_{j=1}^m \mathbf{1}\{\text{Var}_{x \in X_{\text{est}}} \mu_j(x) > \delta\}, \quad \delta \in \{10^{-3}, 10^{-2}, 10^{-1}\}, \quad (4)$$

主設定は $\delta = 10^{-2}$ とする。AU、変数型、品質目標の下限に用いる例間分散の分母は n (母分散) であり、報告するシード間 SD の分母は $n - 1$ とする。ID と活性度の読み取りには、シード 20260915 で非復元抽出した同じ 10,000 学習例を用いる。MLE の照合には $k = 10$ 近傍を用いる。AU は診断量であり、手法比較に追加する選択器ではない。

従来の GECO・ARD 変更実装は最大グリッド次元から開始し、300 epochs 実行する。未変換の座標個数を最近傍の候補次元へ写し、同距離なら小さい次元を選んで、最終的な通常 VAE を評価する。ローカルな目的関数、更新、読み取りの相違を付録 C.3 に示す。したがって評価した MSE は元のモデルではなく、次元転用先の通常 VAE のものである。

5.3 実行環境と事前仕様の範囲

保存された画像実験の環境は、Python 3.12.3, PyTorch 2.7.1+cu118, CUDA 11.8, cuDNN 90100 (9.1.0), NVIDIA driver 570.211.01, NVIDIA GeForce RTX 3070, Linux 6.8.0-124-generic, x86-64, glibc 2.39 である。これらの実験には GPU の環境記録があり、GPU 学習に加えて CPU で数値処理とプローブ評価を行う。以前の MAKE47 にも PyTorch 2.0, RTX 3070, CPU への切替は記載されていたが、CUDA・cuDNN・driver の完全な環境は示されていないかった。

設定ファイルは 2026 年 9 月 12 日に作成し、9 月 12–13 日の変更も記録した。これらは内部の仕様記録であり、公開の事前登録ではない。dSprites の尤度など、一部の変更には校正結果が反映されている。剪定法の追加と重みの全走査は 9 月 14–17 日に実行した。対応付き無作為特徴量比較と最初の費用監査は、9 月 18 日付の事後的改訂である。探索の再評価、閾値の全組合せ解析、正規化した ARD の読み取り、限定的なモデル検証は 9 月 19 日に追加した。MNIST など既に調べたデータセットを、科学的に完全に未見の条件とは呼ばない。予測解析でいう「評価条件」は、その予測器の適合に使わなかった条件を意味する。

記録されたコード識別子 8c2c6c28224b3450 は、共通モジュールと設定だけのハッシュであり、実験実装全体のハッシュではない。以前の学習推移記録の識別子は 99cb5eb7404ff6e7 である。新たな SHA-256 ファイル一覧で、確認したスナップショットを特定する。付録 G に、数値結果と元ファイルの対応、来歴に関する残る制約を示す。

5.4 範囲を限定した新規モデル検証

MAKE49 の学習済みモデルは、互換性のある checkpoint としては利用できない。実際の ELBO を評価するため、同じ 18,000/2000/3000 分割、構造、最適化器、300 epochs の上限、patience 30 を用い、 $\beta = 1$ 、シード 42 で独立の MNIST グリッドを学習する。これは CPU 上の 1 シード検証実験で

あり、5 シードの CUDA 比較を置き換えるものではない。環境は macOS 26.6.2 (arm64), Python 3.11.11, PyTorch 2.7.1, NumPy 2.3.2, CPU 4 スレッドである。この実験の時間を GPU 記録と比較しない。

各次元では事後平均 proxy が最良の checkpoint を保持し、その後、次式を評価する。

$$\hat{\mathcal{L}}_K = \frac{1}{nK} \sum_{i=1}^n \sum_{k=1}^K \log p_{\theta}(x_i | z_i^{(k)}) - \frac{1}{n} \sum_{i=1}^n \text{KL}\{q_{\phi}(z | x_i) \| p(z)\}, \quad z_i^{(k)} \sim q_{\phi}(z | x_i). \quad (5)$$

$K = 32$, 評価シードは 20260919, $p_{\theta}(x | z) = \mathcal{N}(g_{\theta}(z), \frac{1}{2}I)$ とする。ガウス分布の正規化定数も含める。同じ 64 次元の正規乱数を、小さな次元では切り詰めて用いる。Monte Carlo 標準誤差 (MC SE) は、32 回の標本化ごとに求めた検証平均の標本 SD を $\sqrt{32}$ で割った値であり、学習シードの不確実性ではなく評価時の雑音を表す。検証 MSE, proxy, 推定 ELBO の各基準で別々に容量を選び、選択をファイルに記録してから test を評価する。したがってこの ELBO 比較は、*proxy で選ばれた checkpoint 群*から容量を選ぶものであり、各 epoch を ELBO で選び直す比較ではない。

別の MNIST・シード 42・300 epochs の実行では、ローカルな hard-concrete (HC) 剪定実装の挙動を記録する。目標は新しい通常 VAE の 64 次元アンカーから定める。native モデルの再構成、制約、ゲート、乗数の推移を保持し、native の出力と次元転用後の出力を比較する。これは 1 条件で当該ローカル実装の挙動を調べるものであり、ARM の再現でも、データセット横断で妥当性を確認した剪定基準でもない。これらの独立した MNIST の通常 VAE・HC 実行については checkpoint を保存した。

5.5 データセット横断の追加分検証

追加実験は、同じ 4 データセットと固定分割、シード 42, 123, 777, 最大候補次元 (64, CIFAR-10 では 256), 300 epochs を用いる。ARM は 12 実行、事前分布の中心に関する 2 設定を含む ARD は 24 実行であり、その後に標本中心の ARD 変種について 12 件の native 剪定評価を行う。いずれも 5.3 節に示した RTX 3070, Python, PyTorch, CUDA, cuDNN, ドライバ, OS と同じ環境を用いる。これらは過去の 5 シード比較および MNIST・1 シード容量研究とは別である。3 シードの集計には標本 SD を用いる。同じシードの反復と共通分割は、独立したデータセットの反復検証ではない。

ARM 実装は対をなすベルヌーイゲートを用い、各例の損失差を計算してからゲート勾配推定値を平均する。提供された線形損失の検査では、この推定量を解析勾配と照合する。再構成制約は dSprites を含む全データセットで二乗誤差和を用いる。閾値は通常の $\beta = 1$ アンカーの決定論的検証 MSE に 1.10 と画素数を乗じた値である。ネットワーク損失にはゲートでマスクした KL の和と制約の乗数を含め、移動平均制約を満たすときに期待ゲート数の罰則を適用する。native 評価はゲート確率が 0.5 を超える二値マスクを用いる。この同じマスクで、事後平均による検証・test MSE と、事後 32 標本で平均した検証 MSE を報告する。

これは構成要素の検証であり、原著アルゴリズムの厳密な再現ではない [7]。ローカルなゲートは確率 0.5 で開始して直ちに更新され、制約を初めて満たすまで開いたままにする処理を用いない。KL もマスク後の和であり、原著の活性個数で正規化した量とは異なる。アンカー由来の閾値とローカルなゲート更新設定にも相違がある。したがってローカルな実行の失敗から、公表手法の失敗を結論できない。最終時点の学習制約充足と決定論的な検証 Q は異なる事象であり、表では分けて示す。

ARD 実装は学習時の重みを 1 に固定し、学習用プール 18,000 例の先頭 1800 例を事前分布の更新用に確保する。残る 16,200 例をパラメータの勾配更新に用いる。事前分布の更新用プールは固定し、

epoch 1, 11, ..., 291 および学習後に潜在標本を再生成する。これは原著の再標本化するプールと調整済み正則化重みとは異なる [8]。原著の設定であるゼロ中心の分散更新と、標本平均を中心とする分散更新をそれぞれ別に学習して評価する。どちらもガウス閉形式 KL における事前平均はゼロに保つ。

最終モデルで、検証集合の先頭 100 例の事後平均における復号器やコピアンを自動微分で評価する。事前分散 v_j と復号器出力座標 ℓ について、スコアを次式とする。

$$w_j = \frac{1}{100} \sum_{i=1}^{100} \sum_{\ell=1}^p \left(\frac{\partial g_{\ell}}{\partial z_j} (\mu(x_i)) \right)^2, \quad s_j = w_j v_j. \quad (6)$$

スコアの降順累積が総和の 99% に達するまでの個数を読み取り値とする。厳密とは有限摂動の代わりに自動微分を用いることを指し、標本や学習の不確実性を除くものではない。最初の ARD 比較は未剪定の全次元モデルを評価する。後述のマスク実験では、保持した軸を評価する。両手法で、次元転用は個数を最近傍の候補次元へ写像し、同じシードの保存済み通常 $\beta = 1$ VAE を評価する。

最初の ARM 12 実行と ARD 24 実行は、5 epochs ごとの評価モード MSE 曲線を保存する。ARM は学習 2000 例の部分集合を用いる。ARD の学習用プール部分集合には事前分布更新専用の例を含むため、その旨を明記する。記録された学習時間はこれらの定期評価を含む。ARM は最終 native 評価時間も記録する。ARD はヤコビアン時間を別に記録するが、最終 native 評価時間は記録しない。これらは部分的な時間計測である。追加スクリプトはモデル checkpoint を保存しない。

■Native ARD のマスクと固定予算での復号器微調整 提供された内部仕様では、新しいマスク実験の実行前に、全次元モデル、非選択軸のマスク、復号器のみの微調整、次元転用の 4 条件を定めている。これは公開の事前登録ではない。学習スクリプトは、各データセットの同じ 3 シードについて標本中心の分散更新設定を繰り返す。全次元モデルの検証・test MSE と選択個数は、先行する標本中心の記録と完全に一致する。したがって同じ設定に対する対応のある拡張であり、独立した基準モデルの反復検証ではない。各実行では、スコアの高い軸から関連度総和の 99% を説明するまで保持し、他の座標を事前平均のゼロに固定する。マスクはネットワークの次元を維持するため、小さな実行モデルや推論速度の改善を確立しない。マスクは一度だけ計算し、微調整後に選び直さない。

第 3 条件は同じマスク済みモデルから開始し、Adam, 学習率 10^{-3} , バッチサイズ 128 で、復号器パラメータのみを 30 epochs 更新する。符号化器パラメータと事前分布は固定する。目的関数は、マスクした事後標本に対する元の再構成項である。微調整では学習用プール 18,000 例すべてを用い、初期学習で事前分布更新専用だった 1800 例も含む。したがって、マスクのみの条件と比べ、学習データへの接触と計算が追加される。検証に基づく早期停止は適用しない。主要な 4 条件はすべて事後平均による検証・test MSE を用い、マスクのみの条件では 32 事後標本の検証 MSE も診断する。最近傍グリッドへの転用は既存の通常 VAE キャッシュを使い、マスクスクリプトで追加モデルを学習するものではない。test 指標はマスクや固定微調整予算の決定に用いない。

ヤコビアンスコアは引き続き式 (6) である。メモリ使用量を抑えるため、CIFAR-10 は 4 例ずつのバッチを用い、dSprites はヤコビアン全体を生成する代わりに、8 例ずつのバッチで出力座標ごとの勾配の二乗を累積する。これは計算方法の変更であり、スコアの定義の変更ではない。新しい JSON は個数と MSE を保存するが、軸の識別子、スコアベクトル、学習曲線、モデル checkpoint は保存しない。時間計測および記録上の制限を付録 F に示す。

評価コードの監査により、追加 ELBO 欄の用途を制限する。32 標本オプションが変更するのは MSE だけである。再構成尤度は事後平均で評価したままで、KL は ARD を含めてマスクなしの標準正規事

前分布を用いる。これらの欄は、学習された native モデルの Monte Carlo ELBO ではない。native マスクのスク립トも、仕様で真の ELBO を要求しているにもかかわらず、この問題を継承する。これらの欄をすべて除外し、追加記録は MSE, ゲート, 関連度個数, 利用可能な曲線に用いる。容量選択の ELBO の根拠は、引き続き 5.4 節の別途の MNIST 実験である。

6 結果

6.1 探索の判断と統一費用

従来の MNIST 費用差は、最小適格次元が初期探索窓内にあり、 $m_0 < m_a$ で、予算による中断がない場合、構造的に次式で決まる。

$$C_{\text{window}} - C_{\text{ascending}} = C_{\text{ref}} + \sum_{m^* < m \leq m_0} C_m \geq 0. \quad (7)$$

両手順ともアンカーを評価するため、その費用は相殺される。主設定では $\hat{d} = 11.68$ から $m_0 = 24$ となる。探索窓は 2, 4, 6, 8, 10, 12, 16, 20, 24 次元を要求し、昇順探索は 6 で停止する。過去の費用記録の差は $715.4 - 182.0 = 533.4 = 205.5 + (400.7 - 72.8)$ 秒である (付録 B.1)。これはこれらの経路に関する費用計上の恒等式であり、ID 情報の価値を実証的に識別した結果ではない。

表 3 と表 4 は、停止の機会が異なる方策を、単一スナップショットの統一単価で評価する。MNIST での候補要求数は ID-local が 9, 従来の探索窓が 10, 昇順探索が 4 であり、いずれも 6 次元を返す。初回利用の統一費用はそれぞれ 636, 672, 177 秒である。単価を統一したため、これらは過去の費用記録の値とは異なる。midpoint 対照は 6 候補を要求し、費用は 279 秒である。したがって経路の短縮だけでは、ID 固有の利得を示せない。

表 3: $\beta = 1$, 5 シードでの事後的な探索再評価。Q: 目標達成; 一致: 全グリッドの最小適格次元との一致; Δm : 平均超過次元数。呼出し数にはアンカーを含む。費用はキーごとの単一の保存単価に、ID 方策では参照群全体の費用を加えた秒数であり、新たな実時間測定ではない。dSprites はベルヌーイ, 他はガウス尤度。

方策	次元数	Q	一致	Δm	要求数	初回費用
<i>MNIST</i>						
全グリッド Q	6.0 ± 0.0	5/5	5/5	0.0	12.0	572
昇順 Q	6.0 ± 0.0	5/5	5/5	0.0	4.0	177
従来探索窓	6.0 ± 0.0	5/5	5/5	0.0	10.0	672
ID-local	6.0 ± 0.0	5/5	5/5	0.0	9.0	636
midpoint-local	6.0 ± 0.0	5/5	5/5	0.0	6.0	279
ID 最小性確認	6.0 ± 0.0	5/5	5/5	0.0	10.0	672
<i>Fashion-MNIST</i>						
全グリッド Q	4.0 ± 0.0	5/5	5/5	0.0	12.0	645
昇順 Q	4.0 ± 0.0	5/5	5/5	0.0	3.0	209
従来探索窓	6.4 ± 3.3	5/5	3/5	2.4	4.0	457
ID-local	4.0 ± 0.0	5/5	5/5	0.0	3.0	416
midpoint-local	4.0 ± 0.0	5/5	5/5	0.0	7.0	407
ID 最小性確認	4.0 ± 0.0	5/5	5/5	0.0	3.0	416

表 4: $\beta = 1$, 5 シードでの事後的な探索再評価。Q: 目標達成; 一致: 全グリッドの最小適格次元との一致; Δm : 平均超過次元数。呼出し数にはアンカーを含む。費用はキーごとの単一の保存単価に, ID 方策では参照群全体の費用を加えた秒数であり, 新たな実時間測定ではない。dSprites はベルヌーイ, 他はガウス尤度。

方策	次元数	Q	一致	Δm	要求数	初回費用
<i>dSprites</i>						
全グリッド Q	20.0 $\pm$ 4.0	5/5	5/5	0.0	12.0	2563
昇順 Q	20.0 $\pm$ 4.0	5/5	5/5	0.0	9.0	1797
従来探索窓	64.0 $\pm$ 0.0	5/5	0/5	44.0	4.0	999
ID-local	20.0 $\pm$ 4.0	5/5	5/5	0.0	9.0	2092
midpoint-local	20.0 $\pm$ 4.0	5/5	5/5	0.0	4.0	941
ID 最小性確認	20.0 $\pm$ 4.0	5/5	5/5	0.0	9.0	2092
<i>CIFAR-10</i>						
全グリッド Q	24.0 $\pm$ 0.0	5/5	5/5	0.0	10.0	428
昇順 Q	24.0 $\pm$ 0.0	5/5	5/5	0.0	4.0	157
従来探索窓	131.2 $\pm$ 113.9	5/5	0/5	107.2	4.0	499
ID-local	24.0 $\pm$ 0.0	5/5	5/5	0.0	4.0	498
midpoint-local	24.0 $\pm$ 0.0	5/5	5/5	0.0	5.0	213
ID 最小性確認	24.0 $\pm$ 0.0	5/5	5/5	0.0	4.0	498

局所探索は要求数を減らし得る。dSprites では, midpoint-local の要求数は昇順探索の 9 に対して 4 であり, 統一費用は 1797 秒に対して 941 秒で, 主設定の各シードで同じ適格次元を返す。このデータでは ID が棄却されるため, ID-local は昇順探索を行ったうえで参照群の費用も負担する。データセット・重み・シードの全 100 条件では, ID-local とその最小性確認付き変種は全 100 条件で全グリッド最小値と一致する。midpoint-local は 98 条件で一致し, 最大超過次元数は 8 である。これら新方策の出力はすべて検証目標を満たし, 再評価で元のソフト費用上限を超えるものはない。これは既に学習したグリッドに条件付けた観測であり, 新たなデータへの保証ではない。

6.2 信頼性判定と fallback を固定した開始次元数の比較

追加アブレーションでは, ID の採用判定, 昇順 fallback, 参照群の費用計上を維持し, 採用時の開始点だけを中点へ変更する (表 5)。両方策は全 100 条件でまったく同じ次元数を選ぶ。ID を採用するのは MNIST の 25 条件だけであり, そこでは ID-local の候補要求数が 8.84 であるのに対し, 判定付き中点对照では 5.84 である。初回利用の統一費用はそれぞれ 705.2 秒, 537.7 秒となる。したがって ID 由来の開始点には選択上の利益が観測されず, 実際に ID を用いる層で処理量が増える。残る 75 条件では, 両方策とも同じ昇順 fallback を使う。

表 5: 各データセットで 5 重み・5 候補シードにわたる開始次元数のアブレーション。ID 採用は MNIST の 25 条件, fallback は他 3 データセットの 75 条件である。ID-local と ID-gated midpoint は同じ信頼性判定, fallback, 参照群の費用計上を用いる。参照群を使わない中点方策は別方策である。一致は全グリッド最小値との一致を表す。費用は初回利用の統一秒数であり, 新しい実時間測定ではない。

層	方策	n	一致	要求数	初回 (秒)
ID 採用	ID-local	25	25/25	8.84	705.2
ID 採用	ID-gated midpoint	25	25/25	5.84	537.7
ID 採用	midpoint-local	25	25/25	5.84	330.2
ID 採用	昇順 Q	25	25/25	4.12	195.1
fallback	ID-local	75	75/75	5.24	995.8
fallback	ID-gated midpoint	75	75/75	5.24	995.8
fallback	midpoint-local	75	73/75	5.11	533.0
fallback	昇順 Q	75	75/75	5.24	714.7
全体	ID-local	100	100/100	6.14	923.1
全体	ID-gated midpoint	100	100/100	5.39	881.3
全体	midpoint-local	100	98/100	5.29	482.3
全体	昇順 Q	100	100/100	4.96	584.8

参照群を使わない中点方策の誤り 2 件は, Fashion-MNIST (シード 31337, $\beta = 0.25$: 最小値 6 に対して 12 次元) と dSprites (シード 31337, $\beta = 4$: 最小値 8 に対して 16 次元) で生じる。どちらも ID を棄却した条件である。したがって, この方策の 98/100 に対する ID-local の 100/100 という完全一致数の差は, fallback の違いを反映しており, ID 由来の開始点が選択を改善する証拠ではない。昇順 Q も全 100 条件で最小値に一致し, 初回取得ではどの条件でも ID-local より費用が小さい。共通のアンカーがあるため, 保存グリッド内での品質達成は構成上保証される。情報を与える比較対象は, 厳密な最小性と費用である。

6.3 係数, 信頼性, 再利用に対する感度

MNIST の主設定では, c を 1 から 4 に変えても選択次元は 6 のままだが, ID-local の要求数は 6 から 11 へ, 初回費用は 487 秒から 743 秒へ変わる。元の信頼性閾値では, 他の 3 データセットはどの係数でも同じ昇順 fallback を用いる。したがってその不変性は, ID 係数が頑健である証拠にはならない。

$c = 2$ で $A_{\max}$ を 0.40 まで緩めると Fashion-MNIST で ID を採用し, 主設定の要求数が 3 から 10 へ増えるが, 選択次元は改善しない。0.85 では CIFAR-10 でも ID を採用する。dSprites の採用にはさらに, $R_{\max} = 0.50$, $A_{\max} = 2.00$ という緩いストレス設定が必要となる。このように閾値は, ID が実際に判断へ関与するデータセットを変える。表 A4 と表 A5 に主設定の全係数結果と代表的な信頼性の対比を示し, 補足資料には全組合せの各行を含める。

感度解析の全 10,000 行で品質は満たされるが, 155 出力は全グリッド最小値を逃し, 最大超過次元数は 56 である。見逃しはすべて $\beta = 1$ 以外で生じる。1 設定で見かけ上単調であっても, 局所停止の最小性を保証できない理由がここにある。各行は記録と参照群を再利用しており, 10,000 は再評価設定の数であって独立した実験反復数ではない。表 6 で, 初回利用, 構築済み参照群の再利用, 25 課題で参照群の 1 回分の構築費を共有する利用を区別する。

表 6: 5 重みと 5 候補シード (各データセット 25 課題) にわたる ID-local の費用。初回利用は毎回参照群を計上し、再利用は構築済み参照群を前提とする。一括利用は 1 回の参照群学習費用を 25 課題に配分する。いずれも記録のない ID・評価の処理時間を除く。非単調は、次元増加に伴い合格から不合格へ変わる合否列の件数。

データセット	参照群 (秒)	初回 (秒)	再利用 (秒)	一括 (秒)	一致	非単調
MNIST	207.5	705.2	497.7	506.0	25/25	1/25
Fashion-MNIST	207.1	352.9	145.8	154.1	25/25	2/25
dSprites	295.8	2127.2	1831.4	1843.3	25/25	13/25
CIFAR-10	340.5	507.2	166.7	180.3	25/25	4/25

6.4 記録された選択器の品質

表 7 と表 8 には、 $\beta = 1$ での通常の実験結果を残し、5 学習シードの標本 SD を示す。モデル次元数、検証・test 誤差、目標達成を報告し、時間記録は新たな再評価の統一単価と分ける。既存の ARD・GECO 行はこの主比較から除き、元の結果と追加確認を付録 C.3 の実装監査にまとめる。

表 7: $\beta = 1$ での次元選択 (ガウス尤度)。値は 5 候補学習シードの平均 $\pm$ 標本 SD。 m_{final} は評価した通常 VAE の次元数。MSE は 10^3 倍し、 Q は検証目標の達成数。過去の時間記録は付録 B.1 に分け、再評価費用には単一の統一スナップショットを用いる。

手法	m_{final}	検証 MSE	test MSE	Q
<i>MNIST</i>				
グリッド (MSE)	12.8 ± 6.4	20.98 ± 0.24	20.50 ± 0.26	5/5
FONDUE	7.0 ± 0.0	21.93 ± 0.77	21.54 ± 0.78	5/5
FONDUE + Q	8.0 ± 0.0	21.72 ± 0.50	21.33 ± 0.55	5/5
昇順 + Q	6.0 ± 0.0	22.44 ± 0.15	22.05 ± 0.17	5/5
従来 ID 探索窓	6.0 ± 0.0	22.44 ± 0.15	22.05 ± 0.17	5/5
<i>Fashion-MNIST</i>				
グリッド (MSE)	22.8 ± 15.6	18.33 ± 0.20	18.08 ± 0.19	5/5
FONDUE	6.8 ± 0.4	19.29 ± 0.16	19.01 ± 0.16	5/5
FONDUE + Q	7.6 ± 0.9	19.00 ± 0.33	18.75 ± 0.34	5/5
昇順 + Q	4.0 ± 0.0	19.38 ± 0.24	19.06 ± 0.25	5/5
従来 ID 探索窓	6.4 ± 3.3	19.03 ± 0.61	18.73 ± 0.57	5/5

表 8: $\beta = 1$ での次元選択 (dSprites はベルヌーイ, CIFAR-10 はガウス尤度)。値は 5 候補学習シードの平均 $\pm$ 標準 SD。 m_{final} は評価した通常 VAE の次元数。MSE は 10^3 倍し, Q は検証目標の達成数。過去の時間記録は付録 B.1 に分け, 再評価費用には単一の統一スナップショットを用いる。

手法	m_{final}	検証 MSE	test MSE	Q
<i>dSprites</i>				
グリッド (MSE)	57.6 ± 14.3	1.16 ± 0.01	1.15 ± 0.01	5/5
FONDUE	4.2 ± 0.4	5.50 ± 1.31	5.42 ± 1.28	0/5
FONDUE + Q	20.0 ± 4.0	1.26 ± 0.05	1.24 ± 0.05	5/5
昇順 + Q	20.0 ± 4.0	1.26 ± 0.05	1.24 ± 0.05	5/5
従来 ID 探索窓	64.0 ± 0.0	1.17 ± 0.02	1.16 ± 0.03	5/5
<i>CIFAR-10</i>				
グリッド (MSE)	140.8 ± 53.5	13.83 ± 0.04	14.07 ± 0.04	5/5
FONDUE	14.4 ± 0.5	17.79 ± 0.30	18.10 ± 0.30	0/5
FONDUE + Q	24.0 ± 0.0	15.12 ± 0.14	15.36 ± 0.13	5/5
昇順 + Q	24.0 ± 0.0	15.12 ± 0.14	15.36 ± 0.13	5/5
従来 ID 探索窓	131.2 ± 113.9	14.01 ± 0.13	14.25 ± 0.14	5/5

通常の FONDUE は dSprites で約 4 次元を返すが, 検証 MSE は 0.00550 であり, 昇順探索の 0.00126 より大きい。通常終了は品質達成を意味しない。FONDUE+ Q には, 予算を超過してもモデルを返した dSprites の 1 試行があり, そのモデルも集計に残す。独立に数えた各状態の件数は付録 A.1 に示す。Fashion-MNIST, dSprites, CIFAR-10 の従来 ID 行は粗い MSE 探索へ切り替えたものであり, CIFAR-10 の大きな次元変動はその fallback に由来する。ここで自然カラー画像のベンチマークは CIFAR-10 だけである。

6.5 追加 native 剪定・関連度の結果

選択された native 表現の品質と, その次元数を通常 VAE へ転用したときの品質を区別する。個数だけでは剪定の成功を測れない。過去と追加の読み取り値の比較は付録 F にまとめる。

表 9 は native 再構成, 次元転用, 最終時点の制約充足を区別する。MNIST と Fashion-MNIST では, native の事後平均再構成は 3 シードすべてで Q を満たす一方, 学習制約を満たすのは 2 シードだけである。dSprites の 3 実行はいずれも両方の検査に不合格だが, 転用先の通常 VAE は Q を満たす。native MSE は約 0.04236 であり, 全 64 ゲートの確率が 0.1 から 0.9 の間に留まる (付録 F)。したがって, 閾値を超える 48–62 という個数は, 安定した疎な解を示さない。CIFAR-10 で native の平均再構成 Q を満たすのは 1 シード, 学習制約を満たすのは 2 シードである。これらはローカル実装の限界を示す。

表 9: 新しいローカル ARM 実装。3 シード (42, 123, 777), 300 epochs。次元数と検証 MSE (10^3 倍) は平均 $\pm$ 標準 SD, 括弧内は外部目標 Q の達成数。平均再構成・標本再構成はともに学習済み二値ゲートマスクを用い, 標本再構成は事後 32 標本による。転用は最近傍のグリッド次元における別の通常 VAE を指す。制約は最終時点の確率的学習制約の達成であり, Q とは異なる。

データセット	ゲート数	native 平均 (Q)	native 標本 (Q)	転用 (Q)	制約
MNIST	7.7 ± 0.6	21.88 ± 0.26 (3/3)	27.36 ± 0.70 (0/3)	21.63 ± 0.70 (3/3)	2/3
Fashion-MNIST	4.7 ± 0.6	19.31 ± 0.20 (3/3)	22.76 ± 0.22 (0/3)	19.28 ± 0.23 (3/3)	2/3
dSprites	54.0 ± 7.2	42.36 ± 0.00 (0/3)	42.36 ± 0.00 (0/3)	1.17 ± 0.03 (3/3)	0/3
CIFAR-10	21.0 ± 2.6	15.33 ± 0.57 (1/3)	17.16 ± 0.34 (0/3)	16.46 ± 1.17 (1/3)	2/3

native ARM の標本再構成 MSE は, すべての実行で決定論的アンカー由来の目標を上回る。この比較は再構成の定義を変えた影響を示すものであり, 標本再構成アンカーから定めた目標による選択実験ではない。また, 平均再構成の Q から学習制約の状態を推論できない理由も示している。

厳密ヤコビアン ARD のゼロ中心での読み取り値は, MNIST, Fashion-MNIST, dSprites, CIFAR-10 で, それぞれ 6.0, 4.0, 9.0, 26.7 である (表 10)。標本中心の変種は 6.0, 4.0, 9.7, 26.3 となる。この 3 シードでの小さな差は, 限定的な中心化感度の観測を支持するもので, 事前分布の指定に対する不変性ではない。両設定とも, dSprites 以外の 3 データセットでは全次元モデルと転用先が Q を満たし, dSprites では両方とも未達となる。これらの最初の評価では, 非選択軸をマスクしていない。

表 10: 新しい厳密ヤコビアン ARD 実装。各設定 3 シード, 300 epochs。事前分布更新の中心はゼロまたは潜在標本平均。個数は関連度の読み取り値であり, 全次元は未剪定の初期次元モデルを表す。その個数へ削減したモデルではない。転用は最近傍のグリッド次元の通常 VAE である。MSE は 10^3 倍, 平均 $\pm$ 標準 SD, 括弧内は Q 達成数。

データセット	中心	個数	全次元 MSE (Q)	転用次元	転用 MSE (Q)
MNIST	ゼロ	6.0 ± 0.0	23.48 ± 0.59 (3/3)	6.0 ± 0.0	22.51 ± 0.15 (3/3)
MNIST	標本平均	6.0 ± 0.0	23.61 ± 0.18 (3/3)	6.0 ± 0.0	22.51 ± 0.15 (3/3)
Fashion-MNIST	ゼロ	4.0 ± 0.0	19.27 ± 0.19 (3/3)	4.0 ± 0.0	19.28 ± 0.23 (3/3)
Fashion-MNIST	標本平均	4.0 ± 0.0	19.43 ± 0.08 (3/3)	4.0 ± 0.0	19.28 ± 0.23 (3/3)
dSprites	ゼロ	9.0 ± 0.0	1.33 ± 0.02 (0/3)	8.0 ± 0.0	1.88 ± 0.08 (0/3)
dSprites	標本平均	9.7 ± 0.6	1.33 ± 0.06 (0/3)	9.3 ± 1.2	1.64 ± 0.30 (0/3)
CIFAR-10	ゼロ	26.7 ± 0.6	14.30 ± 0.13 (3/3)	24.0 ± 0.0	15.19 ± 0.12 (3/3)
CIFAR-10	標本平均	26.3 ± 0.6	14.40 ± 0.24 (3/3)	24.0 ± 0.0	15.19 ± 0.12 (3/3)

■選択した ARD 軸を保持した後の品質 表 11 は, 標本中心の変種について, 欠けていた評価を補う。マスクにより, 平均検証 MSE は MNIST, Fashion-MNIST, dSprites, CIFAR-10 で, それぞれ +0.045%, +0.017%, +126.3%, +3.4% 変化する。これらの割合は, 対応する全次元モデルを基準とした 3 シード平均 MSE の比であり, 各シードの変化率を平均したものではない。全次元, マスク, 微調整, 転用の 4 モデルは, dSprites 以外の各データセットでは 3 シードすべてで Q を満たす。dSprites では 4 条件すべてが全シードで未達となる。

表 11: 標本中心の分散更新を用いた ARD 変種の native マスクと復号器微調整。各データセット 3 シード。検証 MSE は 10^3 倍, 平均 $\pm$ 標本 SD。個数は保持軸数。全次元は初期の全軸を用い, マスクは他の軸をゼロに固定する。微調整は復号器のみを 30 epochs 追加更新する。転用は最近傍グリッド次元の別の保存済み通常 VAE を用いる。括弧内は, 各条件で同じ決定論的検証目標 Q を達成した数。dSprites では, 全次元を含む 4 条件すべてが Q に届かない。

データセット	個数	全次元 (Q)	マスク (Q)	微調整 (Q)	転用 (Q)
MNIST	6.0 ± 0.0	23.61 ± 0.18 (3/3)	23.62 ± 0.18 (3/3)	23.36 ± 0.16 (3/3)	22.51 ± 0.15 (3/3)
Fashion-MNIST	4.0 ± 0.0	19.43 ± 0.08 (3/3)	19.43 ± 0.08 (3/3)	19.19 ± 0.05 (3/3)	19.28 ± 0.23 (3/3)
dSprites	9.7 ± 0.6	1.33 ± 0.06 (0/3)	3.01 ± 0.27 (0/3)	1.83 ± 0.09 (0/3)	1.64 ± 0.30 (0/3)
CIFAR-10	26.3 ± 0.6	14.40 ± 0.24 (3/3)	14.89 ± 0.20 (3/3)	14.73 ± 0.08 (3/3)	15.19 ± 0.12 (3/3)

dSprites では, マスクにより MSE が 0.00133 から 0.00301 に増える。復号器微調整で 0.00183 まで低下するが, 全次元モデルより依然として 37.1% 高い。したがって, ローカルな関連度 99% の閾値は, 他の軸をまとめて除去した後の再構成の保持を保証しない。この結果は, 除去した個々の軸の寄与を特定するものでも, 公表された ARD 手法の失敗を確立するものでもない。転用先通常 VAE の MSE は 0.00164 であり, これも Q に届かない。マスクモデルより品質がよいことは, 選択個数が指定品質目標に十分である根拠にはならない。

CIFAR-10 では, マスク・微調整の平均 (0.01489, 0.01473) は転用の平均 (0.01519) より低いが, 全次元モデルの平均 (0.01440) より高い。MNIST では, この指標上は転用の方がよい。これらは 3 シードの記述的な結果であり, 学習済みモデル, 推論規則, 微調整予算に依存する。native 剪定の一般的な優越性を確立するものではない。付録 F にシードごとの値, 保持された test 集合の再構成, 部分的な時間計測を示す。

6.6 ID の表現依存性と標本数依存性

表 12 に Fashion-MNIST を含む参照群の完全な要約を示す。両方の検査を通過するのは MNIST だけである。同一の参照群を再利用するため, 同じ合否が 5 回現れても ID 推定の独立な 5 反復ではない。

表 12: ID 参照 AE の次元数と TwoNN 推定値 (3 参照シードの平均 $\pm$ SD), 安定性 R , 推定量の不一致 A 。上限は $R \leq 0.15$, $A \leq 0.25$ 。同じ参照群を候補シードと β をまたいで再利用する。

データセット	次元数: 推定値	R	A
MNIST	55: 10.93 ± 0.08 ; 111: 11.78 ± 0.12 ; 221: 12.32 ± 0.09	0.118	0.150
Fashion-MNIST	49: 9.91 ± 0.06 ; 98: 10.45 ± 0.04 ; 197: 10.83 ± 0.05	0.088	0.361
dSprites	30: 3.96 ± 0.48 ; 61: 3.91 ± 1.12 ; 122: 2.10 ± 0.02	0.474	1.816
CIFAR-10	81: 13.60 ± 0.09 ; 162: 13.44 ± 0.71 ; 325: 12.34 ± 0.50	0.094	0.834

図 1 に, 標本数解析と PCA 解析を分けて示す。生入力 1000 例では, 両推定量は 4 データセットすべてで相対許容値 0.25 以内に一致するが, 10,000 例では MNIST だけが一致する。これは生入力の検査であり, 選択器が使う AE 潜在表現の検査とは別である。dSprites ではこの診断の入力 TwoNN は 7.70, PCA 後の推定値は 2.68–4.32, 個々の AE 推定値は 2.08–4.56 である。全体の最大・最小比は約 3.7 倍であり, MNIST の対応する比は約 1.7 倍である。これらは表現に依存する推定値であり, 既知の真値に対する競合測定ではない。




図 1: 左: 推定標本数を変えた生入力での $|d_{\text{TwoNN}} - d_{\text{MLE}}|/d_{\text{TwoNN}}$ 。破線は 0.25。右: PCA 前処理後の TwoNN。PCA 次元, 標本数, 表現は別の介入であり, AE 結果は表 12 に示す。

6.7 正則化と品質条件への依存

手法 a , データセット d について報告する変動幅を次式で定義する。

$$S_{a,d} = \max_{\beta \in \mathcal{B}} \bar{m}_{a,d}(\beta) - \min_{\beta \in \mathcal{B}} \bar{m}_{a,d}(\beta), \quad \bar{m}_{a,d}(\beta) = \frac{1}{5} \sum_{s=1}^5 m_{a,d,s}(\beta), \quad \mathcal{B} = \{0.25, 0.5, 1, 2, 4\}. \quad (8)$$

これは返された未変換の次元数をシード間で平均した値の範囲であり, シード内の変動幅を平均した値ではない。FONDUE-VAR の行では, 未変換のゼロを含め, 各設定で 5 個すべての出力が定義される。検討した重み列に対する記述的な範囲であり, 新たなパラメータ不要の頑健性指標ではない。

表 13: $\beta \in \{0.25, 0.5, 1, 2, 4\}$ にわたる, 返却次元数のシード平均の範囲。剪定変更実装は実装監査に限定する。固定 32 は設計上の定数であり, fallback の変動幅は ID の頑健性ではない。dSprites はベルヌーイ, 他はガウス尤度。

手法	MNIST	Fashion	dSprites	CIFAR-10
グリッド (MSE)	14.8	20.8	40.0	91.2
粗い探索	33.6	37.2	0.0	214.4
固定 32	0.0	0.0	0.0	0.0
FONDUE	3.8	0.8	0.8	8.8
FONDUE-VAR (混合型保持)	50.6	63.0	106.2	68.8
昇順 +Q	6.0	3.6	15.2	52.8
FONDUE + Q	3.6	1.6	28.0	44.8
従来 ID 探索窓	6.0	37.2	0.0	214.4

変動幅は手法とデータセットで異なり, 大小関係は明確に逆転する。例えば, 昇順探索と FONDUE+Q の変動幅は MNIST で 6.0 と 3.6, dSprites では 15.2 と 28.0 である。従来 ID 探索窓の CIFAR-10 での 214.4 という変動幅は fallback に由来する。固定次元は設計上変動幅がゼロであり, dSprites の ID

fallback も粗い探索が常に 64 を返すため変動幅がゼロになる。どちらも選択の有用な頑健性を示さない。尺度が異なるグリッド間で変動幅を平均せず、別条件へ移せる順位も主張しない。

ARD の呼出しでは選択段階の重みを変えておらず、GECO では β そのものではなくアンカー由来の制約を変えている。両者は実装監査の対象であり、図 2 の通常 VAE の正則化比較には含めない。




図 2: 5 条件で返された未変換次元数。5 候補シードの平均 $\pm$ SD。dSprites はベルヌーイ、他はガウス尤度。これらの通常 VAE 選択器では学習時の β を変える。従来 ID 探索窓は、重み列全体で Fashion-MNIST, dSprites, CIFAR-10 に fallback を用いる。

AU 閾値への介入は checkpoint を固定して式 (4) を再計算する。一方、品質許容幅への介入は、保存モデルのうちどれが目標を満たすかを変える。いずれも学習時の β を変えることとは異なる。これらの読み取り・品質解析は別に報告する (6.9 節, 付録 C.4)。未検討の FONDUE 停止閾値や ARD 累積関連度比率について、感度の主張は行わない。

6.8 学習曲線, test 評価, 選択基準

図 3 は、主設定で昇順 Q により選ばれた、実際に早期停止した候補キャッシュの記録を用い、MNIST の 6 次元と CIFAR-10 を含む。各実行は記録された epoch までを示し、proxy で選んだ checkpoint に印を付ける。これらのキャッシュには検証曲線だけがあり、epoch ごとの学習曲線はない。欠けた学習測定値は補完しない。別途行った新しい MNIST 実行で、6 次元の対応する学習・検証曲線を示す (付録 E)。

保存された学習推移実験には、MNIST の 12, 32, 64 次元と dSprites の 6, 16, 32 次元について、




図 3: 実際に選ばれた候補の検証 MSE。 $\beta = 1$, 5 シード, dSprites はベルヌーイ, 他はガウス尤度。次元は昇順 Q で選び, 黒い十字は proxy 選択 epoch を示す。曲線は記録上の停止時点で終わる。図 4 の固定 300 epochs の診断実行とは異なる。

各 5 シードの学習・検証曲線がある (図 4)。学習 MSE は, シード 20260919 で抽出した固定 2000 学習例の部分集合上で, 決定論的モードにより評価する。学習・検証の双方が改善するが, 検証誤差の方が高い。これら 30 実行のどれも, 最終 50 epochs の厳しい plateau 判定を満たさない。300 epochs の完了は収束の証明ではない。この曲線は代表的な設定を対象とし, 4 データセットすべてを網羅しない。




図 4: 学習・検証 MSE。5 シードの平均と ± 1 SD 帯を示す。MNIST はガウス、dSprites はベルヌーイ尤度、 $\beta = 1$ 。黒い十字は各実行の検証 ELBO proxy で選んだ checkpoint。この診断実行には早期停止を用いない。

表 14: $\beta = 1$, 5 シードでの選択基準比較。test MSE は 10^3 倍, プローブ test 正解率は %。プローブはクラスラベル (dSprites では形状) を使い, 容量選択にも使うのはグリッド (プローブ) だけである。時間はアンカー補完を含む過去の記録であり, 再評価の統一単価ではない。記録済みプローブ時間はその選択器に課す。他の表示プローブ正解率は補助評価であり, 費用は加算していない。尤度は表 2 による。

データセット	基準	m	test MSE	正解率	時間 (秒)
MNIST	グリッド (MSE)	12.8 ± 6.4	20.50 ± 0.26	89.4 ± 0.9	628 ± 35
MNIST	グリッド (ELBO proxy)	10.0 ± 2.0	20.54 ± 0.25	89.3 ± 0.7	628 ± 35
MNIST	グリッド (プローブ)	51.2 ± 13.4	23.01 ± 0.55	92.7 ± 0.5	696 ± 36
Fashion-MNIST	グリッド (MSE)	22.8 ± 15.6	18.08 ± 0.19	75.5 ± 2.6	645 ± 42
Fashion-MNIST	グリッド (ELBO proxy)	15.6 ± 8.0	18.12 ± 0.27	74.4 ± 2.6	645 ± 42
Fashion-MNIST	グリッド (プローブ)	57.6 ± 8.8	18.99 ± 0.46	78.4 ± 0.6	750 ± 40
dSprites	グリッド (MSE)	57.6 ± 14.3	1.15 ± 0.01	47.7 ± 2.3	2565 ± 82
dSprites	グリッド (ELBO proxy)	57.6 ± 14.3	1.15 ± 0.01	47.7 ± 2.3	2565 ± 82
dSprites	グリッド (プローブ)	64.0 ± 0.0	1.16 ± 0.03	49.8 ± 3.0	2589 ± 84
CIFAR-10	グリッド (MSE)	140.8 ± 53.5	14.07 ± 0.04	44.3 ± 2.6	428 ± 16
CIFAR-10	グリッド (ELBO proxy)	192.0 ± 45.3	14.11 ± 0.08	46.1 ± 1.1	428 ± 16
CIFAR-10	グリッド (プローブ)	256.0 ± 0.0	14.30 ± 0.12	47.3 ± 1.0	574 ± 15

表 14 に, 以前は示していなかった MSE, ELBO proxy, 線形プローブによるグリッド選択を示す。目的が違えば, 選択次元と再構成誤差も異なり得る。プローブの test 正解率は補助的な教師ありの結果であり, 教師なしの再構成品質を測るものではない。この比較は同じ分割と保存候補を用い, ラベル付き検証データによる選択を明記している。

表 15 の独立した新しい MNIST 比較では, 5.4 節の固定 Monte Carlo 手順により, 実際の期待対数尤度を評価する。保存済み MSE と KL から再構成した値ではない。検証 MSE は 12 次元, proxy は 12 次元, Monte Carlo ELBO も 12 次元を選ぶ。この実行での一致は, proxy が ELBO 推定量であることを意味しない。全グリッドのスコア, MC 誤差, 選択 epoch を付録 E に示す。新しい学習シードが 1 つだけでは, いずれの基準についてもデータセット全体の優位性は確立できない。5.5 節で述べた評価コード上の理由から, 追加の 4 データセットの剪定記録は, この ELBO 容量選択比較を拡張するものではない。

表 15: 新しい MNIST のシード 42 による容量選択。 $\beta = 1$, ガウス分散 $1/2$ 。すべての基準が同じ 12 個の proxy 選択 checkpoint から選ぶ。MSE は 10^3 倍, ELBO は例当たりの平均 nats。 $\pm$ は Monte Carlo SE ($K = 32$) であり, 学習シード間 SD ではない。検証データによる選択を固定してから test を評価する。

基準	次元数	検証 MSE	test MSE	MC ELBO $\pm$ MC SE
MSE	12	20.98	20.43	-478.067 ± 0.012
ELBO proxy	12	20.98	20.43	-478.067 ± 0.012
MC ELBO	12	20.98	20.43	-478.067 ± 0.012

6.9 活性度の読み取り：推移, 閾値, 予測

図 5 と表 16 は, 同一 checkpoint で 2 種類の個数を比較する。MNIST の 64 次元では, epoch 5 の変数型による個数は 9.8 ± 3.8 , AU は 49.4 ± 8.1 であるが, epoch 300 ではいずれも 6.4 ± 0.5 となる。この例では, 平均の一致とシード間の変動を区別できる。表には epoch 50 から 300 までの同一実行内

の変化も示す。変化の大きさは条件に依存するため、最終値の一致から一般的な安定性の優位を推論しない。

表 16: 変数型の個数 V （活性型と混合型の和）と AU 数 A 。5 シード, $\beta = 1$, MNIST はガウス, dSprites はベルヌーイ尤度。平均 $\pm$ SD はシード間変動を表す。最終列は V/A について epoch 50 から 300 までの実行内絶対変化の平均であり、時間方向の分散ではない。

データセット	m	V_5	A_5	V_{300}	A_{300}	変化
MNIST	12	7.2 ± 0.8	8.0 ± 1.6	6.4 ± 0.5	6.4 ± 0.5	0.0/0.0
MNIST	32	8.2 ± 1.5	20.8 ± 4.2	6.0 ± 0.0	6.0 ± 0.0	0.0/0.0
MNIST	64	9.8 ± 3.8	49.4 ± 8.1	6.4 ± 0.5	6.4 ± 0.5	0.4/2.6
dSprites	6	6.0 ± 0.0	6.0 ± 0.0	6.0 ± 0.0	6.0 ± 0.0	0.0/0.0
dSprites	16	16.0 ± 0.0	16.0 ± 0.0	14.2 ± 0.4	13.4 ± 0.5	1.8/1.8
dSprites	32	32.0 ± 0.0	31.8 ± 0.4	14.2 ± 1.1	14.4 ± 1.1	12.4/4.2

図 6 の閾値だけを変える比較では、 $\beta = 1$ の checkpoint を固定する。CIFAR-10 では、 $\delta = 0.001$ は検討したすべてのグリッド次元で全座標を数えるが、 $\delta = 0.1$ は大きな容量で数える座標がはるかに少ない。したがって「未使用座標がない」という推論はこの閾値に依存する。閾値の正規化は診断の定義を変えるものであり、次元推定を確立するものではない。

予測課題は、1 つ小さいグリッド候補が、同じシードの品質目標を満たすかを判定することである。各行は、最小グリッド次元以外の容量で検証データにより選ばれた 1 個の checkpoint である。基準特微量は、検証 MSE, KL, ELBO proxy, 次元数, 次元数と入力 ID の比, 直近 20 記録 epochs の検証 MSE の傾きである。追加する 3 つの AU 特微量は、AU, AU/次元数, AU/入力 ID とする。標準化は開発用の行だけで適合する。 L_2 ロジスティック予測器を MNIST の 55 行に適合し、開発データを 3 シードと 2 シードに分けて $C = 10$ を選ぶ。評価は dSprites の 55 行, Fashion-MNIST の 55 行, CIFAR-10 の 45 行で行い、各 5 シードを用いる。設定されていた MNIST-CNN の予測条件は実行していない。

開発用分割ではシード 42, 123, 777 で内部適合を行い、2024, 31337 で C を選んだ後、5 シードすべてで再適合する。予測器の最大反復数は 5000 とする。各評価データセット・シードのブロックは、そのシードの最小次元を除く全グリッド次元で採点する。checkpoint の各行を独立な観測として再標準化しない。

当初の内部仕様に基づく解析では、AU を追加した予測器と基準予測器の AUROC 差は $+0.108$ であり、シード記録を用いた 2000 回の bootstrap の 95% 区間は $[+0.059, +0.157]$ と報告されていた。後から追加した対照は、独立な 3 個の標準正規特微量と 1 つの雑音実現（生成器シード 7）を用い、その改善量は別に $+0.098$, 区間は $[-0.025, +0.227]$ と報告された。これらの区間の重なりは、両者の差の検定でも同等性の証明でもない。これらの保存値は元の解析の記録として残すが、妥当性が確認された正の所見とは扱わない。その AUROC 計算は、データセット間の分布変化により数値的に飽和し得る確率値を用いていた。




図 5: epoch 1, 2, 5, 50, 300 の同一 checkpoint から得た変数型の個数（活性型と混合型の和）と AU。平均とシード SD を示し、線は観測された checkpoint 間だけを結ぶ。 $\beta = 1$, MNIST はガウス, dSprites はベルヌーイ尤度。全容量に等しい個数が一定でも、診断の安定性の証拠にはならない。

表 17: $\beta = 1$ の対応付き AU 事後比較。飽和確率の同順位を避けるためロジスティック決定スコアを用いる。各値は、各シードの最小次元を除く全容量で評価した AUROC を 5 シードで平均したもの。無作為特徴量は生成器シード 7 の標準正規乱数 3 列。全手法が同じ行とラベルを用いる。

評価条件	行数	基準	基準 + AU	基準 + 無作為	AU - 無作為
dSprites	55	0.950	0.858	0.898	-0.041
Fashion-MNIST	55	0.980	1.000	0.880	+0.120
CIFAR-10	45	1.000	1.000	1.000	+0.000

基準 AUROC は既に, dSprites で 0.950, Fashion-MNIST で 0.980, CIFAR-10 で 1.000 である。特に CIFAR-10 には AUROC を上げる余地がない。この結果は、特定の天井に近い予測課題での追加価




図 6: 同じ $\beta = 1$ 候補に対する 3 閾値での AU。平均 $\pm$ シード SD。dSprites はベルヌーイ、他はガウス尤度。対角線は容量である。これは読み取り閾値への介入であり、図 2 の学習・条件への介入とは異なる。

値に関するものであり、AU 一般の情報量を論じるものではない。

本改訂では $\beta = 1$ を明示的に固定し、対象行を宣言されたグリッドに限定して両予測器を再構成し、ロジスティック回帰の決定スコアから AUROC を計算する。元のキャッシュ読出し処理には β のフィルタもグリッドの制限もなく、キャッシュ拡張後に再実行すると対象行も曖昧になる。決定スコアは、sigmoid 確率がちょうど 1 へ丸められると失われる順位を保持する。飽和件数は付録 C.4 に示す。これは修正した事後解析であり、保存されていた確率の厳密な再現ではない。AU 追加から基準を引いた差は -0.024 、区間は $[-0.102, +0.027]$ となる。AU 予測器と無作為特徴量予測器も、同じデータセット・シードのブロックで比較する。対応差の平均は $+0.026$ であり、事後的な階層 bootstrap の 95% 区間は $[-0.040, +0.133]$ である (2000 反復)。各反復では、3 評価データセットを再標本化し、選ばれたデータセット内で 5 シードブロックを再標本化する。ブロック内の全容量と両予測器の対応は保持する。モデルは固定するため、この区間は開発モデルの適合に関する不確実性を含まない。評価データセットは 3 つしかなく、条件をまたぐ推論の精度は限られる。補助解析では 100 個の雑音実現 (シード 0-99) で対照を平均し、同じ再標本化で対応差 -0.007 、区間 $[-0.064, +0.039]$ を得た。どちらの解析も、これらの評価条件で AU 固有の利得を確立しない。AU に情報が無い、両予測器が同等である、あるいは有意差がないことが検出力不足を証明する、とは主張しない。

6.10 実装監査と退化出力

過去の損失尺度の修正を付録 C.2 に記す。現在の画像比較は、潜在次元について和を取る修正後の規約を用いる。

ARM に固有の追加実装検査は、平均を取る順序に関するものである。提供された線形損失の検査では、各例の対立標本を使う推定量を解析勾配と比較する。ゲート標本との相関を構成する前に損失を平均すると、必要な対応が失われる。追加の学習コードは各例の損失を用いる。この構成要素の修正は、すべての制約が満たされることを意味しない。最終時点の件数を表 9 に示す。これは、過去の損失尺度と ARD 関連度正規化の監査とは別の問題である。

FONDUE-VAR の活性型のみを残す設定がゼロを返すことは、別の現象であり、3 件目の和・平均の欠陥ではない。MNIST の 1 epoch 設定では 5 試行すべてがゼロを返し、最終 VAE は存在しない。表 18 に両設定と品質・有効モデルの件数を示す。

表 18: $\beta = 1$ の FONDUE-VAR。混合型保持の両設定、有効モデル数、品質達成数、test MSE (10^3 倍)、記録学習時間。未変換のゼロ出力も次元集計に残すが、モデルが存在しない場合に MSE はない。5 シード、尤度は表 2 による。

データセット	混合型保持	未変換 m	有効	Q	test MSE	時間 (秒)
MNIST	はい	9.8 ± 8.5	5/5	5/5	22.53 ± 0.89	113 ± 22
MNIST	いいえ	0.0 ± 0.0	0/5	0/5	—	63 ± 10
Fashion-MNIST	はい	14.4 ± 3.8	5/5	5/5	18.96 ± 0.39	91 ± 11
Fashion-MNIST	いいえ	2.0 ± 0.0	5/5	0/5	25.27 ± 0.06	120 ± 18
dSprites	はい	26.0 ± 49.5	4/5	1/5	9.53 ± 9.62	412 ± 118
dSprites	いいえ	1.2 ± 1.6	2/5	0/5	7.71 ± 0.02	278 ± 49
CIFAR-10	はい	34.2 ± 1.3	5/5	5/5	14.40 ± 0.15	103 ± 13
CIFAR-10	いいえ	3.2 ± 0.8	5/5	0/5	31.65 ± 2.68	96 ± 13

7 考察

開始次元数を統制したアブレーションにより、ID-local の結果の解釈が変わる。同じ fallback を持つ ID-gated midpoint でも、最小次元との 100/100 の一致が再現される。ID を採用した 25 条件では、ID 開始点は答えを変えずにより多くの候補を要求する。参照群を使わない中点方策の 2 件の誤りは、ID 方策が昇順 fallback を使う条件で起こる。したがって、この証拠から ID 由来の開始次元数の優位性は確立できない。信頼性判定を備えた探索が有効かという仮説と、幾何学情報が有用な開始次元数を与えるかという仮説は別である。

目標には最大次元のアンカーが含まれるため、保存グリッド内で上方へ網羅的に探索すれば品質達成は保証される。一方、最小性と費用は実質的な評価対象として残る。全組合せ解析では 10,000 設定中 155 件で非最小の出力が得られ、既定値での一致は局所探索の普遍的な保証ではない。共有参照群、単一の分割、事後的な方策設計、4 データセットという範囲が推論を制限する。独立した参照群での追試は未実施である。取得費用と再利用費用も、異なる利用状況に対応する。

正則化に伴う変動範囲と AU 閾値への応答は、異なる介入を測定している。次元の変動には、fallback、グリッド尺度、品質目標の変化を反映するものがある。一定の出力は、設計上の固定値や変化させてい

ない実装引数によって生じ得る。対応付き予測比較では、天井に近い課題において、対応する無作為特微量対照に対する AU 固有の優位性は確立されない。したがって本研究での AU の役割は、明示した閾値のもとで座標の利用状況を診断することに限定される。

native 剪定の比較は、選択個数と、保持軸を用いるモデルの再構成を別々に評価する必要性を示す。ローカルな標本中心の ARD 変種は、MNIST と Fashion-MNIST ではマスク後の平均 MSE をほぼ維持する一方、dSprites では大きく悪化し、復号器微調整による回復も部分的である。全次元モデル自体がすでに Q に届かないため、dSprites の 4 条件のいずれも、目標品質を維持した圧縮の成功として示すことはできない。マスクは元のネットワークにおける推論規則の検証であり、パラメータ数、メモリ、遅延の削減を測定したものではない。固定微調整予算は追加学習を要し、それまで事前分布更新専用だったプールも用いる。マスクなしで 30 epochs 微調整する対照は実施していないため、改善をマスクの影響の補償だけに帰属できない。

これらの結果は、各データセット 3 シードへ native 品質の根拠を広げるが、ローカルな学習設定を維持している。厳密ヤコビアンは有限刻み幅近似を除くもので、標本から求めた関連度スコアや学習表現の不確実性を除くものではない。Gaussian KL 近似は ARD 原著と共通である。標本中心の分散更新は引き続き感度検証用の変種であり、原著のゼロ中心設定に必要な修正ではない。この変種の結果をすべての ARD 設定へ一般化したり、原著手法の厳密な benchmark として扱ったりすることはできない。

追加された 4 データセットの ELBO フィールドは、主張する量に必要な期待尤度と native の事前分布に対する KL を計算していない。妥当な MC ELBO による容量選択の証拠は、MNIST の 1 シードと proxy で選んだ checkpoint に留まる。同様に、新しい剪定曲線は欠けている過去の通常 VAE 学習曲線を回復しない。原著アルゴリズム全体の再現、独立参照群による検証、完全な end-to-end 時間計測、情報漏洩のない合成データの分離評価は未完了である。合成データ診断（付録 D）は尺度と座標の効果を記述するもので、位相が活性軸数を決めることを示さない。

8 結論

明示的な品質・費用の定義の下で、内在次元誘導による VAE ボトルネック選択と活性ユニット診断を評価した。信頼性判定、fallback、参照費用を固定すると、ID が採用されるのは MNIST の 25 条件だけである。ID 由来の開始点と判定付き中点は、平均 8.84 件と 5.84 件の要求で同じ次元数を選ぶ。他の 75 条件は同じ昇順 fallback を用いる。局所探索の最小性は、信頼性と係数の設定にも依存する。追加剪定実験では、native 品質、次元転用後の品質、学習制約を区別する。ローカルな標本中心の ARD 変種では、選択軸によるマスク後も 2 データセットの再構成はほぼ変わらないが、dSprites の MSE は 126.3% 増える。復号器微調整による回復は部分的であり、dSprites の 4 条件すべてが Q に届かない。AU は、今回の天井に近い課題で追加の予測価値を確立しない。本研究の貢献は ID 誘導と潜在診断の限定的な評価であり、一般的な効率上の優位性や剪定品質の保証を確立するものではない。

■著者の貢献 構想：C.O., M.D., K.J.; 方法論：C.O., K.J.; ソフトウェア：C.O., M.D.; 検証：C.O., M.D., K.J.; 形式的解析：C.O., K.J.; 調査：C.O., M.D., K.J.; 初稿執筆：C.O., K.J.; 原稿の検討・編集：C.O., M.D., K.J.; 監督・プロジェクト管理：K.J.

■研究助成 本研究は、JSPS 科研費 JP24K15115 および JP26K14984、東京都市大学重点研究 [知能技術最適化研究ユニット：ORBIT]、東北大学電気通信研究所の共同研究プロジェクト、ならびに電気通信普及財団（TAF）の研究助成を受けた。

■倫理審査 該当なし。

■インフォームド・コンセント 該当なし。

■データの利用可能性 画像データセットは引用した配布元から公開されている。同梱の査読用補足資料 MAKE53_reproducibility.zip には、設定、過去および追加の結果記録、解析・学習コード、分割添字、図、独立した MNIST 検証の checkpoint, SHA-256 manifest を含む。アーカイブを展開して README.md に従うこと。付録 G に内容の対応を示す。過去の MAKE49 および追加 MAKE52 剪定実験の checkpoint は利用できない。アーカイブは本改訂に添付するもので、公開データ寄託ではなく DOI もない。

■謝辞 従来の原稿作成では、実験コードの草案・整理と英文編集に生成 AI の支援を用いた。今回の記録監査、再集計、モデル検証結果の解析、図の作成、原稿改訂では OpenAI Codex の支援を用いた。科学的内容の責任は著者らにある。

■利益相反 著者らは利益相反がないことを宣言する。

A 品質目標と結果の計上

表 A1: 品質アンカーと目標。MSE の単位は 10^{-3} ，5 シードの平均 $\pm$ SD。各判定は表示平均ではなく，そのシード固有の目標を用いる。相対許容幅は 10% で，絶対下限は有効にならない。dSprites はベルヌーイ，他はガウス尤度。

データセット	β	アンカー MSE	目標 $T_{D,s}$
MNIST	0.25	15.843 $\pm$ 0.562	17.428 $\pm$ 0.618
MNIST	0.5	19.202 $\pm$ 0.497	21.122 $\pm$ 0.546
MNIST	1	23.712 $\pm$ 0.532	26.084 $\pm$ 0.585
MNIST	2	30.061 $\pm$ 0.560	33.068 $\pm$ 0.617
MNIST	4	38.977 $\pm$ 0.673	42.875 $\pm$ 0.740
Fashion-MNIST	0.25	15.591 $\pm$ 0.678	17.150 $\pm$ 0.746
Fashion-MNIST	0.5	17.408 $\pm$ 0.513	19.148 $\pm$ 0.564
Fashion-MNIST	1	19.679 $\pm$ 0.162	21.647 $\pm$ 0.179
Fashion-MNIST	2	22.416 $\pm$ 0.527	24.658 $\pm$ 0.580
Fashion-MNIST	4	25.967 $\pm$ 0.587	28.564 $\pm$ 0.645
dSprites	0.25	1.015 $\pm$ 0.032	1.117 $\pm$ 0.036
dSprites	0.5	1.040 $\pm$ 0.032	1.144 $\pm$ 0.035
dSprites	1	1.170 $\pm$ 0.024	1.287 $\pm$ 0.026
dSprites	2	1.453 $\pm$ 0.038	1.598 $\pm$ 0.041
dSprites	4	2.144 $\pm$ 0.064	2.358 $\pm$ 0.070
CIFAR-10	0.25	9.407 $\pm$ 0.610	10.348 $\pm$ 0.671
CIFAR-10	0.5	11.151 $\pm$ 0.200	12.266 $\pm$ 0.220
CIFAR-10	1	14.064 $\pm$ 0.108	15.470 $\pm$ 0.119
CIFAR-10	2	17.806 $\pm$ 0.262	19.587 $\pm$ 0.288
CIFAR-10	4	22.399 $\pm$ 0.286	24.638 $\pm$ 0.314

A.1 各状態の独立した集計

以下の表は，元の複合状態と，各フラグおよび最終モデルの品質を分ける。予算フラグは ID fallback と同時に立ち得る。剪定用ラッパーは学習中に通常選択器の予算を強制していないため，予算フラグがゼロであることは同じ予算管理の証拠ではない。予算超過試行を含め，有効な返却モデルはすべて主設定の平均に含める。退化出力は未変換個数と費用の要約に含めるが，MSE には含めない。

表 A2: $\beta = 1$ の結果監査。すべて 5 試行中の件数。S: 記録上の成功; I: ID 信頼性不足; B: 予算超過; D: 退化; N: 小容量の代替なし。FB は fallback フラグ。予算, 検証品質 Q , 最終 VAE の小容量化は, それぞれ独立に再計算するかフラグから読み取る。

データセット	手法	状態	FB	予算超過	Q	小容量化
MNIST	グリッド (MSE)	S5	0	0	5	5
MNIST	FONDUE	S5	0	0	5	5
MNIST	FONDUE + Q	S5	0	0	5	5
MNIST	GECO 変更実装	S5	0	0	5	5
MNIST	ARD 変更実装	S5	0	0	5	5
MNIST	昇順 + Q	S5	0	0	5	5
MNIST	従来 ID 探索窓	S5	0	0	5	5
MNIST	FONDUE-VAR (混合型保持)	S5	0	0	5	5
MNIST	FONDUE-VAR (活性型のみ)	D5	0	0	0	0
Fashion-MNIST	グリッド (MSE)	S5	0	0	5	5
Fashion-MNIST	FONDUE	S5	0	0	5	5
Fashion-MNIST	FONDUE + Q	S5	0	0	5	5
Fashion-MNIST	GECO 変更実装	S5	0	0	5	5
Fashion-MNIST	ARD 変更実装	S5	0	0	4	5
Fashion-MNIST	昇順 + Q	S5	0	0	5	5
Fashion-MNIST	従来 ID 探索窓	I5	5	0	5	5
Fashion-MNIST	FONDUE-VAR (混合型保持)	S5	0	0	5	5
Fashion-MNIST	FONDUE-VAR (活性型のみ)	S5	0	0	0	5

表 A3: $\beta = 1$ の結果監査。すべて 5 試行中の件数。S: 記録上の成功; I: ID 信頼性不足; B: 予算超過; D: 退化; N: 小容量の代替なし。FB は fallback フラグ。予算, 検証品質 Q , 最終 VAE の小容量化は, それぞれ独立に再計算するかフラグから読み取る。

データセット	手法	状態	FB	予算超過	Q	小容量化
dSprites	グリッド (MSE)	S5	0	0	5	1
dSprites	FONDUE	S5	0	0	0	5
dSprites	FONDUE + Q	B1, S4	0	1	5	5
dSprites	GECO 変更実装	S5	0	0	5	0
dSprites	ARD 変更実装	S5	0	0	0	5
dSprites	昇順 + Q	S5	0	0	5	5
dSprites	従来 ID 探索窓	I5	5	0	5	0
dSprites	FONDUE-VAR (混合型保持)	D1, S4	0	0	1	3
dSprites	FONDUE-VAR (活性型のみ)	D3, S2	0	0	0	2
CIFAR-10	グリッド (MSE)	S5	0	0	5	5
CIFAR-10	FONDUE	S5	0	0	0	5
CIFAR-10	FONDUE + Q	S5	0	0	5	5
CIFAR-10	GECO 変更実装	S5	0	0	2	5
CIFAR-10	ARD 変更実装	S5	0	0	0	5
CIFAR-10	昇順 + Q	S5	0	0	5	5
CIFAR-10	従来 ID 探索窓	I5	5	0	5	3
CIFAR-10	FONDUE-VAR (混合型保持)	S5	0	0	5	5
CIFAR-10	FONDUE-VAR (活性型のみ)	S5	0	0	0	5

B 探索感度と時間記録の来歴

これらの表は、アルゴリズム 1 の事後的な方策を用いる。元の実験を定義し直すものではない。

表 A4: $\beta = 1$, $R \leq 0.15$, $A \leq 0.25$ での ID-local 再評価の係数感度。5 係数すべてを示し、棄却されたデータセットは同じ昇順 fallback を使う。5 シード、尤度は表 2 による。

データセット	c	次元数	Q	一致	要求数	初回費用 (秒)
MNIST	1	6.0 ± 0.0	5/5	5/5	6.0	487
MNIST	1.5	6.0 ± 0.0	5/5	5/5	8.0	584
MNIST	2	6.0 ± 0.0	5/5	5/5	9.0	636
MNIST	3	6.0 ± 0.0	5/5	5/5	11.0	743
MNIST	4	6.0 ± 0.0	5/5	5/5	11.0	743
Fashion-MNIST	1	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	1.5	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	2	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	3	4.0 ± 0.0	5/5	5/5	3.0	416
Fashion-MNIST	4	4.0 ± 0.0	5/5	5/5	3.0	416
dSprites	1	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	1.5	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	2	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	3	20.0 ± 4.0	5/5	5/5	9.0	2092
dSprites	4	20.0 ± 4.0	5/5	5/5	9.0	2092
CIFAR-10	1	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	1.5	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	2	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	3	24.0 ± 0.0	5/5	5/5	4.0	498
CIFAR-10	4	24.0 ± 0.0	5/5	5/5	4.0	498

表 A5: $\beta = 1$, $c = 2$ での信頼性閾値感度。ID: ID を開始点とする局所探索; FB: 昇順 fallback。極端な許容値はストレス条件であり、推奨閾値ではない。各結果は5 シードと同じ参照群を用いる。全組合せの解析は補足資料に含める。

$R_{\max}/A_{\max}$	データセット	利用	平均次元	Q	一致	要求数
0.1/0.25	MNIST	FB	6.0	5/5	5/5	4.0
0.1/0.25	Fashion-MNIST	FB	4.0	5/5	5/5	3.0
0.1/0.25	dSprites	FB	20.0	5/5	5/5	9.0
0.1/0.25	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.15/0.25	MNIST	ID	6.0	5/5	5/5	9.0
0.15/0.25	Fashion-MNIST	FB	4.0	5/5	5/5	3.0
0.15/0.25	dSprites	FB	20.0	5/5	5/5	9.0
0.15/0.25	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.25/0.25	MNIST	ID	6.0	5/5	5/5	9.0
0.25/0.25	Fashion-MNIST	FB	4.0	5/5	5/5	3.0
0.25/0.25	dSprites	FB	20.0	5/5	5/5	9.0
0.25/0.25	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.15/0.4	MNIST	ID	6.0	5/5	5/5	9.0
0.15/0.4	Fashion-MNIST	ID	4.0	5/5	5/5	10.0
0.15/0.4	dSprites	FB	20.0	5/5	5/5	9.0
0.15/0.4	CIFAR-10	FB	24.0	5/5	5/5	4.0
0.15/0.85	MNIST	ID	6.0	5/5	5/5	9.0
0.15/0.85	Fashion-MNIST	ID	4.0	5/5	5/5	10.0
0.15/0.85	dSprites	FB	20.0	5/5	5/5	9.0
0.15/0.85	CIFAR-10	ID	24.0	5/5	5/5	4.0
0.5/2	MNIST	ID	6.0	5/5	5/5	9.0
0.5/2	Fashion-MNIST	ID	4.0	5/5	5/5	10.0
0.5/2	dSprites	ID	20.0	5/5	5/5	6.0
0.5/2	CIFAR-10	ID	24.0	5/5	5/5	4.0

B.1 過去の時間計上と統一時間計上

表 A7 には、元の記録で省かれたアンカーの補完を含め、MAKE50 の過去の費用記録を残す。これは新たな再評価の単価基準ではない。例えば MNIST の平均アンカー単価は、一部の早期記録で 69.3 秒、後の統一スナップショットでは 62.6 秒であり、6 次元の最終モデルの単価はそれぞれ 39.9 秒と 37.6 秒である。これらの一致項目では、論理条件は e300|es1|b1 のままである。集計指標と指定条件の一致から、2 つの時間スナップショットが異なる理由は分からず、モデルがビット単位で同一であることも証明できない。異なるハードウェアや停止設定といった、裏付けのない原因は割り当てない。

補足の results/make51/cost_lineage.csv には、データセット・手法・重み・シードごとに、アンカーと最終モデルの役割、完全なキー、元の trace キー、ファイル・記録の出典、元の所要時間、統一所要時間、可能な範囲での指標同一性の確認を示す。保存されていないグリッド外候補は利用不可と記す。過去のアンカー計上が存在しない場合は、時間ゼロとは区別する。再評価が要求するのは保持されたグリッド候補だけであるため、要求される各アンカーと最終モデルには、利用可能な単一の統一指

標・単価記録を用いる。

表 A6: $\beta = 1$ でのアンカー・最終モデルの時間監査。各項目は手法・役割・シードの記録であり、独立した学習実行ではない。同じ論理キーに異なる単価が付く場合がある。完全なキー、出典、両方の所要時間を `cost_lineage.csv` に示す。保存された集計指標から checkpoint の同一性は確立できない。

データセット	照合項目数	時間の相違	最大差 (秒)
MNIST	117	107	14.53
Fashion-MNIST	130	0	0.00
dSprites	119	109	0.42
CIFAR-10	130	0	0.00

表 A7: 過去の MNIST 学習時間の内訳。 $\beta = 1$, 5 シードの平均秒数。最終モデルは 1 回計上し、他候補列から除く。ID 計算と学習後評価は別に計時されていない。FONDUE の epoch 校正ではデータセット・ β 設定ごとに 4.14 秒を 1 回加えるが、以下には含めない。

手法	アンカー	ID 参照 AE	他の学習	最終	合計
グリッド (MSE)	69.3	0.0	502.0	56.2	627.5
FONDUE	62.6	0.0	1.4	39.9	103.9
FONDUE + Q	69.3	0.0	1.4	55.3	125.9
GECO 変更実装	62.6	0.0	175.4	39.6	277.6
ARD 変更実装	62.6	0.0	138.0	37.6	238.2
昇順 + Q	69.3	0.0	72.8	39.9	182.0
従来 ID 探索窓	69.3	205.5	400.7	39.9	715.4

C 実施範囲と実装詳細

表 A8: 実行した範囲。画像手法の各行は、記載した条件ごとに 5 学習シードを持つ。追加診断ではそれぞれのシード単位を用いる。

実験	対象データセット	条件・件数
過去の通常選択器・対照 14 手法	画像 4 種類すべて	β は 5 値； $14 \times 4 \times 5 \times 5 = 1400$ 手法記録
過去の HC 変更実装	4 種類すべて	アンカー由来の制約 5 種類；100 記録
過去の ARD 変更実装	4 種類すべて	選択段階の重みは 1 に固定；5 条件で反復，100 記録
ID 参照群	4 種類すべて	各 3 次元数 $\times 3$ シード，条件間で共有
学習・検証・読み取り推移	MNIST：12, 32, 64； dSprites：6, 16, 32	$\beta = 1$ ，各 5 シード；30 実行
AU 予測	開発：MNIST； 評価：dSprites, Fashion-MNIST, CIFAR-10	$\beta = 1$ ；開発 55 行，評価 155 行
探索再評価と開始次元のアブレーション	4 種類すべて	7 方策，700 行；係数・閾値の 10,000 設定
独立した MC ELBO 容量実験	MNIST	1 シード，通常 VAE の 12 次元設定
追加 ARM 検証	4 種類すべて	3 シード，12 実行； $\beta = 1$ アンカー
追加の厳密ヤコビアン ARD	4 種類すべて	3 シード，分散更新の 2 中心設定；24 実行
Native ARD のマスク・微調整	4 種類すべて	3 シード；標本中心設定の対応のある拡張，12 評価
合成診断	Swiss roll とトラス	6 容量，3 シード，2 スケーリング設定；72 実行

通常の 14 手法記録は，MSE・ELBO proxy・プローブによるグリッド選択，粗い探索，固定次元，FONDUE，FONDUE-VAR の 2 設定，AU 記録あり・なしの ID 誘導，昇順 + Q ，および粗い探索・FONDUE・FONDUE-VAR に Q を追加したものからなる。AU の記録を除いても ID 選択の判断は変わらず，AU の処理時間は別に計測されていない。紙面には主要な比較だけを載せる場合でも，機械可読の結果には 14 手法すべてを含める。

表 A9: 保存ローダーと固定シードから再構成した分割の識別子。ローダーの規約に従い，int64 の学習・検証・test 添字配列を連結した SHA-256 の先頭 16 桁の 16 進文字を用いる。公式の学習・test 集合は別々の添字空間を持つ。

データセット	再構成した分割識別子
MNIST	cffaecf5bccbb333
Fashion-MNIST	cffaecf5bccbb333
dSprites	1ea516804f7f9ac7
CIFAR-10	55e0bcf8f4474c19

分割添字配列はローダー仕様から再構成したものであり，実行時に独立して保存された分割ファイル

を復元したものではない。MNIST と Fashion-MNIST の識別子が一致するのは、公式データ集合のサイズと添字規則が同じためであり、画像自体は異なる。圧縮した配列を `results/make51/reconstructed_split_indices.npz` として提供する。TwoNN はユークリッド最近傍距離を用い、第 1 近傍距離がゼロの点と経験累積分布の終点を除き、距離比の対数に対して生存関数の対数を原点通過で当てはめる。照合用の MLE は、 $k = 10$ の有効点における局所的な平均対数距離比の逆数を平均する。独自実装では両推定値に 1 の下限を設ける。

表 A10: FONDUE の短期学習 epoch 数と校正時間（データセット・条件ごとに 1 回、選択器時間とは別）。dSprites は校正せず原著設定を使う。他データの安定欄は、連続した校正予測が一致したことを意味する。

データセット	β	epoch 数	校正（秒）	安定
MNIST	0.25	2	9.64	はい
MNIST	0.5	2	9.55	はい
MNIST	1	1	4.14	はい
MNIST	2	2	8.12	はい
MNIST	4	2	9.38	はい
Fashion-MNIST	0.25	1	4.16	はい
Fashion-MNIST	0.5	1	3.64	はい
Fashion-MNIST	1	2	9.07	はい
Fashion-MNIST	2	3	13.70	はい
Fashion-MNIST	4	1	3.80	はい
dSprites	0.25	1	0.00	対象外（原著設定）
dSprites	0.5	1	0.00	対象外（原著設定）
dSprites	1	1	0.00	対象外（原著設定）
dSprites	2	1	0.00	対象外（原著設定）
dSprites	4	1	0.00	対象外（原著設定）
CIFAR-10	0.25	3	30.34	はい
CIFAR-10	0.5	2	15.56	はい
CIFAR-10	1	2	22.72	はい
CIFAR-10	2	3	29.69	はい
CIFAR-10	4	4	42.98	はい

C.1 従来の固定探索窓手順

以前の手順は、ID から導いた上限次元以下の候補をすべて評価した。評価済み集合に品質アンカーが含まれるため、予定されていた拡張分岐には入れなかった。これを有効な拡張探索とは呼ばず、固定探索窓の監査として残す。以前の V1/V2 活性度検査は選択分岐ではなく、AU 記録によって選択次元は変わらない。

アルゴリズム A1 (従来の固定探索窓 ID 手順 (監査)).

入力: データ分割, $\mathcal{M}$, シード s , β , 目標許容幅 10%, 下限係数 0.001, 入力 TwoNN d_0 , 参照シード $\{42, 123, 777\}$, 閾値 (0.15, 0.25), 表 2 の予算。

1. 品質アンカーを取得し, 式 (1) から $T_{D,s}$ を固定する。fallback では, これは粗い選択器の制約ではなく外部監査の段階であり, 学習費用を計上する。
2. $k \in \{4, 8, 16\}$ について $r_k = \text{round}(kd_0)$ とする (最近整数, 同距離なら偶数へ丸め, グリッドには合わせない)。各次元と各参照シードで全結合 AE を学習し, 固定 10,000 学習例で TwoNN と MLE を計算する。 R , A , $\hat{d}$ を計算する。
3. いずれかの検査が不合格なら ID 信頼性不足を記録し, 粗い部分集合を評価する。0 始まりの添字は $\text{round}(\text{geomspace}(1, |\mathcal{M}|, 4)) - 1$ の重複を除いた値である。検証 MSE が最小の候補を返し, 手順 6 へ進む。
4. それ以外は $m_0 = \min\{m \in \mathcal{M} : m \geq 2\hat{d}\}$ とし, 集合が空なら m_a とする。評価済み集合をアンカーで初期化し, 残りの $m \leq m_0$ を昇順に評価する。完了した呼出しが予算を超えたら停止する。
5. 評価済み集合内で目標を満たす最小次元を返す。それがアンカーなら小容量の代替なしと記録する。アンカーは常に適格なので, コードが予定した「適格な評価済み候補がない場合」の拡張分岐には入らない。
6. 返却次元の通常 VAE を取得または再利用する。 $m < 1$ ならモデルなしの退化出力を返す。モデルを返しても予算フラグは保持する。AU は m を変えない診断として記録する。
7. 未変換・最終次元, モデル指標, ID 診断, fallback・予算フラグ, 品質・圧縮指標, 費用計上を返す。

C.2 過去の損失尺度の監査

独自実装で 2 件の尺度不整合が見つかった。第 1 に, 以前の VAE 損失は潜在次元について KL を平均する一方, 再構成は入力次元について和を取っていた。代数的には $\beta_{\text{effective}} = \beta_{\text{nominal}}/m$ となる。本論文の画像結果は, 潜在次元について和を取るよう修正した規約から得たものである。この代数的関係は, β の名前を変えるだけで最適化過程全体や AU 数が再現されることを意味しない。以前の「1.7 ユニット以内」という主張は用いない。

第 2 に, 途中段階の GECO 変更実装は, 画素平均の制約値を, 尺度が整合しない他の項と組み合わせていた。修正した実装は二乗誤差和を用い, 画素平均の目標に入力次元数を掛ける。目的関数, 目標, 乗数の尺度が整合していれば, 和の規約も平均の規約も成立し得る。この hard-concrete 変更実装で観測した挙動を, 原著の ARM 実装に帰属させない。

C.3 過去の剪定・関連度変更実装

GECO 変更実装は, 学習率 10^{-3} の Adam, 保存順の 128 例バッチ, 300 epochs, hard-concrete のパラメータ $\gamma = -0.1$, $\zeta = 1.1$, 温度 2/3 を用いる。ゲートの初期対数オッズは 2 である。制約は再構成二乗誤差和から $D_{\text{input}}T_{D,s}$ を引いた値で, 移動平均係数は 0.99 とする。二乗 softplus による乗数を $[10^{-6}, 10^6]$ に制限し, 移動平均の制約違反量に対して上昇更新する。KL にはゲートマスクを適用し, 期待ゲート罰則は移動平均制約を満たす場合だけ有効にする。最終読み取りでは 0.5 を超える決定論的ゲートを数える。dSprites でも学習制約は二乗誤差和を用いるが, そこでの転用先通常 VAE はベルヌーイ再構成を用いる。したがって候補モデルの尤度規約から, 剪定段階の目的関数が同じであるとは言えない。

表 A11: 主条件での未変換の保持個数と、次元転用先の通常 VAE の次元数。制約は GECO 学習の最終更新時の移動平均、 Q は最終通常 VAE の検証品質であり、異なるモデル・量を評価する。ARD には GECO 制約はない。

データセット	変更実装	未変換個数	最終次元	制約	Q
MNIST	GECO	7.2 ± 0.4	6.4 ± 0.9	0/5	5/5
MNIST	ARD	6.0 ± 0.0	6.0 ± 0.0	—	5/5
Fashion-MNIST	GECO	4.2 ± 0.4	4.0 ± 0.0	1/5	5/5
Fashion-MNIST	ARD	3.8 ± 0.4	3.6 ± 0.9	—	4/5
dSprites	GECO	64.0 ± 0.0	64.0 ± 0.0	0/5	5/5
dSprites	ARD	9.2 ± 1.5	8.4 ± 1.7	—	0/5
CIFAR-10	GECO	20.0 ± 1.0	19.2 ± 4.4	5/5	2/5
CIFAR-10	ARD	14.2 ± 0.4	16.0 ± 0.0	—	0/5

過去の GECO 行の制約は、学習ミニバッチ上で事後分布から標本化した潜在変数と確率的 hard-concrete ゲートを用いる。これは、例当たりの二乗誤差和から決定論的な検証アンカー目標と入力次元数の積を引いた値の指数移動平均である。native モデルの検証再構成と推移は保存されていない。したがって最終制約達成数が MNIST 0/5, Fashion-MNIST 1/5, dSprites 0/5, CIFAR-10 5/5 であることだけでは、バグを特定することも、実装の妥当性を確認することもできない。

新しい MNIST 診断では、これら不足していた推移を保存する (図 A1)。評価には検証・test の全例を用い、事後平均または 32 回の事後標本化と、決定論的な連続ゲート値または明示的な二値マスクを組み合わせる。これらの評価量は、学習中の確率的ゲートによる再構成とは異なる。最終的な学習移動平均制約は二乗誤差和の単位で $+0.045$ 、計数ゲートは 7 個、乗数は 0.844 である。転用先のグリッド次元は 6 である。最終時点の学習制約はなお違反している。したがってこの診断により、HC 実装を妥当性確認済みの剪定基準と位置づけることはしない。

表 A12: 新しい MNIST の HC 診断と次元転用、シード 42。MSE は 10^3 倍し、同単位の目標は 25.223。HC 次元はゲート閾値を超える個数であるが、連続値での推論では非二値ゲート値も保持する。標本評価は潜在変数 32 標本と決定論的連続ゲートを用いる。通常 VAE は最近傍のグリッド次元を使う。

出力・再構成	次元数	検証 MSE	test MSE	Q
HC：連続/平均	7	22.424	21.950	はい
HC：連続/標本	7	27.019	26.519	いいえ
HC：二値/平均	7	22.424	21.950	はい
次元転用後の通常 VAE	6	22.343	21.933	はい

ARD 変更実装は、学習配列の先頭 10% (1800 例) を事前分布の推定に確保し、残りで学習する。10 epochs ごとと学習終了後に $p_j = \text{mean}(\mu_j^2 + \sigma_j^2)$ を更新し、 $[10^{-6}, 10^6]$ に制限する。これは固定部分集合で解析的な事後 2 次モーメントを使うものであり、符号化データ集合を定期的に再標本化するものではない。選択段階の学習は、再構成と重み 1 のガウス KL を用いる。先頭 512 学習例について次式を計算する。

$$w_j = \text{mean}_{x,k} [g_k(\mu(x) + \sqrt{p_j} e_j) - g_k(\mu(x))]^2, \quad q_j = w_j p_j, \quad (\text{A1})$$

スコアを降順に並べ、合計の 99% に達する最小の個数を残す。この有限差分は刻み幅の二乗で割っていない。局所的には既に p_j の因子を含むため、さらに p_j を掛けると、ヤコビアン の二乗と分散の積によるスコアとは異なる。したがって保存個数は ARD 変更実装と呼び、文章の修正だけでこの相違は解




図 A1: 新しい MNIST の hard-concrete 実装診断。シード 42, 300 epochs。学習制約は標本化した潜在変数とゲートを用い、検証は事後平均を用いる。制約と再構成の推移に加え、ゲート数と乗数を示す。独自 HC 実装の 1 実行であり、原著 ARM の再現ではない。

消できない。ガウス近似自体は原著からの逸脱ではない。条件間で関連度配列と個数が同じであることを数値監査で確認した。これは固定設定の反復であり、 β の走査ではない。

保存された q_j と p_j があれば、checkpoint なしでも有限刻み幅の余分な因子を除ける。 $h_j = \sqrt{p_j}$ とすると、正しく正規化した有限刻み幅のスコアは次式となる。

$$\tilde{q}_j = p_j \operatorname{mean}_{x,k} \left[\frac{g_k(\mu + h_j e_j) - g_k(\mu)}{h_j} \right]^2 = \frac{q_j}{p_j}. \quad (\text{A2})$$

保存された p_j はすべて正である。累積 99% の個数を再計算し、同じ最近傍グリッド規則で次元を転用する。表 A13 では、CIFAR-10 の未変換個数の平均は 14.2 から 26.0 へ変わり、24 次元へ写すと 5 試行すべてで Q を満たす。これは保存数値の精度の範囲での、有限刻み幅の読み取りに対する代数的修正である。刻み幅が大きい可能性と事前分布更新の変更は残るため、厳密なヤコビアンや原著 ARD のベンチマークではない。

表 A13: 主条件の保存スコアと事前分散から修正した、有限刻み幅の関連度読み取り。同じ保存摂動を刻み幅の二乗で正規化してから分散で重み付けし、新しい ARD 学習は行わない。検証するのは代数的な読み取り修正であり、厳密なヤコビアン関連度や原著学習手順ではない。test MSE (10^3 倍) は次元転用先の通常 VAE の値。

データセット	修正前個数	修正後個数	転用次元	Q	test MSE
MNIST	6.0 ± 0.0	6.2 ± 0.4	6.0 ± 0.0	5/5	22.05 ± 0.17
Fashion-MNIST	3.8 ± 0.4	4.0 ± 0.0	4.0 ± 0.0	5/5	19.06 ± 0.25
dSprites	9.2 ± 1.5	10.6 ± 0.5	10.0 ± 0.0	0/5	1.47 ± 0.05
CIFAR-10	14.2 ± 0.4	26.0 ± 0.0	24.0 ± 0.0	5/5	15.36 ± 0.13

追加の厳密ヤコビアン実験は 6.5 節で別に報告する。これらは過去の記録を置き換えるものではない。

FONDUE の記述に基づく分類器は、公開リポジトリ https://github.com/bonheml/VAE_learning_dynamics の commit f6d6e66b536bcbe635392d3438338949d4dc8730 と照合した。独自実装は、1 回の指数変換による事後分散の分類と TwoNN を用いる。公開コードの実行経路や元の実験設定との同等性は主張しない。過去の参照値として、原著は 1 epoch の dSprites 選択を 12.2 ± 0.4 と報告する [4] が、本研究の $\beta = 1$ では 4.2 ± 0.4 である。条件が揃っていないこの差は、実装誤りの証拠でも、元のベンチマークの再現でもない。別の制御フロー検査では、保存された ID 差系列に対し、原著アルゴリズムの上下限更新を再実行した。FONDUE の全 100 経路と返却次元が疑似コードと一致し、通常終了した。この検査は、それらの入力に対する探索更新ロジックを検証するものであり、推定量の実装、学習フレームワークの同等性、公表ベンチマークを検証するものではない。行ごとの結果を `results/make51/fondue_control_flow.json` に含める。

C.4 閾値のみの解析と品質許容幅の解析

事後的予測解析は Python 3.11.11, NumPy 2.3.2, scikit-learn 1.7.1 を用いる。表 A14 は、この再構成での確率飽和を示す。元の予測器の完全な環境と行ごとの確率は保存されていないため、集計値だけからその浮動小数点結果を厳密に確認できない。今回の再構成の行ごとの決定スコアと確率は `results/make51/au_predictions.csv` に保存する。

表 A14: 今回の予測器再構成における確率の数値飽和。AUROC 計算前にちょうど 1 へ丸められた予測の件数を示す。決定スコアではこれらの行の順位が保持される。

評価条件	基準	基準 + AU	基準 + 無作為
dSprites	55/55	44/55	49/55
Fashion-MNIST	0/55	0/55	0/55
CIFAR-10	45/45	40/45	36/45

本文の AU 閾値図では、3 つの δ すべてに同じ checkpoint を用いる。重み列全体について、CIFAR-10 のグリッド・シード候補のうち、AU が容量に等しい割合を以下に示す。各 β で 10 次元数と 5 シードを用いた件数であり、50 個の独立したデータセットではない。

表 A15: CIFAR-10（ガウス尤度）で、AU が容量に等しい候補の割合（%）。分母は次元数・シードの 50 候補であり、各列では同じ checkpoint から各閾値の個数を読み直す。

δ	$\beta = .25$	.5	1	2	4
0.001	100	100	100	98	60
0.01	60	50	36	22	10
0.1	48	38	32	20	10

別の事後的な品質許容幅検査では、 $\beta = 1$ の保存済み全グリッドを固定し、再学習やアンカー変更をせず、各許容幅で目標を満たす最小次元を読み取る。表 A16 はこの全グリッド基準を報告するもので、制限された探索窓の選択器の経路や費用を報告するものではない。FONDUE の閾値や ARD の 99% 基準に対する感度学習は実行していないため、それら独自の読み取り閾値への応答は主張しない。

表 A16: $\beta = 1$ で相対許容幅を変えた場合の、品質を満たす最小の保存次元数。5 シードの平均 $\pm$ SD。検証分散の 0.001 倍という絶対下限は固定する。dSprites はベルヌーイ、他はガウス尤度。

データセット	1%	5%	10%	25%	50%
MNIST	6.0 ± 0.0	6.0 ± 0.0	6.0 ± 0.0	4.0 ± 0.0	4.0 ± 0.0
Fashion-MNIST	4.0 ± 0.0	4.0 ± 0.0	4.0 ± 0.0	4.0 ± 0.0	2.0 ± 0.0
dSprites	51.2 ± 17.5	36.0 ± 16.5	20.0 ± 4.0	12.0 ± 0.0	9.6 ± 0.9
CIFAR-10	41.6 ± 8.8	32.0 ± 0.0	24.0 ± 0.0	16.0 ± 0.0	16.0 ± 0.0

D 合成データの尺度・除去診断

Swiss roll の点は $(t \cos t, h, t \sin t)$ で、 $t \sim U[1.5\pi, 4.5\pi]$, $h \sim U[0, 1]$ とする。トーラスの点は $((3 + \cos \phi) \cos \theta, (3 + \cos \phi) \sin \theta, \sin \phi)$ で、角度は独立に $[0, 2\pi]$ 上の一様分布から得る。各データは 5000 例、生成シード 0 とし、座標ごとに独立な標準偏差 0.01 のガウス雑音を加える。先頭 4500 例を適合、残り 500 例を報告する診断に用いる。保存実験では、各座標の標準化を分割前の全 5000 例に適合した。これを前処理の情報漏洩として明示し、結果は記述的なものであり、情報漏洩のない独立 test 推定値とは扱わない。

全結合 VAE は幅 128, 64 と逆順の復号器、隠れ層の ReLU, 線形出力, Adam の学習率 10^{-3} , バッチ 128, 300 epochs, $\beta = 1$, シード 42, 123, 777 を用いる。最後の checkpoint で、500 診断例上の事後平均分散が 0.01 以下の座標をゼロにし、同じ例上で MSE を再計算する。表 A17 は標準化した実行を報告する。この保存実験には別の test 集合はない。

表 A17: 合成データの尺度・除去診断。ガウス尤度, $\beta = 1$, $\delta = 0.01$, 3 学習シード。標準化は分割前に行ったため, 記述的な検証結果であり, 情報漏洩のない汎化推定ではない。変化は実行ごとの MSE 相対変化の平均 (%)。

データ	m	AU	除去前 MSE	除去後 MSE	変化
Swiss roll	1	1.0 ± 0.0	0.3511 ± 0.0267	0.3511 ± 0.0267	+0.000
Swiss roll	2	2.0 ± 0.0	0.1997 ± 0.0177	0.1997 ± 0.0177	+0.000
Swiss roll	3	3.0 ± 0.0	0.1407 ± 0.0018	0.1407 ± 0.0018	+0.000
Swiss roll	4	3.0 ± 0.0	0.1404 ± 0.0136	0.1406 ± 0.0135	+0.147
Swiss roll	6	3.0 ± 0.0	0.1365 ± 0.0023	0.1368 ± 0.0022	+0.183
Swiss roll	8	3.0 ± 0.0	0.1437 ± 0.0089	0.1440 ± 0.0089	+0.165
トーラス	1	1.0 ± 0.0	0.3217 ± 0.0163	0.3217 ± 0.0163	+0.000
トーラス	2	2.0 ± 0.0	0.1654 ± 0.0242	0.1654 ± 0.0242	+0.000
トーラス	3	3.0 ± 0.0	0.1083 ± 0.0036	0.1083 ± 0.0036	+0.000
トーラス	4	3.0 ± 0.0	0.1124 ± 0.0050	0.1124 ± 0.0050	+0.063
トーラス	6	3.0 ± 0.0	0.1095 ± 0.0035	0.1096 ± 0.0035	+0.107
トーラス	8	3.0 ± 0.0	0.1104 ± 0.0069	0.1105 ± 0.0069	+0.156

雑音のない両生成曲面の内在次元は 2 であり, ここでは 3 次元の外部座標で表現されている。だからといって, Swiss roll のパッチの最小埋め込み次元が 3 になるわけではない。この損失のもとで活性座標が 3 個観測されることは, 位相の定理ではない。以前の原稿は合成座標を標準化したと記載していたが, 実装監査ではその記述と実行された前処理の不一致が見つかった。未標準化の Swiss roll では高さ座標の分散が他の座標よりはるかに小さく, 二乗誤差上はその省略が安価になる。この尺度の観測だけで, 以前の AU 結果すべての因果説明が完了するわけではない。

E 新しい MNIST モデルの記録

新実験は, 候補となる 12 通りの次元数すべて, 学習シード 42, 固定シードから再構成した元の分割を用いる。モデル構造と目的関数は通常の MNIST 手順に一致するが, CPU 環境は過去の CUDA 実行と異なる。表 A18 に, 各 proxy 選択 checkpoint の検証基準をすべて示す。MC SE は, 事後標本化による評価雑音だけを表す。容量選択を固定したファイルを, 最終 test 評価に先立って保存する。重み, epoch 曲線, 標本化ごとの ELBO 平均を査読用補足資料に含める。この 1 シード検証から, 学習シード間の信頼区間は推論しない。

表 A18: 新たに学習した MNIST の全グリッド。シード 42, $\beta = 1$, ガウス尤度。選択 epoch は決定論的 proxy で選び, 停止 epoch は実際の学習最終時点。proxy はガウス正規化定数と事後期待値を省くが, MC ELBO は両方を含む。MSE は 10^3 倍。

次元数	選択 epoch	停止 epoch	検証 MSE	proxy	MC ELBO $\pm$ SE
2	81	111	37.406	-34.647	-484.386 $\pm$ 0.009
4	85	115	27.840	-29.304	-480.108 $\pm$ 0.009
6	169	199	22.343	-26.696	-478.174 $\pm$ 0.010
8	73	103	22.417	-26.544	-478.285 $\pm$ 0.009
10	70	100	22.954	-26.663	-478.627 $\pm$ 0.009
12	196	226	20.983	-26.055	-478.067 $\pm$ 0.012
16	107	137	23.030	-26.774	-478.592 $\pm$ 0.009
20	144	174	21.327	-26.156	-478.134 $\pm$ 0.010
24	132	162	22.977	-26.956	-478.664 $\pm$ 0.008
32	136	166	23.402	-27.042	-478.869 $\pm$ 0.012
48	114	144	24.177	-27.411	-479.310 $\pm$ 0.013
64	217	247	22.930	-26.946	-479.043 $\pm$ 0.011




図 A2: 新しい MNIST のシード 42, 6 次元と 64 次元の学習・検証 MSE。ガウス尤度, $\beta = 1$ 。学習曲線は固定 2000 例の部分集合, 検証は分離した全 2000 例を用いる。黒い十字は proxy 選択 epoch。新たに保存した実行であり, 過去の CUDA checkpoint の学習曲線を復元したものではない。

F 追加 GPU 検証記録

表 A19 で過去と追加の読み取り値を比較する。ARM の dSprites 平均は 54.0 であり, 過去の HC 個数 64 とは異なる。過去の未正規化 CIFAR-10 ARD 個数は 14.2 だったが, その正規化監査ですでに 26.0 へ修正されていた (表 A13)。新しい厳密ヤコビアン個数は, この修正後の結果に近い。学習と事前分布更新も変わっているため, 14.2 からの差全体をヤコビアン計算だけでは帰属できない。

表 A19: 未変換の次元読み取り値。過去の HC・未正規化有限刻み幅 ARD (5 シード) と、新しい ARM・厳密ヤコビアン ARD (3 シード) の比較。平均 ± 標本 SD。学習・読み取り設定が異なるため、すべての差を推定器だけに帰属できない。過去の有限刻み幅 ARD の修正後結果は表 A13 に保持する。

データセット	HC ($n = 5$)	ARM ($n = 3$)	旧 ARD ($n = 5$)	厳密・ゼロ	厳密・標本
MNIST	7.2 ± 0.4	7.7 ± 0.6	6.0 ± 0.0	6.0 ± 0.0	6.0 ± 0.0
Fashion-MNIST	4.2 ± 0.4	4.7 ± 0.6	3.8 ± 0.4	4.0 ± 0.0	4.0 ± 0.0
dSprites	64.0 ± 0.0	54.0 ± 7.2	9.2 ± 1.5	9.0 ± 0.0	9.7 ± 0.6
CIFAR-10	20.0 ± 1.0	21.0 ± 2.6	14.2 ± 0.4	26.7 ± 0.6	26.3 ± 0.6

新しい記録は、ARM および ARD の各分散更新設定について、各データセット 3 シードからなる。表 A20 のゲート区分と図 A3 の個々の制約推移は、閾値を超えた次元数だけでは剪定の成功を診断できない理由を示す。特に dSprites では、明確な二値ゲート構成にも制約充足にも近づかない。

表 A20: 300 epochs 後の ARM ゲート確率。中間は $0.1 \leq p \leq 0.9$ ，他の区分は厳密不等号を用いる。期待値は $\sum_j p_j$ ，個数は $p_j > 0.5$ で数える。dSprites のゲートはどちらの極端な区分にも達しないため、閾値個数を安定した二値構造と解釈すべきではない。

データセット	シード	$p < 0.1$	中間	$p > 0.9$	期待値	個数
MNIST	42	56	0	8	8.33	8
MNIST	123	56	1	7	8.11	8
MNIST	777	57	0	7	7.34	7
Fashion-MNIST	42	59	0	5	5.32	5
Fashion-MNIST	123	59	0	5	5.30	5
Fashion-MNIST	777	60	0	4	4.35	4
dSprites	42	0	64	0	32.08	52
dSprites	123	0	64	0	32.20	62
dSprites	777	0	64	0	32.05	48
CIFAR-10	42	236	1	19	25.65	19
CIFAR-10	123	230	3	23	30.27	24
CIFAR-10	777	235	1	20	26.18	20

図 A4 および図 A5 に、全 4 データセットの評価モードでの再構成曲線を示す。これらは提供された 300 epochs の実行を記述するものであり、曲線が視覚的に平坦でも最適性を保証しない。ARD の図はゼロ中心の分散更新を用いる。標本平均を中心とする変種を含む全 24 件の ARD 曲線記録は補足資料に収録する。

表 A21 に、固定した最終 native モデルと転用先の通常次元における、分離した test 再構成を示す。選択には制約または検証データに基づく関連度読み取りを用い、これらの test 指標は用いない。ARD の全次元モデル列を、選択された native 次元での品質と明確に区別する。




図 A3: 新しい ARM 各シードの確率的学習制約の移動平均。5 epochs ごとに記録した。ゼロが制約境界で、負値は制約充足を表す。大きな正の違反量と負値を表示するため、縦軸は対称対数尺度とする。これらの推移は、決定的な検証目標の達成とは異なる。

表 A21: test MSE (10^3 倍)。3 シードの平均 $\pm$ 標本 SD。ARM の native 評価は二値ゲートマスクと事後平均を用いる。ARD の native 評価は未剪定の全次元モデルを用いる。転用先通常 VAE は過去の候補キャッシュから再利用したもので、その test 集計は新しい未変換個数の選択に用いていない。

データセット	実装	native / 全次元	転用
MNIST	ARM	21.35 $\pm$ 0.25	21.22 $\pm$ 0.79
MNIST	ARD・ゼロ	22.97 $\pm$ 0.53	22.15 $\pm$ 0.14
MNIST	ARD・標本	23.17 $\pm$ 0.17	22.15 $\pm$ 0.14
Fashion-MNIST	ARM	19.01 $\pm$ 0.23	18.94 $\pm$ 0.23
Fashion-MNIST	ARD・ゼロ	18.97 $\pm$ 0.17	18.94 $\pm$ 0.23
Fashion-MNIST	ARD・標本	19.17 $\pm$ 0.15	18.94 $\pm$ 0.23
dSprites	ARM	42.10 $\pm$ 0.00	1.17 $\pm$ 0.04
dSprites	ARD・ゼロ	1.32 $\pm$ 0.01	1.86 $\pm$ 0.09
dSprites	ARD・標本	1.32 $\pm$ 0.06	1.61 $\pm$ 0.30
CIFAR-10	ARM	15.60 $\pm$ 0.59	16.74 $\pm$ 1.21
CIFAR-10	ARD・ゼロ	14.55 $\pm$ 0.13	15.42 $\pm$ 0.13
CIFAR-10	ARD・標本	14.64 $\pm$ 0.24	15.42 $\pm$ 0.13

表 A22 は、記録された所要時間の構成要素を示す。出所記録には NVIDIA GPU とソフトウェア環




図 A4: その時点の二値ゲートマスクを用いた native ARM の事後平均 MSE。学習 2000 例の部分集合と検証分割で 5 epochs ごとに評価した。線と陰影は 3 シードの平均と標本 SD。縦軸は対数尺度で、表示のため陰影の下限を正値に制限する。欠けている過去の通常 VAE 学習記録を再構成した曲線ではない。

境が記載されている。学習区間には定期評価を含む。ARD の初回・最終の事前分布更新と最終 native 評価は、表示した学習・ヤコビアン時間の区間には含まれない。ヤコビアン時間は検証 100 例と当該ネットワーク構造に対するものである。参照群、アンカー、転用、評価の費用に欠落があるため、これらを選択器の全費用と解釈したり、過去の CPU による ID 時間と合算したりすることはできない。




図 A5: ゼロ中心の分散更新を用いた、全次元 ARD の事後平均 MSE。5 epochs ごとに評価し、3 シードの平均と標本 SD を示す。縦軸は対数尺度。学習用プールの 2000 例の部分集合には、事前分布更新専用の 1800 例とパラメータ勾配学習に用いた 200 例が含まれるため、純粋な学習適合度の推定ではない。これらの評価では native モデルを剪定していない。

表 A22: 新しい GPU 剪定実験の記録時間内訳。単位は秒、3 シードの平均 ± 標本 SD。学習ループには定期的な学習・検証評価を含む。ARM の事後評価は最終 native 評価を含むが、ARD ではその時間を個別に記録していない（未記録）。アンカー、転用候補、その他の欠落費用は含まない。これらは完全な end-to-end 選択器費用ではない。

データセット	実装	学習ループ	ヤコビアン	事後評価
MNIST	ARM	197.8 ± 2.2	—	0.043 ± 0.000
MNIST	ARD・ゼロ	87.3 ± 0.3	0.011 ± 0.000	未記録
MNIST	ARD・標本	87.1 ± 0.7	0.012 ± 0.002	未記録
Fashion-MNIST	ARM	197.8 ± 1.5	—	0.043 ± 0.000
Fashion-MNIST	ARD・ゼロ	88.2 ± 0.5	0.011 ± 0.000	未記録
Fashion-MNIST	ARD・標本	88.0 ± 0.3	0.012 ± 0.002	未記録
dSprites	ARM	664.8 ± 0.3	—	1.264 ± 0.001
dSprites	ARD・ゼロ	299.2 ± 0.0	10.830 ± 0.169	未記録
dSprites	ARD・標本	299.2 ± 0.2	11.047 ± 0.712	未記録
CIFAR-10	ARM	328.4 ± 0.3	—	0.570 ± 0.001
CIFAR-10	ARD・ゼロ	146.2 ± 0.1	6.968 ± 0.452	未記録
CIFAR-10	ARD・標本	146.1 ± 0.1	7.505 ± 0.171	未記録

F.1 Native マスクと復号器微調整

表 A23 と表 A24 に、native 剪定の 4 条件についてシード別の検証記録と保持された test 集合の集計を示す。選択個数は先行する標本中心の実行と一致する。未剪定の検証・test MSE も一致するため、繰り返された基準値は追加の独立した根拠ではない。dSprites の test 平均は検証と同じ傾向を示し、マスク前 0.00132, マスク後 0.00294, 復号器微調整後 0.00178 となる。

表 A23: シードごとの native 剪定の検証 MSE (10^3 倍)。個数は関連度で選択した軸数, グリッドは転用先通常 VAE の次元数。全次元, マスク, 微調整は事後平均を用いる。標本マスクは微調整前の 32 事後標本による平均 MSE であり, ELBO でも標本アンカー目標による比較でもない。マスクそのものとモデル checkpoint は保存されていない。

データセット	シード	個数	グリッド	全次元	マスク	微調整	標本マスク
MNIST	42	6	6	23.762	23.772	23.445	27.040
MNIST	123	6	6	23.669	23.681	23.454	27.050
MNIST	777	6	6	23.410	23.420	23.175	26.896
Fashion-MNIST	42	4	4	19.336	19.340	19.158	21.573
Fashion-MNIST	123	4	4	19.452	19.456	19.248	21.732
Fashion-MNIST	777	4	4	19.496	19.496	19.176	21.563
dSprites	42	10	10	1.393	3.317	1.893	3.611
dSprites	123	10	10	1.278	2.783	1.727	3.084
dSprites	777	9	8	1.327	2.945	1.859	3.223
CIFAR-10	42	26	24	14.668	15.109	14.817	17.584
CIFAR-10	123	26	24	14.192	14.728	14.671	17.253
CIFAR-10	777	27	24	14.353	14.835	14.692	17.392

表 A24: Native 剪定の test MSE (10^3 倍)。3 シードの平均 $\pm$ 標本 SD。全列で事後平均による再構成を用いる。条件は表 11 と同じであり, test 指標は軸や固定微調整予算の選択に用いない。

データセット	全次元	マスク	微調整	Transfer
MNIST	23.17 $\pm$ 0.17	23.18 $\pm$ 0.17	22.90 $\pm$ 0.14	22.15 $\pm$ 0.14
Fashion-MNIST	19.17 $\pm$ 0.15	19.17 $\pm$ 0.15	18.93 $\pm$ 0.08	18.94 $\pm$ 0.23
dSprites	1.32 $\pm$ 0.06	2.94 $\pm$ 0.25	1.78 $\pm$ 0.07	1.61 $\pm$ 0.30
CIFAR-10	14.64 $\pm$ 0.24	15.14 $\pm$ 0.19	14.97 $\pm$ 0.08	15.42 $\pm$ 0.13

表 A25 は, 記録された 2 種類の時間区間を示す。先行する曲線取得実験とは異なり, 初期学習の時間区間は定期評価を含まず, 最後の事前分布更新を含む。最初の事前分布更新, ヤコビアン評価, マスク生成, 最終モデル評価は, 記録された時間区間の外である。したがって, 学習時間と微調整時間を足しても, 剪定の end-to-end 費用にはならない。提供されたスクリプトは 300 epochs の学習と 30 epochs の微調整プロトコルを定義するが, JSON には epoch カウンタや推移がない。これらの設定はスクリプトと内部仕様から記述したもので, 保存された学習履歴から独立に復元したものではない。

表 A25: Native 剪定実行の部分的な時間計測。単位は秒，3 シードの平均 $\pm$ 標本 SD。学習時間は最後の事前分布更新を含むが，最初の更新を含まない。微調整時間は復号器の 30 epochs のループのみを計測する。ヤコビアン・マスクの生成，最終評価，アンカーおよび転用先の学習は含まず，この実行では個別に計測していない。

データセット	学習区間	復号器微調整
MNIST	86.5 ± 0.7	5.9 ± 0.1
Fashion-MNIST	86.5 ± 0.4	5.9 ± 0.0
dSprites	289.0 ± 0.3	20.7 ± 0.0
CIFAR-10	142.3 ± 0.1	10.8 ± 0.0

記録された `elbo` と `val_elbo` 欄は，来歴のため未変更の `raw` ファイルに保持するが，新しいマスク記録も含め，`native ELBO` の測定値として用いない (5.5 節)。マスク後の `native MSE` は今回記録されたが，`checkpoint` と選択軸の識別子は保存されていない。したがって，集計だけからマスク，推論出力，修正された `native` 尤度を独立に再評価することはできない。解析的な ARM 勾配検査は成分を検証するもので，これらのモデル単位の記録を代替しない。

G 再現性のためのファイル一覧と残る記録

再集計の入口は `src/make51/rebuild_review.py` である。保存済み JSON と設定ファイルを読み，過去の記録から数値表，6 図，対応のある予測解析を出力する。新しい探索解析は `src/make51/replay_search.py`，限定的なモデル検証は `src/make51/validate_models.py` である。その出力は `src/make51/summarize_validation.py` で集計する。追加実行の再集計は `src/make52/summarize_revision.py`，`native` 剪定の再集計は `src/make53/summarize_native_pruning.py`，原稿の組立ては `src/make53/build_manuscript.py` である。生成された主 TeX は表の内容を埋め込み，図 PDF を参照する。英語版はプロジェクト直下で `pdflatex` を参照が確定するまで繰り返してコンパイルする。同梱の `MAKE53_reproducibility.zip` は，この一覧だけでなくファイル自体を提供する。README は軽量の再集計と任意の再学習を区別し，依存環境の版と利用できない過去の成果物を示す。MANIFEST.sha256 が収録内容を識別する。アーカイブは固定されたソースの snapshot を含み，非公開リポジトリへのアクセスなしで利用できる。

表 A26: 本改訂のソースと出力の対応。ディレクトリはプロジェクト直下からの相対表記。補足資料の README に個別ファイル名と再集計コマンドを示す。

証拠	ファイル・ディレクトリ
設定	config/
過去の手法・推移・診断記録	results/make49/
候補指標と潜在分散	results/make49/stage4_cache/
探索・AU・過去の監査の集計	results/make51/
別途の MNIST モデル・MC ELBO 記録	results/make51/model_validation/
判定付き開始点・ARM・ARD・native マスクの raw 記録	results/make52/
Native マスク集計・ソースハッシュ	results/make53/
過去と追加の学習コード	src/make49/;src/make52/
過去と追加の再集計	src/make51/;src/make53/
英語原稿テンプレート	src/make53/
日本語訳と検証	src/nn53/;results/nn53/
英語図	results/figures/MAKE51/;results/figures/MAKE52/
日本語図	results/figures/NN53/

手法単位の行の識別子は、データセット、手法、候補シード、 β または条件である。候補キーには次元数、指定 epoch 数、停止設定も含まれる。主たる手法記録の各設定・データセット・手法・条件の組合せに 5 シードがあることを、再集計中に確認する。ARD の反復によって、異なる選択重み条件が 5 個生じるわけではない。初期のグリッド外キャッシュ項目はすべて残っているわけではないが、最終指標と学習 trace は手法記録に残る。元の test 予測、過去の完全なモデル checkpoint、独立した ID・評価時間は、欠けたファイルから復元しない。

内部の変更記録には、9 月 12 日の初期仕様、崩壊診断後の dSprites のベルヌーイ尤度への変更、実現不能な検証 10,000 例の抽出から学習データの利用への ID 推定標本の変更、早期停止なしの推移実行、9 月 13 日の参照次元・実行費用計上・退化出力の明確化が記録されている。主要な予測解析の後には無作為特徴量対照を追加した。本改訂のアンカー費用補完、対応付き AU 推論、品質許容幅の読み直し、明示的実装監査は事後的である。いずれも公開の事前登録済み検定とは言い換えない。9 月 19 日の局所方策、閾値の全組合せ、正規化した ARD 読み取り、新たな 1 シード検証は、先の結果の後に仕様を定めた。補足資料には、それぞれの仕様と出力場所を保持する。

追加の開始次元数・剪定記録は、別途の事後解析である。再集計では、統合ファイルとデータセット別ファイルの一致、3 シードの網羅性、300 epochs の曲線終点、未変換個数の読み取り、アンカー目標、転用先キャッシュ指標を検査する。これは提供記録の整合性を検証するもので、利用できない checkpoint の再実行一致を検証するものではない。新しい native マスク監査ではさらに、12 件すべてをデータセット別ファイル、先行する標本中心の全次元モデルの MSE・個数、転用候補キャッシュと照合し、 Q と対応のある集計を再計算する。未保存のマスクや checkpoint テンソルは復元できない。

■日本語版の生成 日本語本文の組立ては src/nn53/build_japanese.py、図の表示文字の日本語化は src/nn53/render_figures.py による。日本語 TeX のコンパイルには、プロジェクト直下で lualatex main_paper_NN53.tex を参照が確定するまで繰り返す。日本語図は results/figures/NN53/ に保存する。

参考文献

- [1] Kingma, D.P.; Welling, M. Auto-encoding variational Bayes. In *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, Banff, AB, Canada, 14–16 April 2014. arXiv:1312.6114. <https://doi.org/10.48550/arXiv.1312.6114>.
- [2] Facco, E.; d’Errico, M.; Rodriguez, A.; Laio, A. Estimating the intrinsic dimension of datasets by a minimal neighborhood information. *Sci. Rep.* **2017**, *7*, 12140. <https://doi.org/10.1038/s41598-017-11873-y>.
- [3] Levina, E.; Bickel, P.J. Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems*, **2004**, *17*. <https://proceedings.neurips.cc/paper/2004/hash/74934548253bcab8490ebd74afed7031-Abstract.html>.
- [4] Bonheme, L.; Grzes, M. FONDUE: An algorithm to find the optimal dimensionality of the latent representations of variational autoencoders. arXiv **2022**, arXiv:2209.12806. <https://doi.org/10.48550/arXiv.2209.12806>.
- [5] Burda, Y.; Grosse, R.; Salakhutdinov, R. Importance weighted autoencoders. In *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, San Juan, Puerto Rico, 2–4 May 2016. arXiv:1509.00519. <https://doi.org/10.48550/arXiv.1509.00519>.
- [6] Bonheme, L.; Grzes, M. Be more active! Understanding the differences between mean and sampled representations of variational autoencoders. *J. Mach. Learn. Res.* **2023**, *24*(324), 1–30. <https://jmlr.org/papers/v24/21-1145.html>.
- [7] De Boom, C.; Wauthier, S.; Verbelen, T.; Dhoedt, B. Dynamic narrowing of VAE bottlenecks using GECO and L_0 regularization. arXiv **2020**, arXiv:2003.10901. <https://doi.org/10.48550/arXiv.2003.10901>.
- [8] Saha, S.; Joshi, S.; Whitaker, R. ARD-VAE: A statistical formulation to find the relevant latent dimensions of variational autoencoders. arXiv **2025**, arXiv:2501.10901. <https://doi.org/10.48550/arXiv.2501.10901>.
- [9] Tipping, M.E.; Bishop, C.M. Probabilistic principal component analysis. *J. R. Stat. Soc. Ser. B* **1999**, *61*, 611–622. <https://doi.org/10.1111/1467-9868.00196>.
- [10] Tenenbaum, J.B.; de Silva, V.; Langford, J.C. A global geometric framework for nonlinear dimensionality reduction. *Science* **2000**, *290*, 2319–2323. <https://doi.org/10.1126/science.290.5500.2319>.
- [11] Roweis, S.T.; Saul, L.K. Nonlinear dimensionality reduction by locally linear embedding. *Science* **2000**, *290*, 2323–2326. <https://doi.org/10.1126/science.290.5500.2323>.
- [12] Ceruti, C.; Bassis, S.; Rozza, A.; Lombardi, G.; Casiraghi, E.; Campadelli, P. DANCo: An intrinsic dimensionality estimator exploiting angle and norm concentration. *Pattern Recognit.* **2014**, *47*, 2569–2581. <https://doi.org/10.1016/j.patcog.2014.02.013>.
- [13] Johnsson, K.; Soneson, C.; Fontes, M. Low bias local intrinsic dimension estimation from expected simplex skewness. *IEEE Trans. Pattern Anal. Mach. Intell.* **2015**, *37*, 196–202. <https://doi.org/10.1109/TPAMI.2014.2343220>.

- [14] Costa, J.A.; Hero, A.O. Geodesic entropic graphs for dimension and entropy estimation in manifold learning. *IEEE Trans. Signal Process.* **2004**, *52*, 2210–2221. <https://doi.org/10.1109/TSP.2004.831130>.
- [15] Camastra, F.; Staiano, A. Intrinsic dimension estimation: Advances and open problems. *Inf. Sci.* **2016**, *328*, 26–41. <https://doi.org/10.1016/j.ins.2015.08.029>.
- [16] Allegra, M.; Facco, E.; Denti, F.; Laio, A.; Mira, A. Data segmentation based on the local intrinsic dimension. *Sci. Rep.* **2020**, *10*, 16449. <https://doi.org/10.1038/s41598-020-72222-0>.
- [17] Gałka, Ł.; Karczmarek, P.; Tokovarov, M. Isolation Forest Based on Minimal Spanning Tree. *IEEE Access* **2022**, *10*, 74175–74186. <https://doi.org/10.1109/ACCESS.2022.3190505>.
- [18] Ansuini, A.; Laio, A.; Macke, J.H.; Zoccolan, D. Intrinsic dimension of data representations in deep neural networks. In *NeurIPS 2019*, Vol. 32, 2019. https://proceedings.neurips.cc/paper_files/paper/2019/file/cfcce0621b49c983991ead4c3d4d3b6b-Paper.pdf.
- [19] Pope, P.; Zhu, C.; Abdelkader, A.; Goldblum, M.; Goldstein, T. The intrinsic dimension of images and its impact on learning. In *ICLR 2021*, 2021. arXiv:2104.08894. <https://doi.org/10.48550/arXiv.2104.08894>.
- [20] Rezende, D.J.; Viola, F. Taming VAEs. arXiv **2018**, arXiv:1810.00597. <https://doi.org/10.48550/arXiv.1810.00597>.
- [21] Louizos, C.; Welling, M.; Kingma, D.P. Learning sparse neural networks through L_0 regularization. In *Proceedings of the 6th International Conference on Learning Representations (ICLR)*, Vancouver, BC, Canada, 30 April–3 May 2018. arXiv:1712.01312. <https://doi.org/10.48550/arXiv.1712.01312>.
- [22] Obata, C.; Jin’no, K. Analysis of the relationship between manifold structure and latent space capacity of input data using VAE. In *Proceedings of the 2025 International Symposium on Nonlinear Theory and Its Applications (NOLTA2025)*, Okinawa, Japan, 27–31 October 2025; pp. 32–35. Publication record: https://www.comm.tcu.ac.jp/nel/list_j_2025.html (accessed on 18 September 2026).
- [23] Whitney, H. The self-intersections of a smooth n -manifold in $2n$ -space. *Ann. Math.* **1944**, *45*, 220–246. <https://doi.org/10.2307/1969265>.
- [24] Lucas, J.; Tucker, G.; Grosse, R.B.; Norouzi, M. Don’t blame the ELBO! A linear VAE perspective on posterior collapse. In *NeurIPS 2019*, Vol. 32, 2019. <https://proceedings.neurips.cc/paper/2019/file/7e3315fe390974fcf25e44a9445bd821-Paper.pdf>.
- [25] Rolinek, M.; Zietlow, D.; Martius, G. Variational autoencoders pursue PCA directions (by accident). In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA, 15–20 June 2019; pp. 12406–12415. <https://doi.org/10.1109/CVPR.2019.01269>.
- [26] LeCun, Y.; Bottou, L.; Bengio, Y.; Haffner, P. Gradient-based learning applied to document recognition. *Proc. IEEE* **1998**, *86*, 2278–2324. <https://doi.org/10.1109/5.726791>.

- [27] Xiao, H.; Rasul, K.; Vollgraf, R. Fashion-MNIST: A Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv* **2017**, 1708.07747. <https://doi.org/10.48550/arXiv.1708.07747>.
- [28] Krizhevsky, A. Learning multiple layers of features from tiny images. *Technical Report*; University of Toronto: Toronto, ON, Canada, 2009.
- [29] Matthey, L.; Higgins, I.; Hassabis, D.; Lerchner, A. dSprites: Disentanglement testing sprites dataset. 2017. Available online: <https://github.com/google-deepmind/dsprites-dataset> (accessed on 12 September 2026).
- [30] Fu, H.; Li, C.; Liu, X.; Gao, J.; Celikyilmaz, A.; Carin, L. Cyclical annealing schedule: A simple approach to mitigating KL vanishing. In *Proceedings of NAACL-HLT 2019*, Minneapolis, MN, USA, 2019; pp. 240–250. <https://doi.org/10.18653/v1/N19-1021>.